FoveaWAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景；然而推断场景运动多花的每一毫秒，都会让目标走得更远。世界—动作模型以统一的精细程度预测未来图像或隐变量，把时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器速度快，却忽略了约束或推动其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；周围物体只通过它们留下的间隙和传给目标的运动起作用；其余背景则与任务无关。我们提出 FoveaWAM，一个建立在这种按角色区分精度的 4D 结构之上的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，因此只需一帧 RGB-D 作为输入。它学习精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景，这些预测只在训练中使用。这些设计合在一起，使 FoveaWAM 在一块 RTX 5090 上 [XX] ms 即可输出动作，比视频世界—动作基线快 [N] 倍。我们还提出开源基准 ConMoto，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动。FoveaWAM 在 ConMoto 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在目标运动形式多样的六个真机任务上为 [XX]%。

1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[5, 6, 12, 20, 42, 48, 62]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。在这样的场景中，动作必须适合它执行那一刻的场景，而不是观测采集那一刻的场景，因此策略必须知道场景如何运动。这种认识本身需要推断，而推断需要时间，这段时间里场景仍在运动：策略为预判运动计算得越久，需要预判得就越远。

近期的动态策略加入了对过去运动的记忆（通常是光流等图像空间线索 [14, 27]）和对未来的预测 [27, 38, 55]。基于视频的 WAM 以统一的精细程度预测完整的未来帧或隐变量，把大量计算花在视觉细节上 [42, 48]。紧凑的未来编码 [28] 降低了这一开销，度量 3D 场景动力学 [53] 引入了几何，但两者仍对整个场景一视同仁。无论哪种情况，决定接触的量——动作执行时刻目标的度量位姿——仍然是隐式的。以目标为中心的预测器和预测物体层面未来的动态 VLA 位于另一端 [14, 17]：它们速度快，但只预判目标，把可能阻挡或改变其运动的周围环境排除在外。两类方法都没有按接触对场景各部分的要求来分配精度。由此引出一个核心问题：为了完成接触并保持较低的推理延迟，策略需要知道运动场景的哪些信息，又需要知道得多精确？

我们的关键观察是：动态策略需要精确知道的东西其实很少（图 1）。接触要求目标在动作执行时刻的位姿达到毫米级精度；周围物体只通过它们留下的间隙和传给目标的运动起作用，因此只需粗略地知道。基于这一观察，我们提出 FoveaWAM，一个学习按角色区分精度的度量 4D 表示的世界—动作模型，在接触需要之处保持精确（图 2）。为了在不编码过去图像帧的情况下获得运动信息，FoveaWAM 把单帧 RGB-D 与目标度量 SE(3) 位姿的一段短历史配对。世界流通过预测目标未来的 SE(3) 轨迹，以

图占位：概念图，设计待定

计划内容：一帧 ConMoto 画面，叠加其真实的训练标签，不使用生成图像。目标在采集时刻（实线）与指令生效时刻（半透明）的位置；目标在 8 个预测时域的 SE(3) 位姿（坐标轴）；14 × 14 个 patch 点上的稀疏 3D 流（箭头，在背景上接近于零）。任务、版式与样式待定。

图 1. **概念图（占位）**。图注将随最终图一并撰写。

及以稀疏 3D 流表示的整个场景的运动，来学习这一表示。动作流读取世界流的场景 token 与摘要 token 来生成动作块，显式预测只在训练中进行 [52]。因此，FoveaWAM 把对目标运动的精确预判与较低的推理延迟结合起来，限制了从观测到动作之间场景的变化。

我们构建了开源基准 ConMoto，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动，因此每个方法都要为自己的延迟付出代价。FoveaWAM 在 ConMoto 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms，比视频世界—动作基线低 [N] 倍。它在 24 个 DOMINO 任务 [14] 上同样领先，在六个真机任务上的试验成功率为 [XX]%，最强基线为 [XX]%。受控消融检验目标运动历史与未来监督的贡献，并比较按角色区分精度与统一精度的预测，以考察精度的分配。

我们的贡献有三点：

- 我们表明，动态策略只在动作执行时刻目标的位姿上需要毫米级精度，并把这一原理实例化为按角色区分精度的 4D 建模：为目标建立精确的度量 SE(3) 轨迹，为整个场景建立粗略的稀疏 3D 流。
- 我们提出 FoveaWAM，一个把目标的度量位姿历史与按角色区分精度的预测监督相结合、以低延迟生成动作的世界—动作模型。
- 我们提出开源动态操作基准 ConMoto，它为每个策略计入其自身的推理延迟；FoveaWAM 在 ConMoto、24 个 DOMINO 任务和六个真机任务上均优于强基线。

2 相关工作

动态操作。 补偿感知与执行之间的时间差是一个经典问题，从带纯滞后的控制 [35]，到用卡尔曼类滤波器跟踪目标并规划拦截的抓取系统 [1–3, 30]；这些系统精确，但针对每种物体和任务专门设计。近来，学习型策略开始进入运动场景 [46]。PUMA 读取历史光流，并以未来物体特征作为监督 [14]；DynamicWAM 以光流和运动学描述子为 WAM 提供条件，并以实时分块方式执行 [27]。两者都从图像空间线索中推断过去的运动，而 FoveaWAM 以目标的度量 SE(3) 位姿历史为输入，只观测当前一帧 RGB-D。另一些动态策略预测显著 token [38]、未来图像 [56]、紧凑的未来编码 [28] 或 3D 场景动力学 [53]，并在测试时以这些预测为条件生成动作。DynaWM 针对动态操作调整基础 VLA 的动作块 [10]，DynamicManip 从单条静态示范合成动态示范 [22]。执行调度方案通过让推理与执行重叠 [33, 46]、保持相邻动作块一致 [7, 25]，或以执行时刻为条件 [39]，来减小或掩盖延迟。它们决定的是动作何时计算、何时执行，而不是策略表示什么。DOMINO [14] 与 PhysMani-Bench [53] 提供了多样的动态操作任务，但它们公开的默认评测流程只在策略返回预测之后才推进仿真。ConMoto 则在推理期间推进场景，

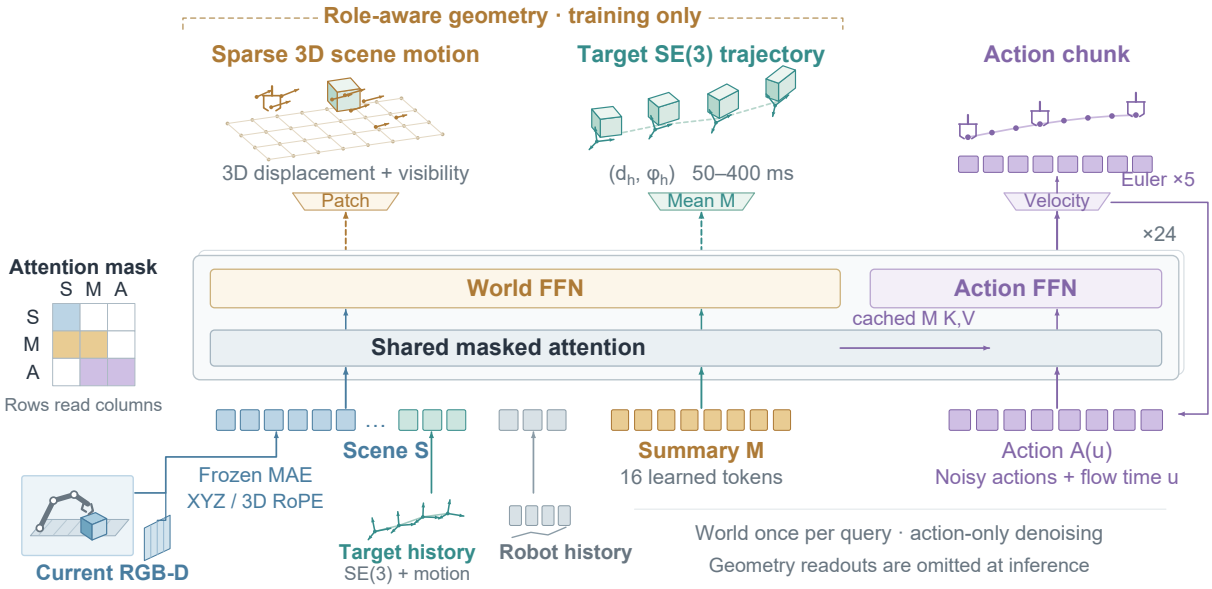


图 2. **FoveaWAM 架构。**自下而上阅读。当前 RGB-D 和目标、机器人状态历史输入世界流。世界流与动作流共享注意力，使用独立的 FFN。仅训练时使用的预测头（虚线）从 patch 状态预测全场景稀疏 3D 位移及可见性，从摘要均值预测目标 SE(3) 轨迹。动作通过结构化掩码读取场景与摘要 token。推理时，每次查询只计算一次场景与摘要 token 的键和值，在 5 个 Euler 步中复用，跳过预测头。几何图形为示意。

并让每个方法承担其实测延迟。

WAM 中的预测监督。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [21, 42, 48, 60]，其基础是把视频预测作为策略目标 [40, 45]。由于生成视频代价高，近期工作改变了预测的内容，例如动态区域、深度与语义特征 [55]，与 RGB 并列的光流和几何 [51]，物体掩码或物体槽 [26, 49]，以及紧凑隐变量 [37, 59]；它们也在追问测试时是否需要预测。Fast-WAM 在不做测试时想象的情况下保留了视频建模的大部分收益 [52]，PUMA 与 SG-WAM 则在训练后去掉预测器 [14, 57]。FoveaWAM 沿用这种只在训练中使用预测的方式，但主要预测的是度量 4D 状态，而不是像素、特征或隐变量，因此目标未来的位姿得到显式监督，而不是停留在隐式。

以物体为中心与基于几何的运动表示。 度量 3D 输入使策略更精确、样本效率更高 [32, 54]。运动已被表示为 2D 点轨迹 [4, 44, 47]、3D 流 [15, 18, 50, 53]，以及物体关键点或 SE(3) 轨迹 [17, 29, 36]；刚体分解也早已用于学习场景动力学 [8, 9]。这些工作用同一种表示描述场景：要么处处是稠密的流或轨迹，要么每个物体一个位姿。以目标为中心的预测器（包括预测物体层面未来的动态 VLA）只建模目标的未来 [14, 17]，把阻挡或推动目标的物体排除在外。DOCIR 把机器人、目标与障碍物分开，但只把这种区分用作输入编码 [13]。FoveaWAM 按角色分配精度：粗粒度的稀疏 3D 流描述整个场景，接触依赖毫米级精度的目标另由其 SE(3) 历史与预测描述。

3 FoveaWAM

我们把动态操作表述为：从一个表示生成按时刻索引的动作块（第 3.1 节），并在这些指令的执行时刻，用场景的稀疏 3D 流与目标的 SE(3) 轨迹监督该表示（图 2）。下文依次介绍度量输入（第 3.2 节）、这一监督（第 3.3 节），以及动作流如何读取该表示以生成动作块（第 3.4 节）。

3.1 问题形式化

我们研究场景在策略计算期间持续运动的操作。在第 t 次查询时，从示范中学得的策略 π 读取在时刻 τ_t 采集的 RGB 图像 I_t 与深度图 D_t，以及目标位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 的历史 $\mathcal{T}_t$ 与机器人状态的历史 $\mathcal{R}_t$，所有几何量都在机器人基座坐标系中表示，并输出一个包含 H 条指令的动作块：

$$(\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1}) \sim \pi\big(\cdot \mid I_t, D_t, \mathcal{T}_t, \mathcal{R}_t\big), \tag{1}$$

其中第 j 条指令对应时刻 $\tau_t + j\Delta_a$，Δ_a 为控制周期。

每个任务指定一个目标，机器人须在接触或容纳容差内对齐其位姿。起作用的周围物体构成环境：机器人须避开的障碍物，以及推动目标运动的驱动物。动作块要在推理完成后才可用，因此每条被执行的指令必须考虑目标与环境在其执行时刻、而不是 τ_t 时刻的状态。

3.2 度量场景与运动输入

FoveaWAM 精确编码目标的运动，并通过当前几何编码环境：当前 RGB-D 帧给出场景的度量布局，目标位姿的短历史给出单帧无法显示的运动，其中也反映了驱动物对目标的推动。

当前场景。 FoveaWAM 把每个 patch token 锚定在一个度量 3D 点上，使观测与预测、动作处于同一个基座坐标系中。冻结的 MAE ViT-B/16 [16] 把 RGB 图像编码为14×14 网格上的 196 个 patch token，深度图把 patch i 的中心反投影为基座坐标系中的点 $\mathbf{x}_i \in \mathbb{R}^3$。$\mathbf{x}_i$ 的线性嵌入加到 patch token 上，$\mathbf{x}_i$ 还驱动 patch 查询与键的 3D 旋转位置编码，使 patch 之间的注意力取决于它们的相对 3D 位置。这些点 $\mathbf{x}_i$ 也是场景流的源点（第 3.3 节）。

目标运动。 FoveaWAM 不使用过去的图像帧（从中恢复运动需要比较多帧图像），而是以度量 SE(3) 状态的形式接收目标近期的运动。目标历史以 20 Hz 的 8 次采样覆盖最近 350 ms；它的 8 个 token 包含当前目标位姿与相邻采样之间的七段运动，每段包含平移、相对旋转、时间间隔，以及以物理单位表示的有限差分速度与加速度。决定目标将到达何处的速度与加速度因此直接进入模型，代价只是几个低维 token；第 4.3 节去掉这段历史以衡量其作用。在仿真中，这些位姿来自仿真器；在真机上，由因果跟踪器从 RGB-D 流中估计。

世界流。 patch token、目标 token，以及编码目标历史各采样时刻末端执行器状态的 8 个机器人 token，共同组成 212 个场景 token。它们与汇聚它们的 16 个可学习摘要 token 一起构成世界流。

3.3 按角色区分精度的 4D 预测监督

FoveaWAM 用两种精度不同的几何预测监督其表示：以 patch 网格上的稀疏 3D 流表示整个场景的运动；由于目标的位姿决定接触，还预测目标完整的 SE(3) 轨迹。两者都在基座坐标系中、以相对当前状态的变化表示于时刻 $\tau_t + \delta_h$，其中 $\delta_h = h{\cdot}50\,\mathrm{ms}$，$h = 1, \ldots, 8$，即采集后 50 ms 到 400 ms；连同当前状态，这些时域覆盖动作块中所有指令的执行时刻。

场景流。 在 patch 网格的分辨率上，场景流覆盖 patch 所见的每个表面：机器人、目标，以及指令必须考虑其间隙与运动的环境。对 196 个点 $\mathbf{x}_i$ 中的每一个和每个时域 h，patch token i 最终状态上的线性

头预测该点在基座坐标系中的位移 $\hat{F}_{ih} \in \mathbb{R}^3$ 与可见性 logit $\hat{o}_{ih}$，以如下损失训练：

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h)\in\mathcal{V}_F} \Big[\tfrac{1}{3} \big\| (\hat{F}_{ih} - F_{ih})/s \big\|^2 + \mathrm{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \tag{2}$$

其中 F_{ih} 为 $\mathbf{x}_i$ 处表面点的位移，o_{ih} 为其可见性，s 为在训练标签上拟合的固定尺度，$\mathcal{V}_F$ 为有效标签集合。

目标轨迹。 场景流只在目标覆盖的少数几个 patch 上采样目标，过于稀疏，无法确定其旋转，因此由摘要 token 最终状态均值上的一个专用线性头直接预测目标的刚体运动：对每个时域 h，预测目标的位移 $\hat{\mathbf{d}}_h$ 与旋转增量 $\hat{\phi}_h$，以如下损失训练：

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h\in\mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\mathrm{SO(3)}}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{3}$$

其中 $\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t)$ 与 $R_h = R(\tau_t{+}\delta_h)$ 为真实的位移与朝向，$\hat{R}_h = \mathrm{Exp}(\hat{\phi}_h^{\wedge}) R(\tau_t)$，$d_{\mathrm{SO(3)}}$ 为测地距离，$\mathcal{V}$ 为具有有效标签的时域集合。旋转项对接触很重要：旋转误差 θ 可使与目标原点相距 r 的接触点偏移至多 $2r\sin(\theta/2)$。例如，在 $r = 10\,\mathrm{cm}$ 处，5° 的误差可使接触点偏移近 9 mm。

3.4 世界—动作联合学习与推理

动作流。 动作流以条件流匹配 [23] 生成动作块。它包含 $H = 8$ 个 token，每个嵌入一条加噪指令：末端执行器的平移增量、旋转增量与夹爪指令。每一层中，一个注意力以共享的投影覆盖两条流，其后接各自独立的前馈网络；世界 token 使用层归一化，动作 token 使用以流时间为条件的自适应层归一化。记场景、摘要与动作 token 为 S、M 与 A，注意力掩码允许 $S \to S$、$M \to \{S, M\}$ 与 $A \to \{S, M, A\}$，其中 $X \to \mathcal{Y}$ 表示 X 中的 token 读取 $\mathcal{Y}$ 中的 token。世界流从不读取动作。动作流在每一层都同时读取受场景流监督塑造的 patch 状态与受目标轨迹监督塑造的摘要状态。

训练目标。 对以训练统计量归一化的动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与流时间 $u \sim \mathcal{U}[0, 1]$，动作流 v_ψ 回归流匹配速度：

$$\mathcal{L}_A = \mathbb{E}\,\mathrm{MSE}\big(v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t),\, \mathbf{a}_1 - \mathbf{a}_0\big), \tag{4}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为式 (1) 中的输入，MSE 在有效指令与动作维度上取平均。世界流与动作流以

$$\mathcal{L} = \mathcal{L}_A + \lambda_F \mathcal{L}_F + \lambda_P \mathcal{L}_P + \lambda_{\mathrm{aux}} \mathcal{L}_{\mathrm{aux}} \tag{5}$$

联合训练，其中 $\mathcal{L}_F$ 与 $\mathcal{L}_P$ 为式 (2) 与式 (3) 的流与位姿损失，$\mathcal{L}_{\mathrm{aux}}$ 为辅助外观损失之和。

推理。 部署时，FoveaWAM 跳过预测头，与近期的世界—动作模型相同 [21, 52, 55]。由于世界 token 既不读取动作，也不读取流时间，世界流每次查询只运行一次，动作流在场景与摘要 token 缓存的键和值上积分 5 个 Euler 步。指令按相对采集时刻的时间索引，因此策略不需要延迟输入：执行器在推理完成时或之后的第一个控制周期边界接收动作块，并从对应该边界的指令开始执行。在真机上，一次查询的延迟还包括在最新一帧中跟踪目标的时间。更多实现细节见补充材料。

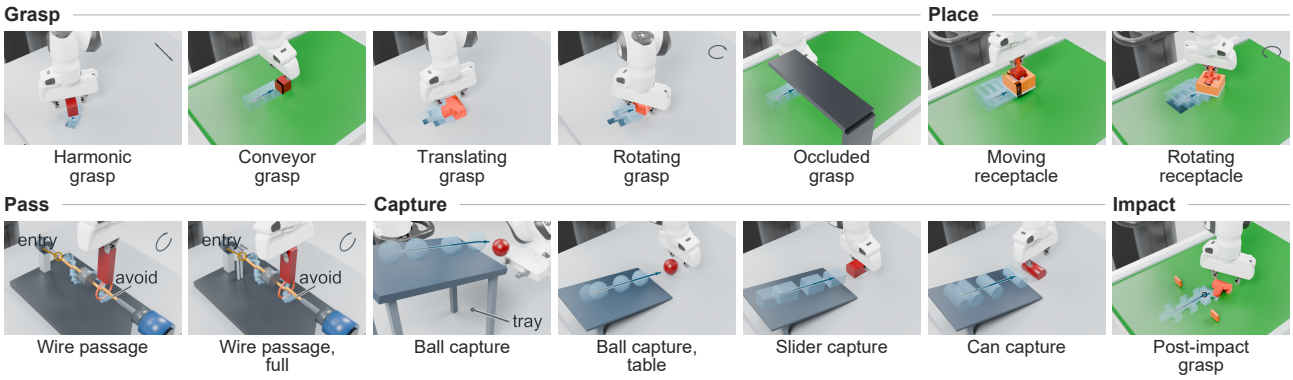


图 3. **ConMoto** 。采用统一主视角，从记录的仿真状态渲染五个任务族共 14 个任务。四个历史位姿以半透明蓝色显示，时间越早越淡；深蓝轨迹表示实测的过去运动。灰色角落箭头定性表示旋转或振荡，小圆圈标出记录到撞击时的目标中心。两个 Pass 子图均展示穿越阶段：导线在入口处是目标，沿途则是避碰障碍；Full 还要求获取、退出和释放。被遮挡的运动保持隐藏。这些原生专家示例用于展示任务动态，不代表 FoveaWAM 的执行结果，图中不显示未来预测。

4 实验

我们检验：当场景在推理期间持续运动时，按角色区分的精度与较低的延迟能否共同改善操作。我们先将 FoveaWAM 与已有策略比较，每个方法都承担自身的延迟（第 4.2 节）；再分析其设计中哪些部分带来了这些结果（第 4.3 节）；最后在使用跟踪目标位姿的真机上验证（第 4.4 节）。

4.1 实验设置

ConMoto 。 DOMINO [14] 与 PhysMani-Bench [53] 的评测器在策略返回预测之后才推进仿真；与之不同，ConMoto 让观测、场景运动与动作执行共用一个物理时钟，因此策略计算时场景继续运动。它包含五个任务族共 14 个任务，基于 MuJoCo/robosuite [41, 61] 构建：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（图 3）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个）上报告全部 ConMoto 结果。

评测。 每次查询期间，物理按该方法的推理延迟推进：延迟从该方法在其原生部署设置下、于一块 RTX 5090（我们机器人所用的 GPU）上以 batch 1 实测的延迟分布中抽取。所有方法共用同一个执行器，它从对应于动作块到达时那个控制周期边界的指令开始执行该动作块。除这一原生设置外，我们还为每个方法附加 150 ms 延迟，并以推理期间暂停物理作为不计计算代价的参照。我们报告任务等权的成功率（SR）与 p95 出动作时间，即从观测到其第一条指令可用的实测时间；配对 95% 区间由对留出场景的自助法得到。完整的评测协议见补充材料。

基线。 我们比较反应式策略 ACT [58] 与 Diffusion Policy [12] 及 VLA $\pi_{0.5}$ [5]；动态 VLA DynamicVLA [46] 与 PUMA [14]；WAM OpenWAM-α [42]；以及动态 WAM DynamicWAM [27]（表 1）。每个基线使用官方架构和任务适配后的配方，在相同示范上训练。FoveaWAM 接收单帧主视角 RGB-D 与目标的 SE(3) 历史，不使用过去的帧。为了让基线获得相同的目标运动信息，$\pi_{0.5}$ 与 DynamicWAM 还以接收我们 SE(3) 历史 token 的形式运行（+SE(3)）。

表 1. **ConMoto 上的结果。**1,400 个留出场景上按任务等权的 SR（%），分别为各方法的原生延迟、附加 150 ms，以及推理期间暂停物理。p95：各方法在一块 RTX 5090 上、按其原生部署设置测得的出动作时间。历史：当前帧之外携带过去运动信息的输入。OpenWAM-α 使用官方的缓存与编译，off 关闭两者。每列的最佳与次佳已标出。[一句结论，例如 FoveaWAM 以远低于 WAM 的延迟取得最高的原生 SR。]

	历史			SR (%) ↑			
方法	腕部 RGB	光流	SE(3)	原生	+150 ms	暂停	p95 (ms) ↓
ACT [58]				41.6	24.3	40.6	**5.8**
DP [12]	✓			30.7	15.9	31.0	68.9
$\pi_{0.5}$ [5]				**53.8**	27.8	66.0	59.6
$\pi_{0.5}$+SE(3)			✓	52.8	**28.2**	**74.9**	61.2
DynamicVLA [46]	✓			50.9	23.4	54.6	97.3
PUMA [14]		✓		—	—	—	—
OpenWAM-α [42]				46.1	24.7	58.3	151.7
OpenWAM-α (off)				15.8	10.4	58.3	466.3
DynamicWAM [27]		✓		40.5	20.6	49.1	149.6
DynamicWAM+SE(3)		✓	✓	36.8	21.9	64.1	153.3
FoveaWAM			✓	—	—	—	—

实现。 FoveaWAM 的 Transformer 共 24 层，宽度 1024，16 个注意力头，可训练参数 523.8M，建立在冻结的 MAE ViT-B/16 编码器之上。在 ConMoto 上，它从随机初始化开始，使用 AdamW 训练至多 20 轮，我们保留验证损失最低的检查点。

4.2 动态操作结果

与基线的比较。 在原生延迟下，FoveaWAM 在 ConMoto 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。由于 +SE(3) 基线接收相同的目标运动输入，后一差距衡量的是 FoveaWAM 的表示在这一输入之外带来的增益。它的 p95 延迟为 [XX] ms，是视频 WAM（OpenWAM-α 与 DynamicWAM）的 [X] 分之一，与 [最快的反应式策略，待定] 相近。优势最大的是 [任务类型]。

推理延迟的影响。 [计入计算时间会改变排序：] 推理期间暂停物理时，FoveaWAM 领先 [名称] [X.X] 个百分点，原生延迟下领先 [X.X] 个百分点，而视频 WAM 从 [XX.X]% 降至 [XX.X]%（表 1）。附加 150 ms 延迟拉长了每个方法需要预判的时长。FoveaWAM 保持 [XX.X]% 的 SR，而不预判目标运动的反应式策略，其速度误差在更长的延迟中累积，平均降至 [XX.X]%；本就较慢的视频 WAM 降至 [XX.X]%。图 4 将这一比较扩展到 0 至 200 ms：[趋势，例如差距随每档附加延迟扩大]。

DOMINO 上的结果。 为了在 ConMoto 之外检验这一设计，我们在 DOMINO [14] 的 24 个单臂 Franka 任务上，用其示范训练 FoveaWAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA，并用其原生评测器评测；与在 ConMoto 上一样，FoveaWAM 读取仿真器中的目标位姿。在已完成的基线中，DynamicWAM 的总体 SR 最高，为 29.3%，PUMA 与 $\pi_{0.5}$ 分别为 18.3% 和 17.3%（表 2）；$\pi_{0.5}$ 在拦截任务上最高，为 33.8%。[补入 FoveaWAM 已验收的结果及比较。] 更多结果见补充材料。

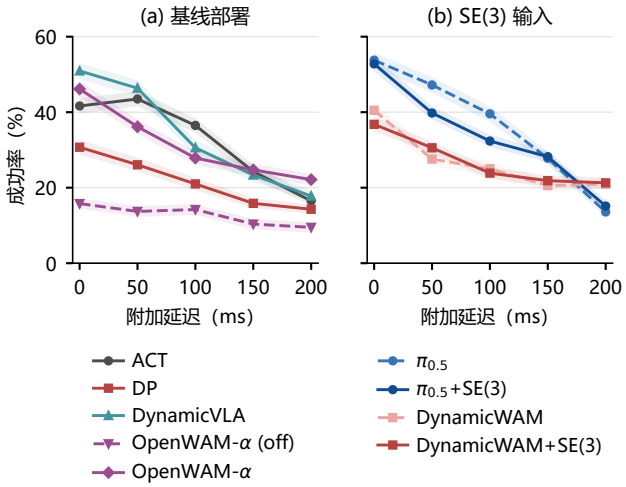


图 4. **附加延迟下的成功率。**在各方法原生延迟之上附加延迟时，1,400 个 ConMoto 留出场景上的 SR。(a) 基线，其中 OpenWAM-α 分别开启与关闭官方缓存和编译。(b) $\pi_{0.5}$ 与 DynamicWAM 加入与不加入 SE(3) 历史。阴影：配对 95% 场景自助法区间。

表 2. **DOMINO 结果：**24 个单臂 Franka clean-L1 任务，各方法一个训练种子、相同的 1,200 个测试场景（每任务 50 场）。拦截/跟踪包含 8/16 个任务；全部列对 24 个任务等权。SR 与 MS 均为 0–100 尺度，保留失败场次。已报告值中的最佳与次佳已标出，待填结果不参与排名。

方法	拦截	跟踪	全部↑	MS↑
$\pi_{0.5}$	**33.8**	9.1	17.3	31.1
DynamicWAM	18.3	**34.9**	**29.3**	**42.8**
PUMA	29.5	12.8	18.3	33.4
FoveaWAM	—	—	—	—

4.3 角色化建模分析

五个对照各改变 FoveaWAM 的一个部分，保持其数据与配方不变（图 5）。除无目标历史的对照外，每个对照只改变训练损失，而这些损失对应的预测头在部署时被跳过，因此其推理与 FoveaWAM 相同。我们依次报告每个对照在原生延迟与附加 150 ms 延迟下的 SR 变化。

精度的分配。 去掉专用 SE(3) 监督后，目标只剩下整个场景共有的统一粗粒度场景流监督，SR 分别下降 [X.X] 与 [X.X] 个百分点。去掉场景流监督后，目标保留其 SE(3) 轨迹，而场景其余部分（包括环境）失去运动监督，SR 分别下降 [X.X] 与 [X.X] 个百分点。两个消融与完整模型一样保留全部辅助目标。如果精度按角色分配，SE(3) 监督应在预先声明的旋转敏感任务上作用最大，而流监督应在环境活跃任务上作用最大，这些任务的环境约束机器人或推动目标。[图 5 是否呈现这一模式，以及它对精度分配意味着什么。]

目标运动历史。 移除过去的目标位姿及其速度、加速度特征，同时保留当前图像、当前目标位姿与机器人历史，SR 分别下降 [X.X] 与 [X.X] 个百分点。[下降幅度随附加延迟增大，] 这与历史提供目标速度的作用一致：延迟越长，速度误差累积得越远。由于历史依赖位姿估计，我们还对位姿施加扰动：在 [X mm 与 X°] 的合成时序相关位姿噪声下，FoveaWAM 的 SR 为 [XX.X]%，比无噪声位姿低 [X.X] 个百分点。

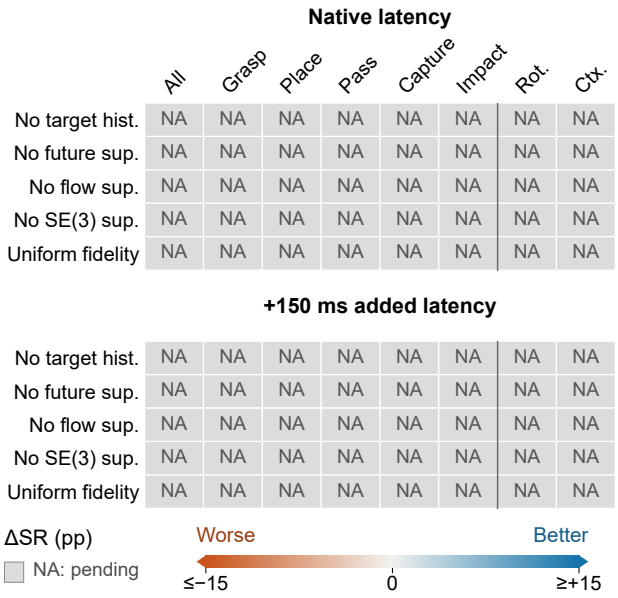


图 5. **按任务的消融效应（设计预览；数据待齐）。** ΔSR = SR(对照) − SR(完整模型)，单位为百分点；色阶在 ±15 处饱和。各行为第 4.3 节的五个对照；统一粗粒度流去掉专用 SE(3) 监督，使目标只接受整个场景共有的场景流监督。完整模型在原生延迟下的 SR 为 [XX.X]%，附加 150 ms 时为 [XX.X]%。Rot./Ctx. 分别表示预先声明、可重叠的旋转敏感组和环境活跃组（表 S3）。粗体：配对 95% 场景自助法区间不含零。NA：暂无数据。

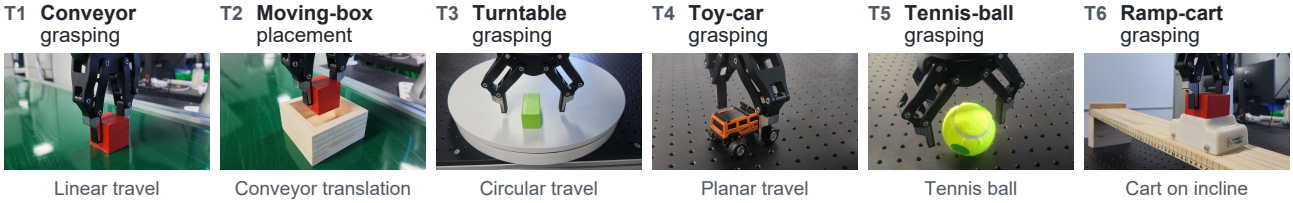


图 6. **真机任务场景。**六项任务的实拍照片：传送带抓取（T1）、向移动盒放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5）和斜坡小车载块抓取（T6）。

未来监督与辅助目标。 移除全部未来监督，即 SE(3)、场景流与未来外观目标，同时保留当前目标的重建，推理不变，但 SR 分别下降 [X.X] 与 [X.X] 个百分点，在 [目标做非匀速运动的任务] 上最明显。若改为移除辅助目标 $\mathcal{L}_{\text{aux}}$（包括当前目标重建）并保留两种几何预测，SR 变化 [X.X] 个百分点，[这对辅助目标的作用意味着什么]。离线评估中，学习得到的 SE(3) 预测也比对同一历史做匀速与匀加速外推更准确（400 ms 时 [X] mm，对比 [X] 与 [X] mm）。[用一句话概括哪些组件起作用、在哪里起作用。]

4.4 真机评估

设置。 我们在 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机上评估六个任务（图 6）：传送带抓取（T1）、向移动盒放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5），以及斜坡小车载块抓取（T6）。基线为仿真中最强的基线 $\pi_{0.5}$、低延迟的模仿学习策略 ACT，以及动态 WAM DynamicWAM。所有方法都在每个任务相同的 100 条遥操作示范上训练或微调（FoveaWAM 从一个在 DROID [19] 上预训练的 48 层基座出发），并以共享试验键各运行 20 次试验。基线接收 RGB[，若配方使用腕部相机则一并提供]；FoveaWAM 接收第三人称 RGB-D 帧与 FoundationPose [43] 的目标位姿估计，后者在每个控制周期边界、查询之前更新。

表 3. **真机结果。**第 4.4 节六个任务上的成功率（%），每个任务每个方法 20 次试验；All 合并全部试验。p95：在一块 RTX 5090 上实测的端到端出动作时间（ms），FoveaWAM 包含跟踪。每列最佳已标出，并列者同样标出。

方法	T1	T2	T3	T4	T5	T6	All ↑	p95 (ms) ↓
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
ACT	—	—	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	—	—

结果。 FoveaWAM 在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%，配对差为 [X.X] 个百分点（95% 区间 [[X.X, X.X]]；表 3）。包含跟踪在内，其 p95 延迟为 [XX] ms，[在一个控制周期之内]，而 [名称] 需要 [XX] ms。优势最大的是 [任务]。[表 1 的排序在真实感知下是否保持，以及跟踪带来的代价。][一个可由轨迹核实的接触实例：目标位姿、旋转或环境如何解释 FoveaWAM 的成功或基线的失败。]FoveaWAM 的主要失败模式是 [失败模式]。更多细节见补充材料。

5 结论

FoveaWAM 把精度花在接触所依赖之处：用度量 SE(3) 历史与预测表示目标，用稀疏 3D 流表示整个场景，并且预测只作为训练监督。当每个方法都承担自身的延迟时，这些设计让 FoveaWAM 既精确又迅速：它在 ConMoto 与六个真机任务上优于反应式策略、VLA 与世界—动作模型，包括为运动目标设计的模型，在 ConMoto 上的 p95 延迟为 [XX] ms；它在 DOMINO 上同样领先。[说明计入延迟后排序相对暂停评测有何变化。][一到两条最强的消融发现。] 我们将公开 ConMoto，使今后的动态策略在计入延迟的条件下评测。

局限性。 FoveaWAM 需要一个指定的刚体目标及可靠的位姿估计，其预测也忽略了机器人自身的接触如何改变目标的运动；学习以接触为条件的目标动力学是自然的扩展。目标轨迹预测头在每个时域只预测一个未来，因而无法表示多模态运动；不确定性感知的预测可以弥补这一点。我们的任务中没有独立于目标运动的环境；在这类场景中，环境同样需要运动历史，例如其场景流的历史。

LLM Usage Statement（大语言模型使用声明）

我们使用 OpenAI Codex 辅助文献调研、代码实现与调试、实验执行及论文语言润色。Codex 还用于辅助编写绘图代码，以及调整图表与论文排版。作者审阅了 AI 辅助生成或修改的内容，对照原始来源核查了参考文献，并通过测试与实验验证了实现。作者对最终稿件、实验结果和结论承担全部责任。

参考文献

[1] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[2] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. Wiley, 2001.

[3] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[4] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[5] Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *Proceedings of The 9th Conference on Robot Learning*, pages 17–40, 2025.

[6] Kevin Black, Noah Brown, Danny Driess, et al. π_0: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[7] Kevin Black, Manuel Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, pages 33383–33407, 2025.

[8] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, pages 173–180, 2017.

[9] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[10] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[11] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Joon-Young Lee, and Alexander Schwing. Putting the object back into video object segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[12] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[13] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 15873–15879, 2025.

[14] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. In *European Conference on Computer Vision*, pages 314–333, 2026.

[15] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *IEEE Robotics and Automation Letters*, 11(3):2466–2473, 2026.

[16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[17] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[18] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20765–20779, 2026.

[19] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[20] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, pages 2679–2713, 2025.

[21] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[22] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[23] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[24] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[25] Yuejiang Liu, Jubayer Hamid, Annie Xie, Yoonho Lee, Max Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, pages 4594–4627, 2025.

[26] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[27] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[28] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[29] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *Robotics Research: The 19th International Symposium ISRR*, pages 132–157. Springer, 2022.

[30] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[31] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, pages 28085–28128, 2025.

[32] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pages 785–799, 2023.

[33] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[34] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[35] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[36] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. In *European Conference on Computer Vision*, pages 437–453, 2026.

[37] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. In *Proceedings of the 43rd International Conference on Machine Learning*, pages 115917–115933, 2026.

[38] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. In *Conference on Robot Learning*, 2026. Accepted for publication.

[39] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[40] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, pages 92033–92052, 2025.

[41] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[42] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[43] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[44] Chuan Wen, Xingyu Lin, John Ian Reyes So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[45] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, pages 10641–10662, 2024.

[46] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[47] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, pages 2475–2499, 2025.

[48] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[49] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[50] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2025.

[51] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[52] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[53] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. In *European Conference on Computer Vision*, pages 20–39, 2026.

[54] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[55] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[56] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[57] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[58] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[59] Ruijie Zheng, Jing Wang, Scott Reed, et al. FLARE: Robot learning with implicit world modeling. In *Proceedings of The 9th Conference on Robot Learning*, pages 3952–3971. PMLR, 2025.

[60] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[61] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

[62] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183, 2023.

A 方法与训练细节

A.1 架构

表 S1 按下文所述的数据流顺序列出各模块的配置。

表 S1. FoveaWAM 的架构。各预测头在部署时被跳过。

模块	配置
视觉编码器	冻结的 MAE ViT-B/16，输入 224×224，196 个 patch token
目标状态编码	$28 \to 1024 \to 1024$ GELU MLP，加性相对时间嵌入
机器人状态编码	线性，$7 \to 1024$
Token	212 个场景（196 个 patch、8 个目标状态、8 个机器人）、16 个摘要、8 个动作
主干	24 层，宽度 1024，16 个注意力头，共享注意力，每个流的 SiLU 前馈 4096，504.0M 参数
位姿头	线性，摘要状态均值 $\to 8 \times 6$
流预测头	每个 patch token 上的线性读出，$8 \times (3{+}1)$
外观预测头	每个 patch token 上的线性读出：深度与运动表面 RGB 以 16×16 像素输出，1024 维 DINOv3 ViT-L/16 特征
目标重建	$1024 \to 256 \to 3072$ GELU MLP 加 sigmoid，32×32 RGB
动作流	流匹配，以流时间做自适应层归一化，5 个 Euler 步

场景 token。 冻结的 MAE ViT-B/16 [16] 输出的每个 patch token 加上一个可学习的视角嵌入，以及其平均有效度量深度和其中心像素反投影后基座坐标系位置 $\mathbf{x}_i$ 的线性嵌入；中心像素没有有效深度的 patch 不加位置嵌入。只有 patch 的 query 与 key 使用由 $\mathbf{x}_i$ 驱动的 3D 旋转位置编码，同样的点也是稀疏 3D 流的源点。过去的图像从不进入模型。

状态 token。 8 个目标状态 token 在偏移 $-350, -300, \ldots, 0$ ms 处取样。每个都是 25 维描述子 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta t, \mathbf{v}, \boldsymbol{\omega}, \mathbf{a}, \boldsymbol{\alpha})$：槽位 0–6 描述相邻偏移之间的七个区间，速度与加速度由经过时间上的有限差分得到；槽位 7 存放基座坐标系下的当前位姿。每一维用训练统计量标准化，无效维置零，并附加三个有效性标志（位姿、区间与加速度）；没有任何有效特征的槽位在注意力中被掩码。机器人 token 包含相同偏移处的末端位置、旋转向量与夹爪开度，16 个可学习嵌入构成摘要 token。策略没有语言输入。

主干与预测头。 第 3.4 节的掩码在训练与部署时、在每一层每个头中都把被屏蔽的注意力 logit 置为 $-\infty$，因此世界状态每次查询只计算一次，并在各 Euler 步间复用。所有预测头都读取最终的世界状态，部署时跳过，没有 token 读取它们的输出。位姿头读取摘要状态的均值（$\mathcal{L}_P$，式 3）。流头给出每个 patch 点在各时域的位移与可见性 logit（$\mathcal{L}_F$，式 2，尺度 $s = 0.7154605$ m，可见性权重为 1）；有效但不可见的点仍监督其位移。$\mathcal{L}_{\text{aux}}$ 由四项组成：未来度量深度（有效像素）、位移超过 1 mm 的表面的 RGB，以及经层归一化的 DINOv3 特征 [34] 上的平方误差，以及由摘要状态均值重建当前目标 RGB 区域的绝对误差。

动作流。 每个动作 token 嵌入一条七维指令：基座坐标系下的平移增量、左乘相对旋转向量与夹爪指令，均相对于施加时测得的末端位姿。部署时，解码后的指令按每个平移轴 0.10 m、每个旋转轴 0.5 rad 截断；夹爪指令只有超出死区（小球捕获任务为 0.5，其余任务为 0.1）时才切换状态。

A.2 在 ConMoto 上训练

示范的每个控制步锚定一个包含 8 个查询位置的窗口，每个位置有自己的因果历史，位置之间互不注意，由 11,200 条示范共得到 1,324,374 个窗口；另有 350 个回合构成验证集。流标签由 patch 中

心处渲染到的表面点随其 MuJoCo 几何体的真值刚体运动得到；若未来点投影在图像内、落在同一几何体上，且深度差在 $\max(1\,\text{mm}, 0.001z)$ 以内，则视为可见。查询 t 动作块的第 j 条指令标注为示范在 $\tau_t + j\Delta_a$ 下发的指令，因为 d_{task} 只在执行时起作用（式 (S1)）；指令在训练集上标准化。每个查询位置对 8 组噪声—时间对的动作损失取平均，每项损失按全局 batch 中有效标签的数量归一化。表 S2 列出训练配方。

表 S2. ConMoto 上的训练超参数。

项目	取值
优化器	AdamW，$\beta = (0.9, 0.999)$，$\epsilon = 10^{-8}$，权重衰减 10^{-4}
学习率	2×10^{-4}，从 0 开始 5,174 次预热更新，余弦衰减到 0
Batch 与训练长度	全局 batch 512 个窗口，至多 20 轮，取验证损失最低的检查点
损失权重	$\lambda_F = \lambda_P = \lambda_R = 0.1$，每个辅助目标 $\lambda_{\text{aux}} = 0.1$
动作噪声	每个查询位置 8 对噪声—时间样本
精度	可训练权重 FP32，冻结编码器 BF16，梯度截断 0.1
推理	FP32，查询内缓存世界状态
硬件	[N] 块 RTX PRO 6000 GPU，每次训练 [X] 小时

A.3 DROID 预训练与微调

真机基座在 DROID [19]（15 Hz）上训练，使用第一台外部相机及其深度，以及 PointWorld [18] 发布的 3D 点轨迹与标定，并按机器人状态、指令与相机身份与原始回合匹配。可用的 42,087 个回合给出 598,889 个锚定窗口（训练 538,740 个，验证 60,149 个）；每个锚点扩展为 8 个查询位置，只有锚点带有流与 DINOv3 标签。所有带下发指令的动作槽位都被保留，不按速度过滤。每个 patch 跟随一条从其内部出发的 PointWorld 轨迹，优先选择运动最大且一致的一条，以覆盖小的运动物体；47.05% 的点—时域槽位带有标签。

DROID 没有物体位姿，因此基座没有目标状态 token 与位姿头；它读取当前 RGB-D 帧与机器人历史，以权重 1 训练动作损失与稀疏 3D 流，以权重 0.1 训练未来 DINOv3 特征，不使用可见性损失。由于 DROID 中的物体大多只在机器人推动时才运动，基座主要学到度量几何与机器人自身引起的运动；外部驱动的目标运动在微调中才进入。基座共 48 层，宽度 1024（可训练参数 1.02B），以全局 batch 512 在 64 块 GPU 上训练 20 轮（21,060 次更新），优化器与精度同表 S2。每个真机策略从基座出发，在其任务的示范上微调 [更新次数、学习率与 batch 大小]，目标状态 token 与基座缺少的预测头重新初始化；真机策略不使用任何仿真数据或权重。

B ConMoto 与评测协议

B.1 基准设计

ConMoto 包含五个任务族共 14 个任务（图 3），覆盖平移、旋转、暂时遮挡、受约束的通行，以及目标运动的突变。我们将公开这些任务、场景、成功判定与示范。

环境。 任务在 MuJoCo 3.11.0 与 robosuite 1.5.2 [41, 61] 中运行，使用 Franka Panda 机械臂与平行夹爪，由 robosuite 的操作空间位姿控制器驱动，控制周期 50 ms，物理步长 2 ms。一台固定的第三人称相机位于 $(0.68, -0.58, 1.62)$ m，垂直视场角 40°，渲染 224×224 的 RGB-D 图像。动作是基座坐标系下末端的平移与旋转向量增量，加一条夹爪指令，按每个平移轴 0.10 m、每个旋转分量 0.5 rad 截断。

成功与终止。 表 S3 给出各任务的成功条件，在每个物理步判定；连续条件一旦中断，其计数器清零。回合在成功、失败（例如不安全接触、离开工作空间或掉落）或达到时限时结束。

表 S3. **ConMoto 的十四项任务。**目标：策略接收其位姿的物体（第 3.1 节）。速度：目标速度范围（捕获任务取离开斜坡时的速度）。每个任务都须依次通过各阶段且不触发终止性失败；抓取要求双侧指垫接触、抬升至少 0.05 m 并保持 0.5 s。时限：回合时限。图 5 的任务组：R 为旋转敏感组，C 为环境活跃组（附录 B.1）。发布的任务配置包含确切阈值与场景范围。

任务（代号）	目标	速度（m/s）	成功条件	时限（s）	任务组
谐波抓取 (grasp)	物块	0.03–0.20	抓住做谐波运动并偏航的物块，抬起并保持。	8	R
传送带抓取 (t1_belt)	零件	0.04–0.10	抓住传送带上的零件，抬起并保持。	8	C
平移抓取 (t1_xyz)	零件	0.04–0.15	抓住平移的零件，抬起并保持。	8	–
旋转抓取 (t1_so3)	零件	0.04–0.15	抓住平移并旋转的零件（$\|\omega\| \le 1.2$ rad/s），抬起并保持。	8	R
遮挡抓取 (t1_occ)	零件	0.04–0.10	抓住传送带上的零件（遮挡罩会将其遮住 0.5–3.0 s），且不与遮挡罩发生不安全接触；抬起并保持。	8	C
移动容器 (t2_trans)	容器	0.03–0.06	把所持物体完整放入移动的容器并释放，使其静止。	10	–
旋转容器 (t2_se3)	T 形容器	0.03–0.06	把所持 T 形件完整放入平移并旋转的 T 形容器并释放，使其静止。	10	R
导线穿越 (t3_phase)	导线入口	[X]	把所持杆端的环在 30 mm 内对准旋转的导线，然后沿导线无接触地穿到终点。	21	R, C
完整导线穿越 (t3_full)	导线入口	[X]	抓起杆，完成穿越，离开导线后释放杆。	32	R, C
小球捕获 (t4_sphere)	小球	[0.4–0.7]	在小球离开斜坡后、触及托盘前将其接住，抬起并保持。	6	C
桌面小球捕获 (t4_sphere_tabletop)	小球	[0.4–0.7]	在小球离开斜坡后仍在桌面滚动时将其抓住，抬起并保持。	6	C
滑块捕获 (t4_slider)	滑块	[0.4–0.8]	在滑块离开斜坡后仍在桌面滑动时将其抓住，抬起并保持。	6	C
罐体捕获 (t4_can)	罐体	[0.4–0.7]	在罐体离开斜坡后仍在桌面滚动、尚未倾倒时将其抓住，抬起并保持。	6	R, C
撞击后抓取 (t5_replan)	零件	0.12–0.14	撞击器把传送带上的零件撞偏后，沿其抓取轴将其抓住，抬起并保持。	6	R, C

角色与任务组。 表 S3 给出每个任务的目标。移动的容器是目标，因为它的位姿决定能否放入；在穿越任务中，杆须在 30 mm 内与之对准的导线入口是目标，导线其余部分是不允许接触的环境。图 5 的两个任务组在消融之前确定：若目标在领先时长内旋转且其朝向在接触时起作用，则任务属于旋转敏感组，这排除了小球；若任务有障碍间隙 m 或驱动物（传送带、斜坡或撞击器），则属于环境活跃组。

B.2 场景、示范与数据划分

每个场景在各任务的范围内均匀采样目标的初始状态与运动参数：除表 S3 的速度外，还包括至多 35 mm、0.25–0.7 Hz 的谐波振幅、至多 1.2 rad/s 的偏航角速度、2.5–7.5°/s 的导线转速，以及 5–15° 的斜坡坡度。遮挡场景中，目标在开始时至少可见八帧，随后被遮挡 0.5–3.0 s，再至少可见三帧。只保留物理上可行的场景，评测时回放存储的场景。

专家是针对各任务的闭环状态机，使用仿真特权状态：目标的位姿与速度、机器人状态、任务几何，以及真实的接触与阶段事件。它在抓取任务中外推目标，再跟踪、下探、闭爪与抬升；在捕获任务中预测截获点；在穿越任务中补偿导线的相位；其指令按每个轴截断到 0.05 m 与 0.5 rad。只有专家成功、回放其动作能重现该回合、且路径与 jerk 通过质量检查的示范才被保留。训练池包含 11,200 条示范（每个任务 800 条），以 20 Hz 记录 RGB-D、机器人状态、指令与仿真真值；策略只接收第 3 节的输入。

我们在 1,400 个开发场景（每个任务 100 个）上选择配置，并在 1,400 个留出场景上报告全部 ConMoto 结果；留出场景以相同的范围生成，所用种子不出现在任何训练、验证或开发回合中。每个任务的留出集是按种子顺序的前 100 个可行场景，所有方法共用。

B.3 实时评测

执行器。 所有方法在 50 ms 控制时钟上共用一个执行器。第 t 次查询的第 j 条指令对应时刻 $\tau_t + j\Delta_a$，其执行时刻（第 3.1 节）为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\mathrm{task}}, \tag{S1}$$

其中撞击后抓取在下发每条指令 50 ms 后才施加，$d_{\text{task}} = 50$ ms；其余任务 $d_{\text{task}} = 0$。与 RTC [7] 相同，延迟按整数个控制周期计：总延迟为 L_t 的查询在其结束时或之后的第一个周期边界交出动作块，即采集后 $k_t = \lceil L_t/\Delta_a \rceil$ 个周期，执行从对应该边界的第 k_t 条指令继续。策略随即重新观测并开始下一次查询，其间上一个动作块继续执行，因此策略以其延迟允许的频率重新规划。当 $L_t = 0$ 时，下一次查询在采集后一个周期开始。动作块包含该方法原生的 H_m 条指令（表 S4），$k_t \geq H_m$ 时整体丢弃。在第一个动作块到达之前及动作块耗尽时，控制器保持当前的手臂目标与夹爪指令，不重复执行任何指令。FoveaWAM 的每条指令都在采集后 $(H-1)\Delta_a + d_{\text{task}}$ 以内执行，处于其预测时域之内。

协议。 在实时协议下，每次查询期间物理按该方法的延迟推进，延迟每次查询从其在一块 RTX 5090 上实测的分布中抽取。在暂停协议下，推理不占用物理时间，策略每 50 ms 重新规划；这一对照去掉了推理等待，同时也提高了反馈频率，不是性能上界。等延迟协议为每个方法计入 FoveaWAM 的 p95 延迟；原执行方式协议让每个基线保留其论文中的执行方式，例如 ACT 的时间聚合或 DynamicVLA 的流式执行。延迟扫描在实时协议下于推理之后附加 0 至 200 ms，步长 50 ms。rollout 在 RTX PRO 6000 上运行，回放 RTX 5090 上的实测延迟。

延迟测量。 我们在一块 RTX 5090（32 GB，即我们机器人所用的 GPU）上独占运行，以 batch 1 和各方法发布版本的精度（FoveaWAM 为 FP32）为每个方法计时：三轮，每轮 30 次预热与 300 次测量调用，使用录制观测及所需的因果历史。一次计时查询从最新观测开始，到第一条指令可用时结束，包含所有需要最新帧的计算，例如预处理、图像编码、PUMA 与 DynamicWAM 的在线光流与运动描述子、采样与动作解码，在真机上还包括跟踪。FoveaWAM 的预测头在部署时跳过，另行计时。出动作时间超过 50 ms 的查询称为超时；一条指令的动作年龄是其执行时刻减去采集时刻。附录 C.2 报告实测值。

B.4 指标与统计

方法 m 按任务等权的成功率为

$$\text{SR}(m) = \frac{100}{14} \sum_{k=1}^{14} \frac{1}{n_k} \sum_{i=1}^{n_k} y_{mki}, \tag{S2}$$

其中 y_{mki} 是任务 k 的场景 i 上的二值结果。首次接触时的位置误差 e_p 是末端到专家在目标上的接触坐标系的距离；放置任务开始时物体已被抓住，因此使用所持物体与容器的接触及专家的放置位姿。e_p 在有接触的 13 个任务（不含 `t3_phase`）及发生接触的回合上平均；没有接触的失败仍计入 SR 的分母。

配对区间。 每个方法训练一次。配对 95% 区间在每个任务内、跨方法联合地对留出场景做自助法，刻画给定训练权重下的场景不确定性；区间落在 ±2 个百分点以内的差异视为持平。对消融，我们还在去掉纯相位导线穿越（`t3_phase`，附录 C.4）后重复比较。

B.5 基线与消融对照

共同条件。 每个基线保留其官方架构、动作块长度、初始化与训练配方（表 S4），在相同的 11,200 条示范上训练一次（指令通过同一个笛卡尔控制器映射到其动作空间），配置在开发场景上选择。rollout 使用各基线训练时的主视角（腕部槽位被屏蔽）及表 1 所列历史；延迟在各方法自身的原生部署设置下测量。对有无腕部视角两种方式都计时的七个配置，两者的 p95 延迟至多相差 3.8 ms，不到控制周期的十分之一；PUMA、使用官方加速的 OpenWAM 与 DynamicWAM+SE(3) 只在其部署设置下计时。DP 使用作者真机配方的 16 步 DDIM 采样器；OpenWAM 分别在开启与关闭官方缓存和编译时计时。

表 S4. **基线训练。**所有方法均在相同的 11,200 条示范上按各自的官方配方训练，并在附录 B.3 的共享执行器下运行。更新数 × batch：训练量。H：每个返回动作块中的指令数。参数量：可训练参数，不含冻结的编码器。DOM 检查点：DynamicVLA 发布的、在 DOM 上训练的检查点。OpenWAM-α 联合生成视频与动作，但不解码视频。

方法	初始化	更新数 ×batch	H	参数量
ACT [58]	从头训练	$50{,}000 \times 32$	100	[X]
DP [12]	从头训练	$50{,}000 \times 32$	15	[X]
$\pi_{0.5}$ [5]	`pi05_base`	$30{,}000 \times 256$	10	[X]
$\pi_{0.5}$+SE(3)	`pi05_base`	$30{,}000 \times 256$	10	[X]
DynamicVLA [46]	DOM 检查点	$50{,}000 \times 44$	20	[X]
PUMA [14]	官方	[X]×[X]	[X]	[X]
OpenWAM-α [42]	官方	$34{,}490 \times 192$	32	[X]
DynamicWAM [27]	官方	$40{,}000 \times 128$	16	[X]
DynamicWAM+SE(3)	官方	$40{,}000 \times 128$	16	[X]
FoveaWAM	从头训练	$51{,}740 \times 512$	8	523.8M

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.1 的八个目标状态 token，带有相同的有效标志。一个输出层零初始化的两层 MLP 把它们映射到模型宽度；对 $\pi_{0.5}$，它们接在前缀中的图像 token 之后，由动作专家读取；对 DynamicWAM，它们并入其运动学描述。训练沿用基础模型的配方。

消融对照。 第 4.3 节的五个对照各改变表 S2 配置中的一个组件，数据、含检查点选择在内的配方以及执行器保持不变。*无专用 SE(3)* 去掉 $\mathcal{L}_P$ 与位姿头，使目标只接受整个场景共有的统一粗粒度场景流监督；*无场景流监督*去掉 $\mathcal{L}_F$ 与流读出；两者都保留目标状态 token 与全部辅助目标。*无目标历史*去掉目标状态槽位 0–6，即过去的位姿及其速度与加速度特征，保留存放当前位姿的槽位 7（附录 A.1）。*无未来监督*去掉 $\mathcal{L}_P$、$\mathcal{L}_F$ 与三个未来外观损失及其预测头，保留当前目标重建。*无辅助目标*去掉 $\mathcal{L}_{\text{aux}}$，即三个未来外观损失与当前目标重建，保留 $\mathcal{L}_P$ 与 $\mathcal{L}_F$。由于所有预测头在部署时都被跳过，只有无目标历史对照改变推理时的输入。

C 补充仿真结果

C.1 各任务结果

表 S5. **ConMoto 各任务的留出成功率**（%），涵盖表 1 中的全部方法，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。OWAM：使用官方缓存与编译的 OpenWAM-α；OW-off：关闭两者。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。σ：使用标称合成相关位姿噪声的 FoveaWAM （附录 C.5）。Δ：该任务上 FoveaWAM 相对最强其他方法之差及其 95% 配对区间。最后两行为首次接触时的位置误差 e_p（mm，在有接触的 13 个任务上平均）与发生接触的回合数 n（附录 B.4）；–：无 13 任务均值。任务代号见表 S3。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	OWAM	OW-off	DWAM	DWAM+	σ	本文	Δ [95% CI]
谐波抓取	49.0	31.0	51.0	**85.0**	39.0	—	41.0	1.0	50.0	51.0	—	—	—
传送带抓取	45.0	45.0	**96.0**	58.0	89.0	—	62.0	0.0	59.0	47.0	—	—	—
平移抓取	14.0	33.0	59.0	38.0	**61.0**	—	53.0	0.0	53.0	15.0	—	—	—
旋转抓取	24.0	20.0	32.0	**44.0**	26.0	—	42.0	3.0	30.0	37.0	—	—	—
遮挡抓取	30.0	28.0	37.0	51.0	**80.0**	—	34.0	0.0	44.0	36.0	—	—	—
移动容器	26.0	8.0	26.0	19.0	**39.0**	—	28.0	0.0	0.0	0.0	—	—	—
旋转容器	**0.0**	**0.0**	**0.0**	**0.0**	**0.0**	—	**0.0**	**0.0**	**0.0**	**0.0**	—	—	—
导线穿越	99.0	99.0	**100.0**	**100.0**	99.0	—	50.0	58.0	23.0	23.0	—	—	—
导线穿越（完整）	0.0	3.0	1.0	5.0	**12.0**	—	0.0	0.0	0.0	0.0	—	—	—
小球捕获	36.0	16.0	**46.0**	21.0	41.0	—	45.0	13.0	24.0	23.0	—	—	—
小球捕获（桌面）	71.0	81.0	**100.0**	**100.0**	88.0	—	99.0	88.0	98.0	**100.0**	—	—	—
滑块捕获	56.0	30.0	58.0	68.0	28.0	—	**71.0**	31.0	47.0	63.0	—	—	—
罐体捕获	91.0	31.0	98.0	99.0	72.0	—	**100.0**	5.0	96.0	**100.0**	—	—	—
撞击后抓取	42.0	5.0	49.0	**51.0**	39.0	—	21.0	22.0	43.0	20.0	—	—	—
任务等权	41.6	30.7	**53.8**	52.8	50.9	—	46.1	15.8	40.5	36.8	—	—	—
e_p (mm)	32.2	36.2	31.2	32.5	**30.0**	—	31.7	–	31.2	37.0	—	—	–
n	1110	941	1231	1187	1203	—	1115	439	1193	970	—	—	–

表 S5 把表 1 中 ConMoto 留出结果按任务分解到每个方法，并给出 FoveaWAM 相对每个任务上最强其他方法的配对区间；最后两行给出首次接触时的位置误差 e_p 与发生接触的回合数（附录 B.4）。使用真机 DDIM16 采样器时，Diffusion Policy 的实时 SR 为 30.7%，暂停物理时为 31.0%。关闭缓存与编译的 OpenWAM 在部分任务没有接触，因此其完整 13 任务 e_p 未定义。[所有方法都失败或基线优于 FoveaWAM 的任务，以及 FoveaWAM 的主要失败模式。]

C.2 评测协议与延迟

表 S6 在另外三种协议下评估每个方法。暂停物理显示不计计算代价时相对表现如何变化；等延迟在 FoveaWAM 的 p95 延迟下比较所有方法；原执行方式检验共享执行器是否去掉了某个基线所依赖的能力。在暂停协议下，FoveaWAM 与 [名称] 的差为 [±X.X] 个百分点，在等延迟协议下为 [±X.X] 个百分点。原执行方式使各基线的 SR 至多改变 [X.X] 个百分点。表 S7 给出九种配置在五个附加延迟点的结果；PUMA 与 FoveaWAM 仍待补。图 4 直接读取该表绘制部分对比；全部方法保留在表中。

表 S6. **评测协议对照**：ConMoto 留出场景（SR，%），协议定义见附录 B.3；实时即表 1 的协议。超时：实时协议下出动作时间超过 50 ms 控制周期的查询比例（%）。年龄：实时协议下动作年龄的 p95（ms）；–：没有执行任何指令。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

方法	暂停	等延迟	原执行执行器	实时	超时 (%)	年龄 p95
ACT	40.6	—	—	41.6	0.0	50
Diffusion Policy	31.0	—	—	30.7	100.0	150
$\pi_{0.5}$	66.0	—	—	**53.8**	100.0	150
$\pi_{0.5}$ + SE(3)	**74.9**	—	—	52.8	100.0	150
DynamicVLA	54.6	—	—	50.9	100.0	150
PUMA	—	—	—	—	—	—
OpenWAM-α	58.3	—	—	46.1	100.0	350
OpenWAM-α (off)	58.3	—	—	15.8	100.0	950
DynamicWAM	49.1	—	—	40.5	100.0	250
DynamicWAM + SE(3)	64.1	—	—	36.8	100.0	350
FoveaWAM	—	—	–	—	—	—

表 S7. **成功率随附加延迟的变化**：每点使用 1,400 个 ConMoto 留出场景（SR，%；实时协议，单个训练种子）。0 与 150 ms 两列分别等于表 1 的原生与 +150 ms 列。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

	附加延迟（ms）				
方法	0	50	100	150	200
ACT	41.6	43.5	36.5	24.3	16.5
Diffusion Policy	30.7	26.1	21.0	15.9	14.3
$\pi_{0.5}$	**53.8**	**47.2**	**39.6**	27.8	13.6
$\pi_{0.5}$ + SE(3)	52.8	39.8	32.4	**28.2**	15.1
DynamicVLA	50.9	46.4	30.6	23.4	17.8
PUMA	—	—	—	—	—
OpenWAM-α	46.1	36.1	27.9	24.7	**22.1**
OpenWAM-α (off)	15.8	13.7	14.2	10.4	9.5
DynamicWAM	40.5	27.6	25.0	20.6	20.9
DynamicWAM + SE(3)	36.8	30.6	23.9	21.9	21.3
FoveaWAM	—	—	—	—	—

计时。 表 S8 按阶段分解 FoveaWAM 在一块 RTX 5090 上的出动作时间，测量方式见附录 B.3；表 1 给出每个方法的 p95 延迟，表 S4 给出参数量。在真机上，我们报告动作年龄的 p50、p95 与最大值，测试试验全部查询中超过 50 ms 截止时间的比例，以及峰值显存。

表 S8. **单次查询的延迟分解**（FoveaWAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
图像编码	—	—
世界流（每次查询一次）	—	—
动作流（5 个 Euler 步）	—	—
出动作时间（合计）	—	—
预测头（仅训练，供参考）	—	—
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

C.3 DOMINO 上的结果

在 DOMINO [14] 上，我们在其 clean 一级设置的 24 个单臂 Franka 任务上比较 FoveaWAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA。所有方法使用该基准的示范、场景与原生评测器，各训练一个种子，每个任

务与方法评测 50 个回合。我们报告 SR 与操作得分（MS）；MS 用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度（表 2）。FoveaWAM 使用该领域的归一化，并读取指令所指目标在仿真器中的位姿；没有有效位姿的槽位按附录 A.1 的方式掩码。基于 RGB 的基线不接收这一位姿。

数据与适配。 三条基线共用 1,200 条训练与 240 条验证示范，保留全部原始采样帧，通过 DOMINO 原生控制器执行绝对关节位置目标，不添加关节差值过滤或策略侧裁剪。DynamicWAM 保留官方 stride-3、horizon-16 采样规则，每条示范至少需要 10 个完整窗口：实际参与监督的训练与验证来源为 1,054 和 210 条。短来源仍保留在语料中；两个任务没有可用训练来源，一个任务仅有四条。测试集仍包含全部 24 个任务。$\pi_{0.5}$ 与 PUMA 按各自的窗口规则使用全部 1,200/240 条来源。所有归一化统计仅由训练数据计算。

DynamicWAM 将发布模型的状态/动作投影适配为八维，以 global batch 128 训练 40,000 次更新，评测使用最终检查点。$\pi_{0.5}$ 从官方基座出发，以 global batch 256 训练 30,000 次更新，评测使用最终 EMA。PUMA 保留发布的共享权重，初始化八维输出投影，适配全部原可训练参数并保持 teacher 冻结，在 16 卡上使用 global batch 64。其预定预算为 30,000 次更新，仅在验证持续改善时延长至 40,000。每 2,000 步评估全部 240 条验证来源（18,618 个窗口），以任务宏平均归一化动作 MSE 为指标；至少训练 10,000 步后，连续三次检查未达到 0.5% 相对改善即停止。实际在 12,000 步早停，最低验证 MSE 选择了第 6,000 步权重。选点和早停均不使用测试结果。这一比较共享数据来源与测试场景，同时保留各方法的训练配方；不同方法的优化步数与算力没有配平。

结果。 三条基线均在 32 卡上完成相同的 1,200 个固定场景，每任务每臂 25 场，无缺失或重复，全部失败均保留。DynamicWAM 成功 352 场，PUMA 成功 220 场，$\pi_{0.5}$ 成功 208 场。DynamicWAM 在跟踪任务上最高（SR 34.9%），$\pi_{0.5}$ 在拦截任务上最高（33.8%）；PUMA 在这两组分别为 12.8% 与 29.5%。总体平均对 24 个任务等权，而不是平均大小不同的两个任务组。这些是单训练种子结果，不能据此确定跨训练种子的稳定性。[补入 FoveaWAM 已验收的 DOMINO 比较。]

C.4 最终消融

表 S9. **最终消融**（ConMoto 留出场景；附录 C.4）。原生延迟与附加 150 ms 延迟下的 SR（%）；Δ：对照减 FoveaWAM（百分点）及其 95% 配对区间。最后两列：去掉纯相位导线穿越（`t3_phase`）后 13 个任务上的 Δ。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。

	原生		+150 ms		Δ 去掉 `t3_phase`	
变体	SR	Δ [95%]	SR	Δ [95%]	原生	+150 ms
FoveaWAM *	—	–	—	–	–	–
无专用 SE(3)（统一粗粒度场景流）	—	—	—	—	—	—
无场景流监督	—	—	—	—	—	—
无目标历史	—	—	—	—	—	—
无未来监督	—	—	—	—	—	—
无辅助目标	—	—	—	—	—	—

表 S9 报告第 4.3 节的五个对照（附录 B.5）在原生延迟与附加 150 ms 延迟下的结果，以及各自相对完整模型的配对差值。最后两列在去掉纯相位导线穿越（`t3_phase`）后重复这些配对差值：在开发场景上，以不同种子重新训练同一配置，SR 最多相差 [7.4] 个百分点，主要来自该任务，其成功率从 [0] 到 [71]% 不等（附录 B.4）。图 5 的两个任务组列于附录 B.1。[第 4.3 节的结论在去掉 `t3_phase` 后是否改变。]

C.5 对位姿噪声的鲁棒性

在权重冻结的条件下，我们评估三种对目标位姿的合成扰动：标称的时序相关噪声、两倍幅度的噪声，以及带连续缺失观测的标称噪声。标称过程由每回合固定的偏置与平稳相关分量组成，二者每轴的标准差均为 5 mm 与 1°，相关时间为 200 ms。缺失持续 200 ms，其间隔服从均值为 3.8 s 的几何分布，长期缺失比例为 5%。扰动作用于当前与过去的估计，在计算历史特征之前施加。

图 S1 在这些扰动下评估最终模型，使用相同的留出场景与零附加延迟。相对干净位姿，在标称相关噪声、两倍幅度噪声与缺失观测下，SR 分别变化 [X.X]、[X.X] 与 [X.X] 个百分点。

图占位：图 S1——位姿噪声

横轴：干净位姿、标称相关噪声、两倍幅度噪声、带缺失观测的标称噪声；纵轴：FoveaWAM 在各任务族上的 SR，冻结权重，实时协议；匹配场景上的配对区间。

图 S1. **对位姿噪声的鲁棒性。**在目标位姿的合成扰动下 FoveaWAM 的 SR，相对干净位姿。

C.6 预测诊断

表 S10 离线比较最终模型学到的 SE(3) 预测与由同一位姿历史得到的匀速和匀加速外推。

表 S10. **离线预测误差。**在同一批留出观测上计算 400 ms 处的目标位置误差（mm）。CV 和 CA 是由因果位姿历史计算的解析外推；学习位姿头读取冻结完整模型的状态。

	匀速	谐波	滚动/滑动	撞击
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的位姿头	—	—	—	—

D 真机实验

D.1 平台与任务

机器人为 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机，通过 [带时间戳的笛卡尔接口] 以 [控制频率] 控制；一台固定的第三人称相机以 [分辨率与帧率] 录制 RGB-D，每次采集前用 [标定方法] 标定。FoveaWAM 使用这一视角，配方使用腕部视角的基线另外获得 [腕部相机]，所有策略都在一块 RTX 5090 上运行。各任务装置轮流安装在这一平台上（图 S2；表 S11）。T3 转盘上的方块边长不等，必须沿短边抓取，因此接触时其朝向起作用；T4 的玩具小车以固定油门运行。

图占位：图 S2——真机平台

内容：一张从机器人后方拍摄、装有一个任务装置的共用平台照片，不做修饰；逐一标注第三人称 RGB-D 相机、机器人，以及基线使用的腕部相机（若有）。

图 S2. **真机平台，**装有一个任务装置。

表 S11. **真机任务。**目标：被跟踪的物体。试验键：20 个测试键各自固定的内容。速度：由全部测试试验录制的 RGB-D 测得的目标速度（m/s，均值 ± 标准差）。抓取指物体被两指夹持。每个任务有 100 条训练示范与 20 条验证示范。

任务	目标	运动；试验键	速度	成功条件	时限（s）
T1	方块	传送带；[在带上的放置、带速]	—	抓住方块并抬起 [X] cm。	[X]
T2	无盖盒	传送带；[盒子的放置、带速]；方块开始时在夹爪中	—	将方块释放进盒中；方块留在盒内 [直到盒子离开工作空间]。	[X]
T3	边长不等的方块	转盘；[半径、方块的初始角度与偏航、角速度]	—	沿短边抓住方块并抬起 [X] cm。	[X]
T4	玩具小车	以固定油门遥控行驶；[起始位姿、航向]	—	抓住小车并抬起 [X] cm。	[X]
T5	网球	[球的运动机制、释放位置与运动设定]	—	抓住网球并抬起 [X] cm。	[X]
T6	小车上的方块	小车沿倾斜轨道下行；[坡度、释放点]	—	抓住方块并抬起 [X] cm。	[X]

表 S12. **真机成功与失败。**上半部分：每个任务的成功次数（共 20 次试验；任务见表 S11）；All：合并成功率（%）及 95% Wilson 区间；Δ：相对 FoveaWAM 的配对差值（百分点）及按试验键自助法得到的区间。下半部分：每个方法全部 120 次试验中各类失败的次数（附录 D.4）；–：不适用。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。

方法	T1	T2	T3	T4	T5	T6	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
ACT	—	—	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	—	–

	跟踪丢失	过晚	未对准	滑落/掉落	碰撞/中止	超时	失败合计
$\pi_{0.5}$	–	—	—	—	—	—	—
DynamicWAM	–	—	—	—	—	—	—
ACT	–	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	—

D.2 位姿跟踪与标签

跟踪不使用标记，每个物体实例有一个米制网格；球体由球心与半径定义。首帧中，Grounding DINO [24] 定位任务所指的物体，SAM 2.1 [31] 分割它，FoundationPose [43] 注册其位姿；之后 Cutie [11] 传播掩码，FoundationPose 在每次更新时精修卡尔曼滤波的预测。掩码为空时估计无效，不沿用上一位姿，[丢失后的重新初始化]。跟踪器在每个控制周期边界用最新一帧更新，并保留该帧的采集时刻，目标状态 token 的有限差分基于这些时刻；跟踪计入实测延迟（表 S8）。

示范的目标状态输入由同一跟踪器在其录制的 RGB-D 上因果回放得到。位姿标签是未来周期边界上的跟踪位姿 [（在整个回合上离线精修）]，流标签来自 [录制 RGB-D 的 3D 点轨迹，做法同 DROID（附录 A.3）]。对于球体，目标状态 token 与位姿头只使用平移。表 S13 报告测试试验中跟踪丢失的频率。

表 S13. **真机上的跟踪。**按任务统计 FoveaWAM 的测试试验：控制周期边界数、估计无效的比例、最长缺失时长，以及重新初始化次数。

任务	边界数	无效（%）	最长缺失（s）	重新初始化
T1	—	—	—	—
T2	—	—	—	—
T3	—	—	—	—
T4	—	—	—	—
T5	—	—	—	—
T6	—	—	—	—

D.3 训练与评测协议

FoveaWAM 从 DROID 基座出发逐任务微调（附录 A.3）。$\pi_{0.5}$、DynamicWAM 与 ACT [58] 在相同示范上训练或微调，初始化、配方与动作块长度见表 S4；DynamicWAM [是否使用实时分块执行]。示

范、开发试验与测试试验来自不同的采集批次。

每个任务有 20 个预生成的试验键，固定物体实例、其初始位姿与装置设定。操作员参照参考图像重置场景后，四个方法对每个键以随机顺序连续运行，使装置的漂移不会与方法对齐。试验在成功、失败、安全中止或时限（约为该任务示范时长中位数的三倍）时结束。只有装置自身偏离试验键时（[实测速度超出设定的 ±X%，或装置故障]）才重做该键；其余情况都计为失败，包括 FoveaWAM 的跟踪丢失。我们报告每个任务的成功次数，以及合并成功率及其 95% Wilson 区间；配对差值在每个任务内按试验键自助重采样。每次查询的端到端出动作时间都在同一块 RTX 5090 上记录，FoveaWAM 包含跟踪。

D.4 详细结果与失败

表 S12 报告每个任务的成功次数、区间与配对差值，以及各方法按类别统计的失败次数。这些类别在测试试验前确定，都是可观察的事件：跟踪丢失（仅 FoveaWAM ）、过晚（夹爪在目标后方合拢）、抓取未对准、接触后滑落或掉落、碰撞或安全中止，以及超时。[优势最大的任务及其失败类别；FoveaWAM 最常见的失败。]