SE(3)-WAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景；然而推断场景运动多花的每一毫秒，都会让目标走得更远。世界—动作模型以统一的精细程度预测未来图像或隐变量，把时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器速度快，却忽略了约束或推动其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；周围物体只通过它们留下的间隙和传给目标的运动起作用；其余背景则与任务无关。我们提出 SE(3)-WAM，一个建立在这种按角色区分精度的 4D 结构之上的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，并被训练去精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景。这些预测只作为训练监督，部署时被跳过，因此推理既不需要过去的帧，也不需要生成未来，速度足以支撑实时控制。在推理期间场景持续运动的仿真基准 Dynamic-14 上，SE(3)-WAM 的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在目标运动形式多样的六个真机任务上，它的成功率为 [XX]%。

图占位：图 1 预览——运动场景的按角色区分精度的 4D 视图（真机）

版式：通栏，两部分。**(a) 左侧，约 62%：**直线运动抓取的一帧真机画面，取动作块发出的瞬间。按论文语义配色叠加：蓝色为因果跟踪器给出的目标过去 SE(3) 位姿（$-350\ldots0$ ms 的小三轴，随时间变淡）；橙色为动作块各执行时刻的目标 SE(3) 预测，取自离线运行的训练期预测头；浅橙色箭头为覆盖整个场景的14×14 网格稀疏 3D 流；紫色为在 τ^{a} 与目标相遇的指令夹爪路径。灰色虚影标出采集时观测到的位姿，红色虚线箭头示意反应式策略会在何处闭合。图像下方的细时间轴：采集 $\tau_t \to$ 延迟 $\ell_t \to$ 执行 τ^{a}。**(b) 右侧，约 38%：**上：“图像空间 WAM：以统一精细程度预测未来帧或隐变量”（胶片图标）；中：“SE(3)-WAM：目标用 SE(3)，整个场景用稀疏 3D 流，仅训练时使用”（三轴 + 稀疏箭头）；下（**必需**）：SE(3)-WAM 与最强基线的成功率随附加延迟（0–200 ms）的变化（数据：附录 D.2 的延迟扫描）。**规则：**真实照片不做修饰；叠加由该次试验记录的跟踪、预测与指令数据绘制；图注说明该次试验的结果。

图 1. **运动场景的按角色区分精度的 4D 视图。**从图像采集到第一条指令之间，传送带上的零件移动的距离超过了抓取所能容忍的误差。SE(3)-WAM 编码目标的度量运动（蓝色），并被训练去精确预测目标的 SE(3) 位姿、以稀疏 3D 流粗略预测整个场景（橙色），因此它的指令在执行时与目标相遇（紫色）。图像空间的世界—动作模型则以统一精细程度预测外观。右：Dynamic-14 上成功率随附加延迟的变化。

1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[9, 16, 37, 56, 75, 84, 106]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。这带来两个相互耦合的困难。单张图像无法揭示目标如何运动；而等到动作执行时，目标已不在它被看到的位置：传送带上以 0.1 m/s 运动的零件在 150 ms 的延迟中移动 15 mm，超过了平行夹爪抓取通常能容忍的误差（图 1）。

近期工作为策略加入对过去运动的记忆和对未来的预测 [19, 49, 67, 94]。两者都消耗动态操作最缺乏的资源——时间：更丰富的历史和更稠密的预测增加计算，增加的延迟又放大了预测本应消除的误差。因此，现有设计在信息与速度之间权衡。基于视频的 WAM 以统一的精细程度预测完整的未来帧

或隐变量 [49, 75, 84]，只预测动态区域或显著 token 的方法仍在图像空间中预测 [67, 94]。两者都把大部分容量花在外观上，而决定接触的量——动作执行时目标的度量位姿——仍然是隐式的。以目标为中心的预测器位于另一端 [19, 28, 50]：它们速度快，却看不到可能阻挡或改变目标运动的周围环境。它们都没有提供这样一种对运动场景的认识：在接触所依赖之处精确，在其他地方粗略，并且在执行时使用的代价很低。

我们的关键观察是：动态策略需要精确知道的东西其实很少。接触取决于动作执行时刻目标的位姿，精度要到毫米；周围物体只通过它们留下的间隙和传给目标的运动起作用，粗略的估计即可把握；其余背景则与任务无关。这些认识也不必在测试时计算：在训练中作为监督的预测，会塑造策略所学到的表示，部署时即可去掉 [89]。SE(3)-WAM 建立在这两点之上（图 2）。它看到当前图像，以及目标与机器人的度量 SE(3) 短历史；这些历史直接表达运动，而不必编码一叠过去的帧。世界流被训练在同一个度量 4D 空间中精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景；动作流读取世界流的摘要，并按其延迟允许的频率重新规划。因此，SE(3)-WAM 以接近反应式策略的延迟，获得了度量预测带来的精度。

我们在 Dynamic-14 上评估 SE(3)-WAM 。这是一个包含 14 个任务的仿真基准，观测、场景运动与动作执行共用同一个物理时钟，策略计算期间场景持续运动。SE(3)-WAM 以 [XX.X]% 的成功率达到最优，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms；在六个真机任务上，它的成功率为 [XX]%，最强基线为 [XX]%。四个最终规模对照分别检验目标运动历史、未来监督及其两项几何成分的贡献。

我们的贡献有三点：

- 我们提出面向动态操作的按角色区分精度的 4D 建模。分析延迟与估计误差如何传递到接触点可知，只有目标需要毫米级精度；因此我们用度量的 SE(3) 位姿历史和未来轨迹精确表示目标，用稀疏 3D 流粗略表示整个场景。
- 我们提出 SE(3)-WAM ，一个以这些按角色区分精度的 4D 预测作为训练监督的世界—动作模型，其延迟接近反应式策略。
- 我们构建了 Dynamic-14 ，其中推理期间场景持续运动；SE(3)-WAM 在该基准和六个真机任务上取得最优结果。

2 相关工作

动态操作。 补偿感知与执行之间的时间差是一个经典问题，从带纯滞后的控制 [64]，到用卡尔曼类滤波器跟踪目标并规划拦截的抓取系统 [2, 5, 6, 52]；这些系统精确，但针对每种物体和任务专门设计。近来，学习型策略开始进入运动场景。PUMA 读取历史光流，并以未来物体特征作为监督 [19]；DynamicWAM 以光流和运动学描述子为 WAM 提供条件，并以实时分块方式执行 [49]；另一些方法预测显著 token、未来图像或紧凑的未来编码，并在测试时把预测提供给策略 [50, 67, 90, 95]。执行调度方案则从执行一侧减小或掩盖延迟：让推理与执行重叠 [60, 62, 81]，保持相邻动作块一致 [10, 46]，或以执行时刻为条件 [68, 72]。它们决定动作何时计算、何时执行，而 SE(3)-WAM 改变的是策略所表示的内容；我们让所有方法在同一个实时执行器下运行。

世界—动作模型中的预测监督。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [40, 75, 84, 103]，其基础是把视频预测作为策略目标 [29, 70, 79]。由于视频代价高且以外观为主，近期工作改变了预测的内容，例如动态区域、深度与语义特征 [94]，与 RGB 并列的光流和几何 [88]，物体掩码或物体槽 [48, 85]，以及紧凑隐变量 [38, 39]；它们也在追问测试时是否需要预测：Fast-WAM 发现跳

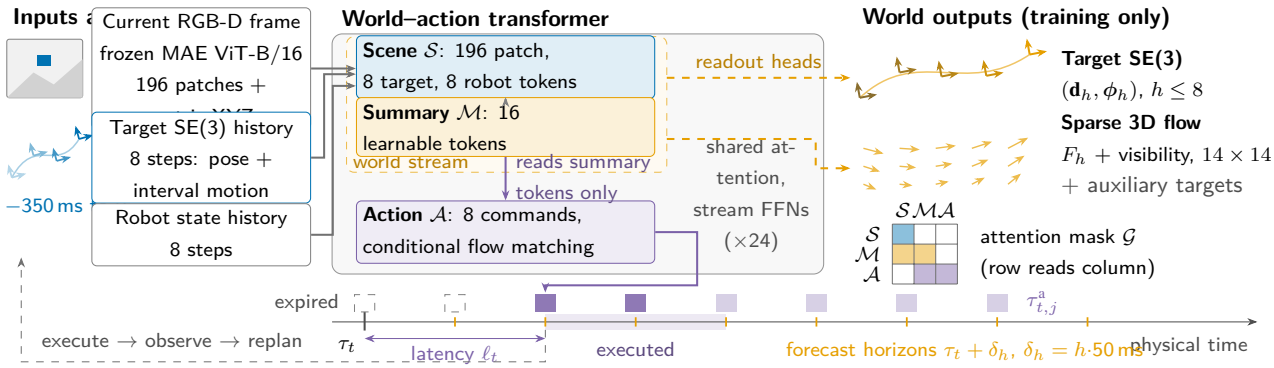


图 2. **SE(3)-WAM** 。世界流包含 212 个场景 token（冻结编码器给出的当前图像 patch，以及目标度量 SE(3) 位姿与机器人状态的短历史）和 16 个摘要 token。训练时，轻量读出头把世界流读出为物理时域 $\tau_t + \delta_h$ 上按角色区分精度的 4D 预测：目标的 SE(3) 轨迹，以及覆盖整个场景、位于14×14 网格上带可见性的稀疏 3D 流（虚线：仅训练）。动作流以流匹配生成 8 条指令组成的动作块。注意力掩码 $\mathcal{G}$ 只允许场景 token 读取场景、摘要 token 读取场景与摘要、动作 token 读取摘要与动作。策略在每次查询结束时或之后的首个控制边界重新观测并重新规划，新动作块从对应该边界的那条指令开始接管执行。

过测试时的想象仍保留了视频建模的大部分收益 [89]，PUMA 等方法在训练后去掉预测器 [19, 66, 97]。SE(3)-WAM 沿用这种只在训练时使用预测的方式，改变的是监督的目标：不是统一分辨率的像素、特征或隐变量，而是一个精度随各部分在接触中所起作用而定的度量 4D 状态。

运动的几何表示。 度量 3D 输入使策略更精确、样本效率更高 [22, 35, 61, 91]。运动已被表示为 2D 点轨迹 [7, 77, 82, 100]、3D 流 [23, 30, 87, 101]，以及物体关键点或 SE(3) 轨迹 [28, 51, 65, 78]；刚体分解也早已用于学习场景动力学 [12, 13]。这些工作用同一种表示描述场景：要么处处是稠密的流或轨迹，要么每个物体一个位姿；DOCIR 把机器人、目标与障碍物分开，但只是作为输入编码 [18]。SE(3)-WAM 按角色分配精度：粗粒度的稀疏 3D 流描述整个场景，接触依赖毫米级精度的目标另由其 SE(3) 历史与预测描述。附录 F 讨论更多相关工作。

3 SE(3)-WAM

SE(3)-WAM 是一个以按角色区分的精度表示动态场景的世界—动作模型（图 2）。它编码当前 RGB-D 帧以及目标 SE(3) 位姿与机器人状态的短历史：冻结的 MAE ViT-B/16 [26] 把 RGB 编码为 196 个 patch token，深度为每个 patch 给出其中心点在机器人基座坐标系中的度量 3D 位置。这 212 个场景 token 与汇聚它们的 16 个可学习摘要 token 构成世界流；训练时，预测头以目标未来的 SE(3) 轨迹与整个场景的稀疏 3D 流监督世界流。动作流与世界流共享注意力，读取其摘要 token，并以条件流匹配 [43] 生成动作块。

3.1 问题定义

SE(3)-WAM 从示范中学习策略。在第 t 次查询时，策略接收在时刻 τ_t 采集的 RGB 图像、深度图与机器人状态，以及机器人状态和目标物体位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$（机器人基座坐标系）的短历史。它输出一个动作块 $(\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1})$，每个控制周期 Δ_a 一条指令，按相对采集时刻的时间索引：第 j 条指令对应的执行时刻为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\mathrm{task}}. \tag{1}$$

图占位：图 3——作用于运动目标（示意图）

版式：单行三个等宽子图 (a)–(c)，矢量示意图，使用论文的语义配色；各子图使用同一机械臂与 T 形零件；不使用照片。**(a) 同一位姿，不同运动**：零件的两段历史 A（蓝色实线）与 B（蓝色虚线），在 −100、−50、0 ms 处画出半透明位姿，二者在采集时刻 τ_t 到达同一位姿。标注："仅凭当前位姿无法区分"。**(b) 执行时刻的位姿**：子图下方一条时间轴：从采集 τ_t 起每隔 $\Delta_a = 50$ ms 一个刻度，对应动作块各指令的时刻 $\tau^{\mathrm{a}}_{t,j}$；动作块在 $\tau_t + \ell_t$ 到达之前的刻度灰显为已过期，第一条被执行的指令标为 τ^{a}。上方画出 A 与 B 在 τ^{a} 时位置和朝向都不同的零件（橙色三轴）。标注："指令必须适合 τ^{a} 时的位姿"。**(c) 角色**：同一场景中的三类物体。*目标*：零件，标出末端执行器坐标系 E、目标坐标系 O、接触点与容差 ε（mm）。*环境中的障碍物*：容器壁或遮挡物，以箭头标出间隙 $m \gg \varepsilon$。*环境中的驱动物*：承载零件的传送带及其运动箭头，可另画一个正在接近的撞击器；标注"推动目标运动"。*背景*：桌沿与远处物体，以灰色去饱和显示；标注"不影响任务"。三行图例：目标 → 精确 SE(3)；环境 → 粗粒度 3D 流；背景 → 无需建模。**规则**：概念示意，位置为假设；蓝色为过去，橙色为未来，紫色为指令，灰色为背景。

图 3. **作用于运动目标**（示意图）。(a) 两段历史在采集时刻 τ_t 到达相同位姿，但对应不同运动。(b) 在执行时刻 τ^{a}，它们对应不同的目标位姿。(c) 接触要求末端执行器坐标系 E 与目标 O 在 ε 内对齐；环境中的障碍物只通过它留下的间隙 $m \gg \varepsilon$ 起作用，传送带这类驱动物通过传给目标的运动起作用，背景则不影响任务。

其中 d_{task} 为任务内置的指令延迟。动作块要经过延迟 ℓ_t 才可用，因此 $j\Delta_a < \ell_t$ 的指令已经过期，其余指令在各自的时刻 $\tau^{\mathrm{a}}_{t,j}$ 执行。因此，指令必须适合 $\tau^{\mathrm{a}}_{t,j}$ 而非 τ_t 时刻的目标位姿，而这一位姿只能由 τ_t 的观测来估计；被执行指令的领先时长 $\Delta = \tau^{\mathrm{a}}_{t,j} - \tau_t$ 至少为 ℓ_t，因而随推理的每一毫秒增长。场景中的物体扮演不同的角色。*目标*是位姿必须在接触或容纳容差 ε 内对齐的物体，例如要抓取的物体或要放入的容器。*环境*由约束或推动目标运动的物体组成：障碍物（例如遮挡物或导线）须以间隙 m 避开，驱动物（例如传送带、斜坡或撞击器）推动目标运动。场景的其余部分不影响任务。第 3.2 节分析这一估计的误差如何依赖领先时长与这些角色，并据此导出 SE(3)-WAM 的表示。

3.2 按角色区分精度的 4D 表示

哪些必须精确。 设策略显式或隐式地依据 τ^{a} 时刻目标位姿的一个估计行动，其位置误差为 e、旋转误差为 θ。力臂为 r 的接触点的误差至多为 $e + 2r\sin(\theta/2)$。把目标在领先时长内的运动写成匀速 $\mathbf{v}$ 加残差（加速、滚动、撞击），并把策略所假定的领先时长记为 $\hat{\Delta}$，可得

$$e \le e_{\text{loc}} + \hat{\Delta}\, e_v + \|\mathbf{v}\|\, e_\tau + e_{\text{dyn}}, \tag{2}$$

其中 e_{loc}、e_v、$e_\tau = |\hat{\Delta} - \Delta|$ 与 e_{dyn} 依次为当前位置、速度、时刻与残差运动的误差（附录 E）。容差 ε 通常只有几毫米，旋转误差还会经力臂放大，因此必须精确掌握目标的位姿与运动。环境所需的精度低得多：障碍物只需以间隙 m 避开，m 通常远大于 ε；驱动物通过传给目标的运动起作用，这一运动随后体现在目标自身的未来中；两种情况下，策略都只需大致知道环境如何运动（图 3c）。因此，我们用度量 SE(3) 状态表示目标，包括其已观测的历史与预测的轨迹，并用稀疏 3D 流表示整个场景；它们都在机器人基座坐标系与物理时间中表示。

延迟允许什么。 延迟两次进入式 (2)：一次通过放大每个速度误差的领先时长，一次通过残差累积的运动。因此，消耗推理时间的信息，只有当它消除的误差多于额外延迟带来的误差时才划算。SE(3)-WAM 让输入保持廉价：只用一张当前图像和低维的状态历史，而不用过去的帧；预测只用于监督训练，因而不增加推理时间（第 3.4 节）。

目标运动：历史与预测。 单个位姿无法揭示目标如何运动（图 3a）。目标历史覆盖最近 8 个控制步（20 Hz 下为 350 ms）。它由基座坐标系下的当前目标位姿和相邻采样之间的七段区间运动组成，每段包

含平移、相对旋转、时间间隔，以及有限差分得到的速度与加速度，均为物理单位，构成 8 个目标状态 token（附录 A.1）。这些 token 直接给出 e_v 与部分 e_{dyn} 所依赖的速度和加速度，代价只是几个低维 token。机器人历史另外提供 8 个末端执行器状态 token。在仿真中，目标位姿来自仿真器；在真机上，由因果跟踪器从 RGB-D 流中估计（附录 C）。

预测描述指令执行时目标会在哪里（图 3b）。它覆盖固定的物理时刻 $\tau_t + \delta_h$，其中 $\delta_h = h{\cdot}50\,\text{ms}$，$h = 1, \dots, 8$，即采集后 50 ms 到 400 ms，因此 $j \geq 1$ 的每个指令时刻 $\tau^{\text{a}}_{t,j}$ 都是一个预测时域。与我们所有的运动标签一样，它从当前状态累计，各损失只在有效标签上取平均。对每个时域，目标的运动为

$$\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t), \quad \boldsymbol{\phi}_h = \operatorname{Log}\big(R(\tau_t{+}\delta_h)R(\tau_t)^\top\big)^\vee. \tag{3}$$

摘要 token 最终状态均值上的线性位姿头预测 $(\hat{\mathbf{d}}_h, \hat{\boldsymbol{\phi}}_h)$，损失为

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h \in \mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\text{SO(3)}}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{4}$$

其中 $\hat{R}_h = \operatorname{Exp}(\hat{\boldsymbol{\phi}}_h^\wedge) R(\tau_t)$，$\mathcal{V}$ 为有效时域集合。由于位姿头读取的是摘要 token，即动作唯一能读取的世界 token（第 3.3 节），精确的目标监督塑造的正是动作所使用的表示。目标的过去与未来因此共用同一个度量坐标系与同一条时间轴。

场景运动：稀疏 3D 流。 14×14 网格上 196 个 patch 的中心点覆盖目标、机器人与周围环境。对每个点 i 和时域 h，其最终 patch token 上的线性头预测基座坐标系中的位移 $\hat{F}_{ih} \in \mathbb{R}^3$ 与可见性 logit $\hat{o}_{ih}$，损失为

$$\begin{aligned} \mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h) \in \mathcal{V}_F} \Big[& \tfrac{1}{3} \big\| (\hat{F}_{ih} - F_{ih})/s \big\|^2 \\ & + \operatorname{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \end{aligned} \tag{5}$$

其中 s 为在训练标签上拟合的固定尺度，o_{ih} 为可见性，$\mathcal{V}_F$ 为有效标签集合。网格对工作空间稀疏采样，相邻点约相距 [X] mm。因此，流以这一间距为环境与机器人提供运动估计，在静止的背景上接近于零，而目标还额外接受式 (4) 的专用 SE(3) 监督。流监督的是摘要 token 从中汇聚信息的 patch token，比精确的目标监督低一层；这就是 SE(3)-WAM 按角色分配精度的方式。

辅助监督。 另有两类目标对表示起正则作用；我们在开发场景上选定了它们（附录 D.5）。patch token 上的未来外观头在每个时域预测度量深度、冻结 DINOv3 教师 [63] 的特征，以及运动表面的 RGB。此外，摘要 token 上的一个小头重建当前目标区域的 RGB，使摘要与目标关联，而不使用未来标签。它们的损失构成 $\mathcal{L}_{\text{aux}}$（附录 A.2）。

3.3 动作生成与联合学习

动作流。 动作流包含 $H = 8$ 个 token，对应动作块中的每条指令；每个 token 嵌入一条加噪指令，即末端执行器的平移与旋转增量加夹爪指令（附录 A.3）。注意力掩码 $\mathcal{G}$ 让场景 token 读取场景，摘要 token 读取场景与摘要，动作 token 读取摘要与动作；因此动作通过摘要 token 读取世界，而世界流不依赖动作。每一层中，两条流共享注意力投影，借此交换信息，并各自保留独立的前馈网络，使每条流有自己的容量；我们在开发场景上将这一主干与参数完全分开的主干比较后选定了它（附录 D.5）。世界 token 使用层归一化，动作 token 使用以流时间为条件的自适应层归一化。

图占位：图 4——Dynamic-14 的 14 个任务

版式：通栏，两行各七个等宽子图，每个任务一格，使用 Dynamic-14 渲染的主视角画面（不用照片）。每组子图上方有一条细的任务族标签条。第 1 行：抓取（谐波、传送带、平移、旋转、遮挡）与放置（移动容器、旋转容器）。第 2 行：穿越（导线穿越、完整导线穿越）、捕获（小球、桌面小球、滑块、罐体）与撞击（撞击后抓取）。每格下方标注任务名。**每格：**裁剪到目标运动的区域，各格比例尺相同；叠加目标的 3–4 个半透明历史位姿与一个运动方向箭头，使运动形式可见（往复、直线、旋转、消失在遮挡物后、滚动、撞击后偏转）；障碍物描边、驱动物标注，配色与图 3c 的角色配色一致。**规则：**不画时间轴（图 2 与图 3 已有）；各格使用同一相机。

图 4. **Dynamic-14** 。五个任务族共 14 个任务，每格叠加目标近期的运动。观测、场景运动与执行共用一个物理时钟，因此策略计算时场景继续运动。

联合学习。 对以训练统计量归一化的动作块 $\mathbf{a}_1$（附录 A.3）、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与流时间 $u \sim \mathcal{U}[0,1]$，参数为 ψ 的动作流 v_ψ 回归流匹配速度：

$$\mathcal{L}_A = \mathbb{E}\left\| v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t, \mathcal{G}) - (\mathbf{a}_1 - \mathbf{a}_0) \right\|^2, \tag{6}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为第 t 次查询的场景 token，误差在有效指令上取平均。所有部分以

$$\mathcal{L} = \mathcal{L}_A + \lambda_P \mathcal{L}_P + \lambda_F \mathcal{L}_F + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}} \tag{7}$$

联合训练，各权重见第 4.1 节。

3.4 高效推理与执行

SE(3)-WAM 的预测头联合训练、在测试时跳过，与近期的 WAM [40, 89] 相同。由于世界 token 既不读取动作，也不读取流时间，世界流每次查询只运行一次，动作流在缓存的键和值上积分 5 个 Euler 步。执行器按整数个控制周期计延迟，与 RTC [10] 的做法相同。总延迟为 L_t 的查询在其结束时或之后的第一个控制周期边界交出动作块，即采集后 $\ell_t = k_t \Delta_a$，其中 $k_t = \lceil L_t / \Delta_a \rceil$；执行从对应该边界的第 k_t 条指令继续。策略在该边界重新观测并开始下一次查询；在此之前，执行器继续执行上一个动作块。因此，策略以其延迟允许的最高频率重新规划；当一次查询能在一个控制周期内完成时，每条指令之前都会重新规划。由于每条指令都在其标签所指的时刻下发，动作流不需要延迟输入，式 (2) 中的时间误差 e_τ 仅剩执行器的动作延迟。每条被执行的指令距采集至多 $(H-1)\Delta_a + d_{\text{task}}$，都落在预测监督的时域之内（附录 B.3）。在真机上，L_t 还包括在最新一帧中跟踪目标的时间。

4 实验

我们依次评估：场景在推理期间持续运动时 SE(3)-WAM 的表现（第 4.2 节），它在真机上的表现（第 4.3 节），以及各组件的贡献（第 4.4 节）。

4.1 设置

Dynamic-14 。 Dynamic-14 是一个仿真基准，观测、场景运动与动作执行共用一个物理时钟，因此策略计算时场景继续运动，每个方法都要为自身的延迟付出代价。[一句话说明与现有动态操作基准的区别，待确认。] 它在 MuJoCo/robosuite [71, 104] 中包含五个任务族共 14 个任务：抓取运动目标（简谐、

表 1. **主要结果**：1,400 个 Dynamic-14 留出场景。SR（%）在 14 个任务上等权平均，SE(3)-WAM 取三个训练种子的平均（基线为一个），分别给出各方法原生延迟下、附加 150 ms 延迟下，以及推理期间暂停物理时的成功率。p95：在一块 RTX 5090 上以 batch 1 测得的出动作时间（ms）；这些延迟在 RTX PRO 6000 上运行的 rollout 中回放。所有方法都接收当前主视角 RGB 与机器人状态。腕部：额外的腕部相机。历史：过去的 RGB 帧（RGB）、光流或基于光流的运动历史（光流），或目标的 SE(3) 历史。SE(3)-WAM 另外使用当前帧的深度，为每个 patch 给出其度量 3D 位置。DP：Diffusion Policy。粗体为最佳。各任务族与各任务的结果、接触误差与置信区间见附录 D.1。

		历史			SR (%)			
方法	腕部	RGB	光流	SE(3)	原生	+150	暂停	p95
ACT [98]	✓				—	—	—	—
DP [16]	✓	✓			—	—	—	—
$\pi_{0.5}$ [56]	✓				—	—	—	—
$\pi_{0.5}$+SE(3)	✓			✓	—	—	—	—
DynamicVLA [81]		✓			—	—	—	—
PUMA [19]			✓		—	—	—	—
DreamVLA [94]	✓	✓			—	—	—	—
OpenWAM-α [75]	✓				—	—	—	—
DynamicWAM [49]			✓		—	—	—	—
DynamicWAM+SE(3)			✓	✓	—	—	—	—
SE(3)-WAM				✓	—	—	—	—

传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（图 4；附录 B）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个，新种子）上报告全部 Dynamic-14 结果。

评测。 每次查询期间，物理按该方法自身的推理延迟推进：延迟从该方法在一块 RTX 5090（我们机器人所用的 GPU）上以 batch 1 实测的延迟分布中抽取，rollout 本身在 RTX PRO 6000 上运行（附录 B.7）。所有方法共用一个按相对采集时刻的时间索引动作块的执行器（第 3.4 节）：查询在控制周期边界开始，其动作块在查询结束时或之后的第一个边界接管执行（附录 B.3）。除这一原生延迟设置外，我们还为每个方法附加 150 ms 延迟，以及在推理期间暂停物理；附录 D.2 另给出等延迟与原执行方式两种对照，以及附加延迟的扫描。我们报告在 14 个任务上等权、并在训练种子上平均的成功率（SR），以及 p95 出动作时间，即从观测到达到其第一条指令可用的实测时间。本文各变体取三个训练种子的平均，每个基线训练一次；配对 95% 区间由对留出场景的自助法得到。

基线。 我们比较反应式策略、动态 VLA、图像或隐空间 WAM，以及一个动态 WAM（表 1）。每个基线使用其官方代码、输入与训练配方，在相同示范上训练；若其配方使用腕部相机或帧、光流历史，则一并提供（附录 B.4）。SE(3)-WAM 只使用一个主视角及其深度和目标的 SE(3) 历史，不使用过去的帧。为了让基线获得相同的目标运动信息，$\pi_{0.5}$ 与 DynamicWAM 还以接收我们 SE(3) 历史 token 的形式运行（+SE(3)）。

实现。 Transformer 共 24 层，宽度 1024，16 个注意力头，可训练参数 523.8M；MAE ViT-B/16 编码器与 DINOv3 教师保持冻结。在 Dynamic-14 上，它从随机初始化开始训练 20 轮，使用 AdamW，$\lambda_P = \lambda_F = 1$，$\lambda_R = \lambda_{\text{aux}} = 0.1$（附录 A.4）。在真机上，它从一个在 DROID [36] 上预训练的 48 层基座出发，逐任务微调（附录 A.5）。

图占位：图 4——真机试验

行：SE(3)-WAM 的一次成功；最强基线在同一试验键上的表现；SE(3)-WAM 的一次失败。**列**：查询帧、首个执行时刻 τ^a 与接触时刻。**叠加**：蓝色为跟踪得到的过去位姿；紫色为指令的夹爪路径。真实照片不做修饰；叠加来自各次试验的日志数据。

图 5. **真机试验**：SE(3)-WAM 与 [最强基线] 在同一试验键上的表现（上两行），以及 SE(3)-WAM 的一次失败（下）。[对所选试验的一句话说明。]

图占位：图 6——按任务的消融效应

四个对照与匀速外推输入替代方案相对完整模型的 SR 差值，按任务族以及旋转目标任务分列，0 与 150 ms 附加延迟；在相同留出场景与三个训练种子上的 95% 配对自助法区间。

图 6. **按任务的消融效应**。各对照相对完整模型的 SR 差值。[概括各组件在哪些任务上起作用。]

4.2 仿真结果

对比。 在原生延迟下，SE(3)-WAM 在 Dynamic-14 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。优势最大的是 [任务类型]（附录 D.1）。它的 p95 出动作时间为 [XX] ms，是图像空间 WAM 的 [X] 分之一，[与反应式策略相近]。它只用一个相机视角、不用过去的帧，而多数基线还接收腕部视角或帧、光流历史。

延迟与协议。 附加 150 ms 延迟后，SE(3)-WAM 保持 [XX.X]%，而反应式策略平均降至 [XX.X]%，图像空间 WAM 降至 [XX.X]%；图 1（右）与附录 D.2 给出 0 到 200 ms 的完整扫描。推理期间暂停物理、即不计计算代价时，SE(3)-WAM 仍领先 [名称] [X.X] 个百分点，原生延迟下这一差距为 [X.X] 个百分点。当每个方法都被计入 SE(3)-WAM 的 p95 延迟时，其领先为 [X.X] 个百分点；让 [依赖自身异步执行的基线] 使用原执行方式，其 SR 的变化不超过 [X.X] 个百分点（附录 D.2）。

DOMINO。 我们还在 DOMINO [19] 的 24 个单臂 Franka 任务上，用其示范训练 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA，并用其原生评测器评测。SE(3)-WAM 的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%（附录 D.3）。与在 Dynamic-14 上一样，它读取仿真器中的目标位姿。

4.3 真机实验

我们在 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机上评估六个任务（图 S3，表 S8），比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 Diffusion Policy [16]：传送带抓取（T1）、放入传送带上的容器（T2）、转盘抓取（T3）、抓取运动的玩具小车（T4）、拦截碰撞后的球（T5），以及拦截沿斜坡滚落或滑落的物体（T6）。它们涵盖直线、圆周、平面自由运动、撞击后运动与重力加速运动。每个方法在相同的 100 条遥操作示范上逐任务训练或微调，另用独立的 20 条示范验证，并以共享的试验键在每个任务上运行 20 次试验。SE(3)-WAM 用 [跟踪器] 跟踪目标，在一块 RTX 5090 上运

表 2. **真机结果**。六个任务上的成功率（%）：T1 传送带抓取、T2 移动容器放置、T3 转盘抓取、T4 移动小车抓取、T5 碰撞后拦截、T6 斜坡拦截（每个任务每个方法 20 次试验）。All 合并全部试验；区间见附录 C。

方法	T1	T2	T3	T4	T5	T6	All
$\pi_{0.5}$	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—

表 3. **核心消融**（最终 24 层模型，Dynamic-14 留出场景，三个训练种子）。每行只改变 SE(3)-WAM （⋆）的一个组件。原生、+150 ms：原生延迟下与附加 150 ms 延迟下的成功率（%）；下方为匀速外推输入的替代方案，它以匀速外推作为输入 token 取代预测损失；e_p：首次接触时的位置误差（mm）；p95：出动作时间（ms）。

变体	原生	+150 ms	e_p	p95
SE(3)-WAM ⋆	—	—	—	—
无目标历史	—	—	—	—
无未来监督	—	—	—	—
无场景流监督	—	—	—	—
无专用 SE(3)	—	—	—	—
匀速外推输入	—	—	—	—

行，p95 出动作时间为 [XX] ms。它在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%（表 2）。[优势最大的任务及主要失败模式]（图 5）。

4.4 消融

四个对照各改变最终模型的一个组件，保持数据、配方与训练预算不变，每个对照训练三个种子（表 3，图 6）。我们在实时协议下以 0 与 150 ms 附加延迟评估它们。

目标历史。 无历史对照保留当前图像、当前目标位姿与机器人历史，移除过去的目标位姿及其速度、加速度特征。去掉它们后，SR 在 0 ms 时变化 [带符号 X.X] 个百分点，在 150 ms 附加延迟时变化 [带符号 X.X] 个百分点（图 6）。在合成位姿噪声下，SE(3)-WAM 的 SR 为 [XX.X]%（附录 D.4）。

未来监督。 无未来对照移除全部预测损失，即 SE(3)、场景流与未来外观目标，保留当前目标 RGB 重建。它使 SR 在 0 ms 时变化 [带符号 X.X] 个百分点，在 150 ms 时变化 [带符号 X.X] 个百分点，衡量未来监督的整体作用。作为学习监督的替代方案，匀速外推输入变体去掉预测损失，改为以目标位姿的匀速外推作为输入 token（附录 B.4）；它落后 SE(3)-WAM [X.X] 个百分点。

两项几何成分。 另外两个对照保留全部辅助目标。移除场景流监督使 SR 变化 [带符号 X.X] 个百分点；由于流覆盖整个场景，这一项衡量的是整体的粗粒度场景运动，而不只是周围环境。移除专用 SE(3) 监督后，目标只剩下场景各部分共有的粗粒度流，SR 变化 [带符号 X.X] 个百分点，在 [任务族] 上最明显。图 S5 展示 SE(3) 头在执行时刻的预测。

5 结论

我们提出了 SE(3)-WAM ，一个用于操作运动物体的世界—动作模型：它把精度花在接触所依赖之处，把时间只花在值得的地方。它记住目标的度量 SE(3) 运动而非过去的帧，学会精确预测目标的 SE(3) 轨迹并以稀疏 3D 流粗略预测整个场景，并让动作读取由这些预测塑造的表示，而不在测试时生成预测。在策略计算期间场景持续运动的 Dynamic-14 上，以及在六个真机任务上，它优于反应式、动态与世界—动作策略。四个最终规模对照检验度量运动历史、未来监督及其两项几何成分。[核心消融完成后写入证据支持的组件结论。]

局限性。 SE(3)-WAM 假设目标是刚体、在接触之前自行运动，因此可变形或带关节的目标以及接触后的动力学不在其范围内。它依赖目标的位姿估计，跟踪器的失败会传递给策略；在仿真中我们从仿真器读取位姿。回归得到的目标预测无法表示多模态的未来，例如撞击之前。我们的真机基座在没有目标位姿的 DROID 上学习，因此与位姿相关的部分只在微调中学习。最后，我们的任务只有单个目标，且环境运动较慢。

LLM Usage Statement（大语言模型使用声明）

[投稿前补充：实际使用的工具、受影响的研究与稿件部分，以及使用程度。]

参考文献

[1] Iretiayo Akinola, Jingxi Xu, Shuran Song, and Peter K. Allen. Dynamic grasping with reachability and motion awareness. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 9422–9429, 2021.

[2] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[3] Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Mojtaba Komeili, et al. V-JEPA 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025.

[4] Ronald Azuma and Gary Bishop. Improving static and dynamic registration in an optical see-through HMD. In *Proceedings of SIGGRAPH*, pages 197–204, 1994.

[5] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation*. Wiley, 2001.

[6] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[7] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[8] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pre-trained image-editing diffusion models. In *International Conference on Learning Representations*, 2024.

[9] Kevin Black, Noah Brown, Danny Driess, et al. π_0: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[10] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, 2025.

[11] Anthony Brohan, Noah Brown, Justice Carbajal, et al. RT-1: Robotics transformer for real-world control at scale. In *Proceedings of Robotics: Science and Systems*, 2023.

[12] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, 2017.

[13] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[14] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[15] Yixiang Chen, Peiyan Li, Yuan Xu, Qisen Ma, Jiabing Yang, Kai Wang, Jianhua Yang, Dong An, He Guan, Gaoteng Liu, Jianlou Si, Jun Huang, Jing Liu, Nianfeng Liu, Yan Huang, and Liang Wang. FlowWAM: Optical flow as a unified action representation for world action models. *arXiv preprint arXiv:2607.13017*, 2026.

[16] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[17] Yilun Du et al. Learning universal policies via text-guided video generation. In *Advances in Neural Information Processing Systems*, 2023.

[18] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. *arXiv preprint arXiv:2503.11565*, 2025.

[19] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. *arXiv preprint arXiv:2603.15620*, 2026.

[20] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[21] Chelsea Finn and Sergey Levine. Deep visual foresight for planning robot motion. In *IEEE International Conference on Robotics and Automation*, 2017.

[22] Ankit Goyal, Jie Xu, Yijie Guo, Valts Blukis, Yu-Wei Chao, and Dieter Fox. RVT: Robotic view transformer for 3D object manipulation. In *Conference on Robot Learning*, pages 694–710, 2023.

[23] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *arXiv preprint arXiv:2505.10075*, 2025.

[24] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse control tasks through world models. *Nature*, 640(8059), 2025.

[25] Nicklas Hansen, Hao Su, and Xiaolong Wang. TD-MPC2: Scalable, robust world models for continuous control. In *International Conference on Learning Representations*, 2024.

[26] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[27] B. Hove and Jean-Jacques E. Slotine. Experiments in robotic catching. In *American Control Conference*, 1991.

[28] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[29] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *International Conference on Machine Learning*, 2025.

[30] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[31] Wei Huang, Bohan Zhang, Chenzhi Liu, Isabella Liu, Shuai Yang, Weian Mao, Luozhou Wang, Yicheng Xiao, Weifeng Lin, Qixin Hu, Bryan Chu, Sifei Liu, Linxi Fan, Xiaojuan Qi, Song Han, and Yukang Chen. Long-WAM: Scaling the context of world-action models. *arXiv preprint arXiv:2610.10528*, 2026.

[32] Seth Hutchinson, Gregory D. Hager, and Peter I. Corke. A tutorial on visual servo control. *IEEE Transactions on Robotics and Automation*, 12(5):651–670, 1996.

[33] Haoyuan Ji, Lingxiang Fan, Shang Su, Yinqiao Lu, Mengkai Shi, Jun Gao, and Shuo Feng. DC-WAM: Dynamic-centric visual supervision and reasoning for world-action models. *arXiv preprint arXiv:2607.25918*, 2026.

[34] Nikita Karaev, Ignacio Rocco, Benjamin Graham, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. CoTracker: It is better to track together. In *European Conference on Computer Vision*, 2024.

[35] Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3D diffuser actor: Policy diffusion with 3D scene representations. In *Conference on Robot Learning*, 2024.

[36] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset.

In *Proceedings of Robotics: Science and Systems*, 2024.

[37] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, 2024.

[38] Fenghao Lei, Zhixiong Huang, Long Yang, Jiabao Chen, Peilin Huang, Han Fu, Zhuo Li, and Xiaoxue Ren. DELE-w0.5: Inferring action from future latent state for robotic manipulation. *arXiv preprint arXiv:2608.22067*, 2026.

[39] Jiajun Li, Tiecheng Guo, Yifan Ye, Rongyu Zhang, Xiaowei Chi, Qianpu Sun, Ying Li, Yunfan Lou, Jinqiao Wang, Zhihe Lu, Meng Guo, and Shanghang Zhang. Efficient-WAM: A 1B-parameter world-action model with low-cost future imagination. *arXiv preprint arXiv:2606.10040*, 2026.

[40] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[41] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[42] Minghui Lin, Pengxiang Ding, Shu Wang, Zifeng Zhuang, Yang Liu, Xinyang Tong, Wenxuan Song, Shangke Lyu, Siteng Huang, and Donglin Wang. HiF-VLA: Hindsight, insight and foresight through motion representation for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[43] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[44] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[45] Xingyu Liu, Charles R. Qi, and Leonidas J. Guibas. FlowNet3D: Learning scene flow in 3D point clouds. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019.

[46] Yuejiang Liu, Jubayer Ibn Hamid, Annie Xie, Yoonho Lee, Maximilian Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, 2025.

[47] Yushan Liu, Jingjing Fan, Shoujie Li, Yifan Xie, Xiao-Ping Zhang, and Wenbo Ding. PACT-WAM: Predicting actions and visual foresight with compact temporal encoding for robot manipulation. *arXiv preprint arXiv:2602.15882*, 2026.

[48] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[49] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[50] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[51] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *International Symposium on Robotics Research*, 2019.

[52] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[53] Henrique Morimitsu, Xiaobin Zhu, Roberto M. Cesar, Xiangyang Ji, and Xu-Cheng Yin. DPFlow: Adaptive optical

flow estimation with a dual-pyramid framework. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17810–17820, 2025.

[54] E-Ro Nguyen, Yichi Zhang, Kanchana Ranasinghe, Xiang Li, and Michael S. Ryoo. Pixel motion diffusion is what we need for robot control. *arXiv preprint arXiv:2509.22652*, 2025.

[55] Octo Model Team, Dibya Ghosh, Homer Walke, et al. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, 2024.

[56] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.

[57] Kanchana Ranasinghe, Xiang Li, E-Ro Nguyen, Cristina Mata, Jongwoo Park, and Michael S. Ryoo. Pixel motion as universal representation for robot control. *arXiv preprint arXiv:2505.07817*, 2025.

[58] Kanchana Ranasinghe, Honglu Zhou, Yu Fang, Luyu Yang, Le Xue, Ran Xu, Caiming Xiong, Silvio Savarese, Michael S. Ryoo, and Juan Carlos Niebles. Future optical flow prediction improves robot control & video generation. *arXiv preprint arXiv:2601.10781*, 2026.

[59] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, 2025.

[60] Yiran Shi, Dongqi Guo, Tianchen Zhao, Feng Gao, Liangzhi Shi, Chao Yu, ZhiJian Mo, Qihua Xiao, XiaoShuai Peng, Qingmin Liao, and Yu Wang. StreamingVLA: Streaming vision-language-action model with action flow matching and adaptive early observation. *arXiv preprint arXiv:2603.28565*, 2026.

[61] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, 2022.

[62] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[63] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[64] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[65] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. *arXiv preprint arXiv:2601.05237*, 2026.

[66] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. *arXiv preprint arXiv:2602.22010*, 2026.

[67] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. *arXiv preprint arXiv:2606.02486*, 2026.

[68] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[69] Zachary Teed and Jia Deng. RAFT-3D: Scene flow using rigid-motion embeddings. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.

[70] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, 2025.

[71] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[72] Changhao Wang, Jaden Clark, and Shuran Song. Chronos policy: Learning robot policies on physical time. *arXiv preprint arXiv:2610.13929*, 2026.

[73] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[74] Ruicheng Wang, Sicheng Xu, Yue Dong, Yu Deng, Jianfeng Xiang, Zelong Lv, Guangzhong Sun, Xin Tong, and Jiaolong Yang. MoGe-2: Accurate monocular geometry with metric scale and sharp details. *arXiv preprint arXiv:2507.02546*, 2025.

[75] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[76] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[77] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[78] Gaoyuan Wu, Ziyu Shan, Haoyang Du, Yuyao Jiang, and Ziwei Wang. AffordTrajDP: Dynamic affordance-guided visuomotor policy learning for robotic manipulation. *arXiv preprint arXiv:2608.01603*, 2026.

[79] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, 2024.

[80] Yuxi Xiao, Qianqian Wang, Shangzhan Zhang, Nan Xue, Sida Peng, Yujun Shen, and Xiaowei Zhou. SpatialTracker: Tracking any 2D pixels in 3D space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[81] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. *arXiv preprint arXiv:2601.22153*, 2026.

[82] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, 2024.

[83] Zhenjia Xu, Zhanpeng He, Jiajun Wu, and Shuran Song. Learning 3D dynamic scene representations for robot manipulation. In *Conference on Robot Learning*, 2020.

[84] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[85] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[86] Heng Yu, David D. Yuan, Juze Zhang, Changan Chen, Yao Feng, Michelle Baldonado, Steve Cousins, Li Fei-Fei, Jiajun Wu, and Ehsan Adeli. OpenWAM: An open framework for composable world-action models. *arXiv preprint arXiv:2610.07922*, 2026.

[87] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2024.

[88] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[89] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

[90] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. *arXiv preprint arXiv:2607.01938*, 2026.

[91] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[92] Chuhan Zhang, Guillaume Le Moing, Skanda Koppula, Ignacio Rocco, Liliane Momeni, Junyu Xie, Shuyang Sun, Rahul Sukthankar, Joëlle K. Barral, Raia Hadsell, Zoubin Ghahramani, Andrew Zisserman, Junlin Zhang, and Mehdi S. M. Sajjadi. Efficiently reconstructing dynamic scenes one D4RT at a time. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[93] Jiahui Zhang, Yurui Chen, Yueming Xu, Ze Huang, Yanpeng Zhou, Yu-Jie Yuan, Xinyue Cai, Guowei Huang, Xingyue Quan, Hang Xu, and Li Zhang. 4D-VLA: Spatiotemporal vision-language-action pretraining with cross-scene calibration. In *Advances in Neural Information Processing Systems*, 2025.

[94] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[95] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[96] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Tsung-Yi Lin, Gordon Wetzstein, Ming-Yu Liu, and Donglai Xiang. CoT-VLA: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[97] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[98] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[99] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3D-VLA: A 3D vision-language-action generative world model. In *International Conference on Machine Learning*, 2024.

[100] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *International Conference on Learning Representations*, 2025.

[101] Hongyan Zhi, Peihao Chen, Siyuan Zhou, Yubo Dong, Quanxi Wu, Lei Han, and Mingkui Tan. 3DFlowAction: Learning cross-embodiment manipulation from 3D flow world model. *arXiv preprint arXiv:2506.06199*, 2025.

[102] Gaoyue Zhou, Hengkai Pan, Yann LeCun, and Lerrel Pinto. DINO-WM: World models on pre-trained visual features enable zero-shot planning. In *International Conference on Machine Learning*, 2025.

[103] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[104] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning.

arXiv preprint arXiv:2009.12293, 2020.

[105] Yifeng Zhu, Zhenyu Jiang, Peter Stone, and Yuke Zhu. Learning generalizable manipulation policies with object-centric 3D representations. In *Conference on Robot Learning*, 2023.

[106] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, 2023.

补充材料

本补充材料给出 SE(3)-WAM 的模型与训练细节，包括在真实机器人数据上的预训练（附录 A）、基准与评测协议（附录 B）、真机设置（附录 C）、补充结果（附录 D）、促成这一设计的误差分解（附录 E），以及更多相关工作（附录 F）。彩色破折号与方括号内容表示由最终实验填写的数值。

A 模型与训练

A.1 场景 token 与摘要 token

当前图像。 冻结的 MAE ViT-B/16 [26] 把 224×224 的主视角 RGB 编码为 196 个 patch token；我们在开发场景上将它与冻结的 DINOv3 编码器 [63] 以及与策略一同训练的 CNN 比较后选定了它（附录 D.5）。每个 patch 获得视角嵌入、其平均有效度量深度的线性嵌入，以及其中心像素反投影后在基座坐标系中位置的线性嵌入；后者由相机内参与外参计算。这些位置也进入 patch query 与 key 的 3D 旋转位置编码，同样的中心点也是稀疏 3D 流的源点（附录 A.2）。目标、机器人、摘要和动作 token 不使用旋转位置编码。过去的图像从不进入模型，因此场景共有 212 个 token。

目标运动历史。 目标历史覆盖最近 8 个控制步，即偏移 $-350,-300,\dots,0$ ms。8 个目标状态 token 各是一个 25 维描述子 $(\mathbf{p},\log R,\Delta\mathbf{p},\log\Delta R,\Delta t,\mathbf{v},\boldsymbol{\omega},\mathbf{a},\boldsymbol{\alpha})$，各分量维数为 $(3,3,3,3,1,3,3,3,3)$。槽位 0–6 描述相邻偏移之间的七个区间，槽位 7 存放基座坐标系下当前的绝对位姿。速度为区间位移除以经过的时间，加速度为相邻速度之差除以区间中心的间隔。我们用训练统计量对每一维标准化，把无效维置零，并附加三个有效性标志（位姿、区间与加速度），然后送入带加性相对时间嵌入的 $28\to1024\to1024$ GELU MLP。没有任何有效特征的槽位在注意力中被掩码。在真机上，我们在相同偏移处对跟踪器的估计（附录 C.2）重采样：平移线性插值、旋转沿测地线插值，不外推，也不跨越超过两个相机周期的空缺插值。

机器人状态与摘要 token。 相同偏移处的 8 个末端执行器状态（位置、旋转向量与测得的夹爪开度比例）构成机器人 token。16 个可学习嵌入构成摘要 token。策略没有语言 token，视角、时间、深度与位置嵌入只修改已有 token，不增加槽位。

A.2 预测头

所有预测头都是世界流最终隐藏状态上的轻量读出。它们与动作流一同训练，部署时被跳过，且没有任何 token 读取其输出。

目标。 摘要 token 最终状态均值上的线性映射给出 $\{(\hat{\mathbf{d}}_h,\hat{\phi}_h)\}_{h=1}^{8}$，以式 4 的 $\mathcal{L}_P$ 训练，$\lambda_R=0.1$。我们使用左相对旋转向量与累计平移，而不使用 twist 指数映射，因为后者会通过其雅可比矩阵把平移与旋转耦合起来。平方误差训练给出点估计，会对多种可能的未来取平均，例如撞击发生之前。

稀疏 3D 流。 流是 196 个 patch 中心点在 8 个时域上、以基座坐标系表示的累计位移及其可见性。每个 patch token 上的线性读出给出其点在每个时域的位移与可见性 logit，以式 5 的 $\mathcal{L}_F$ 训练，尺度 $s=0.7154605$ m。仿真中可见性损失的权重为 1，有效但不可见的点仍监督其位移。这些点同样覆盖目标、机器人与周围环境。

辅助目标。 最终 patch token 上的线性读出在每个时域预测三个未来外观目标：通过每个 patch 的 16×16 像素读出预测度量深度与运动表面 RGB，以及冻结 DINOv3 ViT-L/16 教师 [63] 在 14×14 网格上的 1024 维特征。深度在有效像素上取平方误差，DINO 特征经通道层归一化后取平方误差，RGB 在移动超过 1 mm 的表面（包括机器人）上取平方误差。一个带 GELU 和末端 sigmoid 的 $1024 \to 256 \to 3072$ MLP 读取最终摘要 token 的均值，以绝对误差重建当前目标的 32×32 RGB 区域。四项损失构成 $\mathcal{L}_{\text{aux}}$，权重均为 $\lambda_{\text{aux}} = 0.1$。

A.3 动作流与主干

指令。 每个动作块有 8 条七维指令，控制周期为 50 ms，每条包含基座坐标系下的平移增量、左相对旋转向量与夹爪指令。平移与非零旋转增量以执行时测得的末端位姿为参照。第 t 次查询的动作块中，第 j 条指令的标签是示范在 $\tau_t + j\Delta_a$ 下发的指令。任务内置的指令延迟 d_{task} 在实际应用时叠加（式 1），不平移训练索引。归一化使用训练集中有效下发指令的均值与总体标准差。流匹配在这些坐标中使用单位高斯，每个动作块一个流时间 u，动作 token 通过自适应层归一化接收 u。每个预测位置抽取 8 对独立的噪声—时间样本并对其损失取平均，这在不扩大 batch 的情况下降低了动作梯度的方差。部署时，我们积分 5 个 Euler 步，反归一化，解码旋转向量，并把每个轴截断到 0.05 m 与 0.5 rad；夹爪跟随其指令的符号。

主干与掩码。 24 层中的每一层都用共享的 query、key、value 与输出投影对全部 token 做一次注意力，随后世界 token 与动作 token 分别通过各自的 SiLU 前馈网络（比例 4），主干参数共 504.0M。掩码作用于场景（$\mathcal{S}$）、摘要 token（$\mathcal{M}$）与动作（$\mathcal{A}$）：场景 token 读取 $\mathcal{S}$，摘要 token 读取 $\mathcal{S}$ 和 $\mathcal{M}$，动作 token 读取 $\mathcal{M}$ 和 $\mathcal{A}$。被阻断的连接在每一层、每个注意力头上、训练与部署时都取 logit $-\infty$。由于世界 token 既不读取动作，也不读取流时间，它们的状态在每次查询中只计算一次，并在各 Euler 步之间复用。

A.4 训练配方

表 S1 列出在 Dynamic-14 上的训练配方。示范中的每个控制步都是一个查询窗口，11,200 条示范共给出 1,324,374 个训练窗口；另有 350 个回合构成验证集。每个窗口包含 8 个各自带有因果历史的查询位置，位置之间没有注意力。每个损失按整个累积全局 batch 上的有效标签数归一化。未来帧的 DINOv3 特征按回合缓存一次。我们在开发场景上、以相同的训练样本数，在宽度 1024 下的 12、24 与 48 层之间选择模型深度（图 S1a）。

A.5 在 DROID 上预训练

数据。 真机基座在以 15 Hz 录制的 DROID [36] 上训练，并使用 PointWorld 为其发布的 3D 点轨迹与优化后的相机标定 [30]。我们要求关节序列、末端位姿、夹爪状态、指令与相机身份完全一致，以此把每个发布片段与其原始 DROID 回合对应起来，并排除采集时钟不单调或对应关系有歧义的片段。模型看到第一台外部相机、其深度以及 PointWorld 对它的标定。在 42,935 个已对应的回合中，42,087 个产生可用窗口：37,874 个训练回合给出 538,740 个锚点窗口，4,213 个验证回合给出 60,149 个，两者没有共享回合（表 S2）。所有时间均为采集时间戳。机器人历史使用查询时刻及之前最近的 8 个状态；流与 DINOv3 目标保留 PointWorld 的记录时刻，不插值到 50 ms 时域。每个锚点扩展为 8 个连续的查询位置，各有自己的因果历史；锚点带有流与 DINOv3 标签，其余位置只带动作标签。机器人状态与指

表 S1. Dynamic-14 上的训练超参数。

项目	取值
主干	24 层，宽度 1024，16 个注意力头，前馈 4096，504.0M 参数
Token	212 个场景、16 个摘要、8 个动作
编码器	冻结的 MAE ViT-B/16，输入 224×224
优化器	AdamW，$\beta = (0.9, 0.999)$，$\epsilon = 10^{-8}$，权重衰减 10^{-4}
学习率	2×10^{-4}，从 0 开始 5,174 次预热更新，余弦衰减到 0
Batch 与更新	全局 batch 512 个窗口，20 轮（51,740 次更新）
损失权重	$\lambda_P = \lambda_F = 1$，$\lambda_R = 0.1$，每个辅助目标 $\lambda_{\text{aux}} = 0.1$
精度	可训练权重 FP32，冻结编码器 BF16，梯度截断 0.1
动作噪声	每个查询位置 8 对噪声—时间样本
采样	动作 5 个 Euler 步
推理	FP32，查询内缓存世界状态
硬件	[N] 块 RTX PRO 6000 GPU，每次训练 [X] 小时

表 S2. **DROID 预训练数据**。各阶段的保留量与标签有效率。窗口指带有对齐标签的因果观测窗口，主相机的每个控制步一个；流标签按点与时域计数。

	训练	验证	全部
已对齐的 episode	–	–	42,935
形成窗口的 episode	37,874	4,213	42,087
窗口	538,740	60,149	598,889
有效动作（%）	—	—	96.88
有效流标签（%）	—	—	47.05
DINO 目标的未来帧	—	—	3,425,218
含物体运动的窗口（%）	—	—	—

令经标定的法兰到 TCP 变换后以基座坐标系表示。我们保留采集程序下发了指令的 96.88% 的动作槽位，不按幅度或速度过滤，以免基座偏向缓慢运动。

基座学到什么。 DROID 不提供物体位姿，因此基座没有目标状态 token，也没有位姿头。它的输入是当前 RGB-D 帧与机器人历史（204 个场景 token），不可用的深度被显式掩码；其目标是动作损失（权重 1）、稀疏 3D 流（权重 1）与未来 DINOv3 特征（权重 0.1）。PointWorld 的轨迹只记录可见位置，因此流标签中没有不可见的负样本，可见性损失关闭。DROID 中的大多数物体只在机器人移动它们时才运动，因此基座主要学习度量几何、机器人自身动作引起的运动及其与动作的耦合；我们任务中的外生运动与目标位姿在微调时才引入。

流标签。 14×14 网格的每个 patch 在窗口内跟随一条 PointWorld 轨迹。在起点位于该 patch 内、初始可见且深度有效为正的轨迹中，我们优先选择图像运动最大且其 3D 位移与图像运动一致的一条，否则取最靠近 patch 中心的轨迹。这一规则覆盖了固定中心点会漏掉的运动物体：在 18 段有可见物体运动的片段中，它在 13 段里把动态轨迹放在物体内部，而中心点规则只有 5 段。标签是轨迹相对其初始位置的位移，没有有效轨迹的 patch 记为无效；47.05% 的点—时域槽位带有标签。在图像中静止的表面上，所选轨迹的位移为 [0.9] 与 [5.8] mm（中位数与第 95 百分位），而由 2D 对应 [53] 与单目度量深度 [74] 提升得到的流为 [18] 与 [72] mm，因此我们使用 PointWorld 轨迹。

图占位：图 S2——模型规模与预训练

(a) 仿真模型。纵轴：开发集 SR；横轴：相同样本量下的 12、24 与 48 层；星标为选定配置。**(b) DROID 基座**。横轴：训练样本数（对数）；纵轴：48 层训练的验证集末时域流端点误差（左轴，mm）与动作损失（右轴）；标记为选定检查点。

图 S1. 仿真模型的规模（a）与 DROID 基座的预训练（b）。

配方。 基座使用宽度 1024 的 48 层（1.02B 可训练参数），以全局 batch 512 在 64 块 GPU 上训练 20 轮（21,060 次更新，2,106 次预热更新），优化器与精度同表 S1（图 S1b）。

微调。 每个真机策略从基座初始化，并在其任务的示范上微调。基座所缺的目标状态 token、位姿头与外观头重新初始化，策略从附录 C.2 的跟踪器接收位姿。没有任何真机策略从仿真权重初始化，基座也不接触仿真数据。

A.6 部署

每次查询编码最新观测，运行一次不带预测头的世界流，并在缓存的世界状态上积分动作流。动作块在查询结束时或之后的第一个控制周期边界、从对应该边界的指令起接管执行，下一次查询也在该边界以新的观测开始。查询进行期间，物理继续推进，执行器继续执行上一个动作块的剩余指令（附录 B.3）。

B Dynamic-14 与评测协议

B.1 任务

我们在 MuJoCo 与 robosuite [71, 104] 上构建了 Dynamic-14 。它包含五个任务族共 14 个任务（图 S2）。表 S3 列出它们的成功条件，表 S5 列出其场景范围。我们将公开这些任务、已接受的场景、成功判定与示范。

角色。 表 S4 把每个任务中的物体分配到第 3.1 节的目标与环境两种角色。移动的容器是目标，因为它的位姿决定能否放入。穿越任务中的导线同时扮演两种角色：入口处的位姿是目标，因为棒必须在 30 mm 内与之对齐；沿环的几何是环境，因为任何接触都算失败。传送带、转台、斜坡与撞击器是环境中的驱动物。最后一列列出每个任务涉及的式 2 中的误差项（附录 E）。

终止事件。 我们在每个 2 ms 的物理步上，按表 S3 的先后要求判定成功；连续条件一旦中断，其计数器清零。终止事件分为五类。*无效*事件是仿真器状态损坏。*边界*事件是离开工作空间或越过下游、掉落，或目标时间窗过期。*安全*事件是不安全接触、过大的边缘冲量、碰到导线、释放冲量、机器人过早接触、无支撑地接触托盘或被撞击器卡住。*任务违规*是在目标之外释放、偏离路径或倒退、过早释放、偏转而未捕获、倾倒、撞击缺失或多余，或出射运动改变不足。最后一类是*超时*。每个任务族在每个物理步按固定顺序判定事件，并保留第一个终止事件。

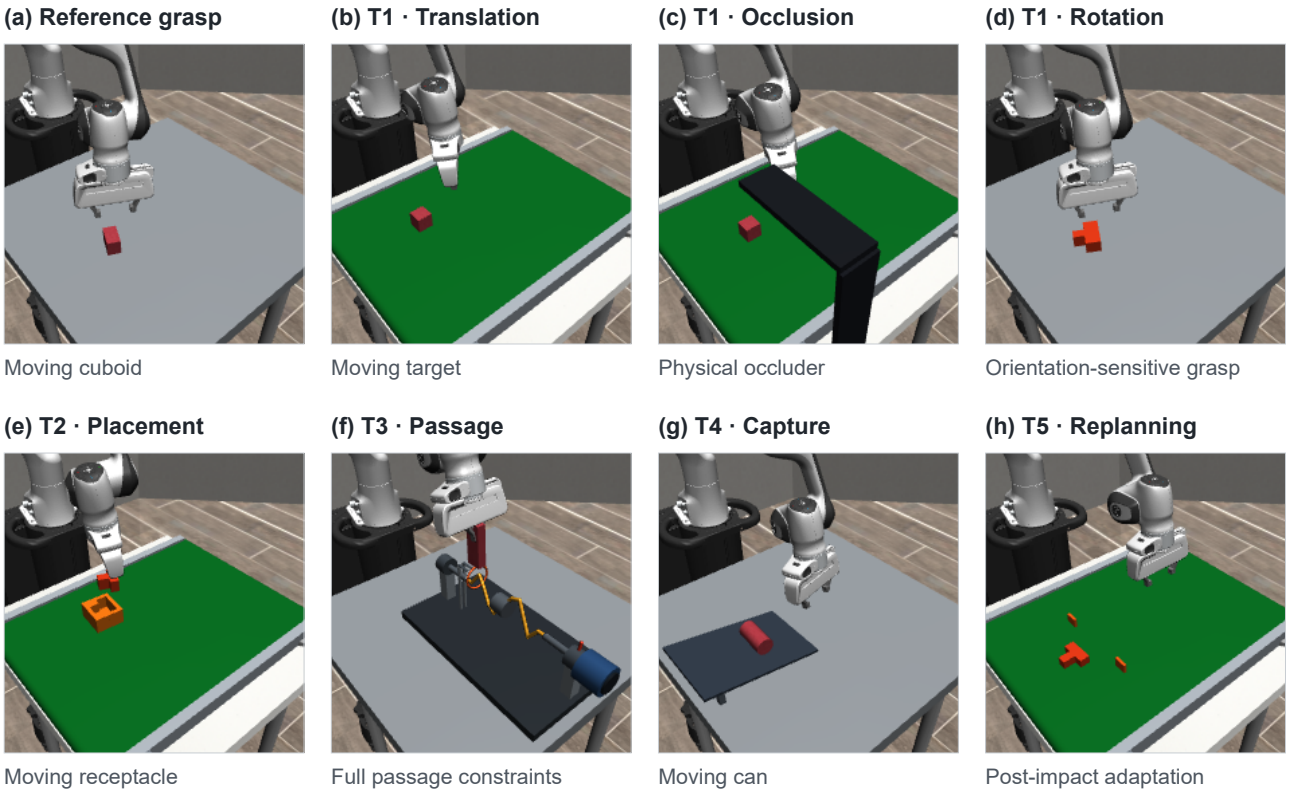


图 S2. Dynamic-14 的观测。八个示例涵盖参考抓取，抓取平移、被遮挡或旋转的目标，放入移动容器，沿旋转导线穿越，捕获滚动物体，以及撞击后抓取。每个子图是一个开发集场景最后观测到的、未裁剪的 224×224 主视角 RGB。表 S3 列出全部 14 个任务。

B.2 场景与示范

我们对连续范围均匀采样，对离散选项等概率采样，然后进行物理可行性检查。评测回放存储下来的已接受场景。简谐平移遵循 $\mathbf{p}(t) = \mathbf{c} + (0, v_y, 0)t + (A_x \sin(2\pi f_x t + \phi), 0, 0)$，其中 $\phi \sim \mathcal{U}[-\pi, \pi]$。捕获任务的目标从静止开始，在 $[5, 15]^\circ$ 的斜坡上受重力与摩擦作用运动。只有当目标在开始时至少可见八帧、被完全遮挡 0.5–3.0 s、之后再次至少可见三帧时，我们才接受一个遮挡场景。

训练池包含 11,200 条示范，每个任务 800 条，由使用仿真特权状态的专家生成；学习得到的策略只接收第 3 节的输入。我们以 20 Hz 记录示范，包括相机图像、深度、机器人状态、下发的指令，以及目标位姿与场景几何的仿真真值，并由此计算未来标签、其有效掩码与指令标签。

B.3 执行协议

执行器。 所有方法都在同一个 50 ms 控制时钟的异步执行器下运行，查询只在控制周期的边界开始。记 L_t 为第 t 次查询的总延迟，即查询期间物理推进的时间：实时协议下的推理时间加上任何附加延迟。执行器按相对采集时刻的时间索引每个动作块，其第 j 条指令的执行时刻为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\mathrm{task}}, \tag{S1}$$

其中 d_{task} 为任务内置的指令延迟（撞击后抓取为 50 ms，其余为零）。动作块在 $k_t\Delta_a$ 之后接管执行，$k_t = \lceil L_t/\Delta_a \rceil$：其 $j < k_t$ 的指令已经过期并被丢弃，从第 k_t 条起替换上一个动作块的剩余部分，下一次查询也在同一边界开始。因此，第 t 次查询执行其第 $j = k_t, \ldots, \min(8, k_t + k_{t+1}) - 1$ 条指令，每个控制周期一条；推理能在一个控制周期内完成的方法在每条指令之前都重新规划。我们报告的出动作

表 S3. Dynamic-14 十四项任务的成功条件，阈值为我们任务实现中的取值。任务须依次通过各阶段，且不触发终止性失败。所有任务的控制频率为 20 Hz，物理仿真步长为 2 ms；下列时长均为物理时间。COM 表示质心。

任务	依次满足的成功条件	时限
grasp; t1_belt, t1_xyz, t1_so3, t1_occ	接近至 0.10 m 内；双侧指垫接触持续 0.05 s；碰撞几何体底部高于支撑面至少 0.05 m；接触与间隙保持 0.50 s。T1 分别加入传送带驱动、平移、旋转或实体遮挡物。SO3 无额外的成功角度阈值；OCC 中与遮挡物发生不安全接触即终止。	160 步 8 s
t2_trans	接近至 0.10 m 内。物体的完整碰撞几何体位于容器内：平面间隙和底面间隙均 ≥ -0.002 m，顶端不高于容器开口。释放要求张开指令 < -0.5 且无指垫接触。相对线速度和角速度分别 ≤ 0.08 m/s、0.8 rad/s，持续 0.10 s，随后稳定停留 0.50 s。	200 10 s
t2_se3	接近至 0.05 m 和 0.12 rad 内。完整纳入 T 形容器：平面间隙 ≥ 0.002 m，底面间隙位于 $[-0.002, 0.002]$ m，倾角 ≤ 0.05 rad，顶端低于开口。释放后，相对线速度和角速度分别 ≤ 0.02 m/s、0.04 rad/s，持续 0.10 s，再停留 0.50 s。0.12 rad 阈值用于接近阶段。	200 10 s
t3_phase	回合开始时杆已被抓住。相位对齐要求距离 ≤ 0.090 m、环方向误差 ≤ 0.20 rad。在进度 ≤ 0.15 时进入 0.030 m 范围；历史最大进度先达到 ≥ 0.60，再达到 ≥ 0.85，且距终点 ≤ 0.055 m。	420 21 s
t3_full	双侧接触持杆 0.05 s，然后完成上述相位阶段。在后续采样时刻，当前进度仍须 ≥ 0.85，且离路径和终点均至少 0.045 m。最后张开夹爪（< -0.5）且无指垫接触。退出前释放判为失败。	640 32 s
t4_sphere	接近至 0.10 m 内；首次合格接触须在离开斜坡后发生；成功前接触托盘即判为失败。双侧夹持的名义时长为 25 ms（12 个物理采样步，24 ms）。以首次达到双侧夹持条件时的高度为基准，将质心抬升 0.05 m，并保持接触和高度 0.50 s。	120 6 s
t4_sphere_tabletop; t4_slider	接近至 0.10 m 内；接触须发生在离开斜坡后、仍受支撑、位于捕获区且平面速度 ≥ 0.08 m/s 时。双侧夹持持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m；随后保持接触和高度 0.50 s。	120 6 s
t4_can	采用相同的受支撑捕获顺序。首次指垫接触前，若罐体轴线与竖直方向的点积绝对值 > 0.45，则按不稳定倾倒判为失败。配置不要求夹爪沿横向闭合。	120 6 s
t5_replan	机器人接触前，所选侧恰有一个撞击组完成。在物理撞击结束时间戳后 30 ms，按分支方向取符号的横向速度 ≥ 0.035 m/s，偏航角速度 ≥ 0.35 rad/s。接近至 0.10 m 内；双侧夹持且抓取轴误差 $\leq 18°$，持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m，并稳定夹持 0.50 s。撞击组时滞为 12 ms，最长接触时长为 0.10 s。	120 6 s

时间是取整之前的实测延迟（附录 B.7）。由于 $j \leq 8-1$，每条被执行的指令距采集至多 $350\,\text{ms} + d_{\text{task}}$，因而落在预测监督的 400 ms 之内。当 $k_t + k_{t+1} > 8$ 时，例如总延迟恒定且超过 200 ms，动作块会在下一个到达之前耗尽；若 $k_t \geq 8$，其全部指令都已过期。在回合的第一个动作块到达之前，以及动作块在下一个到达之前耗尽时，控制器保持当前的手臂目标与夹爪指令，物理照常推进，不重复执行任何指令。

实时协议。 除非另有说明，推理期间物理按该方法的原生延迟推进：每次查询从该方法在一块 RTX 5090 上以 batch 1 实测的延迟分布中抽取（附录 B.7）。rollout 在 RTX PRO 6000 上运行，其本身的计算时间不计入回合。表 S14 报告三种替代协议。在*暂停*协议下，执行器不变，仿真等待推理完成；附加延迟仍推进物理。没有附加延迟时 $L_t = 0$，第 0 条指令在采集时刻执行。在*等延迟*协议下，无论自身速度如何，每个方法都被计入 SE(3)-WAM 的 p95 延迟。在*原执行方式*协议下，每个基线保留其论文中的执行方式，例如在重新规划前执行更长的动作块。

表 S4. **Dynamic-14 各任务的角色与容差。**目标是位姿误差进入接触或容纳容差 ε 的物体；环境包括须以间隙 m 避开的障碍物，以及推动目标运动的驱动物。速度取自表 S5 的采样范围（捕获任务取离开斜坡时的速度）。误差项：任务涉及的误差分解项。v：目标运动。$r\theta$：朝向影响接触。e_{dyn}：非匀速运动（谐波、重力、摩擦、撞击）。m：须避开某个环境物体。occ.：历史缺失。delay：任务内置的指令延迟。

任务	代号	目标	环境	ε (mm)	$\|\mathbf{v}\|$ (m/s)	m (mm)	误差项
谐波抓取	grasp	物块	桌面	[X]	0.03–0.20	–	v, $r\theta$, e_{dyn}
传送带抓取	t1_belt	零件	传送带	[X]	0.04–0.10	–	v
平移抓取	t1_xyz	零件	桌面	[X]	0.04–0.15	–	v, e_{dyn}
旋转抓取	t1_so3	零件（$\omega \le 1.2$ rad/s）	桌面	[X]	0.04–0.15	–	v, $r\theta$, e_{dyn}
遮挡抓取	t1_occ	零件	遮挡罩	[X]	0.04–0.10	[X]	v, m, occ.
移动容器	t2_trans	容器	桌面	[X]	0.03–0.06	–	v
旋转容器	t2_se3	T 形容器	桌面	[X]	0.03–0.06	–	v, $r\theta$
导线穿越	t3_phase	导线环（入口）	旋转导线	30	[X]	扫描	v, $r\theta$, m
导线穿越（完整）	t3_full	导线环（入口）	旋转导线	30	[X]	扫描	v, $r\theta$, m
小球捕获	t4_sphere	小球	托盘、斜坡	[X]	[0.4–0.7]	[X]	v, e_{dyn}, m
小球捕获（桌面）	t4_sphere_tabletop	小球	桌面、斜坡	[X]	[0.4–0.7]	–	v, e_{dyn}
滑块捕获	t4_slider	滑块	桌面、斜坡	[X]	[0.4–0.8]	–	v, e_{dyn}
罐体捕获	t4_can	罐体	桌面、斜坡	[X]	[0.4–0.7]	–	v, $r\theta$, e_{dyn}
撞击后抓取	t5_replan	零件	撞击器	[X]	0.12–0.14	[X]	v, $r\theta$, e_{dyn}, m, delay

附加延迟。 在推理之后、协议本身的延迟之上，插入 0、50、100、150 或 200 ms 的附加延迟，期间物理继续推进。

位姿噪声。 在权重冻结的条件下，我们评估三种对目标位姿的合成扰动：标称的时序相关噪声、两倍幅度的噪声，以及带连续缺失观测的标称噪声。标称过程由每回合固定的偏置与平稳相关分量组成，二者每轴的标准差均为 5 mm 与 1°，相关时间为 200 ms。缺失持续 200 ms，其间隔服从均值为 3.8 s 的几何分布，长期缺失比例为 5%。扰动作用于当前与过去的估计，在计算历史特征之前施加。

B.4 基线

共同条件。 表 S6 汇总各基线的适配。每个基线保留其官方架构、输入、动作块与初始化。ACT 与 Diffusion Policy 从头训练，$\pi_{0.5}$ 从 `pi05_base` 微调，其余方法从其发布的权重出发。它们都在相同的 11,200 条示范上训练，示范中的指令通过同一个笛卡尔控制器映射到各自的动作空间。Dynamic-14 除主视角外还渲染 224×224 的腕部相机，配方使用腕部视角的方法会获得该图像；SE(3)-WAM 与其匀速输入变体只使用主视角。每个基线按官方配方训练到原论文的更新次数，只训练一次，种子为 0；我们只改动数据读取与动作空间。对 DreamVLA，我们同时运行了其原始的 40 轮调度与 20 轮余弦调度，并报告在开发场景上更好的一个。

输入。 PUMA [19] 接收在渲染帧上计算的历史光流。DreamVLA 接收七帧因果 RGB、末端执行器位置与朝向、手指位置和固定的任务文本，用十步 DDIM 和 1.5 的无分类器引导采样。OpenWAM-α 接收当前 RGB 视图、关节值、夹爪开度与任务文本，联合生成视频与动作，但不解码视频。DynamicWAM 接收其光流历史与运动学描述。

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.1 的八个目标状态 token，带有相同的有效标志与掩码。一个两层 MLP 把这些 token 映射到模型宽度。对 $\pi_{0.5}$，我们

表 S5. 场景的提议采样范围。除另有说明外，长度、线速度、角度和角速度的单位分别为 m、m/s、rad 和 rad/s。除注明的斜坡局部偏移外，位置均采用世界坐标。可行性检查前，连续区间内均匀采样，离散选项等概率采样。评测重放已存储的接受场景，其分布未必仍为均匀分布。谐波运动中心不等于初始位置。

任务	初态提议范围	运动或事件参数
grasp	谐波运动中心 $c_x \in [-.08, .08]$、$c_y \in [-.26, -.19]$、$z = .822$；偏航角 $[-1.1, 1.1]$。	$v_y \in [.025, .125]$, $A_x \in [.015, .035]$, $f_x \in [.3, .7]$ Hz; $\omega_z \in [-1.2, 1.2]$.
t1_belt	目标 $x \in [-.08, .08]$、$y \in [-.26, -.18]$、$z = .822$；姿态为单位旋转，初始 twist 为零。	传送带 $v_y \in [.04, .10]$。
t1_occ	目标提议范围同传送带任务；遮挡罩位于 $(.322, -.29, 1.20)$。	传送带速度范围相同；间隙参数为.20；实体遮挡。
t1_xyz	谐波运动中心 $c_x \in [-.025, .025]$、$c_y \in [-.24, -.20]$、$z = .818$；偏航角 $[-.35, .35]$。	$v_y \in [.04, .09]$, $A_x \in [0, .03]$, $f_x \in [.25, .65]$ Hz; $\omega_z = 0$.
t1_so3	同 XYZ。	平移相同；$\omega_z \in [-1.2, -.4] \cup [.4, 1.2]$，正负等概率。
t2_trans	目标容器 $x \in [-.13, -.08]$、$y \in [-.18, -.12]$、$z = .825$；姿态固定。	目标容器 $v_y \in [.03, .06]$；无旋转。
t2_se3	目标容器的 x, y 范围相同，$z = .804$；偏航角 $[-.3, .3]$。	目标容器 $v_y \in [.03, .06]$；$\omega_z \in [-.25, -.08] \cup [.08, .25]$，正负等概率。
t3_phase	杆的位置 $x, y \in [-.03, .03]$、$z = .870$，偏航角 $[0, 2\pi]$；导线相位 $[-.25, .35]$。	导线中心 $(.10, -.02, .94)$；绕世界 X 轴旋转，$\omega_x = -\{2.5, 3, \ldots, 7.5\}°$/s（11 个等概率取值）。
t3_full	杆位于 $(-.05, -.02, 1.04)$，姿态为单位旋转；导线相位范围相同。	导线旋转相同；启用托架及释放要求。
t4_sphere	斜坡局部偏移：横向 $[-.015, .015]$，纵向 / 法向 $(-.145, .030)$；坡沿 $(.06, -.02, 1.10)$。	从静止开始由重力驱动；在 tick 0 释放闸门；坡度 $[5, 15]°$；目标 / 斜坡滑动摩擦系数 $[.7, .9]$；无支撑捕获。
t4_sphere_tabletop	横向 $[-.015, .015]$，纵向 / 法向 $(-.124, .034)$；坡沿 $(0, -.06, .808)$。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.7, .9]$，桌面摩擦系数.35。
t4_slider	横向 $[-.015, .015]$，纵向 / 法向 $(-.129, .024)$；受支撑斜坡。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.025, .045]$，桌面摩擦系数 $[.012, .018]$。
t4_can	横向 $[-.010, .010]$，相对斜坡轴线的偏航角 $[-4, 4]°$；纵向位置由闸门几何及罐体在该姿态下的包围范围确定。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.25, .45]$，桌面摩擦系数 $[.09, .15]$。
t5_replan	$x \in [-.005, .005]$、$y = -.29$、$z = .812$；偏航角 $[-.08, .08]$；初始 twist 为零。	传送带 $v_y \in [.12, .14]$；在 $y = -.13$ 处等概率触发左 / 右撞击器；行程.098，脉冲.35 s，执行器缩放系数 $[1, 1.1]$，力上限 4 N；指令延迟 50 ms。

把它们附加在前缀中的图像 token 之后，动作专家会读取它们；对 DynamicWAM，它们并入其运动学描述。MLP 的输出层零初始化，训练沿用基础模型的配方。

匀速输入变体。 *SE(3)-WAM*，匀速输入与 SE(3)-WAM 共享场景 token 和动作流，但没有预测损失。其动作流改为以输入 token 的形式接收由目标历史得到的目标位姿匀速外推，外推到采集后固定的物理时刻：[指令时刻 $\tau_t + j\Delta_a + d_{\text{task}}$ 或预测时域 $\tau_t + \delta_h$，待对照实现确认]。它用相同的数据和配方训练，并保留当前目标 RGB 重建。

表 S6. **基线适配**。所有方法均在相同的 11,200 条示范上、以其原论文的输入训练，并在附录 B.3 的共享执行器下运行。更新数 × batch 沿用官方训练配方。Exec.：原论文的执行方式（重规划前每个动作块执行的指令数），仅用于表 S14 的原执行方式对照。参数量：可训练参数，不含冻结的编码器。Seeds：训练种子数。

方法	初始化	输入	更新数 × batch	执行	参数量	种子
ACT [98]	从头训练	主视角 + 腕部 RGB、机器人状态	50,000 × 32	时间聚合	[X]	1
Diffusion Policy [16]	从头训练	主视角 + 腕部 RGB（原论文观测长度）、机器人状态	50,000 × 32	8	[X]	1
$\pi_{0.5}$ [56]	`pi05_base`	当前主视角 + 腕部 RGB、机器人状态、任务文本	30,000 × 256	10	[X]	1
$\pi_{0.5}$ + SE(3)	`pi05_base`	同 $\pi_{0.5}$ + SE(3) 运动 token	30,000 × 256	10	[X]	1
DynamicVLA [81]	发布的 DOM 检查点	帧 $[-2, 0]$、机器人状态、任务文本	50,000 × 44	流式	[X]	1
PUMA [19]	官方检查点	RGB、光流历史、机器人状态、任务文本	[X]×[X]	[X]	[X]	1
DreamVLA [94]	发布的组件	七个因果主视角 + 腕部 RGB 帧、机器人状态、任务文本	48,220 × 512	1	[X]	1
OpenWAM-α [75]	官方基础模型	当前主视角 + 腕部 RGB、关节、夹爪、任务文本	34,490 × 192	32	[X]	1
DynamicWAM [49]	官方初始化	RGB、光流历史、运动学描述	40,000 × 128	16	[X]	1
DynamicWAM + SE(3)	官方初始化	同 DynamicWAM + SE(3) 运动 token	40,000 × 128	16	[X]	1
SE(3)-WAM，匀速外推输入	同 SE(3)-WAM	同 SE(3)-WAM，另加匀速外推 token，无预测损失	同 SE(3)-WAM	–	[X]	3
SE(3)-WAM	冻结的 MAE 编码器	当前主视角 RGB-D、SE(3) 与机器人历史	51,740 × 512	1	523.8M	3

B.5 划分与统计

我们在 1,400 个开发场景（每个任务 100 个）上选择配置。全部 Dynamic-14 结果使用另外 1,400 个留出场景，它们以相同的范围生成，使用不出现在任何训练、验证或开发回合中的新源种子；按种子递增顺序的前 100 个可行场景构成每个任务的集合。完整模型、匀速输入变体与四个消融对照使用训练种子 0、1 与 2，每个基线使用种子 0。在开发场景上，同一配置的三个训练种子之间 SR 最多相差 [7.4] 个百分点，主要来自导线穿越，其成功率在各种子间从 [0] 到 [71]% 不等。我们报告每个训练种子以及跨种子的均值与标准差。对于配对 95% 区间，我们对每个场景的各种子取平均，并在每个任务内、跨方法联合地对留出场景做自助法。这些区间刻画给定训练权重下的场景不确定性；区间落在 ±2 个百分点以内的差异视为持平。

B.6 指标

按任务等权的成功率为

$$\mathrm{SR}(m) = \frac{100}{14} \sum_{k=1}^{14} \frac{1}{S_m n_k} \sum_{s=1}^{S_m} \sum_{i=1}^{n_k} y_{mski}, \tag{S2}$$

其中 y_{mski} 是以种子 s 训练的方法 m 在任务 k 的场景 i 上的二值结果；本文各变体 $S_m = 3$，基线 $S_m = 1$。*首次接触时的位置误差* e_p 是首次接触时末端到接触坐标系的距离。*接触时刻误差* e_t 是首次接触时刻到场景可行接触时间窗的距离，在时间窗内为零。该时间窗是特权专家能够完成任务第一个成功阶段所需接触的控制周期边界 t 的集合。时刻 t 属于该时间窗的条件是：专家在目标上的接触坐标系在 t 时刻（取自机器人保持初始位姿时同一场景的一次回放）(i) 满足该阶段的几何条件（表 S3），(ii) 在专家的关节限位内有逆运动学解，且 (iii) 末端在专家的单条指令限位（每个平移轴 0.05 m、每个旋转向量分量 0.5 rad）下能从初始位姿在 t 之前到达。最早到达时刻取 $\lceil \max_i |\Delta p_i| / 0.05\,\mathrm{m} \rceil$ 与 $\lceil \max_i |\Delta \phi_i| / 0.5\,\mathrm{rad} \rceil$ 两者中较大的控制周期数；这是忽略控制器跟踪滞后的下界。在这次参照回放中只关闭机器人与目标

表 S7. **单次查询的延迟分解**（SE(3)-WAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
图像编码	—	—
世界流（每次查询一次）	—	—
动作流（5 个 Euler 步）	—	—
出动作时间（合计）	—	—
预测头（仅训练，供参考）	—	—
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

之间的碰撞。该时间窗只取决于场景，对所有方法相同。两个放置任务开始时物体已被抓住，因此其接触是所持物体与容器的首次接触，接触坐标系是专家放置目标所对应的末端位姿。仅含相位阶段的穿越任务（`t3_phase`）开始时已持杆，且成功不需要任何接触，因此 e_t 与 e_p 的平均覆盖其余 13 个任务，而 SR 覆盖全部 14 个任务。两项误差只在发生接触的回合上报告；没有接触的失败仍计入 SR 的分母。我们区分三个时间量。*出动作时间*是从观测到达到其第一条指令可用的实测墙钟时间，不取整；*交接时刻* $\ell_t = k_t\Delta_a$ 把总延迟向上取整到控制周期（附录 B.3）；*动作年龄*是一条指令的执行时刻减去采集时刻。表 S11 报告 e_p 以及发生接触的回合数。

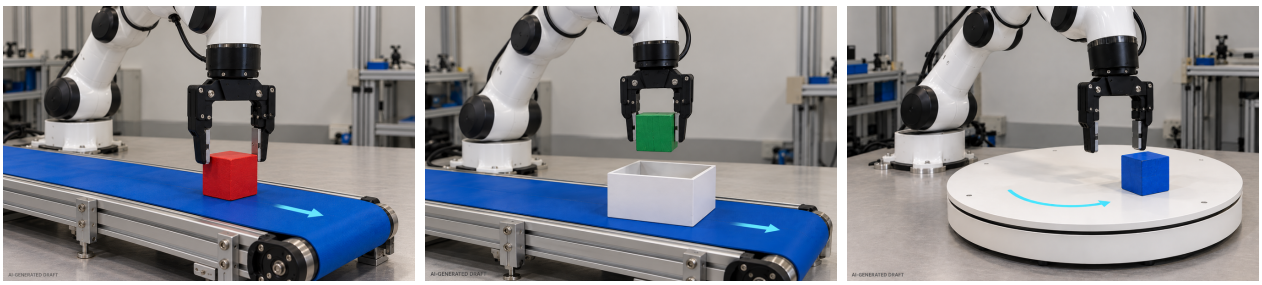
B.7 计时

我们在一块 RTX 5090（32 GB，即我们机器人所用的 GPU）上独占运行、以 batch 1 为所有方法计时。这些测量构成仿真 rollout 所回放的延迟分布，而 rollout 本身在 RTX PRO 6000 上运行。每个方法在三轮中各进行三十次预热调用，再在三段各八帧的观测序列上测量 300 次调用；调用边界处做 CUDA 同步，方法顺序轮换。每个方法使用其发布版本的精度，SE(3)-WAM 使用 FP32。出动作时间包括图像编码与生成第一条指令，在真机上还包括跟踪最新一帧。对 SE(3)-WAM，我们另外测量预测头的耗时，尽管部署时跳过它们。表 1 给出 p95 值，表 S6 给出参数量。在真机上，日志记录采集、可用、预处理、推理开始与结束、进入队列、指令下发与执行等时刻。我们报告动作年龄的 p50、p95 与最大值。若一次查询的出动作时间超过 50 ms 的控制周期，下一个周期只能执行剩余指令或保持，我们称该查询超时，并报告测试试验全部查询中超时查询的比例以及峰值显存（表 S7）。

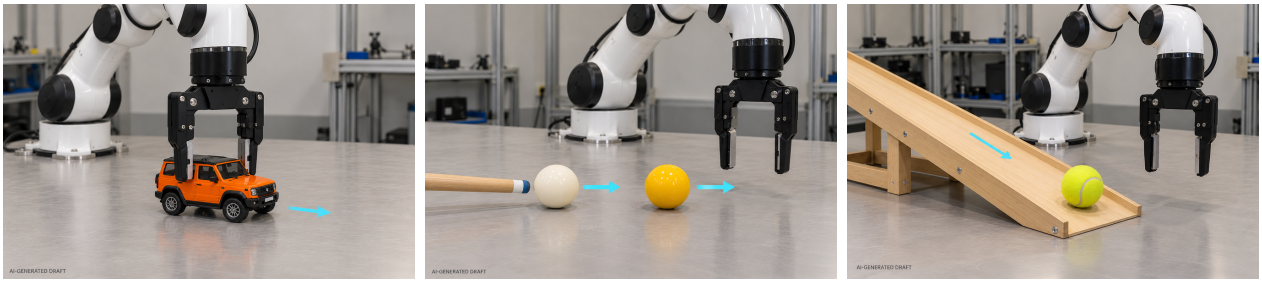
C 真机设置

C.1 平台与任务

机器人为 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机，通过 [带时间戳的笛卡尔接口] 以 [控制频率] 控制。相机以 [分辨率] 与 [帧率] 录制 RGB-D，每次采集前用 [标定方法] 标定其外参。SE(3)-WAM 使用这一固定的第三人称视角；配方需要腕部视角的基线获得 [逐方法相机配置]。所有策略都在一块 RTX 5090 上运行。表 S8 定义六个任务。T1 与 T2 共用一条传送带，T3 使用转盘，T4 使用遥控玩具小车，T5 使用球杆驱动的两球碰撞，T6 使用斜坡。触碰或推动目标而未完成任务、单指夹持，以及目标离开工作空间之后的动作，都算作失败；[设备无效试验与安全干预按以下规则重做或计为失败]。



T1：传送带抓取　T2：移动容器放置　T3：转盘抓取



T4：移动小车抓取　T5：碰撞后拦截　T6：斜坡拦截

图 S3. **真机任务**。AI 生成的概念示意图，将替换为实验装置照片；箭头表示目标的预期运动。T6 图示滚动变体，该任务也包括滑动物体。

表 S8. 真机任务定义。$N = 100$：每个任务的训练示范数；每个任务另留 20 条示范用于验证。

任务	装置、运动与物体	运行范围；N	成功与失败条件
T1	传送带运输可抓取的方块。	[带速]；100	[稳定抓取并抬升；失败条件]
T2	传送带运输无盖盒，机械臂将方块放入其中。	[带速]；100	[放入并留存；失败条件]
T3	转盘携带方块绕轴运动。	[角速度、半径]；100	[稳定抓取并抬升；失败条件]
T4	遥控玩具小车在桌面上运动。	[速度、路径]；100	[抓取并抬起小车；失败条件]
T5	球杆驱动的球撞击第二个球，机械臂在碰撞后拦截第二个球。	[碰撞与碰后速度]；100	[碰后捕获；失败条件]
T6	球沿斜坡滚落或方块沿斜坡滑落，朝拦截区域运动。	[坡度、释放、速度]；100	[捕获并保持；失败条件]

C.2 位姿跟踪

跟踪不使用标记。每个物体有一个固定的参考模型，其原点、坐标轴与尺度在所有示范与试验中保持一致。Grounding DINO [44] 在第一帧中定位任务所指的物体，SAM 2.1 [59] 因果地传播其掩码，[跟踪器，例如 FoundationPose [76]] 把掩码内的 RGB-D 观测配准到参考模型。[图像分辨率、参考模型采集方式，以及丢失与恢复阈值。] 跟踪器在独立线程中运行。每个估计带有采集时刻、可用时刻与有效标志，只输出一次，之后的帧不会修改它。示范的训练标签在同一物体坐标系中通过多帧配准得到。在球类任务中，目标状态 token 保留球心的平移、速度与加速度，屏蔽其朝向与角运动，位姿头只监督平移。表 S9 报告跟踪精度。

C.3 试验

我们比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 Diffusion Policy [16]，每个方法在每个任务上运行 20 次试验。所有方法使用相同的预生成试验键，试验键确定物体实例、初始位姿与运动参数，按 [采样协议] 采样。试验按 [随机化的方法顺序] 进行，使装置的漂移不会与方法对齐。操作员重置场景。试验从第一个可用观测开始，机器人随时可以运动；试验在成功、失败或 [X] s 超时时结束。示范、开发试

表 S9. **真机位姿跟踪。**跟踪器相对无标记参照的平移（mm）与旋转（°）误差的中位数/p95、该参照的不确定度，以及观测丢失比例。球体不使用旋转。

目标	mm	°	参照不确定度	丢失
真机刚体	—	—	—	—
真机球体	—	–	—	—

表 S10. **真机成功次数**，按任务分列（成功次数/试验数，每个任务 20 次；任务定义见表 S8）。All：合并成功率（%）及 95% 二项区间。Δ：相对 SE(3)-WAM 的配对差值（百分点）及按试验键自助法得到的区间。

方法	T1	T2	T3	T4	T5	T6	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	–

验与测试试验来自不同的采集批次。SE(3)-WAM 从 DROID 基座出发逐任务微调（附录 A.5），基线在相同示范上训练或微调，采用 [各方法的初始化与训练设置]。表 S10 报告每个任务的成功次数、合并成功率的 95% 二项区间，以及按试验键自助法得到的配对差值。

D 补充结果

D.1 各任务结果与回合结局

表 S11 把表 1 中 Dynamic-14 留出结果按任务族分解，并报告首次接触时的位置误差及其回合数；表 S12 把它们按任务分解到每个方法，并给出 SE(3)-WAM 相对每个任务上最强其他方法的配对区间，以及每个方法的接触时刻误差。表 S13 报告回合如何结束，使以一种失败换取另一种失败的方法（例如更少的碰撞换来更多的超时）得以显现。每个失败都计入 SR 的分母。

[所有方法都失败的任务（如有）及原因。][基线优于 SE(3)-WAM 的任务。]SE(3)-WAM 的其余失败大多是 [主要失败模式]。

D.2 协议与延迟

表 S14 在另外三种协议下评估每个方法。暂停物理显示不计计算代价时相对表现如何变化；等延迟在 SE(3)-WAM 的 p95 延迟下比较所有方法；原执行方式检验共享执行器是否去掉了某个基线所依赖的能力。在暂停协议下，SE(3)-WAM 与 [名称] 的差为 [±X.X] 个百分点，在等延迟协议下为 [±X.X] 个百分点。原执行方式使各基线的 SR 至多改变 [X.X] 个百分点。表 S15 给出每个附加延迟下的成功率；其中 SE(3)-WAM 与最强基线的两行即图 1（右）的数据。

D.3 DOMINO

在 DOMINO [19] 上，我们在其 clean 一级设置的 24 个单臂 Franka 任务上比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA。所有方法使用该基准的示范、场景与原生评测器，各训练一个种子，每个任务与方法评测 50 个回合。我们报告 SR 与操作得分（MS）；MS 用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度（表 S16）。SE(3)-WAM 使用该领域的归一化，并读取指令所指目标在仿真器中的位

表 S11. **各任务族的成功率与接触误差**：Dynamic-14 留出场景，原生延迟。各任务族的 SR（%）在族内按任务等权。e_p：首次接触时的位置误差（mm），在有接触的 13 个任务上平均；n：发生首次接触的回合数，e_p 在这些回合上计算。

方法	抓取	放置	穿越	捕获	撞击	e_p	n
ACT	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—	—
PUMA	—	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—

图占位：图 S3——位姿噪声

横轴：干净位姿、标称相关噪声、两倍幅度噪声、带缺失观测的标称噪声；纵轴：SE(3)-WAM 在各任务族上的 SR，冻结权重，实时协议；匹配场景上的配对区间。

图 S4. **对位姿噪声的鲁棒性**。在目标位姿的合成扰动下 SE(3)-WAM 的 SR，相对干净位姿。

姿；没有有效位姿的槽位按附录 A.1 的方式掩码。基于 RGB 的基线不接收这一位姿。[概括 DOMINO 结果。]

D.4 位姿噪声

图 S4 在权重冻结的条件下，以附录 B.3 的三种合成位姿扰动评估最终模型，使用相同的留出场景、零附加延迟与全部三个训练种子。相对干净位姿，在标称相关噪声、两倍幅度噪声与缺失观测下，SR 分别变化 [X.X]、[X.X] 与 [X.X] 个百分点。

D.5 设计筛选

我们用更小的模型筛选了编码器、历史表示、预测目标，以及世界流与动作流的耦合方式：4 层、宽度 768，训练 4 轮（全局 batch 16 下 40,104 次更新），并用实时协议之前的同步执行器评测。每组保留各自的编码器与种子数（见下文），各条件只在组内比较。这些研究选出了最终模型的组件；第 4.4 节的四个消融随后在完整规模上检验其核心组件。

编码器与主干。 我们比较了与策略一同训练的 CNN、冻结的 DINOv3 ViT-S/16 与 ViT-L/16 [63]，以及 MAE ViT-B/16 [26]（MAE 参照为三个种子；表 S17），并选定 MAE。我们还在约 47.3M 主干参数、各三个种子的条件下，比较了共享注意力并分设前馈网络的主干与世界、动作参数完全分开的主干（表 S23），并选定共享注意力。

表 S12. **Dynamic-14 各任务的留出成功率**（%），涵盖表 1 中的全部方法，本文各变体取三个训练种子的平均、基线训练一次，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。DrVLA：DreamVLA。OWAM：OpenWAM-α。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。CV：匀速外推输入的 SE(3)-WAM 。σ：使用标称合成相关位姿噪声的 SE(3)-WAM（附录 D.4）。Δ：该任务上 SE(3)-WAM 相对最强其他方法之差及其 95% 配对区间。最后一行为接触时刻误差 e_t（附录 B.6）。任务代号见表 S4。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	DrVLA	OWAM	DWAM	DWAM+	CV	σ	本文	Δ [95% CI]
谐波抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
传送带抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
平移抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
遮挡抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
移动容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越（完整）	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获（桌面）	—	—	—	—	—	—	—	—	—	—	—	—	—	—
滑块捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—
罐体捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—
撞击后抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
任务等权	—	—	—	—	—	—	—	—	—	—	—	—	—	—
e_t (ms)	—	—	—	—	—	—	—	—	—	—	—	—	—	—

历史。 在冻结 DINO-L 编码器、每个条件一个种子的设置下，我们比较了只用当前状态、目标运动历史、RGB 窗口、Farnebäck 光流 [20]、带运动统计的光流 [49]、编解码器运动向量、视频 VAE 隐变量与压缩窗口（表 S18）。表 S19 在测试时把训练好的历史模型的过去目标位姿替换为当前位姿。

预测目标。 在冻结 DINO-L 编码器、每个条件一个种子的设置下，我们比较了十五种未来目标（表 S20），从只预测目标和图像空间预测到按角色组合的预测（表 S21）。第二组使用 MAE 编码器与一个种子，从选定配置中逐一移除未来外观目标。表 S22 离线比较最终模型学到的 SE(3) 预测与由同一位姿历史得到的匀速和匀加速外推。

耦合方式。 在 MAE 编码器、每个条件三个种子的设置下，我们比较了世界流与动作流的六种耦合方式。R0 关闭所有预测损失。R1 在世界流中加入一个物体查询和每个 patch 一个查询，它们读取 $\mathcal{S}$、$\mathcal{M}$ 与彼此，并承载预测读出，但与动作之间没有任何连接。R2 让动作 token 在每一层读取这些查询，R3 让这些查询读取动作，R4 同时开启两个方向；在 R3 和 R4 中，世界状态在每个 Euler 步都要重算。R5 在每次查询中解码一次预测，把目标轨迹与带可见性的流（旋转采用连续的 6D 表示）经几何编码器（0.37M 参数）编码为动作可读取的 token。把预测送给动作没有带来稳定的增益：R1 平均比 R0 高 [3.14] 个百分点，各种子的差值为 [−1.29]、[+9.64] 与 [+1.07]，而读取或解码预测的耦合方式在不同种子间符号不一（表 S23）。因此我们只把预测用作训练监督，这也使部署无需承担其代价。

D.6 执行时刻的预测

图 S5 按物理时间对齐查询、预测、真值、下发的动作与首次接触。这些示例显示预测误差出现在哪里，例如撞击时刻或滚动物体离开斜坡时。

表 S13. **结局类别**：Dynamic-14 留出场景（各类 episode 占比，%，种子平均，实时协议）。类别定义见附录 B.1；每行合计为 100。含噪位姿行复用鲁棒性实验中标称合成时序相关噪声的轨迹。

方法	成功	安全	任务违规	边界	超时	无效
ACT	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—
SE(3)-WAM，含噪位姿	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—

表 S14. **评测协议对照**：Dynamic-14 留出场景（SR，%）。暂停：共享执行器，推理期间物理暂停。等延迟：共享执行器，所有方法均计入 SE(3)-WAM 的 p95 延迟。原执行方式：实时协议下使用各方法自身的执行方式。实时：表 1 的协议。超时：实时协议下出动作时间超过 50 ms 控制周期的查询比例（%）。

方法	暂停	等延迟	原执行执行器	实时	超时 (%)
ACT	—	—	—	—	—
Diffusion Policy	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—
DynamicVLA	—	—	—	—	—
PUMA	—	—	—	—	—
DreamVLA	—	—	—	—	—
OpenWAM-α	—	—	—	—	—
DynamicWAM	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	–	—	—
SE(3)-WAM	—	—	–	—	—

D.7 补充视频

补充视频展示 SE(3)-WAM 与最强基线在全部六个真机任务上的试验（叠加跟踪得到的位姿）、每个任务族的 Dynamic-14 回合及训练期预测头的预测，以及失败案例。

表 S15. **成功率随附加延迟的变化**：Dynamic-14 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的原生与 +150 ms 列。

	附加延迟（ms）				
方法	0	50	100	150	200
ACT	—	—	—	—	—
Diffusion Policy	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—
DynamicVLA	—	—	—	—	—
PUMA	—	—	—	—	—
DreamVLA	—	—	—	—	—
OpenWAM-α	—	—	—	—	—
DynamicWAM	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—

表 S16. **DOMINO 评测**（24 个单臂 clean-L1 任务；每个方法一个训练种子，每个任务与方法 50 个回合）。SR（%）按交互类型分组并在任务上平均；MS 为操作得分。协议见附录 D.3。

方法	拦截	跟踪	全部	MS
$\pi_{0.5}$	—	—	—	—
DynamicWAM	—	—	—	—
PUMA	—	—	—	—
SE(3)-WAM	—	—	—	—

表 S17. **观测编码器**（筛选规模，附录 D.5）。参数量：编码器参数；p95：出动作时间。

编码器	参数	训练	SR	SR_{150}	p95
CNN	—	是	—	—	—
DINOv3 ViT-S/16	22M	冻结	—	—	—
DINOv3 ViT-L/16	300M	冻结	—	—	—
MAE ViT-B/16*	86M	冻结	—	—	—

表 S18. **历史表示**（筛选规模：冻结 DINO-L 编码器，一个训练种子，1,400 个场景）。前八个条件接收当前目标位姿，最后一个条件另加目标运动历史。

历史输入	成功数 / 1,400	SR (%)
当前图像	748	53.43
RGB 窗口	662	47.29
光流	720	51.43
光流＋运动统计	723	51.64
编码器运动向量	733	52.36
视频 VAE 隐变量	710	50.71
压缩窗口（按时间）	634	45.29
压缩窗口（均匀）	670	47.86
当前图像＋目标运动历史	824	58.86

表 S19. **静止历史干预**（表 S18 中的历史模型，1,400 个场景）。测试时把过去的目标位姿替换为当前位姿，并重新计算运动学特征。

目标历史	成功数 / 1,400	SR (%)
真实历史	824	58.86
静止历史替换	9	0.64

表 S20. 预测目标筛选的未来目标定义。张量形状不含 batch 和 query 轴。除保留解码器自身对应关系的 codec 向量外，位移均从当前状态累计。所有监督目标均来自记录的演示。未来深度、DINO 与动态 RGB 同时也是选定模型仅在训练中使用的辅助目标。

目标	形状	几何支持、单位与有效条件
目标位姿	8×6	累计平移 (m) 和左相对旋转向量 (rad)；位姿和 query 有效。
场景流，14×14 网格	$196 \times 8 \times 3$	固定源点网格；基座坐标系中的累计米制位移；源深度有效且未来位移有限。
目标轨迹（二维）	$32 \times 8 \times 3$	目标掩码内的源点；两个图像位移通道与可见性；填充点无效。这是 P09 的目标，不是三维刚体位姿拟合。
物体 DINO	8×1024	按掩码面积加权汇聚未来 patch 特征；沿通道作层归一化；掩码面积为正。
场景轨迹（二维）	$196 \times 8 \times 3$	网格源点；两个图像位移通道除以 224，另加一个可见性 logit。
稠密二维位移	$8 \times 2 \times 224 \times 224$	固定源像素；位移除以 224；源像素有效且投影有限。
编码器运动向量	$8 \times 2 \times 64 \times 64$	每对未来 / 当前帧编码为 P/I 帧；向量除以 64；使用有效向量区域。
视频 VAE 隐变量	$48 \times 2 \times 14 \times 14$	冻结的 Wan2.2 VAE 后验均值及该 VAE 自身的归一化；两组分别截至 200 与 400 ms。
未来深度	$8 \times 1 \times 224 \times 224$	米制深度；像素值为有限正数。
未来 DINO	$8 \times 196 \times 1024$	冻结的 DINOv3 ViT-L/16 教师 [63]，14×14 个 patch，沿通道作层归一化。
动态 RGB	$8 \times 3 \times 224 \times 224$	在世界坐标中移动超过 1 mm 的可见表面（含机器人）上取 RGB 并除以 255。

图占位：图 S4——与实际发生对齐的预测

第 1–4 行：每种运动类型（传送带、旋转目标、滚动捕获、撞击后）预测误差为中位数的留出回合；**第 5 行：**一次失败。**列：**τ_t 时的查询帧；第一条被执行指令的执行时刻 τ^a 的帧；基座坐标系中的 3D 小图。**叠加：**蓝色为过去的 SE(3) 位姿；橙色为训练期预测头给出的 $\tau_t + \delta_h$ 时的目标三轴与稀疏流箭头；灰色为同一物理时刻的真值位姿；紫色为下发的夹爪路径；首次接触处加标记。每行下方的条带绘出学习的 SE(3)、匀速与匀加速预测的平移与旋转误差随时域的变化。第 5 行用红色标注。

图 S5. 训练期预测头在留出回合上的预测，按物理时间与真值和下发的动作对齐。第 1–4 行为每种运动类型预测误差为中位数的回合，第 5 行为一次失败。

表 S21. **预测目标**（筛选规模）。第一组使用冻结 DINO-L 编码器与种子 0，其 140 个开发场景与其余 1,260 个场景分别报告。第二组使用 MAE 编码器与种子 1，在 1,400 个场景上评测；它保留场景流、SE(3) 与当前目标 RGB 重建，并移除未来外观目标。请在组内比较各条件。

编号	未来监督	开发集成功数 / 140	成功数 / 1,260	SR_{1260} (%)
P00	无	88	791	62.78
P01	三维场景流	95	782	62.06
P02	SE(3)	92	789	62.62
P03	场景流＋ SE(3)	93	786	62.38
P04	视频 VAE 隐变量＋ SE(3)	92	783	62.14
P05	稠密二维位移＋ SE(3)	87	746	59.21
P06	编码器运动向量＋ SE(3)	86	795	63.10
P07	稀疏场景二维轨迹＋ SE(3)	90	807	64.05
P08	场景流＋物体 DINO	89	794	63.02
P09	场景流＋目标二维轨迹	88	808	64.13
A_α	P03 ＋运动幅值	89	778	61.75
P12	P03 ＋深度	90	791	62.78
P13	P03 ＋ DINO	92	788	62.54
P14	P03 ＋动态 RGB	89	790	62.70
P15	P03 ＋深度 / DINO / 动态 RGB	94	802	63.65

AUX0 MAE-B：未来外观辅助	成功数 / 1,400	SR_{1400} (%)
无	894	63.86
仅深度	867	61.93
仅 DINO	946	67.57
仅动态 RGB	926	66.14
三者全部（已有参照）	995	71.07

表 S22. **离线预测误差。**在同一批留出观测上计算 400 ms 处的目标位置误差（mm）。CV 和 CA 是由因果位姿历史计算的解析外推；学习位姿头读取冻结完整模型的状态。这些诊断与表 1 中经过训练的匀速输入策略不同。

	匀速	谐波	滚动/滑动	撞击
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的位姿头	—	—	—	—

表 S23. **耦合方式 R0–R5 与主干**（筛选规模：MAE 编码器，各三个训练种子；附录 D.5）。

耦合	SR 均值	SR 标准差	p95 (ms)
R0 （关闭未来损失）	—	—	—
R1 （查询，无连接）	—	—	—
R2 （世界 → 动作）	—	—	—
R3 （动作 → 世界）	—	—	—
R4 （双向）	—	—	—
R5 （解码几何）	—	—	—

E 误差分解

本附录推导促成 SE(3)-WAM 设计的式 2 的分解（第 3.2 节）。它描述一个估计的误差如何随领先时长与运动而变化，并不是成功率的模型。

E.1 平移

设执行时刻目标的真实位置为 $\mathbf{p}(\tau^{\mathrm{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，其中 $\mathbf{v}$ 为 τ_t 时的速度，$\boldsymbol{\rho}$ 为其余运动；策略的估计为 $\hat{\mathbf{p}}(\tau^{\mathrm{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。减去再加上 $\mathbf{v}\hat{\Delta}$ 得到恒等式

$$\begin{aligned}\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}}) = \big[\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\big] + (\hat{\mathbf{v}} - \mathbf{v})\hat{\Delta} \\ + \mathbf{v}(\hat{\Delta} - \Delta) + (\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}),\end{aligned} \tag{S3}$$

由三角不等式即得式 2，其中 $e_v = \|\hat{\mathbf{v}} - \mathbf{v}\|$，$e_{\mathrm{dyn}} = \|\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}\|$。残差 $\boldsymbol{\rho}$ 恰好是匀速外推遗漏的那部分运动：在匀加速 $\mathbf{a}$ 下 $\boldsymbol{\rho} = \frac{1}{2}\mathbf{a}\Delta^2$，因此由历史估计加速度可以消除部分 e_{dyn}；撞击、滚动接触与摩擦变化留下的部分则只有动力学模型才能减小。对学习得到的预测器，其估计拆分为 $\hat{\mathbf{v}}\hat{\Delta}$ 与 $\hat{\boldsymbol{\rho}}$ 的方式并不唯一，因此这一分解说明的是每一项需要什么信息，而不是某个网络如何使用这些信息。

E.2 旋转与接触点

记 $R(\tau^{\mathrm{a}}) = \mathrm{Exp}(\boldsymbol{\omega}\Delta + \boldsymbol{\eta})R(\tau_t)$ 与 $\hat{R}(\tau^{\mathrm{a}}) = \mathrm{Exp}(\hat{\boldsymbol{\omega}}\hat{\Delta} + \hat{\boldsymbol{\eta}})\hat{R}(\tau_t)$。绕同一固定轴的旋转可以相加，于是

$$\theta = \big\|\,\mathrm{Log}(\hat{R}(\tau^{\mathrm{a}})R(\tau^{\mathrm{a}})^{\top})^{\vee}\big\| \le \theta_{\mathrm{loc}} + \hat{\Delta}\, e_\omega + \|\boldsymbol{\omega}\|\, e_\tau + e_\eta, \tag{S4}$$

其中 θ_{loc} 为当前朝向误差，e_ω 与 e_η 的定义与平移相同；对一般旋转，Baker–Campbell–Hausdorff 公式会引入角度的二阶项。物体坐标系中位于 $\mathbf{c}$、$\|\mathbf{c}\| = r$ 的接触点，其世界位置为 $\mathbf{p} + R\mathbf{c}$，误差为 $(\hat{\mathbf{p}} - \mathbf{p}) + (\hat{R}R^{\top} - I)R\mathbf{c}$。由于转角为 θ 时 $\hat{R}R^{\top} - I$ 的算子范数为 $2\sin(\theta/2)$，

$$e_{\mathrm{c}} \le \|\hat{\mathbf{p}} - \mathbf{p}\| + 2r\sin(\theta/2) \le \|\hat{\mathbf{p}} - \mathbf{p}\| + r\theta. \tag{S5}$$

因此朝向误差按力臂放大后进入接触；依赖朝向的抓取或放置需要目标完整的 SE(3) 状态。

E.3 环境：障碍物与驱动物

障碍物。 假设执行路径使机器人与所持物体的每个点，与其经过的环境点的预测位置至少相距 m。那么在某个环境点发生碰撞，要求该点的真实位置与其预测至少相差 m。在这一假设下，小于间隙的环境误差不会导致碰撞，这正是当 $m \gg \varepsilon$ 时对周围环境的粗略估计可以足够的原因。该假设针对的是执行路径：SE(3)-WAM 并不显式保持这一余量，因此粗粒度环境监督的作用由消融实验检验（第 4.4 节）。在网格上采样的流也可能漏掉比其间距更细的结构。

驱动物。 驱动物（例如传送带、斜坡或撞击器）通过传给目标的运动起作用。因此，它对接触的影响通过目标自身的各项进入式 2；当驱动物改变目标的运动时（例如撞击），主要体现在 e_{dyn} 中。策略只需对驱动物的运动了解到足以预见它何时、如何作用于目标即可；由此产生的目标运动正是专用 SE(3) 预测所监督的内容。

E.4 适用范围

这一分解针对接触之前运动由外部决定的刚体目标。它不涵盖可变形或铰接的目标，其运动不由六个数决定；也不涵盖接触之后的运动，后者取决于动作本身，需要以动作为条件的预测。物体的角色随时间改变的场景，例如依次操作多个物体的任务，同样不在其范围内。

F 更多相关工作

本附录补充第 2 节中只简要涉及的工作。

动态操作与延迟。 经典系统通过预测跟踪 [4] 与视觉伺服 [32] 补偿延迟，并在估计的轨迹上规划，以抓取或拦截运动物体 [2, 6, 27]，后来又与抓取和可达性规划结合 [1, 52]。学习型视觉运动策略 [16, 98] 与视觉—语言—动作模型 [9, 11, 37, 55, 56, 106] 能够跨物体与指令泛化，但它们大多在模型计算期间场景保持静止的条件下训练和评测。在面向运动场景的学习方法中，DynamicManip 从单条静态示范合成动态示范 [41]，DynaWM 针对运动物体修正基础 VLA 的动作块 [14]。

世界模型与世界—动作模型。 世界模型已被用于基于视觉预见的规划 [21]、在学习的隐空间中进行强化学习 [24, 25]，以及在预训练视觉特征上规划 [3, 102]。在操作任务中，生成的帧或子目标图像已被转化为动作 [8, 17, 96]。对 WAM 的研究比较了视频流与动作流应如何交换信息 [75, 86]，以及上下文应有多长、压缩到什么程度 [31, 47]。其他预测目标还包括按运动加权的视频 [33]，以及光流或运动向量 [15, 42]。

3D 与运动表示。 以物体为中心的点云提升泛化能力 [105]，3D 与 4D VLA 把 3D 与时空输入引入大模型 [93, 99]。稠密像素运动也被用作中间表示加以预测 [54, 57, 58]。除 SE(3) 分解之外，3D 动态场景记忆 [83] 与场景流估计 [45, 69] 也刻画场景如何运动。点跟踪器、位姿估计器与前馈重建模型 [34, 73, 76, 80, 92] 可以从视频中提取这类运动标签；我们的 DROID 预训练使用 PointWorld 提取的 3D 点轨迹 [30]（附录 A.5）。