SE(3)-WAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景；然而推断场景运动多花的每一毫秒，都会让目标走得更远。世界—动作模型以统一的精细程度预测未来图像或隐变量，把时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器速度快，却忽略了约束或推动其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；周围物体只通过它们留下的间隙和传给目标的运动起作用；其余背景则与任务无关。我们提出 SE(3)-WAM，一个建立在这种按角色区分精度的 4D 结构之上的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，并被训练去精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景。这些预测只作为训练监督，部署时被跳过，因此推理既不需要过去的帧，也不需要生成未来，速度足以支撑实时控制。在推理期间场景持续运动的仿真基准 Dynamic-14 上，SE(3)-WAM 的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在目标运动形式多样的六个真机任务上，它的成功率为 [XX]%。

图占位：图 1 预览——运动场景的按角色区分精度的 4D 视图（真机）

版式：通栏，两部分。**(a) 左侧，约 62%：**直线运动抓取的一帧真机画面，取动作块发出的瞬间。按论文语义配色叠加：蓝色为因果跟踪器给出的目标过去 SE(3) 位姿（$-350\ldots0$ ms 的小三轴，随时间变淡）；橙色为动作块各执行时刻的目标 SE(3) 预测，取自离线运行的训练期预测头；浅橙色箭头为覆盖整个场景的14×14 网格稀疏 3D 流；紫色为在 τ^{a} 与目标相遇的指令夹爪路径。灰色虚影标出采集时观测到的位姿，红色虚线箭头示意反应式策略会在何处闭合。图像下方的细时间轴：采集 $\tau_t \rightarrow$ 延迟 $\ell_t \rightarrow$ 执行 τ^{a}。**(b) 右侧，约 38%：**上：“图像空间 WAM：以统一精细程度预测未来帧或隐变量”（胶片图标）；中：“SE(3)-WAM：目标用 SE(3)，整个场景用稀疏 3D 流，仅训练时使用”（三轴 + 稀疏箭头）；下（**必需**）：SE(3)-WAM 与最强基线的成功率随附加延迟（0–200 ms）的变化（数据：附录 C.2 的延迟扫描）。**规则：**真实照片不做修饰；叠加由该次试验记录的跟踪、预测与指令数据绘制；图注说明该次试验的结果。

图 1. **运动场景的按角色区分精度的 4D 视图。**从图像采集到第一条指令之间，传送带上的零件移动的距离超过了抓取所能容忍的误差。SE(3)-WAM 编码目标的度量运动（蓝色），并被训练去精确预测目标的 SE(3) 位姿、以稀疏 3D 流粗略预测整个场景（橙色），因此它的指令在执行时与目标相遇（紫色）。图像空间的世界—动作模型则以统一精细程度预测外观。右：Dynamic-14 上成功率随附加延迟的变化。

1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[5, 10, 22, 35, 49, 56, 71]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。这带来两个相互耦合的困难。单张图像无法揭示目标如何运动；而等到动作执行时，目标已不在它被看到的位置：传送带上以 0.1 m/s 运动的零件在 150 ms 的延迟中移动 15 mm，超过了平行夹爪抓取通常能容忍的误差（图 1）。

近期工作为策略加入对过去运动的记忆和对未来的预测 [12, 31, 44, 63]。两者都消耗动态操作最缺乏的资源——时间：更丰富的历史和更稠密的预测增加计算，增加的延迟又放大了预测本应消除的误差。因此，现有设计在信息与速度之间权衡。基于视频的 WAM 以统一的精细程度预测完整的未来帧或隐变量 [49, 56]，以运动线索为条件时也是如此，因为这些线索仍在图像空间中，且不把目标与其他运

动区域分开 [31]；只预测动态区域或显著 token 的方法仍在图像空间中预测 [44, 63]。两者都把大部分容量花在外观上，而决定接触的量——动作执行时目标的度量位姿——仍然是隐式的。以目标为中心的预测器和预测物体层面未来的动态 VLA 位于另一端 [12, 17, 32]：它们速度快，却看不到可能阻挡或改变目标运动的周围环境。它们都没有提供这样一种对运动场景的认识：在接触所依赖之处精确，在其他地方粗略，并且在执行时使用的代价很低。

我们的关键观察是：动态策略需要精确知道的东西其实很少。接触取决于动作执行时刻目标的位姿，精度要到毫米；周围物体只通过它们留下的间隙和传给目标的运动起作用，粗略的估计即可把握；其余背景则与任务无关。这些认识也不必在测试时计算：在训练中作为监督的预测，会塑造策略所学到的表示，部署时即可去掉 [60]。SE(3)-WAM 建立在这两点之上（图 2）。它看到当前图像，以及目标与机器人的度量 SE(3) 短历史；这些历史直接表达运动，而不必编码一叠过去的帧。世界流被训练在同一个度量 4D 空间中精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景；动作流读取世界流的摘要，并按其延迟允许的频率重新规划。因此，SE(3)-WAM 以接近反应式策略的延迟，获得了度量预测带来的精度。

我们在 Dynamic-14 上评估 SE(3)-WAM 。这是一个包含 14 个任务的仿真基准，观测、场景运动与动作执行共用同一个物理时钟，策略计算期间场景持续运动。SE(3)-WAM 以 [XX.X]% 的成功率达到最优，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms；在六个真机任务上，它的成功率为 [XX]%，最强基线为 [XX]%；在 DOMINO [12] 的 24 个任务上它同样领先。五个最终规模对照分别检验目标运动历史、未来监督及其两项几何成分的贡献，并比较按角色区分精度与统一精度的预测。

我们的贡献有三点：

- 我们提出面向动态操作的按角色区分精度的 4D 建模。分析延迟与估计误差如何传递到接触点可知，只有目标需要毫米级精度；因此我们用度量的 SE(3) 位姿历史和未来轨迹精确表示目标，用稀疏 3D 流粗略表示整个场景，二者都在度量三维空间而非图像空间中。
- 我们提出 SE(3)-WAM ，一个以这些按角色区分精度的 4D 预测作为训练监督的世界—动作模型，其延迟接近反应式策略。
- 我们构建了 Dynamic-14 ，其中推理期间场景持续运动；SE(3)-WAM 在该基准、DOMINO 和六个真机任务上取得最优结果。

2 相关工作

动态操作。 补偿感知与执行之间的时间差是一个经典问题，从带纯滞后的控制 [41]，到用卡尔曼类滤波器跟踪目标并规划拦截的抓取系统 [1–3, 34]；这些系统精确，但针对每种物体和任务专门设计。近来，学习型策略开始进入运动场景。PUMA 读取历史光流，并以未来物体特征作为监督 [12]；DynamicWAM 以光流和运动学描述子为 WAM 提供条件，并以实时分块方式执行 [31]；另一些方法预测显著 token、未来图像或紧凑的未来编码，并在测试时把预测提供给策略 [32, 44, 61, 64]；DynaWM 针对运动物体修正基础 VLA 的动作块 [9]，DynamicManip 从单条静态示范合成动态示范 [26]。执行调度方案则从执行一侧减小或掩盖延迟：让推理与执行重叠 [37, 39, 54]，保持相邻动作块一致 [6, 29]，或以执行时刻为条件 [45, 48]。它们决定动作何时计算、何时执行，而 SE(3)-WAM 改变的是策略所表示的内容；我们让所有方法在同一个实时执行器下运行，并以各自的原执行方式作为对照。DOMINO [12] 与 PhysMani-Bench [61] 提供了多样的动态操作任务，但它们公开的默认评测流程只在策略返回预测之后才推进仿真；Dynamic-14 则在推理期间推进场景，并让每个方法承担其实测延迟。

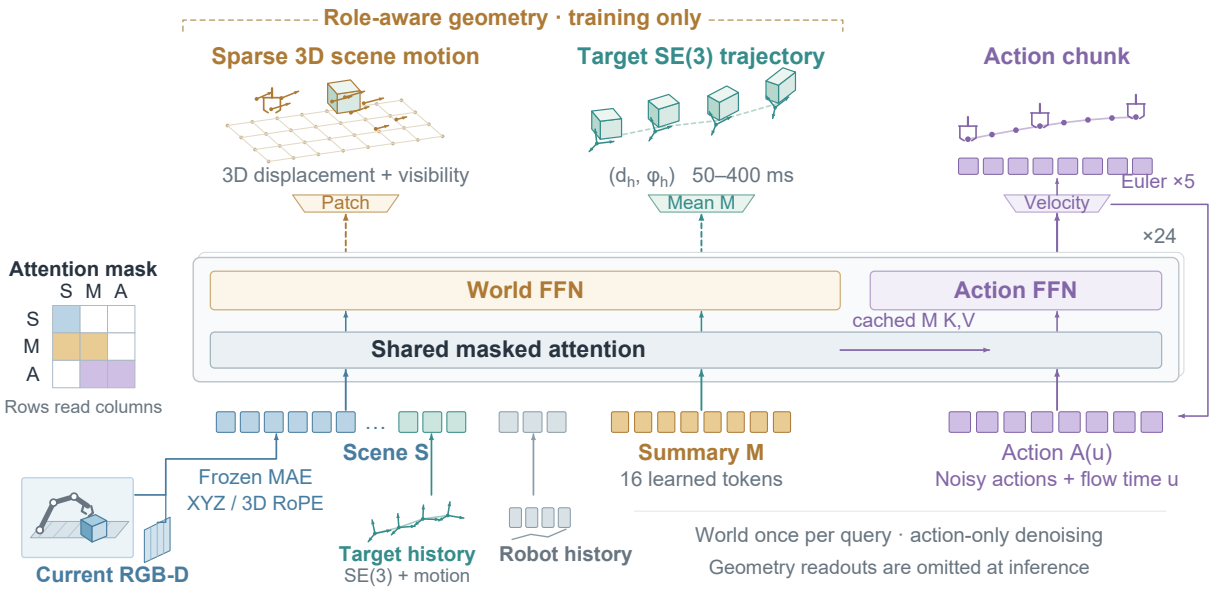


图 2. **SE(3)-WAM 架构。**自下而上阅读。当前 RGB-D 和目标、机器人状态历史输入世界流。世界流与动作流共享注意力，使用独立的 FFN。仅训练时使用的预测头（虚线）从 patch 状态预测全场景稀疏 3D 位移及可见性，从摘要均值预测目标 SE(3) 轨迹。动作通过结构化掩码读取摘要 token。推理时，每次查询只计算一次世界流的键和值，在 5 个 Euler 步中复用，跳过预测头。几何图形为示意。

世界—动作模型中的预测监督。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [25, 49, 56, 69]，其基础是把视频预测作为策略目标 [18, 46, 53]。由于视频代价高且以外观为主，近期工作改变了预测的内容，例如动态区域、深度与语义特征 [63]，与 RGB 并列的光流和几何 [59]，物体掩码或物体槽 [30, 57]，以及紧凑隐变量 [23, 24]；它们也在追问测试时是否需要预测：Fast-WAM 发现跳过测试时的想象仍保留了视频建模的大部分收益 [60]，PUMA 等方法在训练后去掉预测器 [12, 43, 65]。SE(3)-WAM 沿用这种只在训练时使用预测的方式，改变的是监督的目标：不是统一分辨率的像素、特征或隐变量，而是一个精度随各部分在接触中所起作用而定的度量 4D 状态。

运动的几何表示。 度量 3D 输入使策略更精确、样本效率更高 [14, 20, 38, 62]。运动已被表示为 2D 点轨迹 [4, 51, 55, 67]、3D 流 [15, 19, 58, 68]，以及物体关键点或 SE(3) 轨迹 [17, 33, 42, 52]；刚体分解也早已用于学习场景动力学 [7, 8]。这些工作用同一种表示描述场景：要么处处是稠密的流或轨迹，要么每个物体一个位姿；DOCIR 把机器人、目标与障碍物分开，但只是作为输入编码 [11]。SE(3)-WAM 按角色分配精度：粗粒度的稀疏 3D 流描述整个场景，接触依赖毫米级精度的目标另由其 SE(3) 历史与预测描述。

3 SE(3)-WAM

SE(3)-WAM 是一个以按角色区分的精度表示动态场景的世界—动作模型（图 2）。它编码当前 RGB-D 帧以及目标 SE(3) 位姿与机器人状态的短历史：冻结的 MAE ViT-B/16 [16] 把 RGB 编码为 196 个 patch token，深度为每个 patch 给出其中心点在机器人基座坐标系中的度量 3D 位置。这 212 个场景 token 与汇聚它们的 16 个可学习摘要 token 构成世界流；训练时，预测头以目标未来的 SE(3) 轨迹与整个场景的稀疏 3D 流监督世界流。动作流与世界流共享注意力，读取其摘要 token，并以条件流匹配 [27] 生成动作块。

3.1 问题定义

SE(3)-WAM 从示范中学习策略。在第 t 次查询时，策略接收在时刻 τ_t 采集的 RGB 图像、深度图与机器人状态，以及机器人状态和目标物体位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$（机器人基座坐标系）的短历史。它输出一个动作块 $(\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1})$，每个控制周期 Δ_a 一条指令，按相对采集时刻的时间索引：第 j 条指令对应的执行时刻为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\mathrm{task}}. \tag{1}$$

其中 d_{task} 为任务内置的指令延迟。动作块要经过延迟 ℓ_t 才可用，因此 $j\Delta_a < \ell_t$ 的指令已经过期，其余指令在各自的时刻 $\tau^{\mathrm{a}}_{t,j}$ 执行。因此，指令必须适合 $\tau^{\mathrm{a}}_{t,j}$ 而非 τ_t 时刻的目标位姿，而这一位姿只能由 τ_t 的观测来估计；被执行指令的领先时长 $\Delta = \tau^{\mathrm{a}}_{t,j} - \tau_t$ 至少为 ℓ_t，因而随推理的每一毫秒增长。场景中的物体扮演不同的角色。目标是位姿必须在接触或容纳容差 ε 内对齐的物体，例如要抓取的物体或要放入的容器。环境由约束或推动目标运动的物体组成：障碍物（例如遮挡物或导线）须以间隙 m 避开，驱动物（例如传送带、斜坡或撞击器）推动目标运动。场景的其余部分不影响任务。第 3.2 节分析这一估计的误差如何依赖领先时长与这些角色，并据此导出 SE(3)-WAM 的表示。

3.2 按角色区分精度的 4D 表示

哪些必须精确。 设策略显式或隐式地依据 τ^{a} 时刻目标位姿的一个估计行动，其位置误差为 e、旋转误差为 θ。力臂为 r 的接触点的误差至多为 $e + 2r\sin(\theta/2)$。把目标在领先时长内的运动写成匀速 $\mathbf{v}$ 加残差（加速、滚动、撞击），并把策略所假定的领先时长记为 $\hat{\Delta}$，可得

$$e \le e_{\mathrm{loc}} + \hat{\Delta}\, e_v + \|\mathbf{v}\|\, e_\tau + e_{\mathrm{dyn}}, \tag{2}$$

其中 e_{loc}、e_v、$e_\tau = |\hat{\Delta} - \Delta|$ 与 e_{dyn} 依次为当前位置、速度、时刻与残差运动的误差（附录 A.1）。容差 ε 通常只有几毫米，旋转误差还会经力臂放大，因此必须精确掌握目标的位姿与运动。环境所需的精度低得多：障碍物只需以间隙 m 避开，m 通常远大于 ε；驱动物通过传给目标的运动起作用，这一运动随后体现在目标自身的未来中；两种情况下，对环境的粗略估计都已足够（图 3c）。因此，我们用度量 SE(3) 状态表示目标，包括其已观测的历史与预测的轨迹，并用稀疏 3D 流表示整个场景；它们都在机器人基座坐标系与物理时间中表示。

延迟允许什么。 延迟两次进入式 (2)：一次通过放大每个速度误差的领先时长，一次通过残差累积的运动。按式 (2)，消耗推理时间的信息只有当它消除的误差多于额外延迟带来的误差时才划算。SE(3)-WAM 让输入保持廉价：只用一张当前图像和低维的状态历史，而不用过去的帧；预测只用于监督训练，因而不增加推理时间（第 3.4 节）。

目标运动：历史与预测。 单个位姿无法揭示目标如何运动（图 3a）。目标历史覆盖最近 8 个控制步（20 Hz 下为 350 ms）。它由基座坐标系下的当前目标位姿和相邻采样之间的七段区间运动组成，每段包含平移、相对旋转、时间间隔，以及有限差分得到的速度与加速度，均为物理单位，构成 8 个目标状态 token（附录 A.2）。这些 token 直接给出 e_v 与部分 e_{dyn} 所依赖的速度和加速度，代价只是几个低维 token。机器人历史另外提供 8 个末端执行器状态 token。在仿真中，目标位姿来自仿真器；在真机上，由因果跟踪器从 RGB-D 流中估计（附录 D）。

预测描述指令执行时目标会在哪里（图 3b）。它覆盖固定的物理时刻 $\tau_t + \delta_h$，其中 $\delta_h = h{\cdot}50\,\mathrm{ms}$，$h = 1, \ldots, 8$，即采集后 50 ms 到 400 ms，因此 $j \ge 1$ 的每个指令时刻 $\tau^{\mathrm{a}}_{t,j}$ 都是一个预测时域。与我们所

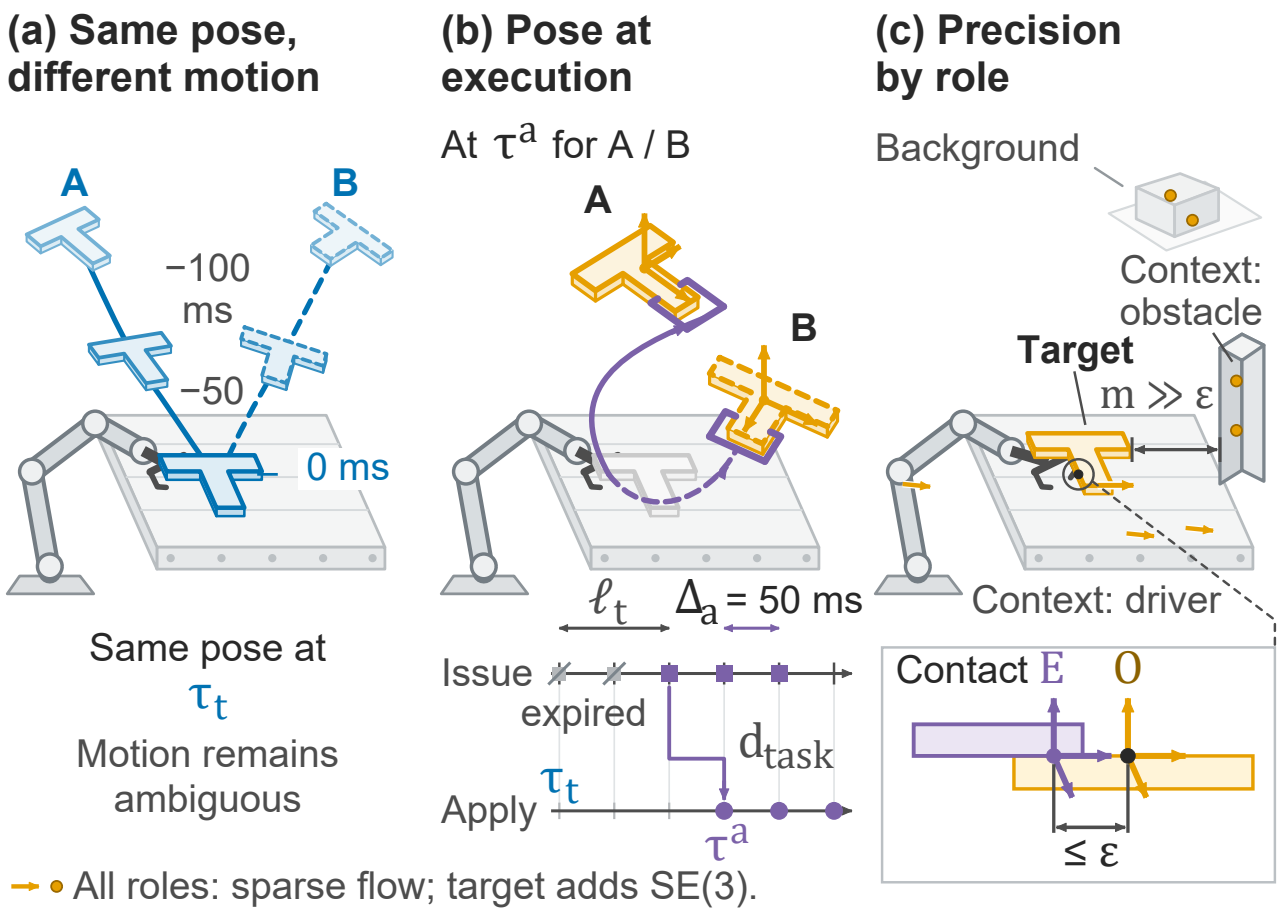


图 3. **作用于运动目标**（示意图）。(a) 不同运动历史在采集时刻 τ_t 到达相同位姿。(b) 在同一执行时刻 τ^{a}，目标的位置和朝向不同，因而需要不同指令（紫色）。指令发出时刻从采集起每隔 $\Delta_a = 50\,\mathrm{ms}$ 排列；灰色时隙在延迟 ℓ_t 期间过期。保留的指令经过任务延迟 d_{task} 后作用于机器人，首次作用时刻为 $\tau^{\mathrm{a}} = \tau_t + \ell_t + d_{\mathrm{task}}$。(c) 接触要求 E 与 O 在毫米级容差 ε 内对齐；障碍物留下间隙 $m \gg \varepsilon$，传送带驱动目标，远处背景不影响任务。稀疏流覆盖所有角色（箭头表示位移，圆点表示零位移），目标额外接受精细 SE(3) 监督。位姿与延迟均为示意（$\ell_t = 2\Delta_a$、$d_{\mathrm{task}} = \Delta_a$）；接触区域已放大。

有的运动标签一样，它从当前状态累计，各损失只在有效标签上取平均。对每个时域，目标的运动为

$$\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t), \quad \phi_h = \mathrm{Log}\big(R(\tau_t{+}\delta_h)R(\tau_t)^{\top}\big)^{\vee}. \tag{3}$$

摘要 token 最终状态均值上的线性位姿头预测 $(\hat{\mathbf{d}}_h, \hat{\phi}_h)$，损失为

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|}\sum_{h\in\mathcal{V}}\Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R\, d_{\mathrm{SO(3)}}\big(\hat{R}_h, R_h\big)^2\Big], \tag{4}$$

其中 $\hat{R}_h = \mathrm{Exp}(\hat{\phi}_h^{\wedge})R(\tau_t)$，$\mathcal{V}$ 为有效时域集合。由于位姿头读取的是摘要 token，即动作唯一能读取的世界 token（第 3.3 节），精确的目标监督塑造的正是动作所使用的表示。目标的过去与未来因此共用同一个度量坐标系与同一条时间轴。

场景运动：稀疏 3D 流。 14×14 网格上 196 个 patch 的中心点覆盖目标、机器人与周围环境。对每个点 i 和时域 h，其最终 patch token 上的线性头预测基座坐标系中的位移 $\hat{F}_{ih} \in \mathbb{R}^3$ 与可见性 logit $\hat{o}_{ih}$，

损失为

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h)\in\mathcal{V}_F} \Big[\tfrac{1}{3} \big\| (\hat{F}_{ih} - F_{ih})/s \big\|^2 + \mathrm{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \tag{5}$$

其中 s 为在训练标签上拟合的固定尺度，o_{ih} 为可见性，$\mathcal{V}_F$ 为有效标签集合。网格对工作空间稀疏采样，相邻点约相距 [X] mm。因此，流以这一间距为环境与机器人提供运动估计，在静止的背景上接近于零，而目标还额外接受式 (4) 的专用 SE(3) 监督。流监督的是摘要 token 从中汇聚信息的 patch token，比精确的目标监督低一层；这就是 SE(3)-WAM 按角色分配精度的方式。

辅助监督。 另有两类目标对表示起正则作用；我们在开发场景上选定了它们（附录 E）。patch token 上的未来外观头在每个时域预测度量深度、冻结 DINOv3 教师 [40] 的特征，以及运动表面的 RGB。此外，摘要 token 上的一个小头重建当前目标区域的 RGB，使摘要与目标关联，而不使用未来标签。它们的损失构成 $\mathcal{L}_{\text{aux}}$（附录 A.2）。

3.3 动作生成与联合学习

动作流。 动作流包含 $H = 8$ 个 token，对应动作块中的每条指令；每个 token 嵌入一条加噪指令，即末端执行器的平移与旋转增量加夹爪指令（附录 A.2）。注意力掩码 $\mathcal{G}$ 让场景 token 读取场景，摘要 token 读取场景与摘要，动作 token 读取摘要与动作；因此动作通过摘要 token 读取世界，而世界流不依赖动作。每一层中，两条流共享注意力投影，借此交换信息，并各自保留独立的前馈网络，使每条流有自己的容量；我们在开发场景上将这一主干与参数完全分开的主干比较后选定了它（附录 E.1）。世界 token 使用层归一化，动作 token 使用以流时间为条件的自适应层归一化。

联合学习。 对以训练统计量归一化的动作块 $\mathbf{a}_1$（附录 A.2）、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与流时间 $u \sim \mathcal{U}[0, 1]$，参数为 ψ 的动作流 v_ψ 回归流匹配速度：

$$\mathcal{L}_A = \mathbb{E} \left\| v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t, \mathcal{G}) - (\mathbf{a}_1 - \mathbf{a}_0) \right\|^2, \tag{6}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为第 t 次查询的场景 token，误差在有效指令上取平均。所有部分以

$$\mathcal{L} = \mathcal{L}_A + \lambda_P \mathcal{L}_P + \lambda_F \mathcal{L}_F + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}} \tag{7}$$

联合训练，各权重见第 4.1 节。

3.4 高效推理与执行

SE(3)-WAM 的预测头联合训练、在测试时跳过，与近期的 WAM [25, 60] 相同。由于世界 token 既不读取动作，也不读取流时间，世界流每次查询只运行一次，动作流在缓存的键和值上积分 5 个 Euler 步。执行器按整数个控制周期计延迟，与 RTC [6] 的做法相同。总延迟为 L_t 的查询在其结束时或之后的第一个控制周期边界交出动作块，即采集后 $\ell_t = k_t \Delta_a$，其中 $k_t = \lceil L_t / \Delta_a \rceil$；执行从对应该边界的第 k_t 条指令继续。策略在该边界重新观测并开始下一次查询；在此之前，执行器继续执行上一个动作块。因此，策略以其延迟允许的最高频率重新规划；当一次查询能在一个控制周期内完成时，每条指令之前都会重新规划。由于每条指令都在其标签所指的时刻下发，动作流不需要延迟输入，式 (2) 中的时间误差 e_τ 仅剩执行器的动作延迟。每条被执行的指令距采集至多 $(H-1)\Delta_a + d_{\text{task}}$，都落在预测监督的时域之内（附录 B.3）。在真机上，L_t 还包括在最新一帧中跟踪目标的时间。

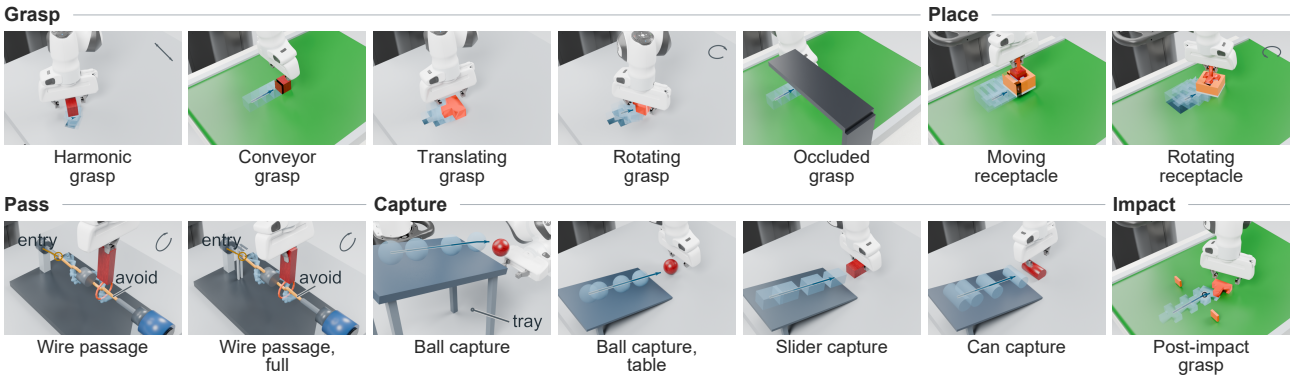


图 4. **Dynamic-14** 。采用统一主视角，从记录的仿真状态渲染五个任务族共 14 个任务。四个历史位姿以半透明蓝色显示，时间越早越淡；深蓝轨迹表示实测的过去运动。灰色角落箭头定性表示旋转或振荡，小圆圈标出记录到撞击时的目标中心。两个 Pass 子图均展示穿越阶段：导线在入口处是目标，沿途则是避碰障碍；Full 还要求获取、退出和释放。被遮挡的运动保持隐藏。这些原生专家示例用于展示任务动态，不代表 SE(3)-WAM 的执行结果，图中不显示未来预测。

4 实验

我们评估：场景在推理期间持续运动时 SE(3)-WAM 的表现（第 4.2 节），各组件的贡献（第 4.3 节），以及它在真机上的表现（第 4.4 节）。

4.1 设置

Dynamic-14 。 Dynamic-14 是一个仿真基准，观测、场景运动与动作执行共用一个物理时钟，因此策略计算时场景继续运动，每个方法都要为自身的延迟付出代价。它在 MuJoCo/robosuite [47, 70] 中包含五个任务族共 14 个任务：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（图 4；附录 B）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个，新种子）上报告全部 Dynamic-14 结果。

评测。 每次查询期间，物理按该方法自身的推理延迟推进：延迟从该方法在一块 RTX 5090（我们机器人所用的 GPU）上以 batch 1 实测的延迟分布中抽取，与运行 rollout 的硬件无关（附录 B.3）。所有方法共用一个按相对采集时刻的时间索引动作块的执行器（第 3.4 节）：查询在控制周期边界开始，其动作块在查询结束时或之后的第一个边界接管执行（附录 B.3）。除这一原生延迟设置外，我们还为每个方法附加 150 ms 延迟，以及在推理期间暂停物理；附录 C.2 另给出等延迟与原执行方式两种对照。我们报告在 14 个任务上等权、并在训练种子上平均的成功率（SR），以及 p95 延迟，即从观测到达到其第一条指令可用的实测时间（出动作时间）。配对 95% 区间由对留出场景的自助法得到。

基线。 我们比较反应式策略、动态 VLA、图像或隐空间 WAM，以及一个动态 WAM（表 1）。每个基线使用其官方代码、输入与训练配方，在相同示范上训练；若其配方使用腕部相机或帧、光流历史，则一并提供（附录 B.5）。SE(3)-WAM 只使用一个主视角及其深度和目标的 SE(3) 历史，不使用过去的帧。为了让基线获得相同的目标运动信息，$\pi_{0.5}$ 与 DynamicWAM 还以接收我们 SE(3) 历史 token 的形式运行（+SE(3)）。

表 1. **主要结果**：1,400 个 Dynamic-14 留出场景。SR（%）在 14 个任务上等权平均，SE(3)-WAM 取三个训练种子的平均（基线为一个），分别给出各方法原生延迟下、附加 150 ms 延迟下，以及推理期间暂停物理时的成功率。p95 延迟：在一块 RTX 5090 上以 batch 1 测得的出动作时间（ms）的 95 分位；这些延迟在仿真中回放；rollout 计算设备见附录 C.2。所有方法都接收当前主视角 RGB 与机器人状态。腕部：额外的腕部相机。历史：过去的 RGB 帧（RGB）、光流或基于光流的运动历史（光流），或目标的 SE(3) 历史。SE(3)-WAM 另外使用当前帧的深度，为每个 patch 给出其度量 3D 位置。DP：Diffusion Policy。粗体为最佳。各任务族与各任务的结果、接触误差与置信区间见附录 C.1。

		历史			SR (%)			
方法	腕部	RGB	光流	SE(3)	原生	+150 ms	暂停	p95 延迟 (ms)
ACT [66]					42.0	24.1	40.9	10.7
DP [10]		✓			0.0	0.0	—	1701.9
$\pi_{0.5}$ [35]					—	—	—	—
$\pi_{0.5}$+SE(3)	—			✓	—	—	—	—
DynamicVLA [54]		✓			—	—	—	—
PUMA [12]			✓		—	—	—	—
DreamVLA [63]		✓			—	—	—	—
OpenWAM-α [49]					—	—	—	—
DynamicWAM [31]			✓		—	—	—	—
DynamicWAM+SE(3)	—		✓	✓	—	—	—	—
SE(3)-WAM				✓	—	—	—	—

实现。 Transformer 共 24 层，宽度 1024，16 个注意力头，可训练参数 523.8M；MAE ViT-B/16 编码器与 DINOv3 教师保持冻结。在 Dynamic-14 上，它从随机初始化开始训练 20 轮，使用 AdamW，$\lambda_P = \lambda_F = 1$，$\lambda_R = \lambda_{\text{aux}} = 0.1$（附录 A.3）。在真机上，它从一个在 DROID [21] 上预训练的 48 层基座出发，逐任务微调（附录 A.4）。

4.2 仿真结果

对比。 在原生延迟下，SE(3)-WAM 在 Dynamic-14 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。优势最大的是 [任务类型]（附录 C.1）。它的 p95 延迟为 [XX] ms，是图像空间 WAM 的 [X] 分之一，与 [作为参照的反应式策略，待定] 相近。

延迟与协议。 附加 150 ms 延迟后，SE(3)-WAM 保持 [XX.X]%，而反应式策略平均降至 [XX.X]%，图像空间 WAM 降至 [XX.X]%，与式 (2) 的预测一致：附加延迟拉长了放大每个速度误差的领先时长，因此不预判目标运动的方法损失最大。图 1（右）与附录 C.2 给出 0 到 200 ms 的完整扫描。推理期间暂停物理、即不计计算代价时，SE(3)-WAM 仍领先 [名称] [X.X] 个百分点，原生延迟下这一差距为 [X.X] 个百分点。当每个方法都被计入 SE(3)-WAM 的 p95 延迟时，其领先为 [X.X] 个百分点；让 [依赖自身异步执行的基线] 使用原执行方式，其 SR 的变化不超过 [X.X] 个百分点（附录 C.2）。

DOMINO。 我们还在 DOMINO [12] 的 24 个单臂 Franka 任务上，用其示范训练 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA，并用其原生评测器评测。SE(3)-WAM 的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%（表 2；附录 C.3）。与在 Dynamic-14 上一样，它读取仿真器中的目标位姿。

表 2. **DOMINO 结果**（24 个单臂 clean-L1 任务，各方法用 DOMINO 的示范训练；每个方法一个训练种子，每个任务与方法 50 个回合）。SR（%）按交互类型分组并在任务上平均；MS 为操作得分。协议见附录 C.3。

方法	拦截	跟踪	全部	MS
$\pi_{0.5}$	—	—	—	—
DynamicWAM	—	—	—	—
PUMA	—	—	—	—
SE(3)-WAM	—	—	—	—

图占位：图 5——按任务的消融效应

版式：单栏，两张热图左右并排、共用行标签：左为*原生延迟*，右为 *+150 ms*。**行（自上而下）**：无目标历史；无未来监督；无场景流监督；无专用 SE(3)；统一精度预测。**列**：全部；五个任务族（抓取、放置、穿越、捕获、撞击）；一条细分隔线；然后是依据表 S3 预先确定的两个任务组：*旋转敏感*（误差项含 $r\theta$ 的任务）与*环境活跃*（有障碍间隙 m 的任务，例如旋转导线，或有驱动物的任务：传送带、斜坡、撞击器）。**单元格**：ΔSR = 对照减完整模型（百分点），三个训练种子的平均，保留一位小数；以 0 为中心的发散配色（红为下降，蓝为上升），两张热图共用同一对称色标，超过 ±15 个百分点饱和；配对 95% 自助法区间不含 0 时数值加粗。**规则**：各行使用相同的留出场景；任务组成员在附录列出；此处不剔除 t3_phase（敏感性分析见附录）。

图 5. **按任务的消融效应。**各对照相对完整模型的 SR 差值（百分点），左为原生延迟，右为附加 150 ms 延迟；按任务族，以及依据表 S3 确定的两个任务组分列：误差依赖旋转（$r\theta$）的任务，与环境约束或推动目标的任务。加粗：配对 95% 区间不含 0。[概括各组件在哪些任务上起作用。]

4.3 消融与分析

五个对照各改变最终模型的一个组件，保持数据、配方与训练预算不变，每个对照训练三个种子（表 3，图 5）。它们检验第 3.2 节的论证：目标历史提供式 (2) 中 e_v 所依赖的速度；未来监督塑造表示而不增加推理时间；两项几何成分与一个统一精度的预测检验按角色分配精度。我们在原生延迟与附加 150 ms 延迟下评估它们（各种子结果与敏感性分析见附录 C.4）。

目标历史。 无历史对照移除过去的目标位姿及其速度、加速度特征，保留当前图像、当前目标位姿与机器人历史；与其他对照不同，它改变的是输入。去掉历史后，SR 在原生延迟下下降 [X.X] 个百分点，在附加 150 ms 延迟下下降 [X.X] 个百分点，与式 (2) 的预测一致：领先时长越长，历史所消除的速度误差被放大得越多。由于历史依赖位姿估计，我们还对位姿施加扰动；在合成的时序相关位姿噪声下，SE(3)-WAM 的 SR 为 [XX.X]%（附录 C.5）。

未来监督。 无未来对照移除全部预测损失，即 SE(3)、场景流与未来外观目标，保留当前目标 RGB 重建。它的推理与 SE(3)-WAM 完全相同，但 SR 在原生延迟下下降 [X.X] 个百分点，在附加 150 ms 延迟下下降 [X.X] 个百分点，在 [目标做非匀速运动的任务] 上最明显。离线评估中，学习得到的 SE(3) 预测也比对同一历史做匀速与匀加速外推更准确（表 S9）。

精度的分配。 三个对照保留全部辅助目标，只改变几何预测。移除场景流监督使 SR 下降 [X.X] 个百分点；由于流也覆盖目标与机器人，而且外观目标仍然保留，这一项衡量的是粗粒度场景运动监督的贡献，而不是全部环境信息的贡献。移除专用 SE(3) 监督后，目标只剩下场景各部分共有的粗粒度流，SR 下降 [X.X] 个百分点。如果精度按角色分配，SE(3) 监督应在位姿容差更紧或接触对旋转敏感的任务上作用最大，而流监督应在环境约束或推动目标运动的任务上作用最大。[图 5 是否呈现这一模式；若没有，则说明这些对照确立了各组件的贡献，但未确立按角色的分配。] 统一精度对照用整帧的 [冻结视频 VAE 的未来隐变量] 在相同时域上取代 SE(3) 与场景流目标，使场景的每一部分都以同一精

表 3. **核心消融**（最终 24 层模型，Dynamic-14 留出场景，三个训练种子）。每行只改变 SE(3)-WAM （⋆）的一个组件。统一精度预测：以整帧单一精细程度的预测取代 SE(3) 与场景流目标。原生、+150 ms：原生延迟下与附加 150 ms 延迟下的成功率（%）；p95 延迟：出动作时间（ms）的 95 分位。

变体	原生	+150 ms	p95 延迟（ms）
SE(3)-WAM ⋆	—	—	—
无目标历史	—	—	—
无未来监督	—	—	—
无场景流监督	—	—	—
无专用 SE(3)	—	—	—
统一精度预测	—	—	—

图占位：图 6——真机任务与一次配对试验

版式：通栏，两行各六个等宽子图，按 16:9 裁剪，两行使用相同的子图尺寸。**(a) 上排，六个等宽子图，每个任务一格（T1–T6）：**SE(3)-WAM 抓住或拦截目标那一刻的真实照片；叠加跟踪器给出的目标 3–4 个半透明历史位姿与一个运动方向箭头（蓝色），画法与图 4 一致；每格下方标注任务名与运动类型（例如“T5 撞击后拦截：碰撞后偏转”）。**(b) 下排，单个任务上的一次配对试验（[T5 或 T6]；不使用图 1 中的直线运动抓取）：**左三格为 SE(3)-WAM，右三格为最强基线，使用同一试验键；每一半依次为 τ_t 的查询帧、第一条被执行指令的执行时刻 τ^{a} 的帧，以及接触时的帧；叠加：蓝色为跟踪得到的过去位姿，紫色为指令的夹爪路径，并标出夹爪合拢的位置；基线一行中，用红色线段连接合拢点与目标，并标注其长度（mm）。每一半下方一条时间轴，标出采集、首次执行与接触，并注明该方法在表 4 中的 p95 延迟；每一半上方标注结果及其判定依据。**规则：**真实照片不做修饰；叠加来自所示试验的日志数据；(b) 中各帧使用相同的裁剪与比例。

图 6. **真机实验。**(a) SE(3)-WAM 在六个任务上接触目标的瞬间。(b) SE(3)-WAM 与 [最强基线] 在 [任务] 的同一试验键上的表现：[例如基线晚 XX ms 动作，在目标后方 XX mm 处合拢]。

细程度被预测；在相同推理代价下，它落后 SE(3)-WAM [X.X] 个百分点。[用一句话概括哪些组件起作用、在哪里起作用。]

4.4 真机实验

设置。 真机实验检验完整系统：位姿来自估计，延迟是真实的物理延迟。我们在 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机上评估六个任务（图 6a；附录 D），它们重现了 Dynamic-14 的运动类型：传送带抓取与放置（T1、T2；抓取与放置任务族）、转盘抓取（T3；旋转目标）、抓取运动的玩具小车（T4；平面自由运动）、碰撞后拦截球（T5；撞击）、拦截沿斜坡滚落或滑落的物体（T6；捕获）。我们将 SE(3)-WAM 与每类各一个基线比较：$\pi_{0.5}$（VLA）、DynamicWAM（动态 WAM）与 Diffusion Policy [10]（反应式）。每个方法在相同的 100 条遥操作示范上逐任务训练或微调，并以共享的试验键在每个任务上运行 20 次试验（附录 D.3）。基线接收 RGB[，若其配方使用腕部相机则一并提供]；SE(3)-WAM 还接收来自 FoundationPose [50] 的目标位姿，它在每个控制周期边界、该边界的查询之前更新（附录 D.2）。表 4 中的延迟都是端到端延迟。

结果。 SE(3)-WAM 在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%，配对差为 [X.X] 个百分点（95% 区间 [[X.X, X.X]]；表 4）。包含跟踪在内，其 p95 延迟为 [XX] ms，[在一个控制周期之内]，而 [名称] 需要 [XX] ms。优势最大的是 [任务]（图 6b），SE(3)-WAM 的主要失败模式是 [失败模式]（附录 D.4）。

表 4. **真机结果**。第 4.4 节六个任务上的成功率（%），每个任务每个方法 20 次试验；All 合并全部试验。p95 延迟：在一块 RTX 5090 上实测的端到端出动作时间（ms），SE(3)-WAM 包含跟踪。DP：Diffusion Policy。区间见附录 D。

方法	T1	T2	T3	T4	T5	T6	All	p95 延迟
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
DP	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	—

5 结论

SE(3)-WAM 把精度花在接触所依赖之处：用度量 SE(3) 历史与预测表示目标，用稀疏 3D 流表示整个场景，并且预测只作为训练监督。它在 Dynamic-14 上的成功率为 [XX.X]%，在 DOMINO 上为 [XX.X]%，在六个真机任务上为 [XX]%，p95 延迟为 [XX] ms，优于反应式、动态与世界—动作策略。[消融表明，目标历史在附加延迟下作用最大，未来监督在不改变推理计算的情况下改善控制。][说明专用 SE(3)、场景流与统一精度对照支持什么：更好的预测设计，或者在任务分组也一致时，按角色分配精度。] 计入推理延迟后，[说明成功率与相对表现与暂停评测相比有何不同]。

局限性。 SE(3)-WAM 需要一个指定的刚体目标及其可靠的位姿估计，其预测也不建模机器人自身的接触如何改变目标的运动。目标轨迹预测头在每个时域只预测一个未来，不表示不确定性或多模态运动；不确定性感知的预测可以弥补这一点。

LLM Usage Statement（大语言模型使用声明）

[投稿前补充：实际使用的工具、受影响的研究与稿件部分，以及使用程度。]

参考文献

[1] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[2] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation*. Wiley, 2001.

[3] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[4] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[5] Kevin Black, Noah Brown, Danny Driess, et al. π_0: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[6] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, 2025.

[7] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, 2017.

[8] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[9] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[10] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[11] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. *arXiv preprint arXiv:2503.11565*, 2025.

[12] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. *arXiv preprint arXiv:2603.15620*, 2026.

[13] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[14] Ankit Goyal, Jie Xu, Yijie Guo, Valts Blukis, Yu-Wei Chao, and Dieter Fox. RVT: Robotic view transformer for 3D object manipulation. In *Conference on Robot Learning*, pages 694–710, 2023.

[15] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *arXiv preprint arXiv:2505.10075*, 2025.

[16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[17] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birch-

field. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[18] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *International Conference on Machine Learning*, 2025.

[19] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[20] Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3D diffuser actor: Policy diffusion with 3D scene representations. In *Conference on Robot Learning*, 2024.

[21] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[22] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, 2024.

[23] Fenghao Lei, Zhixiong Huang, Long Yang, Jiabao Chen, Peilin Huang, Han Fu, Zhuo Li, and Xiaoxue Ren. DELE-w0.5: Inferring action from future latent state for robotic manipulation. *arXiv preprint arXiv:2608.22067*, 2026.

[24] Jiajun Li, Tiecheng Guo, Yifan Ye, Rongyu Zhang, Xiaowei Chi, Qianpu Sun, Ying Li, Yunfan Lou, Jinqiao Wang, Zhihe Lu, Meng Guo, and Shanghang Zhang. Efficient-WAM: A 1B-parameter world-action model with low-cost future imagination. *arXiv preprint arXiv:2606.10040*, 2026.

[25] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[26] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[27] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[28] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[29] Yuejiang Liu, Jubayer Ibn Hamid, Annie Xie, Yoonho Lee, Maximilian Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, 2025.

[30] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[31] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[32] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[33] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *International Symposium on Robotics Research*, 2019.

[34] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving

objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[35] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.

[36] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, 2025.

[37] Yiran Shi, Dongqi Guo, Tianchen Zhao, Feng Gao, Liangzhi Shi, Chao Yu, ZhiJian Mo, Qihua Xiao, XiaoShuai Peng, Qingmin Liao, and Yu Wang. StreamingVLA: Streaming vision-language-action model with action flow matching and adaptive early observation. *arXiv preprint arXiv:2603.28565*, 2026.

[38] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, 2022.

[39] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[40] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[41] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[42] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. *arXiv preprint arXiv:2601.05237*, 2026.

[43] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. *arXiv preprint arXiv:2602.22010*, 2026.

[44] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. *arXiv preprint arXiv:2606.02486*, 2026.

[45] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[46] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, 2025.

[47] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[48] Changhao Wang, Jaden Clark, and Shuran Song. Chronos policy: Learning robot policies on physical time. *arXiv preprint arXiv:2610.13929*, 2026.

[49] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[50] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[51] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[52] Gaoyuan Wu, Ziyu Shan, Haoyang Du, Yuyao Jiang, and Ziwei Wang. AffordTrajDP: Dynamic affordance-guided

visuomotor policy learning for robotic manipulation. *arXiv preprint arXiv:2608.01603*, 2026.

[53] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, 2024.

[54] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. *arXiv preprint arXiv:2601.22153*, 2026.

[55] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, 2024.

[56] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[57] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[58] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2024.

[59] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[60] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

[61] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. *arXiv preprint arXiv:2607.01938*, 2026.

[62] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[63] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[64] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[65] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[66] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[67] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *International Conference on Learning Representations*, 2025.

[68] Hongyan Zhi, Peihao Chen, Siyuan Zhou, Yubo Dong, Quanxi Wu, Lei Han, and Mingkui Tan. 3DFlowAction: Learning cross-embodiment manipulation from 3D flow world model. *arXiv preprint arXiv:2506.06199*, 2025.

[69] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[70] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri,

Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

[71] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, 2023.

A 方法与训练细节

A.1 误差分解

本小节推导式 2，以及附录 B.1 任务分组所依据的旋转项与环境项，并说明一个估计的误差如何随领先时长与运动而变化。

平移。 把执行时刻目标的真实位置写为 $\mathbf{p}(\tau^{\mathrm{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，其中 $\mathbf{v}$ 为 τ_t 时的速度，$\boldsymbol{\rho}$ 为其余运动；策略的估计写为 $\hat{\mathbf{p}}(\tau^{\mathrm{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。减去再加上 $\mathbf{v}\hat{\Delta}$ 得到

$$\begin{aligned}\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}}) = {}& \big[\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\big] + (\hat{\mathbf{v}} - \mathbf{v})\hat{\Delta} \\ & + \mathbf{v}(\hat{\Delta} - \Delta) + (\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}),\end{aligned} \tag{S1}$$

由三角不等式即得式 2，其中 $e_v = \|\hat{\mathbf{v}} - \mathbf{v}\|$，$e_{\mathrm{dyn}} = \|\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}\|$。这一上界对估计拆分为 $\hat{\mathbf{v}}\hat{\Delta}$ 与 $\hat{\boldsymbol{\rho}}$ 的任何方式都成立，计时误差的高阶部分计入 e_{dyn}。残差 $\boldsymbol{\rho}$ 是匀速外推遗漏的运动。在匀加速 $\mathbf{a}$ 下 $\boldsymbol{\rho} = \frac{1}{2}\mathbf{a}\Delta^2$，由历史估计的加速度可以减小这一项；撞击、滚动接触与摩擦变化留下的部分则只有动力学模型才能减小。

旋转与接触点。 把真实朝向写为 $R(\tau^{\mathrm{a}}) = \mathrm{Exp}(\boldsymbol{\omega}\Delta + \boldsymbol{\eta})R(\tau_t)$，其中 $\boldsymbol{\omega}$ 为角速度，$\boldsymbol{\eta}$ 为其余转动，估计同理。旋转角对左右乘法不变，且 Exp 从 $\mathbb{R}^3$ 到 SO(3) 是 1-Lipschitz 的，因此对一般旋转有

$$\begin{aligned}\theta &= \big\| \mathrm{Log}(\hat{R}(\tau^{\mathrm{a}})R(\tau^{\mathrm{a}})^{\top})^{\vee} \big\| \\ &\le \theta_{\mathrm{loc}} + \|\hat{\boldsymbol{\omega}}\hat{\Delta} + \hat{\boldsymbol{\eta}} - \boldsymbol{\omega}\Delta - \boldsymbol{\eta}\| \\ &\le \theta_{\mathrm{loc}} + \hat{\Delta}\, e_\omega + \|\boldsymbol{\omega}\|\, e_\tau + e_\eta,\end{aligned} \tag{S2}$$

其中 θ_{loc} 为当前朝向误差，$e_\omega = \|\hat{\boldsymbol{\omega}} - \boldsymbol{\omega}\|$，$e_\eta = \|\hat{\boldsymbol{\eta}} - \boldsymbol{\eta}\|$。物体坐标系中位于 $\mathbf{c}$、$\|\mathbf{c}\| = r$ 的接触点在 τ^{a} 的偏差为 $(\hat{\mathbf{p}} - \mathbf{p}) + (\hat{R}R^{\top} - I)R\mathbf{c}$，而 $\hat{R}R^{\top} - I$ 的算子范数为 $2\sin(\theta/2)$，因此其误差满足

$$e_{\mathrm{c}} \le e + 2r\sin(\theta/2) \le e + r\theta, \tag{S3}$$

其中 $e = \|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\|$。抓取或放置约束的是分布在物体上的多个点，例如两个手指的接触点或 T 形件的两臂，因此跟踪任何单个点都消不掉 $r\theta$ 项：朝向误差按力臂放大后进入接触，目标需要其完整的 SE(3) 状态。

环境。 记 m 为可行路径在机器人及所持物体与其经过的环境之间所能保持的最大余量，按环境在 τ^{a} 的预测位置度量。如果执行路径保持这一余量，那么只有环境误差至少为 m 时才会发生碰撞，因此当 $m \gg \varepsilon$ 时对周围环境的粗略估计即可满足要求。第 4.3 节的无场景流监督对照直接检验这种粗粒度监督。驱动物（例如传送带、斜坡或撞击器）通过传给目标的运动影响接触，这一运动经由目标自身的各项进入式 2。SE(3) 历史与预测精确表示这一运动，因此驱动物本身不需要精确的状态。

A.2 架构

表 S1 按下文所述的数据流顺序列出各模块的配置。

表 S1. SE(3)-WAM 的架构。各预测头在部署时被跳过。

模块	配置
视觉编码器	冻结的 MAE ViT-B/16，输入 224×224，196 个 patch token
目标状态编码	$28 \to 1024 \to 1024$ GELU MLP，加性相对时间嵌入
机器人状态编码	线性，$7 \to 1024$
Token	212 个场景（196 个 patch、8 个目标状态、8 个机器人）、16 个摘要、8 个动作
主干	24 层，宽度 1024，16 个注意力头，共享注意力，每个流的 SiLU 前馈 4096，504.0M 参数
位姿头	线性，摘要状态均值 $\to 8 \times 6$
流预测头	每个 patch token 上的线性读出，$8 \times (3{+}1)$
外观预测头	每个 patch token 上的线性读出：深度与运动表面 RGB 以 16×16 像素输出，1024 维 DINOv3 ViT-L/16 特征
目标重建	$1024 \to 256 \to 3072$ GELU MLP 加 sigmoid，32×32 RGB
动作流	流匹配，以流时间做自适应层归一化，5 个 Euler 步

场景 token。 冻结的 MAE ViT-B/16 [16] 把主视角 RGB 编码为 196 个 patch token；我们在开发场景上选定了它（附录 E.1）。每个 patch token 加上一个可学习的视角嵌入（单视角设置下由所有 patch 共享），以及其平均有效度量深度和其中心像素反投影后基座坐标系位置的线性嵌入。这些位置也驱动 patch query 与 key 的 3D 旋转位置编码，其他 token 都不使用旋转位置编码；同样的中心点也是稀疏 3D 流的源点。过去的图像从不进入模型。

状态 token。 8 个目标状态 token 在偏移 $-350, -300, \ldots, 0$ ms 处取样。每个都是 25 维描述子 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta$ 各分量维数为 $(3, 3, 3, 3, 1, 3, 3, 3, 3)$：槽位 0–6 描述相邻偏移之间的七个区间，速度为区间位移除以经过的时间，加速度为相邻速度之差除以区间中心的间隔；槽位 7 存放基座坐标系下当前的绝对位姿。我们用训练统计量对每一维标准化，把无效维置零，并附加三个有效性标志（位姿、区间与加速度）；没有任何有效特征的槽位在注意力中被掩码。在真机上，跟踪器在每个控制周期边界更新位姿（附录 D.2），因此历史保持同样的 50 ms 间隔。机器人 token 包含相同偏移处的末端位置、旋转向量与测得的夹爪开度，16 个可学习嵌入构成摘要 token。策略没有语言 token。

主干与掩码。 每一层用两个流共享的 query、key、value 与输出投影对全部 token 做一次注意力，随后世界 token 与动作 token 分别通过各自的 SiLU 前馈网络。第 3.3 节的掩码使被阻断的连接在每一层、每个注意力头上、训练与部署时都取 logit $-\infty$，因此世界状态在每次查询中只计算一次，并在各 Euler 步之间复用。

预测头与辅助头。 所有预测头都读取世界流的最终状态，与动作流一同训练，部署时被跳过，且没有任何 token 读取其输出。位姿头读取摘要状态的均值，以 $\mathcal{L}_P$（式 4）训练。流预测头给出每个 patch 点在每个时域的位移与可见性 logit，以 $\mathcal{L}_F$（式 5）训练，尺度 $s = 0.7154605$ m；仿真中可见性损失的权重为 1，有效但不可见的点仍监督其位移。外观预测头在每个时域预测度量深度（在有效像素上取平方误差）、移动超过 1 mm 的表面（包括机器人）的 RGB（取平方误差），以及 DINOv3 特征 [40]（经通道层归一化后取平方误差）。目标重建头从摘要状态均值以绝对误差恢复当前目标的 RGB 区域。这四项损失构成 $\mathcal{L}_{\text{aux}}$。

动作流。 8 个动作 token 各嵌入一条七维指令：基座坐标系下的平移增量、左相对旋转向量与夹爪指令；增量以执行时测得的末端位姿为参照。部署时，我们积分 5 个 Euler 步，反归一化，解码旋转向量，

并把每个轴截断到 0.05 m 与 0.5 rad；夹爪跟随其指令的符号。附录 B.3 说明动作块如何执行。

A.3 在 Dynamic-14 上训练

示范中的每个控制步锚定一个窗口，窗口包含 8 个查询位置，各有自己的因果历史，位置之间没有注意力；11,200 条示范共给出 1,324,374 个窗口，另有 350 个回合构成验证集。对于流标签，每个 patch 中心像素用渲染深度反投影，并绑定到该像素处渲染的 MuJoCo 几何体的局部坐标系；该几何体的真值刚体变换把同一个表面点带到各未来时域，由此得到它在基座坐标系中的累计位移。若未来点位于相机前方、投影在图像范围内，且其投影像素渲染的是同一几何体、深度与该点深度 z 之差不超过 $\max(1\,\mathrm{mm},\, 0.001z)$，则该点可见。第 t 次查询的动作块中，第 j 条指令的标签是示范在 $\tau_t + j\Delta_a$ 下发的指令，因为 d_{task} 只在执行时叠加（式 1）；指令用训练集中有效指令的均值与标准差归一化。每个查询位置为其动作块抽取 8 对噪声—时间样本并对损失取平均，这在不扩大 batch 的情况下降低了动作梯度的方差；每个损失按全局 batch 中的有效标签数归一化。未来帧的 DINOv3 特征按回合缓存一次。表 S2 列出训练配方。

表 S2. Dynamic-14 上的训练超参数。

项目	取值
优化器	AdamW，$\beta = (0.9, 0.999)$，$\epsilon = 10^{-8}$，权重衰减 10^{-4}
学习率	2×10^{-4}，从 0 开始 5,174 次预热更新，余弦衰减到 0
Batch 与更新	全局 batch 512 个窗口，20 轮（51,740 次更新）
损失权重	$\lambda_P = \lambda_F = 1$，$\lambda_R = 0.1$，每个辅助目标 $\lambda_{\text{aux}} = 0.1$
动作噪声	每个查询位置 8 对噪声—时间样本
精度	可训练权重 FP32，冻结编码器 BF16，梯度截断 0.1
推理	FP32，查询内缓存世界状态
硬件	[N] 块 RTX PRO 6000 GPU，每次训练 [X] 小时

A.4 DROID 预训练与微调

数据。 真机基座在以 15 Hz 录制的 DROID [21] 上训练，并使用 PointWorld 为其发布的 3D 点轨迹与相机标定 [19]；我们按机器人状态、指令与相机身份完全一致把它们与原始回合对应起来。模型使用第一台外部相机及其深度。在 42,935 个已对应的回合中，42,087 个给出 598,889 个锚点窗口：37,874 个训练回合给出 538,740 个，4,213 个验证回合给出 60,149 个。每个锚点扩展为 8 个连续的查询位置；锚点带有流与 DINOv3 标签，其余位置只带动作标签。所有时间均为采集时间戳，流与 DINOv3 目标保留 PointWorld 的记录时刻。我们保留下发了指令的 96.88% 的动作槽位，不按速度过滤，以免基座偏向缓慢运动。

训练目标。 DROID 不提供物体位姿，因此基座没有目标状态 token，也没有位姿头。它读取当前 RGB-D 帧与机器人历史（204 个场景 token），以权重 1 训练动作损失与稀疏 3D 流，以权重 0.1 训练未来 DINOv3 特征；PointWorld 只记录可见位置，因此可见性损失关闭。DROID 中的大多数物体只在机器人移动它们时才运动，因此基座主要学习度量几何与机器人自身动作引起的运动；我们任务中的外生运动与目标位姿在微调时才引入。

流标签。 14×14 网格的每个 patch 跟随一条 PointWorld 轨迹：在起点位于该 patch 内、初始可见且深度有效的轨迹中，取图像运动最大且与其 3D 位移一致的一条，否则取最靠近 patch 中心的一条，从而覆盖固定中心点会漏掉的运动物体。标签是轨迹相对其起点的位移；47.05% 的点—时域槽位带有标签。

配方与微调。 基座使用宽度 1024 的 48 层（1.02B 可训练参数），以全局 batch 512 在 64 块 GPU 上训练 20 轮（21,060 次更新，2,106 次预热更新），优化器与精度同表 S2。每个真机策略从基座出发，在其任务的示范上微调 [更新次数、学习率与 batch 大小]；基座所缺的目标状态 token 与预测头重新初始化。没有任何真机策略使用仿真权重，基座也不接触仿真数据。

B Dynamic-14 与评测协议

B.1 基准设计

Dynamic-14 包含五个任务族共 14 个任务（图 4；第 4.1 节），共同覆盖平移、旋转、暂时遮挡、受约束的通行，以及目标运动的突变。我们将公开这些任务、已接受的场景、成功判定与示范。

环境。 任务在 MuJoCo 3.11.0 与 robosuite 1.5.2 [47, 70] 中运行，使用 Franka Panda 机械臂与平行夹爪，由 robosuite 的操作空间位姿控制器驱动，控制周期为 50 ms，物理步长为 2 ms。一台固定的第三人称主视角相机位于 $(0.68, -0.58, 1.62)$ m，垂直视场角 40°，渲染 224×224 的 RGB-D 图像。动作是机器人基座坐标系下的末端增量，即一个平移与一个旋转向量，再加一条夹爪指令；共享的动作适配器把每条指令截断到每个平移轴 0.10 m、每个旋转向量分量 0.5 rad。

成功与终止。 表 S3 概述各任务的成功条件。我们在每个物理步判定这些条件，连续条件一旦中断其计数器清零；回合在第一个终止事件处结束：成功、失败（例如不安全接触、离开工作空间或掉落），或达到时限。

角色与任务组。 表 S3 给出每个任务的目标。移动的容器是目标，因为它的位姿决定能否放入；在穿越任务中，杆须在 30 mm 内与之对准的导线入口是目标，导线其余部分是不允许任何接触的环境。图 5 的两个任务组依据附录 A.1 的误差项在消融之前确定：若目标在领先时长内旋转且其朝向在接触时起作用，则任务属于旋转敏感组（$r\theta$），这排除了小球；若任务有障碍间隙 m 或驱动物（传送带、斜坡或撞击器），则属于环境活跃组。

B.2 场景、示范与数据划分

场景。 每个场景在各任务的范围内均匀采样目标的初始状态与运动参数，离散选项等概率采样：除表 S3 的速度外，还包括至多 35 mm、0.25–0.7 Hz 的谐波振幅、至多 1.2 rad/s 的偏航角速度、2.5–7.5°/s 的导线转速，以及 5–15° 的斜坡坡度（摩擦按物体设定）。只有当目标在开始时至少可见八帧、随后完全被遮挡 0.5–3.0 s、并再次可见至少三帧时，才接受一个遮挡场景。我们保留通过物理可行性检查的场景，并在评测时回放存储的已接受场景。

表 S3. **Dynamic-14 的十四项任务。**目标：策略接收其位姿的物体（第 3.1 节）。速度：目标速度范围（捕获任务取离开斜坡时的速度）。每个任务都须依次通过各阶段且不触发终止性失败；抓取要求双侧指垫接触、抬升至少 0.05 m 并保持 0.5 s。时限：回合时限。图 5 的任务组：R 为旋转敏感组，C 为环境活跃组（附录 B.1）。发布的任务配置包含确切阈值与场景范围。

任务（代号）	目标	速度（m/s）	成功条件	时限（s）	任务组
谐波抓取 (grasp)	物块	0.03–0.20	抓住做谐波运动并偏航的物块，抬起并保持。	8	R
传送带抓取 (t1_belt)	零件	0.04–0.10	抓住传送带上的零件，抬起并保持。	8	C
平移抓取 (t1_xyz)	零件	0.04–0.15	抓住平移的零件，抬起并保持。	8	–
旋转抓取 (t1_so3)	零件	0.04–0.15	抓住平移并旋转的零件（$\|\omega\| \leq 1.2$ rad/s），抬起并保持。	8	R
遮挡抓取 (t1_occ)	零件	0.04–0.10	抓住传送带上的零件（遮挡罩会将其遮住 0.5–3.0 s），且不与遮挡罩发生不安全接触；抬起并保持。	8	C
移动容器 (t2_trans)	容器	0.03–0.06	把所持物体完整放入移动的容器并释放，使其静止。	10	–
旋转容器 (t2_se3)	T 形容器	0.03–0.06	把所持 T 形件完整放入平移并旋转的 T 形容器并释放，使其静止。	10	R
导线穿越 (t3_phase)	导线入口	[X]	把所持杆端的环在 30 mm 内对准旋转的导线，然后沿导线无接触地穿到终点。	21	R, C
完整导线穿越 (t3_full)	导线入口	[X]	抓起杆，完成穿越，离开导线后释放杆。	32	R, C
小球捕获 (t4_sphere)	小球	[0.4–0.7]	在小球离开斜坡后、触及托盘前将其接住，抬起并保持。	6	C
桌面小球捕获 (t4_sphere_tabletop)	小球	[0.4–0.7]	在小球离开斜坡后仍在桌面滚动时将其抓住，抬起并保持。	6	C
滑块捕获 (t4_slider)	滑块	[0.4–0.8]	在滑块离开斜坡后仍在桌面滑动时将其抓住，抬起并保持。	6	C
罐体捕获 (t4_can)	罐体	[0.4–0.7]	在罐体离开斜坡后仍在桌面滚动、尚未倾倒时将其抓住，抬起并保持。	6	R, C
撞击后抓取 (t5_replan)	零件	0.12–0.14	撞击器把传送带上的零件撞偏后，沿其抓取轴将其抓住，抬起并保持。	6	R, C

示范。 专家是针对各任务的闭环状态机，使用仿真特权状态：目标当前的位姿、线速度与角速度，机器人状态，任务几何，以及真实的接触、夹持与阶段事件。在每个控制周期，它例如在抓取任务中对目标做短时外推，再跟踪、下探、闭爪与抬升；在捕获任务中按重力预测滚动或飞行物体的截获点；在穿越任务中沿已知导线路径运动，并按当前转角与角速度做相位补偿。其指令按每个轴截断到 0.05 m 与 0.5 rad。只有场景可行、专家成功、对记录动作的独立回放能重现该回合，且路径、动作变化与 jerk 通过数值质量检查的示范才被接受。训练池的 11,200 条示范（每个任务 800 条）取自已接受的示范。我们以 20 Hz 记录相机图像、深度、机器人状态、下发的指令，以及目标位姿与场景几何的仿真真值；学习得到的策略只接收第 3 节的输入。

数据划分。 我们在 1,400 个开发场景（每个任务 100 个）上选择配置。全部 Dynamic-14 结果使用另外 1,400 个留出场景，它们以相同的范围生成，使用不出现在任何训练、验证或开发回合中的新源种子；按种子递增顺序的前 100 个可行场景构成每个任务的集合，所有方法共用。

B.3 实时评测

执行器。 所有方法在 50 ms 控制时钟上共用第 3.4 节的执行器；一次查询的总延迟 L_t 是该协议下的推理延迟加上任何附加延迟。在第 3.4 节之外还有四条规则。各方法的动作块包含其原生的 H_m 条指令（表 S4），$k_t \geq H_m$ 的动作块已全部过期，整体丢弃。当 $L_t = 0$ 时，下一次查询在采集后一个控制周期开始。在回合的第一个动作块到达之前，以及动作块耗尽时，控制器保持当前的手臂目标与夹爪指令，物理照常推进，不重复执行任何指令。撞击后抓取在下发每条指令 50 ms 后才施加（式 1 中 $d_{\text{task}} = 50$ ms），其余任务 $d_{\text{task}} = 0$。

协议。 在实时协议下，每次查询期间物理按该方法的原生延迟推进，该延迟每次查询从其在一块 RTX 5090 上实测的延迟分布中抽取。在暂停协议下，仿真等待推理完成；在等延迟协议下，每个方法都被计入 SE(3)-WAM 的 p95 延迟；在原执行方式协议下，每个基线以原生延迟保留其论文中的执行方式，例如 ACT 的时间聚合或 DynamicVLA 的流式执行。表 S7 的附加延迟扫描在实时协议下于推理之后加入 0、50、100、150 或 200 ms，期间物理继续推进。ACT 与 Diffusion Policy 的原生延迟 rollout 在 RTX 5090 上运行，其余 rollout 在 RTX PRO 6000 上运行；所有 rollout 都回放在 RTX 5090 上实测的延迟，因此 rollout 的硬件不影响结果。

延迟测量。 我们在一块 RTX 5090（32 GB，即我们机器人所用的 GPU）上独占运行、以 batch 1 为所有方法计时。每个方法进行三轮，每轮三十次预热调用与 300 次测量调用，覆盖三段各八帧的观测序列；调用边界处做 CUDA 同步，方法顺序轮换，精度沿用其发布版本，SE(3)-WAM 使用 FP32。一次计时查询从最新观测开始（历史已维护好），到其第一条指令可用时结束；它包含所有需要最新帧的计算：预处理、图像编码、PUMA 与 DynamicWAM 的在线光流更新与运动描述子、采样与动作解码，在真机上还包括跟踪。对 SE(3)-WAM ，我们另外测量预测头的耗时，尽管部署时跳过它们。这一出动作时间不取整报告；交接时刻 $\ell_t = k_t\Delta_a$ 把它向上取整到控制周期，一条指令的动作年龄是其执行时刻减去采集时刻。出动作时间超过 50 ms 的查询称为超时。附录 C.2 报告实测值。

B.4 指标与统计

按任务等权的成功率为

$$\mathrm{SR}(m) = \frac{100}{14}\sum_{k=1}^{14}\frac{1}{S_m n_k}\sum_{s=1}^{S_m}\sum_{i=1}^{n_k} y_{mski}, \tag{S4}$$

其中 y_{mski} 是以种子 s 训练的方法 m 在任务 k 的场景 i 上的二值结果；本文各变体 $S_m = 3$，基线 $S_m = 1$。首次接触时的位置误差 e_p 是首次接触时末端到专家在目标上的接触坐标系的距离。两个放置任务开始时物体已被抓住，其接触是所持物体与容器的接触，接触坐标系是专家放置时的末端位姿。e_p 在有接触的 13 个任务（不含 `t3_phase`）及发生接触的回合上平均；没有接触的失败仍计入 SR 的分母。

训练种子与区间。 完整模型与五个消融对照使用训练种子 0、1 与 2，每个基线使用种子 0。我们报告每个训练种子以及跨种子的均值与标准差（附录 C.4），对消融还在去掉纯相位导线穿越（`t3_phase`）后重复比较。对于配对 95% 区间，我们对每个场景的各种子取平均，并在每个任务内、跨方法联合地对留出场景做自助法。这些区间刻画给定训练权重下的场景不确定性；区间落在 ±2 个百分点以内的差异视为持平。

B.5 基线与消融对照

共同条件。 每个基线保留其官方架构、动作块长度、初始化与训练配方（表 S4），以种子 0 在相同的 11,200 条示范上训练一次，示范中的指令通过同一个笛卡尔控制器映射到其动作空间，配置在开发场景上选择。所有方法共用主视角相机，并接收表 1 所列的其他输入；配方需要腕部视角的方法接收被屏蔽或填黑的腕部输入。

表 S4. **基线训练。**所有方法均在相同的 11,200 条示范上按各自的官方配方训练，并在附录 B.3 的共享执行器下运行。更新数 × batch：训练量。H：每个返回动作块中的指令数。参数量：可训练参数，不含冻结的编码器。DOM 检查点：DynamicVLA 发布的、在 DOM 上训练的检查点。DreamVLA 用十步 DDIM 与 1.5 的无分类器引导采样，并在开发场景上从其 40 轮调度与 20 轮余弦调度中取更好者；OpenWAM-α 联合生成视频与动作，但不解码视频。

方法	初始化	更新数 ×batch	H	参数量
ACT [66]	从头训练	50,000 × 32	100	[X]
DP [10]	从头训练	50,000 × 32	8	[X]
$\pi_{0.5}$ [35]	`pi05_base`	30,000 × 256	10	[X]
$\pi_{0.5}$+SE(3)	`pi05_base`	30,000 × 256	10	[X]
DynamicVLA [54]	DOM 检查点	50,000 × 44	20	[X]
PUMA [12]	官方	[X]×[X]	[X]	[X]
DreamVLA [63]	已发布	48,220 × 512	3	[X]
OpenWAM-α [49]	官方	34,490 × 192	32	[X]
DynamicWAM [31]	官方	40,000 × 128	16	[X]
DynamicWAM+SE(3)	官方	40,000 × 128	16	[X]
SE(3)-WAM	从头训练	51,740 × 512	8	523.8M

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.2 的八个目标状态 token，带有相同的有效标志与掩码。一个两层 MLP 把这些 token 映射到模型宽度。对 $\pi_{0.5}$，我们把它们附加在前缀中的图像 token 之后，动作专家会读取它们；对 DynamicWAM，它们并入其运动学描述。MLP 的输出层零初始化，训练沿用基础模型的配方。

消融对照。 第 4.3 节的五个对照各改变表 S2 配置中的一个组件，数据、配方、更新预算、执行器以及训练种子 0、1 与 2 保持不变。*无目标历史*去掉目标状态 token 的槽位 0–6，即过去的位姿及其速度与加速度特征，保留存放当前位姿的槽位 7（附录 A.2）。*无未来监督*去掉 $\mathcal{L}_P$、$\mathcal{L}_F$ 与三个未来外观损失及其预测头，保留对当前目标区域的重建。*无场景流监督*去掉 $\mathcal{L}_F$ 与流读出，*无专用 SE(3)* 去掉 $\mathcal{L}_P$ 与位姿头；两者都保留目标状态 token 与全部外观目标。*统一精度预测*以 [冻结视频 VAE 在相同时域上对整帧未来隐变量的预测、其读出方式与损失权重] 取代 $\mathcal{L}_P$ 与 $\mathcal{L}_F$。由于所有预测头在部署时都被跳过，只有无目标历史对照改变推理时的输入。

C 补充仿真结果

C.1 各任务结果

表 S5 把表 1 中 Dynamic-14 留出结果按任务分解到每个方法，并给出 SE(3)-WAM 相对每个任务上最强其他方法的配对区间；最后两行给出首次接触时的位置误差 e_p 与发生接触的回合数（附录 B.4）。在原生 100 步 DDPM 采样下，Diffusion Policy 的每个动作块到达时都已过期，因此它的指令一条也没有执行。[所有方法都失败或基线优于 SE(3)-WAM 的任务，以及 SE(3)-WAM 的主要失败模式。]

C.2 评测协议与延迟

表 S6 在另外三种协议下评估每个方法。暂停物理显示不计计算代价时相对表现如何变化；等延迟在 SE(3)-WAM 的 p95 延迟下比较所有方法；原执行方式检验共享执行器是否去掉了某个基线所依赖的能力。在暂停协议下，SE(3)-WAM 与 [名称] 的差为 [±X.X] 个百分点，在等延迟协议下为 [±X.X] 个百分点。原执行方式使各基线的 SR 至多改变 [X.X] 个百分点。表 S7 给出每个附加延迟下的成功率；其

表 S5. **Dynamic-14 各任务的留出成功率**（%），涵盖表 1 中的全部方法，本文各变体取三个训练种子的平均、基线训练一次，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。DrVLA：DreamVLA。OWAM：OpenWAM-α。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。σ：使用标称合成相关位姿噪声的 SE(3)-WAM （附录 C.5）。Δ：该任务上 SE(3)-WAM 相对最强其他方法之差及其 95% 配对区间。最后两行为首次接触时的位置误差 e_p（mm，在有接触的 13 个任务上平均）与发生接触的回合数 n（附录 B.4）；–：无 13 任务均值。任务代号见表 S3。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	DrVLA	OWAM	DWAM	DWAM+	σ	本文	Δ [95% CI]
谐波抓取	48.0	0.0	—	—	—	—	—	—	—	—	—	—	—
传送带抓取	46.0	0.0	—	—	—	—	—	—	—	—	—	—	—
平移抓取	18.0	0.0	—	—	—	—	—	—	—	—	—	—	—
旋转抓取	21.0	0.0	—	—	—	—	—	—	—	—	—	—	—
遮挡抓取	32.0	0.0	—	—	—	—	—	—	—	—	—	—	—
移动容器	26.0	0.0	—	—	—	—	—	—	—	—	—	—	—
旋转容器	0.0	0.0	—	—	—	—	—	—	—	—	—	—	—
导线穿越	99.0	0.0	—	—	—	—	—	—	—	—	—	—	—
导线穿越（完整）	0.0	0.0	—	—	—	—	—	—	—	—	—	—	—
小球捕获	36.0	0.0	—	—	—	—	—	—	—	—	—	—	—
小球捕获（桌面）	71.0	0.0	—	—	—	—	—	—	—	—	—	—	—
滑块捕获	57.0	0.0	—	—	—	—	—	—	—	—	—	—	—
罐体捕获	90.0	0.0	—	—	—	—	—	—	—	—	—	—	—
撞击后抓取	44.0	0.0	—	—	—	—	—	—	—	—	—	—	—
任务等权	42.0	0.0	—	—	—	—	—	—	—	—	—	—	—
e_p (mm)	32.2	–	—	—	—	—	—	—	—	—	—	—	–
n	1109	6	—	—	—	—	—	—	—	—	—	—	–

中 SE(3)-WAM 与最强基线的两行即图 1（右）的数据。

表 S6. **评测协议对照**：Dynamic-14 留出场景（SR，%），协议定义见附录 B.3；实时即表 1 的协议。超时：实时协议下出动作时间超过 50 ms 控制周期的查询比例（%）。年龄：实时协议下动作年龄的 p95（ms）；–：没有执行任何指令。

方法	暂停	等延迟	原执行执行器	实时	超时 (%)	年龄 p95
ACT	40.9	—	—	42.0	0.0	50
Diffusion Policy	—	—	—	0.0	100.0	–
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM	—	—	–	—	—	—

计时。 表 S8 按阶段分解 SE(3)-WAM 在一块 RTX 5090 上的出动作时间，测量方式见附录 B.3；表 1 给出每个方法的 p95 延迟，表 S4 给出参数量。在真机上，我们报告动作年龄的 p50、p95 与最大值，测试试验全部查询中超过 50 ms 截止时间的比例，以及峰值显存。

表 S7. **成功率随附加延迟的变化**：Dynamic-14 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的原生与 +150 ms 列。

	附加延迟（ms）				
方法	0	50	100	150	200
ACT	42.0	—	—	24.1	—
Diffusion Policy	0.0	—	—	0.0	—
$\pi_{0.5}$	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—
DynamicVLA	—	—	—	—	—
PUMA	—	—	—	—	—
DreamVLA	—	—	—	—	—
OpenWAM-α	—	—	—	—	—
DynamicWAM	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—

表 S8. **单次查询的延迟分解**（SE(3)-WAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
图像编码	—	—
世界流（每次查询一次）	—	—
动作流（5 个 Euler 步）	—	—
出动作时间（合计）	—	—
预测头（仅训练，供参考）	—	—
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

表 S9. **离线预测误差**。在同一批留出观测上计算 400 ms 处的目标位置误差（mm）。CV 和 CA 是由因果位姿历史计算的解析外推；学习位姿头读取冻结完整模型的状态。

	匀速	谐波	滚动/滑动	撞击
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的位姿头	—	—	—	—

C.3 DOMINO 上的结果

在 DOMINO [12] 上，我们在其 clean 一级设置的 24 个单臂 Franka 任务上比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA。所有方法使用该基准的示范、场景与原生评测器，各训练一个种子，每个任务与方法评测 50 个回合。我们报告 SR 与操作得分（MS）；MS 用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度（表 2）。SE(3)-WAM 使用该领域的归一化，并读取指令所指目标在仿真器中的位姿；没有有效位姿的槽位按附录 A.2 的方式掩码。基于 RGB 的基线不接收这一位姿。[概括 DOMINO 结果。]

C.4 最终消融与种子稳定性

表 S10 按训练种子报告第 4.3 节的五个对照（附录 B.5），并给出跨种子的均值与标准差，以及原生延迟和附加 150 ms 延迟下相对完整模型的配对差值。最后两列在去掉纯相位导线穿越（`t3_phase`）后重复这些配对差值。在开发场景上，同一配置的三个训练种子之间 SR 最多相差 [7.4] 个百分点，主要来自该任务，其成功率在各种子间从 [0] 到 [71]% 不等（附录 B.4）。图 5 的两个任务组列于附录 B.1。[第 4.3 节的结论是否在某个种子上或去掉 `t3_phase` 后改变。]

表 S10. **按训练种子列出的最终消融**（Dynamic-14 留出场景；附录 C.4）。S0–S2：训练种子 0–2 的 SR（%）；均值 ± 标准差为跨种子统计；Δ：对照减 SE(3)-WAM（百分点）及其 95% 配对区间。最后两列：去掉纯相位导线穿越（`t3_phase`）后 13 个任务上的 Δ。

	原生					+150 ms					Δ 去掉 `t3_phase`	
变体	S0	S1	S2	均值 ± 标准差	Δ [95%]	S0	S1	S2	均值 ± 标准差	Δ [95%]	原生	+150 ms
SE(3)-WAM ⋆	—	—	—	—	–	—	—	—	—	–	–	–
无目标历史	—	—	—	—	—	—	—	—	—	—	—	—
无未来监督	—	—	—	—	—	—	—	—	—	—	—	—
无场景流监督	—	—	—	—	—	—	—	—	—	—	—	—
无专用 SE(3)	—	—	—	—	—	—	—	—	—	—	—	—
统一精度预测	—	—	—	—	—	—	—	—	—	—	—	—

C.5 对位姿噪声的鲁棒性

在权重冻结的条件下，我们评估三种对目标位姿的合成扰动：标称的时序相关噪声、两倍幅度的噪声，以及带连续缺失观测的标称噪声。标称过程由每回合固定的偏置与平稳相关分量组成，二者每轴的标准差均为 5 mm 与 1°，相关时间为 200 ms。缺失持续 200 ms，其间隔服从均值为 3.8 s 的几何分布，长期缺失比例为 5%。扰动作用于当前与过去的估计，在计算历史特征之前施加。

图 S1 在这些扰动下评估最终模型，使用相同的留出场景、零附加延迟与全部三个训练种子。相对干净位姿，在标称相关噪声、两倍幅度噪声与缺失观测下，SR 分别变化 [X.X]、[X.X] 与 [X.X] 个百分点。

图占位：图 S1——位姿噪声

横轴：干净位姿、标称相关噪声、两倍幅度噪声、带缺失观测的标称噪声；纵轴：SE(3)-WAM 在各任务族上的 SR，冻结权重，实时协议；匹配场景上的配对区间。

图 S1. **对位姿噪声的鲁棒性。**在目标位姿的合成扰动下 SE(3)-WAM 的 SR，相对干净位姿。

C.6 预测诊断

表 S9 离线比较最终模型学到的 SE(3) 预测与由同一位姿历史得到的匀速和匀加速外推。

D 真机实验

D.1 装置与任务

机器人为 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机，通过 [带时间戳的笛卡尔接口] 以 [控制频率] 控制。相机以 [分辨率] 与 [帧率] 录制 RGB-D，每次采集前用 [标定方法] 标定其外参。SE(3)-WAM 使用这一固定的第三人称视角；配方需要腕部视角的基线获得 [逐方法相机配置]。所有策略都在一块 RTX 5090 上运行。图 S2 给出布局，表 S11 定义六个任务。T1 与 T2 共用一条传送带，T3 使用转盘，T4 使用遥控玩具小车，T5 使用球杆驱动的两球碰撞，T6 使用斜坡。触碰或推动目标而未完成任务、单指夹持，以及目标离开工作空间之后的动作，都算作失败；[设备无

图占位：图 S2——真机装置

(a) 左：工作单元照片，从机器人后方拍摄：第三人称 RGB-D 相机、机器人，以及处于工作位置的传送带、转盘、小车轨道、两球碰撞轨道与斜坡，逐一标注；若有基线使用腕部相机，一并标出。**(b) 右：按比例的俯视示意图**：机器人基座坐标系及其坐标轴，相机位置、朝向及其到工作空间的距离，T1–T6 各装置的占地范围与运动方向，各任务的抓取或拦截区域，以及以 cm 标注的工作空间边界。**规则**：真实照片不做修饰；示意图依据标定的外参与实测的装置位置；不重复图 6 中的任务照片。

图 S2. **真机装置**。(a) 工作单元。(b) 相机、机器人基座坐标系与 T1–T6 各装置的俯视布局 [及工作空间尺寸]。

表 S11. 真机任务定义。$N = 100$：每个任务的训练示范数；每个任务另留 20 条示范用于验证。

任务	装置、运动与物体	运行范围；N	成功与失败条件
T1	传送带运输可抓取的方块。	[带速]；100	[稳定抓取并抬升；失败条件]
T2	传送带运输无盖盒，机械臂将方块放入其中。	[带速]；100	[放入并留存；失败条件]
T3	转盘携带方块绕轴运动。	[角速度、半径]；100	[稳定抓取并抬升；失败条件]
T4	遥控玩具小车在桌面上运动。	[速度、路径]；100	[抓取并抬起小车；失败条件]
T5	球杆驱动的球撞击第二个球，机械臂在碰撞后拦截第二个球。	[碰撞与碰后速度]；100	[碰后捕获；失败条件]
T6	球沿斜坡滚落或方块沿斜坡滑落，朝拦截区域运动。	[坡度、释放、速度]；100	[捕获并保持；失败条件]

效试验与安全干预按以下规则重做或计为失败]。

D.2 位姿跟踪与示范标签

跟踪不使用标记。Grounding DINO [28] 在第一帧中定位任务所指的物体，SAM 2.1 [36] 给出其初始掩码，FoundationPose [50] 由该掩码初始化物体的 6D 位姿并持续跟踪。[FoundationPose 的版本与模式（基于物体网格的模式，或基于参考视图的无模型模式）、物体坐标系如何在示范与试验之间保持一致，以及丢失后的重新初始化。] 跟踪器按控制时钟运行：在每个控制周期边界上，它用该边界时刻或之前最新采集的相机帧更新位姿，因此位姿历史保持训练时的 50 ms 间隔，且每个估计保留其帧的采集时刻。每次查询等待其所在边界的位姿更新，再在同一块 GPU 上运行策略。当一次查询跨越后续边界时，跟踪器以更高的 GPU 优先级继续更新，并且只处理最新一帧，使更新不会积压在较旧的帧之后；跟踪耗时与这一争用都计入实测延迟（表 S8）。[相机帧率与每次更新的实测耗时。] 目标丢失时，该估计记为无效，不沿用上一帧的位姿。[示范中作为输入与训练标签的目标位姿如何获得。] 在球类任务中，目标状态 token 保留球心的平移、速度与加速度，屏蔽其朝向与角运动，位姿头只监督平移。表 S12 报告跟踪精度。

D.3 训练与试验协议

我们比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 Diffusion Policy [10]，每个方法在每个任务上运行 20 次试验。所有方法使用相同的预生成试验键，试验键确定物体实例、初始位姿与运动参数，按 [采样协议] 采样。试验按 [随机化的方法顺序] 进行，使装置的漂移不会与方法对齐。操作员重置场景。试验从第一个可用观测开始，机器人随时可以运动；试验在成功、失败或 [X] s 超时时结束。示范、开发试验与测试试验来自不同的采集批次。SE(3)-WAM 从 DROID 基座出发逐任务微调（附录 A.4），基线在相同示范上训练或微调，采用 [各方法的初始化与训练设置]。对每个方法，我们在同一块 RTX 5090

表 S12. **真机位姿跟踪。**跟踪器相对无标记参照的平移（mm）与旋转（°）误差的中位数/p95、该参照的不确定度，以及观测丢失比例。球体不使用旋转。

目标	mm	°	参照不确定度	丢失
真机刚体	—	—	—	—
真机球体	—	–	—	—

表 S13. **真机成功次数**，按任务分列（成功次数/试验数，每个任务 20 次；任务定义见表 S11）。All：合并成功率（%）及 95% 二项区间。Δ：相对 SE(3)-WAM 的配对差值（百分点）及按试验键自助法得到的区间。

方法	T1	T2	T3	T4	T5	T6	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	–

上记录每次查询的端到端出动作时间，SE(3)-WAM 包含跟踪；表 4 报告其 p95。

D.4 详细结果与失败案例

表 S13 报告每个任务的成功次数、合并成功率的 95% 二项区间，以及按试验键自助法得到的配对差值。[SE(3)-WAM 最常见的失败及其原因。]

E 初步设计研究

我们用更小的模型筛选了编码器、历史表示、预测目标，以及世界流与动作流的耦合方式：4 层、宽度 768，训练 4 轮（全局 batch 16 下 40,104 次更新），并用实时协议之前的同步执行器评测。每组保留各自的编码器与种子数（见下文），各条件只在组内比较。这些研究选出了最终模型的组件；第 4.3 节的五个对照随后在完整规模与实时协议下检验其核心组件（附录 C.4）。

E.1 编码器、主干与历史

编码器与主干。 我们比较了与策略一同训练的 CNN、冻结的 DINOv3 ViT-S/16 与 ViT-L/16 [40]，以及 MAE ViT-B/16 [16]（MAE 参照为三个种子；表 S14），并选定 MAE。我们还在约 47.3M 主干参数、各三个种子的条件下，比较了共享注意力并分设前馈网络的主干与世界、动作参数完全分开的主干（[主干对比的来源]），并选定共享注意力。

历史。 在冻结 DINO-L 编码器、每个条件一个种子的设置下，我们比较了只用当前状态、目标运动历史、RGB 窗口、Farnebäck 光流 [13]、带运动统计的光流 [31]、编解码器运动向量、视频 VAE 隐变量与压缩窗口（表 S15）。其最后一行在测试时把训练好的历史模型的过去目标位姿替换为当前位姿。

E.2 预测目标与辅助监督

在冻结 DINO-L 编码器、每个条件一个种子的设置下，我们比较了十五种未来目标，从只预测目标和图像空间预测到按角色组合的预测（表 S16）。第二组使用 MAE 编码器与一个种子，从选定配置中逐一移除未来外观目标。在第一组中，没有任何未来目标明显优于不加未来监督的变体（P00 为 62.78%，

表 S14. **观测编码器**（筛选规模，附录 E.1）。参数量：编码器参数；p95：出动作时间。

编码器	参数	训练	SR	SR_{150}	p95
CNN	—	是	—	—	—
DINOv3 ViT-S/16	22M	冻结	—	—	—
DINOv3 ViT-L/16	300M	冻结	—	—	—
MAE ViT-B/16*	86M	冻结	—	—	—

表 S15. **历史表示**（筛选规模：冻结 DINO-L 编码器，一个训练种子，1,400 个场景）。前八个条件接收当前目标位姿，第九个条件另加目标运动历史。最后一行：测试时把第九个模型的过去目标位姿替换为当前位姿，并重新计算运动学特征。

历史输入	成功数 / 1,400	SR (%)
当前图像	748	53.43
RGB 窗口	662	47.29
光流	720	51.43
光流＋运动统计	723	51.64
编码器运动向量	733	52.36
视频 VAE 隐变量	710	50.71
压缩窗口（按时间）	634	45.29
压缩窗口（均匀）	670	47.86
当前图像＋目标运动历史	824	58.86
测试时替换为静止历史	9	0.64

场景流与 SE(3) 为 62.38%）；这一规模下的单种子无法分辨这样的差异，最终模型中未来监督的作用由第 4.3 节的全尺度消融检验。

E.3 世界—动作耦合

在 MAE 编码器、每个条件三个种子的设置下，我们比较了世界流与动作流的六种耦合方式。R0 关闭所有预测损失。R1 在世界流中加入一个物体查询和每个 patch 一个查询，它们读取 $\mathcal{S}$、$\mathcal{M}$ 与彼此，并承载预测读出，但与动作之间没有任何连接。R2 让动作 token 在每一层读取这些查询，R3 让这些查询读取动作，R4 同时开启两个方向；在 R3 和 R4 中，世界状态在每个 Euler 步都要重算。R5 在每次查询中解码一次预测，把目标轨迹与带可见性的流（旋转采用连续的 6D 表示）经几何编码器（0.37M 参数）编码为动作可读取的 token。不与动作连接的未来监督（R1）平均比 R0 高 3.14 个百分点，各种子的差值为 −1.29、+9.64 与 +1.07。把预测送给动作没有带来稳定的进一步增益：R2 与 R5 相对 R1 的平均差值为 −1.07 与 +0.36 个百分点，各种子差值的标准差为 4.28 与 3.45 个百分点，两条跨流连接的效应在不同种子间都会变号（表 S17）。因此我们只把预测用作训练监督，这也使部署无需承担其代价。

表 S16. **预测目标**（筛选规模）。第一组使用冻结 DINO-L 编码器与种子 0，其 140 个开发场景与其余 1,260 个场景分别报告。第二组使用 MAE 编码器与种子 1，在 1,400 个场景上评测；它保留场景流、SE(3) 与当前目标 RGB 重建，并移除未来外观目标。请在组内比较各条件。除编码器运动向量外，各目标均为八个时域上相对当前状态的累计量：SE(3) 为目标位姿；三维场景流为 14×14 个 patch 中心在基座坐标系中的位移；二维轨迹与稠密二维位移为目标点、网格点或全部像素的图像位移；编码器运动向量来自视频编码器；视频 VAE 隐变量来自冻结的 Wan2.2 VAE；物体 DINO 为目标掩码内汇聚的 DINOv3 特征。

编号	未来监督	开发集成功数 / 140	成功数 / 1,260	SR_{1260} (%)
P00	无	88	791	62.78
P01	三维场景流	95	782	62.06
P02	SE(3)	92	789	62.62
P03	场景流＋ SE(3)	93	786	62.38
P04	视频 VAE 隐变量＋ SE(3)	92	783	62.14
P05	稠密二维位移＋ SE(3)	87	746	59.21
P06	编码器运动向量＋ SE(3)	86	795	63.10
P07	稀疏场景二维轨迹＋ SE(3)	90	807	64.05
P08	场景流＋物体 DINO	89	794	63.02
P09	场景流＋目标二维轨迹	88	808	64.13
A_α	P03 ＋运动幅值	89	778	61.75
P12	P03 ＋深度	90	791	62.78
P13	P03 ＋ DINO	92	788	62.54
P14	P03 ＋动态 RGB	89	790	62.70
P15	P03 ＋深度 / DINO / 动态 RGB	94	802	63.65

AUX0 MAE-B：未来外观辅助	成功数 / 1,400	SR_{1400} (%)
无	894	63.86
仅深度	867	61.93
仅 DINO	946	67.57
仅动态 RGB	926	66.14
三者全部（已有参照）	995	71.07

表 S17. **耦合方式 R0–R5**（筛选规模：MAE 编码器，各三个训练种子，每个种子 1,400 个开发场景；附录 E.3）。SR：种子平均（%）；标准差：种子间标准差（百分点）。

耦合	SR	标准差
R0 （关闭未来损失）	60.45	3.57
R1 （查询，无连接）	63.60	2.34
R2 （世界 → 动作）	62.52	1.97
R3 （动作 → 世界）	64.21	2.13
R4 （双向）	63.00	4.19
R5 （解码几何）	63.95	1.91