SE(3)-WAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景；然而推断场景运动多花的每一毫秒，都会让目标走得更远。世界—动作模型以统一的精细程度预测未来图像或隐变量，把时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器速度快，却忽略了约束或推动其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；周围物体只通过它们留下的间隙和传给目标的运动起作用；其余背景则与任务无关。我们提出 SE(3)-WAM，一个建立在这种按角色区分精度的 4D 结构之上的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，因此只需一帧 RGB-D 作为输入。它学习精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景，这些预测只在训练中使用。这些设计合在一起，使 SE(3)-WAM 在一块 RTX 5090 上 [XX] ms 即可输出动作，比视频世界—动作基线快 [N] 倍。我们还提出开源基准 Dynamic-14，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动。SE(3)-WAM 在 Dynamic-14 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在目标运动形式多样的六个真机任务上为 [XX]%。

1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[5, 6, 12, 21, 43, 49, 63]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。在这样的场景中，动作必须适合它执行那一刻的场景，而不是观测采集那一刻的场景，因此策略必须知道场景如何运动。这种认识本身需要推断，而推断需要时间，这段时间里场景仍在运动：策略为预判运动计算得越久，需要预判得就越远。

近期的动态策略加入了对过去运动的记忆（通常是光流等图像空间线索 [14, 28]）和对未来的预测 [28, 39, 56]。基于视频的 WAM 以统一的精细程度预测完整的未来帧或隐变量，把大量计算花在视觉细节上 [43, 49]。紧凑的未来编码 [29] 降低了这一开销，度量 3D 场景动力学 [54] 引入了几何，但两者仍对整个场景一视同仁。无论哪种情况，决定接触的量——动作执行时刻目标的度量位姿——仍然是隐式的。以目标为中心的预测器和预测物体层面未来的动态 VLA 位于另一端 [14, 18]：它们速度快，但只预判目标，把可能阻挡或改变其运动的周围环境排除在外。两类方法都没有按接触对场景各部分的要求来分配精度。由此引出一个核心问题：为了完成接触并保持较低的推理延迟，策略需要知道运动场景的哪些信息，又需要知道得多精确？

我们的关键观察是：动态策略需要精确知道的东西其实很少。接触要求目标在动作执行时刻的位姿达到毫米级精度；周围物体只通过它们留下的间隙和传给目标的运动起作用，因此只需粗略地知道。基于这一观察，我们提出 SE(3)-WAM，一个学习按角色区分精度的度量 4D 表示的世界—动作模型，在接触需要之处保持精确（图 1）。为了在不编码过去图像帧的情况下获得运动信息，SE(3)-WAM 把单帧 RGB-D 与目标度量 SE(3) 位姿的一段短历史配对。世界流通过预测目标未来的 SE(3) 轨迹，以及以

稀疏 3D 流表示的整个场景的运动，来学习这一表示。动作流以世界流学到的摘要为条件生成动作块，显式预测只在训练中进行 [53]。因此，SE(3)-WAM 把对目标运动的精确预判与较低的推理延迟结合起来，限制了从观测到动作之间场景的变化。

我们构建了开源基准 Dynamic-14 ，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动，因此每个方法都要为自己的延迟付出代价。SE(3)-WAM 在 Dynamic-14 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms，比视频世界—动作基线低 [N] 倍。它在 24 个 DOMINO 任务 [14] 上同样领先，在六个真机任务上的试验成功率为 [XX]%，最强基线为 [XX]%。受控消融检验目标运动历史与未来监督的贡献，并比较按角色区分精度与统一精度的预测，以考察精度的分配。

我们的贡献有三点：

- 我们表明，动态策略只在动作执行时刻目标的位姿上需要毫米级精度，并把这一原理实例化为按角色区分精度的 4D 建模：为目标建立精确的度量 SE(3) 轨迹，为整个场景建立粗略的稀疏 3D 流。
- 我们提出 SE(3)-WAM ，一个把目标的度量位姿历史与按角色区分精度的预测监督相结合、以低延迟生成动作的世界—动作模型。
- 我们提出开源动态操作基准 Dynamic-14 ,它为每个策略计入其自身的推理延迟;SE(3)-WAM 在 Dynamic-14 、24 个 DOMINO 任务和六个真机任务上均优于强基线。

2 相关工作

动态操作。 补偿感知与执行之间的时间差是一个经典问题，从带纯滞后的控制 [36]，到用卡尔曼类滤波器跟踪目标并规划拦截的抓取系统 [1–3, 31]；这些系统精确，但针对每种物体和任务专门设计。近来，学习型策略开始进入运动场景 [47]。PUMA 读取历史光流，并以未来物体特征作为监督 [14]；DynamicWAM 以光流和运动学描述子为 WAM 提供条件，并以实时分块方式执行 [28]。两者都从图像空间线索中推断过去的运动，而 SE(3)-WAM 以目标的度量 SE(3) 位姿历史为输入，只观测当前一帧 RGB-D。另一些动态策略预测显著 token [39]、未来图像 [57]、紧凑的未来编码 [29] 或 3D 场景动力学 [54]，并在测试时以这些预测为条件生成动作。DynaWM 针对动态操作调整基础 VLA 的动作块 [10]，DynamicManip 从单条静态示范合成动态示范 [23]。执行调度方案通过让推理与执行重叠 [34, 47]、保持相邻动作块一致 [7, 26]，或以执行时刻为条件 [40]，来减小或掩盖延迟。它们决定的是动作何时计算、何时执行，而不是策略表示什么。DOMINO [14] 与 PhysMani-Bench [54] 提供了多样的动态操作任务，但它们公开的默认评测流程只在策略返回预测之后才推进仿真。Dynamic-14 则在推理期间推进场景，并让每个方法承担其实测延迟。

WAM 中的预测监督。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [22, 43, 49, 61]，其基础是把视频预测作为策略目标 [41, 46]。由于生成视频代价高，近期工作改变了预测的内容，例如动态区域、深度与语义特征 [56]，与 RGB 并列的光流和几何 [52]，物体掩码或物体槽 [27, 50]，以及紧凑隐变量 [38, 60]；它们也在追问测试时是否需要预测。Fast-WAM 在不做测试时想象的情况下保留了视频建模的大部分收益 [53]，PUMA 与 SG-WAM 则在训练后去掉预测器 [14, 58]。SE(3)-WAM 沿用这种只在训练中使用预测的方式，但主要预测的是度量 4D 状态，而不是像素、特征或隐变量，因此目标未来的位姿得到显式监督，而不是停留在隐式。

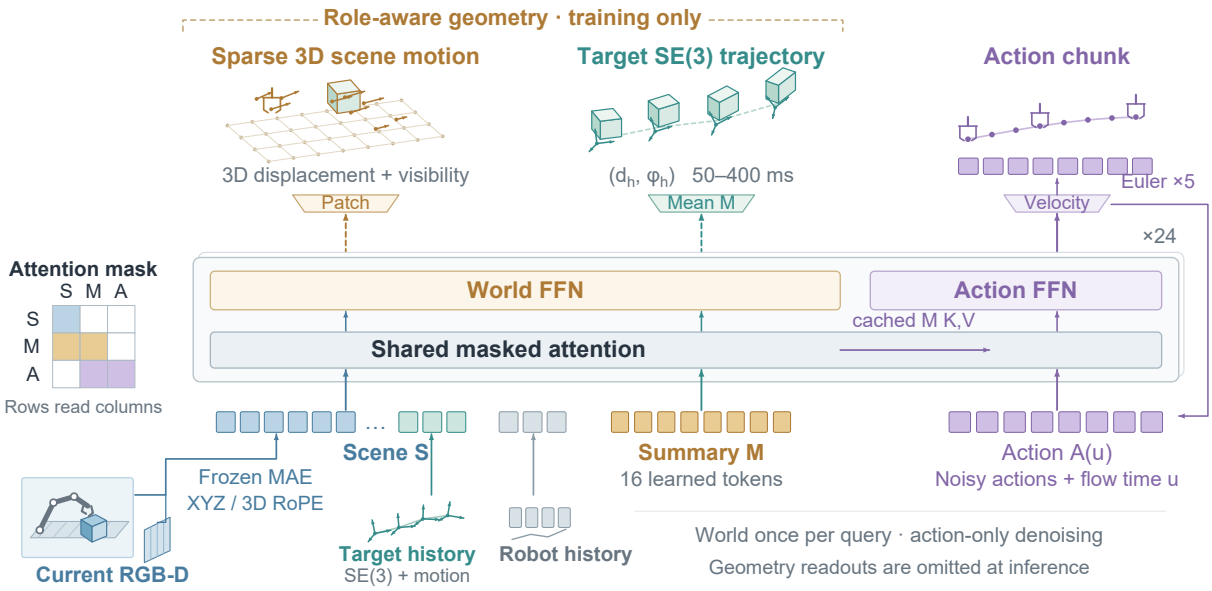


图 1. **SE(3)-WAM 架构。**自下而上阅读。当前 RGB-D 和目标、机器人状态历史输入世界流。世界流与动作流共享注意力，使用独立的 FFN。仅训练时使用的预测头（虚线）从 patch 状态预测全场景稀疏 3D 位移及可见性，从摘要均值预测目标 SE(3) 轨迹。动作通过结构化掩码读取摘要 token。推理时，每次查询只计算一次世界流的键和值，在 5 个 Euler 步中复用，跳过预测头。几何图形为示意。

以物体为中心与基于几何的运动表示。 度量 3D 输入使策略更精确、样本效率更高 [33, 55]。运动已被表示为 2D 点轨迹 [4, 45, 48]、3D 流 [16, 19, 51, 54]，以及物体关键点或 SE(3) 轨迹 [18, 30, 37]；刚体分解也早已用于学习场景动力学 [8, 9]。这些工作用同一种表示描述场景：要么处处是稠密的流或轨迹，要么每个物体一个位姿。以目标为中心的预测器（包括预测物体层面未来的动态 VLA）只建模目标的未来 [14, 18]，把阻挡或推动目标的物体排除在外。DOCIR 把机器人、目标与障碍物分开，但只把这种区分用作输入编码 [13]。SE(3)-WAM 按角色分配精度：粗粒度的稀疏 3D 流描述整个场景，接触依赖毫米级精度的目标另由其 SE(3) 历史与预测描述。

3 SE(3)-WAM

SE(3)-WAM 是一个以按角色区分的精度表示动态场景的世界—动作模型（图 1）。它编码当前 RGB-D 帧以及目标 SE(3) 位姿与机器人状态的短历史：冻结的 MAE ViT-B/16 [17] 把 RGB 编码为 196 个 patch token，深度为每个 patch 给出其中心点在机器人基座坐标系中的度量 3D 位置。这 212 个场景 token 与汇聚它们的 16 个可学习摘要 token 构成世界流；训练时，预测头以目标未来的 SE(3) 轨迹与整个场景的稀疏 3D 流监督世界流。动作流与世界流共享注意力，读取其摘要 token，并以条件流匹配 [24] 生成动作块。

3.1 问题定义

SE(3)-WAM 从示范中学习策略。在第 t 次查询时，策略接收在时刻 τ_t 采集的 RGB 图像、深度图与机器人状态，以及机器人状态和目标物体位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$（机器人基座坐标系）的短历史。它输出一个动作块 $(\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1})$，每个控制周期 Δ_a 一条指令，按相对采集时刻的时间索引：第 j 条指令对应的执行时刻为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\mathrm{task}}. \tag{1}$$

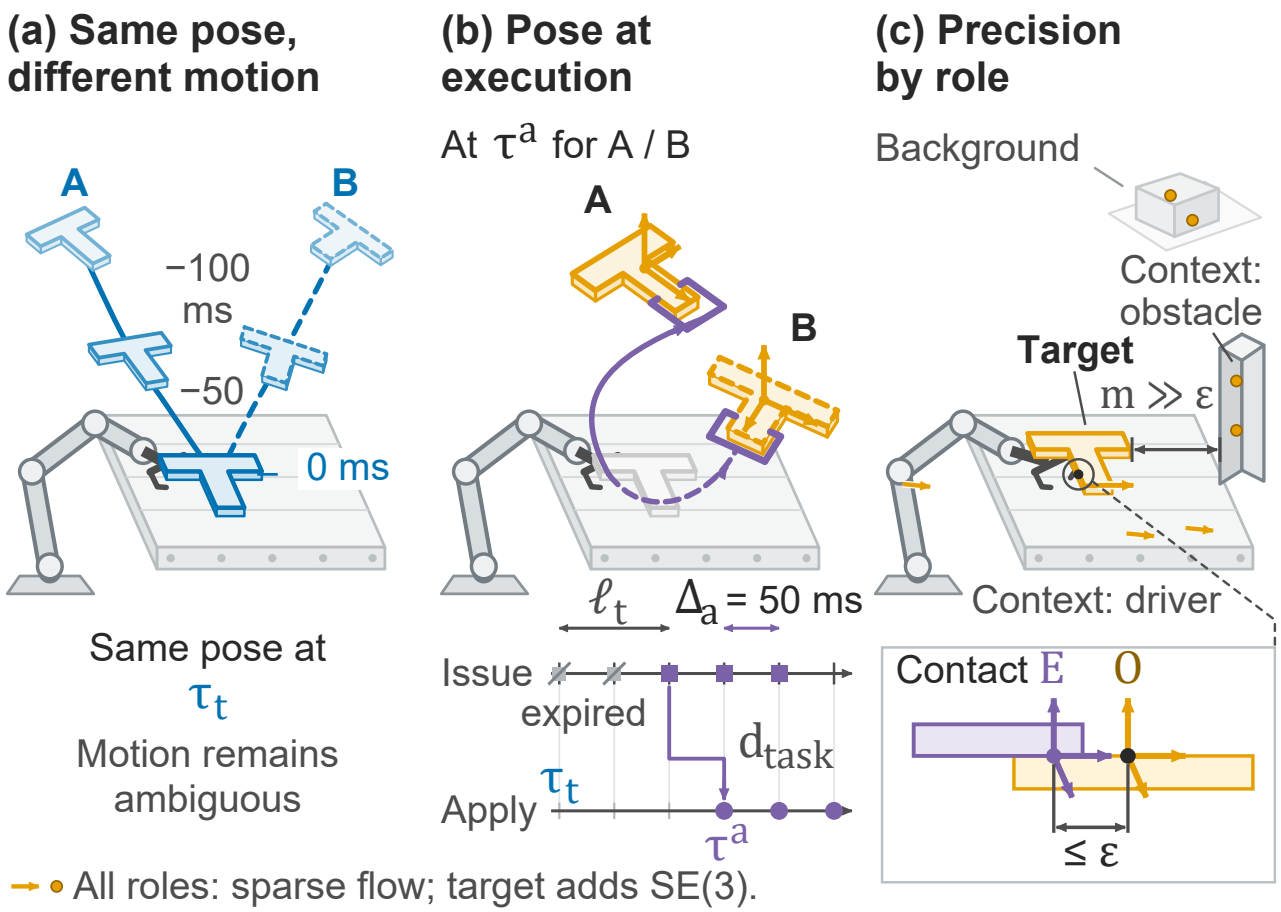


图 2. **作用于运动目标**（示意图）。(a) 不同运动历史在采集时刻 τ_t 到达相同位姿。(b) 在同一执行时刻 τ^{a}，目标的位置和朝向不同，因而需要不同指令（紫色）。指令发出时刻从采集起每隔 $\Delta_a = 50\,\mathrm{ms}$ 排列；灰色时隙在延迟 ℓ_t 期间过期。保留的指令经过任务延迟 d_{task} 后作用于机器人，首次作用时刻为 $\tau^{\mathrm{a}} = \tau_t + \ell_t + d_{\mathrm{task}}$。(c) 接触要求 E 与 O 在毫米级容差 ε 内对齐；障碍物留下间隙 $m \gg \varepsilon$，传送带驱动目标，远处背景不影响任务。稀疏流覆盖所有角色（箭头表示位移，圆点表示零位移），目标额外接受精细 SE(3) 监督。位姿与延迟均为示意（$\ell_t = 2\Delta_a$、$d_{\mathrm{task}} = \Delta_a$）；接触区域已放大。

其中 d_{task} 为任务内置的指令延迟。动作块要经过延迟 ℓ_t 才可用，因此 $j\Delta_a < \ell_t$ 的指令已经过期，其余指令在各自的时刻 $\tau^{\mathrm{a}}_{t,j}$ 执行。因此，指令必须适合 $\tau^{\mathrm{a}}_{t,j}$ 而非 τ_t 时刻的目标位姿，而这一位姿只能由 τ_t 的观测来估计；被执行指令的领先时长 $\Delta = \tau^{\mathrm{a}}_{t,j} - \tau_t$ 至少为 ℓ_t，因而随推理的每一毫秒增长。场景中的物体扮演不同的角色。目标是位姿必须在接触或容纳容差 ε 内对齐的物体，例如要抓取的物体或要放入的容器。环境由约束或推动目标运动的物体组成：障碍物（例如遮挡物或导线）须以间隙 m 避开，驱动物（例如传送带、斜坡或撞击器）推动目标运动。场景的其余部分不影响任务。第 3.2 节分析这一估计的误差如何依赖领先时长与这些角色，并据此导出 SE(3)-WAM 的表示。

3.2 按角色区分精度的 4D 表示

哪些必须精确。 设策略显式或隐式地依据 τ^{a} 时刻目标位姿的一个估计行动，其位置误差为 e、旋转误差为 θ。力臂为 r 的接触点的误差至多为 $e + 2r\sin(\theta/2)$。把目标在领先时长内的运动写成匀速 $\mathbf{v}$ 加残差（加速、滚动、撞击），并把策略所假定的领先时长记为 $\hat{\Delta}$，可得

$$e \le e_{\mathrm{loc}} + \hat{\Delta}\, e_v + \|\mathbf{v}\|\, e_\tau + e_{\mathrm{dyn}}, \tag{2}$$

其中 e_{loc}、e_v、$e_\tau = |\hat{\Delta} - \Delta|$ 与 e_{dyn} 依次为当前位置、速度、时刻与残差运动的误差（附录 A.1）。容差 ε 通常只有几毫米，旋转误差还会经力臂放大，因此必须精确掌握目标的位姿与运动。环境所需的精度低得多：障碍物只需以间隙 m 避开，m 通常远大于 ε；驱动物通过传给目标的运动起作用，这一运动随后体现在目标自身的未来中；两种情况下，对环境的粗略估计都已足够（图 2c）。因此，我们用度量 SE(3) 状态表示目标，包括其已观测的历史与预测的轨迹，并用稀疏 3D 流表示整个场景；它们都在机器人基座坐标系与物理时间中表示。

延迟允许什么。 延迟两次进入式 (2)：一次通过放大每个速度误差的领先时长，一次通过残差累积的运动。按式 (2)，消耗推理时间的信息只有当它消除的误差多于额外延迟带来的误差时才划算。SE(3)-WAM 让输入保持廉价：只用一张当前图像和低维的状态历史，而不用过去的帧；预测只用于监督训练，因而不增加推理时间（第 3.4 节）。

目标运动：历史与预测。 单个位姿无法揭示目标如何运动（图 2a）。目标历史覆盖最近 8 个控制步（20 Hz 下为 350 ms）。它由基座坐标系下的当前目标位姿和相邻采样之间的七段区间运动组成，每段包含平移、相对旋转、时间间隔，以及有限差分得到的速度与加速度，均为物理单位，构成 8 个目标状态 token（附录 A.2）。这些 token 直接给出 e_v 与部分 e_{dyn} 所依赖的速度和加速度，代价只是几个低维 token。机器人历史另外提供 8 个末端执行器状态 token。在仿真中，目标位姿来自仿真器；在真机上，由因果跟踪器从 RGB-D 流中估计（附录 D）。

预测描述指令执行时目标会在哪里（图 2b）。它覆盖固定的物理时刻 $\tau_t + \delta_h$，其中 $\delta_h = h{\cdot}50\,\text{ms}$，$h = 1, \dots, 8$，即采集后 50 ms 到 400 ms，因此 $j \geq 1$ 的每个指令时刻 $\tau^{\text{a}}_{t,j}$ 都是一个预测时域。与我们所有的运动标签一样，它从当前状态累计，各损失只在有效标签上取平均。对每个时域，目标的运动为

$$\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t), \quad \phi_h = \operatorname{Log}\big(R(\tau_t{+}\delta_h)R(\tau_t)^\top\big)^\vee. \tag{3}$$

摘要 token 最终状态均值上的线性位姿头预测 $(\hat{\mathbf{d}}_h, \hat{\phi}_h)$，损失为

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h \in \mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\text{SO(3)}}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{4}$$

其中 $\hat{R}_h = \operatorname{Exp}(\hat{\phi}_h^\wedge) R(\tau_t)$，$\mathcal{V}$ 为有效时域集合。由于位姿头读取的是摘要 token，即动作唯一能读取的世界 token（第 3.3 节），精确的目标监督塑造的正是动作所使用的表示。目标的过去与未来因此共用同一个度量坐标系与同一条时间轴。

场景运动：稀疏 3D 流。 14×14 网格上 196 个 patch 的中心点覆盖目标、机器人与周围环境。对每个点 i 和时域 h，其最终 patch token 上的线性头预测基座坐标系中的位移 $\hat{F}_{ih} \in \mathbb{R}^3$ 与可见性 logit $\hat{o}_{ih}$，损失为

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h) \in \mathcal{V}_F} \Big[\tfrac{1}{3} \big\| (\hat{F}_{ih} - F_{ih})/s \big\|^2 + \text{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \tag{5}$$

其中 s 为在训练标签上拟合的固定尺度，o_{ih} 为可见性，$\mathcal{V}_F$ 为有效标签集合。网格对工作空间稀疏采样，相邻点约相距 [X] mm。因此，流以这一间距为环境与机器人提供运动估计，在静止的背景上接近于零，而目标还额外接受式 (4) 的专用 SE(3) 监督。流监督的是摘要 token 从中汇聚信息的 patch token，比精确的目标监督低一层；这就是 SE(3)-WAM 按角色分配精度的方式。

辅助监督。 另有两类目标对表示起正则作用：我们在开发场景上选定了它们（附录 E）。patch token 上的未来外观头在每个时域预测度量深度、冻结 DINOv3 教师 [35] 的特征，以及运动表面的 RGB。此外，摘要 token 上的一个小头重建当前目标区域的 RGB，使摘要与目标关联，而不使用未来标签。它们的损失构成 $\mathcal{L}_{\text{aux}}$（附录 A.2）。

3.3 动作生成与联合学习

动作流。 动作流包含 $H = 8$ 个 token，对应动作块中的每条指令；每个 token 嵌入一条加噪指令，即末端执行器的平移与旋转增量加夹爪指令（附录 A.2）。注意力掩码 $\mathcal{G}$ 让场景 token 读取场景，摘要 token 读取场景与摘要，动作 token 读取摘要与动作；因此动作通过摘要 token 读取世界，而世界流不依赖动作。每一层中，两条流共享注意力投影，借此交换信息，并各自保留独立的前馈网络，使每条流有自己的容量；我们在开发场景上将这一主干与参数完全分开的主干比较后选定了它（附录 E.4）。世界 token 使用层归一化，动作 token 使用以流时间为条件的自适应层归一化。

联合学习。 对以训练统计量归一化的动作块 $\mathbf{a}_1$（附录 A.2）、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与流时间 $u \sim \mathcal{U}[0, 1]$，参数为 ψ 的动作流 v_ψ 回归流匹配速度：

$$\mathcal{L}_A = \mathbb{E} \left\| v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t, \mathcal{G}) - (\mathbf{a}_1 - \mathbf{a}_0) \right\|^2, \tag{6}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为第 t 次查询的场景 token，误差在有效指令上取平均。所有部分以

$$\mathcal{L} = \mathcal{L}_A + \lambda_P \mathcal{L}_P + \lambda_F \mathcal{L}_F + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}} \tag{7}$$

联合训练，各权重见第 4.1 节。

3.4 高效推理与执行

SE(3)-WAM 的预测头联合训练、在测试时跳过，与近期的 WAM [22, 53] 相同。由于世界 token 既不读取动作，也不读取流时间，世界流每次查询只运行一次，动作流在缓存的键和值上积分 5 个 Euler 步。执行器按整数个控制周期计延迟，与 RTC [7] 的做法相同。总延迟为 L_t 的查询在其结束时或之后的第一个控制周期边界交出动作块，即采集后 $\ell_t = k_t \Delta_a$，其中 $k_t = \lceil L_t / \Delta_a \rceil$；执行从对应该边界的第 k_t 条指令继续。策略在该边界重新观测并开始下一次查询；在此之前，执行器继续执行上一个动作块。因此，策略以其延迟允许的最高频率重新规划；当一次查询能在一个控制周期内完成时，每条指令之前都会重新规划。由于每条指令都在其标签所指的时刻下发，动作流不需要延迟输入，式 (2) 中的时间误差 e_τ 仅剩执行器的动作延迟。每条被执行的指令距采集至多 $(H-1)\Delta_a + d_{\text{task}}$，都落在预测监督的时域之内（附录 B.3）。在真机上，L_t 还包括在最新一帧中跟踪目标的时间。

4 实验

我们评估：场景在推理期间持续运动时 SE(3)-WAM 的表现（第 4.2 节），各组件的贡献（第 4.3 节），以及它在真机上的表现（第 4.4 节）。

4.1 设置

Dynamic-14 。 Dynamic-14 是一个仿真基准，观测、场景运动与动作执行共用一个物理时钟，因此策略计算时场景继续运动，每个方法都要为自身的延迟付出代价。它在 MuJoCo/robosuite [42, 62] 中包含

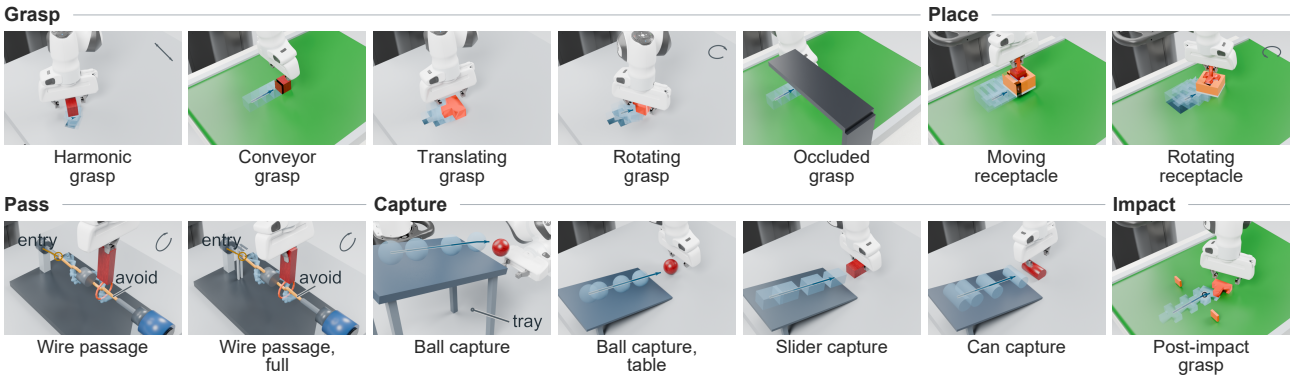


图 3. **Dynamic-14** 。采用统一主视角，从记录的仿真状态渲染五个任务族共 14 个任务。四个历史位姿以半透明蓝色显示，时间越早越淡；深蓝轨迹表示实测的过去运动。灰色角落箭头定性表示旋转或振荡，小圆圈标出记录到撞击时的目标中心。两个 Pass 子图均展示穿越阶段：导线在入口处是目标，沿途则是避碰障碍；Full 还要求获取、退出和释放。被遮挡的运动保持隐藏。这些原生专家示例用于展示任务动态，不代表 SE(3)-WAM 的执行结果，图中不显示未来预测。

五个任务族共 14 个任务：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（图 3；附录 B）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个，新种子）上报告全部 Dynamic-14 结果。

评测。 每次查询期间，物理按该方法自身的推理延迟推进：延迟从该方法在一块 RTX 5090（我们机器人所用的 GPU）上以 batch 1 实测的延迟分布中抽取，与运行 rollout 的硬件无关（附录 B.3）。所有方法共用一个按相对采集时刻的时间索引动作块的执行器（第 3.4 节）：查询在控制周期边界开始，其动作块在查询结束时或之后的第一个边界接管执行（附录 B.3）。除这一原生延迟设置外，我们还为每个方法附加 150 ms 延迟，以及在推理期间暂停物理；附录 C.2 另给出等延迟与原执行方式两种对照。我们报告在 14 个任务上等权、并在训练种子上平均的成功率（SR），以及 p95 延迟，即从观测到达到其第一条指令可用的实测时间（出动作时间）。配对 95% 区间由对留出场景的自助法得到。

基线。 我们比较反应式策略、动态 VLA、图像或隐空间 WAM，以及一个动态 WAM（表 1）。每个基线使用其官方代码、输入与训练配方，在相同示范上训练；若其配方使用腕部相机或帧、光流历史，则一并提供（附录 B.5）。SE(3)-WAM 只使用一个主视角及其深度和目标的 SE(3) 历史，不使用过去的帧。为了让基线获得相同的目标运动信息，$\pi_{0.5}$ 与 DynamicWAM 还以接收我们 SE(3) 历史 token 的形式运行（+SE(3)）。

实现。 Transformer 共 24 层，宽度 1024，16 个注意力头，可训练参数 523.8M；MAE ViT-B/16 编码器与 DINOv3 教师保持冻结。在 Dynamic-14 上，它从随机初始化开始训练 20 轮，使用 AdamW，$\lambda_P = \lambda_F = 1$，$\lambda_R = \lambda_{\text{aux}} = 0.1$（附录 A.3）。在真机上，它从一个在 DROID [20] 上预训练的 48 层基座出发，逐任务微调（附录 A.4）。

4.2 仿真结果

对比。 在原生延迟下，SE(3)-WAM 在 Dynamic-14 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。优势最大

表 1. **主要结果。**1,400 个 Dynamic-14 留出场景的任务均衡 SR：原生延迟、+150 ms 和暂停物理。SE(3)-WAM 训练三个种子，基线各一个。p95：RTX 5090 上的出动作时间。腕部及历史列表示额外输入（第 4.1 节）。每列已有结果的最佳值为粗体加蓝底，次佳为浅蓝底；结果待齐，排名为暂时性比较。

方法	历史			SR (%) ↑			
	腕部 RGB	光流	SE(3)	原生	+150 ms	暂停	p95 (ms) ↓
ACT [59]				**42.0**	**24.1**	**40.9**	**10.7**
DP [12]		✓		0.0	0.0	33.1	1701.9
$\pi_{0.5}$ [5]				—	—	—	—
$\pi_{0.5}$+SE(3)	—		✓	—	—	—	—
DynamicVLA [47]		✓		—	—	—	—
PUMA [14]			✓	—	—	—	—
OpenWAM-α [43]				—	—	—	—
DynamicWAM [28]			✓	—	—	—	—
DynamicWAM+SE(3)	—		✓	✓	—	—	—	—
SE(3)-WAM				✓	—	—	—	—

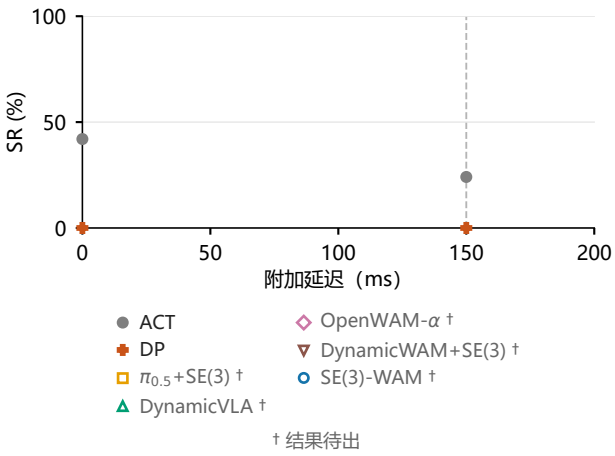


图 4. **附加延迟下的成功率。**1,400 个 Dynamic-14 留出场景上的比较。图例保留全部计划序列并加入 DP；† 标记结果待出的模型。ACT 与 DP 已有 0/150 ms 测量。仅连接相邻的已测点。虚线：+150 ms；完整扫描表见表 S7。

的是 [任务类型]（附录 C.1）。它的 p95 延迟为 [XX] ms，是图像空间 WAM 的 [X] 分之一，与 [作为参照的反应式策略，待定] 相近。

延迟与协议。 附加 150 ms 延迟后，SE(3)-WAM 保持 [XX.X]%，而反应式策略平均降至 [XX.X]%，图像空间 WAM 降至 [XX.X]%，与式 (2) 的预测一致：附加延迟拉长了放大每个速度误差的领先时长，因此不预判目标运动的方法损失最大。图 4 展示 0–200 ms 扫描中的已有测量，待测项列于附录 C.2。推理期间暂停物理、即不计计算代价时，SE(3)-WAM 仍领先 [名称] [X.X] 个百分点，原生延迟下这一差距为 [X.X] 个百分点。当每个方法都被计入 SE(3)-WAM 的 p95 延迟时，其领先为 [X.X] 个百分点；让 [依赖自身异步执行的基线] 使用原执行方式，其 SR 的变化不超过 [X.X] 个百分点（附录 C.2）。

DOMINO。 我们还在 DOMINO [14] 的 24 个单臂 Franka 任务上，用其示范训练 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA，并用其原生评测器评测。SE(3)-WAM 的成功率为 [XX.X]%，[最强基线] 为

表 2. **DOMINO 结果**（24 个单臂 clean-L1 任务，各方法用 DOMINO 的示范训练；每个方法一个训练种子，每个任务与方法 50 个回合）。SR（%）按交互类型分组并在任务上平均；MS 为操作得分。测量完成后，每列最佳以粗体加蓝底标出。协议见附录 C.3。

方法	拦截	跟踪	全部↑	MS↑
$\pi_{0.5}$	—	—	—	—
DynamicWAM	—	—	—	—
PUMA	—	—	—	—
SE(3)-WAM	—	—	—	—

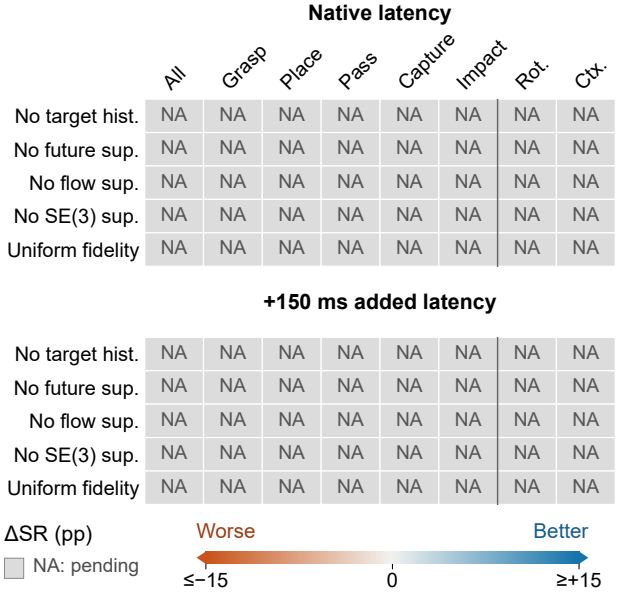


图 5. **按任务的消融效应（设计预览；数据待齐）。** ΔSR = SR(对照) − SR(完整模型)，单位为百分点；色阶在 ±15 处饱和。各行为第 4.3 节的五个对照；完整模型在原生延迟下的 SR 为 [XX.X]%，附加 150 ms 时为 [XX.X]%。Rot./Ctx. 分别表示预先声明、可重叠的旋转敏感组和环境活跃组（表 S3）。计划先对每个场景的三个训练种子取平均，再对各列内任务等权聚合，保留 `t3_phase`。将以粗体标出未作多重比较校正、且不含零的配对 95% 场景自助法区间；区间以给定训练权重为条件（附录 B.4）。灰色 NA 表示尚无合格配对结果或估计。

[XX.X]%（表 2；附录 C.3）。与在 Dynamic-14 上一样，它读取仿真器中的目标位姿。

4.3 消融与分析

五个对照各改变最终模型的一个组件，保持数据、配方与训练预算不变，每个对照训练三个种子（图 5）。它们检验第 3.2 节的论证：目标历史提供式 (2) 中 e_v 所依赖的速度；未来监督塑造表示而不增加推理时间；两项几何成分与一个统一精度的预测检验按角色分配精度。我们在原生延迟与附加 150 ms 延迟下评估它们（各种子结果与敏感性分析见附录 C.4）；由于部署时跳过全部预测头，各对照的推理代价与 SE(3)-WAM 相同。

目标历史。 无历史对照移除过去的目标位姿及其速度、加速度特征，保留当前图像、当前目标位姿与机器人历史；与其他对照不同，它改变的是输入。去掉历史后，SR 在原生延迟下下降 [X.X] 个百分点，在附加 150 ms 延迟下下降 [X.X] 个百分点，与式 (2) 的预测一致：领先时长越长，历史所消除的速度误差被放大得越多。由于历史依赖位姿估计，我们还对位姿施加扰动；在合成的时序相关位姿噪声下，SE(3)-WAM 的 SR 为 [XX.X]%（附录 C.5）。

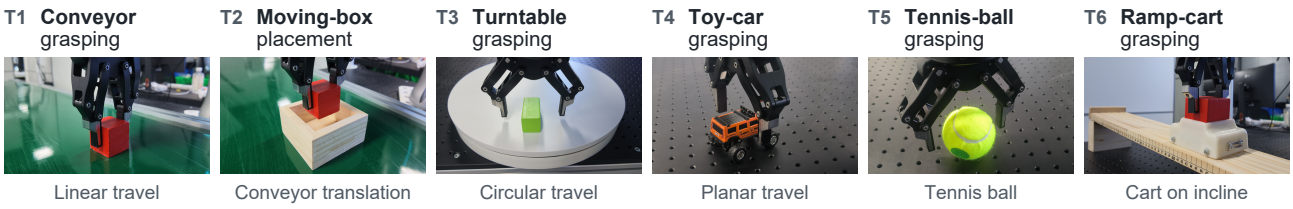


图 6. **真机任务场景。**六项任务的实拍照片：传送带抓取（T1）、向移动盒放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5）和斜坡小车载块抓取（T6）。

表 3. **真机结果。**第 4.4 节六个任务上的成功率（%），每个任务每个方法 20 次试验；All 合并全部试验。p95 延迟：在一块 RTX 5090 上实测的端到端出动作时间（ms），SE(3)-WAM 包含跟踪。DP：Diffusion Policy。测量完成后，每列最佳以粗体加蓝底标出，并列者同样标出。成功次数、区间与失败统计见附录 D。

方法	T1	T2	T3	T4	T5	T6	All ↑	p95 (ms) ↓
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
DP	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	—

未来监督。 无未来对照移除全部预测损失，即 SE(3)、场景流与未来外观目标，保留当前目标 RGB 重建。它的推理与 SE(3)-WAM 完全相同，但 SR 在原生延迟下下降 [X.X] 个百分点，在附加 150 ms 延迟下下降 [X.X] 个百分点，在 [目标做非匀速运动的任务] 上最明显。离线评估中，学习得到的 SE(3) 预测也比对同一历史做匀速与匀加速外推更准确（表 S9）。

精度的分配。 三个对照保留全部辅助目标，只改变几何预测。移除场景流监督使 SR 下降 [X.X] 个百分点；由于流也覆盖目标与机器人，而且外观目标仍然保留，这一项衡量的是粗粒度场景运动监督的贡献，而不是全部环境信息的贡献。移除专用 SE(3) 监督后，目标只剩下场景各部分共有的粗粒度流，SR 下降 [X.X] 个百分点。如果精度按角色分配，SE(3) 监督应在位姿容差更紧或接触对旋转敏感的任务上作用最大，而流监督应在环境约束或推动目标运动的任务上作用最大。[图 5 是否呈现这一模式；若没有，则说明这些对照确立了各组件的贡献，但未确立按角色的分配。] 统一精度对照用整帧的 [冻结视频 VAE 的未来隐变量] 在相同时域上取代 SE(3) 与场景流目标，使场景的每一部分都以同一精细程度被预测；在相同推理代价下，它落后 SE(3)-WAM [X.X] 个百分点。[用一句话概括哪些组件起作用、在哪里起作用。]

4.4 真机实验

设置。 我们在 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机上评估六个任务（图 6；附录 D）：传送带抓取（T1）、向移动容器放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5），以及斜坡小车载块抓取（T6）。基线为 $\pi_{0.5}$（VLA）、DynamicWAM（动态 WAM）与 Diffusion Policy [12]（反应式）。所有方法逐任务在相同的 100 条遥操作示范上训练或微调，并以共享试验键各运行 20 次试验（附录 D.3）。基线接收 RGB[，若配方使用腕部相机则一并提供]；SE(3)-WAM 还接收 FoundationPose [44] 的目标位姿估计，在每个控制周期边界、查询之前更新（附录 D.2）。表 3 报告包含跟踪的端到端延迟。

结果。 SE(3)-WAM 在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%，配对差为 [X.X] 个百分点（95% 区间 [[X.X, X.X]]；表 3）。包含跟踪在内，其 p95 延迟为 [XX] ms，[在一个控制周期之内]，而 [名称] 需要 [XX] ms。优势最大的是 [任务]，SE(3)-WAM 的主要失败模式是 [失败模式]（附录 D.4）。

5 结论

SE(3)-WAM 把精度花在接触所依赖之处：用度量 SE(3) 历史与预测表示目标，用稀疏 3D 流表示整个场景，并且预测只作为训练监督。它在 Dynamic-14 上的成功率为 [XX.X]%，在 DOMINO 上为 [XX.X]%，在六个真机任务上为 [XX]%，p95 延迟为 [XX] ms，优于反应式、动态与世界—动作策略。[消融表明，目标历史在附加延迟下作用最大，未来监督在不改变推理计算的情况下改善控制。][说明专用 SE(3)、场景流与统一精度对照支持什么：更好的预测设计，或者在任务分组也一致时，按角色分配精度。] 计入推理延迟后，[说明成功率与相对表现与暂停评测相比有何不同]。

局限性。 SE(3)-WAM 需要一个指定的刚体目标及其可靠的位姿估计，其预测也不建模机器人自身的接触如何改变目标的运动。目标轨迹预测头在每个时域只预测一个未来，不表示不确定性或多模态运动；不确定性感知的预测可以弥补这一点。

LLM Usage Statement（大语言模型使用声明）

我们使用 OpenAI Codex 辅助文献调研、代码实现与调试、实验执行及论文语言润色。Codex 还用于辅助编写绘图代码，以及调整图表与论文排版。作者审阅了 AI 辅助生成或修改的内容，对照原始来源核查了参考文献，并通过测试与实验验证了实现。作者对最终稿件、实验结果和结论承担全部责任。

参考文献

[1] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[2] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. Wiley, 2001.

[3] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[4] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[5] Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *Proceedings of The 9th Conference on Robot Learning*, pages 17–40, 2025.

[6] Kevin Black, Noah Brown, Danny Driess, et al. π_0: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[7] Kevin Black, Manuel Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, pages 33383–33407, 2025.

[8] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, pages 173–180, 2017.

[9] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[10] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[11] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Joon-Young Lee, and Alexander Schwing. Putting the object back into video object segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[12] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[13] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 15873–15879, 2025.

[14] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. In *European Conference on Computer Vision*, pages 314–333, 2026.

[15] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[16] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model

with flow-based motion representations for robot manipulation. *IEEE Robotics and Automation Letters*, 11(3):2466–2473, 2026.

[17] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[18] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[19] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20765–20779, 2026.

[20] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[21] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, pages 2679–2713, 2025.

[22] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[23] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[24] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[25] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[26] Yuejiang Liu, Jubayer Hamid, Annie Xie, Yoonho Lee, Max Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, pages 4594–4627, 2025.

[27] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[28] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[29] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[30] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *Robotics Research: The 19th International Symposium ISRR*, pages 132–157. Springer, 2022.

[31] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[32] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, pages 28085–28128, 2025.

[33] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pages 785–799, 2023.

[34] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[35] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[36] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[37] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. In *European Conference on Computer Vision*, pages 437–453, 2026.

[38] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. In *Proceedings of the 43rd International Conference on Machine Learning*, pages 115917–115933, 2026.

[39] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. In *Conference on Robot Learning*, 2026. Accepted for publication.

[40] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[41] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, pages 92033–92052, 2025.

[42] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[43] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[44] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[45] Chuan Wen, Xingyu Lin, John Ian Reyes So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[46] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, pages 10641–10662, 2024.

[47] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[48] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, pages 2475–2499, 2025.

[49] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[50] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[51] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2025.

[52] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[53] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[54] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. In *European Conference on Computer Vision*, pages 20–39, 2026.

[55] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[56] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[57] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[58] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[59] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[60] Ruijie Zheng, Jing Wang, Scott Reed, et al. FLARE: Robot learning with implicit world modeling. In *Proceedings of The 9th Conference on Robot Learning*, pages 3952–3971. PMLR, 2025.

[61] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[62] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

[63] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183, 2023.

A 方法与训练细节

A.1 误差分解

本小节推导式 2，以及附录 B.1 任务分组所依据的旋转项与环境项，并说明一个估计的误差如何随领先时长与运动而变化。

平移。 把执行时刻目标的真实位置写为 $\mathbf{p}(\tau^{\mathrm{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，其中 $\mathbf{v}$ 为 τ_t 时的速度，$\boldsymbol{\rho}$ 为其余运动；策略的估计写为 $\hat{\mathbf{p}}(\tau^{\mathrm{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。减去再加上 $\mathbf{v}\hat{\Delta}$ 得到

$$\begin{aligned}\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}}) = \big[\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\big] + (\hat{\mathbf{v}} - \mathbf{v})\hat{\Delta} \\ + \mathbf{v}(\hat{\Delta} - \Delta) + (\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}),\end{aligned} \tag{S1}$$

由三角不等式即得式 2，其中 $e_v = \|\hat{\mathbf{v}} - \mathbf{v}\|$，$e_{\mathrm{dyn}} = \|\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}\|$。这一上界对估计拆分为 $\hat{\mathbf{v}}\hat{\Delta}$ 与 $\hat{\boldsymbol{\rho}}$ 的任何方式都成立，计时误差的高阶部分计入 e_{dyn}。残差 $\boldsymbol{\rho}$ 是匀速外推遗漏的运动。在匀加速 $\mathbf{a}$ 下 $\boldsymbol{\rho} = \frac{1}{2}\mathbf{a}\Delta^2$，由历史估计的加速度可以减小这一项；撞击、滚动接触与摩擦变化留下的部分则只有动力学模型才能减小。

旋转与接触点。 把真实朝向写为 $R(\tau^{\mathrm{a}}) = \mathrm{Exp}(\boldsymbol{\omega}\Delta + \boldsymbol{\eta})R(\tau_t)$，其中 $\boldsymbol{\omega}$ 为角速度，$\boldsymbol{\eta}$ 为其余转动，估计同理。旋转角对左右乘法不变，且 Exp 从 $\mathbb{R}^3$ 到 SO(3) 是 1-Lipschitz 的，因此对一般旋转有

$$\begin{aligned}\theta &= \big\|\,\mathrm{Log}(\hat{R}(\tau^{\mathrm{a}})R(\tau^{\mathrm{a}})^{\top})^{\vee}\big\| \\ &\le \theta_{\mathrm{loc}} + \|\hat{\boldsymbol{\omega}}\hat{\Delta} + \hat{\boldsymbol{\eta}} - \boldsymbol{\omega}\Delta - \boldsymbol{\eta}\| \\ &\le \theta_{\mathrm{loc}} + \hat{\Delta}\, e_\omega + \|\boldsymbol{\omega}\|\, e_\tau + e_\eta,\end{aligned} \tag{S2}$$

其中 θ_{loc} 为当前朝向误差，$e_\omega = \|\hat{\boldsymbol{\omega}} - \boldsymbol{\omega}\|$，$e_\eta = \|\hat{\boldsymbol{\eta}} - \boldsymbol{\eta}\|$。物体坐标系中位于 $\mathbf{c}$、$\|\mathbf{c}\| = r$ 的接触点在 τ^{a} 的偏差为 $(\hat{\mathbf{p}} - \mathbf{p}) + (\hat{R}R^{\top} - I)R\mathbf{c}$，而 $\hat{R}R^{\top} - I$ 的算子范数为 $2\sin(\theta/2)$，因此其误差满足

$$e_{\mathrm{c}} \le e + 2r\sin(\theta/2) \le e + r\theta, \tag{S3}$$

其中 $e = \|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\|$。抓取或放置约束的是分布在物体上的多个点，例如两个手指的接触点或 T 形件的两臂，因此跟踪任何单个点都消不掉 $r\theta$ 项：朝向误差按力臂放大后进入接触，目标需要其完整的 SE(3) 状态。

环境。 记 m 为可行路径在机器人及所持物体与其经过的环境之间所能保持的最大余量，按环境在 τ^{a} 的预测位置度量。如果执行路径保持这一余量，那么只有环境误差至少为 m 时才会发生碰撞，因此当 $m \gg \varepsilon$ 时对周围环境的粗略估计即可满足要求。第 4.3 节的无场景流监督对照直接检验这种粗粒度监督。驱动物（例如传送带、斜坡或撞击器）通过传给目标的运动影响接触，这一运动经由目标自身的各项进入式 2。SE(3) 历史与预测精确表示这一运动，因此驱动物本身不需要精确的状态。

A.2 架构

表 S1 按下文所述的数据流顺序列出各模块的配置。

表 S1. SE(3)-WAM 的架构。各预测头在部署时被跳过。

模块	配置
视觉编码器	冻结的 MAE ViT-B/16，输入 224×224，196 个 patch token
目标状态编码	$28 \to 1024 \to 1024$ GELU MLP，加性相对时间嵌入
机器人状态编码	线性，$7 \to 1024$
Token	212 个场景（196 个 patch、8 个目标状态、8 个机器人）、16 个摘要、8 个动作
主干	24 层，宽度 1024，16 个注意力头，共享注意力，每个流的 SiLU 前馈 4096，504.0M 参数
位姿头	线性，摘要状态均值 $\to 8 \times 6$
流预测头	每个 patch token 上的线性读出，$8 \times (3{+}1)$
外观预测头	每个 patch token 上的线性读出：深度与运动表面 RGB 以 16×16 像素输出，1024 维 DINOv3 ViT-L/16 特征
目标重建	$1024 \to 256 \to 3072$ GELU MLP 加 sigmoid，32×32 RGB
动作流	流匹配，以流时间做自适应层归一化，5 个 Euler 步

场景 token。 冻结的 MAE ViT-B/16 [17] 把主视角 RGB 编码为 196 个 patch token；我们在开发场景上选定了它（附录 E.4）。每个 patch token 加上一个可学习的视角嵌入（单视角设置下由所有 patch 共享），以及其平均有效度量深度和其中心像素反投影后基座坐标系位置的线性嵌入。这些位置也驱动 patch query 与 key 的 3D 旋转位置编码，其他 token 都不使用旋转位置编码；同样的中心点也是稀疏 3D 流的源点。过去的图像从不进入模型。

状态 token。 8 个目标状态 token 在偏移 $-350, -300, \ldots, 0$ ms 处取样。每个都是 25 维描述子 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta t, \mathbf{v}, \boldsymbol{\omega}, \mathbf{a}, \boldsymbol{\alpha})$，各分量维数为 $(3, 3, 3, 3, 1, 3, 3, 3, 3)$：槽位 0–6 描述相邻偏移之间的七个区间，速度为区间位移除以经过的时间，加速度为相邻速度之差除以区间中心的间隔；槽位 7 存放基座坐标系下当前的绝对位姿。我们用训练统计量对每一维标准化，把无效维置零，并附加三个有效性标志（位姿、区间与加速度）；没有任何有效特征的槽位在注意力中被掩码。在真机上，跟踪器在每个控制周期边界更新位姿（附录 D.2），因此历史保持同样的 50 ms 间隔。机器人 token 包含相同偏移处的末端位置、旋转向量与测得的夹爪开度，16 个可学习嵌入构成摘要 token。策略没有语言 token。

主干与掩码。 每一层用两个流共享的 query、key、value 与输出投影对全部 token 做一次注意力，随后世界 token 与动作 token 分别通过各自的 SiLU 前馈网络。第 3.3 节的掩码使被阻断的连接在每一层、每个注意力头上、训练与部署时都取 logit $-\infty$，因此世界状态在每次查询中只计算一次，并在各 Euler 步之间复用。

预测头与辅助头。 所有预测头都读取世界流的最终状态，与动作流一同训练，部署时被跳过，且没有任何 token 读取其输出。位姿头读取摘要状态的均值，以 $\mathcal{L}_P$（式 4）训练。流预测头给出每个 patch 点在每个时域的位移与可见性 logit，以 $\mathcal{L}_F$（式 5）训练，尺度 $s = 0.7154605$ m；仿真中可见性损失的权重为 1，有效但不可见的点仍监督其位移。外观预测头在每个时域预测度量深度（在有效像素上取平方误差）、移动超过 1 mm 的表面（包括机器人）的 RGB（取平方误差），以及 DINOv3 特征 [35]（经通道层归一化后取平方误差）。目标重建头从摘要状态均值以绝对误差恢复当前目标的 RGB 区域。这四项损失构成 $\mathcal{L}_{\text{aux}}$。

动作流。 8 个动作 token 各嵌入一条七维指令：基座坐标系下的平移增量、左相对旋转向量与夹爪指令；增量以执行时测得的末端位姿为参照。部署时，我们积分 5 个 Euler 步，反归一化，解码旋转向量，

并把每个轴截断到 0.05 m 与 0.5 rad；夹爪跟随其指令的符号。附录 B.3 说明动作块如何执行。

A.3 在 Dynamic-14 上训练

示范中的每个控制步锚定一个窗口，窗口包含 8 个查询位置，各有自己的因果历史，位置之间没有注意力；11,200 条示范共给出 1,324,374 个窗口，另有 350 个回合构成验证集。对于流标签，每个 patch 中心像素用渲染深度反投影，并绑定到该像素处渲染的 MuJoCo 几何体的局部坐标系；该几何体的真值刚体变换把同一个表面点带到各未来时域，由此得到它在基座坐标系中的累计位移。若未来点位于相机前方、投影在图像范围内，且其投影像素渲染的是同一几何体、深度与该点深度 z 之差不超过 $\max(1\,\mathrm{mm},\, 0.001z)$，则该点可见。第 t 次查询的动作块中，第 j 条指令的标签是示范在 $\tau_t + j\Delta_a$ 下发的指令，因为 d_{task} 只在执行时叠加（式 1）；指令用训练集中有效指令的均值与标准差归一化。每个查询位置为其动作块抽取 8 对噪声—时间样本并对损失取平均，这在不扩大 batch 的情况下降低了动作梯度的方差；每个损失按全局 batch 中的有效标签数归一化。未来帧的 DINOv3 特征按回合缓存一次。表 S2 列出训练配方。

表 S2. Dynamic-14 上的训练超参数。

项目	取值
优化器	AdamW，$\beta = (0.9, 0.999)$，$\epsilon = 10^{-8}$，权重衰减 10^{-4}
学习率	2×10^{-4}，从 0 开始 5,174 次预热更新，余弦衰减到 0
Batch 与更新	全局 batch 512 个窗口，20 轮（51,740 次更新）
损失权重	$\lambda_P = \lambda_F = 1$，$\lambda_R = 0.1$，每个辅助目标 $\lambda_{\text{aux}} = 0.1$
动作噪声	每个查询位置 8 对噪声—时间样本
精度	可训练权重 FP32，冻结编码器 BF16，梯度截断 0.1
推理	FP32，查询内缓存世界状态
硬件	[N] 块 RTX PRO 6000 GPU，每次训练 [X] 小时

A.4 DROID 预训练与微调

数据。 真机基座在以 15 Hz 录制的 DROID [20] 上训练，并使用 PointWorld 为其发布的 3D 点轨迹与相机标定 [19]；我们按机器人状态、指令与相机身份完全一致把它们与原始回合对应起来。模型使用第一台外部相机及其深度。在 42,935 个已对应的回合中，42,087 个给出 598,889 个锚点窗口：37,874 个训练回合给出 538,740 个，4,213 个验证回合给出 60,149 个。每个锚点扩展为 8 个连续的查询位置；锚点带有流与 DINOv3 标签，其余位置只带动作标签。所有时间均为采集时间戳，流与 DINOv3 目标保留 PointWorld 的记录时刻。我们保留下发了指令的 96.88% 的动作槽位，不按速度过滤，以免基座偏向缓慢运动。

训练目标。 DROID 不提供物体位姿，因此基座没有目标状态 token，也没有位姿头。它读取当前 RGB-D 帧与机器人历史（204 个场景 token），以权重 1 训练动作损失与稀疏 3D 流，以权重 0.1 训练未来 DINOv3 特征；PointWorld 只记录可见位置，因此可见性损失关闭。DROID 中的大多数物体只在机器人移动它们时才运动，因此基座主要学习度量几何与机器人自身动作引起的运动；我们任务中的外生运动与目标位姿在微调时才引入。

流标签。 14×14 网格的每个 patch 跟随一条 PointWorld 轨迹：在起点位于该 patch 内、初始可见且深度有效的轨迹中，取图像运动最大且与其 3D 位移一致的一条，否则取最靠近 patch 中心的一条，从而覆盖固定中心点会漏掉的运动物体。标签是轨迹相对其起点的位移；47.05% 的点—时域槽位带有标签。

配方与微调。 基座使用宽度 1024 的 48 层（1.02B 可训练参数），以全局 batch 512 在 64 块 GPU 上训练 20 轮（21,060 次更新，2,106 次预热更新），优化器与精度同表 S2。每个真机策略从基座出发，在其任务的示范上微调 [更新次数、学习率与 batch 大小]；基座所缺的目标状态 token 与预测头重新初始化。没有任何真机策略使用仿真权重，基座也不接触仿真数据。

B Dynamic-14 与评测协议

B.1 基准设计

Dynamic-14 包含五个任务族共 14 个任务（图 3；第 4.1 节），共同覆盖平移、旋转、暂时遮挡、受约束的通行，以及目标运动的突变。我们将公开这些任务、已接受的场景、成功判定与示范。

环境。 任务在 MuJoCo 3.11.0 与 robosuite 1.5.2 [42, 62] 中运行，使用 Franka Panda 机械臂与平行夹爪，由 robosuite 的操作空间位姿控制器驱动，控制周期为 50 ms，物理步长为 2 ms。一台固定的第三人称主视角相机位于 $(0.68, -0.58, 1.62)$ m，垂直视场角 40°，渲染 224×224 的 RGB-D 图像。动作是机器人基座坐标系下的末端增量，即一个平移与一个旋转向量，再加一条夹爪指令；共享的动作适配器把每条指令截断到每个平移轴 0.10 m、每个旋转向量分量 0.5 rad。

成功与终止。 表 S3 概述各任务的成功条件。我们在每个物理步判定这些条件，连续条件一旦中断其计数器清零；回合在第一个终止事件处结束：成功、失败（例如不安全接触、离开工作空间或掉落），或达到时限。

角色与任务组。 表 S3 给出每个任务的目标。移动的容器是目标，因为它的位姿决定能否放入；在穿越任务中，杆须在 30 mm 内与之对准的导线入口是目标，导线其余部分是不允许任何接触的环境。图 5 的两个任务组依据附录 A.1 的误差项在消融之前确定：若目标在领先时长内旋转且其朝向在接触时起作用，则任务属于旋转敏感组（$r\theta$），这排除了小球；若任务有障碍间隙 m 或驱动物（传送带、斜坡或撞击器），则属于环境活跃组。

B.2 场景、示范与数据划分

场景。 每个场景在各任务的范围内均匀采样目标的初始状态与运动参数，离散选项等概率采样：除表 S3 的速度外，还包括至多 35 mm、0.25–0.7 Hz 的谐波振幅、至多 1.2 rad/s 的偏航角速度、2.5–7.5°/s 的导线转速，以及 5–15° 的斜坡坡度（摩擦按物体设定）。只有当目标在开始时至少可见八帧、随后完全被遮挡 0.5–3.0 s、并再次可见至少三帧时，才接受一个遮挡场景。我们保留通过物理可行性检查的场景，并在评测时回放存储的已接受场景。

表 S3. **Dynamic-14 的十四项任务。**目标：策略接收其位姿的物体（第 3.1 节）。速度：目标速度范围（捕获任务取离开斜坡时的速度）。每个任务都须依次通过各阶段且不触发终止性失败；抓取要求双侧指垫接触、抬升至少 0.05 m 并保持 0.5 s。时限：回合时限。图 5 的任务组：R 为旋转敏感组，C 为环境活跃组（附录 B.1）。发布的任务配置包含确切阈值与场景范围。

任务（代号）	目标	速度（m/s）	成功条件	时限（s）	任务组
谐波抓取 (grasp)	物块	0.03–0.20	抓住做谐波运动并偏航的物块，抬起并保持。	8	R
传送带抓取 (t1_belt)	零件	0.04–0.10	抓住传送带上的零件，抬起并保持。	8	C
平移抓取 (t1_xyz)	零件	0.04–0.15	抓住平移的零件，抬起并保持。	8	–
旋转抓取 (t1_so3)	零件	0.04–0.15	抓住平移并旋转的零件（$\|\omega\| \leq 1.2$ rad/s），抬起并保持。	8	R
遮挡抓取 (t1_occ)	零件	0.04–0.10	抓住传送带上的零件（遮挡罩会将其遮住 0.5–3.0 s），且不与遮挡罩发生不安全接触；抬起并保持。	8	C
移动容器 (t2_trans)	容器	0.03–0.06	把所持物体完整放入移动的容器并释放，使其静止。	10	–
旋转容器 (t2_se3)	T 形容器	0.03–0.06	把所持 T 形件完整放入平移并旋转的 T 形容器并释放，使其静止。	10	R
导线穿越 (t3_phase)	导线入口	[X]	把所持杆端的环在 30 mm 内对准旋转的导线，然后沿导线无接触地穿到终点。	21	R, C
完整导线穿越 (t3_full)	导线入口	[X]	抓起杆，完成穿越，离开导线后释放杆。	32	R, C
小球捕获 (t4_sphere)	小球	[0.4–0.7]	在小球离开斜坡后、触及托盘前将其接住，抬起并保持。	6	C
桌面小球捕获 (t4_sphere_tabletop)	小球	[0.4–0.7]	在小球离开斜坡后仍在桌面滚动时将其抓住，抬起并保持。	6	C
滑块捕获 (t4_slider)	滑块	[0.4–0.8]	在滑块离开斜坡后仍在桌面滑动时将其抓住，抬起并保持。	6	C
罐体捕获 (t4_can)	罐体	[0.4–0.7]	在罐体离开斜坡后仍在桌面滚动、尚未倾倒时将其抓住，抬起并保持。	6	R, C
撞击后抓取 (t5_replan)	零件	0.12–0.14	撞击器把传送带上的零件撞偏后，沿其抓取轴将其抓住，抬起并保持。	6	R, C

示范。 专家是针对各任务的闭环状态机，使用仿真特权状态：目标当前的位姿、线速度与角速度，机器人状态，任务几何，以及真实的接触、夹持与阶段事件。在每个控制周期，它例如在抓取任务中对目标做短时外推，再跟踪、下探、闭爪与抬升；在捕获任务中按重力预测滚动或飞行物体的截获点；在穿越任务中沿已知导线路径运动，并按当前转角与角速度做相位补偿。其指令按每个轴截断到 0.05 m 与 0.5 rad。只有场景可行、专家成功、对记录动作的独立回放能重现该回合，且路径、动作变化与 jerk 通过数值质量检查的示范才被接受。训练池的 11,200 条示范（每个任务 800 条）取自已接受的示范。我们以 20 Hz 记录相机图像、深度、机器人状态、下发的指令，以及目标位姿与场景几何的仿真真值；学习得到的策略只接收第 3 节的输入。

数据划分。 我们在 1,400 个开发场景（每个任务 100 个）上选择配置。全部 Dynamic-14 结果使用另外 1,400 个留出场景，它们以相同的范围生成，使用不出现在任何训练、验证或开发回合中的新源种子；按种子递增顺序的前 100 个可行场景构成每个任务的集合，所有方法共用。

B.3 实时评测

执行器。 所有方法在 50 ms 控制时钟上共用第 3.4 节的执行器；一次查询的总延迟 L_t 是该协议下的推理延迟加上任何附加延迟。在第 3.4 节之外还有四条规则。各方法的动作块包含其原生的 H_m 条指令（表 S4），$k_t \geq H_m$ 的动作块已全部过期，整体丢弃。当 $L_t = 0$ 时，下一次查询在采集后一个控制周期开始。在回合的第一个动作块到达之前，以及动作块耗尽时，控制器保持当前的手臂目标与夹爪指令，物理照常推进，不重复执行任何指令。撞击后抓取在下发每条指令 50 ms 后才施加（式 1 中 $d_{\text{task}} = 50$ ms），其余任务 $d_{\text{task}} = 0$。

协议。 在实时协议下，每次查询期间物理按该方法的原生延迟推进，该延迟每次查询从其在一块 RTX 5090 上实测的延迟分布中抽取。在暂停协议下，仿真等待推理完成；在等延迟协议下，每个方法都被计入 SE(3)-WAM 的 p95 延迟；在原执行方式协议下，每个基线以原生延迟保留其论文中的执行方式，例如 ACT 的时间聚合或 DynamicVLA 的流式执行。表 S7 的附加延迟扫描在实时协议下于推理之后加入 0、50、100、150 或 200 ms，期间物理继续推进。ACT 与 Diffusion Policy 的原生延迟 rollout 在 RTX 5090 上运行，其余 rollout 在 RTX PRO 6000 上运行；所有 rollout 都回放在 RTX 5090 上实测的延迟，因此 rollout 的硬件不影响结果。

延迟测量。 我们在一块 RTX 5090（32 GB，即我们机器人所用的 GPU）上独占运行、以 batch 1 为所有方法计时。每个方法进行三轮，每轮三十次预热调用与 300 次测量调用，覆盖三段各八帧的观测序列；调用边界处做 CUDA 同步，方法顺序轮换，精度沿用其发布版本，SE(3)-WAM 使用 FP32。一次计时查询从最新观测开始（历史已维护好），到其第一条指令可用时结束；它包含所有需要最新帧的计算：预处理、图像编码、PUMA 与 DynamicWAM 的在线光流更新与运动描述子、采样与动作解码，在真机上还包括跟踪。对 SE(3)-WAM，我们另外测量预测头的耗时，尽管部署时跳过它们。这一出动作时间不取整报告；交接时刻 $\ell_t = k_t\Delta_a$ 把它向上取整到控制周期，一条指令的动作年龄是其执行时刻减去采集时刻。出动作时间超过 50 ms 的查询称为超时。附录 C.2 报告实测值。

B.4 指标与统计

按任务等权的成功率为

$$\mathrm{SR}(m) = \frac{100}{14}\sum_{k=1}^{14}\frac{1}{S_m n_k}\sum_{s=1}^{S_m}\sum_{i=1}^{n_k} y_{mski}, \tag{S4}$$

其中 y_{mski} 是以种子 s 训练的方法 m 在任务 k 的场景 i 上的二值结果；本文各变体 $S_m = 3$，基线 $S_m = 1$。首次接触时的位置误差 e_p 是首次接触时末端到专家在目标上的接触坐标系的距离。两个放置任务开始时物体已被抓住，其接触是所持物体与容器的接触，接触坐标系是专家放置时的末端位姿。e_p 在有接触的 13 个任务（不含 `t3_phase`）及发生接触的回合上平均；没有接触的失败仍计入 SR 的分母。

训练种子与区间。 完整模型与五个消融对照使用训练种子 0、1 与 2，每个基线使用种子 0。我们报告每个训练种子以及跨种子的均值与标准差（附录 C.4），对消融还在去掉纯相位导线穿越（`t3_phase`）后重复比较。对于配对 95% 区间，我们对每个场景的各种子取平均，并在每个任务内、跨方法联合地对留出场景做自助法。这些区间刻画给定训练权重下的场景不确定性；区间落在 ±2 个百分点以内的差异视为持平。

B.5 基线与消融对照

共同条件。 每个基线保留其官方架构、动作块长度、初始化与训练配方（表 S4），以种子 0 在相同的 11,200 条示范上训练一次，示范中的指令通过同一个笛卡尔控制器映射到其动作空间，配置在开发场景上选择。所有方法共用主视角相机，并接收表 1 所列的其他输入；配方需要腕部视角的方法接收被屏蔽或填黑的腕部输入。

表 S4. **基线训练。**所有方法均在相同的 11,200 条示范上按各自的官方配方训练，并在附录 B.3 的共享执行器下运行。更新数 × batch：训练量。H：每个返回动作块中的指令数。参数量：可训练参数，不含冻结的编码器。DOM 检查点：DynamicVLA 发布的、在 DOM 上训练的检查点。OpenWAM-α 联合生成视频与动作，但不解码视频。

方法	初始化	更新数 ×batch	H	参数量
ACT [59]	从头训练	50,000 × 32	100	[X]
DP [12]	从头训练	50,000 × 32	8	[X]
$\pi_{0.5}$ [5]	`pi05_base`	30,000 × 256	10	[X]
$\pi_{0.5}$+SE(3)	`pi05_base`	30,000 × 256	10	[X]
DynamicVLA [47]	DOM 检查点	50,000 × 44	20	[X]
PUMA [14]	官方	[X]×[X]	[X]	[X]
OpenWAM-α [43]	官方	34,490 × 192	32	[X]
DynamicWAM [28]	官方	40,000 × 128	16	[X]
DynamicWAM+SE(3)	官方	40,000 × 128	16	[X]
SE(3)-WAM	从头训练	51,740 × 512	8	523.8M

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.2 的八个目标状态 token，带有相同的有效标志与掩码。一个两层 MLP 把这些 token 映射到模型宽度。对 $\pi_{0.5}$，我们把它们附加在前缀中的图像 token 之后，动作专家会读取它们；对 DynamicWAM，它们并入其运动学描述。MLP 的输出层零初始化，训练沿用基础模型的配方。

消融对照。 第 4.3 节的五个对照各改变表 S2 配置中的一个组件，数据、配方、更新预算、执行器以及训练种子 0、1 与 2 保持不变。*无目标历史*去掉目标状态 token 的槽位 0–6，即过去的位姿及其速度与加速度特征，保留存放当前位姿的槽位 7（附录 A.2）。*无未来监督*去掉 $\mathcal{L}_P$、$\mathcal{L}_F$ 与三个未来外观损失及其预测头，保留对当前目标区域的重建。*无场景流监督*去掉 $\mathcal{L}_F$ 与流读出，*无专用 SE(3)* 去掉 $\mathcal{L}_P$ 与位姿头；两者都保留目标状态 token 与全部外观目标。*统一精度预测*以 [冻结视频 VAE 在相同时域上对整帧未来隐变量的预测、其读出方式与损失权重] 取代 $\mathcal{L}_P$ 与 $\mathcal{L}_F$。由于所有预测头在部署时都被跳过，只有无目标历史对照改变推理时的输入。

C 补充仿真结果

C.1 各任务结果

表 S5 把表 1 中 Dynamic-14 留出结果按任务分解到每个方法，并给出 SE(3)-WAM 相对每个任务上最强其他方法的配对区间；最后两行给出首次接触时的位置误差 e_p 与发生接触的回合数（附录 B.4）。在原生 100 步 DDPM 采样下，Diffusion Policy 的每个动作块到达时都已过期，因此它的指令一条也没有执行。[所有方法都失败或基线优于 SE(3)-WAM 的任务，以及 SE(3)-WAM 的主要失败模式。]

C.2 评测协议与延迟

表 S6 在另外三种协议下评估每个方法。暂停物理显示不计计算代价时相对表现如何变化；等延迟在 SE(3)-WAM 的 p95 延迟下比较所有方法；原执行方式检验共享执行器是否去掉了某个基线所依赖的能力。在暂停协议下，SE(3)-WAM 与 [名称] 的差为 [±X.X] 个百分点，在等延迟协议下为 [±X.X] 个百分点。原执行方式使各基线的 SR 至多改变 [X.X] 个百分点。表 S7 列出各附加延迟下已有的成功率与待测项。图 4 直接读取该表，展示全部已有测量的方法，保留零成功率。

表 S5. **Dynamic-14 各任务的留出成功率**（%），涵盖表 1 中的全部方法，本文各变体取三个训练种子的平均、基线训练一次，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。OWAM：OpenWAM-α。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。σ：使用标称合成相关位姿噪声的 SE(3)-WAM（附录 C.5）。Δ：该任务上 SE(3)-WAM 相对最强其他方法之差及其 95% 配对区间。最后两行为首次接触时的位置误差 e_p（mm，在有接触的 13 个任务上平均）与发生接触的回合数 n（附录 B.4）；–：无 13 任务均值。任务代号见表 S3。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	OWAM	DWAM	DWAM+	σ	本文	Δ [95% CI]
谐波抓取	**48.0**	0.0	—	—	—	—	—	—	—	—	—	—
传送带抓取	**46.0**	0.0	—	—	—	—	—	—	—	—	—	—
平移抓取	**18.0**	0.0	—	—	—	—	—	—	—	—	—	—
旋转抓取	**21.0**	0.0	—	—	—	—	—	—	—	—	—	—
遮挡抓取	**32.0**	0.0	—	—	—	—	—	—	—	—	—	—
移动容器	**26.0**	0.0	—	—	—	—	—	—	—	—	—	—
旋转容器	**0.0**	**0.0**	—	—	—	—	—	—	—	—	—	—
导线穿越	**99.0**	0.0	—	—	—	—	—	—	—	—	—	—
导线穿越（完整）	**0.0**	**0.0**	—	—	—	—	—	—	—	—	—	—
小球捕获	**36.0**	0.0	—	—	—	—	—	—	—	—	—	—
小球捕获（桌面）	**71.0**	0.0	—	—	—	—	—	—	—	—	—	—
滑块捕获	**57.0**	0.0	—	—	—	—	—	—	—	—	—	—
罐体捕获	**90.0**	0.0	—	—	—	—	—	—	—	—	—	—
撞击后抓取	**44.0**	0.0	—	—	—	—	—	—	—	—	—	—
任务等权	**42.0**	0.0	—	—	—	—	—	—	—	—	—	—
e_p (mm)	32.2	–	—	—	—	—	—	—	—	—	—	–
n	1109	6	—	—	—	—	—	—	—	—	—	–

计时。 表 S8 按阶段分解 SE(3)-WAM 在一块 RTX 5090 上的出动作时间，测量方式见附录 B.3；表 1 给出每个方法的 p95 延迟，表 S4 给出参数量。在真机上，我们报告动作年龄的 p50、p95 与最大值，测试试验全部查询中超过 50 ms 截止时间的比例，以及峰值显存。

C.3 DOMINO 上的结果

在 DOMINO [14] 上，我们在其 clean 一级设置的 24 个单臂 Franka 任务上比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA。所有方法使用该基准的示范、场景与原生评测器，各训练一个种子，每个任务与方法评测 50 个回合。我们报告 SR 与操作得分（MS）；MS 用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度（表 2）。SE(3)-WAM 使用该领域的归一化，并读取指令所指目标在仿真器中的位姿；没有有效位姿的槽位按附录 A.2 的方式掩码。基于 RGB 的基线不接收这一位姿。[概括 DOMINO 结果。]

C.4 最终消融与种子稳定性

表 S10 按训练种子报告第 4.3 节的五个对照（附录 B.5），并给出跨种子的均值与标准差，以及原生延迟和附加 150 ms 延迟下相对完整模型的配对差值。最后两列在去掉纯相位导线穿越（`t3_phase`）后重复这些配对差值。在开发场景上，同一配置的三个训练种子之间 SR 最多相差 [7.4] 个百分点，主要来自该任务，其成功率在各种子间从 [0] 到 [71]% 不等（附录 B.4）。图 5 的两个任务组列于附录 B.1。[第 4.3 节的结论是否在某个种子上或去掉 `t3_phase` 后改变。]

表 S6. **评测协议对照**：Dynamic-14 留出场景（SR，%），协议定义见附录 B.3；实时即表 1 的协议。超时：实时协议下出动作时间超过 50 ms 控制周期的查询比例（%）。年龄：实时协议下动作年龄的 p95（ms）；–：没有执行任何指令。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

方法	暂停	等延迟	原执行执行器	实时	超时 (%)	年龄 p95
ACT	**40.9**	—	—	**42.0**	**0.0**	50
Diffusion Policy	33.1	—	—	0.0	100.0	–
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM	—	—	–	—	—	—

表 S7. **成功率随附加延迟的变化**：Dynamic-14 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的原生与 +150 ms 列。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

	附加延迟（ms）				
方法	0	50	100	150	200
ACT	**42.0**	—	—	**24.1**	—
Diffusion Policy	0.0	—	—	0.0	—
$\pi_{0.5}$	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—
DynamicVLA	—	—	—	—	—
PUMA	—	—	—	—	—
OpenWAM-α	—	—	—	—	—
DynamicWAM	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—

表 S8. **单次查询的延迟分解**（SE(3)-WAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
图像编码	—	—
世界流（每次查询一次）	—	—
动作流（5 个 Euler 步）	—	—
出动作时间（合计）	—	—
预测头（仅训练，供参考）	—	—
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

表 S9. **离线预测误差。**在同一批留出观测上计算 400 ms 处的目标位置误差（mm）。CV 和 CA 是由因果位姿历史计算的解析外推；学习位姿头读取冻结完整模型的状态。

	匀速	谐波	滚动/滑动	撞击
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的位姿头	—	—	—	—

表 S10. **按训练种子列出的最终消融**（Dynamic-14 留出场景；附录 C.4）。S0–S2：训练种子 0–2 的 SR（%）；均值 ± 标准差为跨种子统计；Δ：对照减 SE(3)-WAM （百分点）及其 95% 配对区间。最后两列：去掉纯相位导线穿越（`t3_phase`）后 13 个任务上的 Δ。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。

	原生					+150 ms					Δ 去掉 `t3_phase`	
变体	S0	S1	S2	均值 ± 标准差	Δ [95%]	S0	S1	S2	均值 ± 标准差	Δ [95%]	原生	+150 ms
SE(3)-WAM ⋆	—	—	—	—	–	—	—	—	—	–	–	–
无目标历史	—	—	—	—	—	—	—	—	—	—	—	—
无未来监督	—	—	—	—	—	—	—	—	—	—	—	—
无场景流监督	—	—	—	—	—	—	—	—	—	—	—	—
无专用 SE(3)	—	—	—	—	—	—	—	—	—	—	—	—
统一精度预测	—	—	—	—	—	—	—	—	—	—	—	—

C.5 对位姿噪声的鲁棒性

在权重冻结的条件下，我们评估三种对目标位姿的合成扰动：标称的时序相关噪声、两倍幅度的噪声，以及带连续缺失观测的标称噪声。标称过程由每回合固定的偏置与平稳相关分量组成，二者每轴的标准差均为 5 mm 与 1°，相关时间为 200 ms。缺失持续 200 ms，其间隔服从均值为 3.8 s 的几何分布，长期缺失比例为 5%。扰动作用于当前与过去的估计，在计算历史特征之前施加。

图 S1 在这些扰动下评估最终模型，使用相同的留出场景、零附加延迟与全部三个训练种子。相对干净位姿，在标称相关噪声、两倍幅度噪声与缺失观测下，SR 分别变化 [X.X]、[X.X] 与 [X.X] 个百分点。

图占位：图 S1——位姿噪声

横轴：干净位姿、标称相关噪声、两倍幅度噪声、带缺失观测的标称噪声；纵轴：SE(3)-WAM 在各任务族上的 SR，冻结权重，实时协议；匹配场景上的配对区间。

图 S1. **对位姿噪声的鲁棒性。**在目标位姿的合成扰动下 SE(3)-WAM 的 SR，相对干净位姿。

C.6 预测诊断

表 S9 离线比较最终模型学到的 SE(3) 预测与由同一位姿历史得到的匀速和匀加速外推。

图占位：图 S2——真机装置

(a) 左：共用平台的照片，从机器人后方拍摄，装有一个任务装置：第三人称 RGB-D 相机、机器人，以及基线使用的腕部相机（若有），逐一标注。**(b) 右：六个按比例的小幅俯视示意图，每个任务一幅（T1–T6）**：机器人基座坐标系及其坐标轴，相机位置与朝向，所装装置及其占地范围，目标的起始或释放区域及其运动方向的范围，抓取区域，以及以 cm 标注的关键尺寸。**规则**：真实照片不做修饰；示意图依据标定的外参与实测的装置位置；不重复图 6 中的任务照片。

图 S2. **真机装置**。(a) 共用平台。(b) 各任务的俯视布局：装置、目标的起始或释放区域与运动方向，以及抓取区域。

表 S11. **真机任务**。目标：被跟踪的物体。试验键：20 个测试键各自固定的内容。速度：由全部测试试验录制的 RGB-D 测得的目标速度（m/s，均值 ± 标准差）。抓取指物体被两指夹持。每个任务有 100 条训练示范与 20 条验证示范。

任务	目标	运动；试验键	速度	成功条件	时限（s）
T1	方块	传送带；[在带上的放置、带速]	—	抓住方块并抬起 [X] cm。	[X]
T2	无盖盒	传送带；[盒子的放置、带速]；方块开始时在夹爪中	—	将方块释放进盒中；方块留在盒内 [直到盒子离开工作空间]。	[X]
T3	边长不等的方块	转盘；[半径、方块的初始角度与偏航、角速度]	—	沿短边抓住方块并抬起 [X] cm。	[X]
T4	玩具小车	以固定油门遥控行驶；[起始位姿、航向]	—	抓住小车并抬起 [X] cm。	[X]
T5	网球	[球的运动机制、释放位置与运动设定]	—	抓住网球并抬起 [X] cm。	[X]
T6	小车上的方块	小车沿倾斜轨道下行；[坡度、释放点]	—	抓住方块并抬起 [X] cm。	[X]

D 真机实验

D.1 平台与任务

机器人为 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机，通过 [带时间戳的笛卡尔接口] 以 [控制频率] 控制。相机以 [分辨率] 与 [帧率] 录制 RGB-D，每次采集前用 [标定方法] 标定其外参。SE(3)-WAM 使用这一固定的第三人称视角；配方使用腕部视角的基线另外获得 [腕部相机]。所有策略都在一块 RTX 5090 上运行。各任务装置共用这一平台，按任务轮流安装，每次只装一个（图 S2）。表 S11 定义各任务。T3 转盘上的目标是边长不等的方块，必须沿短边抓取，因此接触时其朝向起作用；T4 的玩具小车以固定油门运行。

D.2 位姿跟踪与标签

在线跟踪。 跟踪不使用标记。每个物体实例有一个米制网格，其原点与坐标轴固定，由 [参考采集] 一次准备，并为全部示范与试验共用；球由其球心与半径定义。在第一帧中，Grounding DINO [25] 定位任务所指的物体，SAM 2.1 [32] 将其分割，FoundationPose [44] 在网格上注册其位姿。此后，Cutie [11] 在每一帧中传播掩码，一个 6D Kalman 滤波器预测位姿；其位置由掩码包围框的中心与掩码内的深度中位数校正，FoundationPose 的一步精化再把校正后的位姿变为该帧的估计，并作为滤波器的下一次测量。我们以 FP16 运行 FoundationPose 的 TensorRT 实现，并使用 CUDA Graph。掩码为空时估计记为无效，不沿用上一帧的位姿；[丢失后的重新初始化]。

表 S12. **真机上的跟踪。**按任务统计 SE(3)-WAM 的测试试验：控制周期边界数、估计无效的比例、最长缺失时长，以及重新初始化次数。

任务	边界数	无效（%）	最长缺失（s）	重新初始化
T1	—	—	—	—
T2	—	—	—	—
T3	—	—	—	—
T4	—	—	—	—
T5	—	—	—	—
T6	—	—	—	—

表 S13. **真机成功与失败。**上半部分：每个任务的成功次数（共 20 次试验；任务见表 S11）；All：合并成功率（%）及 95% Wilson 区间；Δ：相对 SE(3)-WAM 的配对差值（百分点）及按试验键自助法得到的区间。下半部分：每个方法全部 120 次试验中各类失败的次数（附录 D.4）；–：不适用。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。

方法	T1	T2	T3	T4	T5	T6	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	–

	跟踪丢失	过晚	未对准	滑落/掉落	碰撞/中止	超时	失败合计
$\pi_{0.5}$	–	—	—	—	—	—	—
DynamicWAM	–	—	—	—	—	—	—
Diffusion Policy	–	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—

时序。 跟踪器按控制时钟运行。在每个控制周期边界上，它用该边界时刻或之前最新采集的帧更新位姿，因此每个估计最多早于边界一个相机帧周期，并保留其帧的采集时刻；目标状态 token 中的速度与加速度按这些采集时刻做有限差分。每次查询等待其所在边界的位姿更新，再在同一块 GPU 上运行策略。当一次查询跨越后续边界时，跟踪器以更高的 GPU 优先级继续更新，并且只处理最新一帧，使更新不会积压在较旧的帧之后。跟踪耗时与这一争用都计入实测延迟（表 S8）。

示范标签。 示范的目标状态输入，是同一跟踪器在控制周期边界上对其录制 RGB-D 的因果回放。预测的位姿标签是同一物体坐标系下未来边界处的跟踪位姿，[并在整段示范上离线精化]；流标签来自[录制 RGB-D 的三维点轨迹，与 DROID 相同（附录 A.4）]。对于球类目标，目标状态 token 保留球心的平移、速度与加速度，屏蔽其朝向与角运动，位姿头只监督平移。表 S12 报告测试试验中跟踪丢失的情况。

D.3 训练与评测协议

训练。 SE(3)-WAM 从 DROID 基座出发逐任务微调（附录 A.4）。$\pi_{0.5}$、DynamicWAM 与 Diffusion Policy [12] 在相同示范上训练或微调，初始化、训练配方与动作块长度见表 S4；DynamicWAM [是否使用实时分块执行]。示范、开发试验与测试试验来自不同的采集批次。

试验。 每个任务有 20 个预生成的试验键，固定物体实例、其初始位姿与装置设定（表 S11）。试验按键分块：对每个键，四个方法以随机顺序连续运行，使装置的漂移不会与方法对齐。操作员参照相机的参考图像，将场景重置到该键。试验从第一个可用观测开始，机器人随时可以运动；试验在成功、

图占位：图 S3——SE(3)-WAM 的失败案例

版式：通栏，两行，分别对应表 S13 中 SE(3)-WAM 最常见的两类失败（例如过晚、滑落或掉落）；每行四个等宽的 16:9 子图。**每行子图：**查询帧、其动作块首次执行时、接触或最接近时，以及试验结束时，每格标注取自试验日志的采集后时间（ms）；叠加：蓝色为跟踪得到的过去位姿，紫色为指令的夹爪路径；每行上方标注任务、试验键与失败类别。**规则：**真实照片不做修饰；叠加来自所示试验的日志数据；图注只描述可观察的事件。

图 S3. **SE(3)-WAM 在真机上的失败案例：**[类别、任务与观察到的事件]（上）与 [类别、任务与观察到的事件]（下）。

失败、安全中止或时限到达时结束，时限约为该任务示范时长中位数的三倍。只有装置自身偏离试验键时（[实测速度超出设定的 ±X%，或装置故障]），才用同一个键重做；其余情况都计为失败，包括 SE(3)-WAM 的跟踪丢失与安全中止。

统计。 我们报告每个任务的成功次数，以及合并成功率及其 95% Wilson 区间；每个任务都是 20 次试验，因此合并成功率等于任务均衡的成功率。相对 SE(3)-WAM 的配对差值在每个任务内按试验键自助重采样。我们在同一块 RTX 5090 上记录每个方法每次查询的端到端出动作时间，SE(3)-WAM 包含跟踪；表 3 报告其 p95，表 S8 给出真机上的计时。

D.4 详细结果与失败

表 S13 报告每个任务的成功次数、区间与配对差值，以及各方法按类别统计的失败次数。这些类别在测试试验前确定，都是可观察的事件：跟踪丢失（仅 SE(3)-WAM ）、过晚（夹爪在目标后方合拢）、抓取未对准、接触后滑落或掉落、碰撞或安全中止，以及超时。[优势最大的任务及其失败类别；真机计时；SE(3)-WAM 最常见的失败，图 S3。]

E 设计研究

我们用宽度 768 的四层模型研究历史输入、未来监督与世界—动作接口，以全局 batch 16 训练四轮（40,104 次更新）。早期同步执行器每次查询执行一条指令，在 1,400 个开发场景上评测，每任务 100 场；最初的预测筛选将用于选择的 140 场与其余 1,260 场分别报告。各研究的编码器、输入与种子数有所不同，比较均在组内进行。预测路径、辅助监督、接口与编码器研究保留其筛选配方的八帧视觉窗口与目标真值运动历史。最终规模的实时消融另见第 4.3 节与附录 C.4。

E.1 历史表示

什么历史有助于控制？ 在冻结 DINOv3-L 编码器 [35]、一个训练种子的条件下，我们将七种视觉历史编码与仅当前图像、当前图像加目标 SE(3) 历史进行比较（图 S4a）。所有条件均保留当前目标真值位姿与机器人状态历史。视觉编码包含基于光流的方案 [15, 28]。目标历史条件还接收过去的真值位姿及其导出的运动学特征。

目标历史使 SR 从 53.43% 提高到 58.86%，增加 5.43 个百分点，场景配对自助法给出的 95% 区间为 $[3.07, 7.86]$。所测视觉历史的点估计均未超过当前图像参照。历史特征更容易读出，并不必然改善控

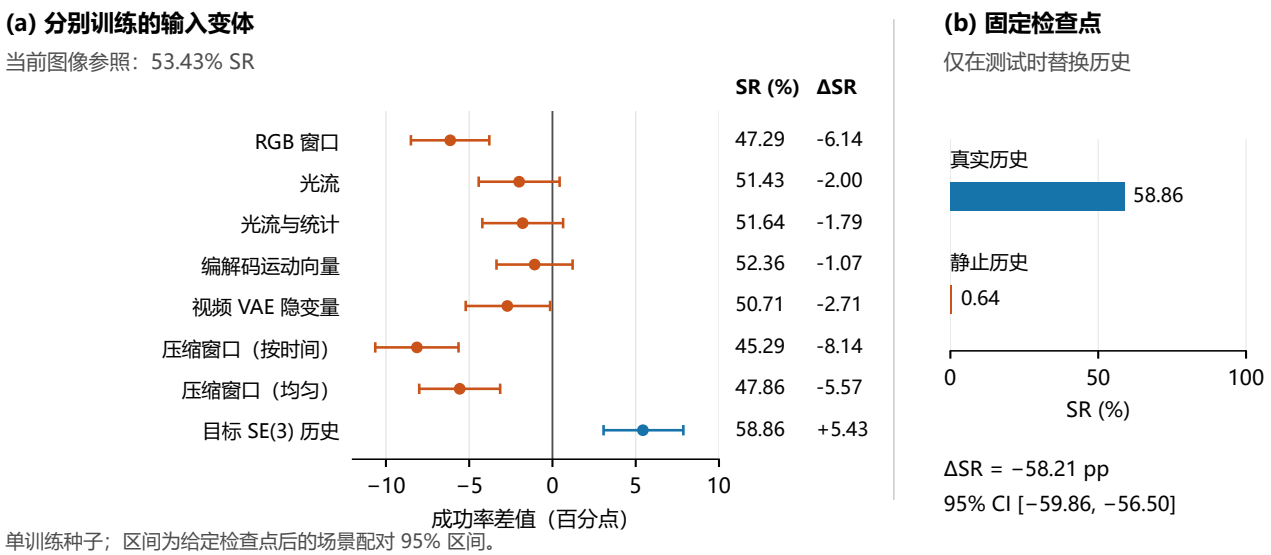


图 S4. **历史输入与测试时干预。**冻结 DINOv3-L，一个训练种子，1,400 个开发场景。所有条件均保留当前目标真值位姿与机器人历史。(a) 分别训练的输入变体：SR 及其相对当前图像参照的差值。横线为给定训练检查点后的逐项场景配对 95% 自助法区间，未作多重比较校正。(b) 在同一检查点替换历史：1,400 场中成功次数由 824 变为 9。这衡量对错误历史的敏感性，与 (a) 的训练收益分开解释。

制：使用 RGB 窗口时，摘要表示的冻结线性探针将过去 350 ms 位置的读出误差从 10.89 降至 8.46 mm，而 SR 下降 6.14 个百分点。这些结果支持在该训练配方下保留显式目标运动信息。

训练好的策略是否使用历史？ 我们固定目标历史模型的检查点，将过去目标位姿替换为当前位姿，再重新计算运动学特征。当前位姿、图像、机器人状态与时间戳保持不变。SR 从 58.86% 降至 0.64%（图 S4b），210 个诊断窗口的首条执行动作全部改变；恒等替换则复现原始动作。下降衡量对错误历史的敏感性；训练收益由前述 5.43 个百分点的比较衡量。区间刻画给定这些单种子检查点后的场景变化。

E.2 未来表示与监督

初始目标筛选。 在冻结 DINOv3-L、种子 0 下，我们比较十五种预测配置（表 S14）。几何目标使用八个未来时域：目标 SE(3)、14 × 14 patch 网格的基座系位移或投影后的二维运动，均相对当前状态。编解码器目标使用当前帧与未来帧的配对；物体 DINO 汇聚目标掩码内的特征。Wan2.2 VAE 目标在时间上压缩九帧片段，并非每个时域各对应一个隐变量。

在其余 1,260 个场景上，P07 与 P09 的点估计最高，分别为 64.05% 和 64.13%；无未来监督的 P00 为 62.78%，场景流加 SE(3) 的 P03 为 62.38%。配对比较未确立 P07 或 P09 的总体优势。稠密二维位移（P05）相对 P00 降低 3.57 个百分点（27 项比较的 Bonferroni 校正后 $p = 0.00844$）。这些条件比较的是完整预测配置：P07 从共享特征直接回归，P03 则使用主干内独立的 Future 流与流匹配。因此，二者的差异需要进一步分开考察表示与预测路径。

区分表示与预测路径。 我们将二维、三维目标与直接回归、Future 流的流匹配实现交叉比较，固定可训练 CNN、SE(3) 监督、当前目标 RGB 重建与历史输入，每个条件训练三个种子（图 S5a）。两种坐标表示使用相同源点与时域，尺度由训练标签校准。在二维和三维下，直接预测均在每个种子上取得高于 Future 流实现的 SR。在任一路径内，二维与三维的差值都随种子变号。跨路径还改变了损失、运动加权与可见性监督，因此结果支持的是完整的直接预测配方。

表 S14. **初始预测配置筛选。**冻结 DINOv3-L，种子 0。用于选择的 140 场与其余 1,260 个开发场景互不重叠。按所改变的目标分组；预测路径也有差异，见附录 E.2。破折号表示该目标未启用。各结果列中，粗体加蓝底与浅蓝底分别标出最佳、次佳点估计，不表示统计显著性。

ID	场景目标	物体目标	附加目标	成功数 / 140	SR_{1260} (%)
基础监督对照					
P00	–	–	–	88	62.78
P01	三维场景流	–	–	**95**	62.06
P02	–	SE(3)	–	92	62.62
P03	三维场景流	SE(3)	–	93	62.38
相对 P03 更换场景目标					
P04	视频 VAE 隐变量	SE(3)	–	92	62.14
P05	稠密二维位移	SE(3)	–	87	59.21
P06	编解码器运动向量	SE(3)	–	86	63.10
P07	稀疏二维轨迹	SE(3)	–	90	64.05
相对 P03 更换物体目标					
P08	三维场景流	物体 DINO	–	89	63.02
P09	三维场景流	目标二维轨迹	–	88	**64.13**
在 P03 上增加目标					
A_α	三维场景流	SE(3)	运动幅值	89	61.75
P12	三维场景流	SE(3)	深度	90	62.78
P13	三维场景流	SE(3)	DINO	92	62.54
P14	三维场景流	SE(3)	动态 RGB	89	62.70
P15	三维场景流	SE(3)	深度、DINO、动态 RGB	94	63.65

进一步的比较固定直接路径、冻结 DINOv3-L 与三项未来外观目标（图 S5b）。二维减三维的逐种子差值为 $+2.00$、-1.50 和 $+1.00$ 个百分点，均值为 $+0.50$。我们保留三维位移，以在机器人的米制坐标系中表达场景运动；这些开发研究尚未确立三维相对二维的控制性能优势。

辅助监督的选择。 在冻结 MAE-B、种子 1 下，我们保留直接三维场景流、SE(3) 与当前目标 RGB 重建，比较无未来外观目标、各目标单独启用和三者同时启用（表 S15）。单独 DINO 与动态 RGB 高于无辅助参照，单独深度使 SR 下降，三者组合取得最高的 71.07%。单项行衡量该目标加入参照后的效果，不隔离另两项已开启时该项的边际贡献。这轮筛选支持在 MAE-B 下保留组合。辅助收益依赖编码器：在三种子 CNN 研究中，三项全开平均为 62.86%，全关为 63.95%。第 4.3 节的最终模型无未来对照检验包含几何目标在内的全部预测监督。

E.3 世界—动作信息流

接口与对照。 在冻结 MAE-B、共享注意力与世界 / 动作分设前馈网络的条件下，我们区分已观测条件 C、未来查询隐藏状态 W 和解码预测 Y。动作始终读取 C。一个物体查询和每个 patch 一个查询读取 C 与彼此，预测 SE(3) 和场景流。R1–R4 保持模块、损失与初始化流程相同，切换 $W \to A$ 和 $A \to W$ 两条注意力边（表 S16）。记录结果的联合评测在每个 Euler 步重算 W。R0 保留相同模块，关闭所有未来损失，当前 RGB 重建仍然开启。R5 则在每次查询中解码一次 Y，通过一个 0.37M 参数的几何编码器，将轨迹、流与可见性重新编码为动作条件。训练和推理均使用预测几何，动作梯度沿该接口反传。

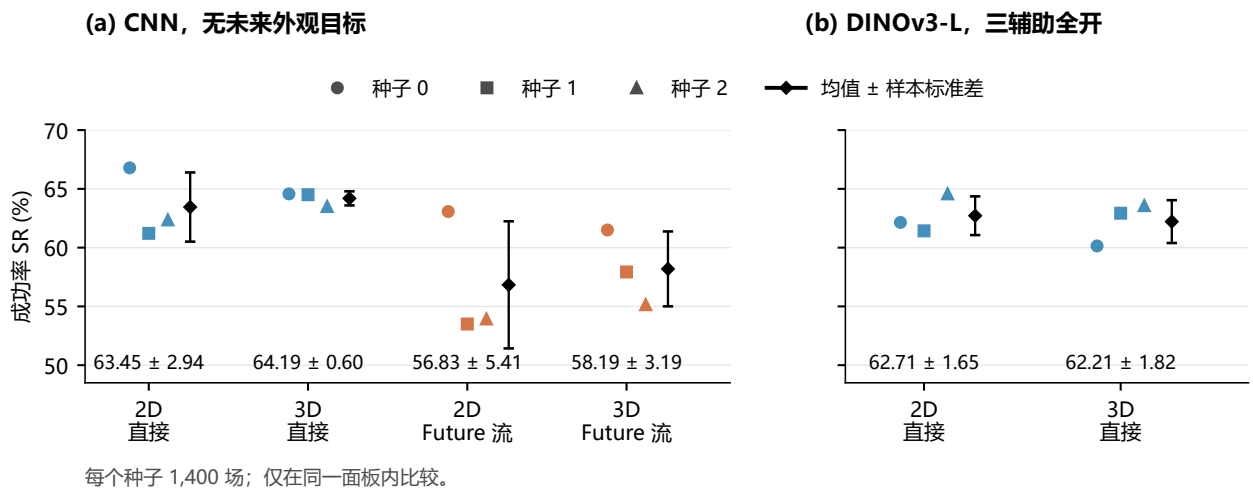


图 S5. **表示与预测路径。**彩色标记表示三个训练种子，每个种子评测 1,400 个开发场景；黑色菱形及误差线表示均值与样本标准差，下方同时列出数值。两面板均保留 SE(3) 与当前目标 RGB 监督。(a) CNN，无未来外观目标：直接回归与 Future 流的流匹配配方。(b) 冻结 DINOv3-L、直接回归、三项外观目标全开。仅在面板内比较；种子间离散程度不是置信区间。

表 S15. **未来外观监督。**冻结 MAE-B，种子 1，1,400 场；直接三维场景流、SE(3) 与当前目标 RGB 重建始终开启。Δ：相对首行的 SR 差值（百分点）。✓ 表示开启，– 表示关闭。粗体加蓝底与浅蓝底分别标出最高、次高 SR 点估计。Δ 底色：蓝色为 SR 更高，橙色为更低，在 15 个百分点处饱和，不表示统计显著性。

深度	DINO	动态 RGB	SR (%)	Δ
–	–	–	63.86	参照
✓	–	–	61.93	−1.93
–	✓	–	67.57	+3.71
–	–	✓	66.14	+2.29
✓	✓	✓	**71.07**	+7.21

表 S16. **世界—动作信息流。**冻结 MAE-B，三个训练种子，各评测 1,400 个开发场景。W：未来查询隐藏状态；A：动作状态；Y：解码几何。动作始终读取已观测条件 C。R1–R4 构成两条边的交叉比较。SR 为种子均值 ± 样本标准差（%）；Δ_{R1} 为同种子相对 R1 差值的均值 ± 样本标准差（百分点）。粗体加蓝底与浅蓝底分别标出最高、次高 SR 点估计。Δ 底色：蓝色为 SR 更高，橙色为更低，在 15 个百分点处饱和，不表示统计显著性。

ID	未来损失	$W \to A$	$A \to W$	$Y \to A$	SR (%)	Δ_{R1}
R0	–	–	–	–	60.45 ± 3.57	−3.14 ± 5.75
R1	✓	–	–	–	63.60 ± 2.34	参照
R2	✓	✓	–	–	62.52 ± 1.97	−1.07 ± 4.28
R3	✓	–	✓	–	**64.21 ± 2.13**	+0.62 ± 0.84
R4	✓	✓	✓	–	63.00 ± 4.19	−0.60 ± 6.52
R5	✓	–	–	✓	63.95 ± 1.91	+0.36 ± 3.45

监督与动作条件。 R1 相对 R0 平均提高 3.14 个百分点，逐种子差值为 −1.29、+9.64 和 +1.07。加入隐藏状态读取（R2）或解码几何（R5）后，相对 R1 的 SR 变化分别为 −1.07 与 +0.36 个百分点，逐种子差值的标准差分别为 4.28 与 3.45 个百分点。两者均未带来跨种子一致收益。R3 均值最高，但相对 R1 的 0.62 个百分点增益在纯相位导线任务之外变为 −0.03 个百分点；主指标始终保留全部十四个任务。两条边的主效应及其交互也随种子变号。

与部署模型的关系。 我们保留未来监督，不增加预测到动作的接口。R1 使用独立未来查询，SE(3)-WAM 从已有场景与摘要 token 直接读出预测（第 3.2 节）。这两种不同结构都只将预测用于监督。在 SE(3)-WAM 中，动作仍然读取已观测的世界表示，预测头则在部署时跳过。

E.4 编码器与参数共享

表 S17. **编码器与参数共享。**三个种子，各评测 1,400 场；直接三维、SE(3) 与全部外观目标。SR 为种子均值 ± 样本标准差（%）。面板 (b) 固定 MAE-B，复用 (a) 的共享注意力结果。参数量仅计可训练主干；⋆ 表示选定配置。各面板和结果列中，粗体加蓝底与浅蓝底分别标出最佳、次佳点估计，不表示统计显著性。

配置	状态 / 参数量	SR (%)
(a) 观测编码器		
CNN	可训练	62.86 ± 2.64
DINOv3 ViT-S/16	冻结	61.69 ± 2.00
DINOv3 ViT-L/16	冻结	62.21 ± 1.82
MAE ViT-B/16⋆	冻结	**66.76 ± 3.84**
(b) 世界 / 动作参数共享		
共享注意力 ⋆	47.266M	**66.76 ± 3.84**
独立参数	47.272M	62.86 ± 2.98

观测编码器。 我们比较可训练 CNN、冻结 DINOv3-S、DINOv3-L [35] 与 MAE-B [17]，保留直接三维预测、SE(3) 与三项外观目标（表 S17a）。各条件训练三个种子，采用相同的 8 卡训练配方与全局 batch。MAE-B 的平均 SR 最高，为 66.76%，被选用于后续接口与主干研究。

参数共享。 固定 MAE-B 后，我们比较共享注意力、分设前馈网络的方案与世界 / 动作注意力及前馈参数各自独立的方案（表 S17b）。二者保持相同信息流与约 47.3M 可训练主干参数；独立参数方案采用较小的前馈宽度以配平参数量。共享注意力的平均 SR 为 66.76%，独立参数为 62.86%。去掉两项导线任务后，平均差距降至 0.39 个百分点，说明差异集中在这两项任务。我们依据这一总体比较保留共享注意力。