SE(3)-WAM：面向动态操作、在指令生效时刻进行的世界—动作建模

中文审读稿

摘要

机器人从传送带上抓取零件时，等到指令真正生效，它所依据的图像已经过去了几百毫秒。反应式策略忽略这段延迟；想象未来画面的世界—动作模型则把容量花在外观上，而且其推理延迟本身又加重了这一问题。我们提出 SE(3)-WAM，一个为其指令生效时刻预测场景的世界—动作模型。它从因果位姿跟踪器编码目标的度量运动，在物理时域上预测目标的 SE(3) 轨迹与场景其余部分的粗粒度 3D 流，并生成以领先时长（从图像采集到指令生效的时间）为条件的指令。预测只在训练中监督模型，部署时只运行动作分支。面向真机，我们在自动提升为度量 4D 标签的 DROID 上预训练基座模型。在实时评测的 14 个仿真动态任务 Dynamic-14 上，SE(3)-WAM 在留出场景中的成功率为 [XX.X]%，最强基线为 [XX.X]%；在真实传送带上，它在 180 次试验中的成功率为 [XX]%，$\pi_{0.5}$ 为 [XX]%。分析表明，目标的度量运动历史比视觉历史更重要，并且在指令生效时刻监督预测，即使测试时不生成预测，也能保留其收益。

1 引言

从传送带上取零件、把物体放进移动的料箱、接住从斜坡滚下的球，这些任务都要求指令在生效的那一刻与场景相符。从图像采集到夹爪闭合，策略要完成推理，指令要在队列中等待，机械臂还要运动。传送带以 0.10 m/s 运行时，零件在 150 ms 的延迟中移动 15 mm，超过了平行夹爪抓取它所能容忍的 [X] mm。从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[10, 31, 42, 49]，大多数视觉运动策略都是为准静态场景开发的，在那里这段延迟几乎无关紧要 [1, 12, 46]，于是它们会在运动目标的后方合拢（图 1）。

近期的动态策略从三个方面应对这一问题。执行方案通过流式输出动作、丢弃过时动作来缩短或掩盖延迟 [6, 36, 46]，但延迟总会残留。基于历史的策略向模型提供堆叠帧、光流或过去的运动学描述 [12, 23, 29]，模型必须从中推断场景如何运动。世界—动作模型预测未来帧、隐变量、深度或语义，并与之一同学习动作 [35, 42, 49, 55]。它们的预测按帧索引，而不是按指令生效的时刻索引；它们以同样的精度建模每一个像素；而且模型的规模本身又加长了它们要弥补的延迟。

我们从交互的需求出发。抓取或放置能否成功，取决于指令生效那一刻目标的位姿，误差要在几毫米以内；场景的其余部分只通过它留下的间隙起作用。因此，一条指令的误差随目标速度乘以领先时长增长，而旋转误差随目标原点到接触点的距离放大。由此得到三个设计选择：策略应当记住目标的度量运动而不是其外观，精确预测目标的 SE(3) 轨迹、只粗略预测场景其余部分，并依据按生效时刻索引的预测与指令行动。

我们基于这些选择构建 SE(3)-WAM（图 2）。一个 Transformer 编码当前 RGB-D 帧、机器人状态以及因果位姿跟踪器给出的目标 SE(3) 历史。世界分支在物理时域上预测目标的 SE(3) 轨迹与粗粒度 3D 场景流，动作分支生成以领先时长为条件的指令。世界分支在训练中塑造共享表示，部署时只运行动

图占位：图 1 首图——在指令生效时刻预测场景（真机）

版式：通栏，左右两部分。**(a) 左侧约 62%**：传送带抓取在发出动作块瞬间的一帧真机图像。按论文语义配色叠加：蓝色为因果跟踪器给出的目标过去 SE(3) 位姿（$-350 \ldots 0$ ms 的小坐标轴，越旧越淡）；橙色为各指令生效时刻的目标 SE(3) 坐标轴，首个生效时刻 τ^{a} 处加粗，取自离线运行的训练期世界头；浅橙色箭头为仅在14×14 网格上的环境粗粒度 3D 流；紫色为在 τ^{a} 与目标相遇的夹爪指令轨迹。灰色虚影标出采集时刻观测到的位姿，红色虚线箭头示意反应式策略会在何处合拢。图像下方一条细时间轴：采集 $\tau_t \rightarrow$ 延迟 $\ell_t \rightarrow$ 生效 τ^{a}。**(b) 右侧约 38%**：上：“图像空间 WAM：未来帧或隐变量”（胶片图标）；中：“SE(3)-WAM：目标用 SE(3)，环境用 3D 流，按生效时刻索引”（坐标轴 + 稀疏箭头）；下（**必需**）：SE(3)-WAM 与最强基线的成功率随附加延迟（0–200 ms）的变化（数据：附录 E.2 的延迟扫描）。**要求**：真实照片不修饰；叠加内容取自该次试验记录的跟踪、预测与指令数据；图注写明该次试验结果。

图 1. **在指令生效时刻预测场景。**从图像采集到第一条指令之间，传送带上的零件移动的距离超过抓取所能容忍的范围。SE(3)-WAM 编码目标的度量运动（蓝），并被训练去预测目标在每条指令生效时刻的 SE(3) 位姿以及周围场景的粗粒度 3D 流（橙，只在训练中预测），使其指令在该处与目标相遇（紫）。图像空间的世界—动作模型预测的则是外观。右：Dynamic-14 上成功率随附加延迟的变化。

作分支，从而保持策略快速。面向真机，我们用现成的感知模型 [17, 18, 32] 把 DROID [20] 提升为度量 4D 标签，并在其上预训练基座模型。

我们在 Dynamic-14 、DOMINO [12]、LIBERO [25] 以及真实传送带上评估 SE(3)-WAM 。Dynamic-14 包含 14 个仿真任务，涉及运动的目标、料箱、障碍物与撞击。评测采用实时协议：每个方法计算期间场景持续运动。SE(3)-WAM 在 Dynamic-14 留出场景上的成功率达到 [XX.X]%，比最强基线高 [X.X] 个百分点，在 DOMINO 上提升 [X.X] 个百分点，并在静态的 LIBERO 任务上与强策略保持接近。在传送带上，它的试验成功率为 [XX]%，$\pi_{0.5}$ 为 [XX]%，且优势随带速增大。受控比较表明，一旦领先时长超过未补偿运动的抓取所能容忍的范围，目标的 SE(3) 历史就会带来收益，而 RGB、光流与视频隐变量历史几乎没有帮助；SE(3) 目标预测加粗粒度流与图像空间预测同样有用，而训练代价只是其一小部分。只要预测在指令生效时刻受到监督，即使测试时不生成预测，其大部分收益仍然保留，这与 Fast-WAM [51] 在静态场景中的发现一致。总之，我们的贡献是：

- SE(3)-WAM ，一个在指令生效时刻预测目标 SE(3) 轨迹与粗粒度 3D 场景流、并生成以领先时长为条件的动作的世界—动作模型，以及在带有提升 4D 标签的 DROID 上预训练的真机基座；
- 带实时协议的 Dynamic-14 ，SE(3)-WAM 在其上优于反应式、动态与世界—动作策略；我们将连同 DROID 标签与代码一起发布；
- 对动态策略需要记住什么、预测什么、测试时读取什么的受控分析。

2 相关工作

动态操作。 用预测补偿延迟在控制 [34] 与预测跟踪 [3] 中由来已久。机器人接物与手眼系统通常用卡尔曼类滤波器从视觉估计物体轨迹 [4]，并实施拦截 [2, 5, 15]。视觉伺服在图像特征上闭环 [19]，动态抓取把运动预测与可达性结合起来 [1]。在学习型策略中，DOMINO 提出了动态基准以及 PUMA；PUMA 读取历史光流，并以未来物体特征作为监督 [12]。DynamicVLA 流式输出动作并丢弃过时动作 [46]，DynamicWAM 以光流和运动学描述作为 WAM 的条件 [29]，其他工作预测显著的未来 token [35] 或事件时刻 [56]。若干近期预印本用运动感知的世界模型、速度场或合成的动态示范探索相关思路 [9, 22, 52]。在执行方面，实时分块在延迟下保持控制平滑 [6]，VLASH 把机器人状态前推到执行时刻 [36]，同期的 Chronos Policy 以观测与执行时间戳为条件 [39]。SE(3)-WAM 与后两者一样使用执行时刻，但它还为该时刻预测场景，并以度量方式表示目标的运动，而不是从像素中推断。

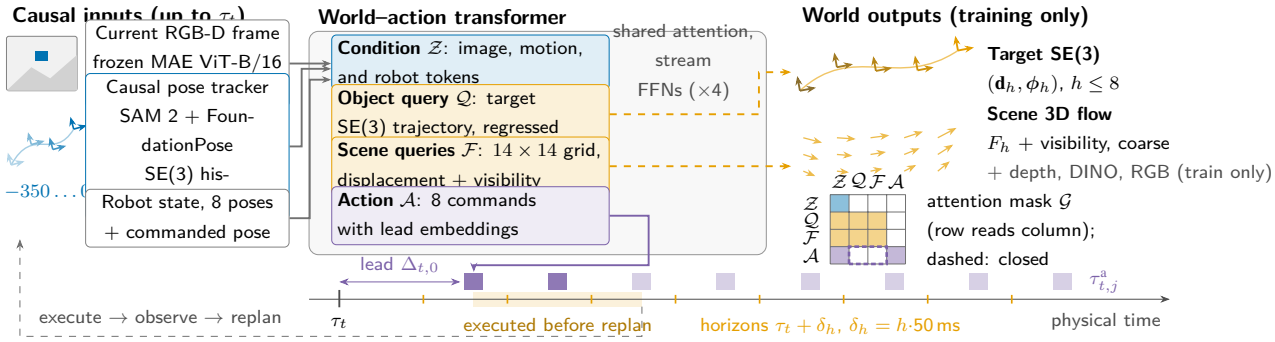


图 2. **SE(3)-WAM** 。条件 token $\mathcal{Z}$ 编码当前 RGB-D 帧、因果跟踪器给出的目标 SE(3) 历史以及机器人状态。物体查询 $\mathcal{Q}$ 与场景查询 $\mathcal{F}$ 在物理时域 $\tau_t + \delta_h$ 上回归目标的 SE(3) 轨迹以及带可见性的粗粒度 3D 场景流，外观读出头提供额外的训练目标。动作 token $\mathcal{A}$ 生成以领先时长为条件、在 $\tau^{\mathrm{a}}_{t,j}$ 生效的指令，每 100 ms 重规划一次。掩码 $\mathcal{G}$ 规定每个组读取哪些组。动作 token 不读取任何世界 token，因此部署时只运行动作分支。

世界—动作模型。 WAM 通过预测特征 [16]、视觉子目标 [57] 或视频—动作联合生成 [21, 42, 49, 60] 把未来预测与动作生成结合起来。DreamVLA 借助分块注意力预测动态区域、深度与语义特征 [55]，其他工作为预测加入更多监督 [50] 或压缩长历史 [27]。Fast-WAM 发现，在其静态任务上可以跳过测试时想象而不损失性能 [51]。这些模型在图像或隐空间中预测，并按帧索引未来。SE(3)-WAM 在与指令领先时长对应的物理时域上预测度量的物体级状态，而且我们发现在动态场景中，预测的收益同样可以在没有测试时想象的情况下保留。

结构化的 3D 与 4D 运动。 刚体结构早已用于学习型动力学模型与场景流 [7, 8, 37, 48]，3D 点跟踪在空间中追踪像素 [45]。点轨迹与 3D 流曾被用作策略接口 [44, 47, 59]，点云被用作策略输入 [53]，物体位姿被用作世界模型与策略的结构 [11, 28]。PointWorld 大规模预测以动作为条件的 3D 点流 [17]，前馈模型重建场景几何 [40] 与动态点轨迹 [54]。我们只对目标使用刚体结构，把场景其余部分保留为粗粒度 3D 流，二者都按指令生效时刻索引。

3 SE(3)-WAM

SE(3)-WAM（图 2）是一个包含三组 token 的 Transformer：条件 token 编码当前观测与目标的运动历史，世界查询在物理时域上预测场景，动作 token 生成以领先时长为条件的指令。我们以确定性方式预测世界，用流匹配生成动作 [24]。下面先说明促成这一设计的问题设定。

3.1 在物理时间中行动

生效时刻。 我们考虑一个连同采集时刻一起接收图像与机器人状态的策略。在查询 t，其历史为 $\mathcal{H}_t = \{(o_i, s_i, \tau_i)\}_{\tau_i \le \tau_t}$，输出一个动作块 $A_t = (\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1})$，其中第 j 条指令在

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + \ell_t + j\Delta_a \tag{1}$$

生效，ℓ_t 是从采集到首次生效的延迟（预处理、推理、排队与执行），Δ_a 是控制周期。我们把 $\Delta_{t,j} = \tau^{\mathrm{a}}_{t,j} - \tau_t$ 称为指令 j 的领先时长；这条指令必须与 $\tau^{\mathrm{a}}_{t,j}$ 而不是 τ_t 时的场景相符（图 3）。

目标与环境。 令 $W_t(\mathbf{x}, \tau) \in \mathbb{R}^3$ 为位于 $\mathbf{x}$ 的场景点在 τ_t 与 τ 之间的位移，在机器人基座坐标系中表示。目标 $\mathcal{O}$ 是其位姿误差进入接触或容纳容差 ε 的刚体，例如要抓取的物体或要放入的料箱。环境 $\mathcal{C}$

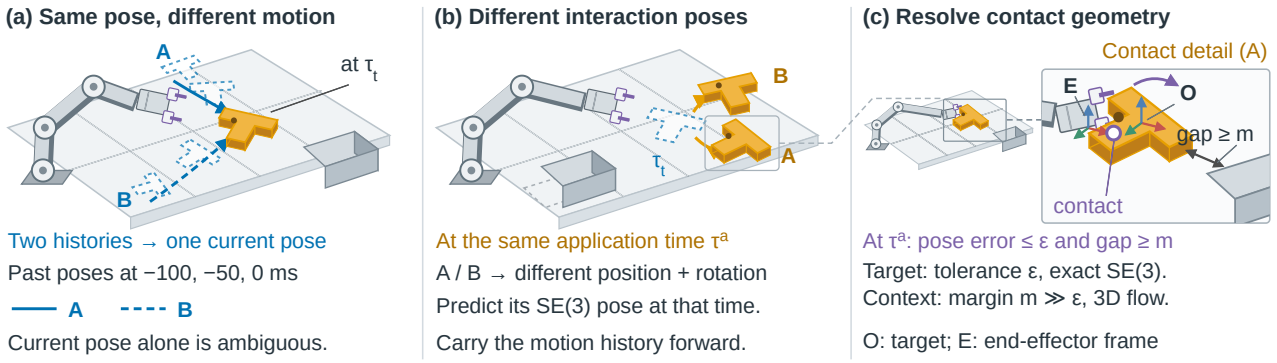


图 3. **在物理时间中行动**（示意）。(a) 两段历史在采集时刻 τ_t 到达同一位姿，却意味着不同的运动。(b) 在生效时刻 τ^{a}，它们导致不同的目标位姿。(c) 接触要求末端坐标系 E 与目标 O 在 ε 内对齐，而环境只通过它留下的间隙起作用，$m \gg \varepsilon$。

包含只需以间隙 m 避开的物体——传送带或遮挡物。同一物体可以同时扮演两种角色，例如入口必须精确对准、环路必须避开的导线。在目标上，运动场由其位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 决定：

$$W_t(\mathbf{x}, \tau) = T(\tau)\, T(\tau_t)^{-1}\mathbf{x} - \mathbf{x}, \qquad \mathbf{x} \in \mathcal{O}. \tag{2}$$

误差从何而来。 设策略显式或隐式地依据目标在 τ^{a} 时位姿的估计 $\hat{T}$ 行动。对力臂为 r 的接触点与旋转误差 θ，接触误差至多为 $\|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\| + 2r\sin(\theta/2)$。把领先时长 Δ 内的运动写成匀速 $\mathbf{v}$ 加残差 $\boldsymbol{\rho}$（加速度、滚动、撞击），得到

$$\|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\| \le e_{\mathrm{loc}} + \hat{\Delta}\, e_v + \|\mathbf{v}\|\, e_\tau + e_{\mathrm{dyn}}, \tag{3}$$

四项依次为当前位置误差、速度误差乘领先时长、时间误差乘速度，以及残差运动的误差（附录 G）。对于环境，只有当沿指令路径某处的预测误差至少为 m 时才会发生碰撞。因此，忽略运动的策略一旦 $\|\mathbf{v}\|\Delta$ 超过 ε 就会失手，而环境可以预测得粗得多。这些观察促成了 SE(3)-WAM 的三个部分，当前位置（e_{loc}）则依赖位姿跟踪器：度量的运动历史，针对速度误差 e_v（第 3.2 节）；目标的 SE(3) 预测加粗粒度环境流，针对 e_{dyn} 与旋转误差（第 3.3 节）；知道自身领先时长、并与生效时刻的预测一起训练的指令，针对 e_τ（第 3.4 节）。

3.2 度量的目标运动历史

我们用因果跟踪器在每个全分辨率 RGB-D 帧中估计目标位姿。SAM 2 从目标上的提示出发传播掩码 [32]，FoundationPose 依据 CAD 模型或少量参考视图跟踪物体 [43]。两者都没有时，我们使用逐帧估计度量包围盒位姿的单目三维检测器 [18]。每个估计只输出一次，带有其采集时刻与有效标志，之后的帧不会修改它。我们在 $-350, -300, \ldots, 0$ ms 处对这条因果轨迹重采样，使其含义不依赖于相机频率，并构建 8 个运动 token，包含区间运动、有限差分速度与加速度以及当前位姿，均在基座坐标系与物理单位下表示（附录 A.1）。冻结的 MAE ViT-B/16 [14] 把当前 RGB 图像编码为 196 个图像块 token，深度图为每个图像块提供用于旋转位置注意力的度量 3D 位置。机器人 token 保存 8 个末端状态以及为第一个生效时刻指令的位姿。模型不接收过去的图像；训练时它使用与测试时相同的因果位姿估计，包括跟踪失败。

3.3 按角色划分的 4D 预测

世界查询在时域 $\tau_t + \delta_h$ 上预测 W_t，其中 $\delta_h = h{\cdot}50\,\text{ms}$，$h = 1, \ldots, 8$，覆盖下一次重规划之前所执行指令的领先时长，使预测在指令生效的时刻受到监督（附录 G.4）。目标通过式 (2) 参数化。对每个时域，

$$\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t), \quad \phi_h = \mathrm{Log}\big(R(\tau_t{+}\delta_h)R(\tau_t)^\top\big)^\vee. \tag{4}$$

物体查询以平方平移误差加 λ_R 倍平方测地旋转误差回归 $(\mathbf{d}_h, \phi_h)$（$\mathcal{L}_P$）。对旋转对称的目标，我们排除绕对称轴的不可观测旋转。场景的其余部分表示为 3D 场景流，即固定14×14 图像网格上 $N = 196$ 个点在基座坐标系中的位移 $F_h \in \mathbb{R}^{N\times 3}$，这些点在工作空间中相距约 [X] mm。每个点对应一个带角色嵌入（目标、机器人或环境）的场景查询，回归该点的位移与可见性（$\mathcal{L}_F$）。网格刻意取得较粗，因为环境的误差在其间隙之内都可以容忍。未来深度、DINOv3 特征 [33] 与运动表面的 RGB 作为场景查询的额外训练目标（$\mathcal{L}_{\text{aux}}$）。所有标签都从当前状态累计，损失只使用有效标签。

3.4 以领先时长为条件的动作

一个动作块包含 8 条按式 (1) 的时刻生效的指令，控制周期 Δ_a 为 50 ms（20 Hz）。每 100 ms 重规划一次时，动作块的前两条指令会在下一个动作块替换其余指令之前执行。每条指令是末端在基座坐标系中的平移与左乘相对旋转，外加一个夹爪指令，以为前一个生效时刻所指令的位姿为参考，这一位姿控制器确切知道 [36]。每个动作 token 嵌入其领先时长 $\Delta_{t,j} = \ell_t + j\Delta_a$。训练时我们采样 $\ell \sim \mathcal{U}[0, 250\,ms]$，并从示范的 $\tau_t + \ell + j\Delta_a$ 处读取指令标签，因此一个模型可服务于该范围内的任何延迟。对归一化的动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与 $u \sim \mathcal{U}[0, 1]$，动作损失为

$$\mathcal{L}_A = \mathbb{E}\left\| v_\psi(\mathbf{a}_u, u \mid \mathcal{Z}_t, \hat{\mathcal{W}}_t, \mathcal{G}) - (\mathbf{a}_1 - \mathbf{a}_0) \right\|^2, \tag{5}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{Z}_t$ 为条件 token，$\hat{\mathcal{W}}_t$ 为耦合方式允许动作读取的世界 token（R0 与 R1 中没有）。总损失为 $\mathcal{L} = \mathcal{L}_A + \lambda_F\mathcal{L}_F + \lambda_P\mathcal{L}_P + \lambda_{\text{aux}}\mathcal{L}_{\text{aux}}$。

世界—动作耦合。 注意力掩码 $\mathcal{G}$ 作用于四个 token 组：条件 $\mathcal{Z}$、物体查询 $\mathcal{Q}$、场景查询 $\mathcal{F}$ 与动作 $\mathcal{A}$。条件 token 只相互读取；世界查询读取条件与彼此；动作 token 读取条件、自身以及耦合方式所允许的那部分世界。动作不读取任何世界 token。世界损失在训练中塑造共享参数，部署时只运行动作分支。两个分支共享注意力投影，各自拥有前馈网络。第 4.4 节把这一选择与其他方案进行比较，记号如下：R0 关闭世界损失，R1 中动作不读取任何世界 token，R2 中动作读取世界查询的隐藏状态，R3 中世界读取带噪动作，R4 双向开放，R5 把解码出的几何编码后供动作读取（附录 A.5）。

执行与实现。 测试时，我们依据执行器的延迟估计设定领先时长，即近期推理时间的 p95 加执行延迟。Transformer 有 4 层、宽度 768、8 个头，主干参数 47.3M，可训练参数共 62.2M。图像编码器与 DINOv3 教师保持冻结，但在每个训练步都要运行，并占据了其主要开销。在 Dynamic-14 上，我们以数据并行训练 4 个 epoch（全局 batch 为 16 时约 40k 次更新），在 8 块 RTX PRO 6000 GPU 上每个训练种子约需 7.7 小时。测试时，动作分支以半精度进行 5 步欧拉积分，在一块 RTX 5090 上的 p95 出动作时间为 [XX] ms（附录 A.6 与附录 D.4）。

3.5 在提升为 4D 的真实机器人数据上预训练

真实机器人数据不提供物体位姿或场景流。我们不使用物体模型，将 DROID [20] 提升为度量 4D 标签。场景流来自 PointWorld 为 DROID 发布的 3D 轨迹与优化后的相机标定 [17]。我们把指令中提到

的物体作为目标：开放词汇检测器找到它 [26]，SAM 2 跟踪其掩码，单目三维检测器估计其度量位姿。输入来自前向跟踪，与部署时一致；式 (4) 的标签来自整段回合上平滑的前向—后向跟踪。DROID 中的目标大多在机器人移动它们时才运动（[X]% 的窗口在接触前出现目标运动），因此预训练主要教会模型度量几何、3D 流以及它们与以领先时长为条件的动作之间的耦合（图 S1）。真机策略从这一基座初始化。仿真模型从通用初始化（冻结的 MAE 编码器加随机初始化的 Transformer）训练，另有一组受控比较在 Dynamic-14 上对基座做后训练（附录 B）。

4 实验

我们在仿真和真机上比较 SE(3)-WAM 与反应式、动态及世界—动作策略（第 4.2 节与第 4.3 节），然后分析它的哪些组件起作用以及原因（第 4.4 节）。

4.1 实验设置

Dynamic-14 。 我们在 MuJoCo/robosuite [38, 61] 中构建了 14 个任务，分为五个任务族：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动料箱、让棒沿旋转导线穿越、捕获滚动或滑动的物体，以及撞击后抓取（附录 C，图 S3）。扫描改变速度（0.5–1.5×）、附加延迟（0–200 ms）、穿越间隙（[取值] mm）与位姿噪声。使用仿真器状态的脚本专家为每个任务提供 800 条示范。我们在开发集场景上选择配置，Dynamic-14 上的所有数字都在 1,400 个留出场景（每个任务 100 个，新种子）上报告。本文各变体取三个训练种子的平均，每个基线训练一次。我们通过对留出场景的 bootstrap 给出配对 95% 区间。在仿真中，跟踪器以第一帧中目标的渲染掩码作为提示，并以仿真网格作为物体模型。

协议。 所有方法在同一执行器下实时运行：方法计算期间，物理仿真按其在一块 RTX 5090 上测得的延迟继续推进。每 100 ms 或在上一次推理结束时请求新的动作块，指令在其生效时刻执行，过时的指令被丢弃。+150 ms 设置为每个方法附加 150 ms 延迟，暂停设置在推理期间停止物理仿真（附录 E.2）。我们报告按任务等权的成功率（SR）、接触时刻误差 e_t、首次接触时的位置误差 e_p 以及 p95 出动作时间。在 DOMINO [12] 上，我们评估单臂拦截与跟踪；LIBERO [25] 用于检验结构化的世界表示不会损害静态任务上的性能。

基线。 我们与反应式策略（ACT [58]、Diffusion Policy [10] 与 $\pi_{0.5}$ [31]）、动态 VLA（DynamicVLA [46] 与 PUMA [12]）、图像或隐空间 WAM（DreamVLA [55] 与 OpenWAM-α [42]）以及动态 WAM（DynamicWAM [29]）比较。每个基线使用其官方代码、输入与训练方案，在相同示范上训练；若其方案使用腕部相机，则提供渲染的腕部相机图像（附录 D）。SE(3)-WAM 只使用主视角，但还使用深度与跟踪得到的目标位姿。为把这些输入与模型本身区分开，$\pi_{0.5}$ 与 DynamicWAM 还额外接收我们的 SE(3) 历史 token（+SE(3)）；我们也报告使用单目三维检测器位姿、无需物体模型的 SE(3)-WAM 。另有两个基线只使用跟踪器：*CV* 输入是去掉世界监督、以跟踪位姿的匀速外推作为输入 token 的 SE(3)-WAM ；卡尔曼拦截器则规划到匀加速卡尔曼滤波器 [4] 预测的目标位姿。

4.2 主要结果

在实时协议下，SE(3)-WAM 在 Dynamic-14 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [最强基线名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [最强 +SE(3) 基线名称] 高 [X.X] 个百分点。优势在 [旋转目标以及快速的传送带与平移目标] 上最大，这些目标在领先时长内移动得最远 [；

表 1. **主要结果。**Dynamic-14 留出集成功率（%；1,400 个新场景，按任务等权，实时协议，本文各变体取三个训练种子的平均，基线训练一次），按任务族分列；另列加入 150 ms 延迟后的成功率、推理期间物理暂停时的成功率（暂停）、DOMINO 单臂成功率、LIBERO 四个套件的平均成功率，以及在一块 RTX 5090 上的 p95 出动作时间。输入：R 为 RGB 与机器人状态；D 为深度；P 为本文跟踪器借助物体模型给出的目标 SE(3) 历史；P′ 为单目三维检测器给出的同一历史，无需物体模型。粗体为最佳；置信区间见附录 E。

		Dynamic-14，除注明外为实时协议										
方法	输入	全部	抓取	放置	穿越	捕获	撞击	+150 ms	暂停	DOMINO	LIBERO	p95 (ms)
ACT [58]	R	—	—	—	—	—	—	—	—	—	—	—
Diffusion Policy [10]	R	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ [31]	R	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	R+P	—	—	—	—	—	—	—	—	—	—	—
DynamicVLA [46]	R	—	—	—	—	—	—	—	—	—	—	—
PUMA [12]	R	—	—	—	—	—	—	—	—	—	—	—
DreamVLA [55]	R	—	—	—	—	—	—	—	—	—	—	—
OpenWAM-α [42]	R	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM [29]	R	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM + SE(3)	R+P	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	RD+P	—	—	—	—	—	—	—	—	—	—	—
卡尔曼拦截器	D+P	—	—	—	—	—	—	—	—	–	–	—
SE(3)-WAM，检测器位姿	RD+P′	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM	RD+P	—	—	—	—	—	—	—	—	—	—	—

表 2. **真机传送带抓取。**按物体与传送带速度（慢、中、快：0.04、0.08、0.12 m/s）分列的成功率（%；各 60 次试验）及每个方法全部 180 次试验的成功率。每个方法以三个种子微调，每个种子执行一组 60 次试验。二项分布 95% 区间见附录 D.3。

	物体			带速			
方法	盒	罐	杯	慢	中	快	全部
$\pi_{0.5}$ [31]	—	—	—	—	—	—	—
SE(3)-WAM，无 DROID 基座	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—

没有任何方法解决放入旋转料箱的 SE(3) 放置任务]。附加 150 ms 延迟时，SE(3)-WAM 保持 [XX.X]%，而反应式策略降到 [XX.X]%，图像空间 WAM 降到 [XX.X]%。在推理期间暂停物理仿真时，与 [暂停协议下最强基线名称] 的差距为 [±X.X] 个百分点，这把速度的贡献与模型本身的贡献区分开来。用检测器位姿替代物体模型损失 [X.X] 个百分点；CV 输入变体与卡尔曼拦截器分别落后 SE(3)-WAM [X.X] 与 [X.X] 个百分点，主要差在非匀速运动上（附录 F.3）。在 DOMINO 上，SE(3)-WAM 取得 [XX.X]%，[DOMINO 上最强基线名称] 为 [XX.X]%；在静态的 LIBERO 任务上，它与 $\pi_{0.5}$ 相差不超过 [X.X] 个百分点（[XX.X]% 对 [XX.X]%）。

4.3 真机实验

一台配备平行夹爪的七自由度 Franka 机械臂需要抓取由传送带带过的物体，将其提起并保持 0.5 s，由一台标定好的 RGB-D 相机观测（图 S4）。三个物体的朝向重要程度不同：一个边长不等的盒子、一个细长的罐子和一个带单个把手的杯子。传送带以 0.04、0.08 或 0.12 m/s 运行。每个方法在相同的 [300] 条遥操作示范上以三个种子微调，运行 180 次试验，每个物体与速度组合 20 次，分为三组共享试验键，每组一个种子。SE(3)-WAM 使用 [借助每个物体的 CAD 模型或参考视图的 FoundationPose]，而其

图占位：图 4——真实传送带试验

行：SE(3)-WAM 在 0.12 m/s 下抓取杯子的一次成功；$\pi_{0.5}$ 在同一试验键上的结果；SE(3)-WAM 的一次失败。**列：**查询帧、首个生效时刻 τ^{a} 与接触时刻。**叠加：**蓝色为跟踪得到的过去位姿；橙色为各指令生效时刻的预测坐标轴；紫色为指令的夹爪轨迹。真实照片不修饰；叠加内容取自各次试验的记录数据。

图 4. **真实传送带试验。**SE(3)-WAM 在指令生效时杯子将要到达的位置合拢，而 $\pi_{0.5}$ 在杯子后方合拢。下：跟踪器在夹爪下方丢失把手后的一次失败。

图占位：图 5——组件分析（四个子图）

(a) 历史。x：附加延迟（0–200 ms）；y：相对仅当前帧的 ΔSR。曲线：RGB 窗口、光流、视频 VAE 隐变量（灰），因果 SE(3)（蓝）、检测器 SE(3)（蓝点线）、真值 SE(3)（蓝虚线）；静止目标为一条浅色线；刻度标出各任务族的临界领先时长 $\varepsilon/\|\mathbf{v}\|$。**(b) 目标预测。**按运动类型（匀速、简谐、滚动/滑动、撞击后）的柱状图：CV、CA 与学习的 SE(3) 预测（橙）在 τ^{a} 处的预测误差，点表示相应策略的 SR。**(c) 环境。**仅穿越任务。x：间隙（mm）；y：SR；曲线：无环境流、14^2、28^2、56^2 网格、未来隐变量；标记：各网格实测的路径误差。**(d) 耦合。**x：附加延迟；y：相对最终模型的 ΔSR；曲线：其他耦合方式与关闭世界损失（R0，点线）；静止目标为右侧的点。95% 配对 bootstrap 区间带，留出场景，三个种子。

图 5. **各组件的贡献。**(a) 一旦领先时长超过临界领先时长，SE(3) 历史就带来收益，且延迟越大收益越大，而视觉历史保持平坦。(b) 学习的 SE(3) 预测在非匀速运动上优于外推。(c) 在间隙降到其路径误差之前，粗粒度环境流已经足够。(d) 在每个延迟下，仅在训练中使用的世界监督都与在线使用预测相当。区间带为 95% 配对 bootstrap 区间。

基座是在检测器位姿上预训练的。SE(3)-WAM 的试验成功率为 [XX.X]%（95% 区间 [[a, b]]），$\pi_{0.5}$ 为 [XX.X]%，不使用 DROID 基座时为 [XX.X]%（表 2）。它相对 $\pi_{0.5}$ 的优势从 0.04 m/s 时的 [X.X] 个百分点增长到 0.12 m/s 时的 [X.X] 个百分点，在 [杯子] 上最大（表 S10，图 4）。其余失败主要是 [夹爪下方跟踪丢失后合拢过晚]。

预训练。 DROID 基座使真机 SR 比通用初始化高 [X.X] 个百分点（表 2）。在仿真中，在 Dynamic-14 上对基座做后训练，使用全部示范时 SR 变化 [X.X] 个百分点，只用 10% 示范时变化 [X.X] 个百分点；在试点规模下，只用动作预训练的基座只能恢复相同预算的世界—动作基座低数据增益的 [XX]%，因此大部分收益来自 4D 标签（附录 B）。

4.4 分析：动态策略需要什么？

我们接着考察 SE(3)-WAM 的哪些部分带来了这些增益。每个变体只改变最终模型的一个组件，保持数据、训练预算与其他组件不变（表 3 与图 5）。完整比较见附录 F。

记住什么。 我们固定当前帧、当前目标位姿与机器人历史。加入 8 帧 RGB、同一窗口上带 DynamicWAM 运动统计量 [29] 的光流或视频 VAE 隐变量，使 SR 变化 [X.X] 到 [X.X] 个百分点。因果 SE(3) 历史带来 [X.X] 个百分点，真值历史带来 [X.X] 个百分点（表 3）。增益在领先时长超过某任务族的临界领先时长 $\varepsilon/\|\mathbf{v}\|$ 后出现，随延迟增大，并在目标静止时消失（图 5a）。冻结读出表明视觉历史确实包含运动信息（附录 F.2），但在我们的数据规模下，即使为过去的帧提供度量 XYZ，策略也没有把它转化为度量速度（[±X.X] 个百分点，表 S17）。位姿噪声与遮挡的分析见附录 F.2 与附录 G.5。把同样的

表 3. **组件分析**（Dynamic-14 留出场景，三个训练种子）。每组只改变 SE(3)-WAM （⋆）的一个组件。SR、SR_{150}：不加和加入 150 ms 延迟时的成功率（%）；e_t：接触时刻误差（ms）；e_p：首次接触时的位置误差（mm）；p95：出动作时间（ms）。

变体	SR	SR_{150}	e_t	e_p	p95
SE(3)-WAM ⋆	—	—	—	—	—
历史（保留当前帧与当前位姿）					
无	—	—	—	—	—
RGB 窗口（8 帧）	—	—	—	—	—
光流与运动统计	—	—	—	—	—
视频 VAE 隐变量	—	—	—	—	—
SE(3)（真值）	—	—	—	—	—
预测目标					
无（关闭世界损失，R0）	—	—	—	—	—
目标点轨迹 + 环境流	—	—	—	—	—
仅目标 SE(3)	—	—	—	—	—
SE(3) + 28 × 28 流	—	—	—	—	—
SE(3) + 未来 RGB/隐变量（无流）	—	—	—	—	—
去除外观辅助目标	—	—	—	—	—
世界—动作耦合					
动作读取世界隐藏状态（R2）	—	—	—	—	—
双向读取隐藏状态（R4）	—	—	—	—	—
动作读取解码几何（R5）	—	—	—	—	—
物理时间					
去除领先时长嵌入	—	—	—	—	—
按控制步计的领先时长	—	—	—	—	—
预测时域偏移 50 ms	—	—	—	—	—

历史提供给 $\pi_{0.5}$ 与 DynamicWAM，其 SR 分别提高 [X.X] 与 [X.X] 个百分点（表 1），因此这一收益并非我们的模型所特有。

预测什么。 用目标的 SE(3) 轨迹替代点轨迹作为监督，总体 SR 变化 [±X.X] 个百分点，但在旋转目标上提高 [X.X] 个百分点，因为力臂会放大旋转误差。在生效时刻，学习的 SE(3) 预测在传送带运动上与匀速和匀加速外推同样准确，但在滚动、滑动与撞击后运动上准确 [X] 倍（图 5b）；不过在撞击之前，它对可能的结果取平均（图 6）。对于环境，路径误差为 [X] mm 的14 × 14 流在穿越间隙降到 [X] mm 之前与 28^2 和 56^2 网格相当（图 5c，表 S21），而世界分支的训练代价低 [X] 倍。去掉环境流损失 [X.X] 个百分点，主要在穿越任务上。作为预测的世界，未来 RGB、VAE 隐变量、深度、DINO 特征或冻结视频模型的隐变量在同等容量下为 SE(3) 轨迹至多增加 [X.X] 个百分点，训练代价却高达 [X] 倍。外观在另一种角色中有用：作为场景查询的辅助目标（其读出头在部署时去掉），深度、DINO 特征与运动区域 RGB 带来 [X.X] 个百分点。

如何使用预测。 仅在训练中使用世界监督、部署时只运行动作分支，与读取世界的耦合方式表现相当（0 ms 时 [±X.X] 个百分点，150 ms 时 [±X.X] 个百分点，图 5d），而出动作时间低 [X.X] 倍。关闭世界损失会损失 [X.X] 个百分点，这一差距随领先时长增大，并在目标静止时消失。因此，预测作为以领先时长为条件的动作的训练信号起作用，而在测试时生成预测只会增加延迟，不会提高成功率。

物理时间。 去掉领先时长嵌入损失 [X.X] 个百分点，附加 150 ms 延迟时损失 [X.X] 个百分点。从第一条指令起按控制步计数领先时长，在测试延迟与训练延迟不同时损失 [X.X] 个百分点；把预测的监

图占位：图 6——生效时刻的预测

行：一次滚动捕获（预测误差中位数）与一次失败的撞击后抓取。**列**：τ_t 处的查询帧、τ^a 处的帧，以及基座坐标系中的 3D 插图。**叠加**：蓝色过去位姿，橙色预测坐标轴与粗粒度流箭头，灰色同一时刻的真值，紫色指令轨迹。完整示例见图 S5。

图 6. Dynamic-14 留出回合中**生效时刻的预测**。上：SE(3) 预测跟上了外推会冲过头的滚动目标。下：在撞击之前，回归的预测对可能的结果取平均，抓取失手。

督时刻偏离生效时刻 50 ms，在最快的三分之一场景上损失 [X.X] 个百分点，对静止目标则为 [X.X] 个百分点（附录 F.5）。

5 结论

我们提出了 SE(3)-WAM ，一个面向运动物体操作、为指令生效时刻预测场景的世界—动作模型。它记住目标的度量运动，精确预测目标的 SE(3) 轨迹、粗略预测场景其余部分，并让每条指令以其领先时长为条件。在实时协议下，它在仿真、DOMINO 与真实传送带上都优于反应式、动态与世界—动作策略；在带提升 4D 标签的 DROID 上预训练的基座能够迁移到真机。我们的分析把增益归因于度量运动历史，以及与生效时刻的预测一起学习的、以领先时长为条件的动作，而不是更丰富的外观模型。对于世界—动作模型，这一结论支持在指令生效的时刻监督未来、保持部署策略快速，而不是在测试时生成未来。

局限性。 SE(3)-WAM 假设目标是在接触前自行运动的刚体，因此可变形或铰接的目标以及接触后的动力学不在其范围内。它依赖位姿跟踪器，跟踪失败会传递给策略。单目三维检测器的位姿免去了物体模型，但损失精度；回归的目标预测无法表示多模态的未来，例如撞击之前。把 DROID 提升为 4D 标签需要大量计算。最后，我们的任务只有一个目标且环境运动缓慢，真机实验只涵盖一个平台上的一个任务。

LLM Usage Statement（大语言模型使用声明）

[投稿前补充：实际使用的工具、受影响的研究与稿件部分，以及使用程度。]

参考文献

[1] Iretiayo Akinola, Jingxi Xu, Shuran Song, and Peter K. Allen. Dynamic grasping with reachability and motion awareness. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 9422–9429, 2021.

[2] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[3] Ronald Azuma and Gary Bishop. Improving static and dynamic registration in an optical see-through HMD. In *Proceedings of SIGGRAPH*, pages 197–204, 1994.

[4] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation*. Wiley, 2001.

[5] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[6] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, 2025.

[7] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, 2017.

[8] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[9] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[10] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[11] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. *arXiv preprint arXiv:2503.11565*, 2025.

[12] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. *arXiv preprint arXiv:2603.15620*, 2026.

[13] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[14] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[15] B. Hove and Jean-Jacques E. Slotine. Experiments in robotic catching. In *American Control Conference*, 1991.

[16] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *International Conference on Machine Learning*, 2025.

[17] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[18] Weikai Huang, Jieyu Zhang, Sijun Li, Taoyang Jia, Jiafei Duan, et al. WildDet3D: Scaling promptable 3D detection in the wild. *arXiv preprint arXiv:2604.08626*, 2026.

[19] Seth Hutchinson, Gregory D. Hager, and Peter I. Corke. A tutorial on visual servo control. *IEEE Transactions on Robotics and Automation*, 12(5):651–670, 1996.

[20] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[21] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[22] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[23] Minghui Lin, Pengxiang Ding, Shu Wang, Zifeng Zhuang, Yang Liu, Xinyang Tong, Wenxuan Song, Shangke Lyu, Siteng Huang, and Donglin Wang. HiF-VLA: Hindsight, insight and foresight through motion representation for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[24] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[25] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: Benchmarking knowledge transfer for lifelong robot learning. In *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*, 2023.

[26] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[27] Yushan Liu, Jingjing Fan, Shoujie Li, Yifan Xie, Xiao-Ping Zhang, and Wenbo Ding. PACT-WAM: Predicting actions and visual foresight with compact temporal encoding for robot manipulation. *arXiv preprint arXiv:2602.15882*, 2026.

[28] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[29] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[30] Henrique Morimitsu, Xiaobin Zhu, Roberto M. Cesar, Xiangyang Ji, and Xu-Cheng Yin. DPFlow: Adaptive optical flow estimation with a dual-pyramid framework. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17810–17820, 2025.

[31] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.

[32] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, 2025.

[33] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[34] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[35] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. *arXiv preprint arXiv:2606.02486*, 2026.

[36] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[37] Zachary Teed and Jia Deng. RAFT-3D: Scene flow using rigid-motion embeddings. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.

[38] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[39] Changhao Wang, Jaden Clark, and Shuran Song. Chronos policy: Learning robot policies on physical time. *arXiv preprint arXiv:2610.13929*, 2026.

[40] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[41] Ruicheng Wang, Sicheng Xu, Yue Dong, Yu Deng, Jianfeng Xiang, Zelong Lv, Guangzhong Sun, Xin Tong, and Jiaolong Yang. MoGe-2: Accurate monocular geometry with metric scale and sharp details. *arXiv preprint arXiv:2507.02546*, 2025.

[42] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[43] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[44] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[45] Yuxi Xiao, Qianqian Wang, Shangzhan Zhang, Nan Xue, Sida Peng, Yujun Shen, and Xiaowei Zhou. SpatialTracker: Tracking any 2D pixels in 3D space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[46] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. *arXiv preprint arXiv:2601.22153*, 2026.

[47] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, 2024.

[48] Zhenjia Xu, Zhanpeng He, Jiajun Wu, and Shuran Song. Learning 3D dynamic scene representations for robot manipulation. In *Conference on Robot Learning*, 2020.

[49] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[50] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[51] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

[52] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. *arXiv preprint arXiv:2607.01938*, 2026.

[53] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[54] Chuhan Zhang, Guillaume Le Moing, Skanda Koppula, Ignacio Rocco, Liliane Momeni, Junyu Xie, Shuyang Sun, Rahul Sukthankar, Joëlle K. Barral, Raia Hadsell, Zoubin Ghahramani, Andrew Zisserman, Junlin Zhang, and Mehdi S. M. Sajjadi. Efficiently reconstructing dynamic scenes one D4RT at a time. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[55] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[56] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[57] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Tsung-Yi Lin, Gordon Wetzstein, Ming-Yu Liu, and Donglai Xiang. CoT-VLA: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[58] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[59] Hongyan Zhi, Peihao Chen, Siyuan Zhou, Yubo Dong, Quanxi Wu, Lei Han, and Mingkui Tan. 3DFlowAction: Learning cross-embodiment manipulation from 3D flow world model. *arXiv preprint arXiv:2506.06199*, 2025.

[60] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[61] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

补充材料

本补充材料给出 SE(3)-WAM 的实现细节（附录 A）、把 DROID 提升为 4D 标签及预训练（附录 B）、基准（附录 C）、基线、外部基准、真机与计时（附录 D）、补充结果（附录 E）、支撑第 4.4 节的完整组件研究（附录 F），以及促成这一设计的误差分析（附录 G）。彩色破折号与方括号内容表示等待最终实验填写的数值。

A 实现细节

A.1 条件 token

当前图像。 冻结的 MAE ViT-B/16 [14] 把 224×224 的主视角 RGB 编码为 196 个图像块 token。我们在开发集场景上把它与冻结的 DINOv3 编码器 [33] 以及与策略一同训练的 CNN 比较后选定了它（附录 F.1）。每个图像块获得一个视角嵌入、其有效度量深度均值的线性嵌入，以及其反投影到基座坐标系的位置的线性嵌入；这些位置由固定的源像素与相机内外参计算。这些位置同时进入图像查询与键以及场景查询的 3D 旋转位置编码，场景查询共享同样的源点。目标、机器人与动作 token 不使用旋转位置编码。仅在训练中，条件 token 上的一个线性解码器重建目标当前包围盒内的 RGB（在 $\mathcal{L}_{\text{aux}}$ 中权重为 0.1），从而在不增加任何输入的情况下把图像块特征与目标联系起来。

目标运动历史。 因果跟踪器在采集时刻输出位姿（附录 A.2）。每次查询均在偏移 $-350, -300, \ldots, 0$ ms 处对已输出的轨迹重采样，在相邻估计之间对平移线性插值、对旋转沿测地线插值。我们不做外推，也不跨越超过两个相机周期的空缺插值，因此两侧都没有估计的偏移被标记为无效。8 个运动 token 中的每一个都是 25 维描述子 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta t, \mathbf{v}, \boldsymbol{\omega}, \mathbf{a}, \boldsymbol{\alpha})$，各部分维度为 $(3, 3, 3, 3, 1, 3, 3, 3, 3)$。槽位 0–6 描述相邻偏移之间的七个区间，槽位 7 保存当前的绝对位姿。速度为区间位移除以经过的时间，加速度为相邻速度之差。我们用训练统计量标准化每一维，把无效维度置零，并附加三个有效标志（位姿、区间与加速度），再送入带时间嵌入的 $28 \to 768 \to 768$ GELU MLP。跟踪器报告目标丢失时，一个可学习嵌入替代该位姿。

机器人状态。 同样偏移处的 8 个末端状态（位置、旋转向量与测得的夹爪开度）构成机器人 token。另有一个 token 保存为第一个生效时刻 $\tau^{\text{a}}_{t,0}$ 指令的末端位姿，它是动作块增量的参考（附录 A.4）。

A.2 位姿跟踪器

SAM 2.1（Hiera-small）从第一帧中的包围盒出发因果地传播目标掩码 [32]。在仿真中，该包围盒来自目标的渲染掩码；在真机上，它来自 Grounding DINO 对指令中物体短语的检测 [26]。FoundationPose 使用其发布的权重，在全分辨率 RGB-D 帧（[640 × 480]）中注册并跟踪物体 [43]。在仿真中，物体模型是目标的仿真网格；在真机上，它是 CAD 模型或每个物体采集一次的 [16] 张带掩码参考视图。跟踪器在独立线程中运行，每个估计带有其采集时刻、可用时刻与有效标志。注册失败、掩码区域深度缺失或帧间跳变超过 [X] mm 后，该标志为假。

单目三维检测器的位姿（第 4.2 节）不需要物体模型。对每个带掩码的帧，WildDet3D [18] 根据 RGB 帧、紧致的 2D 包围盒与内参预测被提示目标的度量 3D 包围盒。包围盒的坐标轴在其对称性范围内有歧义，因此与 DROID 的做法一样（附录 B.2），我们在 24 种坐标轴排列与符号翻转中选出与上

表 S1. **因果跟踪器精度。**输出位姿相对真值的中位数与 p95 误差、报告丢失的帧比例，以及使用各跟踪器时 SE(3)-WAM 在 Dynamic-14 留出集上的成功率（⋆：采用的设置）。

跟踪器	mm	°	丢失	SR
FoundationPose，全分辨率 ⋆	—	—	—	—
FoundationPose，224 × 224	—	—	—	—
单目三维检测器（无物体模型）	—	—	—	—
仿真位姿（真值）	0/0	0/0	0	—
真机，CAD 先验	—	—	—	–
真机，参考视图	—	—	—	–
真机，三维检测器	—	—	—	–

一帧朝向最接近的一种，把每个包围盒映射到该回合的同一个物体坐标系。对旋转对称的目标，我们从估计、标签与误差中去掉绕对称轴的旋转。表 S1 报告两种跟踪器的精度以及输入分辨率的影响。

A.3 世界分支

世界由一个可学习的物体查询（$\mathcal{Q}$）与每个网格点一个场景查询（$\mathcal{F}$）组成，宽度均为 768。它们由可学习嵌入与位置编码初始化，读取条件与彼此，并以确定性方式回归，因此未来标签与噪声都不会进入它们。读出头嵌入每个时域的物理偏移 δ_h，这使我们可以像预训练时那样在其他偏移上监督同样的查询（附录 B.1）。

目标。 一个 MLP 从物体查询的最终状态读出轨迹 $\{(\mathbf{d}_h, \phi_h)\}_{h=1}^{8}$。设有效时域为 $\mathcal{V}$，

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h \in \mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\mathrm{SO}(3)}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{S1}$$

其中 $\lambda_R = 0.1$，$\hat{R}_h = \mathrm{Exp}(\hat{\boldsymbol{\phi}}_h^{\wedge}) R(\tau_t)$。对对称目标，$d_{\mathrm{SO}(3)}$ 忽略绕对称轴的旋转。我们使用左乘相对旋转向量与累计平移，而不是会通过其雅可比把平移与旋转耦合起来的 twist 指数。预测是条件均值，因此它会对多模态的未来取平均（例如撞击发生之前其结果）。

场景流。 场景流是 $N = 196$ 个源点在 8 个时域上的累计 3D 位移 $F \in \mathbb{R}^{N \times 8 \times 3}$，在基座坐标系中表示，并附带可见性 $o \in \{0,1\}^{N \times 8}$。每个场景查询带有其点的源位置与角色的嵌入。角色（目标、机器人或环境）来自跟踪器的掩码以及机器人的渲染或运动学掩码。一个线性读出头给出每个点在每个时域的位移与可见性 logit。我们用在训练标签上拟合的一个固定尺度除以位移，并使用

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h) \in \mathcal{V}_F} o_{ih} \big\| \hat{F}_{ih} - F_{ih} \big\|^2 + \mathrm{BCE}(\hat{o}, o), \tag{S2}$$

其中 $\mathcal{V}_F$ 包含有效标签，因此被遮挡的点只监督其可见性。

外观目标。 场景查询最终状态上的图像块解码器在每个时域预测三个目标：其图像块的度量深度（有效深度上的平方误差）、冻结的 DINOv3 ViT-L/16 教师 [33] 在 14×14 网格上经逐通道层归一化后的特征（平方误差），以及运动表面（即移动超过 1 mm 的表面，包括机器人）的 RGB，在该掩码内计算平方误差。每个目标以权重 0.1 进入 $\mathcal{L}_{\mathrm{aux}}$。部署时我们跳过这些读出头，也没有 token 读取它们的输出，因此它们只塑造场景查询的状态。

A.4 动作分支

每个动作块有 8 条七维指令，每条包含基座坐标系中的平移增量、左乘相对旋转向量与一个夹爪指令。指令 j 是相对为 $\tau^{\mathrm{a}}_{t,j-1}$ 所指令位姿的增量；当 $j=0$ 时，参考是仍在执行的上一个动作块为 $\tau^{\mathrm{a}}_{t,0}$ 指令的位姿。因此动作块锚定在控制器确切知道的位姿上，而不是采集时刻测得的机械臂位姿。每个动作 token 加上其领先时长 $\Delta_{t,j}=\ell_t+j\Delta_a$ 的正弦嵌入。训练时，我们为每个窗口采样延迟 $\ell\sim\mathcal{U}[0,250\,ms]$，并把示范在 $\tau_t+\ell+j\Delta_a$ 处的指令增量（在控制步之间插值）作为指令 j 的标签。归一化使用训练集中有效且不重复的已发出指令的均值与总体标准差。流匹配在这些坐标中使用单位高斯，每个动作块一个 u，动作 token 通过自适应层归一化接收 u。部署时，我们反归一化、解码旋转向量，并把平移与旋转在每个轴上分别裁剪到 0.10 m 与 0.5 rad。夹爪按其指令的符号动作。

A.5 耦合

注意力掩码作用于四个 token 组：条件（$\mathcal{Z}$）、物体查询（$\mathcal{Q}$）、场景查询（$\mathcal{F}$）与动作（$\mathcal{A}$）。条件 token 只读取 $\mathcal{Z}$；世界查询读取 $\mathcal{Z}$、$\mathcal{Q}$ 与 $\mathcal{F}$；动作 token 读取 $\mathcal{Z}$ 与 $\mathcal{A}$，再加上其耦合方式所开放的边。R0 与 R1 不开放任何从世界到动作的边。R2 让 $\mathcal{A}$ 读取 $\mathcal{Q}$ 与 $\mathcal{F}$，R3 让 $\mathcal{Q}$ 与 $\mathcal{F}$ 读取 $\mathcal{A}$，R4 双向开放，R5 让 $\mathcal{A}$ 读取由解码世界编码得到的几何 token。R0 还关闭所有世界损失。被屏蔽的边在训练与部署中、在每一层与每个头上的 logit 都为 $-\infty$。因此，动作不读取的世界查询无法影响动作，未来标签也不会经由条件到达动作。所有耦合方式使用相同的模块、初始化与损失，只在掩码上不同，R5 还多一个几何编码器。我们不在两个分支之间截断任何梯度。除非开放动作到世界的边，世界既不读取动作也不读取流时间，因此在 R1、R2 与 R5 中，其状态每次查询只计算一次，并在各欧拉步之间复用；在 R3 与 R4 中，每一步都要重新计算。在选定的耦合方式 R1 中，没有从世界到动作的边。世界损失塑造共享参数，部署时只以 5 步欧拉积分运行动作分支。主干在各组之间共享注意力投影，并为世界查询与动作 token 使用各自的前馈网络（比例 4）。世界查询使用层归一化，动作 token 使用自适应层归一化，主干可训练参数为 47.3M。附录 F.4 中的另一种参数化与之相比，可训练参数数量相差约 0.01%。

A.6 训练方案

表 S2 列出在 Dynamic-14 上训练的方案。每条示范提供查询时刻相隔 [8] 个控制步的窗口，每条示范约 [14] 个，每个窗口各自采样延迟。在试点实验中，全局 batch 64 加两倍学习率的训练速度约快 [2.5] 倍，但在不同种子之间不够稳定，因此我们保留 16。每步的开销主要来自冻结网络：图像编码器处理当前帧，DINOv3 ViT-L/16 教师处理每个窗口的未来帧。因此我们使用数据并行来缩短墙钟时间。一次训练在 8 块 RTX PRO 6000 GPU 上约需 7.7 小时。耦合方式的各变体在十六块 GPU 上训练，每块 GPU 一个窗口，全局 batch 相同。DROID 基座与受控比较使用附录 B.5 的方案。

A.7 部署

每次查询编码最新观测，在查询内复用缓存的条件 token，并发出一个动作块，其指令按各自的生效时刻调度（式 1）。查询之前，执行器把 ℓ_t 设为其延迟估计，即最近 50 次实测推理时间的 p95 加平台的执行延迟。若推理提前结束，指令等待各自的时刻；若推理结束过晚，时刻已过的指令被丢弃，其余照常执行。附录 C.3 描述所有方法共用的执行器，附录 D.4 描述计时测量。

表 S2. Dynamic-14 上的训练超参数。

项目	取值
主干	4 层，宽度 768，8 个头，47.3M 参数
编码器	冻结的 MAE ViT-B/16，输入 224×224
优化器	AdamW，$\beta = (0.9, 0.95)$，$\epsilon = 10^{-8}$，权重衰减 0.05
学习率	2×10^{-4}，1,000 次预热更新，余弦衰减到 0.1
Batch 与更新	全局 batch 16，4 个 epoch（40,104 次更新，641,664 个窗口）
损失权重	$\lambda_P = \lambda_F = 1$，$\lambda_R = 0.1$，每个目标 $\lambda_{\text{aux}} = 0.1$
延迟采样	每个窗口 $\ell \sim \mathcal{U}[0, 250\,ms]$
精度	BF16 加 TF32，梯度裁剪为 1，不使用 dropout
采样	动作 5 步欧拉积分
推理	FP16，编译，缓存条件 token
硬件	8 块 RTX PRO 6000 GPU，每次训练约 7.7 小时

B 把真实机器人数据提升为 4D 并预训练

B.1 数据、划分与时间

预训练语料是 DROID [20]，以 15 Hz 录制，含两台外部相机与一台腕部相机，并配有 PointWorld 为其发布的 3D 点轨迹与优化后的相机标定 [17]。我们要求关节序列、末端位姿、夹爪状态、指令与相机身份完全一致，才把每个发布的片段与其原始 DROID 回合关联起来；采集时钟不单调或关联有歧义的片段被排除。模型看到的是第一台外部相机。训练单元是一个因果观测窗口及其对齐的未来与动作标签。我们在任何筛选之前，按原始标识把回合分到训练、开发与留出划分（90/5/5，固定随机种子），因此同一回合的重叠片段不会跨越划分。表 S3 报告每个阶段的产出，并分别统计回合、窗口、动作与有效标签。

时间。 所有时间都是采集时间戳，我们不把帧重新标注为名义帧率。历史偏移位于 15 Hz 帧不会恰好落在的 50 ms 网格上，因此我们与部署时完全一样（附录 A.1），在查询时刻之前已输出的估计之间对因果输入在这些偏移处重采样，不做外推。目标标签以同样的方式对离线轨迹插值（位置线性插值，旋转沿测地线插值），不跨越超过两个源周期的空缺，因此它们位于主模型的时域上。流标签保留 PointWorld 自己的记录时刻（前方 [0.13] 到 [1.13] s），不做插值。世界读出头嵌入每个时域在物理时间中的偏移 δ_h（附录 A.3），因此场景查询在预训练时在这些偏移上受到监督，之后在 50 ms 网格上受到监督。

动作。 我们在经过标定的法兰到工具中心点变换之后，在机器人基座坐标系中表示机器人状态与笛卡尔指令。指令标签遵循附录 A.4：每个标签是从为前一个生效时刻指令的位姿到为当前生效时刻指令的位姿的增量，DROID 的指令位姿被插值到所采样延迟对应的生效时刻 $\tau_t + \ell + j\Delta_a$。数值有限且其参考状态可因果获得的标签才被接受。机器人的执行限幅不是接受规则，因为每条指令每轴 5 cm 的限幅会丢弃运动最快四分位中 [XX]% 的指令，使基座偏向慢速示范。我们只屏蔽 DROID 采集器没有发出指令的步（窗口槽位的 [3.1]%）。动作与流的有效性相互独立，因此无效的动作不会去掉其窗口的流标签。

表 S3. **提升为 4D 的 DROID**。各阶段的保留量。窗口指带有对齐标签的因果观测窗口。外源窗口指在机器人与目标首次接触前目标已在运动的窗口（附录 B.3）；最后两行比较全部窗口与有效窗口。

	训练	开发	留出
含 PointWorld 轨迹的 episode	—	—	—
与原始 DROID 对齐	—	—	—
指令只指定一个刚体且已检测	—	—	—
窗口	—	—	—
外源（%）	—	—	—
含因果位姿输入	—	—	—
有效动作（%）	—	—	—
有效 SE(3) 标签（时域，%）	—	—	—
有效 3D 流标签（点，%）	—	—	—
速度，全部 / 有效（cm/s）	—/—	—/—	—/—
遮挡，全部 / 有效（%）	—/—	—/—	—/—

图占位：图 S1——把真实机器人回合提升为度量 4D（示意）

左（共同设置）：指令及其被加下划线的物体短语（“put the mug in the sink”），以及两个外部视角第一帧上的 Grounding DINO 包围盒，其 WildDet3D 包围盒中心在基座坐标系中一致；小插图给出 PointWorld 优化后的相机位姿与原始位姿的对比。**上行（因果输入路径，蓝）**：帧从左到右到达；SAM 2 向前传播掩码，WildDet3D 把每个带掩码的帧提升为度量 3D 包围盒；输出的位姿画为带可用时刻标记的坐标轴；空掩码显示一个明确的 “缺失” token。没有箭头指向过去。**下行（离线标签路径，橙）**：向前与向后传播的掩码，映射到同一物体坐标系的逐帧包围盒，由鲁棒平滑器融合并保留突变事件（抓取）的两条位姿轨迹，50 ms 时域上的累计 SE(3) 标签 $(\mathbf{d}_h, \phi_h)$；另一分支在每个网格图像块中选取离块中心最近的 PointWorld 轨迹，画出其在 PointWorld 记录时刻的 3D 位移，无效点以灰色显示。竖直虚线标出机器人与目标的首次接触，掩码标签对照在其后去掉世界标签。**右**：一个训练样本 = 因果输入（上）+ 带掩码的标签（下）。使用一段真实 DROID 帧序列，只用矢量叠加。

图 S1. 把 DROID 提升为度量 4D 监督。指令中提到的物体被框出并跟踪。输入以只向前的跟踪重现部署条件，标签则使用整个回合、双向跟踪与平滑，以及 PointWorld 的 3D 轨迹。标签不改写输入，无效标签屏蔽其损失。

B.2 目标及其位姿

DROID 不提供物体位姿，其指令只说出被操作物体的名字而不标出它。我们把指令中提到的物体作为目标，即依存句法分析器提取的主要动词的直接宾语（“put the mug in the sink” 中的 “the mug”），每个回合一个持续存在的实例。Grounding DINO [26] 在该短语得分首次达到 0.35 的帧中给出包围盒，SAM 2.1 [32] 跟踪其掩码。对每个掩码非空的帧，我们以紧致 2D 包围盒、RGB 帧与固定内参提示 WildDet3D [18]。它从单张图像、用自身的几何估计而不借助外部深度预测度量 3D 包围盒，PointWorld 优化后的外参把包围盒映射到基座坐标系。当两台外部相机给出的包围盒中心在基座坐标系中相距 5 cm 以内时，我们接受该包围盒。指令中没有物体、有多个物体或物体非刚性的回合，以及没有被接受的包围盒的回合，都被排除。空掩码记为缺失观测，我们不用上一个位姿填补。

物体坐标系。 3D 包围盒只在其对称性范围内确定坐标系，检测器在相邻帧之间可能排列或翻转其坐标轴。因此我们把每个新包围盒映射到与上一个有效估计最接近的等价坐标系（保持其尺寸的坐标轴排列与符号翻转），从而为每个回合固定一个物体坐标系。经过这一步后仍然存在的相邻帧间超过 45° 的旋转跳变（占 [X.X]% 的帧）被标为无效，而不是被平滑。与仿真中一样，对称目标绕对称轴的旋转被排除在损失之外（第 3.3 节）。

B.3 因果输入与离线标签

因果输入。 SAM 2.1（Hiera-small）因果地传播掩码，WildDet3D 以全精度提升每个带掩码的帧，使估计不依赖于 batch 的组成。每次查询只处理新到达的帧，并追加其估计而不改写之前的估计。空掩码、被拒绝的包围盒与旋转跳变把输入有效性置为假；训练使用这些自然出现的缺失状态，不做合成的随机丢弃。对没有 CAD 模型或参考视图的物体，真机使用同一路径（附录 A.2）。

离线标签。 标签使用整个回合与同一目标短语。SAM 2 向前和向后传播掩码，我们接受两个掩码 IoU 至少为 0.5 的帧。两个方向的包围盒进入同一个鲁棒平滑器：Huber 代价，位姿残差以 5 mm 与 3° 缩放，速度变化残差权重为 0.1。在空缺处以及超过 0.2 m/s 或 1 rad/s 的速度跳变处省略速度项，以保留突变事件。二十次流形 Gauss–Newton 迭代优化该代价，两个包围盒相差超过 20 mm 或 15° 的帧为无效。目标标签是离线轨迹内的 $\tilde{\mathbf{p}}_{t+h} - \tilde{\mathbf{p}}_t$ 与 $\mathrm{Log}(\tilde{R}_{t+h}\tilde{R}_t^\top)^\vee$。由于它们不是离线未来减去因果估计，因此不会吸收对当前位姿的修正。只有当参考位姿与未来位姿都有效、且身份与物体坐标系相同时，一个时域才有效。

场景流。 PointWorld 的轨迹已经在基座坐标系中表示。对网格中的每个点，标签取其初始投影在该点所在图像块内离该点最近的已发布轨迹，前提是该轨迹初始可见、在图像内有有效的正深度，并与其最近像素处的深度相差在 20 mm 以内。没有这样的轨迹的图像块为无效，我们不用邻近块填补。标签是轨迹在每个记录时刻相对其初始位置的位移，可见性取自 PointWorld。被遮挡、出图像或深度无效的未来点屏蔽其位移损失，只监督其可见性。所选轨迹到图像块中心的距离中位数为 [0.5] px（第 95 百分位为 [9] px）。

接触与外部运动。 机器人与目标的首次接触是目标包围盒首次进入由机器人运动学得到的夹爪手指几何 1 cm 范围内的那一帧。若目标在该接触之前、在其 400 ms 时域内移动超过 1 cm 或 5°，则该窗口为*外部运动*窗口，表 S3 报告其比例。表 S4 中的掩码标签对照在首次接触之后去掉所有世界标签，并保留动作损失。它保留了预训练低数据增益的 [XX]%，因此 [这一增益的大部分并非来自预测机器人如何移动目标]。

有效性偏差。 PointWorld 的轨迹对静态表面的覆盖比对快速运动表面更完整，被接受的包围盒偏向未被遮挡、纹理丰富的目标。表 S3 比较全部窗口与有效窗口之间的目标速度与遮挡情况。表 S4 中的标签来源对照用从 2D 对应关系 [30] 结合单目度量深度 [41] 提升得到的流替代这些轨迹，后者覆盖图像的更大部分。

B.4 标签质量

我们在四十个片段上检查标签，其中十四个用于开发、二十六个留出，每个片段五个锚点。这些片段覆盖七个层次：静止目标、平滑平移、旋转、接触或打滑、遮挡与恢复、外观较弱，以及对称或铰接部件。留出片段未用于调整估计器。在对 [200] 个随机回合的人工检查中，被接受的包围盒在 [XX]% 的回合中落在预期目标上。前缀截断与未来替换实验证实，已输出的输入、有效性、身份与参考几何不随未来帧改变。独立的人工标注关键点与多视角几何在约束充分处提供参考，其他地方我们把物理精度标为未验证。在留出片段上，因果路径的平移与旋转误差中位数为 [X] mm 与 [X]°，离线路径为 [X] mm 与 [X]°。身份错误出现在 [X]% 的锚点上，被接受窗口中有 [X]% 为误接受，标签覆盖 [XX]% 的窗口。这次检查用了 [X] 小时的标注，提升整个 DROID 用了 [X] GPU 小时。在图像中静止的表面

表 S4. **初始化的受控比较。**每行从各自的初始化出发，用 10/25/50/100% 的 Dynamic-14 示范后训练仿真模型（留出 SR，%，三个后训练种子）；通用初始化即 SE(3)-WAM 所用的初始化。最后几列为各基座在留出 DROID episode 上最后一个时域的预测误差：目标平移（mm）与旋转（°，相对平滑标签），以及相对 PointWorld 轨迹的流端点误差（mm）。对照基座按试点规模预训练，并与相同预算的世界—动作基座比较（附录 B.5）。

	Dynamic-14 SR，示范比例				DROID 留出		
初始化	10%	25%	50%	100%	mm	°	流（mm）
仅通用视觉初始化（SE(3)-WAM ）	—	—	—	—	–	–	–
仅动作基座，相同 episode	—	—	—	—	–	–	–
世界—动作基座，单目深度提升的流	—	—	—	—	—	—	—
世界—动作基座，接触后屏蔽世界标签	—	—	—	—	—	—	—
世界—动作基座，试点规模	—	—	—	—	—	—	—
世界—动作基座（真机基座）	—	—	—	—	—	—	—

图占位：图 S2——训练方案与规模

(a) 仿真扫描。y：开发集 SR；x 分组：两种主干规模；每组内在相同样本量下的四根柱：$(B_0, 0.5\eta_0)$、(B_0, η_0)、$(4B_0, \eta_0)$、$(4B_0, 2\eta_0)$；细化结果为小菱形；选定配置以星号标出。**(b) DROID 基座。**x：训练样本数（对数）；y：留出集最后一个时域的目标平移误差（左轴，mm）与流端点误差（右轴，mm）；细线为两个试点规模，粗线为主训练；标记选定的检查点；水平点线：同一历史的匀速外推。

图 S2. 仿真模型（a）与 DROID 基座（b）的训练方案与规模。

上，所选 PointWorld 轨迹在各时域上的位移为 [0.9] 与 [5.8] mm（中位数与第 95 百分位），而用单目深度提升的流为 [18] 与 [72] mm，其尺度随时间漂移。在运动子集上，两种来源都没有参考，我们报告两者与一个前向—后向一致的 2D 跟踪器之间的一致性。

B.5 训练方案与规模

仿真模型。 SE(3)-WAM 从通用视觉初始化出发，以表 S2 的方案在 Dynamic-14 上训练。我们在相同训练样本数下扫描两种主干规模（参考规模以及固定宽度、加深到约两倍参数的规模）、两种全局 batch（B_0 与其四倍）以及每种 batch 两种学习率（B_0 时为 $\{0.5, 1\}\eta_0$，较大 batch 时为 $\{1, 2\}\eta_0$），再在每种规模的最佳配置周围做 [四] 次局部细化，全部在开发集场景上选择（图 S2a），以确定其规模与方案。

DROID 基座。 基座使用相同的结构与初始化，只使用真实数据。我们训练了两个试点规模，约为仿真主干的两倍与四倍，在按层抽取的四分之一训练窗口上训练一遍。我们依据留出集上的预测与动作误差，在一块 RTX 5090 的部署预算（p95 出动作时间不超过 200 ms，且没有超过 250 ms 的调用）下选择规模。选定的规模（主干参数 [XX]M）在全部训练窗口上预训练一次，共 [四] 遍，全局 batch 为 [256]，使用 AdamW、2.5% 预热以及余弦衰减到峰值学习率的 0.1。开发集损失最低的检查点即为基座（图 S2b）。我们以较小的试点规模与预算训练只用动作、标签来源与掩码标签三个对照，并与同规模的世界—动作基座比较（表 S4）。

B.6 独立的后训练与对照

真机策略从选定的基座初始化，只在传送带示范上微调。基座是在检测器位姿上预训练的，而传送带策略接收基于模型的跟踪器给出的位姿；微调使历史编码器适应跟踪器，我们没有单独测量这一位姿来源变化的代价。仿真权重不用于初始化任何真机策略，基座也不接触仿真数据。每个策略创建自己的优化器、学习率计划、仅用于训练的归一化与读出头，不兼容的动作或状态投影在每个对照中都以相同种子重新初始化。不使用基座的参考策略从通用视觉初始化出发，在相同示范上微调，在开发试验上进行相同的搜索（[三] 种学习率与两种训练长度），并采用相同的评测。仿真中的受控比较以下游方案、与通用初始化相同的数据比例在 Dynamic-14 上对基座做后训练。只用动作的对照在相同窗口上预训练 R0，因此其世界查询没有目标。标签来源对照只替换流标签，掩码标签对照在首次接触后去掉世界标签（表 S4）。

C Dynamic-14

C.1 任务、角色与误差项

我们在 MuJoCo 与 robosuite [38, 61] 上构建了 Dynamic-14 ，它包含五个任务族中的 14 个任务（图 S3）。表 S5 列出其成功条件，表 S7 列出其场景取值范围。我们将发布这些任务、通过筛选的场景、成功判定与示范。

角色与临界领先时长。 表 S6 把每个任务中的物体分配到第 3.1 节的两种角色。目标是其位姿误差进入接触或容纳容差 ε 的物体，环境由只需以间隙 m 避开的物体组成。因此移动料箱是目标，因为它的位姿决定能否放入。穿越任务中的导线同时扮演两种角色：它在入口处的位姿是目标，因为棒必须在那里对准到 30 mm 以内；它沿环路的几何是环境，因为任何接触都会失败。该表还给出每个任务的速度及其临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$（附录 G.5），最后一列列出每个任务涉及的误差项（式 3 与附录 G.2–G.3）。传送带与平移目标决定速度与领先时长；旋转目标、SE(3) 放置与导线使朝向进入接触；斜坡、低摩擦与撞击器产生外推无法预料的运动；遮挡物、导线、托盘与撞击器决定间隙，遮挡物还会去掉历史。

我们在每个 2 ms 的物理步、按表 S5 中要求的顺序检查成功，被中断的持续条件会重置其计数。终止事件分为五类，分别报告。*无效*事件是仿真器状态损坏。*边界*事件是离开工作空间或下游区域、掉落或目标时间窗过期。*安全*事件是不安全接触、过大的边缘冲量、触碰导线、释放冲量、机器人过早接触、无支撑的托盘接触或被撞击器卡住。*任务违规*是在目标外释放、路径偏离或倒退、过早释放、偏转而未捕获、倾倒、缺少或多出撞击，或出射运动改变不足。最后一类是*超时*。每个任务族在每个物理步按固定顺序检查其事件，并保留第一个终止事件。按任务等权的得分对每个任务赋予相同权重，包括某些方法从未成功的任务。

C.2 场景与示范

我们对连续范围均匀采样，对离散选项等概率采样，然后进行物理可行性检查。评测回放存储下来的已通过场景。简谐平移遵循 $\mathbf{p}(t) = \mathbf{c} + (0, v_y, 0)t + (A_x \sin(2\pi f_x t + \phi), 0, 0)$，其中 $\phi \sim \mathcal{U}[-\pi, \pi]$。捕获任务的目标从静止开始，在 $[5, 15]^\circ$ 的斜坡上受重力与摩擦作用运动。只有当目标在开始时至少可见八帧、被完全遮挡 0.5–3.0 s、之后再次至少可见三帧时，我们才接受一个遮挡场景。

训练集包含 11,200 条示范，每个任务 800 条。它们由使用特权仿真器状态的脚本专家生成，而学习型策略只接收第 3.2 节中的输入。我们以 20 Hz 记录示范，包含相机图像、深度、机器人状态、已发

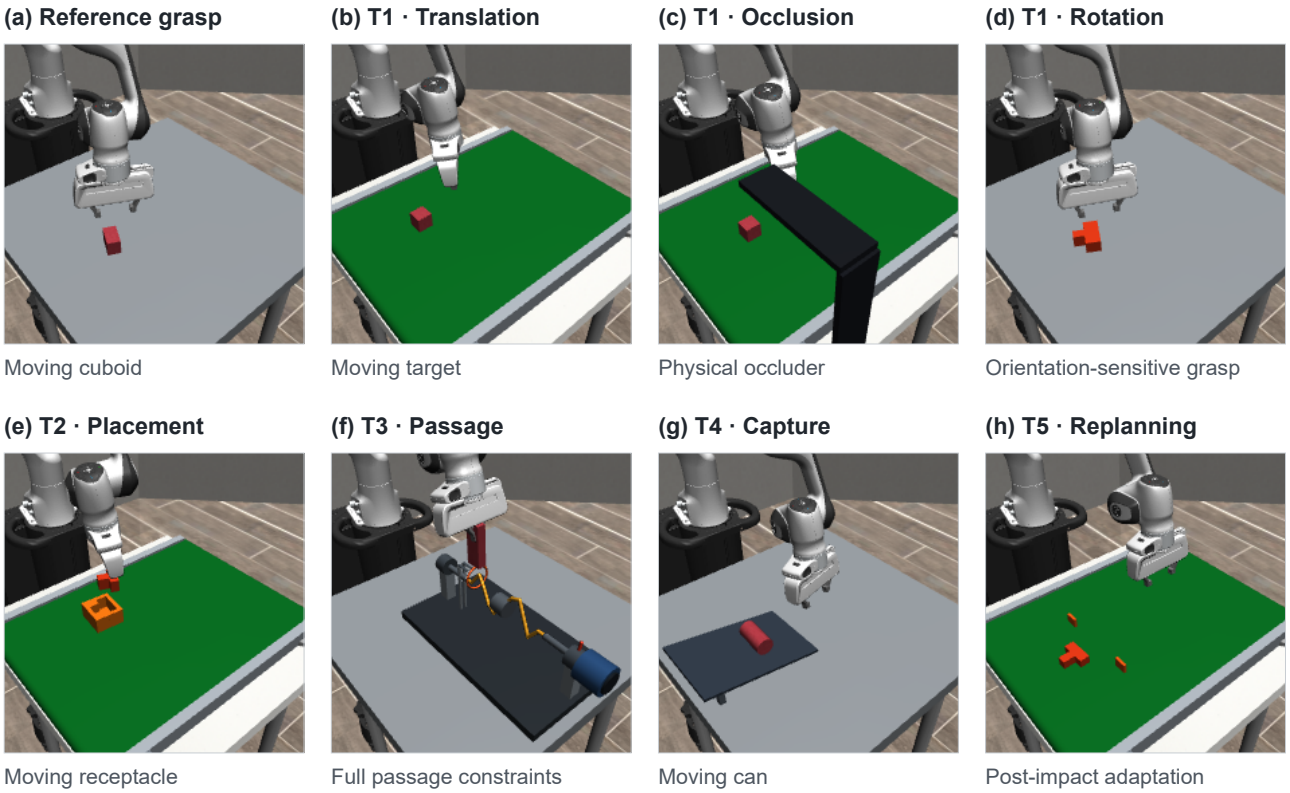


图 S3. Dynamic-14 的观测。八个示例涵盖参考抓取，抓取平移、被遮挡或旋转的目标，放入移动料箱，沿旋转导线穿越，捕获滚动物体，以及撞击后抓取。每个子图是一个开发集场景最后观测到的、未裁剪的 224×224 主视角 RGB。表 S5 列出全部 14 个任务。

出的指令，以及目标位姿与场景几何的仿真真值，并据此计算未来标签、其有效掩码以及按延迟平移的指令标签。在仿真中，跟踪器的物体模型是仿真器中目标的网格，对应真机上的 CAD 模型。

C.3 协议与扫描

执行器。 所有方法都在同一个异步执行器下运行。每 100 ms 仿真时间，或在上一次推理结束时（取较晚者）请求一个动作块，每条指令在其生效时刻执行。新的动作块替换上一个动作块中尚未执行的部分；可用时生效时刻已过的指令被丢弃并计数。没有生效时刻概念的方法，其动作块被视为在推理结束时发出，这也是它们的部署方式。

实时协议。 除非另行说明，推理期间物理仿真按每次查询从该方法在一块 RTX 5090 上实测的延迟分布中采样的延迟推进（附录 D.4）。撞击后抓取任务本身还内置 50 ms 的指令延迟。表 S14 报告三种替代协议。在*暂停*协议下，仿真等待推理完成，许多仿真基准都是这样做的。在*等延迟*协议下，无论自身速度如何，每个方法都被计入相同的延迟，即 SE(3)-WAM 的 p95。在*原执行器*协议下，每个基线保留其论文中的执行方案。

延迟。 在协议本身的延迟之外，推理后再插入 0、50、100、150 或 200 ms 的附加延迟，期间物理仿真继续推进。

速度。 场景中所有外部速度（传送带、料箱、导线以及简谐运动的速率）都乘以 $s \in \{0.5, 1, 1.5\}$。在某个系数下变得物理不可行的场景对所有方法都排除，我们报告剩余数量。

表 S5. Dynamic-14 十四项任务的成功条件，阈值为我们任务实现中的取值。任务须依次通过各阶段，且不触发终止性失败。所有任务的控制频率为 20 Hz，物理仿真步长为 2 ms；下列时长均为物理时间。COM 表示质心。

任务	依次满足的成功条件	时限
grasp; t1_belt, t1_xyz, t1_so3, t1_occ	接近至 0.10 m 内；双侧指垫接触持续 0.05 s；碰撞几何体底部高于支撑面至少 0.05 m；接触与间隙保持 0.50 s。T1 分别加入传送带驱动、平移、旋转或实体遮挡物。SO3 无额外的成功角度阈值；OCC 中与遮挡物发生不安全接触即终止。	160 步 8 s
t2_trans	接近至 0.10 m 内。物体的完整碰撞几何体位于容器内：平面间隙和底面间隙均 ≥ -0.002 m，顶端不高于容器开口。释放要求张开指令 < -0.5 且无指垫接触。相对线速度和角速度分别 ≤ 0.08 m/s、0.8 rad/s，持续 0.10 s，随后稳定停留 0.50 s。	200 10 s
t2_se3	接近至 0.05 m 和 0.12 rad 内。完整纳入 T 形容器：平面间隙 ≥ 0.002 m，底面间隙位于 $[-0.002, 0.002]$ m，倾角 ≤ 0.05 rad，顶端低于开口。释放后，相对线速度和角速度分别 ≤ 0.02 m/s、0.04 rad/s，持续 0.10 s，再停留 0.50 s。0.12 rad 阈值用于接近阶段。	200 10 s
t3_phase	回合开始时杆已被抓住。相位对齐要求距离 ≤ 0.090 m、环方向误差 ≤ 0.20 rad。在进度 ≤ 0.15 时进入 0.030 m 范围；历史最大进度先达到 ≥ 0.60，再达到 ≥ 0.85，且距终点 ≤ 0.055 m。	420 21 s
t3_full	双侧接触持杆 0.05 s，然后完成上述相位阶段。在后续采样时刻，当前进度仍须 ≥ 0.85，且离路径和终点均至少 0.045 m。最后张开夹爪（< -0.5）且无指垫接触。退出前释放判为失败。	640 32 s
t4_sphere	接近至 0.10 m 内；首次合格接触须在离开斜坡后发生；成功前接触托盘即判为失败。双侧夹持的名义时长为 25 ms（12 个物理采样步，24 ms）。以首次达到双侧夹持条件时的高度为基准，将质心抬升 0.05 m，并保持接触和高度 0.50 s。	120 6 s
t4_sphere_tabletop; t4_slider	接近至 0.10 m 内；接触须发生在离开斜坡后、仍受支撑、位于捕获区且平面速度 ≥ 0.08 m/s 时。双侧夹持持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m；随后保持接触和高度 0.50 s。	120 6 s
t4_can	采用相同的受支撑捕获顺序。首次指垫接触前，若罐体轴线与竖直方向的点积绝对值 > 0.45，则按不稳定倾倒判为失败。配置不要求夹爪沿横向闭合。	120 6 s
t5_replan	机器人接触前，所选侧恰有一个撞击组完成。在物理撞击结束时间戳后 30 ms，按分支方向取符号的横向速度 ≥ 0.035 m/s，偏航角速度 ≥ 0.35 rad/s。接近至 0.10 m 内；双侧夹持且抓取轴误差 $\leq 18°$，持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m，并稳定夹持 0.50 s。撞击组时滞为 12 ms，最长接触时长为 0.10 s。	120 6 s

间隙与网格分辨率。 间隙扫描使用穿越任务，其导线是环境物体。棒的环与导线之间的自由间隙取 [X, X, X, X, X] mm，涵盖 14^2、28^2 与 56^2 流网格在工作空间中的间距（[X]、[X] 与 [X] mm），物体与运动保持不变。放置容差关乎目标精度（ε），不属于此扫描。

位姿噪声。 我们向跟踪器过去的位姿估计加入高斯噪声（附录 F.2）。

遮挡与静止。 0.5、1、2 与 3 s 的遮挡以及一个无遮挡对照用于隔离历史空缺。静止目标变体冻结每个任务的外部运动，作为第 4.4 节的静态对照。

C.4 数据划分与统计

所有设计决策都使用 1,400 个场景（每个任务 100 个）的开发集。我们在正文与本补充材料中报告的所有 Dynamic-14 数字都使用另外的 1,400 个留出场景；它们以相同的取值范围生成，使用不出现在任何训练、验证或开发回合中的新源种子。按种子递增顺序的前 100 个可行场景构成每个任务的集合。

表 S6. **Dynamic-14 各任务的角色、容差与临界领先时长。**目标是位姿误差进入接触或容纳容差 ε 的物体；环境是只需以间隙 m 避开的物体。速度取自表 S7 的采样范围（捕获任务取离开斜坡时的速度）；临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$ 按速度中位数给出。误差项：任务涉及的误差分解项。v：目标运动。$r\theta$：朝向影响接触。e_{dyn}：非匀速运动（谐波、重力、摩擦、撞击）。m：须避开某个环境物体。occ.：历史缺失。delay：任务内置的指令延迟。

任务	代号	目标	环境	ε (mm)	$\|\mathbf{v}\|$ (m/s)	$\Delta^\star$ (ms)	m (mm)	误差项
谐波抓取	grasp	物块	桌面	[X]	0.03–0.20	[X]	–	v, $r\theta$, e_{dyn}
传送带抓取	t1_belt	零件	传送带	[X]	0.04–0.10	[X]	–	v
平移抓取	t1_xyz	零件	桌面	[X]	0.04–0.15	[X]	–	v, e_{dyn}
旋转抓取	t1_so3	零件（$\omega \le 1.2$ rad/s）	桌面	[X]	0.04–0.15	[X]	–	v, $r\theta$, e_{dyn}
遮挡抓取	t1_occ	零件	遮挡罩	[X]	0.04–0.10	[X]	[X]	v, m, occ.
移动容器	t2_trans	容器	桌面	[X]	0.03–0.06	[X]	–	v
旋转容器	t2_se3	T 形容器	桌面	[X]	0.03–0.06	[X]	–	v, $r\theta$
导线穿越	t3_phase	导线环（入口）	旋转导线	30	[X]	[X]	扫描	v, $r\theta$, m
导线穿越（完整）	t3_full	导线环（入口）	旋转导线	30	[X]	[X]	扫描	v, $r\theta$, m
小球捕获	t4_sphere	小球	托盘、斜坡	[X]	[0.4–0.7]	[X]	[X]	v, e_{dyn}, m
小球捕获（桌面）	t4_sphere_tabletop	小球	桌面、斜坡	[X]	[0.4–0.7]	[X]	–	v, e_{dyn}
滑块捕获	t4_slider	滑块	桌面、斜坡	[X]	[0.4–0.8]	[X]	–	v, e_{dyn}
罐体捕获	t4_can	罐体	桌面、斜坡	[X]	[0.4–0.7]	[X]	–	v, $r\theta$, e_{dyn}
撞击后抓取	t5_replan	零件	撞击器	[X]	0.12–0.14	[X]	[X]	v, $r\theta$, e_{dyn}, m, delay

最终模型、其消融以及表 3 中的变体使用训练种子 0、1 与 2。附录 F 中的筛选变体与各基线使用种子 0。在开发集场景上，同一配置的三个训练种子在 SR 上最多相差 [7.4] 个百分点。这一差异主要来自导线穿越任务，其成功率在不同种子之间从 [0] 到 [71]% 不等，因此我们不解读几个百分点的单种子差异。三个种子太少，无法重采样，因此我们先在每个场景上对种子取平均，再在每个任务内对留出场景做 bootstrap（各方法联合重采样），得到配对 95% 区间。区间落在 ±2 个百分点以内的差异视为持平。

C.5 评测指标

按任务等权的成功率为

$$\mathrm{SR}(m) = \frac{1}{14}\sum_{k=1}^{14}\frac{1}{n_k}\sum_{i=1}^{n_k} y_{mki}, \tag{S3}$$

其中 y_{mki} 是方法 m 在任务 k 的场景 i 上的二值结果。一个场景的*可行接触时间窗*是满足任务第一个成功阶段的接触在运动学上可能发生的时刻集合，由目标真值轨迹与机器人可达工作空间计算。*接触时刻误差*是首次接触时刻到该时间窗的距离，在时间窗内为零。*首次接触时的位置误差*是该时刻末端到目标抓取坐标系的距离。两者都只在发生接触的回合上报告；没有接触的失败仍计入 SR 的分母，其接触误差记为缺失而不是零。*碰撞*统计安全事件。*出动作时间*是从观测到达到第一条指令可用的墙钟时间（附录 D.4），*动作时龄*是生效时刻减去采集时刻。

表 S7. 场景的提议采样范围。除另有说明外，长度、线速度、角度和角速度的单位分别为 m、m/s、rad 和 rad/s。除注明的斜坡局部偏移外，位置均采用世界坐标。可行性检查前，连续区间内均匀采样，离散选项等概率采样。评测重放已存储的接受场景，其分布未必仍为均匀分布。谐波运动中心不等于初始位置。

任务	初态提议范围	运动或事件参数
grasp	谐波运动中心 $c_x \in [-.08, .08]$、$c_y \in [-.26, -.19]$、$z = .822$；偏航角 $[-1.1, 1.1]$。	$v_y \in [.025, .125]$, $A_x \in [.015, .035]$, $f_x \in [.3, .7]$ Hz; $\omega_z \in [-1.2, 1.2]$.
t1_belt	目标 $x \in [-.08, .08]$、$y \in [-.26, -.18]$、$z = .822$；姿态为单位旋转，初始 twist 为零。	传送带 $v_y \in [.04, .10]$。
t1_occ	目标提议范围同传送带任务；遮挡罩位于 $(.322, -.29, 1.20)$。	传送带速度范围相同；间隙参数为.20；实体遮挡。
t1_xyz	谐波运动中心 $c_x \in [-.025, .025]$、$c_y \in [-.24, -.20]$、$z = .818$；偏航角 $[-.35, .35]$。	$v_y \in [.04, .09]$, $A_x \in [0, .03]$, $f_x \in [.25, .65]$ Hz; $\omega_z = 0$.
t1_so3	同 XYZ。	平移相同；$\omega_z \in [-1.2, -.4] \cup [.4, 1.2]$，正负等概率。
t2_trans	目标容器 $x \in [-.13, -.08]$、$y \in [-.18, -.12]$、$z = .825$；姿态固定。	目标容器 $v_y \in [.03, .06]$；无旋转。
t2_se3	目标容器的 x, y 范围相同，$z = .804$；偏航角 $[-.3, .3]$。	目标容器 $v_y \in [.03, .06]$；$\omega_z \in [-.25, -.08] \cup [.08, .25]$，正负等概率。
t3_phase	杆的位置 $x, y \in [-.03, .03]$、$z = .870$，偏航角 $[0, 2\pi]$；导线相位 $[-.25, .35]$。	导线中心 $(.10, -.02, .94)$；绕世界 X 轴旋转，$\omega_x = -\{2.5, 3, \ldots, 7.5\}°$/s（11 个等概率取值）。
t3_full	杆位于 $(-.05, -.02, 1.04)$，姿态为单位旋转；导线相位范围相同。	导线旋转相同；启用托架及释放要求。
t4_sphere	斜坡局部偏移：横向 $[-.015, .015]$，纵向 / 法向 $(-.145, .030)$；坡沿 $(.06, -.02, 1.10)$。	从静止开始由重力驱动；在 tick 0 释放闸门；坡度 $[5, 15]°$；目标 / 斜坡滑动摩擦系数 $[.7, .9]$；无支撑捕获。
t4_sphere_tabletop	横向 $[-.015, .015]$，纵向 / 法向 $(-.124, .034)$；坡沿 $(0, -.06, .808)$。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.7, .9]$，桌面摩擦系数.35。
t4_slider	横向 $[-.015, .015]$，纵向 / 法向 $(-.129, .024)$；受支撑斜坡。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.025, .045]$，桌面摩擦系数 $[.012, .018]$。
t4_can	横向 $[-.010, .010]$，相对斜坡轴线的偏航角 $[-4, 4]°$；纵向位置由闸门几何及罐体在该姿态下的包围范围确定。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.25, .45]$，桌面摩擦系数 $[.09, .15]$。
t5_replan	$x \in [-.005, .005]$、$y = -.29$、$z = .812$；偏航角 $[-.08, .08]$；初始 twist 为零。	传送带 $v_y \in [.12, .14]$；在 $y = -.13$ 处等概率触发左 / 右撞击器；行程.098，脉冲.35 s，执行器缩放系数 $[1, 1.1]$，力上限 4 N；指令延迟 50 ms。

D 基线、外部基准、真机与计时

D.1 基线

共同条件。 表 S8 汇总各基线的适配。每个基线保留其官方结构、输入、动作块与初始化。ACT 与 Diffusion Policy 从零训练，$\pi_{0.5}$ 从 `pi05_base` 微调，其余方法从其发布的权重出发。它们都在相同的 11,200 条示范上训练，示范中的指令通过同一个笛卡尔控制器映射到各自的动作空间。Dynamic-14 除主视角外还渲染 224×224 的腕部相机，配方使用腕部视角的方法会接收它。SE(3)-WAM 与运动学基

线只使用主视角。所有方法都在附录 C.3 的共享执行器与实时协议下运行，表 S14 另外给出它们原有的执行器。

训练。 每个基线按其官方方案训练到论文公布的更新次数，并以种子 0 训练一次。我们只改变了数据加载与动作空间。对于 DreamVLA，我们同时运行了其原始的 40 epoch 计划与一个 20 epoch 的余弦计划，并报告在开发集场景上更好的那个。相比之下，SE(3)-WAM 的配置是通过附录 F 的组件研究选出的，这是基线没有得到的搜索，而且其各变体使用三个训练种子。

输入。 PUMA [12] 接收在渲染帧上计算的历史光流。DreamVLA 接收七帧因果 RGB、末端位置与朝向、手指位置以及固定的任务文本，以十步 DDIM 与 1.5 的无分类器引导采样。OpenWAM-α 接收当前 RGB 视角、关节值、夹爪开度与任务文本，在关闭视频解码的情况下联合生成视频与动作。DynamicWAM 接收其光流历史与运动学描述子。

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从同一个因果跟踪器接收附录 A.1 中的八个运动 token，以及相同的有效标志与缺失状态嵌入。一个两层 MLP 把这些 token 映射到模型宽度。对 $\pi_{0.5}$，我们把它们附加在前缀中图像 token 之后，供动作专家读取；对 DynamicWAM，它们并入其运动学描述子。MLP 的输出层以零初始化，因此训练从基础模型的行为开始，训练方案也沿用基础模型。

运动学基线。 *SE(3)-WAM*，*CV* 输入与 SE(3)-WAM 共享跟踪器、条件 token 与动作分支，但没有世界监督。动作分支改为接收跟踪位姿在各生效时刻的匀速外推作为输入 token，模型以相同的方案在相同的数据上训练。附录 F.3 另有一个接收这些 token 并保留世界监督的变体。卡尔曼拦截器没有学习组件：一个匀加速卡尔曼滤波器 [4] 在跟踪位姿上运行，其过程噪声在开发集场景上调整，并预测目标轨迹。拦截器在该轨迹上选择机械臂在延迟估计之后、在速度限制下能到达的最早一点，沿专家的预抓取偏移接近它，并在预测时刻合拢、释放或对准。它在每次查询时重新规划，并使用专家针对任务的抓取、放置与入口坐标系。

D.2 DOMINO 与 LIBERO

DOMINO [12] 包含 35 个任务，分为拦截与跟踪两种交互类型，并有三个动力学等级：匀速、多项式轨迹，以及带突变的随机分段。我们在干净设置下、以 [0.1] 的速度系数，在全部三个等级上使用其在 Franka 本体上的 [N] 个单臂任务，使用官方示范与基准自带的评测器，每个任务、每个训练种子进行 100 个闭环回合。我们报告 SR 与 DOMINO 的操作得分（MS），后者以离开工作空间或视野以及碰撞的惩罚缩放路线完成度。表 1 中的 DOMINO 一列是按任务等权的 SR。在 LIBERO [25] 上，我们使用 Spatial、Object、Goal 与 Long 四个套件，每个十个任务，每个任务 50 个评测回合，本文各变体取三个训练种子、基线一个，并使用发布的示范与初始状态。在这两个基准上，SE(3)-WAM 都从与 Dynamic-14 相同的通用初始化训练，并使用各领域自己的归一化。跟踪器的物体模型是指令首先作用的物体的仿真网格，没有有效位姿的查询（LIBERO 上 [XX]%，DOMINO 上 [XX]%）使用附录 A.1 的缺失状态嵌入。该网格是基线得不到的特权信息，因此表 S9 还报告使用检测器位姿的 SE(3)-WAM 。该表分别报告各等级与各套件。

表 S8. **基线适配。**所有方法均在相同的 11,200 条示范上、以其原论文的输入训练，并在附录 C.3 的共享执行器下运行。更新数 × batch 沿用官方训练配方。Exec.：原论文的执行方式（重规划前每个动作块执行的指令数），仅用于表 S14 的原执行方式对照。参数量：可训练参数，不含冻结的编码器。Seeds：训练种子数。

方法	初始化	输入	更新数 × batch	执行	参数量	种子
ACT [58]	从头训练	主视角 + 腕部 RGB、机器人状态	50,000 × 32	时间聚合	[X]	1
Diffusion Policy [10]	从头训练	主视角 + 腕部 RGB（原论文观测长度）、机器人状态	50,000 × 32	8	[X]	1
$\pi_{0.5}$ [31]	`pi05_base`	当前主视角 + 腕部 RGB、机器人状态、任务文本	30,000 × 256	10	[X]	1
$\pi_{0.5}$ + SE(3)	`pi05_base`	同 $\pi_{0.5}$ + SE(3) 运动 token	30,000 × 256	10	[X]	1
DynamicVLA [46]	发布的 DOM 检查点	帧 $[-2, 0]$、机器人状态、任务文本	50,000 × 44	流式	[X]	1
PUMA [12]	官方检查点	RGB、光流历史、机器人状态、任务文本	[X]×[X]	[X]	[X]	1
DreamVLA [55]	发布的组件	七个因果主视角 + 腕部 RGB 帧、机器人状态、任务文本	48,220 × 512	1	[X]	1
OpenWAM-α [42]	官方基础模型	当前主视角 + 腕部 RGB、关节、夹爪、任务文本	34,490 × 192	32	[X]	1
DynamicWAM [29]	官方初始化	RGB、光流历史、运动学描述	40,000 × 128	16	[X]	1
DynamicWAM + SE(3)	官方初始化	同 DynamicWAM + SE(3) 运动 token	40,000 × 128	16	[X]	1
SE(3)-WAM，匀速外推输入	同 SE(3)-WAM	同 SE(3)-WAM，另加匀速外推 token，无世界监督	同 SE(3)-WAM	–	[X]	3
卡尔曼拦截器	无	跟踪得到的 SE(3) 历史、专家抓取坐标系	–	–	–	–
SE(3)-WAM	冻结的 MAE 编码器	当前主视角 RGB-D、SE(3) 历史、机器人状态	40,104 × 16	–	62.2M	3

图占位：图 S4——真机设置

左：工作单元照片：带夹爪的 Franka 机械臂、固定的第三人称 RGB-D 相机、腕部相机与传送带，标出基座坐标系与传送带上可抓取的区段。**右：**三个物体（边长不等的盒子、细长的罐子、带单个把手的杯子），训练实例与测试实例并排放置，每个标出其等价抓取；下方为每种带速（0.04、0.08、0.12 m/s）在首条指令时刻的一帧，标注实测延迟下的 $\|\mathbf{v}\|\Delta$。

图 S4. 真机设置：传送带工作单元以及三个物体的训练与测试实例。

D.3 真机

平台。 机器人是一台配备平行夹爪的七自由度 Franka 机械臂，通过带时间戳的笛卡尔接口以 20 Hz 控制（图 S4）。一台固定的 [RealSense D435] 以 [640 × 480] 与 [30] Hz 记录 RGB-D，每次实验前用棋盘格标定其外参。SE(3)-WAM 使用这一第三人称视角；按其方案要求，$\pi_{0.5}$ 还接收腕部第二台相机的图像。

任务与成功。 传送带把物体从机械臂旁带过。若两根手指在传送带的可抓取区段内稳定夹住物体，并把物体提离传送带保持至少 0.5 s，则试验成功。触碰或推动物体、单指夹持，以及物体离开工作空间后的抓取都算失败。

物体。 三个物体的朝向重要程度不同：一个边长不等的轻质纸盒，其对称性留下几种等价抓取；一个几乎轴对称的细长空饮料罐；一个带单个把手的轻质塑料杯。我们记录每个实例的质量、尺寸、材质、质心与等价抓取。测试试验使用未出现在任何示范中的实例，示范、开发试验与测试试验来自不

表 S9. **外部基准**（本文各变体三个训练种子，基线一个）。DOMINO：单臂任务按交互类型与动力学等级（L1 匀速、L2 多项式轨迹、L3 含突变的随机分段）分列的 SR（%），以及操作得分 MS；LIBERO：各套件 SR（%）。

	DOMINO						LIBERO				
方法	拦截	跟踪	L1	L2	L3	MS	空间	物体	目标	长程	平均
ACT	—	—	—	—	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—	—	—	—	—	—
PUMA	—	—	—	—	—	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，检测器位姿	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	—	—	—	—

同的实验时段。

速度。 传送带以 0.04、0.08 或 0.12 m/s 运行。我们在每组试验开始与结束时用编码器测量其速度，因为随着电机升温，传送带在一个时段内最多减速 [3]%。速度偏离名义值超过 5% 的试验会重做，并作为设备故障报告。夹爪在罐子上合拢约需 [XX] ms，这一时间计入附录 A.7 中延迟估计的执行延迟。

试验。 每个方法运行 180 次试验，每个物体与速度组合 20 次。所有方法使用相同的预生成试验键，它固定物体实例、速度以及从标定的可抓取区域中采样的起始位置与朝向。一个策略看不到的外部夹具设置并记录起始位姿。这些试验键构成三个平衡的组，每组 60 次试验。每组按自己的随机顺序运行，使设备漂移不与方法对齐，一个方法的每个微调种子运行一组。操作员手动复位场景。试验从第一个可用观测开始，没有空闲观测期，机器人可以随时运动。人工接触、安全停机与人工完成都算失败。在第一个可用观测之前出现的基础设施故障会重做并报告。

微调。 SE(3)-WAM 从 DROID 基座出发，在该任务的 [300] 条遥操作示范上以三个种子微调（附录 B.6）。不使用基座的参考策略从通用初始化出发，使用相同的示范、种子与搜索；$\pi_{0.5}$ 从 `pi05_base` 出发，在相同示范上以三个种子微调。跟踪器使用 [盒子的 CAD 模型以及罐子和杯子的参考视图]（表 S1）。

分析。 我们相对由传送带编码器计算的可行接触时间窗测量接触时刻误差，没有接触的失败仍计入 SR 的分母。表 S10 按物体、速度与组报告成功次数，并给出合并成功率的 95% 二项区间以及对试验键 bootstrap 得到的配对差值。由于物理与相机不同，我们把这些结果与仿真传送带任务分开报告。评测用了 [四] 天。SE(3)-WAM 的失败大多是 [在罐子上合拢过晚，因为夹爪遮挡罐子时跟踪器丢失其位姿]；在杯子上则大多是 [在把手一侧合拢的抓取]。

表 S10. **真机成功次数**，按物体与传送带速度（S、M、F：0.04、0.08、0.12 m/s；每格 20 次）及按组（每组 60 次）分列。每组包含全部物体与速度，由一个微调种子执行。All：每个方法 180 次试验的成功率（%）及 95% 二项分布区间。Δ：相对 SE(3)-WAM 的配对差值（百分点）及按试验键自助法得到的区间。

	盒			罐			杯			组				
方法	S	M	F	S	M	F	S	M	F	1	2	3	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，无 DROID 基座	—	—	—	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	—	—	—	—	—	—	–

表 S11. **单次查询的延迟分解**（SE(3)-WAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧）	—	—
图像编码	—	—
条件 token（缓存）	—	—
动作生成（无世界）	—	—
出动作时间（合计）	—	—
可选预测（不被读取）	—	—
生效时的动作年龄（真机）	—	—
超时比例（真机，%）	—	

D.4 计时

我们在一块 RTX 5090（32 GB）上为所有方法计时，这也是机器人的部署 GPU。对每个方法，计时在三段各八帧的观测序列上进行三十次预热调用与 300 次测量调用，在调用边界进行 CUDA 同步，并以轮换的方法顺序进行三轮；每个方法使用其发布版本的精度。出动作时间包括跟踪最新帧、编码图像与生成第一条指令，我们另外记录得到完整预测的时间。表 1 给出 p95 值，表 S8 给出参数量。在机器人上，日志记录采集、可用、预处理、推理开始与结束、进入队列、发出指令与生效的时刻。动作时龄是生效时刻减去采集时刻，我们报告其 p50、p95 与最大值，以及错过截止时刻的比例与峰值显存（表 S11）。Dynamic-14 的延迟扫描不同于墙钟部署，因为它在物理仿真推进的同时插入规定的延迟。

E 补充结果

E.1 逐任务结果与回合结局

表 S12 把表 1 中 Dynamic-14 的留出结果按任务拆分到每个方法，并给出 SE(3)-WAM 在每个任务上相对最强其他方法的配对区间。表 S13 报告回合如何结束。一个方法若以一种失败换另一种失败，例如以更少的碰撞换来更多的超时，只能在这里看出来。所有失败都留在成功率的分母中。

E.2 协议与延迟

表 S14 在另外三种协议下评估每个方法。暂停物理仿真去除了计算的代价。等延迟协议向每个方法计入 SE(3)-WAM 的 p95 延迟，从而把方法的速度与其利用时间的方式区分开。原执行器协议检验我们的共享执行器是否使某个方法处于不利地位。在暂停物理仿真时，SE(3)-WAM 与 [DreamVLA] 的差距为 [±X.X] 个百分点，在等延迟下为 [±X.X] 个百分点。原执行器使各基线的 SR 至多变化 [X.X] 个百分点。表 S15 给出扫描中每个附加延迟下的成功率，其中 SE(3)-WAM 与最强基线的两行即图 1（右）的数据。

表 S12. **Dynamic-14 各任务的留出成功率**（%），涵盖表 1 中的全部方法，本文各变体取三个训练种子的平均、基线训练一次，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。DrVLA：DreamVLA。OWAM：OpenWAM-α。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。CV：匀速外推输入的 SE(3)-WAM 。KF：卡尔曼拦截器。Det.：使用检测器位姿的 SE(3)-WAM 。Δ：该任务上 SE(3)-WAM 相对最强其他方法之差及其 95% 配对区间。任务代号见表 S6。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	DrVLA	OWAM	DWAM	DWAM+	CV	KF	Det.	本文	Δ [95% CI]
谐波抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
传送带抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
平移抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
遮挡抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
移动容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越（完整）	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获（桌面）	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
滑块捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
罐体捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
撞击后抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
任务等权	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—

E.3 负面与无差异结果

视觉历史。 表 S17 中的八种视觉历史没有一种比只用当前帧高出两个百分点以上。其中 [N] 种的区间落在 ±2 个百分点以内，[N] 种无定论，包括带度量位置的 RGB-D 窗口。冻结读出能从这些历史中恢复过去的目标位置，误差为 [X]–[X] mm，而 SE(3) 历史为 [X] mm。因此信息是存在的，但在我们的数据规模下，策略没有把它转化为度量运动。更大的数据集或专门的运动目标可能会改变这一点。

图像空间的未来。 作为世界目标，表 S20 中没有任何图像空间的未来（场景轨迹、稠密位移、编解码器运动向量、视频隐变量、冻结视频模型、深度、DINO 或动态 RGB）比不带环境的 SE(3) 未来高出 [X.X] 个百分点以上。它们的目标函数对像素或隐变量维度加权，而容差取决于度量误差。作为仅用于训练的目标加在选定的世界旁边时，深度、DINO 特征与运动区域 RGB 带来 [X.X] 个百分点。因此，外观作为场景查询的辅助目标是有帮助的，但不能替代度量的未来。

环境分辨率。 在粗粒度流的路径误差之上，28^2 与 56^2 网格以及物体采样的流与 14^2 网格相差在两个百分点以内，代价却高达其 [X] 倍；它们的优势只限于最窄的间隙。

耦合方式。 让世界读取动作（R3）或双向读取（R4），在任何延迟下都没有稳定地优于 R1（表 S23）。没有任何让动作读取世界的耦合方式比仅在训练中使用世界高出 [X.X] 个百分点以上。在同一网络中关闭世界损失（R0）相对 R1 损失 [X.X] 个百分点，因此增益来自监督而不是增加的查询。在 R1 中没有从世界到动作的边，因此在部署时计算预测不会改变动作，只会增加 [X.X] ms。在实时协议下，这种部署方式比只运行动作的部署低 [X.X] 个百分点。

未解决的任务。 放入旋转料箱的 SE(3) 放置任务（t2_se3）对所有方法都失败（表 S12）。[策略能到达料箱，但在它转开之前达不到其角度容差。]SE(3)-WAM 的任何变体都没有解决完整的导线穿越任务

表 S13. **结局类别**：Dynamic-14 留出场景（各类 episode 占比，%，种子平均，实时协议）。类别定义见附录 C.1；每行合计为 100。

方法	成功	安全	任务违规	边界	超时	无效
ACT	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—
卡尔曼拦截器	—	—	—	—	—	—
SE(3)-WAM，检测器	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—

图占位：图 S5——与实际发生对齐的预测

第 1–4 行：每种运动类型（传送带、旋转目标、滚动捕获、撞击后）预测误差居中的留出回合；**第 5 行**：一次失败。**列**：τ_t 处的查询帧；首条指令生效时刻 τ^{a} 处的帧；基座坐标系中的 3D 插图。**叠加**：蓝色过去的 SE(3) 位姿；橙色 $\tau_t + \delta_h$ 处预测的目标坐标轴与粗粒度环境流箭头；灰色同一物理时刻的真值位姿；紫色发出的夹爪轨迹；首次接触处的标记。每行下方的条带画出学习的 SE(3)、匀速与匀加速预测的平移与旋转误差随时域的变化。用红色标注第 5 行的失败原因。

图 S5. 世界读出头在留出回合上的预测，在物理时间上与真值和发出的动作对齐。第 1–4 行为每种运动类型预测误差居中的回合，第 5 行为一次失败。

（t3_full），该任务在穿越之外还要求抓取与释放棒，而 [OpenWAM-α] 在其中 [XX]% 的回合中成功。在以已抓住棒开始的穿越任务（t3_phase）上，SE(3)-WAM 的成功率在不同训练种子之间从 [0] 到 [71]% 不等。

其他失败。 图 S6a 中的曲线聚合在捕获任务上最弱（Spearman $\rho = [X.XX]$），因为这些任务的成功还取决于夹爪何时合拢；噪声交叉点位于无模型 $\sigma^{\star}$ 的 [X.X] 倍处。撞击后抓取从世界监督中获益最少（相对 CV 输入 [X.X] 个百分点），因为条件均值无法表示撞击的各种结果。检测器位姿损失 [X.X] 个百分点，主要在对称与细长的目标上。SE(3)-WAM 的其余失败大多是 [例如首次抓取失手后的超时]（表 S13）。

E.4 生效时刻的预测

图 S5 把查询、预测、真值、发出的动作与首次接触按物理时间戳对齐。这些示例展示预测误差在何处出现——例如撞击的瞬间或滚动物体离开斜坡时——以及它们如何转化为接触时刻与位姿误差。

表 S14. **评测协议对照**：Dynamic-14 留出场景（SR，%）。暂停：推理期间物理暂停，各方法使用其原论文的执行方式。等延迟：共享执行器，所有方法均计入 SE(3)-WAM 的 p95 延迟。原执行方式：实时协议下使用各方法自身的执行方式。实时：表 1 的协议。丢弃：实时协议下因过时而被丢弃的指令比例（%）。

方法	暂停	等延迟	原执行器	实时	丢弃 (%)
ACT	—	—	—	—	—
Diffusion Policy	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—
DynamicVLA	—	—	—	—	—
PUMA	—	—	—	—	—
DreamVLA	—	—	—	—	—
OpenWAM-α	—	—	—	—	—
DynamicWAM	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	–	—	—
卡尔曼拦截器	—	—	–	—	—
SE(3)-WAM，检测器位姿	—	—	–	—	—
SE(3)-WAM	—	—	–	—	—

E.5 补充视频

补充视频展示 SE(3)-WAM 与 $\pi_{0.5}$ 在全部三种带速下的传送带试验（叠加预测）、每个任务族的一组 Dynamic-14 回合，以及第 4.3 节讨论的失败案例。

表 S15. **成功率随附加延迟的变化**：Dynamic-14 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的 All 与 +150 ms 列。斜率：SR 对附加延迟的最小二乘斜率（每 100 ms 的百分点）。

	附加延迟（ms）					
方法	0	50	100	150	200	斜率
ACT	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—
卡尔曼拦截器	—	—	—	—	—	—
SE(3)-WAM，检测器位姿	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—

F 完整的组件研究

本附录列出我们在设计 SE(3)-WAM 时比较过的所有变体，包括表 3 中未列出的变体。每组比较只改变一个设计轴，其他轴保持在选定配置，所有变体使用附录 A.6 的训练方案以及相同的场景与推理种子。我们以一个训练种子筛选所有变体，所有选择决策都在开发集上做出。各表报告留出场景上的结果。编码器与耦合方式的比较，以及同时出现在表 3 中的行，取三个训练种子的平均，其余行使用一个种子。整个研究共约 [XXXX] GPU 小时的训练与 [XXXXXX] 个评测回合。

选择规则。 候选方案必须在部署精度下保持 p95 出动作时间低于 200 ms、峰值显存低于一块 RTX 5090 的 80%。由于单个种子之间相差数个百分点（附录 C.4），只有当候选方案在开发集上用种子 0 提升超过 3 个百分点、并在种子 1 与 2 上保持提升时，我们才替换参考配置；否则保留更便宜或更简单的变体。

F.1 共享组件

观测编码器与仅用于训练的外观目标为所有比较所共享，我们首先确定它们。我们在开发集场景上比较了与策略一同训练的 CNN、冻结的 DINOv3 ViT-S/16 与 ViT-L/16 [33] 以及 MAE ViT-B/16 [14] 编码器（表 S16）。冻结的 MAE 编码器三个种子的均值最高，为 [66.8]%，但其各种子在 [63.7] 到 [71.1]% 之间，与 DINOv3 编码器有重叠。我们因为这一均值以及它比 ViT-L/16 更便宜而选择了它。DINOv3 ViT-L/16 特征仍是未来外观目标之一，我们将其与世界表示一同选定（附录 F.3）。

F.2 历史

条件设置。 每种条件都接收当前图像、因果跟踪器给出的当前目标位姿、八个机器人状态、选定的未来目标与选定的耦合方式。各条件只在保留过去 350 ms 中的哪些信息上不同。RGB 窗口保留七帧过去图像，每帧 196 个图像块，每 50 ms 采样一次，不做压缩。光流是在 64×64 RGB 上、覆盖同一 350 ms 窗口的四个区间（100、100、100 与 50 ms）上计算的双向 Farnebäck 光流 [13]，带前向—后向有效性检

表 S16. **观测编码器**（留出场景，三个训练种子），其余组件均为选定配置（*：采用）。参数量为编码器参数；p95 出动作时间在一块 RTX 5090 上测得。

编码器	参数	训练	SR	SR_{150}	p95
CNN	—	是	—	—	—
DINOv3 ViT-S/16	22M	冻结	—	—	—
DINOv3 ViT-L/16	300M	冻结	—	—	—
MAE ViT-B/16*	86M	冻结	—	—	—

表 S17. **历史：完整比较**（留出场景；一个训练种子，同时出现在表 3 中的行为三个种子）。所有条件均保留当前图像、当前目标位姿（最后一行除外）、机器人历史、选定的未来表示与选定的耦合方式。SR（%）按附加延迟分列；readout：冻结岭回归对 350 ms 前目标位置的读出误差（mm，越低越好）；δa：重复过去输入时首个动作平移的变化（mm）；tokens：新增历史 token 数；p95：出动作时间（ms）。

	不同附加延迟下的 SR（ms）								
历史	0	50	100	150	200	读出	δa	Token	p95
仅当前帧	—	—	—	—	—	—	0	0	—
RGB 窗口	—	—	—	—	—	—	—	1,372	—
RGB-D 窗口	—	—	—	—	—	—	—	1,372	—
光流	—	—	—	—	—	—	—	60	—
光流 + 运动统计	—	—	—	—	—	—	—	60	—
编码器运动向量	—	—	—	—	—	—	—	56	—
视频 VAE 隐变量	—	—	—	—	—	—	—	56	—
压缩窗口（按时间分配）	—	—	—	—	—	—	—	56	—
压缩窗口（均匀分配）	—	—	—	—	—	—	—	56	—
SE(3) 历史（因果估计）*	—	—	—	—	—	—	—	8	—
SE(3) 历史（仅位置）	—	—	—	—	—	—	—	8	—
SE(3) 历史（检测器三维框）	—	—	—	—	—	—	—	8	—
SE(3) 历史（真值）	—	—	—	—	—	—	—	8	—
SE(3) 历史 + RGB 窗口	—	—	—	—	—	—	—	1,380	—
RGB 窗口，无当前位姿	—	—	—	—	—	—	—	1,371	—

查；“光流 + 运动统计” 附加 DynamicWAM [29] 每个区间的十二个物理统计量。编解码器运动向量来自真实的 MPEG-4 P 帧运动向量，编码方式与光流相同；视频隐变量是冻结 Wan2.2 VAE 的后验均值，由 56 个可学习查询读取。压缩窗口用八个共享查询读取过去的帧，或均匀分配，或按 PACT-WAM [27] 的分配给更新的帧更多查询。RGB-D 窗口为每个过去的图像块加入度量位置，检验缺失的是否是度量几何而非运动。在 SE(3) 变体中，仅位置的历史去掉朝向，检测器历史用单目检测器逐帧的 3D 包围盒替代物体模型（附录 A.2），真值历史使用仿真位姿。最后一个对照从 RGB 窗口中去掉当前目标位姿，测量当前位姿本身的贡献。

冻结读出。 为区分历史编码包含的信息与策略使用的信息，我们在三个位置的冻结特征上拟合岭回归读出：历史编码器的输出、最终的物体查询，以及第一次函数求值时动作头的输入。标签为过去 50、200 与 350 ms 时的目标位置、最后一个区间的速度，以及 400 ms 时的未来位移，均在基座坐标系中表示。每个任务分别把 60、20 与 20 个不同的开发集回合分配给训练、验证与测试，每个回合取五个窗口。我们在验证误差上从 $\{0.1, 1, 10, 100\}$ 中选择惩罚系数，打乱标签的对照给出随机水平的界。条件读出先由当前图像、几何、机器人状态与当前位姿拟合基线，再用该位置的特征预测其残差，以检验

表 S18. **冻结策略干预。**每行只在推理时改变一个输入。历史干预使用最终模型。隐藏状态干预使用耦合 R2，几何干预使用 R5（最终模型不读取预测）。SR 为留出场景成功率（%）。δa：首个动作平移的平均变化（mm）。

输入	干预	SR	δa
历史	无	—	0
	静止（重复当前位姿）	—	—
	时间反转	—	—
	当前状态匹配的交换	—	—
	方向歧义交换	—	—
世界状态（R2）	无	—	0
	当前状态匹配的交换	—	—
	时域时刻偏移 ±50 ms	—	—
解码几何（R5）	无	—	0
	零运动	—	—
	当前状态匹配的打乱	—	—
	时间偏移 ±50 ms	—	—
	真值（接触前）	—	—

历史在当前信息之外增加了什么。

扰动与干预。 离线扰动在所有过去槽位中重复当前图像，或在保持当前帧、位姿与噪声不变时反转过去的图像，并测量首个发出动作的变化。在最终模型上（表 S18），*静止历史*在重新计算运动学之前用当前位姿替换每个过去位姿，从而去掉位移、速度与加速度。*时间反转*反转过去的位姿。*当前状态匹配的交换*代入最近的另一个开发集回合的历史，该回合任务、物体与相机相同，当前目标与末端位姿相差在 5 mm 与 5° 以内。*方向歧义*子集还要求最后一个区间的速度方向相反且至少为 0.01 m/s。

位姿噪声。 我们向每个过去的位姿估计独立加入高斯噪声，位置标准差 $\sigma_p \in \{0, 1, 2, 5, 10, 20, 40\}$ mm，旋转标准差 $\sigma_R = \sigma_p/(30\,\text{mm})$ rad，使两者在 3 cm 力臂处产生相同的位移，然后再计算运动学。当前位姿保持不变，因此该测试隔离了历史。我们按表 S6，以 $T = 350$ ms、$n = 8$ 与实际领先时长逐任务计算交叉噪声水平 $\sigma^\star$（附录 G.5），并与跟踪器实测误差（表 S1）一起标在图 S6b 中。

遮挡与采样。 0.5、1、2 与 3 s 的遮挡以及一个无遮挡对照检验历史空缺。采样测试保持 350 ms 跨度，选取 2、4 或 8 个偏移，并在实际偏移处使用时间嵌入。

F.3 预测目标

表示。 表 S19 定义各类未来目标。所有目标都从当前状态累计，覆盖 50 到 400 ms 的相同八个时域。表 S20 的每一行都保持选定配置的历史、耦合方式、动作损失、训练预算与世界分支容量，只替换世界目标，由场景查询通过附录 A.3 的接口回归。因此我们在同等容量下比较图像空间目标。冻结视频一行则读取预训练图生视频模型从当前帧预测的隐变量，这一未来不依赖我们的容量。Kabsch 一行预测物体轨迹并对其拟合 SE(3)，因此它得到与轨迹一行相同的信息外加一个刚性先验。最后一组保持选定的世界，只改变仅用于训练的外观目标（其读出头在部署时去掉），因此它衡量这些目标教给场景查询的内容。

在开发集场景上，大多数表示的总体差距在几个百分点以内，差异集中在少数任务上。目标点轨迹加流的总体 SR 甚至略高于 SE(3) 轨迹（单种子 [+1.7] 个百分点）。我们保留了 SE(3) 轨迹，因为它

表 S19. “预测”研究中比较的未来目标族。张量形状不含 batch 和 query 轴。除保留解码器自身对应关系的 codec 向量外，位移均从当前状态累计。除冻结视频模型（其隐变量为该模型自身的预测）外，所有监督目标均来自记录的演示。未来深度、DINO 与动态 RGB 同时也是选定模型仅在训练中使用的辅助目标。

目标	形状	几何支持、单位与有效条件
目标位姿	8×6	累计平移 (m) 和左相对旋转向量 (rad)；位姿和 query 有效。
场景流，$k \times k$ 网格	$k^2 \times 8 \times 3$	每边 $k \in \{14, 28, 56\}$ 个点的固定网格；基座坐标系中的米；源深度有效且未来位移有限。
场景流，按物体采样	$196 \times 8 \times 3$	在环境掩码上以最远点采样代替固定网格选取的点。
物体点轨迹	$32 \times 8 \times 3$	在当前目标掩码内作最远点采样；位移与可见性；填充点无效。Kabsch 变体对预测轨迹拟合 SE(3)。
物体 DINO	8×1024	按掩码面积加权汇聚未来 patch 特征；沿通道作层归一化；掩码面积为正。
场景轨迹（二维）	$196 \times 8 \times 3$	网格源点；两个图像位移通道除以 224，另加一个可见性 logit。
稠密二维位移	$8 \times 2 \times 224 \times 224$	固定源像素；位移除以 224；源像素有效且投影有限。
编码器运动向量	$8 \times 2 \times 64 \times 64$	每对未来 / 当前帧编码为 P/I 帧；向量除以 64；使用有效向量区域。
视频 VAE 隐变量	$48 \times 2 \times 14 \times 14$	冻结的 Wan2.2 VAE 后验均值及该 VAE 自身的归一化；两组分别截至 200 与 400 ms。
冻结视频模型	$48 \times 2 \times 14 \times 14$	冻结的预训练图生视频模型由当前帧预测的隐变量；仅读取，不监督。
未来深度	$8 \times 1 \times 224 \times 224$	米制深度；像素值为有限正数。
未来 DINO	$8 \times 196 \times 1024$	冻结的 DINOv3 ViT-L/16 教师 [33]，14×14 个 patch，沿通道作层归一化。
动态 RGB	$8 \times 3 \times 224 \times 224$	在世界坐标中移动超过 1 mm 的可见表面（含机器人）上取 RGB 并除以 255。

直接给出位姿，并且对旋转目标最重要；表 S20 在留出场景上比较了两者。稠密 2D 位移是唯一明显有害的未来表示（相对无未来预测 [−3.6] 个百分点）。

角色覆盖。 在选定的表示上，各角色行保留所有源点与相同的计算，只改变哪个角色参与流损失。最后一行去掉角色嵌入，检验显式的角色划分是否在任务相关的读出之外还有帮助。

分辨率与间隙。 28^2 与 56^2 网格对同一图像更密地采样，物体采样的流把点放在环境掩码上而不是固定网格上。所有变体使用相同的标签、归一化与损失权重。路径误差 e_F 是在执行路径经过时、距路径最近的 256 个留出环境点上的流端点误差。表 S21 报告所有变体在附录 C.3 间隙扫描上的结果，以及同等容量的视频隐变量未来。

外推基线。 匀速与匀加速预测只使用模型可见的因果 SE(3) 历史，即最后一个区间的速度与最后两个区间速度之差，作用于平移，并通过旋转向量作用于旋转。离线时，我们在生效时刻用真值为三种预测打分。为衡量它们的闭环价值，我们以相同的数据与预算训练两个变体（表 S22）：第一个把外推的目标轨迹作为额外输入 token，并保留选定模型的世界监督；第二个用这些输入 token 替代世界监督，即表 1 中的 CV 输入基线。

预测误差。 物理误差使用 256 个目标源点与 256 个环境源点组成的公共点池，确定性采样，并排除在训练查询之外。平移与旋转误差保持度量与测地单位，流误差是有效对应点上的端点误差。所有预测误差都在留出回合的生效时刻测量。

F.4 耦合与主干

主干。 共享注意力的主干在所有 token 组之间共享注意力投影，并按组拆分前馈网络。分组主干拥有各自带注意力投影、自适应层归一化与前馈网络的世界与动作参数组，条件 token 与世界 token 共享世界组。我们通过分组主干的前馈比例（3 而不是 4）匹配可训练参数数量，使两者都约为 47.3M 参数，深度、宽度与头数相同。相同的训练预算并不意味着相同的 FLOPs，因此我们报告实测开销。

耦合方式。 附录 A.5 定义 R0–R5 的注意力掩码。所有耦合方式共享模块、初始化、损失与训练预算。R0 保留世界查询与读出头，但关闭所有世界损失，因此它在容量上与 R1 相同而没有世界监督。R1 加入世界监督，并关闭所有从世界到动作的边。我们把它的检查点既以只运行动作的方式部署，也以计算但不读取预测的方式部署，以隔离未被使用的预测的开销。R2 让动作读取世界查询的隐藏状态，R3 让世界读取带噪动作，R4 双向开放。R3 与 R4 在每个欧拉步都重新计算世界。R5 解码世界的显式几何，并用一个 0.37M 参数的几何编码器为动作重新编码，穿过预测的几何端到端训练，不使用教师强制。由于 R5 同时改变了动作读取的内容与进入的位置，R2 与 R5 之间的比较是两个完整设计之间的比较，而不是单一因素的比较。

在开发集场景上，没有任何耦合方式稳定地优于 R1。让世界读取动作（R3）的三种子均值最高，比 R1 高 [+0.6] 个百分点，但差异全部来自导线穿越任务，而且两个方向的读取效果在不同种子之间符号会翻转。我们保留了同时也最便宜的 R1。世界监督本身（R1 对 R0）平均带来 [3.1] 个百分点，但其增益在不同种子之间从 [−1.3] 到 [+9.6] 个百分点不等。

预测干预。 干预保持条件 token 与动作噪声不变，只改变动作从世界读取的内容。在 R2 上，它们替换动作 token 在每一层读取的键和值。当前状态匹配的交换代入另一个开发集回合的世界状态，该回合当前目标位姿相差在 5 mm 与 5° 以内；时间偏移在每个时域偏移平移 50 ms 后重新计算它们。在 R5 上，它们在编码之前编辑解码出的几何：零运动使用零 3D 位移与单位目标位姿，可见性不变；当前状态匹配的打乱在同样的匹配下取另一个开发集回合的几何；时间偏移在 $\delta_h \pm 50$ ms 处重采样轨迹；真值使用首次接触前实测的外部运动。接触之后，未来标签取决于动作，因此真值分析在一个固定的候选动作序列下分叉仿真快照。动作不从世界读取任何内容的耦合方式作为阴性对照。

F.5 物理时间

表 3 中的物理时间变体保持最终模型的其余部分不变。*去除领先时长*嵌入从动作 token 中去掉领先时长，策略只能从数据中推断延迟。*按控制步计的领先时长*用指令序号 j 替代领先时长，并在 [100] ms 的固定延迟下训练（附录 G.4）。*预测时域偏移 50 ms* 在 $\delta_h + 50$ ms 处监督世界，而指令保持其领先时长，因此训练信号不再与生效时刻对应。我们在扫描的每个附加延迟下评估这三个变体。

表 S20. **预测目标：完整的未来表示比较**（留出场景；一个训练种子，同时出现在表 3 中的行为三个种子）。历史与耦合方式固定为选定配置，各行世界分支容量相同，只改变其预测目标（定义见表 S19）。最后一组之前的各行保留选定的仅训练外观辅助目标；最后一组在选定表示上改变这些目标，其读出头在部署时去除。Pose：400 ms 处的平移（mm）与旋转（°）误差；e_F：沿执行路径的留出环境点上的流误差（mm）；e_t：接触时刻误差（ms）；cost：每次查询的世界分支耗时（ms）。

目标	环境	SR	SR_{150}	位姿 (mm/°)	e_F	e_t	碰撞	耗时
无	无	—	—	–	–	—	—	0
SE(3)	无	—	—	—	–	—	—	—
无	流，14^2	—	—	–	—	—	—	—
SE(3)	流，$14^{2\star}$	—	—	—	—	—	—	—
SE(3)	流，28^2	—	—	—	—	—	—	—
SE(3)	流，56^2	—	—	—	—	—	—	—
SE(3)	流，按物体采样	—	—	—	—	—	—	—
物体点轨迹	流，14^2	—	—	–	—	—	—	—
点轨迹 → SE(3) 拟合	流，14^2	—	—	—	—	—	—	—
物体 DINO	流，14^2	—	—	–	—	—	—	—
SE(3)	场景轨迹（二维）	—	—	—	–	—	—	—
SE(3)	稠密二维位移	—	—	—	–	—	—	—
SE(3)	编码器运动向量	—	—	—	–	—	—	—
SE(3)	视频 VAE 隐变量	—	—	—	–	—	—	—
SE(3)	冻结视频模型	—	—	—	–	—	—	—
SE(3)	未来深度	—	—	—	–	—	—	—
SE(3)	未来 DINO	—	—	—	–	—	—	—
SE(3)	动态 RGB	—	—	—	–	—	—	—
选定表示上的角色覆盖								
SE(3)	流，仅目标点	—	—	—	—	—	—	—
SE(3)	流，仅环境点	—	—	—	—	—	—	—
SE(3)	流，无角色嵌入	—	—	—	—	—	—	—
选定表示（SE(3) + 流）上的仅训练外观目标								
无		—	—	—	—	—	—	—
未来深度		—	—	—	—	—	—	—
未来 DINO 特征		—	—	—	—	—	—	—
运动区域 RGB		—	—	—	—	—	—	—
三者全部 ⋆		—	—	—	—	—	—	—
三者全部，去除当前目标 RGB 重建		—	—	—	—	—	—	—

表 S21. **环境分辨率与间隙**（穿越任务）：工作空间中的网格间距与路径误差 e_F（mm），以及各扫描间隙 $c_1 < \cdots < c_5$ 下的成功率（%）（附录 C.3）；目标始终以 SE(3) 预测。

环境	间距	e_F	c_1	c_2	c_3	c_4	c_5
无	–	–	—	—	—	—	—
流，14^2	—	—	—	—	—	—	—
流，28^2	—	—	—	—	—	—	—
流，56^2	—	—	—	—	—	—	—
流，按物体采样	—	—	—	—	—	—	—
视频 VAE 隐变量	–	–	—	—	—	—	—

表 S22. **世界监督与外推输入的比较**，按运动类型分列。上：在相同数据与训练预算下，以因果 SE(3) 历史的匀速（CV）或匀加速（CA）外推作为输入 token、有或没有世界监督的 SE(3)-WAM 变体的成功率（%）。无世界监督的 CV 行即表 1 中的匀速输入基线。下：两种外推与学习的世界头在 400 ms 处的目标位置误差（mm）。

	匀速	谐波	滚动/滑动	撞击
无世界监督				
无预测输入	—	—	—	—
匀速输入	—	—	—	—
匀加速输入	—	—	—	—
有世界监督				
SE(3)-WAM （无预测输入）	—	—	—	—
匀速输入	—	—	—	—
匀加速输入	—	—	—	—
400 ms 处的位置误差（mm）				
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的世界头	—	—	—	—

表 S23. **耦合：完整比较**（留出场景）。历史与未来表示固定为选定配置。附录 F.4 的各耦合方式在选定主干上逐一比较，另一主干只检验其中两种。$\mathrm{SR}_{\mathrm{static}}$：静止目标变体。NFE：每次查询的网络调用数（世界/动作）。显存：GPU 峰值显存（GiB）。p95 在一块 RTX 5090 上测得。

主干	耦合	SR	SR_{150}	$\mathrm{SR}_{\mathrm{static}}$	LIBERO	NFE	p95 (ms)	显存	e_t
共享注意力 ⋆	R0 （关闭世界损失）	—	—	—	—	0/5	—	—	—
	R1 （辅助，仅动作）⋆	—	—	—	—	0/5	—	—	—
	R1 （辅助，计算预测）	—	—	—	—	1/5	—	—	—
	R2 （世界 → 动作，隐藏状态）	—	—	—	—	1/5	—	—	—
	R3 （动作 → 世界）	—	—	—	—	5/5	—	—	—
	R4 （双向）	—	—	—	—	5/5	—	—	—
	R5 （解码几何）	—	—	—	—	1/5	—	—	—
独立参数组	R2 （世界 → 动作）	—	—	—	—	1/5	—	—	—
	R1 （辅助，仅动作）	—	—	—	—	0/5	—	—	—

G 延迟下行动的误差分析

本附录推导第 3.1 节的误差分解，把它推广到旋转、环境与分块执行，推导简单的比例关系，给出 Dynamic-14 中各项的量级，并说明其不适用的情形。这一分解促成了 SE(3)-WAM 的设计，它不是成功率的模型。

G.1 平移

设生效时刻目标的真实位置为 $\mathbf{p}(\tau^{\mathrm{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，策略的估计为 $\hat{\mathbf{p}}(\tau^{\mathrm{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。减去再加上 $\mathbf{v}\hat{\Delta}$ 得到恒等式

$$\begin{aligned}\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}}) = \big[\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\big] + (\hat{\mathbf{v}} - \mathbf{v})\hat{\Delta} \\ + \mathbf{v}(\hat{\Delta} - \Delta) + (\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}),\end{aligned} \tag{S4}$$

由三角不等式即得式 3。由于 $\mathbf{v}$ 是 τ_t 时的速度，$\boldsymbol{\rho}$ 恰好是匀速外推遗漏的那部分运动。在匀加速度 $\mathbf{a}$ 下，$\boldsymbol{\rho} = \frac{1}{2}\mathbf{a}\Delta^2$，从历史中估计的加速度可以消除 e_{dyn} 的一部分；撞击、滚动接触与摩擦变化留下的余项只有动力学模型才能减小。对于学习型预测器，其估计在 $\hat{\mathbf{v}}\hat{\Delta}$ 与 $\hat{\boldsymbol{\rho}}$ 之间的划分不可辨识，因为任何预测位置都可以写成这种形式。因此我们用这一分解说明每一项需要哪些信息。我们的实验不在学习型预测器内部分离各项，而是改变作用于已知项的领先时长、速度、位姿噪声与时间，并比较接收不同信息的变体（附录 G.5）。

G.2 旋转与接触点

我们写 $R(\tau^{\mathrm{a}}) = \mathrm{Exp}(\boldsymbol{\omega}\Delta + \boldsymbol{\eta})R(\tau_t)$ 与 $\hat{R}(\tau^{\mathrm{a}}) = \mathrm{Exp}(\hat{\boldsymbol{\omega}}\hat{\Delta} + \hat{\boldsymbol{\eta}})\hat{R}(\tau_t)$。当 R 与 $\hat{R}$ 绕同一固定轴旋转时，指数映射可以相加，于是

$$\theta = \big\| \mathrm{Log}(\hat{R}(\tau^{\mathrm{a}})R(\tau^{\mathrm{a}})^{\top})^{\vee} \big\| \le \theta_{\mathrm{loc}} + \hat{\Delta}\, e_{\omega} + \|\boldsymbol{\omega}\|\, e_{\tau} + e_{\eta}, \tag{S5}$$

其中 θ_{loc} 是当前朝向误差，e_{ω} 与 e_{η} 的定义与平移相同。对一般旋转，Baker–Campbell–Hausdorff 公式会带来角度的二阶项。物体坐标系中位于 $\mathbf{c}$、$\|\mathbf{c}\| = r$ 的接触点，其世界位置为 $\mathbf{p} + R\mathbf{c}$，因此误差为 $(\hat{\mathbf{p}} - \mathbf{p}) + (\hat{R}R^{\top} - I)R\mathbf{c}$。对转角为 θ 的旋转，$\hat{R}R^{\top} - I$ 的算子范数为 $2\sin(\theta/2)$，于是

$$e_{\mathrm{c}} \le \|\hat{\mathbf{p}} - \mathbf{p}\| + 2r\sin(\theta/2) \le \|\hat{\mathbf{p}} - \mathbf{p}\| + r\theta, \tag{S6}$$

这就是第 3.1 节中的接触误差界。因此朝向误差以力臂为比例进入接触几何，依赖朝向的抓取或放置需要 SE(3) 的目标状态。对于旋转对称的目标，绕对称轴的旋转不改变任何接触，我们从输入、标签与误差中排除它。

G.3 环境与间隙

令 $\mathcal{P}$ 为执行路径经过的环境点与时刻的集合，并设路径使机器人与被携带物体上的每一点 $\mathbf{x}$ 与预测的环境位置 $\hat{\mathbf{y}}_t(\mathbf{z},\tau)$（$(\mathbf{z},\tau) \in \mathcal{P}$）至少相距 m。碰撞要求对某个 $(\mathbf{z},\tau) \in \mathcal{P}$ 有 $\mathbf{x} = \mathbf{y}_t(\mathbf{z},\tau)$，此时 $\|\hat{\mathbf{y}}_t(\mathbf{z},\tau) - \mathbf{y}_t(\mathbf{z},\tau)\| = \|\hat{\mathbf{y}}_t(\mathbf{z},\tau) - \mathbf{x}\| \ge m$，因此碰撞要求路径上某处的预测误差至少为 m。比 m 更细的环境精度因而对成功率没有一阶影响。这个界只关乎误差的大小，与采样无关。在网格上采样的流会漏掉比其间距更细的结构，并在运动边界处出错；这两种效应都进入路径误差 e_F，我们在执行路径沿线的留出点上测量它（附录 F.3），而不是由网格间距推断。间隙本身也是一个设计变量：环境估计较粗时，策略可以保持更大的间隙，代价是可达性或时间。

G.4 分块执行下的领先时长

动作块含 H 条指令，其中前 k 条在下一个动作块替换其余部分之前执行，相关的领先时长为 $j < k$ 时的 $\Delta_{t,j} = \ell_t + j\Delta_a$。因此预测时域必须覆盖 $[\ell_t, \ell_t + (k-1)\Delta_a]$，时域之间的状态通过插值得到（平移线性插值，旋转沿测地线插值）。延迟至多 250 ms、每 100 ms 重规划一次时，领先时长不超过 350 ms，处于预测的 400 ms 之内。由于时域与领先时长都按物理时间索引，延迟的变化只改变动作 token 嵌入的领先时长，无需重新训练。变体 “按控制步计的领先时长”（表 3）则从第一条指令起按控制周期计数领先时长，正如把观测时刻与执行时刻视为相同的策略那样。它在训练延迟下训练，延迟改变时就会指向错误的时刻。

G.5 比例关系

由这一分解可以得到四个关系。图 S6 给出与前两个关系相关的测量。

临界领先时长。 不补偿运动的策略（$\hat{\mathbf{v}} = 0$，$\hat{\boldsymbol{\rho}} = 0$）在 e_{loc} 与 $\|\boldsymbol{\rho}\|$ 之外还要承受 $\|\mathbf{v}\|\Delta$。定位误差较小、运动平滑时，一旦 $\|\mathbf{v}\|\Delta > \varepsilon$，即超过临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$，其接触就会失败，其成功率只通过 $\|\mathbf{v}\|\Delta/\varepsilon$ 依赖于任务、速度与延迟。表 S6 列出每个任务的 ε、$\|\mathbf{v}\|$ 与 $\Delta^\star$。图 S6a 给出每个方法的成功率与 $\|\mathbf{v}\|\Delta/\varepsilon$ 的关系，后者在每个回合的首个指令生效时刻计算，并在任务、速度与延迟上汇总；同时给出反应式策略的 Spearman 相关系数与拟合的 logistic 曲线。反应式策略 [落在同一条曲线上]（Spearman $\rho = [X.XX]$），其成功率在 [X.X] 处减半。这一分解只给出约为 1 的阈值，而不给出曲线的形状。捕获任务在曲线周围最分散，因为其成功还取决于夹爪何时合拢。

位姿噪声。 由跨度为 T 的 n 个等间隔位姿（每个轴上带独立噪声 σ）得到的最小二乘速度估计，其标准差为 $\sigma\sqrt{12(n-1)/(n(n+1))}/T \approx \sigma\sqrt{12/n}/T$ [4]。因此在噪声达到 $\sigma^\star = \varepsilon T\sqrt{n}/(\Delta\sqrt{12})$ 之前，位姿历史能使 $\hat{\Delta}e_v$ 保持在容差以下。取 $\varepsilon = 10$ mm、$T = 350$ ms、$n = 8$ 与 $\Delta = 200$ ms，得到 $\sigma^\star \approx 14$ mm。带运动先验的学习型估计器可以做得更好，因此 $\sigma^\star$ 是无模型线性估计对应的值。SE(3)-WAM 的 SE(3) 历史在注入 [X] mm 噪声时降到最佳视觉历史的水平（图 S6b），为 $\sigma^\star$ 的 [X.X] 倍、跟踪器误差的 [X] 倍。

时域偏移。 若预测指向 $\tau^{\text{a}} + \delta$ 而不是 τ^{a}，则 $e_\tau = |\delta|$，依据它行动的策略的接触误差增加 $\|\mathbf{v}\|\,|\delta|$。因此固定偏移的代价随目标速度增长，并在目标静止时消失。在 R1 中动作不读取预测，因此偏移的预测只通过训练信号影响策略，其代价衡量动作在多大程度上依赖于其自身生效时刻的预测。

间隙。 路径误差为 e_F 的环境预测在 $m > e_F$ 时避开碰撞。因此，粗粒度流应当在高于其实测 e_F 的间隙上与更细的流相当，在低于它时落后。

G.6 Dynamic-14 中的量级

表 S24 在有代表性的 Dynamic-14 设置下（表 S7）计算各项的大小。每一项都与成功条件中毫米级的容差（表 S5）相当或更大。

斜坡一项使用纯滚动实心球的加速度 $a = \frac{5}{7}g\sin\alpha \approx 1.2\,\text{m/s}^2$（$\alpha = 10°$），以及 $\Delta = 0.2$ s 时的 $\frac{1}{2}a\Delta^2$。

图占位：图 S6——未补偿的运动与位姿噪声

(a) x：首个指令生效时刻的 $\|\mathbf{v}\|\Delta/\varepsilon$（对数）；y：SR。每个方法 × 任务族 × 速度 × 延迟一个点；反应式策略（灰）附拟合的 logistic 曲线与 Spearman ρ，标出阈值 1；补偿运动的基线与 SE(3)-WAM （橙）为平移后的曲线。**(b)** x：注入的位姿噪声 σ（mm，symlog）；y：SE(3) 历史的 SR；区间带：最佳视觉历史；竖线：$\sigma^\star$ 与跟踪器实测误差。

图 S6. **实测趋势。**(a) 反应式策略的成功率与相对容差的未补偿运动之间的关系；运动补偿使曲线右移。(b) 注入位姿噪声时 SE(3) 历史的价值。

表 S24. 领先时长为 200 ms 时式 3 各项的示意量级。数值由所述量推出，并非测量值。

项	设置	大小
$\|\mathbf{v}\|\Delta$	传送带 0.10 m/s	20 mm
$\hat{\Delta} e_v$	速度估计偏差 10%	2.8 mm
$\|\mathbf{v}\| e_\tau$	50 ms 时间误差（一个周期）	7.0 mm
$2r\sin(\theta/2)$	$\omega = 1.2$ rad/s 未被预测，$r = 3$ cm	7.2 mm
e_{dyn}	10° 斜坡上的球，无加速度模型	24 mm
ε	抓取传送带零件	[X] mm
网格间距	工作空间处的14 × 14 流	[X] mm

G.7 适用范围

这一分解针对的是接触前运动由外部决定的刚性目标的接近过程。它不涵盖可变形或铰接的目标，因为其在 $\mathcal{O}$ 上的运动场不由六个数决定。它也不涵盖接触后的运动，后者取决于动作本身，需要以动作为条件的预测，这正是让世界读取动作可能起作用的情形。目标角色随时间变化的场景（例如依次操作多个物体的任务）同样不在其范围内。感知质量只通过 e_{loc} 与 e_v 进入，我们单独测量它（附录 B.4）。这个界不是成功的概率，它指出哪些误差随哪些因素放大。