SE(3)-WAM：动态操作需要记住和预测什么？

中文审读稿

摘要

动态操作要求机器人在持续变化的场景中协调接触的位置、姿态与时机。哪些历史与未来信息能够改善当前动作？本文在世界—动作建模框架下研究历史编码、未来表示和世界—动作交互。核心假设是：根据交互需求，为目标运动与相关环境分配不同的表示粒度。在十四项仿真任务、每组 1,260 个配对场景的十五组未来监督比较中，最高成功率为 64.13%，相对无未来监督的 62.78% 尚无明确总体优势；稠密二维位移监督为 59.21%，在多重比较校正后仍低于参照。这些结果来自单个训练种子、特权当前物体状态与运动历史条件，未来目标仅用于辅助训练。改用另一视觉编码器与重建目标后，选出的轨迹监督配置在 1,400 场开发池上获得 66.79%，匹配无未来监督控制为 57.86%。历史与组合实验揭示了表示效果所依赖的条件。主干、信息流、真实数据预训练及外部验证将进一步确定最终 SE(3)-WAM 及其在线预测的动作价值。

1 引言

运动物体可能在机器人到达之前离开被观测的位置。类似的问题也出现在向移动容器释放物体、穿越变化的通道，以及碰撞后重新接近目标的过程中。动态操作因而要求机器人在正确时刻实现空间对齐。缩短推理时间和持续更新动作能够减小观测年龄 [32]；历史观测则有助于区分当前图像相似、运动方向不同的状态 [9, 22]。两者共同引出本文的问题：为了使动作在实际交互时仍然有效，机器人应当记住和预测什么？

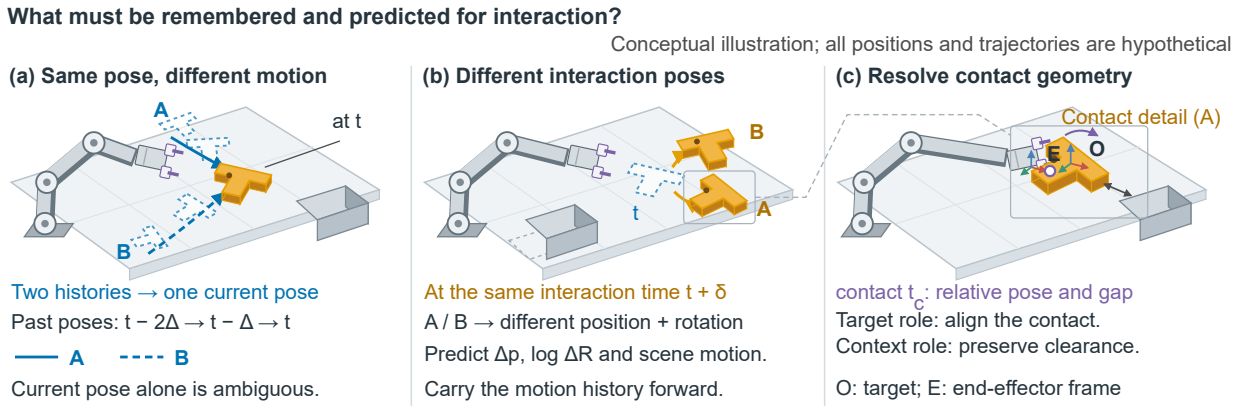


图 1: 交互时刻需要哪些信息？(a) 两条不同历史汇聚到相同的当前目标位姿；(b) 它们在同一未来时刻到达不同位姿，A 为实线、B 为虚线；(c)A 的接触局部示意展示末端与目标对齐，以及相对环境的间隙。同一非对称目标与机器人贯穿三幅图；轨迹均为概念示意。

信息的价值取决于它在任务中的作用。目标的平移和旋转决定机器人在哪里、以怎样的姿态接触；遮挡物和障碍物的运动通过可见性、可达性或碰撞条件影响动作。静态几何也可能持续约束操

作。因此，我们提出按交互需求表示场景演化：在接触需要精度时保留细致的目标信息，以足够支持决策的粒度描述周围变化。固定的目标—环境分组，或共享表示上的任务相关读出，都可能实现这一思想；具体选择由实验决定。

世界—动作模型将场景演化学习与动作学习放在同一框架中 [35, 36]。但加入未来目标会同时改变监督变量、共享表征接收的梯度，有时还会改变执行前的计算。动作可能受益于辅助监督，而无需在部署时生成未来 [38]；准确的几何预测也可能没有为已经掌握物体运动的策略提供额外信息。因此，预测精度、动作收益和在线使用预测需要分别验证。

SE(3)-WAM 研究围绕三个相互关联的问题展开。Q1 研究有限历史如何编码运动；Q2 研究哪些未来变量、区域和粒度能够服务动作；Q3 研究世界与动作分支如何组织参数和交换信息。每项研究匹配自身参照，历史、未来与组合实验采用不同配方。在真实机器人数据预训练之前，通过定向交叉比较复核关键选择，以检查设计之间的相互作用。

已有结果表明，未来监督的价值取决于具体训练条件。十五组未来监督已在 fixed140 之外的 1,260 个同分布场景上完成比较：稀疏场景轨迹和目标轨迹给出较高点估计，相对无未来监督仍无明确总体优势；稠密二维位移监督则降低了成功率。随后十二组组合筛选选出候选 I，其在同一补集上的成功率为 66.59%，匹配的无未来监督控制为 58.02%，位姿与场景流控制仍待完成。采用自身训练与执行配方的 DreamVLA 系统参照达到 79.60%。表示选择需要解释这些条件差异，并检验信息如何影响动作。

现有证据支持两项贡献：

1. 建立面向动态操作的研究协议，分别记录任务结果、可用信息、训练监督与执行条件。
2. 完成十五组未来监督比较，报告配对结果、不利发现及任务差异，并以历史和组合实验确定下一步需要控制的因素。

补充材料详述实测配置、完整数据，以及模型选择、预训练和迁移所需的后续协议。

2 相关工作

动态操作与物理时间。 动态抓取将运动预测、可达性与拦截联系起来 [1]。DOMINO/PUMA 结合动态任务、历史光流与对象未来监督 [9]；DynamicManip 从静态示范扩展动态数据 [17]。DynamicVLA 侧重连续推理与动作流式执行 [32]，DynamicWAM 将运动信息引入世界—动作学习 [22]。时间特征预测 [41]、AHEAD 的预测潜变量 [26] 和 ForeTime-VLA 的未来 token 与事件时间监督 [23]，分别提供了预判交互的途径。RTC 处理延迟条件下动作块的连续执行 [3]，Chronos Policy 显式编码观测采集与动作应用的物理时间 [28]。这些工作提示，预测需要结合动作实际生效的时刻评估，仿真控制周期不能代替实时性测量。

历史与对象信息。 TraceVLA 通过视觉轨迹提示表达时间信息 [44]；HiF-VLA 以运动表示组织历史与未来 [18]。PACT-WAM 为更早的观测分配更少空间 tokens[20]，Long-WAM 将长历史与因果视频预训练一并研究 [13]。历史编码的价值因而取决于时间支持和训练方式。PointWorld 明确指出，不输入历史帧或速度时，其模型假设初始场景静止 [12]；外部运动目标使这类初态信息成为 Q1 的关键因素。DOCIR 区分操作对象、障碍物与机器人 [8]，OA-WAM 在世界—动作模型中保留可寻址的对象信息 [21]。本文 Q1 先区分当前定位、特权运动与视觉历史，再比较编码方式；对象角色的组织方式同样需要实验验证。

未来的表示与作用。 SE3-Nets 用刚体变换描述场景运动 [4]，SE3-Pose-Nets 将结构化位姿动态用于控制 [5]。DSR-Net 跨交互积累三维体素对象表示 [34]；PointWorld 与 PhysMani 进一步研究面向操作的三维世界表示 [12, 39]。ATM 从视频学习点轨迹 [30]，Im2Flow2Act 将生成的对象运动作为策略接口 [33]，AffordTrajDP 利用对象位姿传播接触可供性 [31]，FlowWAM 在策略与世界模型两种模式中使用光流 [6]。这些接口分别涉及期望运动、动作条件下的后果或外部物体演化，不能因为都称为 flow 就等同。DreamVLA 与 DreamWAM 组合视觉、几何和语义未来目标 [37, 40]；DC-WAM 在 RGB 监督内部强调动态区域 [14]；DELE-w0.5 采用紧凑未来潜变量 [16]。Q2 在共同动作路径下比较相关目标的训练价值，位姿输出本身不构成新的刚体运动参数化。

世界—动作交互与归因。 预测通过不同接口进入控制。PointWorld 预测候选动作条件下的三维点运动以评估动作 [12]，NWM 模拟并排序导航轨迹 [2]；CoT-VLA 先生成视觉目标，再生成动作序列 [42]，VPP 以预测特征条件化动作学习 [11]。DreamZero 联合建模世界与动作 [35]，Fast-WAM 区分训练收益与部署时生成未来的作用 [38]。本文参照 D 仅使用未来监督，没有预测到动作的信息边；Q3 在共同输入条件下改变访问关系和生成顺序。Wang 等人的 OpenWAM 提供本文适配基线使用的 Alpha 基座 [29]，Yu 等人的 OpenWAM 研究可组合的世界—动作程序 [36]。ACT、Diffusion Policy 与 $\pi_{0.5}$ 提供系统参照 [7, 24, 43]，DROID 用于计划中的真实数据预训练 [15]。系统级比较和匹配设计对照分别报告。

3 问题定义与评测协议

物理时间中的交互。 令 $\mathcal{H}_t = \{(o_i, s_i, \tau_i)\}_{i \le t}$ 表示可获得的有限观测、机器人状态及时间戳历史。策略生成动作块 $A_t = (a_{t,0}, \ldots, a_{t,H_a-1})$。若最近图像的采集时刻为 τ_t^s，第一条指令在延迟 ℓ_t 后生效，则第 j 条动作的应用时刻为

$$\tau_{t,j}^{\text{apply}} = \tau_t^s + \ell_t + j\Delta_a. \tag{1}$$

预测应以这些物理时刻和任务接触事件为参照。预测时域、动作间隔和计算耗时是不同量。已完成表示实验使用 50–400 ms 的八个未来标签，同步调用策略，每次重规划执行一步。场景规定的原生命令延迟为 T5 的 50 ms，其余任务为零；评测没有将实测计算等待注入场景演化。

任务与数据。 实验使用迁移后的 DB0 v0.6 数据及十四任务评测套件，覆盖移动目标抓取、朝向敏感抓取、物理遮挡、移动容器放置、相位约束穿越、自由滚动或滑动，以及碰撞后重规划。仿真基础设施采用 MuJoCo 与 robosuite[27, 45]。共同训练池包含 11,200 条示教，每任务 800 条。各任务按原生评测器判定物理结果，并在总体得分中等权。P0 纯运动预测和后续新数据生产分别保留来源，不并入这组学习结果。

信息条件。 未来监督筛选使用当前固定相机 RGB、精确深度与相机几何、八帧机器人状态，以及特权当前目标位姿和七个区间的目标运动学。该“物体运动信息条件”用于研究：已知较充分目标运动时，未来目标还能提供什么训练价值。当前位姿历史实验则去除区间运动学，研究视觉历史的条件增量。两类实验均保留特权当前物体位姿；可部署视觉系统需要独立验证由传感器估计这些量的能力。H0V 仅表示没有视觉历史，仍保留机器人状态记忆。

评测划分。 fixed140 开发集每任务 10 场；与其不重叠的 1,260 场补集每任务 90 场，合计 1,400 场。补集来自同一验证分布，已经参与项目开发，不是最终盲测或分布外测试。未来监督与系统参照分别报告两部分；组合筛选按预先约定的 1,400 场总成功数选择配置，同时保留分项计数。未来监督使用固定第四轮终点和一个 fresh 训练 seed，配对场景不等于跨训练 seed 重复。

指标与比较范围。 设 $K = 14$，每任务有 n_k 个评测场景，主要指标为

$$\mathrm{SR}(m) = \frac{1}{K}\sum_{k=1}^{K}\frac{1}{n_k}\sum_{i=1}^{n_k} y_{mki}, \qquad y_{mki} \in \{0,1\}. \tag{2}$$

各任务样本数相同，因此总体成功率等于任务宏平均。结果同时给出成功数、分母与百分比。未来监督报告精确双侧 McNemar 配对检验，将 27 项总体比较作为一个多重比较族；逐任务分析保持探索性质。内部匹配对照控制输入、训练曝光、动作接口与执行方式。不同方法的系统参照保留各自预训练、预算和执行器差异。接触时刻、相对位姿、安全与实际动作年龄等读出，在具备测量接口的机制和部署实验中报告；缺失值不填为零，不将不同表示的原生 loss 当作同一精度指标。

4 SE(3)-WAM 设计研究

研究配置记为 (H, Z, B, G)，分别表示历史编码、未来目标、主干和信息流程序。已完成筛选在固定参照下改变 Z，后续比较 H、B 和 G 并回访保留候选。单个组件的点估计排序不能直接决定最终组合。

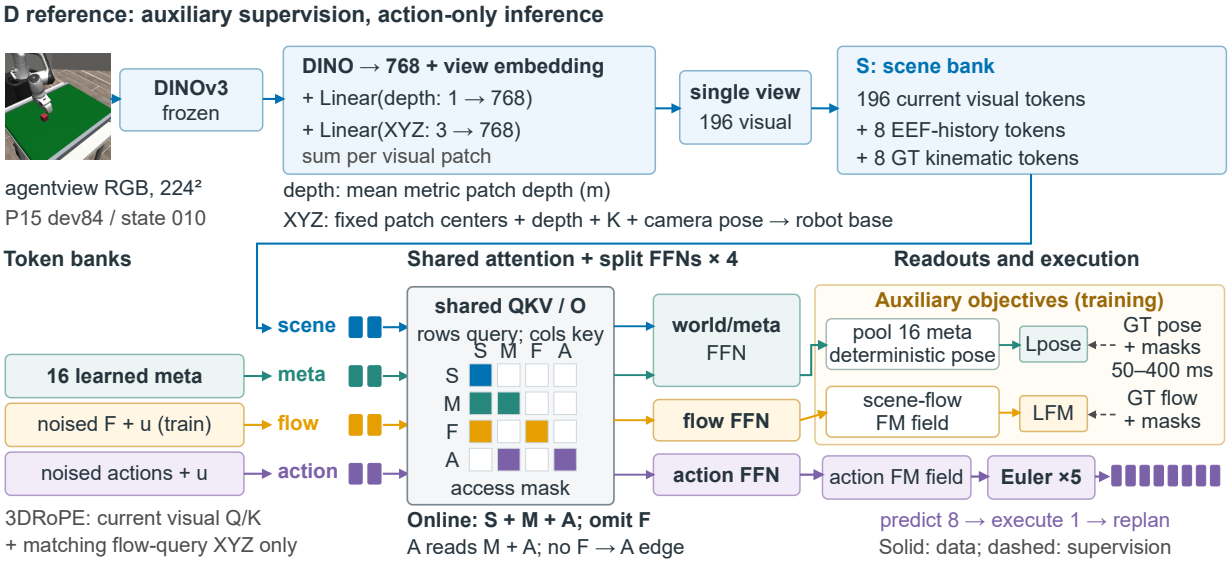


图 2: D 参照模型，以 P03 的位姿和场景流目标为例。RGB 与深度/相机几何、机器人历史和特权目标状态组成 scene bank，learned meta 为独立输入。S、M、F、A 分别表示 scene、meta、flow 和 action；矩阵给出 query 到 key 的访问关系。网络共四层，各层内部共享注意力投影，FFN 按流独立。位姿为确定性读出，场景流和动作用 flow matching 训练。未来标签与掩码提供训练监督；部署经五步 Euler 仅求解动作，执行首条 E7 指令并重规划。RGB 小图为真实 benchmark 观察；嵌入与目标定义见附录 B。

4.1 Q1：信息可得性与历史编码

历史编码器将带时间戳的观测映射为条件 tokens，$X_t = H(\mathcal{H}_t)$。设计包括时间窗、采样间隔、可见性及运动坐标。当前 RGB、RGB 窗口、codec 运动向量、光流、历史潜变量与逐帧 query 压缩，对近期变化提供不同描述。额外提供 GT 速度改变“已知什么”，重组相同视觉样本改变“如何表示”，两者需要分开比较。

当前位姿实验固定当前目标位姿与八帧机器人状态，去除物体历史运动学，比较八种视觉历史条件及重新训练的 GT 历史参照；物体运动条件则提供七个区间运动学。窗口跨度与 token 数量分别记录，位移保留时间间隔，轨迹保留可见性，不能把消失的点解释为静止。

诊断包括运动探针、匹配当前状态的历史替换、遮挡和采样间隔变化。探针检验信息能否被解码，替换检验动作是否响应历史；有效记忆还需要在有效配对条件下改善动作结果。当前状态匹配、历史必要子集和闭环干预仍是 Q1 待完成部分。

4.2 Q2：预测交互相关变量

Q2 区分预测范围、变量和粒度。范围包括目标、环境或二者；变量包括位姿、运动和视觉特征；粒度涉及空间与时间分配。已完成实验比较无未来目标、场景流、目标位姿、联合目标、替代表示与附加监督。场景流也覆盖目标区域，因此“只预测场景流”不是排除目标后的 context-only 对照。

对于刚体目标，当前位姿为固定米制坐标系中的 (p_t, R_t)。在 $\delta_h = 0.05h$ 秒、$h = 1, \ldots, 8$ 处，实际监督量为

$$d_h = p_{t+\delta_h} - p_t, \qquad \phi_h = \mathrm{Log}(R_{t+\delta_h} R_t^\top)^\vee. \tag{3}$$

重建使用

$$\hat{p}_{t+\delta_h} = p_t + \hat{d}_h, \qquad \hat{R}_{t+\delta_h} = \mathrm{Exp}(\hat{\phi}_h^\wedge) R_t. \tag{4}$$

累计平移与左相对旋转分别参数化。位姿读出将 16 个 meta tokens 池化后预测八个累计变换，在有效标签上使用平移平方误差与 0.1 倍旋转测地距离平方。该输出形式不赋予网络严格等变性。

场景流目标是米制累计点位移；替代目标包括稠密二维位移、codec 块运动、带可见性的稀疏场景轨迹及视频潜变量。对象目标还包括池化 DINO 特征和目标轨迹；附加监督包括未来深度、DINO 空间特征和动态区域 RGB。各表示的单位、有效支持和维度不同，因此替换实验比较的是具体表示配置，不能单独归因于二维或三维，也不能直接证明异粒度分配最优。

这些未来量沿示教轨迹提取，在已完成实验中用于辅助训练。标签与有效掩码只进入对应监督分支；掩码描述几何支持与可见性，不保证同一未来在替代动作下仍有效。确定性读出和生成变量具有不同接口。直接检验“目标细、环境粗”仍需在相同身份信息、物理时域和适用的 token/计算预算下，用兼容表示比较统一与异粒度分配。训练标签使用目标 mask，也不等于系统已经能够从视觉可靠地指定目标。

4.3 共同模型、训练与动作生成

Q2 共同模型为四层、宽 768、八头的 Transformer，冻结 DINOv3 ViT-L/16[25]，从 224×224 当前图像提取 196 个 tokens。D 主干共享 attention 投影，为 world/meta、flow 和 action 设置分列 FFN。Action 读取 meta 与 action tokens，不读取预测 flow 或 flow hidden states；未来 loss 可以经共享参数影响动作学习。

动作采用 flow matching[19]。令 a_1 为归一化动作目标，$a_0 \sim \mathcal{N}(0, I)$，插值时间 $u \in [0, 1]$，则

$$a_u = (1-u)a_0 + ua_1, \qquad \mathcal{L}_A = \mathbb{E}\|v_\theta(a_u, u, X_t) - (a_1 - a_0)\|^2. \tag{5}$$

总目标为 $\mathcal{L} = \mathcal{L}_A + \sum_{r \in Z} \lambda_r \mathcal{L}_r$，只加入启用的未来 loss，并按各自有效掩码计算。不同 loss 组合的 total loss 不能直接排成统一质量顺序。

动作块包含八个 E7 指令：基座系平移增量、左相对旋转向量与夹爪指令。部署采用五步 Euler 解码，每次执行第一步后重规划。conditioning cache 开启，temporal 和 velocity cache 关闭。训练平移界限为每轴 0.05 m，继承评测器的执行界限为每轴 0.10 m，二者分别保留。已完成 Q2 部署只求解 Action。

4.4 Q3：主干与信息流

接下来的主干比较固定完整 H/Z 和 Action 不读取预测未来的 G_0 程序，对照 D 的分列 FFN 组织与适配后的 E 世界/动作参数组织。两臂计划均从头训练，活动主干参数差控制在约 5% 内；比较结果尚待完成。

固定 $H/Z/B$ 后，七种信息流配置分别是：R0 去除研究中的未来 loss；R1 保留 loss 但没有跨流边；R2 允许 Future 到 Action；R3 允许 Action 到 Future；R4 双向访问；R5 先生成 Future 再生成 Action；R6 先 Action 再 Future。R1 还比较同一 checkpoint 的 Action-only 与 joint 部署。它们分别回答监督、信息访问和生成程序的问题。顺序模型的第二阶段在训练时使用干净 GT、部署时使用预测值，因此其差异还包含 teacher forcing 及训练—部署失配。

当前生成接口仅定义了场景流。若最终选择稀疏轨迹或视频潜变量，需要先明确其生成状态、归一化、噪声和损失，不能直接以场景流替代。同步五次联合调用与顺序五加五次调用只匹配每模态步数，总计算量仍不同；比较须报告实际调用数、容量和同设备时延。未来 oracle 或有效替换等干预，依赖可替换的预测接口。

5 实验

本文区分三套研究配方。未来监督实验使用当前 RGB、DINO-L、GT 目标运动学，关闭 Alpha，学习率按四轮 cosine 衰减。历史实验使用当前 GT 位姿、DINO-L 及 pose/flow/Alpha 监督，第一轮 cosine 衰减，后三轮固定学习率。组合实验使用完整 T8 图像、GT 运动学、DINO-S 或 CNN，关闭 Alpha，采用四轮 cosine。三者均保留机器人状态历史。

5.1 系统参照与训练条件

DreamVLA 两个配方分别达到 1,000 和 1,003 场成功，当前候选 I 为 839 场，无未来参照为 791 场。该差距为系统改进提供参照，不能单独归因于未来表示。DreamVLA 的 20 轮端点来自独立重训，不是 40 轮轨迹的中间 checkpoint。

十五组未来监督共享 fresh seed0，均训练四轮、40,104 次更新、641,664 个 chunks，global batch16，使用固定第四轮终点。各臂训练分布在八或十六张设备上，拓扑履历单独保留。单端点配对比较可以分析场景差异，不能估计训练种子波动。当前位姿、运动历史、动作目标和每次执行一步的协议在该系列内保持一致。

表 1: 十四任务系统参照。两类场景分别计数，均为单训练 seed 端点；预训练、预算、输入和执行器不同。下方三行具有特权当前目标位姿与区间运动学，不构成与上方方法的公平纯架构消融。

系统	fixed140	1,260 场补集	补集成功率
ACT	50/140	424/1,260	33.65%
Diffusion Policy	54/140	432/1,260	34.29%
$\pi_{0.5}$	89/140	751/1,260	59.60%
DynamicVLA	24/140	363/1,260	28.81%
OpenWAM-Alpha	76/140	708/1,260	56.19%
DynamicWAM	72/140	670/1,260	53.17%
DreamVLA，20 轮配方	112/140	1,000/1,260	79.37%
DreamVLA，40 轮配方	114/140	1,003/1,260	79.60%
P00，无未来监督	88/140	791/1,260	62.78%
P03，场景流＋位姿	93/140	786/1,260	62.38%
候选 I，P07 ＋ CNN ＋重建	96/140	839/1,260	66.59%

5.2 Q2：哪些未来监督有益？

加入场景流与目标位姿。 P00、P01、P02 和 P03 分别成功 791、782、789 和 786 场。在已有特权运动信息、部署不读取预测未来的条件下，联合目标没有显示总体收益，也未体现两种监督的总体互补。

改变预测变量。 P07 和 P09 分别比 P00 净多 16 和 17 场成功。P07 新增 85 场成功、失去 69 场；P09 新增 91 场、失去 74 场。原始精确双侧 McNemar 检验 p 分别为 0.227 和 0.213，尚未形成明确总体优势。未检出差异也不表示等效：P12 虽然与 P00 成功总数相同，仍有 73 场新增成功和 73 场新增失败。

P05 相对 P00 和 P03 分别下降 3.57 和 3.17 个百分点；对 27 项总体比较作 Bonferroni 校正后，p 为 0.00844 和 0.01877。这支持该具体稠密二维表示配置在当前配方下表现不利，不能据此推出二维表示普遍不如三维，因为 P07 和 P09 也采用二维轨迹，但预测范围与支持不同。

任务差异与失败。 十五组在刚体运动容器放置 t2_se3 上均为 0/90；完整约束穿越 t3_full 仅 P00 和 P06 分别为 3/90 和 4/90，其余为零。改变未来目标尚未消除这些共同困难。P05 相对 P03 在滚动球捕获中少成功 27 场，对应 tray_contact 失败从 40 增加到 67；P09 在平移放置与碰撞后重规划中有所增加，却在朝向敏感抓取中下降。这些失败码定位了任务差异，表示如何导致差异仍需干预实验解释。

开发集排序。 fixed140 中 P01 点估计最高，1,260 场补集中则为 P09。开发子集排序没有在其余场景中保持，因此需要保留有竞争力的候选进入组合比较，而非据初次排序确定设计原则。

5.3 未来目标与视觉编码的组合

十二组实验交叉 P07、P09、P15，DINO-S 或 CNN，以及是否重建当前目标 RGB。该系列保留完整视觉窗口和特权目标运动信息，按预先约定的 1,400 场成功数选择配置。

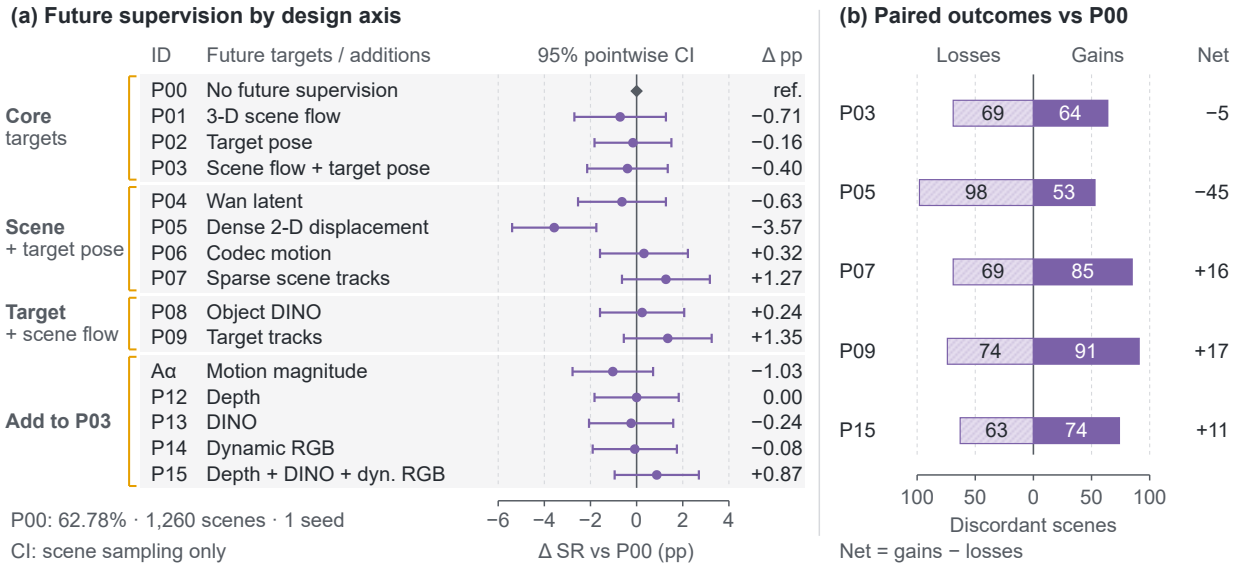


图 3: 未来监督的条件比较。每组为一个训练 seed 的第四轮终点，使用十四任务各 90 场，共 1,260 个配对场景，不包含 fixed140。(a) 十五组按改变的目标分组，点为相对 P00（62.78%）的成功率百分点差，线为任务内配对 bootstrap 的逐项 95% 置信区间。(b) 所列条件与 P00 的场景交换：gain 为候选成功、P00 失败；loss 反之；net 为两者之差。P05 在 27 项总体比较校正后表现不利，P07/P09 尚无明确总体收益。区间以已训练端点为条件，不包含训练 seed 波动。

候选 I，即 P07 + CNN +重建，以 935/1,400（66.79%）被选中；其补集结果为 839/1,260（66.59%）。相对不重建的同 P07/CNN 配置 J，净增 39 场主要来自相位穿越增加 44 场、朝向敏感抓取增加 17 场，同时平移放置减少 10 场、XYZ 抓取减少 7 场。十二组在 t2_se3 和 t3_full 上均为 0/100。

匹配的无未来监督控制 F 保留相同 CNN、视觉窗口与重建目标，获得 810/1,400（57.86%），其中补集为 731/1,260。相同场景上，I 新增 189 次成功、损失 64 次，净增 125 次，即 8.93 个百分点（逐项 95% 置信区间 7.00–10.86）；相位穿越贡献 72 次净增，平移放置则减少 7 次。这支持所选未来目标在该配方下的条件性收益。I 由同一场景池的十二个候选中选出，区间不校正候选选择偏差；仍需更多训练 seed 与未参与选择的场景确认，匹配 P03 控制也尚未完成。

5.4 Q1：当前目标位姿条件下的视觉历史

八个当前位姿条件已形成完整结果，fresh GT 运动历史参照尚待评测完成：

当前图像为 53.43%，七种视觉历史编码均未在点估计上超过它；Wan 为 50.71%，PACT-Uniform 为 47.86%。这一实验保留机器人状态历史和当前 GT 目标位姿，检验定位已知条件下的视觉运动信息。跨研究分数差无法识别历史与未来目标的交互。后续将在共同配方下交叉当前位姿/GT 运动、当前图像/视觉历史条件，检验特权运动是否削弱视觉历史的边际价值。已提取的探针数据还需统计分析和闭环干预。

5.5 执行与学习诊断

未来监督系列的同设备调用均值为 177.071–184.212 ms，p95 为 178.726–185.133 ms，峰值已分配显存为 1.571–1.617 GiB。计时覆盖策略内部感知和动作计算，排除外部 oracle 读取、I/O、渲

表 2: 组合筛选的 1,400 场成功数，包含 fixed140 开发场景。列按视觉编码器与当前目标 RGB 重建组织；候选标识和逐任务计数见补充材料。

	DINO-S		CNN	
未来目标	无重建	有重建	无重建	有重建
P15：P03 ＋三项辅助	873	836	875	867
P07：场景轨迹＋位姿	840	849	896	935
P09：场景流＋目标轨迹	820	830	829	870
所选配置的匹配控制				
P00：无未来监督	—	—	—	810
P03：场景流＋位姿	—	—	—	待完成

表 3: 当前目标位姿条件下已完成的视觉历史比较。各臂保留机器人状态历史，去除物体历史运动学。区间为相对当前图像的逐项 95% 配对场景 bootstrap 区间，不包含训练 seed 与选择不确定性。

视觉历史	fixed140	1,260 场补集	合计 1,400 场	差值区间（百分点）
当前图像	80	668	748	—
Window	69	593	662	$[-8.43, -3.79]$
Codec-MV	77	656	733	$[-3.36, 1.21]$
Flow	76	644	720	$[-4.43, 0.43]$
Flow12D	75	648	723	$[-4.21, 0.64]$
PACT-Age	65	569	634	$[-10.64, -5.64]$
Wan	70	640	710	$[-5.29, -0.14]$
PACT-Uniform	68	602	670	$[-8.00, -3.14]$

染、加载和 priming。单轮固定顺序测量只用于描述当前成本范围，几毫秒的差异尚不足以确定效率排序。50 ms 是物理动作间隔；当前同步评测没有验证 20 Hz 墙钟实时控制。

难任务诊断还发现监督与执行位置错配：历史 T3-full 的 800 条示教均只在末动作释放，释放在动作块 h_7 有监督，实际执行的 h_0 没有对应监督。因此问题是已执行位置的监督覆盖，而不是全部释放标签缺失。短诊断训练只产生不稳定成功，已测首动作加权端点没有形成有效解法。这提示在将困难任务失败归因于未来表示前，需要先核对实际执行位置的监督。

5.6 后续实验与最终模型选择

主干、信息流与交叉确认。 完成组合控制与历史比较后，D/E 主干分别用三个独立训练 seed 配对比较，再在固定 $H/Z/B$ 下研究七种信息流配置。比较分别检验辅助监督、在线访问和生成顺序，并报告成本。改变信息流后重新比较保留的未来表示，将所选信息流用于原先未选主干；改变未来目标后重新比较历史编码。完整设计还需多 seed 及未参与选择的场景确认。【待完成：D/E、R0–R6、交叉确认及成本结果。】

真实数据基座与独立后训练。 下一阶段固定已确认设计，研究训练配方、模型规模、数据量与计算预算。DROID 数据准备需为选中目标提供经标定、时间对齐和有效掩码处理的监督；数据集不

直接提供目标物体位姿真值。正式基座由真实机器人数据预训练，仿真与真机从同一基座独立后训练，仿真权重不进入正式真机初始化。有无预训练将同时在共同下游预算和各自等预算调参后比较，并单列预训练成本。【待完成：正式基座、scaling 及两个后训练分支的结果。】

外部与部署验证。 单臂 DOMINO、静态兼容性和真实传送带操作分别提供外部动态、静态及集成部署证据。最后阶段复用已完成规模和后训练结果，只补齐尚未覆盖的对象、场景、运动与真实延迟条件。各基准保留原生评分，不与十四任务 SR 合并；相关实验同时报告接触误差、安全、实际动作年龄和端到端成本。【待完成：最终 SE(3)-WAM 配置与外部、真机结果。】

6 讨论与结论

本文研究动态操作应当记住和预测什么。最初的十五组比较中，目标和场景预测监督尚未带来明确总体优势：稀疏轨迹的点估计略高，稠密二维位移在所测配方下表现不利。改用 CNN 与当前目标重建后，所选轨迹监督配置超过匹配的无未来监督控制，但两项困难任务仍然全失败。结合历史实验，这些结果说明，表示效果需要在具体输入与训练配方下评估；所选设计的稳定性还需独立确认。

当前证据覆盖十四项仿真任务，主要筛选使用单训练 seed、特权目标信息与同步执行。“目标细、环境粗”、在线预测的有效使用、多 seed 稳定性及真机迁移仍待检验。后续比较将保留有竞争力的候选，以任务间收益与损失、动作级干预和部署成本共同确定最终 SE(3)-WAM。

参考文献

[1] Iretiayo Akinola, Jie Xu, Shuran Song, and Peter K. Allen. Dynamic grasping with reachability and motion awareness. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 9422–9429, 2021.

[2] Amir Bar, Gaoyue Zhou, Danny Tran, Trevor Darrell, and Yann LeCun. Navigation world models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[3] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-Time Execution of Action Chunking Flow Policies. In *Advances in Neural Information Processing Systems*, 2025.

[4] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning Rigid Body Motion using Deep Neural Networks. In *IEEE International Conference on Robotics and Automation*, 2017.

[5] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured Deep Dynamics Models for Visuomotor Planning and Control. *arXiv preprint arXiv:1710.00489*, 2017.

[6] Yixiang Chen, Peiyan Li, Yuan Xu, Qisen Ma, Jiabing Yang, Kai Wang, Jianhua Yang, Dong An, He Guan, Gaoteng Liu, Jianlou Si, Jun Huang, Jing Liu, Nianfeng Liu, Yan Huang, and Liang Wang. FlowWAM: Optical Flow as a Unified Action Representation for World Action Models. *arXiv preprint arXiv:2607.13017*, 2026.

[7] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[8] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled Object-Centric Image Representation for Robotic Manipulation. *arXiv preprint arXiv:2503.11565*, 2025.

[9] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. In *European Conference on Computer Vision*, 2026.

[10] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[11] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video Prediction Policy: A Generalist Robot Policy with Predictive Visual Representations. In *International Conference on Machine Learning*, 2025.

[12] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Fei-Fei Li. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation.

In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[13] Wei Huang, Bohan Zhang, Chenzhi Liu, Isabella Liu, Shuai Yang, Weian Mao, Luozhou Wang, Yicheng Xiao, Weifeng Lin, Qixin Hu, Bryan Chu, Sifei Liu, Linxi Fan, Xiaojuan Qi, Song Han, and Yukang Chen. Long-WAM: Scaling the Context of World-Action Models. *arXiv preprint arXiv:2610.10528*, 2026.

[14] Haoyuan Ji, Lingxiang Fan, Shang Su, Yinqiao Lu, Mengkai Shi, Jun Gao, and Shuo Feng. DC-WAM: Dynamic-Centric Visual Supervision and Reasoning for World-Action Models. *arXiv preprint arXiv:2607.25918*, 2026.

[15] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.

[16] Fenghao Lei, Zhixiong Huang, Long Yang, Jiabao Chen, Peilin Huang, Han Fu, Zhuo Li, and Xiaoxue Ren. DELE-w0.5: Inferring Action from Future Latent State for Robotic Manipulation. *arXiv preprint arXiv:2608.22067*, 2026.

[17] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling Dynamic Manipulation from a Single Static Demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[18] Minghui Lin, Pengxiang Ding, Shu Wang, Zifeng Zhuang, Yang Liu, Xinyang Tong, Wenxuan Song, Shangke Lyu, Siteng Huang, and Donglin Wang. HiF-VLA: Hindsight, Insight and Foresight through Motion Representation for Vision-Language-Action Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[19] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[20] Yushan Liu, Jingjing Fan, Shoujie Li, Yifan Xie, Xiao-Ping Zhang, and Wenbo Ding. PACT-WAM: Predicting Actions and Visual Foresight with Compact Temporal Encoding for Robot Manipulation. *arXiv preprint arXiv:2602.15882*, 2026.

[21] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[22] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[23] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal Future-Token Distillation from a World Action Model for Conveyor-Belt Manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[24] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.

[25] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[26] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. In *Conference on Robot Learning*, 2026.

[27] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[28] Changhao Wang, Jaden Clark, and Shuran Song. Chronos Policy: Learning Robot Policies on Physical Time. *arXiv preprint arXiv:2610.13929*, 2026.

[29] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An Open, Modular Exploration Towards Systematic World-Action Model Pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[30] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point Trajectory Modeling for Policy Learning. *arXiv preprint arXiv:2401.00025*, 2024.

[31] Gaoyuan Wu, Ziyu Shan, Haoyang Du, Yuyao Jiang, and Ziwei Wang. AffordTrajDP: Dynamic Affordance-Guided Visuomotor Policy Learning for Robotic Manipulation. *arXiv preprint arXiv:2608.01603*, 2026.

[32] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. In *Advances in Neural Information Processing Systems*, 2026.

[33] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the Cross-Domain Manipulation Interface. In *Conference on Robot Learning*, 2024.

[34] Zhenjia Xu, Zhanpeng He, Jiajun Wu, and Shuran Song. Learning 3D Dynamic Scene Representations for Robot Manipulation. In *Conference on Robot Learning*, 2020.

[35] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[36] Heng Yu, David D. Yuan, Juze Zhang, Changan Chen, Yao Feng, Michelle Baldonado, Steve Cousins, Fei-Fei Li, Jiajun Wu, and Ehsan Adeli. OpenWAM: An open framework for composable world-action models. *arXiv preprint arXiv:2610.07922*, 2026.

[37] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB Future Prediction for World Action Models. *arXiv preprint arXiv:2608.04996*, 2026.

[38] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

[39] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. In *European Conference on Computer Vision*, 2026.

[40] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[41] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[42] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Ming-Yu Liu, Donglai Xiang, Gordon Wetzstein, and Tsung-Yi Lin. CoT-VLA: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[43] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.

[44] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual Trace Prompting Enhances Spatial-Temporal Awareness for Generalist Robotic Policies. *arXiv preprint arXiv:2412.10345*, 2024.

[45] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

补充材料：数据、实现与完整结果

A 任务、数据与统计口径

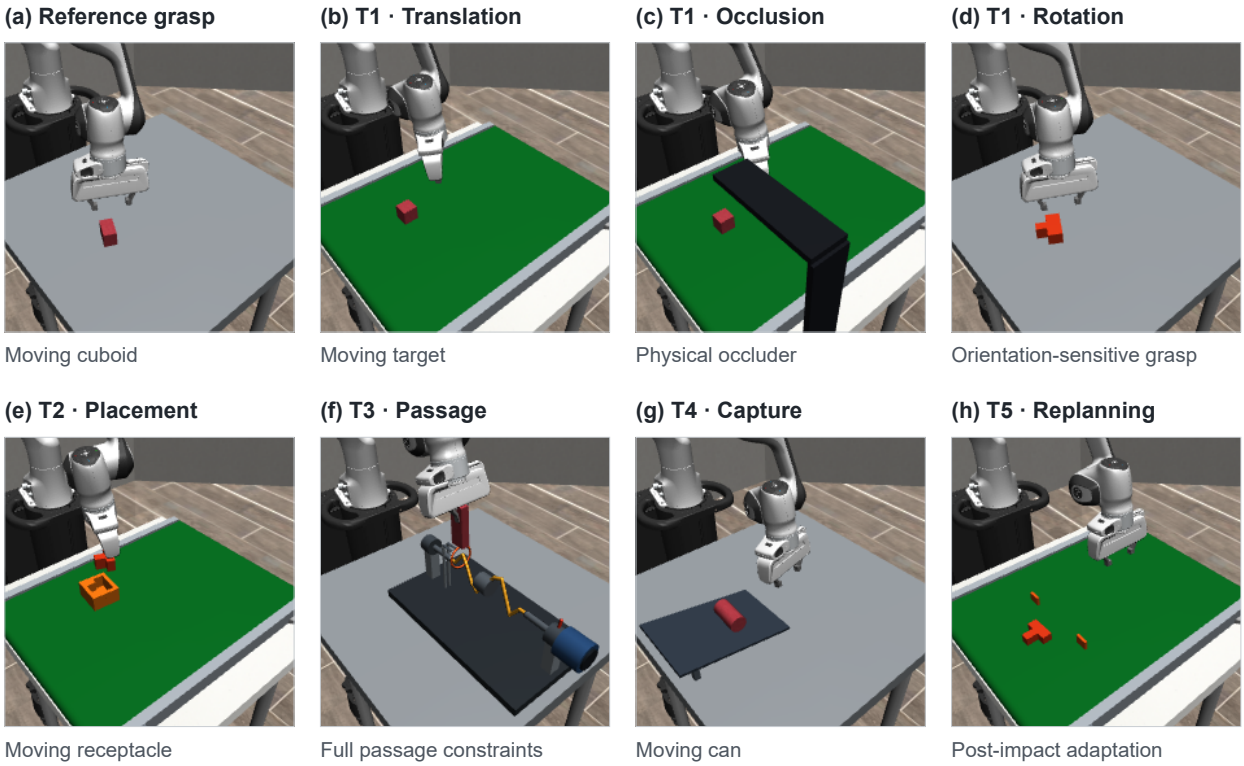


图 S1: Benchmark 记录观测示例。八个面板覆盖参考抓取、T1 平移/物理遮挡/朝向敏感抓取，以及 T2 移动容器放置、T3 约束穿越、T4 捕获和 T5 碰撞后适应。每项展示任务取已接受 DEV84 清单的最低 state index，显示最后一帧未经裁切的 224×224 agentview RGB。标签表示任务条件；快照展示外观与几何，任务结果另行统计。

表 S1 列出十四项任务的原生成功条件；全部任务进入等权评分，包括零成功任务。FUTURE0、BASE2 和 HISTORY1 的已接受部署包指向同一历史评测器、任务配置和十四任务场景清单，表中定义由该归档恢复。控制频率为 20 Hz，物理步长为 2 ms，每个物理步检查成功与终止事件。连续条件中断后计数清零。T4 空中球体的名义 25 ms 双侧抓持离散为 12 个物理采样，即 24 ms；T2 低相对运动计数达标的同一步开始驻留计数，不能将两段时长机械相加为精确 0.600 s。

原生失败分为五类：invalid 为无效状态；boundary 包括工作区/下游越界、掉落和目标窗口过期；safety 包括不安全接触、过大容器边缘冲量、碰线、阶段阻挡、释放冲量、过早机器人接触、托盘或夹爪—支撑面接触以及撞击器夹困；task violation 包括驱动受阻、目标外释放、路径偏离/回退、过早释放、只停止或拨开而未捕获、罐体失稳，以及缺失/额外撞击、错误撞击器接触、出射运动变化不足；timeout 为超时。这些名称是评测器结果类别。

失败类别没有统一优先级。每个 family 按当前物理步的代码顺序选取首个终止事件，终止后不再改写。Grasp 依次检查无效状态、工作区越界、下游越界、掉落、成功、超时；T1 在无效状态后插入遮挡体不安全接触。T2 依次检查无效状态、边缘冲量 $> 0.10\,\mathrm{N\,s}$、掉落、目标窗口过期、目标外释放、成功、超时。T3 依次检查无效状态、阶段阻挡、掉落、工作区越界、碰线、过早释放、路径偏离、回退、成功、超时。碰线阈值为冲量 $> 0.020\,\mathrm{N\,s}$，或穿透 $> 0.004\,\mathrm{m}$ 连续超过两步；

表 S1: Native success conditions in the reported fourteen-task suite. Thresholds come from the evaluator source and task configurations bound to the accepted FUTURE0, BASE2, and HISTORY1 packages. A task must pass its preceding stages and avoid terminal failures. All tasks run at 20 Hz with a 2 ms physics step; durations below refer to physical time. COM denotes center of mass.

Task	Ordered success conditions	Limit
grasp; t1_belt, t1_xyz, t1_so3, t1_occ	Approach within 0.10 m; bilateral fingerpad contact for 0.05 s; collision-geometry bottom at least 0.05 m above support; retain contact and clearance for 0.50 s. T1 adds conveyor drive, translation, rotation, or a physical occluder. SO3 has no additional success-angle threshold; unsafe occluder contact terminates OCC.	160 steps 8 s
t2_trans	Approach within 0.10 m. Entire object collision geometry inside the receptacle: planar clearance and floor gap both ≥ -0.002 m, top no higher than the opening. Release requires an opening command < -0.5 and no fingerpad contact. Relative linear/angular speeds ≤ 0.08 m/s and 0.8 rad/s for 0.10 s, followed by a 0.50 s stable dwell.	200 10 s
t2_se3	Approach within 0.05 m and 0.12 rad. Full T-shaped containment: planar clearance ≥ 0.002 m, floor gap in $[-0.002, 0.002]$ m, tilt ≤ 0.05 rad, top below opening. After release, relative speeds ≤ 0.02 m/s and 0.04 rad/s for 0.10 s, then a 0.50 s dwell. The 0.12 rad gate applies to approach.	200 10 s
t3_phase	Start with the native pre-grasp. Phase alignment: distance ≤ 0.090 m and loop-direction error ≤ 0.20 rad. Enter within 0.030 m at progress ≤ 0.15; reach historical maximum progress ≥ 0.60, then ≥ 0.85 and endpoint distance ≤ 0.055 m.	420 21 s
t3_full	Acquire the wand with bilateral contact for 0.05 s, then complete the phase stages above. In a later sample, retain current progress ≥ 0.85 and move at least 0.045 m from both path and endpoint. Finally open (< -0.5) with no fingerpad contact. Releasing before exit fails.	640 32 s
t4_sphere	Approach within 0.10 m; first qualifying contact after ramp exit; any tray contact before success fails. Bilateral hold for nominal 25 ms (12 physics samples, 24 ms). Raise COM by 0.05 m from its height when the bilateral-hold criterion is first met, and retain contact and height for 0.50 s.	120 6 s
t4_sphere_tabletop; t4_slider	Approach within 0.10 m; contact after ramp exit, while supported, in the capture region, and moving at planar speed ≥ 0.08 m/s. Bilateral hold for 0.05 s, COM lift ≥ 0.05 m from the first attainment of that hold criterion, then contact and height for 0.50 s.	120 6 s
t4_can	Same supported-capture sequence. Before first fingerpad contact, a can-axis absolute dot product with vertical > 0.45 fails as unstable tipping. The configuration does not require a transverse closing axis.	120 6 s
t5_replan	Exactly one selected-side impact group completes before robot contact. At 30 ms after the physical impact-end timestamp, branch-signed lateral speed ≥ 0.035 m/s and yaw rate ≥ 0.35 rad/s. Approach within 0.10 m; bilateral hold with grasp-axis error $\leq 18^\circ$ for 0.05 s; COM lift ≥ 0.05 m from the first attainment of that hold criterion and stable hold for 0.50 s. Impact-group lag is 12 ms and maximum contact is 0.10 s.	120 6 s

路径偏离 > 0.030 m 持续 0.050 s 即失败，回退阈值为相对历史最大 progress 超过 0.05。

T4 依次检查无效状态、释放冲量 > 0.002 N s、不安全 ramp 接触、空中任务的托盘接触、罐

体失稳、过早接触/边界分支和不合格支撑面捕获，再检查成功与超时。目标退出 ramp 后，仍接触下游支撑面、无指垫接触且速度 $\leq 0.03\,\mathrm{m/s}$ 持续 0.25 s，判为只停止或拨开而未捕获。T5 依次检查无效状态、不安全接触、过早机器人接触、错误撞击器、额外撞击/夹困、出射变化不足、越界、成功；到达时限后，零次完成撞击判为缺失所选撞击，其余为超时。

共同训练池为 11,200 条；本文内部表征实验使用 350 条验证 episode、每轮 160,416 个 chunks。DreamVLA 和 OpenWAM 保留各自 1,400 条 heldout 设置，因此 350 不能写成所有方法统一的验证规模。future screen 的十五臂共 18,900 个有效结果，缺场与基础设施错误排除均为零。fixed140 与补集分别报告；BASE2 按完整 1,400 场选择配置。

T5 的 100 个场景均保留一个控制步，即 50 ms 的原生命令延迟，其余十三任务为零。动作队列先返回零命令，经过规定延迟后执行最早入队命令。此延迟来自场景配置；同步策略调用的实测计算耗时没有注入物理演化。

表 S2 给出历史 validation 配方的提议采样范围。连续区间由 NumPy PCG64 均匀采样，离散项在物理可行性筛选前等概率选择；已接受场景不一定仍服从均匀分布。评测直接读取 1,400 个场景的完整 ScenarioSpec，不重新采样。谐波平移为

$$p(t) = c + (0, v_y, 0)t + (A_x \sin(2\pi f_x t + \phi), 0, 0), \qquad \phi \sim U[-\pi, \pi].$$

因此采样中心 c 与初始位置存在相位相关偏移。T4 从零线/角速度释放，之后为自由动力学，不指定恒定目标速度；坡角连续采样自 $[5, 15]^\circ$。T2-SE3 训练的角速度为 $U[-.25, .25]$，验证配方排除 $(-.08, .08)$；其余十三项训练与验证提议配方相同。

表中普通位置使用世界坐标；T4 局部偏移以坡面中心为原点，三轴为横向、下坡方向与坡面法向，按 $p_{\mathrm{world}} = c_{\mathrm{ramp}} + R_x(-\alpha)p_{\mathrm{offset}}$ 转换。坡面中心由出口 lip 和坡面半尺寸计算，偏移不能直接加到 lip 上。

遮挡验收要求初始可见至少八帧、可见比例 $\geq .95$，完全遮挡十至六十帧、比例 $\leq .05$，再出现至少三帧、比例 $\geq .8$；20 Hz 下遮挡持续 0.5–3.0 s。这些是验收条件，不是独立采样变量。OCC 实际接受场景的带速为 0.059588–0.099852 m/s，只覆盖提议区间的一部分。接受的 source seed 存在间隔，不能用连续 seed 区间重建原场景集。

全部场景的机器人初始关节为 $(0, .19634954, 0, -2.61799388, 0, 2.94159265, .78539816)$ rad，双指位置为 $(.020833, -.020833)$ m。T4 另存临时准备目标 $x, y \sim U[-.03, .03]$、yaw $U[0, 2\pi]$，不同于表中的释放初态。

历史源码的采样配方位于 `configs/scenarios/`，任务绑定位于 `configs/tasks/`，生成入口为 `se3_wam_benchmark/cli/generate_scenarios.py`。评测包中的 `evaluation_reference/scenes/validation.jsonl` 保存完整场景，同目录 `suites/sr_<task>.yaml` 的十四套配置各重复一次并按 task 筛选；精确复现应保留这些文件及原 scenario ID、source seed。

令 b 为候选成功、参照失败的场景数，c 为候选失败、参照成功的场景数，则差值为 $100(b - c)/1260$ 个百分点。原分析对结果不一致的配对场景使用精确双侧 McNemar 检验，14 项相对 P00 与 13 项相对 P03 共 27 项整体比较组成校正族，调整值为 $\min(1, 27p)$。378 项逐任务检验只作探索性描述。

由真实配对计数计算逐项 95% 置信区间：在每项任务内有放回抽取 90 个场景对（组合实验为 100 个），保持十四任务等权，以 100,000 次重采样差值的 2.5 与 97.5 百分位构造区间，分位数采用线性插值。按四格经验概率进行多项式抽样与重采二元场景对等价。实现为 NumPy 2.3.5

表 S2: Historical validation proposal ranges. Length, linear velocity, angle, and angular velocity use m, m/s, rad, and rad/s unless marked otherwise. Positions are in world coordinates except the stated ramp-local offsets. Continuous intervals are uniform proposals; discrete choices are equiprobable before feasibility checks. Evaluation replays the stored accepted scenarios, whose distribution need not remain uniform. Harmonic centers are not initial positions.

Task	Initial-state proposal	Motion or event parameters
grasp	Harmonic center $c_x \in [-.08, .08]$, $c_y \in [-.26, -.19]$, $z = .822$; yaw $[-1.1, 1.1]$.	$v_y \in [.025, .125]$, $A_x \in [.015, .035]$, $f_x \in [.3, .7]$ Hz; $\omega_z \in [-1.2, 1.2]$.
t1_belt	Target $x \in [-.08, .08]$, $y \in [-.26, -.18]$, $z = .822$; identity orientation, zero initial twist.	Belt $v_y \in [.04, .10]$.
t1_occ	Same target proposal as Belt; canopy at $(.322, -.29, 1.20)$.	Same belt range; clearance parameter .20; physical occlusion.
t1_xyz	Harmonic center $c_x \in [-.025, .025]$, $c_y \in [-.24, -.20]$, $z = .818$; yaw $[-.35, .35]$.	$v_y \in [.04, .09]$, $A_x \in [0, .03]$, $f_x \in [.25, .65]$ Hz; $\omega_z = 0$.
t1_so3	Same as XYZ.	Same translation; $\omega_z \in [-1.2, -.4] \cup [.4, 1.2]$, equal sign probabilities.
t2_trans	Goal $x \in [-.13, -.08]$, $y \in [-.18, -.12]$, $z = .825$; fixed orientation.	Goal $v_y \in [.03, .06]$; no rotation.
t2_se3	Same goal x, y range, $z = .804$; yaw $[-.3, .3]$.	Goal $v_y \in [.03, .06]$; $\omega_z \in [-.25, -.08] \cup [.08, .25]$, equal sign probabilities.
t3_phase	Wand $x, y \in [-.03, .03]$, $z = .870$, yaw $[0, 2\pi]$; wire phase $[-.25, .35]$.	Wire center $(.10, -.02, .94)$; world-X rotation $\omega_x = -\{2.5, 3, \ldots, 7.5\}^\circ$/s (11 equal-probability values).
t3_full	Wand at $(-.05, -.02, 1.04)$ with identity orientation; same wire phase range.	Same wire rotation; cradle and release requirement enabled.
t4_sphere	Ramp-local offsets: lateral $[-.015, .015]$, longitudinal/normal $(-.145, .030)$; lip $(.06, -.02, 1.10)$.	Gravity-driven from rest; gate release at tick 0; slope $[5, 15]^\circ$; target/ramp sliding friction $[.7, .9]$; unsupported capture.
t4_sphere_tabletop	Lateral $[-.015, .015]$, longitudinal/normal $(-.124, .034)$; lip $(0, -.06, .808)$.	Same slope and release; target/ramp friction $[.7, .9]$, table friction .35.
t4_slider	Lateral $[-.015, .015]$, longitudinal/normal $(-.129, .024)$; supported ramp.	Same slope and release; target/ramp friction $[.025, .045]$, table friction $[.012, .018]$.
t4_can	Lateral $[-.010, .010]$, ramp-axis yaw $[-4, 4]^\circ$; longitudinal position follows gate geometry and oriented can extent.	Same slope and release; target/ramp friction $[.25, .45]$, table friction $[.09, .15]$.
t5_replan	$x \in [-.005, .005]$, $y = -.29$, $z = .812$; yaw $[-.08, .08]$; zero initial twist.	Belt $v_y \in [.12, .14]$; equal-probability left/right striker triggered at $y = -.13$; stroke .098, pulse .35 s, actuator scale $[1, 1.1]$, force cap 4 N; command delay 50 ms.

PCG64；27 项比较按候选与参照的字典序排列，seed 为 20261017 加从零开始的序号，I 与 F 比较的 seed 为 20261017，任务也按字典序处理。区间以已训练端点及固定任务组合为条件，不包含训

练 seed 波动或候选选择不确定性，也不是同时置信区间；未来监督整体推断仍使用上述校正检验。

B 实现与预算

D 主干为四层、width768、8heads、factorized attention 与 split_ffn，冻结 DINOv3-L/16。当前图像为 agentview224，196 个当前视觉 tokens。视觉 patch 线性投影后，加入 view embedding、有效像素平均深度的线性嵌入，以及固定 patch 中心反投影到机器人基座坐标的 XYZ 嵌入，再经单视角接口直接返回 agentview；当前配置没有跨视角 attention。中心像素索引为 7、23、……、215。XYZ 还进入视觉 Q/K 及对应 flow query 的 3D RoPE；其他 token 不分配 XYZ。

H0V 没有视觉历史 query，但保留 20 Hz 的 T8 EEF7 及八个 object tokens。25 维对象统计按 $(p, \log R, \Delta p, \log \Delta R, \Delta t, v, \omega, a, \alpha)$ 排列，来自 GT。八帧覆盖 -350 到 0 ms；前七 slot 表示相邻区间，时间编码为 -325 到 -25 ms 的区间中心，末 slot 仅保留当前绝对位姿。速度由区间位移除时间间隔，加速度由相邻速度差除区间中心时间差，不读取窗口外前驱。各维按训练统计标准化，无效维置零，再拼接 pose、interval、acceleration 三类标志，经 $28 \to 768 \to 768$ 的 GELU MLP 及时间嵌入形成 tokens。八个 object、八个 EEF 与 196 个视觉 tokens 组成 scene bank；十六个 learned meta tokens 独立初始化。当前位姿条件屏蔽历史物体位姿及全部派生区间运动学。

实际位姿损失为有效 pose 上的平移欧氏距离平方加 0.1 倍 SO(3) 测地距离平方，按有效 pose 数平均，外层权重单独设置。Action 统计取自训练集中非重复、有效的 issued E7 命令，以 FP64 累计总体均值与方差后存为 FP32。归一化后的动作使用单位高斯源；每个查询独立采样 $u \sim U[0,1)$，共享给整个 8×7chunk。scene flow 另行采样时间并使用标准差 0.02 m 的米制高斯源。位姿为确定性读出，不消费 FM 噪声和时间。执行时依次反标准化、解码旋转、裁剪平移与旋转至每轴 ± 0.10 m 和 ± 0.5 rad，再对夹爪取 sign；训练 action 声明中的平移界限为 ± 0.05 m。

未来监督比较的 AdamW 学习率为 2×10^{-4}，betas 为 $(0.9, 0.95)$，$\epsilon = 10^{-8}$，weight decay 为 0.05，梯度范数裁剪为 1。预热 1,000 次更新后，cosine 日程覆盖四轮，最低学习率比为 0.1。训练为 FP32 并启用 TF32，dropout 为零，FFN 扩展比为 4。P03 的 action、flow 和 pose 损失外层权重均为 1，Alpha 关闭。场景流动态权重为 $w_h = 1 + 128\,\mathrm{clip}(\|F_h - F_{h-1}\|_2/c, 0, 1)$，其中 $F_0 = 0$、$c = 0.014620669186115265$ m；加权 FM 损失仍除以三倍有效对应数，不除以权重和。

表 S3 列出各目标尺寸、单位和有效支持，省略 batch 与 query 轴。通常八个时域为 50 至 400 ms。几何对应沿固定源表面身份传播，未来遮挡本身不使其失效；轨迹可见性另以相机深度一致性 $\max(0.001\ \mathrm{m}, 0.001z)$ 判定。

P04 的 Wan 接收九帧 192×160、归一化至 $[-1, 1]$ 的 RGB，保留 native VAE 归一化和 posterior mean；丢弃当前 latent 后，两组未来 latent 分别覆盖第 1–4 和 5–8 帧。P06 为实际 decoder 输出的 codec 块运动。P09 在当前目标 mask 内先选最近质心的点，再做最远点采样，以 row-major 顺序处理平局；不足 32 点时补零并置为无效。P08/P09 是机制改编。普通回归先对通道平方误差取均值，再汇总全部有效位置；轨迹损失为二维 MSE 加 visibility 的 logits BCE。P04–P09 外层权重均为 1；Aalpha 为 0.5；P12、P13、P14 及 P15 中的各项均为 0.1。P15 不能识别全部两两交互。

ACT 和 DP 各 50,000 更新、global32，从头训练；$\pi_{0.5}$ 从 pi05_base 开始，30,000 更新、global256。DynamicVLA 从官方 hzxie/dynamic-vla-DOM 初始化，冻结 vision、text 和 connector，50,000 更新、global44；读取 $[-2, 0]$ 帧、horizon20，归一化统计使用 800 条示教。OpenWAM-Alpha 从

表 S3: Future targets in the representation screen. Shape excludes batch/query axes. Displacements are cumulative from the current state except codec vectors, which retain the decoder's native correspondence. All targets come from the recorded demonstration.

Target	Shape	Support, units, and validity
Scene flow	$196 \times 8 \times 3$	Fixed 14×14 patch centers; base-frame meters; valid source depth/geometry and finite future displacement.
Target pose	8×6	Cumulative translation (m) and left-relative rotvec (rad); valid object pose and query.
P04: Wan	$48 \times 2 \times 12 \times 10$	Frozen Wan2.2 VAE posterior mean and native normalization; future groups end at 200/400 ms; valid query.
P05: dense 2-D	$8 \times 2 \times 224 \times 224$	Fixed source pixels; displacement divided by 224; valid source and finite future projection.
P06: codec	$8 \times 2 \times 64 \times 64$	Each future/current pair is encoded as P/I frames; native vectors divided by 64; actual valid vector regions.
P07: scene tracks	$196 \times 8 \times 3$	Same patch source points; two displacement channels divided by 224 and one visibility logit; valid correspondences.
P08: object DINO	8×1024	Object-mask-area-weighted patch pooling; channel layer normalization; positive mask area.
P09: object tracks	$32 \times 8 \times 3$	Deterministic farthest-point sampling in the current target mask; displacement and visibility as P07; padded points invalid.
A_α: magnitude	196×8	Cumulative flow norm (m); same correspondence mask as flow.
P12: depth	$8 \times 1 \times 224 \times 224$	Metric future depth; finite positive pixels.
P13: DINO	$8 \times 196 \times 1024$	Frozen DINOv3-L/16 patches, channel layer normalization; valid query/horizon/patch.
P14: dynamic RGB	$8 \times 3 \times 224 \times 224$	RGB divided by 255; visible surfaces moving more than 1 mm in world coordinates, including robot and other geometry.

Wang 等人发布的官方基座 [29] 重新微调五轮，共 34,490 更新、global192；DynamicWAM 用官方 full 初始化，40,000 更新、global128。DreamVLA 独立 20 轮与原 40 轮配方分别 48,220 与 96,440 更新，global512。

DreamVLA 输入七帧因果 RGB、EEF 位置和 Euler 姿态、双指位置及固定任务文本，缺失 wrist 用黑图；DDIM10、CFG1.5。它预测三步，但每 tick 重新规划，将最近三个 forecast 按 $\exp(-0.01k)$ 时间集成后只执行一步。OpenWAM 输入当前 agentview、两个黑 wrist 组成的 384×320 图像，joint7、实测夹爪 opening 和任务文本映射到 native80 维 state；十次同步联合推理输出九帧视频与 32 动作，关闭视频解码，执行 32 步后再规划。其他执行器为 ACT 时间集成、DP 八步、$\pi_{0.5}$ 十步、DynamicWAM 十六步，内部 screen 一步。系统结果保留这些输入、初始化与执行差异。

C Q1 完整比较的边界

八臂的 task、scene、source seed 和 inference seed 完整配对。相对 Current，Window、Codec-MV、Flow、Flow12D、PACT-Age、Wan 和 PACT-Uniform 的 gain/loss 依次为 137/223、133/148、176/204、183/208、132/246、194/232、122/200。按附录 A 流程在每任务 100 个场景对内重采

表 S4: History encoders in the current-pose study. All conditions preserve the current 196 DINO-L visual tokens, T8 EEF states, and current object pose. History tokens are width 768 and carry no XYZ. Counts below concern added visual/numeric history tokens, not allocated scene slots.

Condition	Sampled times (ms)	History encoding	Added tokens
Current	0	Past image slots are masked.	0
Window	−350:50:0	Seven past frames, 196 DINO patches each; no query compression.	1,372
Flow	$-350, -250, -150, -50, 0$	Four $2 \times 64 \times 64$ flows; each RGB+validity field yields 64 patches and 14 learned-query outputs.	$56 + 4$
Flow12D	Same as Flow	Same visual encoder; four numeric slots receive twelve motion statistics and their flags.	$56 + 4$
Codec-MV	Same as Flow	Four actual codec MV fields, encoded by the same RGB+validity backend; no numeric slots.	56
Wan	−350:50:0	Repeat current frame once; $48 \times 3 \times 14 \times 14$ VAE latent → 147 patches → 56 queries.	56
PACT-Uniform	−350:50: − 50	Shared eight-query bank reads each of seven past frames.	56
PACT-Age	Same as Uniform	Shared query bank interpolated to $[2, 4, 6, 8, 10, 12, 14]$ per frame.	56

样 100,000 次，依上述顺序使用 seed20261017–20261023，得到主文的逐项 95% 区间。区间以 E4、seed0 端点和开发场景为条件，不作选择或多重比较调整；结果身份配对不等于九臂探针数组核查完成。 共同 T8 覆盖 $-350, -300, \ldots, 0$ ms，当前帧始终保留 196 个 DINO-L 视觉 tokens。Current、Window 和 PACT 用秒制相对时间加入固定 768 维 sin/cos 编码；Window 不压缩过去 patch，PACT 将同一个八 query bank 按端点对齐线性插值，生成各帧分配，不增加逐帧 query 参数。

Flow 与 Flow12D 采用 $[-350, -250, -150, -50, 0]$ ms 的五帧，四段时长为 100、100、100、50 ms。在 area-resize 的 64×64 图像上计算双向 Farnebäck flow[10]，参数为 pyr-scale0.5、levels3、winsize15、iterations3、poly-n5、poly-sigma1.2、flags0。可靠性要求向量有限、端点和反向双线性采样有效，且 $\|f + b(x+f)\|^2 \le 0.01(\|f\|^2 + \|b(x+f)\|^2) + 0.5$。方向映为 HSV hue，saturation 为 1，幅值除以每段 99 百分位后截到 $[0, 1]$ 作为 value；无效像素为黑且 mask0。RGB 加 validity 经 kernel/stride8 的 $4 \to 768$ 卷积，得到 64patch；加入空间和区间时间嵌入，由十四个共享 query 读取，形成每段十四个 tokens。

令有效 flow 为 (d_x, d_y)、模长为 r，横线表示像素均值，q 为 r 的 99 百分位。Flow12D 的十二维依次为

$$(\bar{d}_x, \bar{d}_y, \bar{r}, q, \Delta t, \bar{d}_x/\Delta t, \bar{d}_y/\Delta t, \bar{r}/\Delta t, q/\Delta t, a_x, a_y, \|a\|_2).$$

加速度由相邻均值速度之差除区间中心时间差计算，分母为 100、100、75 ms，首段无有效加速度。除 Δt 外各维均除以 64，不拟合均值方差；再拼接十二个有效标志，经 $24 \to 768 \to 768$ 的 GELU MLP，并加入左右端点相对时间的独立 MLP 嵌入。Pure Flow 将数值与 flags 置零，但保留四个数值槽及时间嵌入。

Codec 使用逐段独立 MPEG-4 Part2 I/P 对：无 B 帧、GOP2、quantizer2、YUV420p、单线程、bitrate10^6。其 decoder 反向向量取负后仍位于 destination block grid，不能当作 source-grid 光流；intra、未覆盖与参考出画区域无效，不作双向置信筛选。Wan 将 T8 末帧复制一次，冻结 FP32 VAE 输出 $48 \times 3 \times 14 \times 14$，组末真实时刻为 $-350, -150, 0\,\mathrm{ms}$，真实帧比例为 $1, 1, 0.75$；经 kernel/stride2 的卷积成为 147 个源 tokens，加空间与时间/比例嵌入后压为 56queries，每窗清空 VAE cache。

原实现为 Current/Window 分配 1,584 个 scene 槽，为 Flow/Flow12D 分配 272 个，其余压缩臂 268 个；其中包含被屏蔽的历史 object 槽，十六个 meta 另计。槽位数量不等于有效信息量。

八个当前位姿条件均已完成；fresh GT 历史参照已完成训练，评测与探针仍待完成。PACT-Age 将 56 个历史 query 按远至近的 $[2, 4, 6, 8, 10, 12, 14]$ 分配；Uniform 为七组各 8 个，均为逐帧 query 压缩改编。八臂各有 350 episode、1,050 窗口的探针提取与 306 项有效读出；这些数组还需整理为可报告的探针效应。Flow12D 和 Wan 在十六张 PRO6000 上从头训练；PACT-Uniform 在八张 PRO6000 训练，从 781 步按相同拓扑恢复。Window、Codec-MV 和 Flow 保留 A100 前缀并在 PRO6000 接续，PACT-Age 还经历十六至八卡转换。各臂均保持 global batch16 和四轮曝光，设备履历不用于匹配吞吐比较。

HISTORY1 采用冻结 DINO-L、原 Alpha，学习率第一轮 10,026 更新 cosine 后，三轮保持 2×10^{-5}；BASE2 使用 DINO-S/CNN、Alpha 关闭和覆盖 40,104 更新的 cosine。需要在共同配方下完成当前位姿/GT 运动与当前帧/视觉历史对照。匹配当前状态的历史替换、遮挡持续时间与采样间隔诊断，需同时保留当前状态匹配证据及实际时间。【待完成：完整九臂、匹配输入核查、探针统计与闭环干预。】

D 全部未来监督与组合结果

组合实验的 CNN 含四级 Conv2d、GroupNorm(8) 和 GELU，通道为 $3 \to 32 \to 64 \to 128 \to 192$；卷积统一 kernel4、stride2、padding1 且无 bias。224^2RGB 经四次下采样成为 196 个 192 维 patch，经 LayerNorm（$\epsilon = 10^{-6}$）与 $192 \to 768$ 投影。RGB 先除 255、双线性抗锯齿 resize，再减 $(0.485, 0.456, 0.406)$、除 $(0.229, 0.224, 0.225)$。I/F 的完整 T8 保留 1,568 视觉、八 EEF 和八 object-kinematic tokens，通过相对时间嵌入及主干 attention 融合；没有 history query 压缩或时间平均池化，十六个 meta 另计。

当前目标重建从最终 meta 均值经 $768 \to 256 \to 3072$ 的 GELU MLP 和 Sigmoid 输出 $3 \times 32 \times 32$。目标 geom ID 确定当前可见目标的紧 bbox，RGB 双线性、mask 最近邻 resize，mask 外置零。权重 0.1 的 masked L1 除以全局有效 RGB 元素数；完全不可见时 mask 为空但不丢样本。该读出只在训练时使用，不回灌动作。I/F 共享从 11,200 条训练 episode 中 1,324,374 个有效 issued actions 得到的归一化统计，350 条验证 episode 不参与拟合。

下列表格按改变的预测目标分组，给出全部条件的成功、配对差异和失败结果。场景流包含目标区域，不能将 P01 当作纯 context-only 对照。正向点估计、不利结果和任务失败全部保留。

表 S5: All fifteen future-supervision conditions, grouped by the objective changed. Each uses one training seed, four epochs, common privileged object-motion input, and action-only deployment. The 140 development scenes and 1,260-scene complement remain separate. Scene flow includes target regions.

		Development	Disjoint complement	
ID	Future supervision	Success / 140	Success / 1,260	SR (%)
Reference and component objectives				
P00	No future supervision	88	791	62.78
P01	3-D scene flow	95	782	62.06
P02	Target pose	92	789	62.62
P03	Scene flow + target pose	93	786	62.38
Scene replacements: target-pose objective retained				
P04	Wan latent + pose	92	783	62.14
P05	Dense 2-D displacement + pose	87	746	59.21
P06	Codec motion + pose	86	795	63.10
P07	Sparse scene tracks + pose	90	807	64.05
Target replacements: scene-flow objective retained				
P08	Scene flow + object DINO	89	794	63.02
P09	Scene flow + target tracks	88	808	64.13
Additional objectives: scene flow + target pose retained				
A_α	P03 + motion magnitude	89	778	61.75
P12	P03 + depth	90	791	62.78
P13	P03 + DINO	92	788	62.54
P14	P03 + dynamic RGB	89	790	62.70
P15	P03 + depth / DINO / dynamic RGB	94	802	63.65

表 S6: Paired outcomes over the same 1,260 scenes. Gain means candidate success/reference failure; loss means candidate failure/reference success. Intervals are pointwise task-stratified paired bootstrap intervals for the SR difference, conditional on the trained checkpoints (Appendix A). Exact two-sided McNemar tests use the full family of fourteen P00 and thirteen P03 contrasts: $p_{\text{adj}} = \min(1, 27p)$. P03 against itself is inapplicable.

	P00: no future supervision				P03: scene flow + target pose			
ID	Gain	Loss	95% CI (pp)	Adjusted p	Gain	Loss	95% CI (pp)	Adjusted p
Reference and component objectives								
P01	80	89	$[-2.70, 1.27]$	1	72	76	$[-2.14, 1.51]$	1
P02	61	63	$[-1.83, 1.51]$	1	61	58	$[-1.43, 1.90]$	1
P03	64	69	$[-2.14, 1.35]$	1	—	—	—	—
Scene replacements: target-pose objective retained								
P04	74	82	$[-2.54, 1.27]$	1	71	74	$[-2.06, 1.59]$	1
P05	53	98	$[-5.40, -1.75]$	0.00844	47	87	$[-4.92, -1.43]$	0.0188
P06	81	77	$[-1.59, 2.22]$	1	68	59	$[-1.03, 2.46]$	1
P07	85	69	$[-0.63, 3.17]$	1	81	60	$[-0.16, 3.49]$	1
Target replacements: scene-flow objective retained								
P08	75	72	$[-1.59, 2.06]$	1	59	51	$[-0.95, 2.22]$	1
P09	91	74	$[-0.56, 3.25]$	1	79	57	$[0.00, 3.49]$	1
Additional objectives: scene flow + target pose retained								
A_α	60	73	$[-2.78, 0.71]$	1	53	61	$[-2.30, 1.03]$	1
P12	73	73	$[-1.83, 1.83]$	1	63	58	$[-1.27, 2.06]$	1
P13	70	73	$[-2.06, 1.59]$	1	60	58	$[-1.51, 1.83]$	1
P14	71	72	$[-1.90, 1.75]$	1	62	58	$[-1.35, 2.06]$	1
P15	74	63	$[-0.95, 2.70]$	1	63	47	$[-0.32, 2.94]$	1

P05 相对 P00 和 P03 的校正 p 分别为 0.00844 和 0.01877。逐任务表保留零成功任务，失败表将全部失败计入对应条件的 1,260 场分母。

表 S7: Future-study successes: ninety scenes per task and 1,260 per condition. Columns follow the task families in Table S1; all tasks are retained, including zero-success tasks. Occl. denotes physical occlusion; Trans. denotes translating-receptacle placement; Tabletop denotes tabletop sphere capture.

	Reference	T1: target motion				T2: placement		T3: passage		T4: capture				T5	
ID	Grasp	Belt	Occl.	SO(3)	XYZ	SE(3)	Trans.	Full	Phase	Can	Slider	Sphere	Tabletop	Replan	Total
Reference and component objectives															
P00	85	90	90	75	76	0	8	3	15	90	69	45	86	59	791
P01	84	90	90	64	69	0	18	0	11	90	74	46	90	56	782
P02	87	90	90	78	73	0	7	0	0	90	71	59	89	55	789
P03	86	90	88	75	77	0	7	0	6	86	80	50	87	54	786
Scene replacements: target-pose objective retained															
P04	83	85	84	73	76	0	20	0	0	90	72	54	89	57	783
P05	84	89	90	66	75	0	10	0	0	90	71	23	88	60	746
P06	86	88	89	79	70	0	6	4	2	89	72	60	85	65	795
P07	82	90	90	78	71	0	17	0	0	89	79	55	90	66	807
Target replacements: scene-flow objective retained															
P08	84	90	90	71	81	0	13	0	0	90	77	60	90	48	794
P09	84	90	89	65	78	0	21	0	0	90	77	59	90	65	808
Additional objectives: scene flow + target pose retained															
A_α	86	90	90	72	75	0	3	0	0	85	73	55	90	59	778
P12	83	90	90	76	76	0	5	0	0	89	77	57	90	58	791
P13	86	90	90	80	73	0	6	0	0	88	78	54	90	53	788
P14	85	89	90	72	79	0	5	0	0	90	80	53	88	59	790
P15	87	90	90	79	81	0	11	0	0	90	75	54	90	55	802

表 S8: Native evaluator failure counts out of 1,260 scenes per condition, in the same design groups as the success tables. Safety is the evaluator category, not a certified safety measure. Every failure remains in the success-rate denominator.

ID	Future supervision	Boundary	Safety	Task viol.	Timeout	Total
Reference and component objectives						
P00	No future supervision	84	297	17	71	469
P01	3-D scene flow	62	324	23	69	478
P02	Target pose	77	331	17	46	471
P03	Scene flow + target pose	76	295	51	52	474
Scene replacements: target-pose objective retained						
P04	Wan latent + pose	79	310	41	47	477
P05	Dense 2-D displacement + pose	87	356	14	57	514
P06	Codec motion + pose	96	250	23	96	465
P07	Sparse scene tracks + pose	47	329	20	57	453
Target replacements: scene-flow objective retained						
P08	Scene flow + object DINO	61	322	42	41	466
P09	Scene flow + target tracks	67	299	35	51	452
Additional objectives: scene flow + target pose retained						
A_α	P03 + motion magnitude	57	315	65	45	482
P12	P03 + depth	62	327	40	40	469
P13	P03 + DINO	71	326	27	48	472
P14	P03 + dynamic RGB	70	322	18	60	470
P15	P03 + depth / DINO / dynamic RGB	59	343	19	37	458

P06 的 safety 类失败最少，为 250 次，但 timeout 最多，为 96 次；P15 的 timeout 最少，为 37 次，safety 仍有 343 次。减少某一类失败不能单独说明策略更优。

表 S9: Combination-study successes, grouped by future target and visual encoder. DINO is frozen DINO-S; CNN is trained from scratch. Minus/plus denotes current-target RGB reconstruction off/on; parentheses retain source condition IDs. F is the selected configuration's matched no-future control. Each task has one hundred scenes, including development scenes, and each condition has one training seed. Totals use the predefined 1,400-scene selection pool.

Task	P15: auxiliary				P07: scene tracks				P09: target tracks				P00
	DINO− (B)	DINO+ (A)	CNN− (D)	CNN+ (C)	DINO− (H)	DINO+ (G)	CNN− (J)	CNN+ (I)	DINO− (L)	DINO+ (K)	CNN− (N)	CNN+ (M)	CNN+ (F)
Reference grasp													
Grasp	90	89	91	92	90	92	87	90	79	85	77	87	78
T1: target motion													
Belt	100	100	99	100	100	100	100	97	99	100	90	99	100
Occlusion	100	100	99	99	99	100	100	97	96	99	82	98	98
SO(3)	86	71	80	88	75	87	69	86	69	62	64	78	71
XYZ	58	58	82	75	73	75	89	82	44	56	82	84	82
T2: receptacle motion													
SE(3)	0	0	0	0	0	0	0	0	0	0	0	0	0
Translation	8	4	6	5	9	1	14	4	4	5	9	14	11
T3: constrained passage													
Full	0	0	0	0	0	0	0	0	0	0	0	0	0
Phase	0	0	0	0	0	0	28	72	0	0	0	2	0
T4: object capture													
Can	99	99	99	98	100	99	99	100	97	99	96	99	99
Slider	88	85	88	91	74	83	86	81	84	84	88	88	77
Sphere	71	67	67	63	47	40	53	56	68	68	62	64	45
Tabletop sphere	100	100	100	99	99	100	95	98	100	100	100	100	99
T5: post-impact replanning													
Replan	73	63	64	57	74	72	76	72	80	72	79	57	50
Total / 1,400	873	836	875	867	840	849	896	935	820	830	829	870	810

BASE2 候选 I 相对 J 有 817 场共同成功、118 场仅 I 成功、79 场仅 J 成功、386 场共同失败，净差 39；该选择仍为单 seed 开发结果。

匹配控制 F 保留 I 的随机可训练 CNN、完整视觉窗口、GT 运动输入和当前目标 RGB 重建（masked L1，权重 0.1），关闭未来目标；二者均采用 fresh seed0、global batch16 和四轮 cosine 配方。F 在 fixed140 与补集分别为 79 和 731 次成功，共 810/1,400。I 与 F 有 746 场共同成功、189 场仅 I 成功、64 场仅 F 成功、401 场共同失败，净增 125 场；相位穿越净增 72、重规划净增 22，平移放置净减 7。该比较仍使用选择 I 的场景池；匹配 P03 及多 seed、未参与选择场景上的确认尚未完成。

直接检验预测粒度，需要在同一兼容表示内匹配身份信息、物理时域及 token/成本，再改变角色与精度分配。现有跨表示替换不能代替该对照。生成预测与接触事件应按同一物理时间对齐，不能用未来 FM 验证 loss 替代自由生成误差，也不能把预测误差下降直接写成动作机制。【待完成：匹配粒度对照、预测—实际—接触图及未来 oracle 诊断。】

E D/E、七配置信息流与交叉确认

BACKBONE0 当前只有准备与 CPU 接线，无 GPU 训练、SR 或成本结果。两臂计划各 fresh seed0、1、2；若沿用四轮，共六次训练 240,624 更新、8,400 场评测。活动主干参数差目标约 5%；相同曝光或参数量不等于相同 FLOPs。既定选择规则使用 2 个百分点的实际重要差异和非劣界限，以及 10% 的 p95 成本收益条件；只有区间支持对应判据时才称优越、等效或非劣。三 seed 不明确时，两臂按既有方案共同扩至五 seed。

信息流研究的 R0/R1 区分辅助监督，R1 两种部署区分是否额外生成未被读取的 future，R1–R4 区分访问关系，R2/R5 与 R3/R6 区分同步和顺序程序。三 seed 对应 21 个训练配置、24 个部署配置，按每端点 1,400 场计 33,600 场，均为计划数。Alpha 固定为零。scene-flow 生成状态形状为 $[B, S, 196, 8, 3]$；若最终选择其他未来表示，需要先完成生成接口。顺序模型的第二阶段 GT 教师强制与预测部署失配，以及 5 次 joint 对 5+5 次顺序调用的成本差异，都进入解释。

可替换未来接口建立后，再进行 oracle、匹配 swap、时间偏移或校准噪声诊断。动作变化只说明敏感性，有用预测还需由任务表现与安全结果共同验证。改变信息流后回访表示，并将所选信息流用于落选主干；必要多 seed 与未参与选择场景确认完成后，交付固定 (H, Z, B, G) 供预训练使用。【待完成：上述配置与交叉比较的实测结果。】

F 真实数据基座、规模与部署

固定设计后研究既有 loss 权重、训练配方及架构内的深度/宽度；新增表示或信息路径仍属于设计变更。DROID 准备检查时间、标定、深度、命令与实测运动、夹爪语义和训练集归一化。目标 pose 需额外估计并验证，仅生产最终所选目标与必要消融资产，保留无效标签和动作的原因与掩码。

正式基座由真实数据预训练，仿真与真机从同一基座分别后训练。对有无预训练，既比较共同下游预算，也比较双方等预算调参后的表现，单列预训练成本。数据规模、模型规模与计算量分别变化；未运行配置不进入 scaling 曲线。最终阶段复用已完成规模与迁移结果，仅补外部泛化、静态兼容性、真实传送带与实际延迟证据。

现有策略调用均值为 177.071–184.212 ms，p95 为 178.726–185.133 ms，峰值 allocated 显存为 1.571–1.617 GiB。各臂在同一 NVML 标识为 NVIDIA RPBZZZ6、显存 102,641,958,912 字节的设备上串行测量，FP32/TF32、$B = S = 1$、五步 Euler。三条真实 T8 观察各测十次，共六次 warm-up、三十次计时；每次 reset 后先做七次真实 priming，第八次调用前后均同步 CUDA。计时包含内部感知和动作生成，排除加载、I/O、reset、RNG 设置、priming、仿真与 oracle 读取；显存为预热后的 PyTorch 常驻模型与分配峰值。该轮测量不支持几毫秒差异的稳定排名。

部署测量另需记录采集、可用、预处理、推理、排队、下发与应用，以获得实际动作年龄。【待完成：正式基座和 scaling、独立后训练、原生外部成绩、真机次数和端到端计时。】

G 难任务、夹爪与定性证据

T3-full 的 800 条示教释放只在 h_7 监督，h_0 缺失。尾窗口短训有 2/16 成功，随后选定场景复核 1/6，不能据此宣称模型已稳定掌握完整任务。T3-phase 的三 seed 纠偏实验在 256 更新时为 0/96、12/96、26/96，1,024 更新时均为 0/96；首动作加权六端点共 576 场全零，GT 角色诊断另

六端点 576 场全零。将 Action 初始源置零使三个 256 更新端点变为 0/96、1/96、46/96，这是观察已有结果后选择的探索干预。

夹爪“最近三态”将指令投影到距离最近的 $\{-1, 0, +1\}$ 标签，边界为 ± 0.5。第五轮端点的 1,260 场计数分别为 sign698、固定 0.1 死区 742、最近三态 749、历史保持 741。最近三态未显示明确总体优势，历史保持还增加其他任务失败，均未成为生产默认。第四至第八轮更广泛的死区分析尚未通过严格历史轨迹一致性审计，因此未列入主表改进。

图 S2 比较 P15 第四轮端点与两种运动学外推。DEV84 包含十四任务、28 条 episode 的 84 个状态，均有八个有效时域；三例按 P15 八时域平均平移误差排序选取，规则见图注。

每项任务贡献六个状态，共 672 个有效状态—时域配对；分位数按状态等权线性插值，同一 episode 内状态可能相关。50 ms 至 400 ms 的平移误差中位数由 1.45 增至 4.04 mm，旋转误差中位数由 0.47 增至 1.07 度。

CV 和 CA 分别使用 P15 可见历史中的最后两态和三态，不读取未来标签或仿真瞬时速度。保存的原始位置、xyzw 四元数和 FP64 时间戳确认所有状态间隔 $d = 50$ ms；由此得到的末区间导数与模型未标准化 object 输入吻合。CV 预测累计平移 $h(p_0 - p_{-1})/d$；CA 预测 $hv_0 + h^2 a/2$，其中

$$v_0 = \frac{3p_0 - 4p_{-1} + p_{-2}}{2d}, \qquad a = \frac{p_0 - 2p_{-1} + p_{-2}}{d^2}.$$

CV 保留末区间速度，CA 则将位于 -25 ms 区间中心的速度外推到当前时刻。在固定机器人基座系，令 $\omega_+ = \mathrm{Log}(R_0 R_{-1}^\top)^\vee/d$、$\omega_- = \mathrm{Log}(R_{-1} R_{-2}^\top)^\vee/d$。旋转 CV 为 $\Delta R(h) = \mathrm{Exp}(h\omega_+^\wedge)$；CA 取 $\omega_0 = 1.5\omega_+ - 0.5\omega_-$、$\alpha = (\omega_+ - \omega_-)/d$，积分

$$\dot{\Delta R}(t) = [\omega_0 + t\alpha]_\times \Delta R(t), \qquad \Delta R(0) = I.$$

指数中点积分的最大步长为 1 ms，步长减半后全部预测的最大旋转差为 0.000548°。基线没有平滑、裁剪或拟合参数。

表 S10: DEV84 offline prediction errors: 84 states and eight horizons, yielding 672 dependent observations. CV/CA use the last two/three GT poses; P15 also uses the full history and its other observation inputs.

	Translation (mm)		Rotation (°)	
Method	Mean	Median	Mean	Median
P15	3.762	2.771	1.772	0.857
CV	12.943	1.444	9.675	0.175
CA	22.413	0.634	10.114	0.170

表 S10 同时报告均值与中位数。P15 的均值更低，但合并中位数高于两个外推基线；后者有较多小误差，也有较大的误差尾部。按每个状态的八时域平均误差，P15 平移优于 CV/CA 的状态分别为 42/84、37/84，旋转为 27/84、34/84。因此均值更低不能写成普遍预测优势。672 个状态—时域配对只作描述汇总，不作为独立样本作统计推断。

待补的闭环比较需对齐同一场景、相机、查询时刻、预测时刻、实际状态与接触事件，包含不利球体条件、保留轨迹候选及有效的未来到动作干预。【待完成：同步预测—接触资产与匿名视频。】

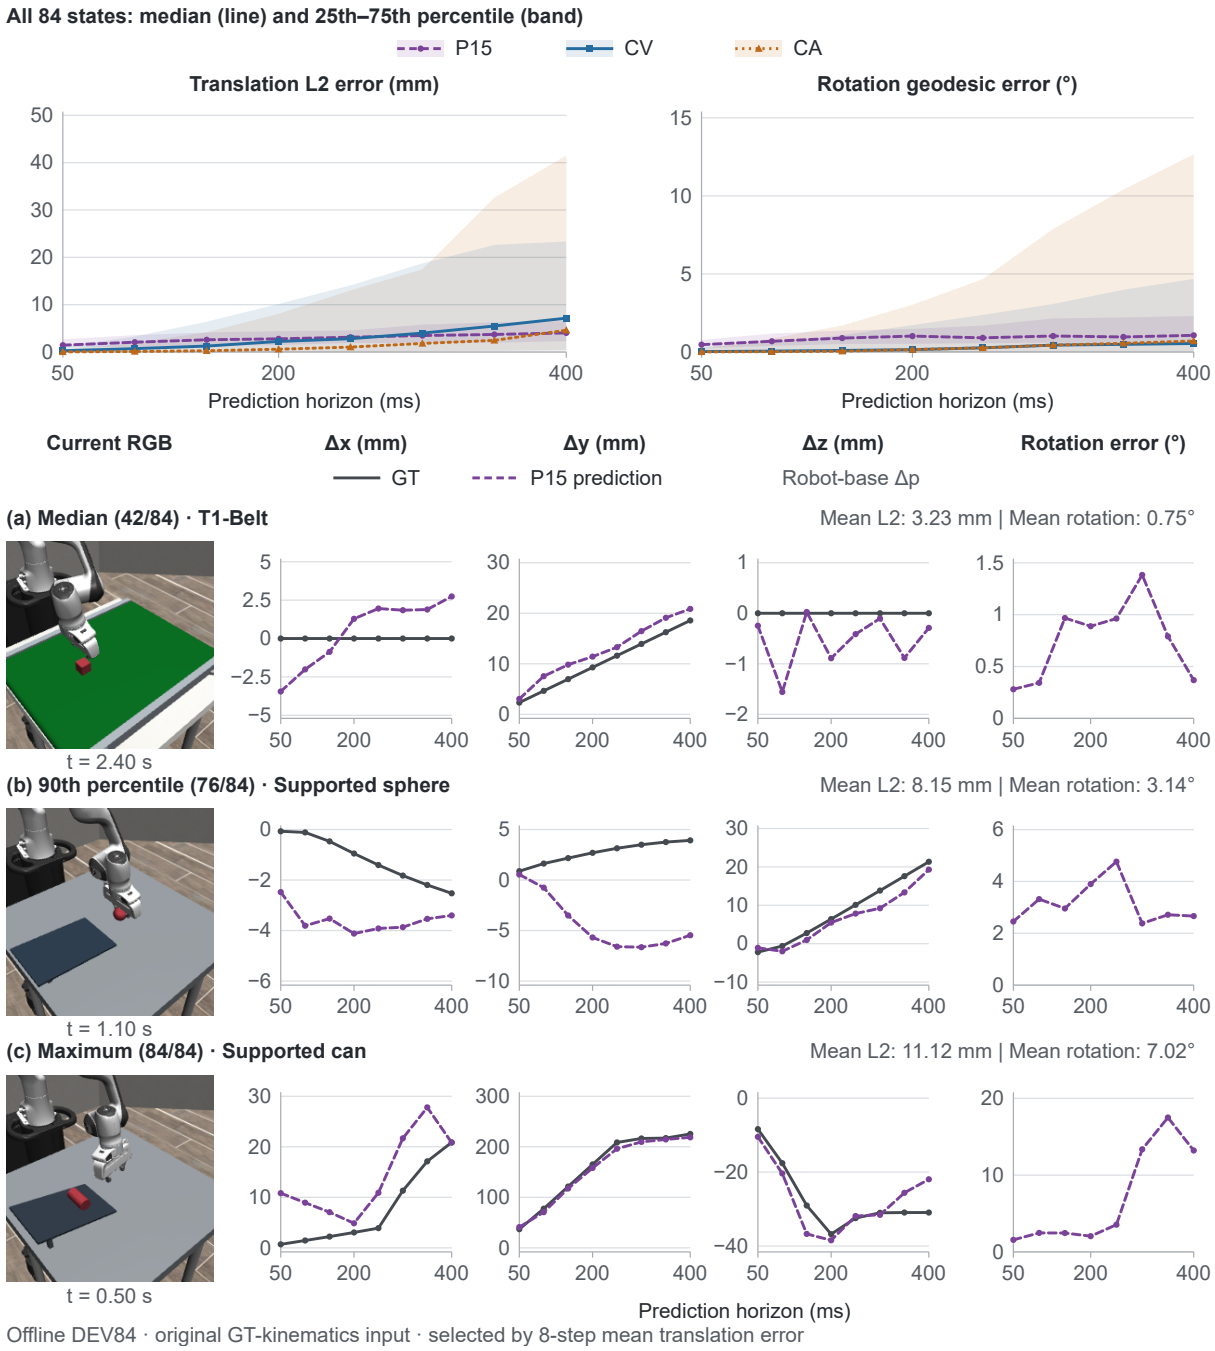


图 S2: P15 第四轮端点与运动学外推的离线预测。上方比较 P15、恒速度（CV）和恒加速度（CA）在全部 84 个状态上的逐时域误差中位数及 25–75 百分位带；带宽描述状态分布，不是置信区间。下方三个 P15 诊断例子为平均平移误差排序中的第 42、76、84 名，展示原始 RGB、累计平移预测与真值，以及旋转测地误差。模型保留 GT 物体运动学与机器人状态历史；该图不提供闭环接触或任务成功证据。

文后说明：待核实与待完成的问题

以下内容属于作者核对说明，不属于投稿正文的科学结论。

1. **完整基线尚未确定。** BASE2 的匹配 P00 已完成，P03 评测仍待完成；HISTORY1 八个当前位姿条件已完成，GT 历史参照的评测与探针仍缺。不同系列的赢家不能机械拼接。

2. **核心方法证据尚未闭合。** D/E、七配置信息流、多 seed 交叉确认、未参与选择场景，以及匹配角色/粒度实验尚无可填写结果。若保留稀疏轨迹或 Wan，需要先明确其生成接口。

3. **部署与迁移尚待测量。**当前 GT 目标位姿/运动学结果不能代表视觉定位；同步 50 ms 时钟不能代表 20 Hz 实时控制。真实数据预训练、独立仿真/真机后训练、外部基准与实机结果仍为空。

4. **接触、延迟与复现材料。**已恢复 FUTURE0、BASE2 和 HISTORY1 接受包共同引用的历史评测器与任务配置，附录给出成功规则、采样范围和回放入口；投稿匿名材料仍需实际提供这些源码、配置及场景清单。FUTURE0 尚未导出接触时刻及相对位姿、实际动作年龄。未来标签沿示教动作轨迹生成，现有几何/可见性掩码不保证替代动作下的有效性。生成预测与真实接触的对齐资产仍待补齐。

5. **统计范围。**主要系列为单训练 seed；1,260 补集与 fixed140 不重叠，但已参与开发，不是最终盲测或 OOD。本轮为未来监督、组合匹配控制及八臂历史比较计算任务内配对 bootstrap 区间；未来监督保留原 27 项校正检验；区间不包含训练随机性，也不校正 BASE2 候选选择偏差，不能据未显著推断等效。

6. **格式年度。**本稿沿用官方 CVPR 2026 author kit 并配置会议年为 2027。本轮访问 2027 Author Guidelines 仍返回 404；投稿前按 2027 正式模板、匿名和补充材料要求复核。

上一稿中缺乏当前依据、或需要纠正的内容

- 上一版把 OpenWAM-Alpha 实验基线指向 Yu 等人的同名论文，引用归属错误。现已改引 Wang 等人的模块化预训练工作（2609.07398），并将 Yu 等人的可组合框架（2610.07922）保留为 Q3 相关工作。本方 D 的重新初始化任务网络不应描述为继承其中任一预训练主干。

- “目标细、环境粗已胜出”“SE(3) + flow 形成互补”“在线预测已改善动作”“强基线一致领先”“预训练模型或实机已经验证”等不能由当前结果支持。新稿将它们保留为待检验问题，或删去无依据的完成式表述。

- 原候选公式 $\mathrm{Exp}(\xi^{\wedge})T_t$ 不对应当前独立累计平移加左相对旋转标签；新稿改为实际参数化。旧候选不确定性 NLL、对称性 loss、pose–flow 一致性和在线几何 bridge 未进入当前已完成方法描述。

- 旧双 RGB-D、width256、batch64 等配置，五个 headline 训练 seed 和 180 次实机预算，不是本轮已完成实验事实。新稿使用当前实验规格，未把历史计划改写成结果。

- 场景流包含目标区域，P01 不能叫纯 context-only；已有替换实验也不能单独证明预测粒度或二维/三维机制。

- 旧 publication manifest 生产链只是一项历史接口设想，现有导入器不证明 Benchmark 已提供生产接口。论文新表直接追溯 Research 原结果；未向旧 pending manifest 写入数值。
- 早期方法图把物体与机器人输入指向 meta tokens，未表现深度/相机几何注入。原部署包显示三类观察组成 scene bank，meta 为独立 learned tokens。新图按实际接线修正。DreamVLA 预测三步但每 tick 只执行一步；OpenWAM 实际执行 32 步后重规划，不能按预测长度或默认接口猜测执行频率。
- 场景概览初稿将参考抓取标为静止目标；历史采样配置及实际场景清单表明它包含平移与 yaw 运动，现改为 Moving cuboid。

本轮科学复核还纠正了四处初稿表述：350 条验证 episode 仅属于内部表征 screen；OpenWAM 是从官方 Alpha 基座重新微调；最近三态应译为 nearest-label ternary projection；当前 PACT 历史候选为逐帧 query 压缩而非点轨迹编码。以上均已修入全文。