FoveaWAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景；然而推断场景运动多花的每一毫秒，都会让目标走得更远。世界—动作模型以统一的精细程度预测未来图像或隐变量，把时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器速度快，却忽略了约束或推动其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；周围物体只通过它们留下的间隙和传给目标的运动起作用；其余背景则与任务无关。我们提出 FoveaWAM，一个建立在这种按角色区分精度的 4D 结构之上的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，因此只需一帧 RGB-D 作为输入。它学习精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景，这些预测只在训练中使用。这些设计合在一起，使 FoveaWAM 在一块 RTX 5090 上 [XX] ms 即可输出动作，比视频世界—动作基线快 [N] 倍。我们还提出开源基准 ConMoto，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动。FoveaWAM 在 ConMoto 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在目标运动形式多样的六个真机任务上为 [XX]%。

1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[5, 6, 12, 20, 42, 48, 62]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。在这样的场景中，动作必须适合它执行那一刻的场景，而不是观测采集那一刻的场景，因此策略必须知道场景如何运动。这种认识本身需要推断，而推断需要时间，这段时间里场景仍在运动：策略为预判运动计算得越久，需要预判得就越远。

近期的动态策略加入了对过去运动的记忆（通常是光流等图像空间线索 [14, 27]）和对未来的预测 [27, 38, 55]。基于视频的 WAM 以统一的精细程度预测完整的未来帧或隐变量，把大量计算花在视觉细节上 [42, 48]。紧凑的未来编码 [28] 降低了这一开销，度量 3D 场景动力学 [53] 引入了几何，但两者仍对整个场景一视同仁。无论哪种情况，决定接触的量——动作执行时刻目标的度量位姿——仍然是隐式的。以目标为中心的预测器和预测物体层面未来的动态 VLA 位于另一端 [14, 17]：它们速度快，但只预判目标，把可能阻挡或改变其运动的周围环境排除在外。两类方法都没有按接触对场景各部分的要求来分配精度。由此引出一个核心问题：为了完成接触并保持较低的推理延迟，策略需要知道运动场景的哪些信息，又需要知道得多精确？

我们的关键观察是：动态策略需要精确知道的东西其实很少（图 1）。接触要求目标在动作执行时刻的位姿达到毫米级精度；周围物体只通过它们留下的间隙和传给目标的运动起作用，因此只需粗略地知道。基于这一观察，我们提出 FoveaWAM，一个学习按角色区分精度的度量 4D 表示的世界—动作模型，在接触需要之处保持精确（图 2）。为了在不编码过去图像帧的情况下获得运动信息，FoveaWAM 把单帧 RGB-D 与目标度量 SE(3) 位姿的一段短历史配对。世界流通过预测目标未来的 SE(3) 轨迹，以

图占位：概念图，设计待定

计划内容：一帧 ConMoto 画面，叠加其真实的训练标签，不使用生成图像。目标在采集时刻（实线）与指令生效时刻（半透明）的位置；目标在 8 个预测时域的 SE(3) 位姿（坐标轴）；14 × 14 个 patch 点上的稀疏 3D 流（箭头，在背景上接近于零）。任务、版式与样式待定。

图 1. **概念图（占位）**。图注将随最终图一并撰写。

及以稀疏 3D 流表示的整个场景的运动，来学习这一表示。动作流读取世界流的场景 token 与摘要 token 来生成动作块，显式预测只在训练中进行 [52]。因此，FoveaWAM 把对目标运动的精确预判与较低的推理延迟结合起来，限制了从观测到动作之间场景的变化。

我们构建了开源基准 ConMoto，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动，因此每个方法都要为自己的延迟付出代价。FoveaWAM 在 ConMoto 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms，比视频世界—动作基线低 [N] 倍。它在 24 个 DOMINO 任务 [14] 上同样领先，在六个真机任务上的试验成功率为 [XX]%，最强基线为 [XX]%。受控消融检验目标运动历史与未来监督的贡献，并比较按角色区分精度与统一精度的预测，以考察精度的分配。

我们的贡献有三点：

- 我们表明，动态策略只在动作执行时刻目标的位姿上需要毫米级精度，并把这一原理实例化为按角色区分精度的 4D 建模：为目标建立精确的度量 SE(3) 轨迹，为整个场景建立粗略的稀疏 3D 流。
- 我们提出 FoveaWAM，一个把目标的度量位姿历史与按角色区分精度的预测监督相结合、以低延迟生成动作的世界—动作模型。
- 我们提出开源动态操作基准 ConMoto，它为每个策略计入其自身的推理延迟；FoveaWAM 在 ConMoto、24 个 DOMINO 任务和六个真机任务上均优于强基线。

2 相关工作

动态操作。 补偿感知与执行之间的时间差是一个经典问题，从带纯滞后的控制 [35]，到用卡尔曼类滤波器跟踪目标并规划拦截的抓取系统 [1–3, 30]；这些系统精确，但针对每种物体和任务专门设计。近来，学习型策略开始进入运动场景 [46]。PUMA 读取历史光流，并以未来物体特征作为监督 [14]；DynamicWAM 以光流和运动学描述子为 WAM 提供条件，并以实时分块方式执行 [27]。两者都从图像空间线索中推断过去的运动，而 FoveaWAM 以目标的度量 SE(3) 位姿历史为输入，只观测当前一帧 RGB-D。另一些动态策略预测显著 token [38]、未来图像 [56]、紧凑的未来编码 [28] 或 3D 场景动力学 [53]，并在测试时以这些预测为条件生成动作。DynaWM 针对动态操作调整基础 VLA 的动作块 [10]，DynamicManip 从单条静态示范合成动态示范 [22]。执行调度方案通过让推理与执行重叠 [33, 46]、保持相邻动作块一致 [7, 25]，或以执行时刻为条件 [39]，来减小或掩盖延迟。它们决定的是动作何时计算、何时执行，而不是策略表示什么。DOMINO [14] 与 PhysMani-Bench [53] 提供了多样的动态操作任务，但它们公开的默认评测流程只在策略返回预测之后才推进仿真。ConMoto 则在推理期间推进场景，

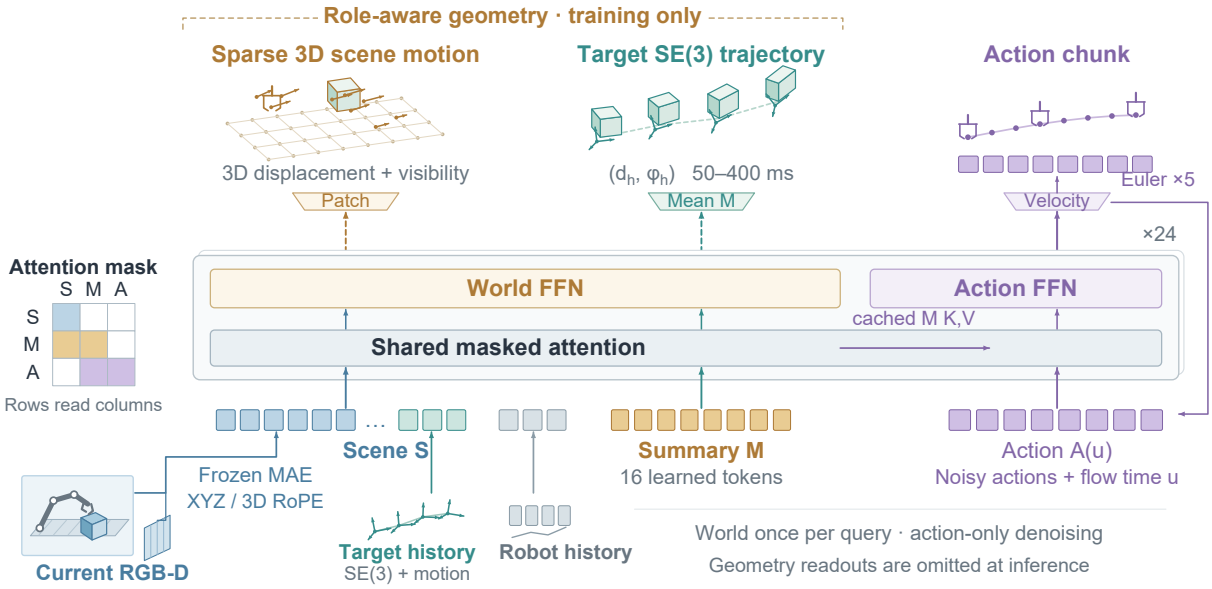


图 2. **FoveaWAM 架构。**自下而上阅读。当前 RGB-D 和目标、机器人状态历史输入世界流。世界流与动作流共享注意力，使用独立的 FFN。仅训练时使用的预测头（虚线）从 patch 状态预测全场景稀疏 3D 位移及可见性，从摘要均值预测目标 SE(3) 轨迹。动作通过结构化掩码读取场景与摘要 token。推理时，每次查询只计算一次场景与摘要 token 的键和值，在 5 个 Euler 步中复用，跳过预测头。几何图形为示意。

并让每个方法承担其实测延迟。

WAM 中的预测监督。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [21, 42, 48, 60]，其基础是把视频预测作为策略目标 [40, 45]。由于生成视频代价高，近期工作改变了预测的内容，例如动态区域、深度与语义特征 [55]，与 RGB 并列的光流和几何 [51]，物体掩码或物体槽 [26, 49]，以及紧凑隐变量 [37, 59]；它们也在追问测试时是否需要预测。Fast-WAM 在不做测试时想象的情况下保留了视频建模的大部分收益 [52]，PUMA 与 SG-WAM 则在训练后去掉预测器 [14, 57]。FoveaWAM 沿用这种只在训练中使用预测的方式，但主要预测的是度量 4D 状态，而不是像素、特征或隐变量，因此目标未来的位姿得到显式监督，而不是停留在隐式。

以物体为中心与基于几何的运动表示。 度量 3D 输入使策略更精确、样本效率更高 [32, 54]。运动已被表示为 2D 点轨迹 [4, 44, 47]、3D 流 [15, 18, 50, 53]，以及物体关键点或 SE(3) 轨迹 [17, 29, 36]；刚体分解也早已用于学习场景动力学 [8, 9]。这些工作用同一种表示描述场景：要么处处是稠密的流或轨迹，要么每个物体一个位姿。以目标为中心的预测器（包括预测物体层面未来的动态 VLA）只建模目标的未来 [14, 17]，把阻挡或推动目标的物体排除在外。DOCIR 把机器人、目标与障碍物分开，但只把这种区分用作输入编码 [13]。FoveaWAM 按角色分配精度：粗粒度的稀疏 3D 流描述整个场景，接触依赖毫米级精度的目标另由其 SE(3) 历史与预测描述。

3 FoveaWAM

我们把动态操作表述为：从一个表示生成按时刻索引的动作块（第 3.1 节），并在这些指令的执行时刻，用场景的稀疏 3D 流与目标的 SE(3) 轨迹监督该表示（图 2）。下文依次介绍度量输入（第 3.2 节）、这一监督（第 3.3 节），以及动作流如何读取该表示以生成动作块（第 3.4 节）。

3.1 问题形式化

我们研究场景在策略计算期间持续运动的操作。在第 t 次查询时，从示范中学得的策略 π 读取在时刻 τ_t 采集的 RGB 图像 I_t 与深度图 D_t，以及目标位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 的历史 $\mathcal{T}_t$ 与机器人状态的历史 $\mathcal{R}_t$，所有几何量都在机器人基座坐标系中表示，并输出一个包含 H 条指令的动作块：

$$(\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1}) \sim \pi\big(\cdot \mid I_t, D_t, \mathcal{T}_t, \mathcal{R}_t\big), \tag{1}$$

其中第 j 条指令对应时刻 $\tau_t + j\Delta_a$，Δ_a 为控制周期。

每个任务指定一个目标，机器人须在接触或容纳容差内对齐其位姿。起作用的周围物体构成环境：机器人须避开的障碍物，以及推动目标运动的驱动物。动作块要在推理完成后才可用，因此每条被执行的指令必须考虑目标与环境在其执行时刻、而不是 τ_t 时刻的状态。

3.2 度量场景与运动输入

FoveaWAM 精确编码目标的运动，并通过当前几何编码环境：当前 RGB-D 帧给出场景的度量布局，目标位姿的短历史给出单帧无法显示的运动，其中也反映了驱动物对目标的推动。

当前场景。 FoveaWAM 把每个 patch token 锚定在一个度量 3D 点上，使观测与预测、动作处于同一个基座坐标系中。冻结的 MAE ViT-B/16 [16] 把 RGB 图像编码为14×14 网格上的 196 个 patch token，深度图把 patch i 的中心反投影为基座坐标系中的点 $\mathbf{x}_i \in \mathbb{R}^3$。$\mathbf{x}_i$ 的线性嵌入加到 patch token 上，$\mathbf{x}_i$ 还驱动 patch 查询与键的 3D 旋转位置编码，使 patch 之间的注意力取决于它们的相对 3D 位置。这些点 $\mathbf{x}_i$ 也是场景流的源点（第 3.3 节）。

目标运动。 FoveaWAM 不使用过去的图像帧（从中恢复运动需要比较多帧图像），而是以度量 SE(3) 状态的形式接收目标近期的运动。目标历史以 20 Hz 的 8 次采样覆盖最近 350 ms；它的 8 个 token 包含当前目标位姿与相邻采样之间的七段运动，每段包含平移、相对旋转、时间间隔，以及以物理单位表示的有限差分速度与加速度。决定目标将到达何处的速度与加速度因此直接进入模型，代价只是几个低维 token；第 4.3 节去掉这段历史以衡量其作用。在仿真中，这些位姿来自仿真器；在真机上，由因果跟踪器从 RGB-D 流中估计。

世界流。 patch token、目标 token，以及编码目标历史各采样时刻末端执行器状态的 8 个机器人 token，共同组成 212 个场景 token。它们与汇聚它们的 16 个可学习摘要 token 一起构成世界流。

3.3 按角色区分精度的 4D 预测监督

FoveaWAM 用两种精度不同的几何预测监督其表示：以 patch 网格上的稀疏 3D 流表示整个场景的运动；由于目标的位姿决定接触，还预测目标完整的 SE(3) 轨迹。两者都在基座坐标系中、以相对当前状态的变化表示于时刻 $\tau_t + \delta_h$，其中 $\delta_h = h{\cdot}50\,\mathrm{ms}$，$h = 1, \ldots, 8$，即采集后 50 ms 到 400 ms；连同当前状态，这些时域覆盖动作块中所有指令的执行时刻。

场景流。 在 patch 网格的分辨率上，场景流覆盖 patch 所见的每个表面：机器人、目标，以及指令必须考虑其间隙与运动的环境。对 196 个点 $\mathbf{x}_i$ 中的每一个和每个时域 h，patch token i 最终状态上的线性

头预测该点在基座坐标系中的位移 $\hat{F}_{ih} \in \mathbb{R}^3$ 与可见性 logit $\hat{o}_{ih}$，以如下损失训练：

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h)\in\mathcal{V}_F} \Big[\tfrac{1}{3} \big\| (\hat{F}_{ih} - F_{ih})/s \big\|^2 + \mathrm{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \tag{2}$$

其中 F_{ih} 为 $\mathbf{x}_i$ 处表面点的位移，o_{ih} 为其可见性，s 为在训练标签上拟合的固定尺度，$\mathcal{V}_F$ 为有效标签集合。

目标轨迹。 场景流只在目标覆盖的少数几个 patch 上采样目标，过于稀疏，无法确定其旋转，因此由摘要 token 最终状态均值上的一个专用线性头直接预测目标的刚体运动：对每个时域 h，预测目标的位移 $\hat{\mathbf{d}}_h$ 与旋转增量 $\hat{\phi}_h$，以如下损失训练：

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h\in\mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\mathrm{SO(3)}}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{3}$$

其中 $\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t)$ 与 $R_h = R(\tau_t{+}\delta_h)$ 为真实的位移与朝向，$\hat{R}_h = \mathrm{Exp}(\hat{\phi}_h^{\wedge}) R(\tau_t)$，$d_{\mathrm{SO(3)}}$ 为测地距离，$\mathcal{V}$ 为具有有效标签的时域集合。旋转项对接触很重要：旋转误差 θ 可使与目标原点相距 r 的接触点偏移至多 $2r\sin(\theta/2)$。例如，在 $r = 10\,\mathrm{cm}$ 处，5° 的误差可使接触点偏移近 9 mm。

3.4 世界—动作联合学习与推理

动作流。 动作流以条件流匹配 [23] 生成动作块。它包含 $H = 8$ 个 token，每个嵌入一条加噪指令：末端执行器的平移增量、旋转增量与夹爪指令。每一层中，一个注意力以共享的投影覆盖两条流，其后接各自独立的前馈网络；世界 token 使用层归一化，动作 token 使用以流时间为条件的自适应层归一化。记场景、摘要与动作 token 为 S、M 与 A，注意力掩码允许 $S \to S$、$M \to \{S, M\}$ 与 $A \to \{S, M, A\}$，其中 $X \to \mathcal{Y}$ 表示 X 中的 token 读取 $\mathcal{Y}$ 中的 token。世界流从不读取动作。动作流在每一层都同时读取受场景流监督塑造的 patch 状态与受目标轨迹监督塑造的摘要状态。

训练目标。 对以训练统计量归一化的动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与流时间 $u \sim \mathcal{U}[0, 1]$，动作流 v_ψ 回归流匹配速度：

$$\mathcal{L}_A = \mathbb{E}\,\mathrm{MSE}\big(v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t),\, \mathbf{a}_1 - \mathbf{a}_0\big), \tag{4}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为式 (1) 中的输入，MSE 在有效指令与动作维度上取平均。世界流与动作流以

$$\mathcal{L} = \mathcal{L}_A + \lambda_F \mathcal{L}_F + \lambda_P \mathcal{L}_P + \lambda_{\mathrm{aux}} \mathcal{L}_{\mathrm{aux}} \tag{5}$$

联合训练，其中 $\mathcal{L}_F$ 与 $\mathcal{L}_P$ 为式 (2) 与式 (3) 的流与位姿损失，$\mathcal{L}_{\mathrm{aux}}$ 为辅助外观损失之和。

推理。 部署时，FoveaWAM 跳过预测头，与近期的世界—动作模型相同 [21, 52, 55]。由于世界 token 既不读取动作，也不读取流时间，世界流每次查询只运行一次，动作流在场景与摘要 token 缓存的键和值上积分 5 个 Euler 步。指令按相对采集时刻的时间索引，因此策略不需要延迟输入：执行器在推理完成时或之后的第一个控制周期边界接收动作块，并从对应该边界的指令开始执行。在真机上，一次查询的延迟还包括在最新一帧中跟踪目标的时间。更多实现细节见补充材料。

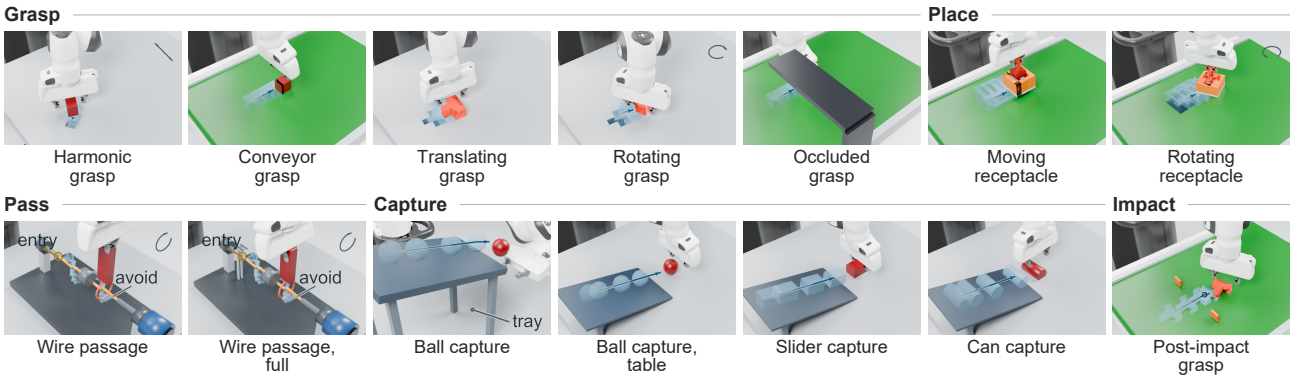


图 3. **ConMoto** 。采用统一主视角，从记录的仿真状态渲染五个任务族共 14 个任务。四个历史位姿以半透明蓝色显示，时间越早越淡；深蓝轨迹表示实测的过去运动。灰色角落箭头定性表示旋转或振荡，小圆圈标出记录到撞击时的目标中心。两个 Pass 子图均展示穿越阶段：导线在入口处是目标，沿途则是避碰障碍；Full 还要求获取、退出和释放。被遮挡的运动保持隐藏。这些原生专家示例用于展示任务动态，不代表 FoveaWAM 的执行结果，图中不显示未来预测。

4 实验

我们检验：当场景在推理期间持续运动时，按角色区分的精度与较低的延迟能否共同改善操作。我们在各方法自身的延迟下，将 FoveaWAM 与一系列策略比较：从基于当前观测行动的反应式策略和 VLA，到为运动目标设计的动态策略，再到预测整个场景的世界—动作模型（第 4.2 节）。随后我们分析其设计中哪些部分带来了这些结果（第 4.3 节），并在使用跟踪目标位姿的真机上加以验证（第 4.4 节）。

4.1 实验设置

ConMoto 。 DOMINO [14] 与 PhysMani-Bench [53] 的评测器在策略返回预测之后才推进仿真；与之不同，ConMoto 让观测、场景运动与动作执行共用一个物理时钟，因此策略计算时场景继续运动，每个方法都要为自身的延迟付出代价。它在 MuJoCo/robosuite [41, 61] 中包含五个任务族共 14 个任务：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（图 3）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个）上报告全部 ConMoto 结果。

评测。 每次查询期间，物理按该方法自身的推理延迟推进：延迟从该方法在一块 RTX 5090（我们机器人所用的 GPU）上以 batch 1 实测的延迟分布中抽取。所有方法共用同一个执行器，它从对应动作块到达时控制周期边界的那条指令开始执行该动作块。除这一原生设置外，我们还为每个方法附加 150 ms 延迟，并以推理期间暂停物理作为不计计算代价的参照。我们报告任务等权的成功率（SR）与 p95 出动作时间，即从观测到其第一条指令可用的实测时间；配对 95% 区间由对留出场景的自助法得到。

基线。 我们比较反应式策略、动态 VLA、图像或隐空间 WAM，以及一个动态 WAM（表 1）。每个基线使用官方架构和任务适配后的配方，在相同示范上训练，其延迟在该方法自身的原生部署设置下测量。FoveaWAM 只使用一个主视角及其深度和目标的 SE(3) 历史，不使用过去的帧。为了让基线获得相同的目标运动信息，$\pi_{0.5}$ 与 DynamicWAM 还以接收我们 SE(3) 历史 token 的形式运行（+SE(3)）。

表 1. **主要结果**。1,400 个 ConMoto 留出场景的任务等权 SR：原生延迟、+150 ms 和暂停物理。输入列描述 rollout；p95 与回放预算使用各方法在一块 RTX 5090 上的原生部署计时。OpenWAM 使用官方缓存与编译；off 关闭两者。粗体蓝底与浅蓝底标出已有数值的最佳、次佳，待测项不参与。

	历史			SR (%) ↑			
方法	腕部 RGB	光流	SE(3)	原生	+150 ms	暂停	p95 (ms) ↓
ACT [58]				41.6	24.3	40.6	**5.8**
DP [12]	✓			30.7	15.9	31.0	68.9
$\pi_{0.5}$ [5]				**53.8**	27.8	66.0	59.6
$\pi_{0.5}$+SE(3)			✓	52.8	**28.2**	**74.9**	61.2
DynamicVLA [46]	✓			50.9	23.4	54.6	97.3
PUMA [14]		✓		—	—	—	—
OpenWAM-α [42]				46.1	24.7	58.3	151.7
OpenWAM-α (off)				15.8	10.4	58.3	466.3
DynamicWAM [27]		✓		40.5	20.6	49.1	149.6
DynamicWAM+SE(3)		✓	✓	36.8	21.9	64.1	153.3
FoveaWAM			✓	—	—	—	—

实现。 Transformer 共 24 层，宽度 1024，16 个注意力头，可训练参数 523.8M；MAE ViT-B/16 编码器与 DINOv3 教师保持冻结。在 ConMoto 上，它从随机初始化开始，使用 AdamW 与 $\lambda_F = \lambda_P = \lambda_{\text{aux}} = \lambda_R = 0.1$ 训练至多 20 轮，我们保留验证损失最低的检查点。在真机上，它从一个在 DROID [19] 上预训练的 48 层基座出发，逐任务微调。完整的评测协议见补充材料。

4.2 动态操作结果

对比。 在原生延迟下，FoveaWAM 在 ConMoto 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。由于 +SE(3) 基线接收相同的目标运动输入，后一差距衡量的是 FoveaWAM 的表示在这一输入之外带来的增益。它的 p95 延迟为 [XX] ms，是图像空间 WAM 的 [X] 分之一，与 [最快的反应式策略，待定] 相近。优势最大的是 [任务类型]。

推理延迟的影响。 [计入计算时间会改变排序：] 推理期间暂停物理时，FoveaWAM 领先 [名称] [X.X] 个百分点，原生延迟下领先 [X.X] 个百分点，而图像空间 WAM 从 [XX.X]% 降至 [XX.X]%（表 1）。附加 150 ms 延迟拉长了每个方法需要预判的时长。FoveaWAM 保持 [XX.X]% 的 SR，而反应式策略平均降至 [XX.X]%，图像空间 WAM 降至 [XX.X]%：不预判目标运动的方法，其速度误差会在更长的延迟中累积。图 4 展示了附加延迟从 0 到 200 ms 时测得的成功率。

DOMINO。 为了在 ConMoto 之外检验这一设计，我们在 DOMINO [14] 的 24 个单臂 Franka 任务上，用其示范训练 FoveaWAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA，并用其原生评测器评测。FoveaWAM 的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%（表 2）。与在 ConMoto 上一样，它读取仿真器中的目标位姿。更多结果见补充材料。

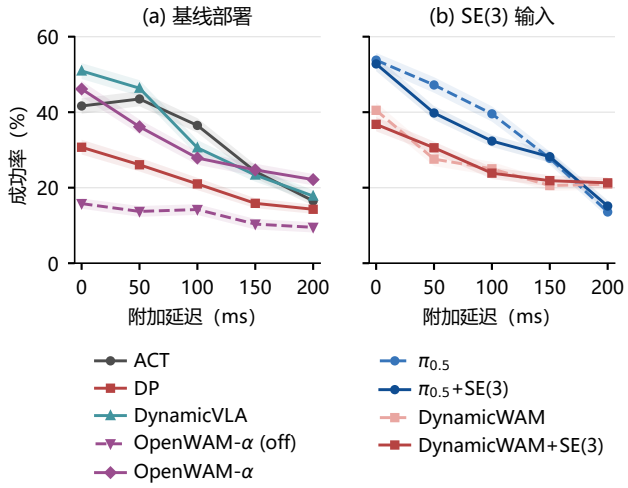


图 4. **附加延迟下的成功率。**(a) 基线部署配置；OpenWAM 使用官方缓存与编译，off 版本关闭两者。(b) 加入与不加入 SE(3) 输入的配对比较。每点使用 1,400 个 ConMoto 留出场景、单个训练种子。阴影表示按任务分层的场景 bootstrap 95% 区间，不表示训练种子间变异。PUMA 与最终 FoveaWAM 结果仍待补。

表 2. **DOMINO 结果**（24 个单臂 clean-L1 任务，各方法用 DOMINO 的示范训练；每个任务与方法 50 个回合）。SR（%）按交互类型分组并在任务上平均；MS 为操作得分。测量完成后，每列最佳以粗体加蓝底标出。

方法	拦截	跟踪	全部 ↑	MS ↑
$\pi_{0.5}$	—	—	—	—
DynamicWAM	—	—	—	—
PUMA	—	—	—	—
FoveaWAM	—	—	—	—

4.3 角色化建模分析

五个对照各改变 FoveaWAM 的一个部分，保持其数据与配方不变（图 5）。除无目标历史的对照外，每个对照只改变训练损失，而这些损失对应的预测头在部署时被跳过，因此其推理与 FoveaWAM 相同。我们在原生延迟与附加 150 ms 延迟下评估每个对照。

精度的分配。 完整模型与两个几何消融都保留全部辅助目标。去掉专用 SE(3) 监督后，目标只剩下场景各部分共有的统一粗粒度场景流监督，SR 在原生延迟下下降 [X.X] 个百分点，附加 150 ms 时下降 [X.X] 个百分点。去掉场景流监督后，目标保留其 SE(3) 轨迹，而场景其余部分（包括环境）失去运动监督，SR 分别下降 [X.X] 与 [X.X] 个百分点。如果精度按角色分配，SE(3) 监督应在预先声明的旋转敏感任务上作用最大，而流监督应在环境活跃任务上作用最大，这些任务的环境约束机器人或推动目标。[图 5 是否呈现这一模式，以及它对精度分配意味着什么。]

目标运动历史。 移除过去的目标位姿及其速度、加速度特征，同时保留当前图像、当前目标位姿与机器人历史，SR 在原生延迟下下降 [X.X] 个百分点，附加 150 ms 时下降 [X.X] 个百分点。[下降幅度随附加延迟增大，] 这与历史提供目标速度的作用一致：延迟越长，速度误差累积得越远。由于历史依赖位姿估计，我们还对位姿施加扰动；在合成的时序相关位姿噪声下，FoveaWAM 的 SR 为 [XX.X]%。

未来监督与辅助目标。 移除全部未来监督，即 SE(3)、场景流与未来外观目标，同时保留当前目标的重建，推理不变，但 SR 在原生延迟下下降 [X.X] 个百分点，附加 150 ms 时下降 [X.X] 个百分点，在

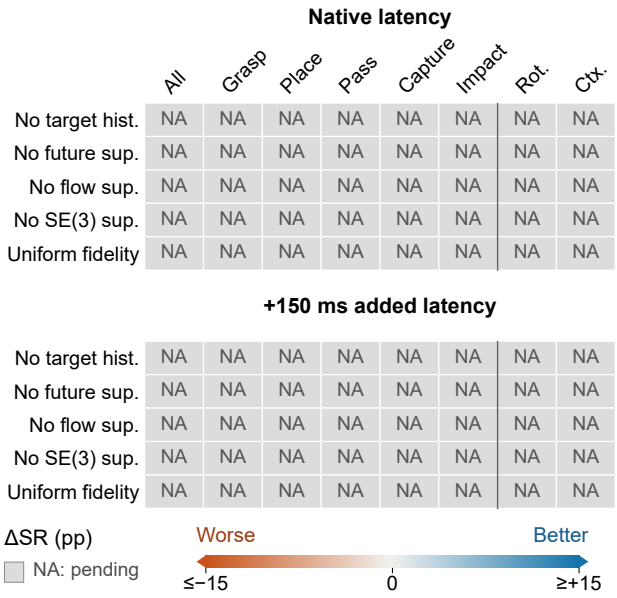


图 5. **按任务的消融效应（设计预览；数据待齐）。** ΔSR = SR(对照) − SR(完整模型)，单位为百分点；色阶在 ±15 处饱和。各行为第 4.3 节的五个对照，按正文顺序排列；统一粗粒度流去掉专用 SE(3) 监督，使目标只接受场景各部分共有的场景流监督。完整模型在原生延迟下的 SR 为 [XX.X]%，附加 150 ms 时为 [XX.X]%。Rot./Ctx. 分别表示预先声明、可重叠的旋转敏感组和环境活跃组（表 S3）。各列内任务等权聚合，保留 `t3_phase`。将以粗体标出未作多重比较校正、且不含零的配对 95% 场景自助法区间；区间以给定训练权重为条件。灰色 NA 表示尚无合格配对结果或估计。

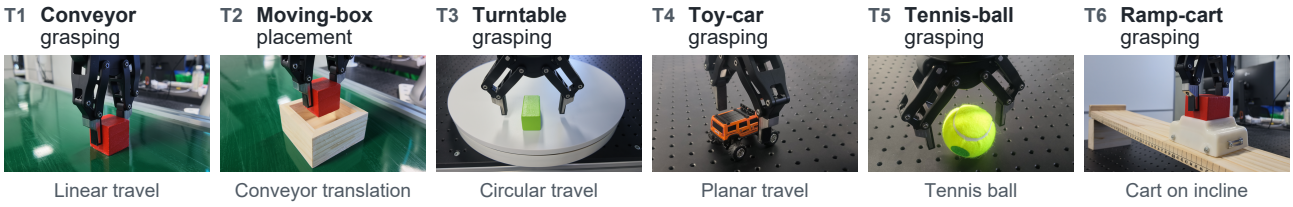


图 6. **真机任务场景。**六项任务的实拍照片：传送带抓取（T1）、向移动盒放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5）和斜坡小车载块抓取（T6）。

[目标做非匀速运动的任务] 上最明显。若改为移除辅助目标 $\mathcal{L}_{\text{aux}}$（包括当前目标重建）并保留两种几何预测，SR 变化 [X.X] 个百分点，[这对辅助目标的作用意味着什么]。离线评估中，学习得到的 SE(3) 预测也比对同一历史做匀速与匀加速外推更准确。[用一句话概括哪些组件起作用、在哪里起作用。]

4.4 真机评估

设置。 我们在 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机上评估六个任务（图 6）：传送带抓取（T1）、向移动容器放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5），以及斜坡小车载块抓取（T6）。基线为 $\pi_{0.5}$（VLA）、DynamicWAM（动态 WAM）与 Diffusion Policy [12]（反应式）。所有方法逐任务在相同的 100 条遥操作示范上训练或微调，并以共享试验键各运行 20 次试验。基线接收 RGB[，若配方使用腕部相机则一并提供]；FoveaWAM 还接收 FoundationPose [43] 的目标位姿估计，在每个控制周期边界、查询之前更新。表 3 报告包含跟踪的端到端延迟。

结果。 FoveaWAM 在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%，配对差为 [X.X] 个百分点（95% 区间 [[X.X, X.X]]；表 3）。包含跟踪在内，其 p95 延迟为 [XX] ms，[在一个控制周期之

表 3. **真机结果**。第 4.4 节六个任务上的成功率（%），每个任务每个方法 20 次试验；All 合并全部试验。p95 延迟：在一块 RTX 5090 上实测的端到端出动作时间（ms），FoveaWAM 包含跟踪。DP：Diffusion Policy。测量完成后，每列最佳以粗体加蓝底标出，并列者同样标出。

方法	T1	T2	T3	T4	T5	T6	All ↑	p95 (ms) ↓
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
DP	—	—	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	—	—

内]，而 [名称] 需要 [XX] ms。优势最大的是 [任务]。[一个可由轨迹核实的接触实例：目标位姿、旋转或环境如何解释 FoveaWAM 的成功或基线的失败。]FoveaWAM 的主要失败模式是 [失败模式]。更多细节见补充材料。

5 结论

FoveaWAM 把精度花在接触所依赖之处：用度量 SE(3) 历史与预测表示目标，用稀疏 3D 流表示整个场景，并且预测只作为训练监督。它在 ConMoto 上的成功率为 [XX.X]%，在 DOMINO 上为 [XX.X]%，在六个真机任务上为 [XX]%，p95 延迟为 [XX] ms，优于反应式、动态与世界—动作策略。[消融表明，目标历史在附加延迟下作用最大，未来监督在不改变推理计算的情况下改善控制。][说明专用 SE(3)、场景流与统一精度对照支持什么：更好的预测设计，或者在任务分组也一致时，按角色分配精度。] 计入推理延迟后，[说明成功率与相对表现与暂停评测相比有何不同]。

局限性。 FoveaWAM 需要一个指定的刚体目标及其可靠的位姿估计，其预测也不建模机器人自身的接触如何改变目标的运动。目标轨迹预测头在每个时域只预测一个未来，不表示不确定性或多模态运动；不确定性感知的预测可以弥补这一点。

LLM Usage Statement（大语言模型使用声明）

我们使用 OpenAI Codex 辅助文献调研、代码实现与调试、实验执行及论文语言润色。Codex 还用于辅助编写绘图代码，以及调整图表与论文排版。作者审阅了 AI 辅助生成或修改的内容，对照原始来源核查了参考文献，并通过测试与实验验证了实现。作者对最终稿件、实验结果和结论承担全部责任。

参考文献

[1] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[2] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. Wiley, 2001.

[3] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[4] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[5] Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *Proceedings of The 9th Conference on Robot Learning*, pages 17–40, 2025.

[6] Kevin Black, Noah Brown, Danny Driess, et al. π_0: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[7] Kevin Black, Manuel Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, pages 33383–33407, 2025.

[8] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, pages 173–180, 2017.

[9] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[10] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[11] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Joon-Young Lee, and Alexander Schwing. Putting the object back into video object segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[12] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[13] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 15873–15879, 2025.

[14] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. In *European Conference on Computer Vision*, pages 314–333, 2026.

[15] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *IEEE Robotics and Automation Letters*, 11(3):2466–2473, 2026.

[16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[17] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[18] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20765–20779, 2026.

[19] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[20] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, pages 2679–2713, 2025.

[21] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[22] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[23] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[24] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[25] Yuejiang Liu, Jubayer Hamid, Annie Xie, Yoonho Lee, Max Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, pages 4594–4627, 2025.

[26] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[27] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[28] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[29] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *Robotics Research: The 19th International Symposium ISRR*, pages 132–157. Springer, 2022.

[30] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[31] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, pages 28085–28128, 2025.

[32] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pages 785–799, 2023.

[33] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[34] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[35] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[36] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. In *European Conference on Computer Vision*, pages 437–453, 2026.

[37] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. In *Proceedings of the 43rd International Conference on Machine Learning*, pages 115917–115933, 2026.

[38] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. In *Conference on Robot Learning*, 2026. Accepted for publication.

[39] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[40] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, pages 92033–92052, 2025.

[41] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[42] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[43] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[44] Chuan Wen, Xingyu Lin, John Ian Reyes So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[45] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, pages 10641–10662, 2024.

[46] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[47] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, pages 2475–2499, 2025.

[48] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[49] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[50] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2025.

[51] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[52] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[53] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. In *European Conference on Computer Vision*, pages 20–39, 2026.

[54] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[55] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[56] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[57] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[58] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[59] Ruijie Zheng, Jing Wang, Scott Reed, et al. FLARE: Robot learning with implicit world modeling. In *Proceedings of The 9th Conference on Robot Learning*, pages 3952–3971. PMLR, 2025.

[60] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[61] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

[62] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183, 2023.

A 方法与训练细节

A.1 架构

表 S1 按下文所述的数据流顺序列出各模块的配置。

场景 token。 冻结的 MAE ViT-B/16 [16] 输出的每个 patch token 加上一个可学习的视角嵌入，以及其平均有效度量深度和其中心像素反投影后基座坐标系位置 $\mathbf{x}_i$ 的线性嵌入；中心像素没有有效深度的 patch 不加位置嵌入。只有 patch 的 query 与 key 使用由 $\mathbf{x}_i$ 驱动的 3D 旋转位置编码，同样的点也是稀疏 3D 流的源点。过去的图像从不进入模型。

状态 token。 8 个目标状态 token 在偏移 $-350, -300, \ldots, 0$ ms 处取样。每个都是 25 维描述子 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta t, \mathbf{v}, \boldsymbol{\omega}, \mathbf{a}, \boldsymbol{\alpha})$：槽位 0–6 描述相邻偏移之间的七个区间，速度与加速度由经过时间上的有限差分得到；槽位 7 存放基座坐标系下的当前位姿。每一维用训练统计量标准化，无效维置零，并附加三个有效性标志（位姿、区间与加速度）；没有任何有效特征的槽位在注意力中被掩码。机器人 token 包含相同偏移处的末端位置、旋转向量与夹爪开度，16 个可学习嵌入构成摘要 token。策略没有语言输入。

主干与预测头。 第 3.4 节的掩码在训练与部署时、在每一层每个头中都把被屏蔽的注意力 logit 置为 $-\infty$，因此世界状态每次查询只计算一次，并在各 Euler 步间复用。所有预测头都读取最终的世界状态，部署时跳过，没有 token 读取它们的输出。位姿头读取摘要状态的均值（$\mathcal{L}_P$，式 3）。流头给出每个 patch 点在各时域的位移与可见性 logit（$\mathcal{L}_F$，式 2，尺度 $s = 0.7154605$ m，可见性权重为 1）；有效但不可见的点仍监督其位移。$\mathcal{L}_{\text{aux}}$ 由四项组成：未来度量深度（有效像素）、位移超过 1 mm 的表面的 RGB，以及经层归一化的 DINOv3 特征 [34] 上的平方误差，以及由摘要状态均值重建当前目标 RGB 区域的绝对误差。

动作流。 每个动作 token 嵌入一条七维指令：基座坐标系下的平移增量、左乘相对旋转向量与夹爪指令，均相对于施加时测得的末端位姿。部署时，解码后的指令按每个平移轴 0.10 m、每个旋转轴 0.5 rad 截断；夹爪指令只有超出死区（小球捕获任务为 0.5，其余任务为 0.1）时才切换状态。

A.2 在 ConMoto 上训练

示范的每个控制步锚定一个包含 8 个查询位置的窗口，每个位置有自己的因果历史，位置之间互不注意，由 11,200 条示范共得到 1,324,374 个窗口；另有 350 个回合构成验证集。流标签由 patch 中心处渲染到的表面点随其 MuJoCo 几何体的真值刚体运动得到；若未来点投影在图像内、落在同一几何体上，且深度差在 $\max(1\text{ mm}, 0.001z)$ 以内，则视为可见。查询 t 动作块的第 j 条指令标注为示范在 $\tau_t + j\Delta_a$ 下发的指令，因为 d_{task} 只在执行时起作用（式 (S1)）；指令在训练集上标准化。每个查询位置对 8 组噪声—时间对的动作损失取平均，每项损失按全局 batch 中有效标签的数量归一化。表 S2 列出训练配方。

A.3 DROID 预训练与微调

真机基座在 DROID [19]（15 Hz）上训练，使用第一台外部相机及其深度，以及 PointWorld [18] 发布的 3D 点轨迹与标定，并按机器人状态、指令与相机身份与原始回合匹配。可用的 42,087 个回合给

表 S1. FoveaWAM 的架构。各预测头在部署时被跳过。

模块	配置
视觉编码器	冻结的 MAE ViT-B/16，输入 224×224，196 个 patch token
目标状态编码	$28 \to 1024 \to 1024$ GELU MLP，加性相对时间嵌入
机器人状态编码	线性，$7 \to 1024$
Token	212 个场景（196 个 patch、8 个目标状态、8 个机器人）、16 个摘要、8 个动作
主干	24 层，宽度 1024，16 个注意力头，共享注意力，每个流的 SiLU 前馈 4096，504.0M 参数
位姿头	线性，摘要状态均值 $\to 8 \times 6$
流预测头	每个 patch token 上的线性读出，$8 \times (3{+}1)$
外观预测头	每个 patch token 上的线性读出：深度与运动表面 RGB 以 16×16 像素输出，1024 维 DINOv3 ViT-L/16 特征
目标重建	$1024 \to 256 \to 3072$ GELU MLP 加 sigmoid，32×32 RGB
动作流	流匹配，以流时间做自适应层归一化，5 个 Euler 步

表 S2. ConMoto 上的训练超参数。

项目	取值
优化器	AdamW，$\beta = (0.9, 0.999)$，$\epsilon = 10^{-8}$，权重衰减 10^{-4}
学习率	2×10^{-4}，从 0 开始 5,174 次预热更新，余弦衰减到 0
Batch 与训练长度	全局 batch 512 个窗口，至多 20 轮，取验证损失最低的检查点
损失权重	$\lambda_F = \lambda_P = \lambda_R = 0.1$，每个辅助目标 $\lambda_{\text{aux}} = 0.1$
动作噪声	每个查询位置 8 对噪声—时间样本
精度	可训练权重 FP32，冻结编码器 BF16，梯度截断 0.1
推理	FP32，查询内缓存世界状态
硬件	[N] 块 RTX PRO 6000 GPU，每次训练 [X] 小时

出 598,889 个锚定窗口（训练 538,740 个，验证 60,149 个）；每个锚点扩展为 8 个查询位置，只有锚点带有流与 DINOv3 标签。所有带下发指令的动作槽位都被保留，不按速度过滤。每个 patch 跟随一条从其内部出发的 PointWorld 轨迹，优先选择运动最大且一致的一条，以覆盖小的运动物体；47.05% 的点—时域槽位带有标签。

DROID 没有物体位姿，因此基座没有目标状态 token 与位姿头；它读取当前 RGB-D 帧与机器人历史，以权重 1 训练动作损失与稀疏 3D 流，以权重 0.1 训练未来 DINOv3 特征，不使用可见性损失。由于 DROID 中的物体大多只在机器人推动时才运动，基座主要学到度量几何与机器人自身引起的运动；外部驱动的目标运动在微调中才进入。基座共 48 层，宽度 1024（可训练参数 1.02B），以全局 batch 512 在 64 块 GPU 上训练 20 轮（21,060 次更新），优化器与精度同表 S2。每个真机策略从基座出发，在其任务的示范上微调 [更新次数、学习率与 batch 大小]，目标状态 token 与基座缺少的预测头重新初始化；真机策略不使用任何仿真数据或权重。

B ConMoto 与评测协议

B.1 基准设计

ConMoto 包含五个任务族共 14 个任务（图 3），覆盖平移、旋转、暂时遮挡、受约束的通行，以及目标运动的突变。我们将公开这些任务、场景、成功判定与示范。

表 S3. **ConMoto 的十四项任务。**目标：策略接收其位姿的物体（第 3.1 节）。速度：目标速度范围（捕获任务取离开斜坡时的速度）。每个任务都须依次通过各阶段且不触发终止性失败；抓取要求双侧指垫接触、抬升至少 0.05 m 并保持 0.5 s。时限：回合时限。图 5 的任务组：R 为旋转敏感组，C 为环境活跃组（附录 B.1）。发布的任务配置包含确切阈值与场景范围。

任务（代号）	目标	速度（m/s）	成功条件	时限（s）	任务组
谐波抓取 (grasp)	物块	0.03–0.20	抓住做谐波运动并偏航的物块，抬起并保持。	8	R
传送带抓取 (t1_belt)	零件	0.04–0.10	抓住传送带上的零件，抬起并保持。	8	C
平移抓取 (t1_xyz)	零件	0.04–0.15	抓住平移的零件，抬起并保持。	8	–
旋转抓取 (t1_so3)	零件	0.04–0.15	抓住平移并旋转的零件（$\|\omega\| \leq 1.2$ rad/s），抬起并保持。	8	R
遮挡抓取 (t1_occ)	零件	0.04–0.10	抓住传送带上的零件（遮挡罩会将其遮住 0.5–3.0 s），且不与遮挡罩发生不安全接触；抬起并保持。	8	C
移动容器 (t2_trans)	容器	0.03–0.06	把所持物体完整放入移动的容器并释放，使其静止。	10	–
旋转容器 (t2_se3)	T 形容器	0.03–0.06	把所持 T 形件完整放入平移并旋转的 T 形容器并释放，使其静止。	10	R
导线穿越 (t3_phase)	导线入口	[X]	把所持杆端的环在 30 mm 内对准旋转的导线，然后沿导线无接触地穿到终点。	21	R, C
完整导线穿越 (t3_full)	导线入口	[X]	抓起杆，完成穿越，离开导线后释放杆。	32	R, C
小球捕获 (t4_sphere)	小球	[0.4–0.7]	在小球离开斜坡后、触及托盘前将其接住，抬起并保持。	6	C
桌面小球捕获 (t4_sphere_tabletop)	小球	[0.4–0.7]	在小球离开斜坡后仍在桌面滚动时将其抓住，抬起并保持。	6	C
滑块捕获 (t4_slider)	滑块	[0.4–0.8]	在滑块离开斜坡后仍在桌面滑动时将其抓住，抬起并保持。	6	C
罐体捕获 (t4_can)	罐体	[0.4–0.7]	在罐体离开斜坡后仍在桌面滚动、尚未倾倒时将其抓住，抬起并保持。	6	R, C
撞击后抓取 (t5_replan)	零件	0.12–0.14	撞击器把传送带上的零件撞偏后，沿其抓取轴将其抓住，抬起并保持。	6	R, C

环境。 任务在 MuJoCo 3.11.0 与 robosuite 1.5.2 [41, 61] 中运行，使用 Franka Panda 机械臂与平行夹爪，由 robosuite 的操作空间位姿控制器驱动，控制周期 50 ms，物理步长 2 ms。一台固定的第三人称相机位于 $(0.68, -0.58, 1.62)$ m，垂直视场角 40°，渲染 224×224 的 RGB-D 图像。动作是基座坐标系下末端的平移与旋转向量增量，加一条夹爪指令，按每个平移轴 0.10 m、每个旋转分量 0.5 rad 截断。

成功与终止。 表 S3 给出各任务的成功条件，在每个物理步判定；连续条件一旦中断，其计数器清零。回合在成功、失败（例如不安全接触、离开工作空间或掉落）或达到时限时结束。

角色与任务组。 表 S3 给出每个任务的目标。移动的容器是目标，因为它的位姿决定能否放入；在穿越任务中，杆须在 30 mm 内与之对准的导线入口是目标，导线其余部分是不允许接触的环境。图 5 的两个任务组在消融之前确定：若目标在领先时长内旋转且其朝向在接触时起作用，则任务属于旋转敏感组，这排除了小球；若任务有障碍间隙 m 或驱动物（传送带、斜坡或撞击器），则属于环境活跃组。

B.2 场景、示范与数据划分

每个场景在各任务的范围内均匀采样目标的初始状态与运动参数：除表 S3 的速度外，还包括至多 35 mm、0.25–0.7 Hz 的谐波振幅、至多 1.2 rad/s 的偏航角速度、2.5–7.5°/s 的导线转速，以及 5–15° 的斜坡坡度。遮挡场景中，目标在开始时至少可见八帧，随后被遮挡 0.5–3.0 s，再至少可见三帧。只保留物理上可行的场景，评测时回放存储的场景。

专家是针对各任务的闭环状态机，使用仿真特权状态：目标的位姿与速度、机器人状态、任务几何，以及真实的接触与阶段事件。它在抓取任务中外推目标，再跟踪、下探、闭爪与抬升；在捕获任务中预测截获点；在穿越任务中补偿导线的相位；其指令按每个轴截断到 0.05 m 与 0.5 rad。只有专家

成功、回放其动作能重现该回合、且路径与 jerk 通过质量检查的示范才被保留。训练池包含 11,200 条示范（每个任务 800 条），以 20 Hz 记录 RGB-D、机器人状态、指令与仿真真值；策略只接收第 3 节的输入。

我们在 1,400 个开发场景（每个任务 100 个）上选择配置，并在 1,400 个留出场景上报告全部 ConMoto 结果；留出场景以相同的范围生成，所用种子不出现在任何训练、验证或开发回合中。每个任务的留出集是按种子顺序的前 100 个可行场景，所有方法共用。

B.3 实时评测

执行器。 所有方法在 50 ms 控制时钟上共用一个执行器。第 t 次查询的第 j 条指令对应时刻 $\tau_t + j\Delta_a$，其执行时刻（第 3.1 节）为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\text{task}}, \tag{S1}$$

其中撞击后抓取在下发每条指令 50 ms 后才施加，$d_{\text{task}} = 50$ ms；其余任务 $d_{\text{task}} = 0$。与 RTC [7] 相同，延迟按整数个控制周期计：总延迟为 L_t 的查询在其结束时或之后的第一个周期边界交出动作块，即采集后 $k_t = \lceil L_t/\Delta_a \rceil$ 个周期，执行从对应该边界的第 k_t 条指令继续。策略随即重新观测并开始下一次查询，其间上一个动作块继续执行，因此策略以其延迟允许的频率重新规划。当 $L_t = 0$ 时，下一次查询在采集后一个周期开始。动作块包含该方法原生的 H_m 条指令（表 S4），$k_t \geq H_m$ 时整体丢弃。在第一个动作块到达之前及动作块耗尽时，控制器保持当前的手臂目标与夹爪指令，不重复执行任何指令。FoveaWAM 的每条指令都在采集后 $(H-1)\Delta_a + d_{\text{task}}$ 以内执行，处于其预测时域之内。

协议。 在实时协议下，每次查询期间物理按该方法的延迟推进，延迟每次查询从其在一块 RTX 5090 上实测的分布中抽取。在暂停协议下，推理不占用物理时间，策略每 50 ms 重新规划；这一对照去掉了推理等待，同时也提高了反馈频率，不是性能上界。等延迟协议为每个方法计入 FoveaWAM 的 p95 延迟；原执行方式协议让每个基线保留其论文中的执行方式，例如 ACT 的时间聚合或 DynamicVLA 的流式执行。延迟扫描在实时协议下于推理之后附加 0 至 200 ms，步长 50 ms。rollout 在 RTX PRO 6000 上运行，回放 RTX 5090 上的实测延迟。

延迟测量。 我们在一块 RTX 5090（32 GB，即我们机器人所用的 GPU）上独占运行，以 batch 1 和各方法发布版本的精度（FoveaWAM 为 FP32）为每个方法计时：三轮，每轮 30 次预热与 300 次测量调用，使用录制观测及所需的因果历史。一次计时查询从最新观测开始，到第一条指令可用时结束，包含所有需要最新帧的计算，例如预处理、图像编码、PUMA 与 DynamicWAM 的在线光流与运动描述子、采样与动作解码，在真机上还包括跟踪。FoveaWAM 的预测头在部署时跳过，另行计时。出动作时间超过 50 ms 的查询称为超时；一条指令的动作年龄是其执行时刻减去采集时刻。附录 C.2 报告实测值。

B.4 指标与统计

方法 m 按任务等权的成功率为

$$\mathrm{SR}(m) = \frac{100}{14} \sum_{k=1}^{14} \frac{1}{n_k} \sum_{i=1}^{n_k} y_{mki}, \tag{S2}$$

其中 y_{mki} 是任务 k 的场景 i 上的二值结果。首次接触时的位置误差 e_p 是末端到专家在目标上的接触坐标系的距离；放置任务开始时物体已被抓住，因此使用所持物体与容器的接触及专家的放置位姿。e_p 在有接触的 13 个任务（不含 `t3_phase`）及发生接触的回合上平均；没有接触的失败仍计入 SR 的分母。

表 S4. **基线训练。**所有方法均在相同的 11,200 条示范上按各自的官方配方训练，并在附录 B.3 的共享执行器下运行。更新数 × batch：训练量。H：每个返回动作块中的指令数。参数量：可训练参数，不含冻结的编码器。DOM 检查点：DynamicVLA 发布的、在 DOM 上训练的检查点。OpenWAM-α 联合生成视频与动作，但不解码视频。

方法	初始化	更新数 ×batch	H	参数量
ACT [58]	从头训练	50,000 × 32	100	[X]
DP [12]	从头训练	50,000 × 32	15	[X]
$\pi_{0.5}$ [5]	`pi05_base`	30,000 × 256	10	[X]
$\pi_{0.5}$+SE(3)	`pi05_base`	30,000 × 256	10	[X]
DynamicVLA [46]	DOM 检查点	50,000 × 44	20	[X]
PUMA [14]	官方	[X]×[X]	[X]	[X]
OpenWAM-α [42]	官方	34,490 × 192	32	[X]
DynamicWAM [27]	官方	40,000 × 128	16	[X]
DynamicWAM+SE(3)	官方	40,000 × 128	16	[X]
FoveaWAM	从头训练	51,740 × 512	8	523.8M

配对区间。 每个方法训练一次。配对 95% 区间在每个任务内、跨方法联合地对留出场景做自助法，刻画给定训练权重下的场景不确定性；区间落在 ±2 个百分点以内的差异视为持平。对消融，我们还在去掉纯相位导线穿越（`t3_phase`，附录 C.4）后重复比较。

B.5 基线与消融对照

共同条件。 每个基线保留其官方架构、动作块长度、初始化与训练配方（表 S4），在相同的 11,200 条示范上训练一次（指令通过同一个笛卡尔控制器映射到其动作空间），配置在开发场景上选择。rollout 使用各基线训练时的主视角（腕部槽位被屏蔽）及表 1 所列历史；延迟在各方法自身的原生部署设置下测量。对有无腕部视角两种方式都计时的七个配置，两者的 p95 延迟至多相差 3.8 ms，不到控制周期的十分之一；PUMA、使用官方加速的 OpenWAM 与 DynamicWAM+SE(3) 只在其部署设置下计时。DP 使用作者真机配方的 16 步 DDIM 采样器；OpenWAM 分别在开启与关闭官方缓存和编译时计时。

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.1 的八个目标状态 token，带有相同的有效标志。一个输出层零初始化的两层 MLP 把它们映射到模型宽度；对 $\pi_{0.5}$，它们接在前缀中的图像 token 之后，由动作专家读取；对 DynamicWAM，它们并入其运动学描述。训练沿用基础模型的配方。

消融对照。 第 4.3 节的五个对照各改变表 S2 配置中的一个组件，数据、含检查点选择在内的配方以及执行器保持不变。*无专用 SE(3)* 去掉 $\mathcal{L}_P$ 与位姿头，使目标只接受整个场景共有的统一粗粒度场景流监督；*无场景流监督*去掉 $\mathcal{L}_F$ 与流读出；两者都保留目标状态 token 与全部辅助目标。*无目标历史*去掉目标状态槽位 0–6，即过去的位姿及其速度与加速度特征，保留存放当前位姿的槽位 7（附录 A.1）。*无未来监督*去掉 $\mathcal{L}_P$、$\mathcal{L}_F$ 与三个未来外观损失及其预测头，保留当前目标重建。*无辅助目标*去掉 $\mathcal{L}_{\text{aux}}$，即三个未来外观损失与当前目标重建，保留 $\mathcal{L}_P$ 与 $\mathcal{L}_F$。由于所有预测头在部署时都被跳过，只有无目标历史对照改变推理时的输入。

表 S5. **ConMoto 各任务的留出成功率**（%），涵盖表 1 中的全部方法，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。OWAM：使用官方缓存与编译的 OpenWAM-α；OW-off：关闭两者。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。σ：使用标称合成相关位姿噪声的 FoveaWAM （附录 C.5）。Δ：该任务上 FoveaWAM 相对最强其他方法之差及其 95% 配对区间。最后两行为首次接触时的位置误差 e_p（mm，在有接触的 13 个任务上平均）与发生接触的回合数 n（附录 B.4）；–：无 13 任务均值。任务代号见表 S3。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	OWAM	OW-off	DWAM	DWAM+	σ	本文	Δ [95% CI]
谐波抓取	49.0	31.0	51.0	**85.0**	39.0	—	41.0	1.0	50.0	51.0	—	—	—
传送带抓取	45.0	45.0	**96.0**	58.0	89.0	—	62.0	0.0	59.0	47.0	—	—	—
平移抓取	14.0	33.0	59.0	38.0	**61.0**	—	53.0	0.0	53.0	15.0	—	—	—
旋转抓取	24.0	20.0	32.0	**44.0**	26.0	—	42.0	3.0	30.0	37.0	—	—	—
遮挡抓取	30.0	28.0	37.0	51.0	**80.0**	—	34.0	0.0	44.0	36.0	—	—	—
移动容器	26.0	8.0	26.0	19.0	**39.0**	—	28.0	0.0	0.0	0.0	—	—	—
旋转容器	**0.0**	**0.0**	**0.0**	**0.0**	**0.0**	—	**0.0**	**0.0**	**0.0**	**0.0**	—	—	—
导线穿越	99.0	99.0	**100.0**	**100.0**	99.0	—	50.0	58.0	23.0	23.0	—	—	—
导线穿越（完整）	0.0	3.0	1.0	5.0	**12.0**	—	0.0	0.0	0.0	0.0	—	—	—
小球捕获	36.0	16.0	**46.0**	21.0	41.0	—	45.0	13.0	24.0	23.0	—	—	—
小球捕获（桌面）	71.0	81.0	**100.0**	**100.0**	88.0	—	99.0	88.0	98.0	**100.0**	—	—	—
滑块捕获	56.0	30.0	58.0	68.0	28.0	—	**71.0**	31.0	47.0	63.0	—	—	—
罐体捕获	91.0	31.0	98.0	99.0	72.0	—	**100.0**	5.0	96.0	**100.0**	—	—	—
撞击后抓取	42.0	5.0	49.0	**51.0**	39.0	—	21.0	22.0	43.0	20.0	—	—	—
任务等权	41.6	30.7	**53.8**	52.8	50.9	—	46.1	15.8	40.5	36.8	—	—	—
e_p (mm)	32.2	36.2	31.2	32.5	**30.0**	—	31.7	–	31.2	37.0	—	—	–
n	1110	941	1231	1187	1203	—	1115	439	1193	970	—	—	–

C 补充仿真结果

C.1 各任务结果

表 S5 把表 1 中 ConMoto 留出结果按任务分解到每个方法，并给出 FoveaWAM 相对每个任务上最强其他方法的配对区间；最后两行给出首次接触时的位置误差 e_p 与发生接触的回合数（附录 B.4）。使用真机 DDIM16 采样器时，Diffusion Policy 的实时 SR 为 30.7%，暂停物理时为 31.0%。关闭缓存与编译的 OpenWAM 在部分任务没有接触，因此其完整 13 任务 e_p 未定义。[所有方法都失败或基线优于 FoveaWAM 的任务，以及 FoveaWAM 的主要失败模式。]

C.2 评测协议与延迟

表 S6 在另外三种协议下评估每个方法。暂停物理显示不计计算代价时相对表现如何变化；等延迟在 FoveaWAM 的 p95 延迟下比较所有方法；原执行方式检验共享执行器是否去掉了某个基线所依赖的能力。在暂停协议下，FoveaWAM 与 [名称] 的差为 [±X.X] 个百分点，在等延迟协议下为 [±X.X] 个百分点。原执行方式使各基线的 SR 至多改变 [X.X] 个百分点。表 S7 给出九种配置在五个附加延迟点的结果；PUMA 与 FoveaWAM 仍待补。图 4 直接读取该表绘制部分对比；全部方法保留在表中。

计时。 表 S8 按阶段分解 FoveaWAM 在一块 RTX 5090 上的出动作时间，测量方式见附录 B.3；表 1 给出每个方法的 p95 延迟，表 S4 给出参数量。在真机上，我们报告动作年龄的 p50、p95 与最大值，测试试验全部查询中超过 50 ms 截止时间的比例，以及峰值显存。

表 S6. **评测协议对照**：ConMoto 留出场景（SR，%），协议定义见附录 B.3；实时即表 1 的协议。超时：实时协议下出动作时间超过 50 ms 控制周期的查询比例（%）。年龄：实时协议下动作年龄的 p95（ms）；–：没有执行任何指令。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

方法	暂停	等延迟	原执行执行器	实时	超时 (%)	年龄 p95
ACT	40.6	—	—	41.6	0.0	50
Diffusion Policy	31.0	—	—	30.7	100.0	150
$\pi_{0.5}$	66.0	—	—	**53.8**	100.0	150
$\pi_{0.5}$ + SE(3)	**74.9**	—	—	52.8	100.0	150
DynamicVLA	54.6	—	—	50.9	100.0	150
PUMA	—	—	—	—	—	—
OpenWAM-α	58.3	—	—	46.1	100.0	350
OpenWAM-α (off)	58.3	—	—	15.8	100.0	950
DynamicWAM	49.1	—	—	40.5	100.0	250
DynamicWAM + SE(3)	64.1	—	—	36.8	100.0	350
FoveaWAM	—	—	–	—	—	—

表 S7. **成功率随附加延迟的变化**：每点使用 1,400 个 ConMoto 留出场景（SR，%；实时协议，单个训练种子）。0 与 150 ms 两列分别等于表 1 的原生与 +150 ms 列。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

	附加延迟（ms）				
方法	0	50	100	150	200
ACT	41.6	43.5	36.5	24.3	16.5
Diffusion Policy	30.7	26.1	21.0	15.9	14.3
$\pi_{0.5}$	**53.8**	**47.2**	**39.6**	27.8	13.6
$\pi_{0.5}$ + SE(3)	52.8	39.8	32.4	**28.2**	15.1
DynamicVLA	50.9	46.4	30.6	23.4	17.8
PUMA	—	—	—	—	—
OpenWAM-α	46.1	36.1	27.9	24.7	**22.1**
OpenWAM-α (off)	15.8	13.7	14.2	10.4	9.5
DynamicWAM	40.5	27.6	25.0	20.6	20.9
DynamicWAM + SE(3)	36.8	30.6	23.9	21.9	21.3
FoveaWAM	—	—	—	—	—

表 S8. **单次查询的延迟分解**（FoveaWAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
图像编码	—	—
世界流（每次查询一次）	—	—
动作流（5 个 Euler 步）	—	—
出动作时间（合计）	—	—
预测头（仅训练，供参考）	—	—
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

表 S9. **离线预测误差**。在同一批留出观测上计算 400 ms 处的目标位置误差（mm）。CV 和 CA 是由因果位姿历史计算的解析外推；学习位姿头读取冻结完整模型的状态。

	匀速	谐波	滚动/滑动	撞击
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的位姿头	—	—	—	—

表 S10. **最终消融**（ConMoto 留出场景；附录 C.4）。原生延迟与附加 150 ms 延迟下的 SR（%）；Δ：对照减 FoveaWAM（百分点）及其 95% 配对区间。最后两列：去掉纯相位导线穿越（`t3_phase`）后 13 个任务上的 Δ。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。

	原生		+150 ms		Δ 去掉 `t3_phase`	
变体	SR	Δ [95%]	SR	Δ [95%]	原生	+150 ms
FoveaWAM ⋆	—	–	—	–	–	–
无专用 SE(3)（统一粗粒度场景流）	—	—	—	—	—	—
无场景流监督	—	—	—	—	—	—
无目标历史	—	—	—	—	—	—
无未来监督	—	—	—	—	—	—
无辅助目标	—	—	—	—	—	—

C.3 DOMINO 上的结果

在 DOMINO [14] 上，我们在其 clean 一级设置的 24 个单臂 Franka 任务上比较 FoveaWAM、$\pi_{0.5}$、DynamicWAM 与 PUMA。所有方法使用该基准的示范、场景与原生评测器，各训练一个种子，每个任务与方法评测 50 个回合。我们报告 SR 与操作得分（MS）；MS 用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度（表 2）。FoveaWAM 使用该领域的归一化，并读取指令所指目标在仿真器中的位姿；没有有效位姿的槽位按附录 A.1 的方式掩码。基于 RGB 的基线不接收这一位姿。[概括 DOMINO 结果。]

C.4 最终消融

表 S10 报告第 4.3 节的五个对照（附录 B.5）在原生延迟与附加 150 ms 延迟下的结果，以及各自相对完整模型的配对差值。最后两列在去掉纯相位导线穿越（`t3_phase`）后重复这些配对差值：在开发场景上，以不同种子重新训练同一配置，SR 最多相差 [7.4] 个百分点，主要来自该任务，其成功率从 [0] 到 [71]% 不等（附录 B.4）。图 5 的两个任务组列于附录 B.1。[第 4.3 节的结论在去掉 `t3_phase` 后是否改变。]

C.5 对位姿噪声的鲁棒性

在权重冻结的条件下，我们评估三种对目标位姿的合成扰动：标称的时序相关噪声、两倍幅度的噪声，以及带连续缺失观测的标称噪声。标称过程由每回合固定的偏置与平稳相关分量组成，二者每轴的标准差均为 5 mm 与 1°，相关时间为 200 ms。缺失持续 200 ms，其间隔服从均值为 3.8 s 的几何分布，长期缺失比例为 5%。扰动作用于当前与过去的估计，在计算历史特征之前施加。

图 S1 在这些扰动下评估最终模型，使用相同的留出场景与零附加延迟。相对干净位姿，在标称相关噪声、两倍幅度噪声与缺失观测下，SR 分别变化 [X.X]、[X.X] 与 [X.X] 个百分点。

图占位：图 S1——位姿噪声

横轴：干净位姿、标称相关噪声、两倍幅度噪声、带缺失观测的标称噪声；纵轴：FoveaWAM 在各任务族上的 SR，冻结权重，实时协议；匹配场景上的配对区间。

图 S1. **对位姿噪声的鲁棒性。**在目标位姿的合成扰动下 FoveaWAM 的 SR，相对干净位姿。

C.6 预测诊断

表 S9 离线比较最终模型学到的 SE(3) 预测与由同一位姿历史得到的匀速和匀加速外推。

D 真机实验

D.1 平台与任务

机器人为 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机，通过 [带时间戳的笛卡尔接口] 以 [控制频率] 控制；一台固定的第三人称相机以 [分辨率与帧率] 录制 RGB-D，每次采集前用 [标定方法] 标定。FoveaWAM 使用这一视角，配方使用腕部视角的基线另外获得 [腕部相机]，所有策略都在一块 RTX 5090 上运行。各任务装置轮流安装在这一平台上（图 S2；表 S11）。T3 转盘上的方块边长不等，必须沿短边抓取，因此接触时其朝向起作用；T4 的玩具小车以固定油门运行。

D.2 位姿跟踪与标签

跟踪不使用标记，每个物体实例有一个米制网格；球体由球心与半径定义。首帧中，Grounding DINO [24] 定位任务所指的物体，SAM 2.1 [31] 分割它，FoundationPose [43] 注册其位姿；之后 Cutie [11] 传播掩码，FoundationPose 在每次更新时精修卡尔曼滤波的预测。掩码为空时估计无效，不沿用上一位姿，[丢失后的重新初始化]。跟踪器在每个控制周期边界用最新一帧更新，并保留该帧的采集时刻，目标状态 token 的有限差分基于这些时刻；跟踪计入实测延迟（表 S8）。

示范的目标状态输入由同一跟踪器在其录制的 RGB-D 上因果回放得到。位姿标签是未来周期边界上的跟踪位姿 [（在整个回合上离线精修）]，流标签来自 [录制 RGB-D 的 3D 点轨迹，做法同 DROID（附录 A.3）]。对于球体，目标状态 token 与位姿头只使用平移。表 S12 报告测试试验中跟踪丢失的频率。

D.3 训练与评测协议

FoveaWAM 从 DROID 基座出发逐任务微调（附录 A.3）。$\pi_{0.5}$、DynamicWAM 与 Diffusion Policy [12] 在相同示范上训练或微调，初始化、配方与动作块长度见表 S4；DynamicWAM [是否使用实时分块执行]。示范、开发试验与测试试验来自不同的采集批次。

每个任务有 20 个预生成的试验键，固定物体实例、其初始位姿与装置设定。操作员参照参考图像重置场景后，四个方法对每个键以随机顺序连续运行，使装置的漂移不会与方法对齐。试验在成功、失

图占位：图 S2——真机平台

内容：一张从机器人后方拍摄、装有一个任务装置的共用平台照片，不做修饰；逐一标注第三人称 RGB-D 相机、机器人，以及基线使用的腕部相机（若有）。

图 S2. **真机平台，**装有一个任务装置。

表 S11. **真机任务。**目标：被跟踪的物体。试验键：20 个测试键各自固定的内容。速度：由全部测试试验录制的 RGB-D 测得的目标速度（m/s，均值 ± 标准差）。抓取指物体被两指夹持。每个任务有 100 条训练示范与 20 条验证示范。

任务	目标	运动；试验键	速度	成功条件	时限（s）
T1	方块	传送带；[在带上的放置、带速]	—	抓住方块并抬起 [X] cm。	[X]
T2	无盖盒	传送带；[盒子的放置、带速]；方块开始时在夹爪中	—	将方块释放进盒中；方块留在盒内 [直到盒子离开工作空间]。	[X]
T3	边长不等的方块	转盘；[半径、方块的初始角度与偏航、角速度]	—	沿短边抓住方块并抬起 [X] cm。	[X]
T4	玩具小车	以固定油门遥控行驶；[起始位姿、航向]	—	抓住小车并抬起 [X] cm。	[X]
T5	网球	[球的运动机制、释放位置与运动设定]	—	抓住网球并抬起 [X] cm。	[X]
T6	小车上的方块	小车沿倾斜轨道下行；[坡度、释放点]	—	抓住方块并抬起 [X] cm。	[X]

败、安全中止或时限（约为该任务示范时长中位数的三倍）时结束。只有装置自身偏离试验键时（[实测速度超出设定的 ±X%，或装置故障]）才重做该键；其余情况都计为失败，包括 FoveaWAM 的跟踪丢失。我们报告每个任务的成功次数，以及合并成功率及其 95% Wilson 区间；配对差值在每个任务内按试验键自助重采样。每次查询的端到端出动作时间都在同一块 RTX 5090 上记录，FoveaWAM 包含跟踪。

D.4 详细结果与失败

表 S13 报告每个任务的成功次数、区间与配对差值，以及各方法按类别统计的失败次数。这些类别在测试试验前确定，都是可观察的事件：跟踪丢失（仅 FoveaWAM ）、过晚（夹爪在目标后方合拢）、抓取未对准、接触后滑落或掉落、碰撞或安全中止，以及超时。[优势最大的任务及其失败类别；FoveaWAM 最常见的失败。]

表 S12. **真机上的跟踪**。按任务统计 FoveaWAM 的测试试验：控制周期边界数、估计无效的比例、最长缺失时长，以及重新初始化次数。

任务	边界数	无效（%）	最长缺失（s）	重新初始化
T1	—	—	—	—
T2	—	—	—	—
T3	—	—	—	—
T4	—	—	—	—
T5	—	—	—	—
T6	—	—	—	—

表 S13. **真机成功与失败**。上半部分：每个任务的成功次数（共 20 次试验；任务见表 S11）；All：合并成功率（%）及 95% Wilson 区间；Δ：相对 FoveaWAM 的配对差值（百分点）及按试验键自助法得到的区间。下半部分：每个方法全部 120 次试验中各类失败的次数（附录 D.4）；–：不适用。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。

方法	T1	T2	T3	T4	T5	T6	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	—	–

	跟踪丢失	过晚	未对准	滑落/掉落	碰撞/中止	超时	失败合计
$\pi_{0.5}$	–	—	—	—	—	—	—
DynamicWAM	–	—	—	—	—	—	—
Diffusion Policy	–	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	—