SE(3)-WAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景；然而推断场景运动多花的每一毫秒，都会让目标走得更远。世界—动作模型以统一的精细程度预测未来图像或隐变量，把时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器速度快，却忽略了约束其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；场景其余部分只通过它留下的间隙起作用。我们提出 SE(3)-WAM，一个建立在这种按角色区分精度的 4D 结构之上的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，并被训练去精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测场景的其余部分。这些预测只作为训练监督：它们从不回流到动作，部署时被跳过，因此推理既不需要过去的帧，也不需要生成未来，速度足以支撑实时控制。在推理期间场景持续运动的仿真基准 Dynamic-14 上，SE(3)-WAM 的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在目标运动形式多样的六个真机任务上，它的成功率为 [XX]%。

图占位：图 1 预览——运动场景的按角色区分精度的 4D 视图（真机）

版式：通栏，两部分。**(a) 左侧，约 62%：**直线运动抓取的一帧真机画面，取动作块发出的瞬间。按论文语义配色叠加：蓝色为因果跟踪器给出的目标过去 SE(3) 位姿（$-350\ldots0$ ms 的小三轴，随时间变淡）；橙色为动作块各执行时刻的目标 SE(3) 预测，取自离线运行的训练期预测头；浅橙色箭头为仅画在环境上的 14×14 网格稀疏 3D 流；紫色为在 τ^{a} 与目标相遇的指令夹爪路径。灰色虚影标出采集时观测到的位姿，红色虚线箭头示意反应式策略会在何处闭合。图像下方的细时间轴：采集 $\tau_t \to$ 延迟 $\ell_t \to$ 执行 τ^{a}。**(b) 右侧，约 38%：**上：“图像空间 WAM：以统一精细程度预测未来帧或隐变量”（胶片图标）；中：“SE(3)-WAM：目标用 SE(3)，环境用稀疏 3D 流，仅训练时使用”（三轴 + 稀疏箭头）；下（**必需**）：SE(3)-WAM 与最强基线的成功率随附加延迟（0–200 ms）的变化（数据：附录 E.2 的延迟扫描）。**规则：**真实照片不做修饰；叠加由该次试验记录的跟踪、预测与指令数据绘制；图注说明该次试验的结果。

图 1. **运动场景的按角色区分精度的 4D 视图。**从图像采集到第一条指令之间，传送带上的零件移动的距离超过了抓取所能容忍的误差。SE(3)-WAM 编码目标的度量运动（蓝色），并被训练去精确预测目标的 SE(3) 位姿、以稀疏 3D 流预测周围场景（橙色）；部署时跳过这一预测，因此它的指令在执行时与目标相遇（紫色）。图像空间的世界—动作模型则以统一精细程度预测外观。右：Dynamic-14 上成功率随附加延迟的变化。

1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[9, 16, 37, 56, 75, 84, 106]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。这带来两个相互耦合的困难。单张图像无法揭示目标如何运动；而等到动作执行时，目标已不在它被看到的位置：传送带上以 0.1 m/s 运动的零件在 150 ms 的延迟中移动 15 mm，超过了平行夹爪抓取通常能容忍的误差（图 1）。

近期工作为策略加入对过去运动的记忆和对未来的预测 [19, 49, 67, 94]。两者都消耗动态操作最缺乏的资源——时间：更丰富的历史和更稠密的预测增加计算，增加的延迟又放大了预测本应消除的误差。因此，现有设计在信息与速度之间权衡。基于视频的 WAM 以统一的精细程度预测完整的未来帧

或隐变量 [49, 75, 84]，只预测动态区域或显著 token 的方法仍在图像空间中预测 [67, 94]。两者都把大部分容量花在外观上，而决定接触的量——动作执行时目标的度量位姿——仍然是隐式的。以目标为中心的预测器位于另一端 [19, 28, 50]：它们速度快，却看不到可能阻挡或改变目标运动的周围环境。它们都没有提供这样一种对运动场景的认识：在接触所依赖之处精确，在其他地方粗略，并且在执行时使用的代价很低。

我们的关键观察是：动态策略需要精确知道的东西其实很少。接触取决于动作执行时刻目标的位姿，精度要到毫米；场景的其余部分只通过它留下的间隙起作用。这些认识也不必在测试时计算：在训练中作为监督的预测，会塑造策略所学到的表示，部署时即可去掉 [89]。SE(3)-WAM 建立在这两点之上（图 2）。它看到当前图像，以及目标与机器人的度量 SE(3) 短历史；这些历史直接表达运动，而不必编码一叠过去的帧。世界流被训练在同一个度量 4D 空间中精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流预测场景的其余部分；动作流读取世界流的摘要，并按其延迟允许的频率重新规划。预测从不到达动作，部署时预测头被跳过，因此 SE(3)-WAM 以接近反应式策略的延迟，获得了度量预测带来的精度。

我们在 Dynamic-14 上评估 SE(3)-WAM 。这是一个包含 14 个任务的仿真基准，观测、场景运动与动作执行共用同一个物理时钟，策略计算期间场景持续运动。SE(3)-WAM 以 [XX.X]% 的成功率达到最优，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms；在六个真机任务上，它的成功率为 [XX]%，最强基线为 [XX]%。四个最终规模对照分别检验目标运动历史、未来监督及其两项几何成分的贡献。

我们的贡献有三点：

- 我们提出面向动态操作的按角色区分精度的 4D 建模。分析延迟与估计误差如何传递到接触点可知，只有目标需要毫米级精度；因此我们用度量的 SE(3) 位姿历史和未来轨迹精确表示目标，用稀疏 3D 流粗略表示场景的其余部分。
- 我们提出 SE(3)-WAM ，一个以这些按角色区分精度的 4D 预测作为训练监督的世界—动作模型；部署时跳过预测，使其延迟接近反应式策略。
- 我们构建了 Dynamic-14 ，其中推理期间场景持续运动；SE(3)-WAM 在该基准和六个真机任务上取得最优结果。

2 相关工作

动态操作。 补偿感知与执行之间的时间差是一个经典问题，从带纯滞后的控制 [64]，到用卡尔曼类滤波器跟踪目标并规划拦截的抓取系统 [2, 5, 6, 52]；这些系统精确，但针对每种物体和任务专门设计。近来，学习型策略开始进入运动场景。PUMA 读取历史光流，并以未来物体特征作为监督 [19]；DynamicWAM 以光流和运动学描述子为 WAM 提供条件，并以实时分块方式执行 [49]；另一些方法预测显著 token、未来图像或紧凑的未来编码，并在测试时把预测提供给策略 [50, 67, 90, 95]。执行调度方案则从执行一侧减小或掩盖延迟：让推理与执行重叠 [60, 62, 81]，保持相邻动作块一致 [10, 46]，或以执行时刻为条件 [68, 72]。它们决定动作何时计算、何时执行，而 SE(3)-WAM 改变的是策略所表示的内容；我们让所有方法在同一个实时执行器下运行。

世界—动作模型中的预测监督。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [40, 75, 84, 103]，其基础是把视频预测作为策略目标 [29, 70, 79]。由于视频代价高且以外观为主，近期工作改变了预测的内容，例如动态区域、深度与语义特征 [94]，与 RGB 并列的光流和几何 [88]，物体掩码或物体槽 [48, 85]，以及紧凑隐变量 [38, 39]；它们也在追问测试时是否需要预测：Fast-WAM 发现跳

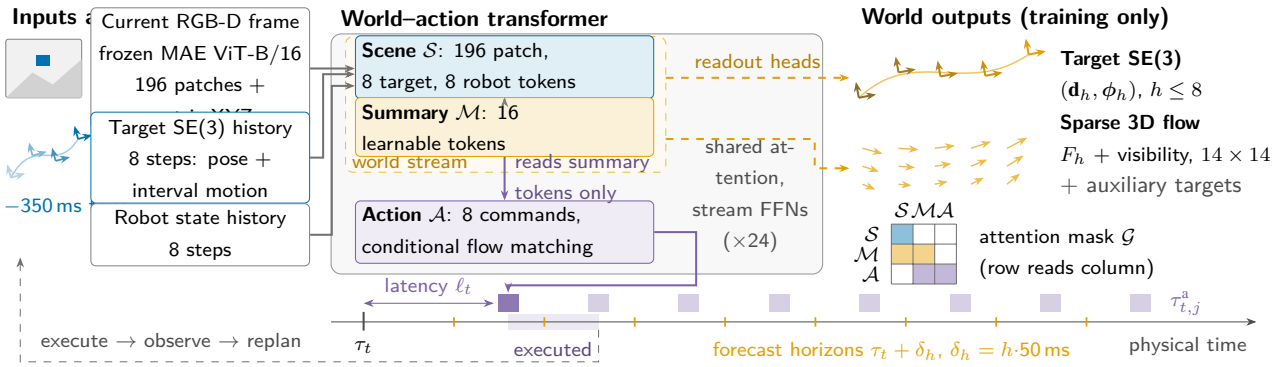


图 2. **SE(3)-WAM** 。世界流包含 212 个场景 token（冻结编码器给出的当前图像 patch，以及目标度量 SE(3) 位姿与机器人状态的短历史）和 16 个摘要 token。训练时，轻量读出头把世界流读出为物理时域 $\tau_t + \delta_h$ 上按角色区分精度的 4D 预测：目标的 SE(3) 轨迹与14×14 网格上带可见性的稀疏 3D 流（虚线：仅训练）。动作流以流匹配生成 8 条指令组成的动作块。注意力掩码 $\mathcal{G}$ 只允许场景 token 读取场景、摘要 token 读取场景与摘要、动作 token 读取摘要与动作，因此预测永远不会进入动作。策略在每次查询结束时或之后的首个控制边界重新观测并重新规划。

过测试时的想象仍保留了视频建模的大部分收益 [89]，PUMA 等方法在训练后去掉预测器 [19, 66, 97]。SE(3)-WAM 沿用这种只在训练时使用预测的方式，改变的是监督的目标：不是统一分辨率的像素、特征或隐变量，而是一个精度随各部分在接触中所起作用而定的度量 4D 状态。

运动的几何表示。 度量 3D 输入使策略更精确、样本效率更高 [22, 35, 61, 91]。运动已被表示为 2D 点轨迹 [7, 77, 82, 100]、3D 流 [23, 30, 87, 101]，以及物体关键点或 SE(3) 轨迹 [28, 51, 65, 78]；刚体分解也早已用于学习场景动力学 [12, 13]。这些工作用同一种表示描述场景：要么处处是稠密的流或轨迹，要么每个物体一个位姿；DOCIR 把机器人、目标与障碍物分开，但只是作为输入编码 [18]。SE(3)-WAM 按角色分配表示：接触依赖毫米级精度的目标由其 SE(3) 历史与预测描述，只通过间隙起作用的场景其余部分由稀疏 3D 流描述。附录 H 讨论更多相关工作。

3 SE(3)-WAM

SE(3)-WAM （图 2）是一个包含世界流与动作流、两者共享注意力的 Transformer。世界流编码当前观测和近期运动，并被训练去预测按角色区分精度的 4D 场景。动作流以条件流匹配 [43] 生成动作块，只通过少量摘要 token 读取世界。我们先说明驱动这一设计的问题设定。

3.1 作用于运动目标

执行时刻。 在第 t 次查询时，策略接收在时刻 τ_t 采集的图像、深度图与机器人状态，以及更早状态的历史，并输出动作块 $A_t = (\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1})$，其第 j 条指令在

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + \ell_t + j\Delta_a \tag{1}$$

执行，其中 ℓ_t 为从采集到首次执行的延迟（预处理、推理与执行机构），Δ_a 为控制周期。指令必须适合 $\tau^{\mathrm{a}}_{t,j}$ 而非 τ_t 时刻的场景（图 3），而领先时长 $\Delta_{t,j} = \tau^{\mathrm{a}}_{t,j} - \tau_t$ 随推理的每一毫秒增长。

目标与环境。 令 $W_t(\mathbf{x}, \tau) \in \mathbb{R}^3$ 为位于 $\mathbf{x}$ 的场景点在 τ_t 与 τ 之间的位移，以机器人基座坐标系表示。目标 $\mathcal{O}$ 是其位姿误差进入接触或容纳容差 ε 的刚体，例如要抓取的物体或要放入的容器。环境 $\mathcal{C}$ 包含只需

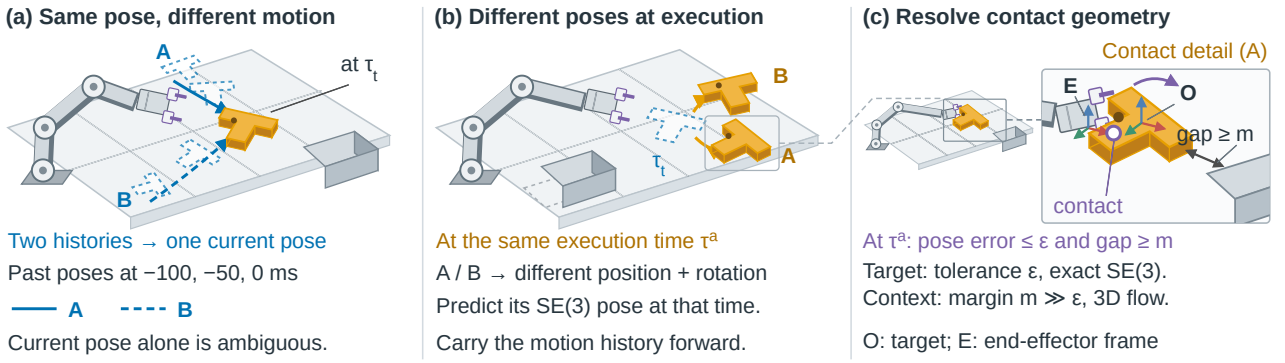


图 3. **作用于运动目标**（示意图）。(a) 两段历史在采集时刻 τ_t 到达相同位姿，但对应不同运动。(b) 在执行时刻 τ^{a}，它们对应不同的目标位姿。(c) 接触要求末端执行器坐标系 E 与目标 O 在 ε 内对齐，而环境只通过它留下的间隙起作用，$m \gg \varepsilon$。

避开的物体，例如传送带或遮挡物，其间隙为 m。在目标上，运动场由其位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 决定：

$$W_t(\mathbf{x}, \tau) = T(\tau)\, T(\tau_t)^{-1}\mathbf{x} - \mathbf{x}, \qquad \mathbf{x} \in \mathcal{O}. \tag{2}$$

误差从何而来。 设策略显式或隐式地依据目标在 τ^{a} 时位姿的估计 $\hat{T}$ 行动。对于力臂为 r 的接触点和旋转误差 θ，接触误差至多为 $\|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\| + 2r\sin(\theta/2)$。把领先时长 Δ 内的运动写成匀速 $\mathbf{v}$ 加残差 $\boldsymbol{\rho}$（加速、滚动、撞击），得到

$$\|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\| \le e_{\mathrm{loc}} + \hat{\Delta}\, e_v + \|\mathbf{v}\|\, e_\tau + e_{\mathrm{dyn}}, \tag{3}$$

四项依次为当前位置误差、速度误差乘以领先时长、时刻误差乘以速度，以及残差运动误差（附录 G）。对环境而言，发生碰撞要求沿指令路径某处的预测误差至少为 m。由此得到两点结论。第一，重要的精度集中在目标上：需要毫米级地估计其位姿与运动，旋转误差还会经力臂 r 放大；环境则可以粗略得多地预测。第二，延迟两次进入误差预算：一次通过放大每个速度误差的领先时长 Δ，一次通过残差累积的运动；因此，消耗推理时间的信息，只有当它消除的误差多于额外延迟带来的误差时才划算。这两点决定了 SE(3)-WAM 的三个部分：它记住什么（第 3.2 节），它学会预测什么（第 3.3 节），以及它的动作如何在部署时不为预测付出代价地使用预测（第 3.4 节）。

3.2 输入：当前帧与运动历史

SE(3)-WAM 只看一张图像。冻结的 MAE ViT-B/16 [26] 把当前 RGB 帧编码为 196 个 patch token，深度图为每个 patch 给出其中心点在基座坐标系中的度量 3D 位置。运动来自最近 8 个控制步（20 Hz 下为 350 ms）上的两段短历史。目标历史由基座坐标系下的当前目标位姿和相邻采样之间的七段区间运动组成：平移、相对旋转、时间间隔，以及有限差分得到的速度与加速度，均为物理单位（附录 A.1）。它们构成 8 个目标状态 token。机器人历史构成 8 个末端执行器状态 token。它们与 patch token 一起构成 212 个场景 token。在真机上，无标记因果跟踪器从 RGB-D 流中估计目标状态；每个估计连同其采集时刻只输出一次，之后的帧不会修改它。真机球类协议保留平移，屏蔽目标角运动特征（附录 A.2）。在仿真中，我们从仿真器读取目标位姿，使策略与跟踪误差分离。我们单独评估合成位姿噪声；真实跟踪器标定与跟踪闭环尚待完成（附录 F.2）。模型不接收过去的图像，因此视觉编码代价不随历史增长。

3.3 按角色区分精度的 4D 预测

世界流被训练在时域 $\tau_t + \delta_h$ 上预测 W_t，其中 $\delta_h = h{\cdot}50\,\text{ms}$、$h = 1, \ldots, 8$，覆盖整个动作块的执行时刻（400 ms）。我们通过式 (2) 参数化目标。对每个时域，

$$\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t), \quad \boldsymbol{\phi}_h = \operatorname{Log}\big(R(\tau_t{+}\delta_h)R(\tau_t)^\top\big)^\vee, \tag{4}$$

位姿头以平移平方误差加 λ_R 倍的测地旋转平方误差回归 $(\mathbf{d}_h, \boldsymbol{\phi}_h)$（$\mathcal{L}_P$）。场景其余部分用稀疏 3D 流表示：对14 × 14 网格上 196 个 patch 的中心点（在工作空间中相距约 [X] mm），流头在每个时域回归其在基座坐标系中的位移 $F_h \in \mathbb{R}^3$ 与可见性（$\mathcal{L}_F$）。网格刻意取得较粗，因为环境的误差只要小于间隙即可容忍，而目标的精度来自其位姿而非其上的点。我们还使用仅用于训练的辅助外观目标（$\mathcal{L}_{\text{aux}}$），部署时跳过其读出头（附录 A.3）。所有头都是世界流最终隐藏状态上的轻量读出，运动标签从当前状态累计，损失只使用有效标签。

3.4 动作与共享主干

世界流包含 212 个场景 token 和 16 个可学习的摘要 token。动作流包含 8 个 token，每条指令一个，嵌入带噪指令与流时间。一个动作块覆盖 8 个 $\Delta_a = 50\,\text{ms}$ 的控制周期，每条指令是末端执行器的平移与旋转加夹爪指令。注意力掩码 $\mathcal{G}$ 只允许场景 token 读取场景、摘要 token 读取场景与摘要、动作 token 读取摘要与动作。因此，动作只通过摘要 token 读取世界；训练中预测损失塑造摘要 token 的内容，而预测本身从不进入动作流。两条流在每一层共享注意力投影，并各有独立的前馈网络，因此它们在注意力中交换信息，同时保留各自的容量。对归一化的动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与 $u \sim \mathcal{U}[0, 1]$，动作损失为

$$\mathcal{L}_A = \mathbb{E}\ \text{MSE}_{\text{valid}}\big(v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t, \mathcal{G}), \mathbf{a}_1 - \mathbf{a}_0\big), \tag{5}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为第 t 次查询的场景 token。总损失为 $\mathcal{L} = \mathcal{L}_A + \lambda_F\mathcal{L}_F + \lambda_P\mathcal{L}_P + \lambda_{\text{aux}}\mathcal{L}_{\text{aux}}$。4 层筛选研究（附录 F.4）比较了其他耦合方案，记号如下：R0 关闭预测损失；R2 加入世界查询，动作在每一层读取其隐藏状态；R3 让这些查询读取动作，R4 同时开启两个方向；R5 把解码出的预测编码为几何 token 供动作读取（附录 A.5）。

部署。 测试时跳过预测头。由于世界 token 从不读取动作，世界流每次查询只运行一次，动作流在缓存的 key 与 value 上积分 5 个 Euler 步。新动作块从下一个控制周期边界开始执行，策略在同一边界重新观测并开始下一次查询，因此只要一次查询能在一个控制周期内完成，每个周期执行的都是新生成的指令（附录 A.7）。在 RTX 5090 上，p95 出动作时间为 [XX] ms。

实现。 Transformer 有 24 层，宽度 1024，16 个注意力头，前馈宽度 4096，主干参数 504.0M，可训练参数共 523.8M。MAE ViT-B/16 编码器（85.8M）和 DINOv3 教师（303M）保持冻结。Dynamic-14 配方使用每个任务 800 条示范的全部窗口、20 轮（全局 batch 512 下 51,740 次更新），使用 AdamW 与余弦调度，$\lambda_F = \lambda_P = 1$、$\lambda_R = \lambda_{\text{aux}} = 0.1$。最终训练硬件与每个种子的时长仍为 [N] 块 RTX PRO 6000 GPU 和 [X] 小时（附录 A.6）。

3.5 面向真机的预训练

真实机器人数据不提供物体位姿，因此真机基座学习 DROID [36] 所能支持的那部分预测。它采用相同架构，有 48 层（1.02B 可训练参数），输入与仿真模型相同，只是没有目标历史。其目标为动作、稀

疏 3D 流和未来 DINOv3 特征。流标签来自 PointWorld 为 DROID 发布的 3D 点轨迹与优化后的相机标定 [30]，重采样为每个图像 patch 一条轨迹，并保留 DROID 的原生时间。配置在 37,874 个训练 episode 的 538,740 个窗口上、用 64 块 GPU 训练 21,060 次更新；预训练仍在进行（附录 B）。真机配方从该基座初始化，加入目标状态 token 与位姿头，并用带跟踪位姿的任务示范微调。仿真模型从通用初始化（冻结的 MAE 编码器加随机初始化的 Transformer）训练。

4 实验

我们在仿真和真机上比较 SE(3)-WAM 与反应式、动态及世界—动作策略（第 4.2 节与第 4.3 节），然后对目标历史与未来监督做消融（第 4.4 节）。

4.1 设置

Dynamic-14 。 我们在 MuJoCo/robosuite [71, 104] 中构建了五个任务族共 14 个任务：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（附录 C，图 S3）。我们在原任务运动范围内扫描附加延迟（0–200 ms）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个，新种子）上报告 Dynamic-14 主要比较与最终模型消融。最终模型的消融取三个训练种子的平均；筛选研究的种子与划分分别见附录 F。每个基线训练一次。我们给出对留出场景自助法得到的配对 95% 区间。

协议。 观测、场景运动与执行共用一个控制周期为 50 ms 的物理时钟。所有方法在同一执行器下运行，方法计算期间物理世界按其在一块 RTX 5090 上测得的延迟继续推进。一条指令执行完毕且上一次推理结束后，策略再次被查询；新动作块到达之前，执行器继续执行上一个动作块。+150 ms 设置为每个方法额外加入 150 ms 延迟，暂停设置在推理期间停止物理仿真（附录 C.3）。我们报告按任务等权的成功率（SR）、接触时刻误差 e_t、首次接触时的位置误差 e_p 以及 p95 出动作时间。

基线。 我们比较反应式策略（ACT [98]、Diffusion Policy [16] 与 $\pi_{0.5}$ [56]）、动态 VLA（DynamicVLA [81] 与 PUMA [19]）、图像或隐空间 WAM（DreamVLA [94] 与 OpenWAM-α [75]），以及一个动态 WAM（DynamicWAM [49]）。每个基线使用其官方代码、输入与训练配方，在相同示范上训练；若其配方使用腕部相机，则提供渲染的腕部图像（附录 D）。SE(3)-WAM 只使用主视角，但还使用深度和目标位姿。为了控制目标运动信息的可用性，$\pi_{0.5}$ 与 DynamicWAM 还额外接收我们的 SE(3) 历史 token（+SE(3)）；它们的深度输入仍与本文方法不同。匀速输入对照是去掉预测损失、改为接收目标位姿匀速外推作为输入 token 的 SE(3)-WAM 。

4.2 主要结果

SE(3)-WAM 在 Dynamic-14 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [最强基线名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。优势最大的是 [旋转目标以及快速的传送带和平移目标]，即领先时长内目标移动最远的任务。它的 p95 出动作时间为 [XX] ms，是图像空间 WAM 的 [X] 分之一；后者的延迟会叠加到它们需要弥补的领先时长上。加入 150 ms 延迟后，SE(3)-WAM 保持 [XX.X]%，而反应式策略降至 [XX.X]%，图像空间 WAM 降至 [XX.X]%。推理期间暂停物理仿真时，它与 [暂停设置下最强基线名称] 的差为 [±X.X] 个百分点，从而把速度的贡献与

表 1. **主要结果。**Dynamic-14 留出集成功率（%；1,400 个新场景，按任务等权，实时协议，本文各变体取三个训练种子的平均，基线训练一次），按任务族分列；另列加入 150 ms 延迟后的成功率、推理期间物理暂停时的成功率（暂停）、接触时刻误差 e_t（ms）、首次接触时的位置误差 e_p（mm），以及在一块 RTX 5090 上的 p95 出动作时间。输入：R 为 RGB 与机器人状态；D 为深度；P 为目标 SE(3) 历史。粗体为最佳；置信区间见附录 E。

		Dynamic-14 成功率，除注明外为实时协议										
方法	输入	全部	抓取	放置	穿越	捕获	撞击	+150 ms	暂停	e_t	e_p	p95 (ms)
ACT [98]	R	—	—	—	—	—	—	—	—	—	—	—
Diffusion Policy [16]	R	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ [56]	R	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	R+P	—	—	—	—	—	—	—	—	—	—	—
DynamicVLA [81]	R	—	—	—	—	—	—	—	—	—	—	—
PUMA [19]	R	—	—	—	—	—	—	—	—	—	—	—
DreamVLA [94]	R	—	—	—	—	—	—	—	—	—	—	—
OpenWAM-α [75]	R	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM [49]	R	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM + SE(3)	R+P	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	RD+P	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM	RD+P	—	—	—	—	—	—	—	—	—	—	—

图占位：图 4——真机试验

行：SE(3)-WAM 的一次成功；最强基线在同一试验键上的表现；SE(3)-WAM 的一次失败。**列**：查询帧、首个执行时刻 τ^a 与接触时刻。**叠加**：蓝色为跟踪得到的过去位姿；紫色为指令的夹爪路径。真实照片不做修饰；叠加来自各次试验的日志数据。

图 4. **真机试验：**SE(3)-WAM 与 [最强基线] 在同一试验键上的表现（上两行），以及 SE(3)-WAM 的一次失败（下）。[对所选试验的一句话说明。]

表示的贡献区分开。匀速输入变体落后 SE(3)-WAM [X.X] 个百分点。我们结合无未来监督对照解释这一差异；后者既没有预测损失，也没有外推输入 token。DOMINO [19] 上的结果见附录 D.2。

4.3 真机实验

我们在 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机上评估六个任务（图 S4，表 S9），比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 Diffusion Policy [16]：传送带抓取（T1）、放入传送带上的容器（T2）、转盘抓取（T3）、抓取运动的玩具小车（T4）、拦截碰撞后的球（T5），以及拦截沿斜坡滚落或滑落的物体（T6）。它们涵盖直线、圆周、平面自由运动、撞击后运动与重力加速运动。每个方法在相同的 100 条遥操作示范上逐任务训练或微调，另用独立的 20 条示范验证，并以共享的试验键在每个任务上运行 20 次试验。SE(3)-WAM 用 [跟踪器] 跟踪目标，在一块 RTX 5090 上运行，p95 出动作时间为 [XX] ms。它在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%（表 2）。[优势最大的任务及主要失败模式]（图 4）。

表 2. **真机结果**。六个任务上的成功率（%）：T1 传送带抓取、T2 移动容器放置、T3 转盘抓取、T4 移动小车抓取、T5 碰撞后拦截、T6 斜坡拦截（每个任务每个方法 20 次试验）。All 合并全部试验；区间见附录 D.3。

方法	T1	T2	T3	T4	T5	T6	All
$\pi_{0.5}$	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—

表 3. **核心消融**（最终 24 层模型，Dynamic-14 留出场景，三个训练种子）。每行只改变 SE(3)-WAM （⋆）的一个组件。SR、SR_{150}：不加和加入 150 ms 延迟时的成功率（%）；e_t：接触时刻误差（ms）；e_p：首次接触时的位置误差（mm）；p95：出动作时间（ms）。

变体	SR	SR_{150}	e_t	e_p	p95
SE(3)-WAM ⋆	—	—	—	—	—
无目标历史	—	—	—	—	—
无未来监督	—	—	—	—	—
无场景流监督	—	—	—	—	—
无专用 SE(3)	—	—	—	—	—

4.4 消融：动态策略需要什么？

四个核心对照使用最终 24 层模型与配方，每个对照训练三个种子，数据与训练预算相同（表 3）。它们检验目标历史、未来监督、场景流监督和专用目标位姿监督。各对照在实时协议下评估 0 与 150 ms 附加延迟，完整模型的参考结果复用第 4.2 节。更广泛的设计选择在 4 层模型上筛选，各组配方见附录 F。

记住什么。 无历史对照保留当前图像、当前目标位姿和八个机器人状态，移除过去的目标位姿及其速度、加速度特征。它相对完整模型的 SR 差值在 0 ms 时为 [带符号 X.X] 个百分点，在 150 ms 附加延迟时为 [带符号 X.X] 个百分点（图 5a）。视觉历史替代方案属于 4 层筛选，不是最终规模的对照。位姿噪声鲁棒性单独用冻结权重评测（附录 F.2）。

预测什么。 无未来对照关闭 SE(3)、场景流及可见性、未来深度、DINO 与动态 RGB 损失，保留当前目标 RGB 重建，用于检验未来监督的整体作用（图 5b）。另外两个对照保留全部外观目标：一个只移除场景流与可见性监督，另一个只移除专用 SE(3) 监督。后者仍用同一14×14 流覆盖目标、机器人与周围环境，场景各部分均使用相同的粗粒度表示。前者检验场景流监督的作用，不能单独归因于环境信息。两者的带符号 SR 差值在 0 ms 时为 [X.X] 和 [X.X] 个百分点，在 150 ms 时为 [X.X] 和 [X.X] 个百分点；图 5c 按任务族分解这些效应。

图占位：图 5——消融（四个子图）

(a) 历史。完整模型与无目标运动历史在 0 和 150 ms 附加延迟下的 SR 差值。**(b) 未来监督。**完整模型与关闭全部未来损失，按任务族分组。**(c) 几何监督。**完整模型、无场景流和无专用 SE(3)，按任务族分组。**(d) 成功率与延迟。**完整模型与四个对照在 0 和 150 ms 附加延迟下的 p95 出动作时间与 SR。各面板复用相同留出轨迹与三个训练种子，显示 95% 配对自助法区间。

图 5. **最终模型规模上的核心消融。**(a) 目标运动历史。(b) 未来监督。(c) 两项几何监督。(d) 实时协议下的成功率与延迟。[四个对照完成后概括实测效应。]

图占位：图 6——执行时刻的预测

行：一次滚动捕获（预测误差为中位数）与一次失败的撞击后抓取。**列：**τ_t 的查询帧、τ^a 的帧，以及基座坐标系中的 3D 小图。**叠加：**蓝色为过去位姿，橙色为训练期预测头给出的预测三轴与粗粒度流箭头，灰色为同一时刻的真值，紫色为指令路径。完整示例见图 S5。

图 6. **执行时刻的预测**（Dynamic-14 留出回合，读自训练期预测头）。上：SE(3) 预测跟随滚动目标，而外推冲过了头。下：撞击之前，回归得到的预测对可能的结果取平均，抓取落空。

如何使用预测。 最终模型只把预测用于训练监督。4 层耦合研究的三个种子中，把预测送给动作没有带来稳定增益（附录 F.4）；该结果不能证明最终规模下的等效性。最终模型开启未使用的预测头时，只检查固定输入与噪声下的动作一致性并测量额外代价。实时协议下，额外延迟可能改变闭环轨迹。图 5d 报告四个训练对照的实测成功率与延迟，不包含最终规模的 R5 比较。

5 结论

我们提出了 SE(3)-WAM ，一个用于操作运动物体的世界—动作模型：它把精度花在接触所依赖之处，把时间只花在值得的地方。它记住目标的度量 SE(3) 运动而非过去的帧，学会精确预测目标的 SE(3) 轨迹并以稀疏 3D 流预测场景其余部分，并让动作读取由这些预测塑造的表示，而不在测试时生成预测。在策略计算期间场景持续运动的 Dynamic-14 上，以及在六个真机任务上，它优于反应式、动态与世界—动作策略。四个最终规模对照检验度量运动历史、未来监督及其两项几何成分。[核心消融完成后写入证据支持的组件结论。] 该设计用预测训练表示，同时将预测头排除在部署的动作路径之外。

局限性。 SE(3)-WAM 假设目标是刚体、在接触之前自行运动，因此可变形或带关节的目标以及接触后的动力学不在其范围内。它依赖目标的位姿估计，跟踪器的失败会传递给策略；在仿真中我们从仿真器读取位姿。回归得到的目标预测无法表示多模态的未来，例如撞击之前。我们的真机基座在没有目标位姿的 DROID 上学习，因此与位姿相关的部分只在微调中学习。最后，我们的任务只有单个目标，且环境运动较慢。

LLM Usage Statement（大语言模型使用声明）

[投稿前补充：实际使用的工具、受影响的研究与稿件部分，以及使用程度。]

参考文献

[1] Iretiayo Akinola, Jingxi Xu, Shuran Song, and Peter K. Allen. Dynamic grasping with reachability and motion awareness. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 9422–9429, 2021.

[2] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[3] Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Mojtaba Komeili, et al. V-JEPA 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025.

[4] Ronald Azuma and Gary Bishop. Improving static and dynamic registration in an optical see-through HMD. In *Proceedings of SIGGRAPH*, pages 197–204, 1994.

[5] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation*. Wiley, 2001.

[6] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[7] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[8] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pre-trained image-editing diffusion models. In *International Conference on Learning Representations*, 2024.

[9] Kevin Black, Noah Brown, Danny Driess, et al. π_0: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[10] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, 2025.

[11] Anthony Brohan, Noah Brown, Justice Carbajal, et al. RT-1: Robotics transformer for real-world control at scale. In *Proceedings of Robotics: Science and Systems*, 2023.

[12] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, 2017.

[13] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[14] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[15] Yixiang Chen, Peiyan Li, Yuan Xu, Qisen Ma, Jiabing Yang, Kai Wang, Jianhua Yang, Dong An, He Guan, Gaoteng Liu, Jianlou Si, Jun Huang, Jing Liu, Nianfeng Liu, Yan Huang, and Liang Wang. FlowWAM: Optical flow as a unified action representation for world action models. *arXiv preprint arXiv:2607.13017*, 2026.

[16] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[17] Yilun Du et al. Learning universal policies via text-guided video generation. In *Advances in Neural Information Processing Systems*, 2023.

[18] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. *arXiv preprint arXiv:2503.11565*, 2025.

[19] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. *arXiv preprint arXiv:2603.15620*, 2026.

[20] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[21] Chelsea Finn and Sergey Levine. Deep visual foresight for planning robot motion. In *IEEE International Conference on Robotics and Automation*, 2017.

[22] Ankit Goyal, Jie Xu, Yijie Guo, Valts Blukis, Yu-Wei Chao, and Dieter Fox. RVT: Robotic view transformer for 3D object manipulation. In *Conference on Robot Learning*, pages 694–710, 2023.

[23] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *arXiv preprint arXiv:2505.10075*, 2025.

[24] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse control tasks through world models. *Nature*, 640(8059), 2025.

[25] Nicklas Hansen, Hao Su, and Xiaolong Wang. TD-MPC2: Scalable, robust world models for continuous control. In *International Conference on Learning Representations*, 2024.

[26] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[27] B. Hove and Jean-Jacques E. Slotine. Experiments in robotic catching. In *American Control Conference*, 1991.

[28] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[29] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *International Conference on Machine Learning*, 2025.

[30] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[31] Wei Huang, Bohan Zhang, Chenzhi Liu, Isabella Liu, Shuai Yang, Weian Mao, Luozhou Wang, Yicheng Xiao, Weifeng Lin, Qixin Hu, Bryan Chu, Sifei Liu, Linxi Fan, Xiaojuan Qi, Song Han, and Yukang Chen. Long-WAM: Scaling the context of world-action models. *arXiv preprint arXiv:2610.10528*, 2026.

[32] Seth Hutchinson, Gregory D. Hager, and Peter I. Corke. A tutorial on visual servo control. *IEEE Transactions on Robotics and Automation*, 12(5):651–670, 1996.

[33] Haoyuan Ji, Lingxiang Fan, Shang Su, Yinqiao Lu, Mengkai Shi, Jun Gao, and Shuo Feng. DC-WAM: Dynamic-centric visual supervision and reasoning for world-action models. *arXiv preprint arXiv:2607.25918*, 2026.

[34] Nikita Karaev, Ignacio Rocco, Benjamin Graham, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. CoTracker: It is better to track together. In *European Conference on Computer Vision*, 2024.

[35] Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3D diffuser actor: Policy diffusion with 3D scene representations. In *Conference on Robot Learning*, 2024.

[36] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset.

In *Proceedings of Robotics: Science and Systems*, 2024.

[37] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, 2024.

[38] Fenghao Lei, Zhixiong Huang, Long Yang, Jiabao Chen, Peilin Huang, Han Fu, Zhuo Li, and Xiaoxue Ren. DELE-w0.5: Inferring action from future latent state for robotic manipulation. *arXiv preprint arXiv:2608.22067*, 2026.

[39] Jiajun Li, Tiecheng Guo, Yifan Ye, Rongyu Zhang, Xiaowei Chi, Qianpu Sun, Ying Li, Yunfan Lou, Jinqiao Wang, Zhihe Lu, Meng Guo, and Shanghang Zhang. Efficient-WAM: A 1B-parameter world-action model with low-cost future imagination. *arXiv preprint arXiv:2606.10040*, 2026.

[40] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[41] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[42] Minghui Lin, Pengxiang Ding, Shu Wang, Zifeng Zhuang, Yang Liu, Xinyang Tong, Wenxuan Song, Shangke Lyu, Siteng Huang, and Donglin Wang. HiF-VLA: Hindsight, insight and foresight through motion representation for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[43] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[44] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[45] Xingyu Liu, Charles R. Qi, and Leonidas J. Guibas. FlowNet3D: Learning scene flow in 3D point clouds. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019.

[46] Yuejiang Liu, Jubayer Ibn Hamid, Annie Xie, Yoonho Lee, Maximilian Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, 2025.

[47] Yushan Liu, Jingjing Fan, Shoujie Li, Yifan Xie, Xiao-Ping Zhang, and Wenbo Ding. PACT-WAM: Predicting actions and visual foresight with compact temporal encoding for robot manipulation. *arXiv preprint arXiv:2602.15882*, 2026.

[48] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[49] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[50] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[51] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *International Symposium on Robotics Research*, 2019.

[52] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[53] Henrique Morimitsu, Xiaobin Zhu, Roberto M. Cesar, Xiangyang Ji, and Xu-Cheng Yin. DPFlow: Adaptive optical

flow estimation with a dual-pyramid framework. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17810–17820, 2025.

[54] E-Ro Nguyen, Yichi Zhang, Kanchana Ranasinghe, Xiang Li, and Michael S. Ryoo. Pixel motion diffusion is what we need for robot control. *arXiv preprint arXiv:2509.22652*, 2025.

[55] Octo Model Team, Dibya Ghosh, Homer Walke, et al. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, 2024.

[56] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.

[57] Kanchana Ranasinghe, Xiang Li, E-Ro Nguyen, Cristina Mata, Jongwoo Park, and Michael S. Ryoo. Pixel motion as universal representation for robot control. *arXiv preprint arXiv:2505.07817*, 2025.

[58] Kanchana Ranasinghe, Honglu Zhou, Yu Fang, Luyu Yang, Le Xue, Ran Xu, Caiming Xiong, Silvio Savarese, Michael S. Ryoo, and Juan Carlos Niebles. Future optical flow prediction improves robot control & video generation. *arXiv preprint arXiv:2601.10781*, 2026.

[59] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, 2025.

[60] Yiran Shi, Dongqi Guo, Tianchen Zhao, Feng Gao, Liangzhi Shi, Chao Yu, ZhiJian Mo, Qihua Xiao, XiaoShuai Peng, Qingmin Liao, and Yu Wang. StreamingVLA: Streaming vision-language-action model with action flow matching and adaptive early observation. *arXiv preprint arXiv:2603.28565*, 2026.

[61] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, 2022.

[62] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[63] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[64] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[65] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. *arXiv preprint arXiv:2601.05237*, 2026.

[66] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. *arXiv preprint arXiv:2602.22010*, 2026.

[67] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. *arXiv preprint arXiv:2606.02486*, 2026.

[68] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[69] Zachary Teed and Jia Deng. RAFT-3D: Scene flow using rigid-motion embeddings. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.

[70] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, 2025.

[71] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[72] Changhao Wang, Jaden Clark, and Shuran Song. Chronos policy: Learning robot policies on physical time. *arXiv preprint arXiv:2610.13929*, 2026.

[73] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[74] Ruicheng Wang, Sicheng Xu, Yue Dong, Yu Deng, Jianfeng Xiang, Zelong Lv, Guangzhong Sun, Xin Tong, and Jiaolong Yang. MoGe-2: Accurate monocular geometry with metric scale and sharp details. *arXiv preprint arXiv:2507.02546*, 2025.

[75] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[76] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[77] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[78] Gaoyuan Wu, Ziyu Shan, Haoyang Du, Yuyao Jiang, and Ziwei Wang. AffordTrajDP: Dynamic affordance-guided visuomotor policy learning for robotic manipulation. *arXiv preprint arXiv:2608.01603*, 2026.

[79] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, 2024.

[80] Yuxi Xiao, Qianqian Wang, Shangzhan Zhang, Nan Xue, Sida Peng, Yujun Shen, and Xiaowei Zhou. SpatialTracker: Tracking any 2D pixels in 3D space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[81] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. *arXiv preprint arXiv:2601.22153*, 2026.

[82] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, 2024.

[83] Zhenjia Xu, Zhanpeng He, Jiajun Wu, and Shuran Song. Learning 3D dynamic scene representations for robot manipulation. In *Conference on Robot Learning*, 2020.

[84] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[85] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[86] Heng Yu, David D. Yuan, Juze Zhang, Changan Chen, Yao Feng, Michelle Baldonado, Steve Cousins, Li Fei-Fei, Jiajun Wu, and Ehsan Adeli. OpenWAM: An open framework for composable world-action models. *arXiv preprint arXiv:2610.07922*, 2026.

[87] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2024.

[88] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[89] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

[90] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. *arXiv preprint arXiv:2607.01938*, 2026.

[91] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[92] Chuhan Zhang, Guillaume Le Moing, Skanda Koppula, Ignacio Rocco, Liliane Momeni, Junyu Xie, Shuyang Sun, Rahul Sukthankar, Joëlle K. Barral, Raia Hadsell, Zoubin Ghahramani, Andrew Zisserman, Junlin Zhang, and Mehdi S. M. Sajjadi. Efficiently reconstructing dynamic scenes one D4RT at a time. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[93] Jiahui Zhang, Yurui Chen, Yueming Xu, Ze Huang, Yanpeng Zhou, Yu-Jie Yuan, Xinyue Cai, Guowei Huang, Xingyue Quan, Hang Xu, and Li Zhang. 4D-VLA: Spatiotemporal vision-language-action pretraining with cross-scene calibration. In *Advances in Neural Information Processing Systems*, 2025.

[94] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[95] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[96] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Tsung-Yi Lin, Gordon Wetzstein, Ming-Yu Liu, and Donglai Xiang. CoT-VLA: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[97] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[98] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[99] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3D-VLA: A 3D vision-language-action generative world model. In *International Conference on Machine Learning*, 2024.

[100] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *International Conference on Learning Representations*, 2025.

[101] Hongyan Zhi, Peihao Chen, Siyuan Zhou, Yubo Dong, Quanxi Wu, Lei Han, and Mingkui Tan. 3DFlowAction: Learning cross-embodiment manipulation from 3D flow world model. *arXiv preprint arXiv:2506.06199*, 2025.

[102] Gaoyue Zhou, Hengkai Pan, Yann LeCun, and Lerrel Pinto. DINO-WM: World models on pre-trained visual features enable zero-shot planning. In *International Conference on Machine Learning*, 2025.

[103] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[104] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning.

arXiv preprint arXiv:2009.12293, 2020.

[105] Yifeng Zhu, Zhenyu Jiang, Peter Stone, and Yuke Zhu. Learning generalizable manipulation policies with object-centric 3D representations. In *Conference on Robot Learning*, 2023.

[106] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, 2023.

补充材料

本补充材料给出 SE(3)-WAM 的实现细节（附录 A）、在真实机器人数据上的预训练（附录 B）、基准（附录 C）、基线、DOMINO 比较、真机与计时（附录 D）、补充结果（附录 E）、支撑第 4.4 节的完整消融研究（附录 F），促成这一设计的误差分析（附录 G），以及更多相关工作（附录 H）。彩色破折号与方括号内容表示等待最终实验填写的数值。

A 实现

A.1 场景 token 与摘要 token

当前图像。 冻结的 MAE ViT-B/16 [26] 把 224×224 的主视角 RGB 编码为 196 个 patch token。我们在开发场景上将它与冻结的 DINOv3 编码器 [63] 以及与策略一同训练的 CNN 比较后选定了它（附录 F.1）。每个 patch 获得视角嵌入、其平均有效度量深度的线性嵌入，以及其中心像素反投影到基座坐标系后位置的线性嵌入；后者由相机内参与外参计算。这些位置也进入 patch query 与 key 的 3D 旋转位置编码。同样的中心点就是稀疏 3D 流的源点（附录 A.3）。目标、机器人、摘要和动作 token 不使用旋转位置编码。过去的图像从不进入模型，我们在主干之前删去其槽位，因此场景共有 212 个 token。

目标运动历史。 每次查询时，目标历史覆盖最近 8 个控制步，即偏移 $-350,-300,\ldots,0$ ms。8 个目标状态 token 各是一个 25 维描述子 $(\mathbf{p},\log R,\Delta\mathbf{p},\log\Delta R,\Delta t,\mathbf{v},\boldsymbol{\omega},\mathbf{a},\boldsymbol{\alpha})$，各分量维数为 $(3,3,3,3,1,3,3,3,3)$。槽位 0–6 描述相邻偏移之间的七个区间，槽位 7 存放基座坐标系下当前的绝对位姿。速度为区间位移除以经过的时间，加速度为相邻速度之差除以区间中心的时间间隔。我们用训练统计量对每一维标准化，把无效维置零，并附加三个有效性标志（位姿、区间与加速度），然后送入带加性相对时间嵌入的 $28\to1024\to1024$ GELU MLP。无效特征置零；没有有效特征的槽位被掩码排除，不使用可学习的目标丢失 token。在仿真中，位姿来自仿真器；在真机上，位姿来自附录 A.2 的因果跟踪器，我们在相同偏移处对其轨迹重采样：平移线性插值、旋转沿测地线插值，不外推，也不跨越超过两个相机周期的空缺插值。

机器人状态。 相同偏移处的 8 个末端执行器状态（位置、旋转向量与测得的夹爪开度比例）构成机器人 token。策略没有语言 token；视角、时间、深度与位置嵌入修改已有 token，不增加槽位。

摘要 token。 16 个可学习嵌入构成世界流的摘要 token。它们在每一层读取场景 token 与彼此，并且是动作 token 能读取的唯一世界 token。

A.2 位姿跟踪器

真机协议完全无标记，包括在线跟踪、离线训练标签与误差测量。每个物体使用一个固定参考，在所有示范中共享原点、坐标轴、尺度与实例身份。候选流程使用 Grounding DINO 与 SAM 2.1 [44, 59] 的因果掩码，并将 RGB-D 与该参考配准，FoundationPose [76] 是候选方法。[在实际装置上验证并确定跟踪器、参考采集、图像分辨率，以及丢失与恢复阈值。]

策略输入必须通过部署跟踪器的因果回放得到。每个估计携带采集时刻、可用时刻与分量有效性；后续帧不得修订已经发给策略的估计。离线监督可在相同物体坐标系内使用多帧或多视角配准与人工

表 S1. **选定的无标记流程。**相对注明来源的无标记参照，报告平移（mm）及旋转（°）误差的中位数/p95、参照不确定度和观测丢失比例。真机球体排除旋转。测量及参照流程尚待验证，估计标签不作为真值。

目标	mm	°	参照不确定度	丢失
真机刚体	—	—	—	—
真机球体	—	–	—	—

复核。这些估计不是独立真值。跟踪误差测量需要无标记参照，并注明其不确定度；仅有重投影一致性不能提供这种参照。

真机球类试验协议从策略输入中排除目标朝向、相对旋转、角速度与角加速度，并从预测监督与报告误差中排除目标旋转。球心平移、平移速度与加速度及其有效观测均予保留。该掩码不丢弃整条目标状态槽位，也不改变机器人朝向状态、旋转指令或仿真中的完整 SE(3) 实验。不开展球体朝向可观测性研究。表 S1 在测量完成后记录所选流程的结果。真实误差标定与跟踪闭环评测独立于附录 F.2 的合成噪声研究。

A.3 预测头

所有预测头都是世界流最终隐藏状态上的轻量读出。它们与动作一同训练，部署时被跳过，且没有任何 token 读取其输出，因此它们只通过损失塑造世界流。

目标。 一个线性映射从 16 个摘要 token 的最终状态均值读出轨迹 $\{(\mathbf{d}_h, \phi_h)\}_{h=1}^{8}$。记有效时域集合为 $\mathcal{V}$，

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h \in \mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\mathrm{SO}(3)}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{S1}$$

其中 $\lambda_R = 0.1$，$\hat{R}_h = \mathrm{Exp}(\hat{\phi}_h^{\wedge}) R(\tau_t)$。我们使用左相对旋转向量与累计平移，而不使用 twist 指数映射，因为后者会通过其雅可比矩阵把平移与旋转耦合起来。平方误差训练得到点估计，不显式表示未来的多个模式。

稀疏 3D 流。 流是 $N = 196$ 个 patch 中心点在 8 个时域上的累计 3D 位移 $F \in \mathbb{R}^{N \times 8 \times 3}$，以基座坐标系表示，并附带可见性 $o \in \{0,1\}^{N \times 8}$。每个 patch token 上的线性读出给出其点在每个时域的位移与可见性 logit。我们用训练标签上拟合的固定尺度 $s_F = 0.7154605\,\mathrm{m}$ 对位移归一化，并使用

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h) \in \mathcal{V}_F} \Big[\frac{\|\hat{f}_{ih} - F_{ih}/s_F\|^2}{3} + \mathrm{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \tag{S2}$$

其中 $\hat{f}$ 为归一化位移，$\mathcal{V}_F$ 为有效标签集合。仿真中可见性 BCE 权重为 1；不可见但标签有效的点仍监督位移。这些点同样覆盖目标、机器人与环境；目标的精度来自其位姿头。

外观目标。 最终 patch token 上的线性读出在每个时域预测三个目标：通过每个 patch 的 16×16 像素读出预测度量深度与运动表面 RGB，以及冻结 DINOv3 ViT-L/16 教师 [63] 在 14×14 网格上的 1024 维特征。深度在有效像素上取平方误差；DINO 特征经通道层归一化后取平方误差；RGB 在移动超过 1 mm 的表面（包括机器人）上取平方误差。这些损失先对通道取平均，再对有效位置取平均。一个带 GELU 和末端 sigmoid 的 $1024 \to 256 \to 3072$ MLP 读取最终摘要 token 的均值，重建当前目标的 32×32

RGB 区域，并对有效 RGB 元素的绝对误差取平均。这使摘要特征与目标关联而不增加输入。四项损失构成 $\mathcal{L}_{\text{aux}}$；$\lambda_{\text{aux}} = 0.1$ 使每项在总目标中的权重为 0.1。四个头都仅用于训练，部署时跳过，其输出从不进入动作流。

A.4 动作流

每个动作块有 8 条七维指令，每条包含基座坐标系下的平移增量、左相对旋转向量与夹爪指令，控制周期为 50 ms。平移与非零旋转增量以执行时测得的末端位姿为参考；零旋转指令可保留控制器之前的姿态目标。归一化使用训练集中有效且不重复的已下发指令的均值与总体标准差。流匹配在这些坐标中使用单位高斯，每个动作块一个 u，动作 token 通过自适应层归一化接收 u。每个预测位置为其动作块抽取 8 对独立的噪声与时间样本并对其损失取平均，这在不扩大 batch 的情况下降低了动作梯度的方差。部署时，我们积分 5 个 Euler 步，反归一化，解码旋转向量，并按导出的运动限幅逐轴截断：候选配置为 0.05 m 与 0.5 rad，0.10 m 平移需要显式部署覆盖。夹爪在 $|g| \le b$ 时输出 0，否则输出 $\text{sign}(g)$，默认 $b = 0$。单独验证的 E5 部署在接球中采用 $b = 0.5$，其余任务采用 $b = 0.1$；该设置不属于最终候选配置。

A.5 主干与耦合

主干。 24 层中的每一层都用共享的 Q/K/V 与输出投影对全部 token 做一次注意力，随后世界 token 与动作 token 分别通过各自的 SiLU 前馈网络（比例 4）。世界 token 使用层归一化，动作 token 使用自适应层归一化，主干可训练参数共 504.0M。附录 F.1 中的替代方案在参数量匹配的条件下，为两条流分别设置注意力投影、归一化与前馈网络。

注意力掩码。 掩码作用于三组 token：场景（$\mathcal{S}$）、摘要 token（$\mathcal{M}$）与动作（$\mathcal{A}$）。场景 token 只读取 $\mathcal{S}$，摘要 token 读取 $\mathcal{S}$ 和 $\mathcal{M}$，动作 token 读取 $\mathcal{M}$ 和 $\mathcal{A}$。被阻断的连接在每一层、每个注意力头上、训练与部署时都取 logit $-\infty$。由于世界 token 既不读取动作，也不读取流时间，它们的状态在每次查询中只计算一次，并在各 Euler 步之间复用；除了预测损失在共享参数上的梯度之外，没有任何未来标签能到达动作。

筛选中的耦合方式。 附录 F.4 的 4 层变体使用相同的模块、初始化与损失，只改变掩码或加入一个小模块。R0 关闭所有预测损失。R1 在世界流中加入一个物体查询和每个 patch 一个查询，它们读取 $\mathcal{S}$、$\mathcal{M}$ 与彼此，并代替池化状态承载预测读出，但它们与动作之间不开启任何连接。R2 让动作 token 在每一层读取这些查询。R3 让这些查询读取动作，R4 同时开启两个方向；在 R3 和 R4 中，世界状态在每个 Euler 步都要重算。R5 在每次查询中解码一次预测，把目标轨迹、流及其可见性概率（旋转采用连续的 6D 表示）经几何编码器（0.37M 参数）编码为几何 token，动作在 $\mathcal{M}$ 之外还读取这些 token。R5 在预测出的几何上训练，并让动作损失经由它反向传播，不使用教师强制。所有变体都不在两条流之间截断任何梯度。

A.6 训练配方

表 S2 列出在 Dynamic-14 上训练的配方。示范中的每个控制步都是一个查询窗口，11,200 条示范共给出 1,324,374 个训练窗口；另有 350 个留出回合作为验证集。每个损失按整个累积全局 batch 上的有效标签数归一化。每个窗口包含 8 个独立的查询位置，各有自己的因果历史，不跨位置进行注意力。

图像编码器处理当前帧，DINOv3 教师对未来帧的特征按回合缓存一次。最终仿真训练正在进行；完整训练的实测时长与硬件尚待报告，为 [X] 小时和 [N] 块 RTX PRO 6000 GPU。DROID 基座使用附录 B.4 的配方。

表 S2. Dynamic-14 上的训练超参数。

项目	取值
主干	24 层，宽度 1024，16 个注意力头，前馈 4096，504.0M 参数
Token	212 个场景、16 个摘要、8 个动作
编码器	冻结的 MAE ViT-B/16，输入 224×224
优化器	AdamW，$\beta = (0.9, 0.999)$，$\epsilon = 10^{-8}$，权重衰减 10^{-4}
学习率	2×10^{-4}，从 0 开始 5,174 次预热更新，余弦衰减到 0
Batch 与更新	全局 batch 512 个窗口，20 轮（51,740 次更新）
损失权重	$\lambda_P = \lambda_F = 1$，$\lambda_R = 0.1$，每个辅助目标 $\lambda_{\text{aux}} = 0.1$
精度	可训练权重 FP32，冻结编码器 BF16，梯度截断 0.1
动作噪声	每个查询位置 8 对噪声与时间样本
采样	动作 5 个 Euler 步
推理	FP32，查询内缓存世界状态
硬件	[N] 块 RTX PRO 6000 GPU，每次训练约 [X] 小时

A.7 部署

每次查询编码最新观测，运行一次不带预测头的世界流，并在缓存的世界状态上积分动作流。动作块从查询结束时或之后的第一个控制周期边界开始执行，下一次查询也在同一边界以新的观测开始，因此策略以其延迟允许的最高频率重新规划。在附录 C.3 的实时协议下，查询进行期间物理继续推进，执行器继续执行上一个动作块的剩余指令。附录 C.3 描述所有方法共用的执行器，附录 D.4 描述计时方法。

B 在真实机器人数据上预训练

B.1 数据、划分与时间

预训练语料为 DROID [36]，以 15 Hz 用两个外部相机和一个腕部相机录制，并配有 PointWorld 为其发布的 3D 点轨迹与优化后的相机标定 [30]。我们要求关节序列、末端执行器位姿、夹爪状态、指令和相机身份完全一致，以此把每个发布片段与其原始 DROID 回合对应起来，并排除采集时钟不单调或对应关系有歧义的片段。在 42,935 个已对齐回合中，42,087 个形成训练窗口。模型使用第一个外部相机、其深度以及 PointWorld 对它的标定。训练单元是带有对齐的未来标签与动作标签的因果观测窗口，共 598,889 个锚点窗口：37,874 个训练回合给出 538,740 个，4,213 个验证回合给出 60,149 个。两划分没有共同回合。表 S3 报告保留量与标签有效率。

时间。 所有时间都是采集时间戳，我们不把帧重新标注为名义帧率。机器人历史因果地使用查询时刻及之前最近的 8 个状态，与部署时一致。流标签保留 PointWorld 自身的记录时刻，而不插值到仿真模型的 50 ms 时域。未来 DINOv3 目标使用相同记录时刻的帧。每个锚点扩展为 8 个连续原生查询位置，各有独立的因果历史。只有锚点位置保留 XYZ 与 DINO 监督，其余位置提供动作监督，不插值或复制世界标签。

表 S3. **DROID 预训练数据。**各阶段的保留量与标签有效率。窗口指带有对齐标签的因果观测窗口，主相机的每个控制步一个；流标签按点与时域计数。

	训练	验证	全部
已对齐的 episode	–	–	42,935
形成窗口的 episode	37,874	4,213	42,087
窗口	538,740	60,149	598,889
有效动作（%）	—	—	96.88
有效流标签（%）	—	—	47.05
DINO 目标的未来帧	—	—	3,425,218
含物体运动的窗口（%）	—	—	—

图占位：图 S1——由 PointWorld 轨迹得到的流标签（示意）

左：主外部相机的一帧 DROID 画面，旁边并列 PointWorld 优化后的相机位姿与原始位姿，以及14×14 的 patch 网格。**中**：每个 patch 中的候选 PointWorld 轨迹（细灰线）与选中的轨迹（橙色）：在三维上保持一致的轨迹中图像运动最大的那条，否则回退到离 patch 中心最近的轨迹；没有有效轨迹的 patch 置灰。**右**：选中轨迹在 PointWorld 记录时刻、基座坐标系下的 3D 位移，机器人夹爪路径为紫色。使用一段真实 DROID 帧序列，仅做矢量叠加。

图 S1. DROID 基座的流标签。每个图像 patch 跟随一条 PointWorld 轨迹，选择规则使其在存在运动物体时覆盖它们；该轨迹在基座坐标系中的 3D 位移即为标签。无效标签屏蔽其损失。

动作。 机器人状态与笛卡尔指令经标定的法兰到 TCP 变换后，以机器人基座坐标系表示，参数化方式同附录 A.4。若标签取值有限且其参考状态可因果地获得，我们就接纳该标签。机器人的执行限幅不作为接纳规则，因为逐轴限幅会丢弃快速但有效的运动，使基座偏向慢速示范。在 4,791,112 个动作槽位中，我们屏蔽 DROID 采集程序未下发指令的 149,318 个，保留其余 96.88%，不按幅度或速度过滤。动作与流的有效性相互独立，因此无效动作不会移除其窗口的流标签。

B.2 基座学习什么

DROID 不提供物体位姿，其指令虽然提到被操作物体，却没有标出它。因此基座没有目标状态 token，也没有位姿头。它的输入是当前 RGB-D 帧与机器人历史（204 个场景 token），不可用深度显式掩码排除；目标是动作损失（权重 1）、选定 patch 轨迹的稀疏 3D 流（权重 1）和未来 DINOv3 特征（权重 0.1）。未来深度、运动区域 RGB 与目标重建关闭。由于 PointWorld 的轨迹只记录可见位置，流标签中没有不可见的负例，因此我们把可见性损失设为零，而不是让模型学到“每个点始终可见”。DROID 中的大多数物体只在机器人移动它们时才运动，因此基座主要学习度量几何、机器人自身动作引起的 3D 运动及其与动作的耦合；我们任务中的外源运动和目标位姿在微调时才进入。

B.3 流标签

PointWorld 的轨迹已在基座坐标系中表示。14×14 网格中的每个 patch 在整个窗口内跟随一条固定轨迹。在初始投影落在该 patch 内、初始可见且具有有效正深度的发布轨迹中，我们优先选择图像运动最大的一条；若其 3D 位移与图像运动不一致，则换成另一条候选。否则取离 patch 中心最近的轨迹。这一规则能覆盖固定中心点会错过的运动物体：在 10 个回合的 30 个片段中，有 18 个片段存在可见的物体运动；该规则在其中 13 个片段中把一条动态轨迹的起点与两个未来点都落在物体内部，而中心规则只有 5 个。这衡量的是与图像一致的运动覆盖，而不是实测的 3D 精度，小物体上的 patch 仍可能漂

图占位：图 S2——配方与规模

(a) 仿真模型。纵轴：开发集 SR；横轴：样本量相同条件下的 12、24、48 层；星号标出选定配置。**(b) DROID 基座。**横轴：训练样本数（对数）；纵轴：48 层模型在最后一个时域的验证流端点误差（左轴，mm）与动作损失（右轴）；标记为选定的检查点。

图 S2. 仿真模型 (a) 与 DROID 基座 (b) 的配方与规模。

到背景上。标签是该轨迹在每个记录时刻相对其初始位置的位移。没有有效轨迹的 patch 记为无效，我们不用邻居填补。在全部窗口中，47.05% 的点—时域槽位带有有效标签。

标签质量。 我们在相同场景上把 PointWorld 轨迹与由二维对应 [53] 加单目度量深度 [74] 提升得到的流进行比较。在图像中静止的表面上，选中的 PointWorld 轨迹在各时域上的移动为 [0.9] 与 [5.8] mm（中位数与第 95 百分位），而用单目深度提升的流为 [18] 与 [72] mm，其尺度随时间漂移；因此我们使用 PointWorld 轨迹，不混入提升得到的流。PointWorld 的掩码不足以可靠地把物体与背景分开，因此我们不使用它们。

B.4 配方与规模

仿真模型。 SE(3)-WAM 从通用视觉初始化出发，按表 S2 的配方在 Dynamic-14 上训练。我们在宽度 1024 下于 12、24、48 层中选择其深度，并用训练样本数相同的短训练选择配方，均在开发场景上决定（图 S2a）。

DROID 基座。 基座采用同一架构族，宽度 1024、48 层（1.02B 可训练参数），只使用真实数据。配置的训练预算为 20 轮（21,060 次更新，其中 2,106 次预热），全局 batch 为 512，使用 64 块 GPU，优化器与精度同表 S2。预训练仍在进行，最终检查点尚未得到（图 S2b）。

B.5 逐任务微调

每个真机策略从基座初始化，并只在其任务的示范上微调。基座所缺少的目标状态 token、位姿头与外观头以新的初始化加入，策略从附录 A.2 的跟踪器获得位姿。仿真权重不用于初始化任何真机策略，基座也不接触仿真数据。每个策略自行建立优化器、学习率调度、仅用于训练的归一化与读出头。

C Dynamic-14

C.1 任务、角色与误差项

我们在 MuJoCo 与 robosuite [71, 104] 上构建了 Dynamic-14 ，它包含五个任务族中的 14 个任务（图 S3）。表 S4 列出其成功条件，表 S6 列出其场景取值范围。我们将发布这些任务、通过筛选的场景、成功判定与示范。

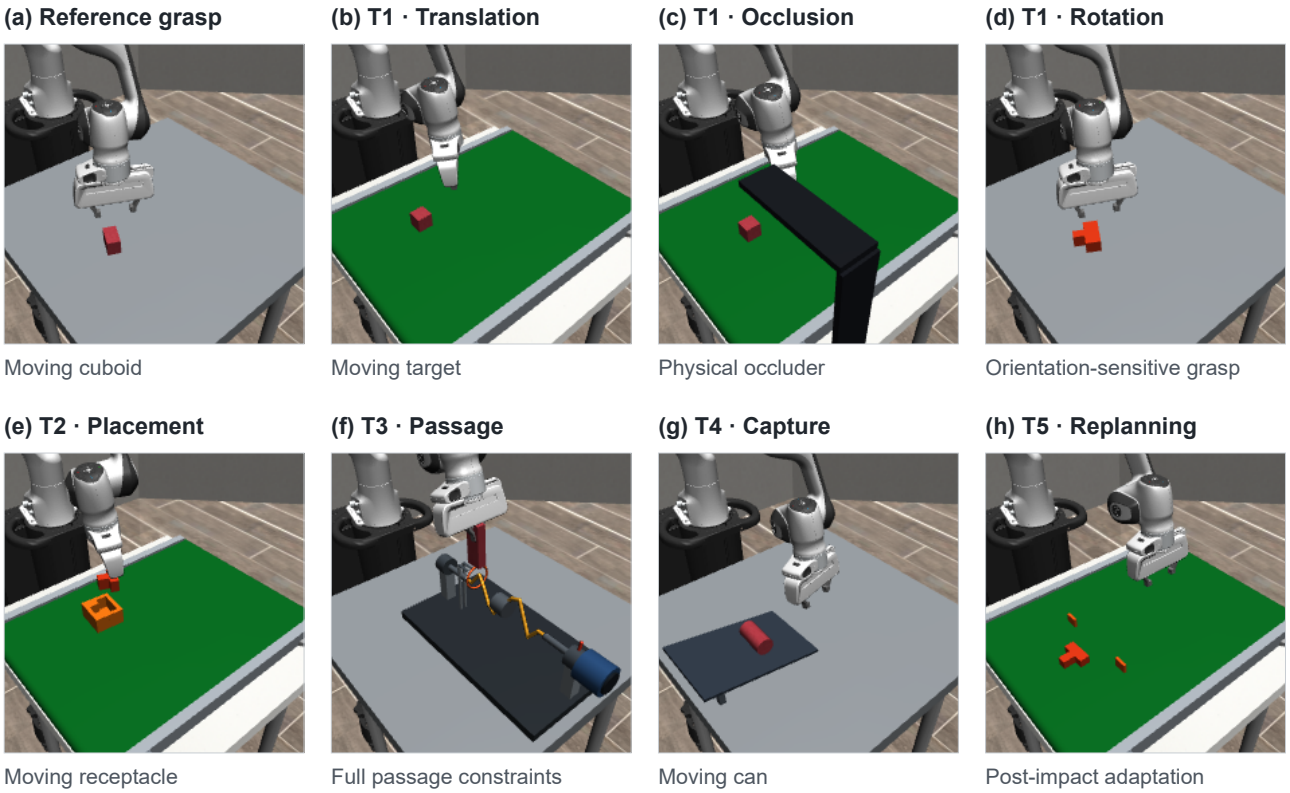


图 S3. Dynamic-14 的观测。八个示例涵盖参考抓取，抓取平移、被遮挡或旋转的目标，放入移动料箱，沿旋转导线穿越，捕获滚动物体，以及撞击后抓取。每个子图是一个开发集场景最后观测到的、未裁剪的 224×224 主视角 RGB。表 S4 列出全部 14 个任务。

角色与临界领先时长。 表 S5 把每个任务中的物体分配到第 3.1 节的两种角色。目标是其位姿误差进入接触或容纳容差 ε 的物体，环境由只需以间隙 m 避开的物体组成。因此移动料箱是目标，因为它的位姿决定能否放入。穿越任务中的导线同时扮演两种角色：它在入口处的位姿是目标，因为棒必须在那里对准到 30 mm 以内；它沿环路的几何是环境，因为任何接触都会失败。该表还给出每个任务的速度及其临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$（附录 G.5），最后一列列出每个任务涉及的误差项（式 3 与附录 G.2–G.3）。传送带与平移目标决定速度与领先时长；旋转目标、SE(3) 放置与导线使朝向进入接触；斜坡、低摩擦与撞击器产生外推无法预料的运动；遮挡物、导线、托盘与撞击器决定间隙，遮挡物还会去掉历史。

我们在每个 2 ms 的物理步、按表 S4 中要求的顺序检查成功，被中断的持续条件会重置其计数。终止事件分为五类，分别报告。*无效*事件是仿真器状态损坏。*边界*事件是离开工作空间或下游区域、掉落或目标时间窗过期。*安全*事件是不安全接触、过大的边缘冲量、触碰导线、释放冲量、机器人过早接触、无支撑的托盘接触或被撞击器卡住。*任务违规*是在目标外释放、路径偏离或倒退、过早释放、偏转而未捕获、倾倒、缺少或多出撞击，或出射运动改变不足。最后一类是*超时*。每个任务族在每个物理步按固定顺序检查其事件，并保留第一个终止事件。按任务等权的得分对每个任务赋予相同权重，包括某些方法从未成功的任务。

C.2 场景与示范

我们对连续范围均匀采样，对离散选项等概率采样，然后进行物理可行性检查。评测回放存储下来的已通过场景。简谐平移遵循 $\mathbf{p}(t) = \mathbf{c} + (0, v_y, 0)t + (A_x \sin(2\pi f_x t + \phi), 0, 0)$，其中 $\phi \sim \mathcal{U}[-\pi, \pi]$。捕获任务的目标从静止开始，在 $[5, 15]^\circ$ 的斜坡上受重力与摩擦作用运动。只有当目标在开始时至少可见八帧、被完全遮挡 0.5–3.0 s、之后再次至少可见三帧时，我们才接受一个遮挡场景。

表 S4. Dynamic-14 十四项任务的成功条件，阈值为我们任务实现中的取值。任务须依次通过各阶段，且不触发终止性失败。所有任务的控制频率为 20 Hz，物理仿真步长为 2 ms；下列时长均为物理时间。COM 表示质心。

任务	依次满足的成功条件	时限
grasp; t1_belt, t1_xyz, t1_so3, t1_occ	接近至 0.10 m 内；双侧指垫接触持续 0.05 s；碰撞几何体底部高于支撑面至少 0.05 m；接触与间隙保持 0.50 s。T1 分别加入传送带驱动、平移、旋转或实体遮挡物。SO3 无额外的成功角度阈值；OCC 中与遮挡物发生不安全接触即终止。	160 步 8 s
t2_trans	接近至 0.10 m 内。物体的完整碰撞几何体位于容器内：平面间隙和底面间隙均 ≥ -0.002 m，顶端不高于容器开口。释放要求张开指令 < -0.5 且无指垫接触。相对线速度和角速度分别 ≤ 0.08 m/s、0.8 rad/s，持续 0.10 s，随后稳定停留 0.50 s。	200 10 s
t2_se3	接近至 0.05 m 和 0.12 rad 内。完整纳入 T 形容器：平面间隙 ≥ 0.002 m，底面间隙位于 $[-0.002, 0.002]$ m，倾角 ≤ 0.05 rad，顶端低于开口。释放后，相对线速度和角速度分别 ≤ 0.02 m/s、0.04 rad/s，持续 0.10 s，再停留 0.50 s。0.12 rad 阈值用于接近阶段。	200 10 s
t3_phase	回合开始时杆已被抓住。相位对齐要求距离 ≤ 0.090 m、环方向误差 ≤ 0.20 rad。在进度 ≤ 0.15 时进入 0.030 m 范围；历史最大进度先达到 ≥ 0.60，再达到 ≥ 0.85，且距终点 ≤ 0.055 m。	420 21 s
t3_full	双侧接触持杆 0.05 s，然后完成上述相位阶段。在后续采样时刻，当前进度仍须 ≥ 0.85，且离路径和终点均至少 0.045 m。最后张开夹爪（< -0.5）且无指垫接触。退出前释放判为失败。	640 32 s
t4_sphere	接近至 0.10 m 内；首次合格接触须在离开斜坡后发生；成功前接触托盘即判为失败。双侧夹持的名义时长为 25 ms（12 个物理采样步，24 ms）。以首次达到双侧夹持条件时的高度为基准，将质心抬升 0.05 m，并保持接触和高度 0.50 s。	120 6 s
t4_sphere_tabletop; t4_slider	接近至 0.10 m 内；接触须发生在离开斜坡后、仍受支撑、位于捕获区且平面速度 ≥ 0.08 m/s 时。双侧夹持持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m；随后保持接触和高度 0.50 s。	120 6 s
t4_can	采用相同的受支撑捕获顺序。首次指垫接触前，若罐体轴线与竖直方向的点积绝对值 > 0.45，则按不稳定倾倒判为失败。配置不要求夹爪沿横向闭合。	120 6 s
t5_replan	机器人接触前，所选侧恰有一个撞击组完成。在物理撞击结束时间戳后 30 ms，按分支方向取符号的横向速度 ≥ 0.035 m/s，偏航角速度 ≥ 0.35 rad/s。接近至 0.10 m 内；双侧夹持且抓取轴误差 $\leq 18°$，持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m，并稳定夹持 0.50 s。撞击组时滞为 12 ms，最长接触时长为 0.10 s。	120 6 s

训练集包含 11,200 条示范，每个任务 800 条。它们由使用特权仿真器状态的专家生成，而学习型策略只接收第 3.2 节中的输入。我们以 20 Hz 记录示范，包含相机图像、深度、机器人状态、已发出的指令，以及目标位姿与场景几何的仿真真值，并据此计算未来标签、其有效掩码以及指令标签。策略从仿真器获得目标位姿，位姿噪声扫描会对其加入扰动（附录 C.3）。

C.3 协议与扫描

执行器。 所有方法都在同一个 50 ms 控制时钟的异步执行器下运行，查询只在控制周期的边界开始。下一次查询从上一次推理结束时或之后的第一个边界开始，这也是该推理产生的动作块开始执行的时刻。查询进行期间，执行器以每个控制周期一条的速度继续执行上一个动作块的剩余部分，新动作块替换这一剩余部分。因此推理能在一个控制周期内完成的方法在每条指令之前都重新规划，延迟为 ℓ 的方法每 $\max(1, \lceil \ell/50\,\text{ms} \rceil)$ 个控制周期重新规划一次。在回合的第一个动作块到达之前，以及动作块在下一个到达之前耗尽时，控制器保持当前的手臂目标与夹爪指令，物理照常推进，不重复执行任何指令。若某个基线的原论文重规划频率更低，则在*原执行方式*协议下保留其自身的动作块长度。

表 S5. **Dynamic-14 各任务的角色、容差与临界领先时长。**目标是位姿误差进入接触或容纳容差 ε 的物体；环境是只需以间隙 m 避开的物体。速度取自表 S6 的采样范围（捕获任务取离开斜坡时的速度）；临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$ 按速度中位数给出。误差项：任务涉及的误差分解项。v：目标运动。$r\theta$：朝向影响接触。e_{dyn}：非匀速运动（谐波、重力、摩擦、撞击）。m：须避开某个环境物体。occ.：历史缺失。delay：任务内置的指令延迟。

任务	代号	目标	环境	ε (mm)	$\|\mathbf{v}\|$ (m/s)	$\Delta^\star$ (ms)	m (mm)	误差项
谐波抓取	grasp	物块	桌面	[X]	0.03–0.20	[X]	–	v, $r\theta$, e_{dyn}
传送带抓取	t1_belt	零件	传送带	[X]	0.04–0.10	[X]	–	v
平移抓取	t1_xyz	零件	桌面	[X]	0.04–0.15	[X]	–	v, e_{dyn}
旋转抓取	t1_so3	零件（$\omega \le 1.2$ rad/s）	桌面	[X]	0.04–0.15	[X]	–	v, $r\theta$, e_{dyn}
遮挡抓取	t1_occ	零件	遮挡罩	[X]	0.04–0.10	[X]	[X]	v, m, occ.
移动容器	t2_trans	容器	桌面	[X]	0.03–0.06	[X]	–	v
旋转容器	t2_se3	T 形容器	桌面	[X]	0.03–0.06	[X]	–	v, $r\theta$
导线穿越	t3_phase	导线环（入口）	旋转导线	30	[X]	[X]	扫描	v, $r\theta$, m
导线穿越（完整）	t3_full	导线环（入口）	旋转导线	30	[X]	[X]	扫描	v, $r\theta$, m
小球捕获	t4_sphere	小球	托盘、斜坡	[X]	[0.4–0.7]	[X]	[X]	v, e_{dyn}, m
小球捕获（桌面）	t4_sphere_tabletop	小球	桌面、斜坡	[X]	[0.4–0.7]	[X]	–	v, e_{dyn}
滑块捕获	t4_slider	滑块	桌面、斜坡	[X]	[0.4–0.8]	[X]	–	v, e_{dyn}
罐体捕获	t4_can	罐体	桌面、斜坡	[X]	[0.4–0.7]	[X]	–	v, $r\theta$, e_{dyn}
撞击后抓取	t5_replan	零件	撞击器	[X]	0.12–0.14	[X]	[X]	v, $r\theta$, e_{dyn}, m, delay

实时协议。 除非另行说明，推理期间物理仿真按每次查询从该方法在一块 RTX 5090 上实测的延迟分布中采样的延迟推进（附录 D.4）。撞击后抓取任务本身还内置 50 ms 的指令延迟。表 S14 报告三种替代协议。在*暂停*协议下，执行器不变，仿真等待推理完成；人为加入的附加延迟仍推进物理。在*等延迟*协议下，无论自身速度如何，每个方法都被计入相同的延迟，即 SE(3)-WAM 的 p95。在*原执行器*协议下，每个基线保留其论文中的执行方案。

延迟。 在协议本身的延迟之外，推理后再插入 0、50、100、150 或 200 ms 的附加延迟，期间物理仿真继续推进。

位姿噪声。 冻结权重，新增三个合成条件：标称时序相关位姿噪声、双倍幅度，以及标称噪声加连续观测缺失。扰动在缓存与运动学计算之前作用于当前及历史估计，复用实时协议的无噪声结果作为参考（附录 F.2）。这些条件未按真实跟踪器标定；真实标定与跟踪闭环评测尚待完成。

C.4 数据划分与统计

我们在开发场景上选择最终配置。Dynamic-14 主要比较与最终模型消融使用独立的 1,400 个留出场景；它们以相同的取值范围生成，使用不出现在任何训练、验证或开发回合中的新源种子。按种子递增顺序的前 100 个可行场景构成每个任务的集合。附录 F 中的筛选结果保留其原始划分与执行协议。

完整模型、CV 输入变体与表 3 中的核心消融均安排训练种子 0、1 与 2。筛选研究保留各自记录的种子数。基线使用单个训练种子（表 S7）。在开发集场景上，同一配置的三个训练种子在 SR 上最多相差 [7.4] 个百分点。这一差异主要来自导线穿越任务，其成功率在不同种子之间从 [0] 到 [71]% 不等，因此我们不解读几个百分点的单种子差异。我们报告每个训练种子的结果、跨种子均值与标准差。同时先在每个场景上对种子取平均，再在每个任务内对留出场景做 bootstrap（各方法联合重采样），得到配对 95% 区间。这些区间量化给定已训练权重后的场景不确定性，训练种子波动另行报告。区间落在 ±2 个百分点以内的差异视为持平。

表 S6. 场景的提议采样范围。除另有说明外，长度、线速度、角度和角速度的单位分别为 m、m/s、rad 和 rad/s。除注明的斜坡局部偏移外，位置均采用世界坐标。可行性检查前，连续区间内均匀采样，离散选项等概率采样。评测重放已存储的接受场景，其分布未必仍为均匀分布。谐波运动中心不等于初始位置。

任务	初态提议范围	运动或事件参数
grasp	谐波运动中心 $c_x \in [-.08, .08]$、$c_y \in [-.26, -.19]$、$z = .822$；偏航角 $[-1.1, 1.1]$。	$v_y \in [.025, .125]$, $A_x \in [.015, .035]$, $f_x \in [.3, .7]$ Hz; $\omega_z \in [-1.2, 1.2]$.
t1_belt	目标 $x \in [-.08, .08]$、$y \in [-.26, -.18]$、$z = .822$；姿态为单位旋转，初始 twist 为零。	传送带 $v_y \in [.04, .10]$。
t1_occ	目标提议范围同传送带任务；遮挡罩位于 $(.322, -.29, 1.20)$。	传送带速度范围相同；间隙参数为.20；实体遮挡。
t1_xyz	谐波运动中心 $c_x \in [-.025, .025]$、$c_y \in [-.24, -.20]$、$z = .818$；偏航角 $[-.35, .35]$。	$v_y \in [.04, .09]$, $A_x \in [0, .03]$, $f_x \in [.25, .65]$ Hz; $\omega_z = 0$.
t1_so3	同 XYZ。	平移相同；$\omega_z \in [-1.2, -.4] \cup [.4, 1.2]$，正负等概率。
t2_trans	目标容器 $x \in [-.13, -.08]$、$y \in [-.18, -.12]$、$z = .825$；姿态固定。	目标容器 $v_y \in [.03, .06]$；无旋转。
t2_se3	目标容器的 x, y 范围相同，$z = .804$；偏航角 $[-.3, .3]$。	目标容器 $v_y \in [.03, .06]$；$\omega_z \in [-.25, -.08] \cup [.08, .25]$，正负等概率。
t3_phase	杆的位置 $x, y \in [-.03, .03]$、$z = .870$，偏航角 $[0, 2\pi]$；导线相位 $[-.25, .35]$。	导线中心 $(.10, -.02, .94)$；绕世界 X 轴旋转，$\omega_x = -\{2.5, 3, \ldots, 7.5\}°$/s（11 个等概率取值）。
t3_full	杆位于 $(-.05, -.02, 1.04)$，姿态为单位旋转；导线相位范围相同。	导线旋转相同；启用托架及释放要求。
t4_sphere	斜坡局部偏移：横向 $[-.015, .015]$，纵向 / 法向 $(-.145, .030)$；坡沿 $(.06, -.02, 1.10)$。	从静止开始由重力驱动；在 tick 0 释放闸门；坡度 $[5, 15]°$；目标 / 斜坡滑动摩擦系数 $[.7, .9]$；无支撑捕获。
t4_sphere_tabletop	横向 $[-.015, .015]$，纵向 / 法向 $(-.124, .034)$；坡沿 $(0, -.06, .808)$。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.7, .9]$，桌面摩擦系数.35。
t4_slider	横向 $[-.015, .015]$，纵向 / 法向 $(-.129, .024)$；受支撑斜坡。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.025, .045]$，桌面摩擦系数 $[.012, .018]$。
t4_can	横向 $[-.010, .010]$，相对斜坡轴线的偏航角 $[-4, 4]°$；纵向位置由闸门几何及罐体在该姿态下的包围范围确定。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.25, .45]$，桌面摩擦系数 $[.09, .15]$。
t5_replan	$x \in [-.005, .005]$、$y = -.29$、$z = .812$；偏航角 $[-.08, .08]$；初始 twist 为零。	传送带 $v_y \in [.12, .14]$；在 $y = -.13$ 处等概率触发左 / 右撞击器；行程.098，脉冲.35 s，执行器缩放系数 $[1, 1.1]$，力上限 4 N；指令延迟 50 ms。

C.5 评测指标

按任务等权的成功率为

$$\mathrm{SR}(m) = \frac{1}{14} \sum_{k=1}^{14} \frac{1}{n_k} \sum_{i=1}^{n_k} y_{mki}, \tag{S3}$$

其中 y_{mki} 是方法 m 在任务 k 的场景 i 上的二值结果。一个场景的可行接触时间窗是特权专家能够完成任务第一个成功阶段所需接触的控制周期边界 t 的集合。时刻 t 属于该时间窗的条件是：专家在目标上的接触坐标系在 t 时刻（取自机器人保持初始位姿时同一场景的一次回放）(i) 满足该阶段的几何条

件（表 S4），(ii) 在专家的关节限位内有逆运动学解，且 (iii) 末端在专家的单条指令限位（每个平移轴 0.05 m、每个旋转向量分量 0.5 rad）下能从初始位姿在 t 之前到达。最早到达时刻取 $\lceil \max_i |\Delta p_i|/0.05\,\mathrm{m} \rceil$ 与 $\lceil \max_i |\Delta \phi_i|/0.5\,\mathrm{rad} \rceil$ 两者中较大的控制周期数；这是忽略控制器跟踪滞后的下界。该离线固定机器人参考回放仅禁用机器人与目标之间的碰撞；目标与环境之间的碰撞保持启用，策略评测回合的物理设置保持不变。该时间窗只取决于场景，对所有方法相同。两个放置任务开始时物体已被抓住，因此其接触是所持物体与目标容器的首次接触，接触坐标系是专家放置目标所对应的末端位姿。仅含相位阶段的穿越任务（`t3_phase`）开始时同样已持杆，且成功不需要任何接触，因此没有接触误差；这两项误差的平均覆盖其余 13 个任务，SR 覆盖全部 14 个任务。*接触时刻误差*是首次接触时刻到该时间窗的距离，在时间窗内为零。*首次接触时的位置误差*是该时刻末端到接触坐标系的距离。两者都只在发生接触的回合上报告；没有接触的失败仍计入 SR 的分母，其接触误差记为缺失而不是零。*碰撞*统计安全事件。*出动作时间*是从观测到达到第一条指令可用的墙钟时间（附录 D.4），*动作时龄*是执行时刻减去采集时刻。

D 基线、外部基准、真机与计时

D.1 基线

共同条件。 表 S7 汇总各基线的适配。每个基线保留其官方架构、输入、动作块与初始化。ACT 与 Diffusion Policy 从头训练，$\pi_{0.5}$ 从 `pi05_base` 微调，其余方法从其发布的权重出发。它们都在相同的 11,200 条示范上训练，示范中的指令通过同一个笛卡尔控制器映射到各自的动作空间。Dynamic-14 除主视角外还渲染 224×224 的腕部相机，配方使用腕部视角的方法会获得该图像。SE(3)-WAM 与其匀速输入变体只使用主视角。所有方法都在附录 C.3 的共享执行器与实时协议下运行，表 S14 另外给出它们原来的执行方式。

训练。 每个基线按官方配方训练到原论文的更新次数，只训练一次，种子为 0。我们只改动了数据读取与动作空间。对 DreamVLA，我们同时运行了其原始的 40 轮调度与 20 轮余弦调度，并报告在开发场景上更好的一个。相比之下，SE(3)-WAM 的配置由附录 F 的消融研究选出，这是基线所没有的搜索；完整模型、CV 输入变体与最终模型的核心对照均安排三个训练种子，筛选研究保留各组实际种子数。

输入。 PUMA [19] 接收在渲染帧上计算的历史光流。DreamVLA 接收七帧因果 RGB、末端执行器位置与朝向、手指位置和固定的任务文本，用十步 DDIM 和 1.5 的无分类器引导采样。OpenWAM-α 接收当前 RGB 视图、关节值、夹爪开度与任务文本，联合生成视频与动作，但不解码视频。DynamicWAM 接收其光流历史与运动学描述。

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.1 的八个目标状态 token，带有相同的有效标志，没有有效特征的槽位同样被掩码排除。一个两层 MLP 把这些 token 映射到模型宽度。对 $\pi_{0.5}$，我们把它们附加在前缀中的图像 token 之后，动作专家会读取它们；对 DynamicWAM，它们并入其运动学描述。MLP 的输出层零初始化，训练沿用基础模型的配方。这使新增嵌入的初值为零，但不保证注意力或动作保持不变。这些对照匹配了目标状态输入，深度输入的差异仍然存在。

匀速输入对照。 *SE(3)-WAM，匀速输入*与 SE(3)-WAM 共享场景 token 和动作流，但没有预测损失；其动作流接收目标位姿在动作块各预计执行时刻的匀速外推作为输入 token。外推只使用查询时已知的

表 S7. **基线适配**。所有方法均在相同的 11,200 条示范上、以其原论文的输入训练，并在附录 C.3 的共享执行器下运行。更新数 × batch 沿用官方训练配方。Exec.：原论文的执行方式（重规划前每个动作块执行的指令数），仅用于表 S14 的原执行方式对照。参数量：可训练参数，不含冻结的编码器。Seeds：计划训练种子数；填入结果前核验训练完成。

方法	初始化	输入	更新数 × batch	执行	参数量	种子
ACT [98]	从头训练	主视角 + 腕部 RGB、机器人状态	50,000 × 32	时间聚合	[X]	1
Diffusion Policy [16]	从头训练	主视角 + 腕部 RGB（原论文观测长度）、机器人状态	50,000 × 32	8	[X]	1
$\pi_{0.5}$ [56]	`pi05_base`	当前主视角 + 腕部 RGB、机器人状态、任务文本	30,000 × 256	10	[X]	1
$\pi_{0.5}$ + SE(3)	`pi05_base`	同 $\pi_{0.5}$ + SE(3) 运动 token	30,000 × 256	10	[X]	1
DynamicVLA [81]	发布的 DOM 检查点	帧 $[-2, 0]$、机器人状态、任务文本	50,000 × 44	流式	[X]	1
PUMA [19]	官方检查点	RGB、光流历史、机器人状态、任务文本	[X]×[X]	[X]	[X]	1
DreamVLA [94]	发布的组件	七个因果主视角 + 腕部 RGB 帧、机器人状态、任务文本	48,220 × 512	1	[X]	1
OpenWAM-α [75]	官方基础模型	当前主视角 + 腕部 RGB、关节、夹爪、任务文本	34,490 × 192	32	[X]	1
DynamicWAM [49]	官方初始化	RGB、光流历史、运动学描述	40,000 × 128	16	[X]	1
DynamicWAM + SE(3)	官方初始化	同 DynamicWAM + SE(3) 运动 token	40,000 × 128	16	[X]	1
SE(3)-WAM，匀速外推输入	同 SE(3)-WAM	同 SE(3)-WAM，另加匀速外推 token，无预测损失	同 SE(3)-WAM	–	[X]	3
SE(3)-WAM	冻结的 MAE 编码器	当前主视角 RGB-D、SE(3) 与机器人历史	51,740 × 512	1	523.8M	3

表 S8. **DOMINO 外部评测**。计划在 24 个单臂 clean-L1 任务上比较：每方法一个训练种子，每任务每方法 50 场，共 4,800 场。SR（%）按交互类型分组并报告任务平均值；MS 为操作得分。协议见附录 D.2。

方法	拦截	跟踪	全部	MS
$\pi_{0.5}$	—	—	—	—
DynamicWAM	—	—	—	—
PUMA	—	—	—	—
SE(3)-WAM	—	—	—	—

历史和延迟估计，不读取未来位姿或该次查询实际发生的延迟。训练使用相同数据和配方，保留当前目标 RGB 重建。表 3 的无未来监督对照没有外推输入 token。这些比较共同区分新增轨迹输入与未来监督的贡献；匀速输入模型是一项单独训练的策略。

D.2 DOMINO

外部比较采用 DOMINO [19]，只包含四种方法：SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA。它们共享所选 Franka 单臂任务、示范与评测场景，使用基准自带的评测器。计划比较已备的 24 个 clean-L1 任务，每方法一个训练种子（0），每任务每方法 50 场，共 4,800 场。我们报告 SR 与操作得分（MS）。正式训练前核对任务清单、动作语义与控制时序；测试场景与接口调试、模型选择所用场景分离。[补充已验证的 DOMINO 协议与结果。]SE(3)-WAM 使用该领域的归一化，并从仿真器读取指令所指定目标的位姿；缺失目标状态槽位按附录 A.1 的方式掩码。这一特权输入与基于 RGB 的基线分开说明。DOMINO 比较不增加组件消融、位姿噪声条件或额外延迟扫描。

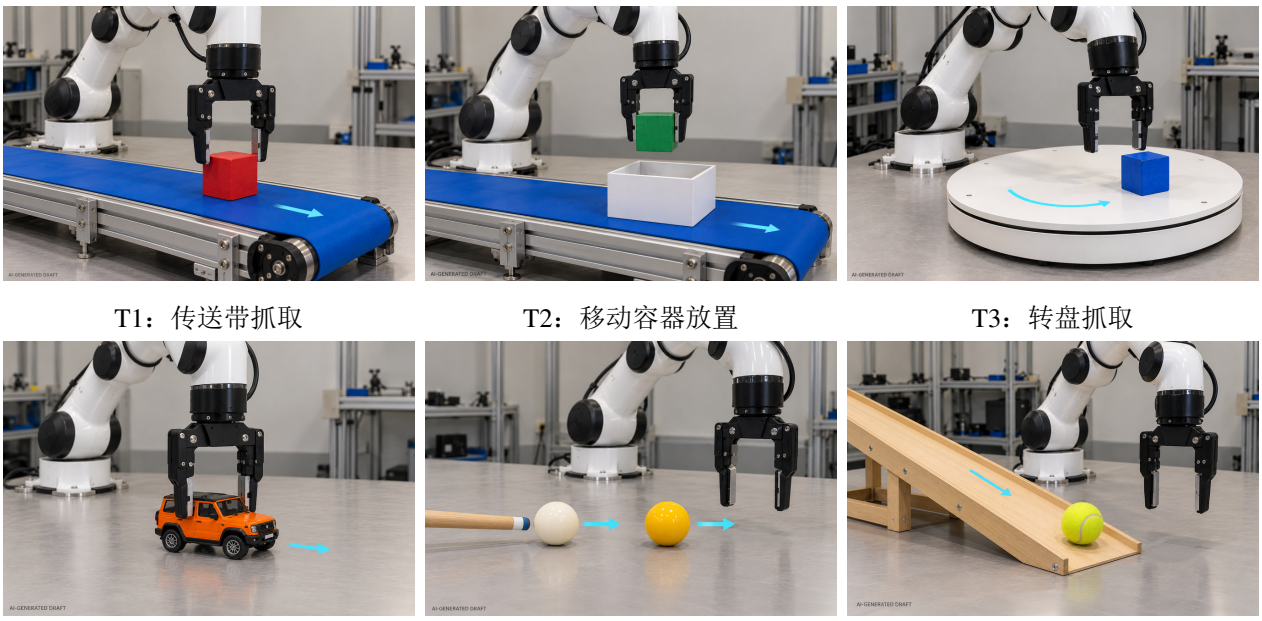


图 S4. **真机任务。**AI 生成的概念示意图，将替换为实验装置照片；箭头表示目标的预期运动。T6 图示滚动变体，该任务也包括滑动物体。

表 S9. 真机任务定义。$N = 100$：每个任务的训练示范数；每个任务另留 20 条示范用于验证。

任务	装置、运动与物体	运行范围；N	成功与失败条件
T1	传送带运输可抓取的方块。	[带速]；100	[稳定抓取并抬升；失败条件]
T2	传送带运输无盖盒，机械臂将方块放入其中。	[带速]；100	[放入并留存；失败条件]
T3	转盘携带方块绕轴运动。	[角速度、半径]；100	[稳定抓取并抬升；失败条件]
T4	遥控玩具小车在桌面上运动。	[速度、路径]；100	[抓取并抬起小车；失败条件]
T5	球杆驱动的球撞击第二个球，机械臂在碰撞后拦截第二个球。	[碰撞与碰后速度]；100	[碰后捕获；失败条件]
T6	球沿斜坡滚落或方块沿斜坡滑落，朝拦截区域运动。	[坡度、释放、速度]；100	[捕获并保持；失败条件]

D.3 真机

平台。 机器人为 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机，通过 [带时间戳的笛卡尔接口] 以 [控制频率] 控制。相机以 [分辨率] 与 [帧率] 录制 RGB-D，每次采集前用 [标定方法] 标定其外参。SE(3)-WAM 使用这一固定的第三人称视角；配方需要腕部视角的基线获得 [逐方法相机配置]。所有策略都在一块 RTX 5090 上运行。

任务与成功判定。 表 S9 定义六个任务。T1 与 T2 共用一条传送带，T3 使用转盘，T4 使用遥控玩具小车，T5 使用球杆驱动的两球碰撞，T6 使用斜坡。每个任务有各自的运行范围与成功条件。触碰或推动目标而未完成任务、单指夹持，以及目标离开工作空间之后的动作，都算作失败；[设备无效试验与安全干预按以下规则重做或计为失败]。

试验。 我们比较 SE(3)-WAM 、$\pi_{0.5}$、DynamicWAM 与 Diffusion Policy [16]。每个方法在每个任务上运行 20 次试验。所有方法使用相同的预生成试验键，试验键确定物体实例、初始位姿与运动参数，按 [采样协议] 采样。试验按 [随机化的方法顺序] 进行，使装置的漂移不会与方法对齐。操作员重置场景。试验从第一个可用观测开始，机器人随时可以运动；试验在成功、失败或 [X] s 超时时结束。示范、开

表 S10. **真机成功次数**，按任务分列（成功次数/试验数，每个任务 20 次；任务定义见表 S9）。All：合并成功率（%）及 95% 二项区间。Δ：相对 SE(3)-WAM 的配对差值（百分点）及按试验键自助法得到的区间。

方法	T1	T2	T3	T4	T5	T6	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	–

表 S11. **单次查询的延迟分解**（SE(3)-WAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
图像编码	—	—
世界流（每次查询一次）	—	—
动作流（5 个 Euler 步）	—	—
出动作时间（合计）	—	—
预测头（仅训练，供参考）	—	—
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

发试验与测试试验来自不同的采集批次，测试初始条件在同一任务协议下独立采样。

训练与适配。 SE(3)-WAM 从 DROID 基座出发逐任务微调（附录 B.5）。基线在相同示范上训练或微调，采用 [各方法的初始化与训练设置]。无标记跟踪器与离线标签共享一个固定物体参考（附录 A.2）；[注明所选参考采集与配准设置]。

分析。 表 S10 报告每个任务的成功次数、合并成功率的 95% 二项区间，以及按试验键自助法得到的配对差值。评测共用了 [X] 天。

D.4 计时

我们在一块 RTX 5090（32 GB，即机器人的目标部署 GPU）上为所有方法计时。每个方法测量三轮，每轮先预热三十次调用，再在三段各八帧的观测序列上测量 300 次调用；调用边界处做 CUDA 同步，逐轮轮换方法顺序。每个方法使用其发布版本的精度，SE(3)-WAM 使用 FP32。出动作时间包括图像编码与生成第一条指令，在真机上还包括跟踪最新一帧。对 SE(3)-WAM，我们另外记录预测头的耗时，尽管部署时跳过它们。表 1 给出 p95 值，表 S7 给出参数量。在真机上，日志记录采集、可用、预处理、推理开始与结束、进入队列、指令下发与执行等时刻。动作年龄为执行时刻减去采集时刻，我们报告其 p50、p95 与最大值。若一次查询的出动作时间严格超过 50 ms 的控制周期，下一个周期使用剩余指令；若没有剩余指令，则保持当前目标。超时比例的分母包含全部查询，包括每次试验的首次查询；仅保持目标的周期不计入动作年龄。我们还报告峰值显存（表 S11）。Dynamic-14 的延迟扫描与实际部署不同：它在物理仿真继续推进的同时插入规定的延迟。

表 S12. **Dynamic-14 各任务的留出成功率**（%），涵盖表 1 中的全部方法，本文各变体取三个训练种子的平均、基线训练一次，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。DrVLA：DreamVLA。OWAM：OpenWAM-α。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。CV：匀速外推输入的 SE(3)-WAM 。σ：使用标称合成时序相关位姿噪声的 SE(3)-WAM ，仅复用已批准鲁棒性设置的轨迹。Δ：该任务上 SE(3)-WAM 相对最强其他方法之差及其 95% 配对区间。任务代号见表 S5。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	DrVLA	OWAM	DWAM	DWAM+	CV	σ	本文	Δ [95% CI]
谐波抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
传送带抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
平移抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
遮挡抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
移动容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越（完整）	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获（桌面）	—	—	—	—	—	—	—	—	—	—	—	—	—	—
滑块捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—
罐体捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—
撞击后抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—
任务等权	—	—	—	—	—	—	—	—	—	—	—	—	—	—

E 补充结果

E.1 逐任务结果与回合结局

表 S12 把表 1 中 Dynamic-14 的留出结果按任务拆分到每个方法，并给出 SE(3)-WAM 在每个任务上相对最强其他方法的配对区间。表 S13 报告回合如何结束。一个方法若以一种失败换另一种失败，例如以更少的碰撞换来更多的超时，只能在这里看出来。所有失败都留在成功率的分母中。

E.2 协议与延迟

表 S14 在另外三种协议下评估每个方法。暂停物理仿真去除了计算的代价。等延迟协议向每个方法计入 SE(3)-WAM 的 p95 延迟，从而把方法的速度与其利用时间的方式区分开。原执行器协议检验我们的共享执行器是否使某个方法处于不利地位。在暂停物理仿真时，SE(3)-WAM 与 [DreamVLA] 的差距为 [±X.X] 个百分点，在等延迟下为 [±X.X] 个百分点。原执行器使各基线的 SR 至多变化 [X.X] 个百分点。表 S15 给出扫描中每个附加延迟下的成功率，其中 SE(3)-WAM 与最强基线的两行即图 1（右）的数据。

E.3 负面与无差异结果

筛选结果。 历史、预测目标、编码器与耦合比较采用附录 F 的筛选配方。每项结果必须同时注明其原始划分与种子数。Q3 的耦合效应在种子之间变号，不能证明最终规模下训练监督与在线预测反馈等效。新的四对照研究在表 3 中报告带符号差值与配对区间。[按实际规模概括已完成的零效应与负面效应。]

表 S17 与 S20 按原始规模报告已完成的历史与预测筛选结果。表 S18 报告冻结筛选权重上的静止历史干预；它不是最终规模的训练消融。

表 S13. **结局类别**：Dynamic-14 留出场景（各类 episode 占比，%，种子平均，实时协议）。类别定义见附录 C.1；每行合计为 100。含噪位姿行复用鲁棒性实验中标称合成时序相关噪声的轨迹。

方法	成功	安全	任务违规	边界	超时	无效
ACT	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—
SE(3)-WAM，含噪位姿	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—

表 S14. **评测协议对照**：Dynamic-14 留出场景（SR，%）。暂停：共享执行器，推理期间物理暂停。等延迟：共享执行器，所有方法均计入 SE(3)-WAM 的 p95 延迟。原执行方式：实时协议下使用各方法自身的执行方式。实时：表 1 的协议。超时：实时协议下出动作时间超过 50 ms 控制周期的查询比例（%）。

方法	暂停	等延迟	原执行执行器	实时	超时 (%)
ACT	—	—	—	—	—
Diffusion Policy	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—
DynamicVLA	—	—	—	—	—
PUMA	—	—	—	—	—
DreamVLA	—	—	—	—	—
OpenWAM-α	—	—	—	—	—
DynamicWAM	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	–	—	—
SE(3)-WAM	—	—	–	—	—

未解决的任务。 放入旋转料箱的 SE(3) 放置任务（t2_se3）对所有方法都失败（表 S12）。[策略能到达料箱，但在它转开之前达不到其角度容差。]SE(3)-WAM 的任何变体都没有解决完整的导线穿越任务（t3_full），该任务在穿越之外还要求抓取与释放棒，而 [OpenWAM-α] 在其中 [XX]% 的回合中成功。在以已抓住棒开始的穿越任务（t3_phase）上，SE(3)-WAM 的成功率在不同训练种子之间从 [0] 到 [71]% 不等。

其他失败。 图 S6a 中的曲线聚合在捕获任务上最弱（Spearman $\rho = [X.XX]$），因为这些任务的成功还取决于夹爪何时合拢。三个合成噪声条件使 SR 变化 [报告相对无噪声参考的三个带符号差值]；这些结果与真实跟踪器标定分开。SE(3)-WAM 的其余失败大多是 [例如首次抓取失手后的超时]（表 S13）。

E.4 执行时刻的预测

图 S5 把查询、预测、真值、发出的动作与首次接触按物理时间戳对齐。这些示例展示预测误差出现的位置，例如撞击的瞬间或滚动物体离开斜坡时，并同时给出接触时刻与位姿误差。这些对齐的诊

表 S15. **成功率随附加延迟的变化**：Dynamic-14 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的 All 与 +150 ms 列。斜率：SR 对附加延迟的最小二乘斜率（每 100 ms 的百分点）。

	附加延迟（ms）					
方法	0	50	100	150	200	斜率
ACT	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—

图占位：图 S5——与实际发生对齐的预测

第 1–4 行：每种运动类型（传送带、旋转目标、滚动捕获、撞击后）预测误差居中的留出回合；**第 5 行**：一次失败。**列**：τ_t 处的查询帧；首条指令执行时刻 τ^{a} 处的帧；基座坐标系中的 3D 插图。**叠加**：蓝色过去的 SE(3) 位姿；橙色 $\tau_t + \delta_h$ 处预测的目标坐标轴与稀疏流箭头（读自训练期预测头）；灰色同一物理时刻的真值位姿；紫色发出的夹爪轨迹；首次接触处的标记。每行下方的条带画出学习的 SE(3)、匀速与匀加速预测的平移与旋转误差随时域的变化。用红色标注第 5 行的失败原因。

图 S5. 训练期预测头在留出回合上的预测，在物理时间上与真值和发出的动作对齐。第 1–4 行为每种运动类型预测误差居中的回合，第 5 行为一次失败。

断不证明部署的动作流读取了解码预测，也不证明某个预测误差导致了某次动作误差。

E.5 补充视频

补充视频展示 SE(3)-WAM 与最强基线在全部六个真机任务上的试验（叠加跟踪位姿）、每个任务族的一组 Dynamic-14 回合（叠加训练期预测头的预测），以及第 4.3 节讨论的失败案例。

F 核心消融与筛选研究

最终规模确认。 表 3 包含最终 24 层模型的四个独立训练对照，每个对照训练三个种子。最终数据、初始化配方、训练曝光量与其他组件保持不变（附录 A.6）。评测在 1,400 个留出场景上采用实时协议，附加延迟为 0 与 150 ms，共享场景键与推理种子。完整模型的参考结果复用主评测。四个对照为：

- **无目标历史**：保留当前图像、当前目标位姿与八个机器人状态；移除过去的目标位姿及其速度、加速度特征。
- **无未来监督**：关闭 SE(3)、场景流与可见性、未来深度、DINO 及动态 RGB 损失；保留当前目标 RGB

表 S16. **观测编码器筛选格式。**4 层研究保留各来源组的配方与种子数（附录 F.1）；MAE 参考有三个种子。空格为未填写测量，不承诺最终规模重训。参数量为编码器参数；p95 为出动作时间。

编码器	参数	训练	SR	SR_{150}	p95
CNN	—	是	—	—	—
DINOv3 ViT-S/16	22M	冻结	—	—	—
DINOv3 ViT-L/16	300M	冻结	—	—	—
MAE ViT-B/16*	86M	冻结	—	—	—

重建与动作损失。

- **无场景流监督：**只关闭场景流与可见性损失；保留专用 SE(3) 和全部外观目标。
- **无专用 SE(3)：**只关闭目标位姿预测损失；保留全部外观目标和覆盖目标、机器人及周围环境的原有 14^2 场景流查询。

最后一个对照为目标分配与其余场景相同的粗粒度流表示，不新增目标轨迹头。场景流包含目标与机器人，因此移除它不能隔离环境信息。结果待完成：[四个对照及其配对区间完成后，再给出最终规模的结论]。

筛选范围。 更广泛的研究使用宽度 768 的 4 层模型，训练 4 轮，通常为全局 batch 16 下的 40,104 次更新。HISTORY1 使用冻结的 DINO-L 编码器和一个训练种子，首轮采用余弦日程，随后保持低学习率。FUTURE0 的深度、宽度相同，也使用一个种子，但余弦日程覆盖全部四轮。Q3-INFO0 使用 MAE，R0–R5 各训练三个种子；BACKBONE0 的两种主干各训练三个种子。AUX0 新增的外观条件使用一个种子。这些组不能合成最终模型下的一套匹配比较。开发集结果用于设计选择，引用时保留其原始划分与配方。保留的筛选表描述原始规模下已完成的条件，不在核心确认之外增加 24 层训练条件。

F.1 共享组件

编码器与主干比较属于筛选规模。它们按各自配方与种子数比较联合训练的 CNN、冻结的 DINOv3 ViT-S/16 与 ViT-L/16 [63]、MAE ViT-B/16 [26]。MAE 参考和 BACKBONE0 比较有三个种子，不能据此把全部编码器或辅助目标条件写成三种子研究。最终模型使用 MAE，DINO-L 仍作为未来特征目标。表 S16 保留筛选比较的格式。

F.2 历史

HISTORY1 筛选了当前状态输入、目标运动历史、RGB 窗口、Farnebäck 光流 [20]、带运动统计的光流 [49]、编解码器运动向量、视频 VAE 隐变量与压缩窗口。其九个已训练条件各使用一个种子。表 S17 报告这九个已完成条件。核心确认只在最终规模重复无目标历史对照。

静止历史干预。 表 S18 中已完成的干预使用冻结的 4 层 HISTORY1 权重、一个训练种子与原同步执行器。它在重新计算运动学之前，用当前位姿替换过去的目标位姿；当前位姿、图像、机器人状态、时间戳与有效性均保留。真实历史的结果复用原评测。该干预改变了输入分布，不能代替单独训练的最终规模无历史对照。

位姿噪声。 独立的鲁棒性评测冻结模型并复用实时协议下的无噪声参考，新增三个条件：标称合成时序相关位姿噪声、双倍幅度，以及标称噪声加连续观测缺失。扰动在历史缓存与运动学计算之前作

表 S17. **历史筛选。**4 层、宽 768、冻结 DINO-L、一个训练种子，按原同步协议评测 1,400 个场景。前八项接收当前目标位姿，最后一项另加目标运动历史。这些不是最终规模的实时结果。

历史输入	成功数 / 1,400	SR (%)
当前图像	748	53.43
RGB 窗口	662	47.29
光流	720	51.43
光流＋运动统计	723	51.64
编码器运动向量	733	52.36
视频 VAE 隐变量	710	50.71
压缩窗口（按时间）	634	45.29
压缩窗口（均匀）	670	47.86
当前图像＋目标运动历史	824	58.86

表 S18. **静止历史干预。**使用同一个冻结的 4 层 HISTORY1 检查点、训练种子 0 及其原同步协议。将过去目标位姿替换为当前位姿，再重算运动学；真实历史结果直接复用。这 1,400 个原场景与最终实时确认实验分开报告。

目标历史	成功数 / 1,400	SR (%)
真实历史	824	58.86
静止历史替换	9	0.64

用于当前及历史估计。真实跟踪器误差标定与跟踪闭环尚待完成（表 S1）。这三个条件的评测不要求只扰动历史的噪声交叉曲线，也不增加视觉历史训练。标称过程由每回合固定偏置与平稳相关分量组成，两者的平移和旋转逐轴标准差分别均为 5 mm 与 1°。相关时间为 200 ms，采样间隔为 50 ms；双倍条件同时放大两种分量。每段缺失持续四个 tick（200 ms），有效间隔服从均值为 76 个 tick 的几何分布，对应长期 5% 的缺失比例。参数在评测前确定。最终模型的三个训练种子在相同配对场景、零附加延迟下评测；三个噪声条件不等于三个训练种子。

F.3 预测目标

FUTURE0 用每个条件一个种子筛选了十五种目标配置。表 S19 定义这些表示，表 S20 报告已完成条件。P09 使用目标 2D 轨迹，与最终规模的统一 3D 流对照不同。表中还报告 AUX0 的四个 MAE 外观目标条件及其已有的全目标参考，均使用种子 1。它们与 FUTURE0 的编码器和配方不同，成绩在各自组内比较。这些结果不能与 Q3 的三种子耦合结果合并，也不能作为最终规模下几何优于外观的证据。

角色覆盖。 核心无 SE(3) 对照保留原有 14^2 场景流，无流对照保留 SE(3) 与全部外观目标。由于场景流覆盖目标、机器人与环境，后一个对照检验的是整体场景流监督。本研究不主张粗网格与更密网格等效。

外推与预测误差。 由因果位姿历史得到的匀速、匀加速估计，可以在日志中的执行时刻与学习的预测做离线比较。表 S21 在相同留出观测上、固定 400 ms 时域处比较它们的位置误差。匀速与匀加速估计只使用因果位姿历史，学习的预测头读取冻结完整模型的状态。这些是离线预测诊断，不增加控制器或训练条件，也不说明部署策略读取了解码后的预测。单独训练的匀速输入策略仍保留在表 1 中；不增加其他匀速 / 匀加速输入训练组合。

表 S19. 已完成筛选条件的未来目标定义。张量形状不含 batch 和 query 轴。除保留解码器自身对应关系的 codec 向量外，位移均从当前状态累计。所有监督目标均来自记录的演示。未来深度、DINO 与动态 RGB 同时也是选定模型仅在训练中使用的辅助目标。

目标	形状	几何支持、单位与有效条件
目标位姿	8×6	累计平移 (m) 和左相对旋转向量 (rad)；位姿和 query 有效。
场景流，14×14 网格	$196 \times 8 \times 3$	固定源点网格；基座坐标系中的累计米制位移；源深度有效且未来位移有限。
目标轨迹（二维）	$32 \times 8 \times 3$	目标掩码内的源点；两个图像位移通道与可见性；填充点无效。这是 P09 的目标，不是三维刚体位姿拟合。
物体 DINO	8×1024	按掩码面积加权汇聚未来 patch 特征；沿通道作层归一化；掩码面积为正。
场景轨迹（二维）	$196 \times 8 \times 3$	网格源点；两个图像位移通道除以 224，另加一个可见性 logit。
稠密二维位移	$8 \times 2 \times 224 \times 224$	固定源像素；位移除以 224；源像素有效且投影有限。
编码器运动向量	$8 \times 2 \times 64 \times 64$	每对未来 / 当前帧编码为 P/I 帧；向量除以 64；使用有效向量区域。
视频 VAE 隐变量	$48 \times 2 \times 14 \times 14$	冻结的 Wan2.2 VAE 后验均值及该 VAE 自身的归一化；两组分别截至 200 与 400 ms。
未来深度	$8 \times 1 \times 224 \times 224$	米制深度；像素值为有限正数。
未来 DINO	$8 \times 196 \times 1024$	冻结的 DINOv3 ViT-L/16 教师 [63]，14×14 个 patch，沿通道作层归一化。
动态 RGB	$8 \times 3 \times 224 \times 224$	在世界坐标中移动超过 1 mm 的可见表面（含机器人）上取 RGB 并除以 255。

F.4 预测的使用方式与主干

BACKBONE0 在约 47.3M 主干参数下比较共享注意力加分流前馈网络与世界/动作独立参数组，三个种子的结果属于这一 4 层设置。

Q3-INFO0 在同一筛选规模下为 R0–R5 各训练三个种子（附录 A.5）。其中 R1 包含与动作无连接的世界查询，而最终模型直接从摘要 token 读出，不含这些查询。因此 Q3 比较没有直接测量最终模型。耦合效应在种子之间变号，支持选择部署更简单的方案，但不能证明统计等效。R1 相对 R0 平均高 [3.14] 个百分点，各种子的差值为 [−1.29]、[+9.64] 和 [+1.07]。核心确认不在 24 层重复 R5 或其他耦合设计。

部署检查。 在最终权重上运行未使用的预测头，可以检查固定输入与流匹配噪声下的动作输出一致性，并测量额外计算。实时执行器在这段计算期间推进物理，所以固定输入下的输出相同不代表闭环成功率相同。不为 R2/R5 增加预测交换、时间偏移或真值输入矩阵。

表 S20. **已完成的预测筛选。**两组均为 4 层、宽 768、4 轮，按各自原同步协议评测。FUTURE0 使用冻结 DINO-L 及种子 0，140 个开发场景与不相交的 1,260 场补集分开报告。AUX0 使用冻结 MAE-B、种子 1 及原 1,400 个场景，保留场景流、SE(3) 和当前目标 RGB 重建；三辅助 MAE 参照直接复用。比较限于各自配方内部，不跨组排名。

编号	未来监督	开发集成功数 / 140	成功数 / 1,260	SR_{1260} (%)
P00	无	88	791	62.78
P01	三维场景流	95	782	62.06
P02	SE(3)	92	789	62.62
P03	场景流＋ SE(3)	93	786	62.38
P04	视频 VAE 隐变量＋ SE(3)	92	783	62.14
P05	稠密二维位移＋ SE(3)	87	746	59.21
P06	编码器运动向量＋ SE(3)	86	795	63.10
P07	稀疏场景二维轨迹＋ SE(3)	90	807	64.05
P08	场景流＋物体 DINO	89	794	63.02
P09	场景流＋目标二维轨迹	88	808	64.13
A_α	P03 ＋运动幅值	89	778	61.75
P12	P03 ＋深度	90	791	62.78
P13	P03 ＋ DINO	92	788	62.54
P14	P03 ＋动态 RGB	89	790	62.70
P15	P03 ＋深度 / DINO / 动态 RGB	94	802	63.65
AUX0 MAE-B：未来外观辅助		成功数 / 1,400		SR_{1400} (%)
无		894		63.86
仅深度		867		61.93
仅 DINO		946		67.57
仅动态 RGB		926		66.14
三者全部（已有参照）		995		71.07

表 S21. **离线预测误差。**在同一批留出观测上计算 400 ms 处的目标位置误差（mm）。CV 和 CA 是由因果位姿历史计算的解析外推；学习位姿头读取冻结完整模型的状态。这些诊断与表 1 中经过训练的匀速输入策略不同。

	匀速	谐波	滚动/滑动	撞击
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的位姿头	—	—	—	—

表 S22. **筛选规模的耦合比较。**Q3-INFO0 使用 4 层、宽度 768，每个条件三个种子。R1 含世界查询，与最终模型不同。SR 与 p95 保留来源评测协议和硬件；空格尚待填写。

耦合	SR 均值	SR 标准差	p95 (ms)
R0 （关闭未来损失）	—	—	—
R1 （查询，无连接）	—	—	—
R2 （世界 → 动作）	—	—	—
R3 （动作 → 世界）	—	—	—
R4 （双向）	—	—	—
R5 （解码几何）	—	—	—

G 延迟下行动的误差分析

本附录推导第 3.1 节的误差分解，把它推广到旋转、环境与分块执行，推导简单的比例关系，给出 Dynamic-14 中各项的量级，并说明其不适用的情形。这一分解促成了 SE(3)-WAM 的设计，它不是成功率的模型。

G.1 平移

设执行时刻目标的真实位置为 $\mathbf{p}(\tau^{\mathrm{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，策略的估计为 $\hat{\mathbf{p}}(\tau^{\mathrm{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。减去再加上 $\mathbf{v}\hat{\Delta}$ 得到恒等式

$$\begin{aligned}\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}}) = \big[\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\big] + (\hat{\mathbf{v}} - \mathbf{v})\hat{\Delta} \\ + \mathbf{v}(\hat{\Delta} - \Delta) + (\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}),\end{aligned} \tag{S4}$$

由三角不等式即得式 3。由于 $\mathbf{v}$ 是 τ_t 时的速度，$\boldsymbol{\rho}$ 恰好是匀速外推遗漏的那部分运动。在匀加速度 $\mathbf{a}$ 下，$\boldsymbol{\rho} = \frac{1}{2}\mathbf{a}\Delta^2$，从历史中估计的加速度可以消除 e_{dyn} 的一部分；撞击、滚动接触与摩擦变化留下的余项只有动力学模型才能减小。对于学习型预测器，其估计在 $\hat{\mathbf{v}}\hat{\Delta}$ 与 $\hat{\boldsymbol{\rho}}$ 之间的划分不可辨识，因为任何预测位置都可以写成这种形式。因此我们用这一分解说明每一项需要哪些信息。我们的实验不在学习型预测器内部分离各项，而是改变作用于已知项的领先时长、速度、位姿噪声与时间，并比较接收不同信息的变体（附录 G.5）。

G.2 旋转与接触点

我们写 $R(\tau^{\mathrm{a}}) = \mathrm{Exp}(\boldsymbol{\omega}\Delta + \boldsymbol{\eta})R(\tau_t)$ 与 $\hat{R}(\tau^{\mathrm{a}}) = \mathrm{Exp}(\hat{\boldsymbol{\omega}}\hat{\Delta} + \hat{\boldsymbol{\eta}})\hat{R}(\tau_t)$。当 R 与 $\hat{R}$ 绕同一固定轴旋转时，指数映射可以相加，于是

$$\theta = \big\|\,\mathrm{Log}(\hat{R}(\tau^{\mathrm{a}})R(\tau^{\mathrm{a}})^{\top})^{\vee}\big\| \le \theta_{\mathrm{loc}} + \hat{\Delta}\, e_{\omega} + \|\boldsymbol{\omega}\|\, e_{\tau} + e_{\eta}, \tag{S5}$$

其中 θ_{loc} 是当前朝向误差，e_{ω} 与 e_{η} 的定义与平移相同。对一般旋转，Baker–Campbell–Hausdorff 公式会带来角度的二阶项。物体坐标系中位于 $\mathbf{c}$、$\|\mathbf{c}\| = r$ 的接触点，其世界位置为 $\mathbf{p} + R\mathbf{c}$，因此误差为 $(\hat{\mathbf{p}} - \mathbf{p}) + (\hat{R}R^{\top} - I)R\mathbf{c}$。对转角为 θ 的旋转，$\hat{R}R^{\top} - I$ 的算子范数为 $2\sin(\theta/2)$，于是

$$e_{\mathrm{c}} \le \|\hat{\mathbf{p}} - \mathbf{p}\| + 2r\sin(\theta/2) \le \|\hat{\mathbf{p}} - \mathbf{p}\| + r\theta, \tag{S6}$$

这就是第 3.1 节中的接触误差界。因此朝向误差以力臂为比例进入接触几何，依赖朝向的抓取或放置需要 SE(3) 的目标状态。计划中的真机球类协议使用球心平移，从输入、旋转监督及旋转误差中排除目标旋转与角运动学分量（附录 A.2）。这一针对具体任务的选择不改变机器人旋转指令或仿真 SE(3) 状态，也不是一般性的对称处理结果。

G.3 环境与间隙

令 $\mathcal{P}$ 为执行路径经过的环境点与时刻的集合，并设路径使机器人与被携带物体上的每一点 $\mathbf{x}$ 与预测的环境位置 $\hat{\mathbf{y}}_t(\mathbf{z},\tau)$（$(\mathbf{z},\tau) \in \mathcal{P}$）至少相距 m。碰撞要求对某个 $(\mathbf{z},\tau) \in \mathcal{P}$ 有 $\mathbf{x} = \mathbf{y}_t(\mathbf{z},\tau)$，此时 $\|\hat{\mathbf{y}}_t(\mathbf{z},\tau) - \mathbf{y}_t(\mathbf{z},\tau)\| = \|\hat{\mathbf{y}}_t(\mathbf{z},\tau) - \mathbf{x}\| \ge m$，因此碰撞要求路径上某处的预测误差至少为 m。比 m 更细的环境精度因而对成功率没有一阶影响。这个界只关乎误差的大小，与采样无关。在网格上采样的流会漏掉比其间距更细的结构，并在运动边界处出错；这两种效应都进入路径误差 e_F，仅凭网格间距不能推断它。间隙本身也是一个设计变量：环境估计较粗时，策略可以保持更大的间隙，代价是可达性或时间。

图占位：图 S6——未补偿的运动与位姿噪声

(a) x：首个指令执行时刻的 $\|\mathbf{v}\|\Delta/\varepsilon$（对数）；y：SR。每个方法 × 任务族 × 延迟一个点，复用主延迟扫描；反应式策略（灰）附拟合的 logistic 曲线与 Spearman ρ，标出阈值 1；补偿运动的基线与 SE(3)-WAM（橙）。**(b)** x：无噪声参考、标称时序相关噪声、双倍幅度，以及标称噪声加连续观测缺失；y：SR。冻结权重并使用同一实时协议；配对区间来自匹配场景。

图 S6. **运动与位姿噪声诊断。**(a) 成功率与相对容差的未补偿运动之间的关系，比较反应式方法与补偿运动的方法。(b) 三个合成位姿噪声条件相对于无噪声参考的鲁棒性。

G.4 滚动重规划下的领先时长

在附录 C.3 的实时执行器下，第 t 次查询的总延迟 ℓ_t 包括附加延迟。其动作块在 $k_t\Delta_a$ 后被采用，其中 $k_t = \max(1, \lceil \ell_t/\Delta_a \rceil)$，下一次查询也在同一边界开始。设动作块长度为 $K = 8$，在被替换或耗尽之前，到达执行阶段的指令具有领先时长 $\Delta_{t,j} = (k_t + j)\Delta_a + d_{\text{task}}$，其中 $j = 0, \ldots, \min(K, k_{t+1}) - 1$。$d_{\text{task}}$ 是任务内置指令延迟：撞击后抓取为 50 ms，其他任务为零。耗尽后的保持阶段不增加新指令。当 $k_t = k_{t+1} = k \le 4$（总延迟不超过 200 ms）时，最大领先时长为 $(2k-1)\Delta_a + d_{\text{task}}$，包括任务延迟在内仍处于 400 ms 的预测时域内。总延迟更大时，最后几条指令可能在这一时域之外执行。完整模型的动作流不接收延迟，因此不会针对特定延迟调整指令。在首个满足条件的边界重新规划可使领先时长保持较短；延迟扫描衡量更长领先时长对成功率的影响。

G.5 比例关系

这一分解给出以下参考关系。图 S6 报告运动与合成噪声诊断。

临界领先时长。 不补偿运动的策略（$\hat{\mathbf{v}} = 0$，$\hat{\boldsymbol{\rho}} = 0$）在 e_{loc} 与 $\|\boldsymbol{\rho}\|$ 之外还要承受 $\|\mathbf{v}\|\Delta$。定位误差较小、运动平滑时，一旦 $\|\mathbf{v}\|\Delta > \varepsilon$，即超过临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$，其接触就会失败，其成功率只通过 $\|\mathbf{v}\|\Delta/\varepsilon$ 依赖于任务、速度与延迟。表 S5 列出每个任务的 ε、$\|\mathbf{v}\|$ 与 $\Delta^\star$。图 S6a 给出每个方法的成功率与 $\|\mathbf{v}\|\Delta/\varepsilon$ 的关系，后者在每个回合的首个指令执行时刻计算，并在已有任务与延迟条件上汇总；同时给出反应式策略的 Spearman 相关系数与拟合的 logistic 曲线。反应式策略 [落在同一条曲线上]（Spearman $\rho = [X.XX]$），其成功率在 [X.X] 处减半。这一分解只给出约为 1 的阈值，而不给出曲线的形状。捕获任务在曲线周围最分散，因为其成功还取决于夹爪何时合拢。

位姿噪声。 由跨度为 T 的 n 个等间隔位姿（每个轴上带独立噪声 σ）得到的最小二乘速度估计，其标准差为 $\sigma\sqrt{12(n-1)/(n(n+1))}/T \approx \sigma\sqrt{12/n}/T$ [5]。因此在噪声达到 $\sigma^\star = \varepsilon T\sqrt{n}/(\Delta\sqrt{12})$ 之前，位姿历史能使 $\hat{\Delta}e_v$ 保持在容差以下。取 $\varepsilon = 10$ mm、$T = 350$ ms、$n = 8$ 与 $\Delta = 200$ ms，得到 $\sigma^\star \approx 14$ mm。带运动先验的学习型估计器可以做得更好，因此 $\sigma^\star$ 是独立噪声下无模型线性估计对应的值。我们的鲁棒性评测采用三个合成条件：时序相关噪声、双倍幅度，以及标称噪声加连续观测缺失。它复用实时协议的无噪声参考，不估计噪声交叉点，也不声称已按真实跟踪器标定。

间隙。 在附录 G.3 的假设下，路径误差为 e_F 的环境预测在 $m > e_F$ 时避开碰撞。这是几何上的充分条件，不是粗、细流网格在实验中等效的结论。

G.6 Dynamic-14 中的量级

表 S23 在有代表性的 Dynamic-14 设置下（表 S6）计算各项的大小。每一项都与成功条件中毫米级的容差（表 S4）相当或更大。

表 S23. 领先时长为 200 ms 时式 3 各项的示意量级。数值由所述量推出，并非测量值。

项	设置	大小
$\|\mathbf{v}\|\Delta$	传送带 0.10 m/s	20 mm
$\hat{\Delta} e_v$	速度估计偏差 10%	2.8 mm
$\|\mathbf{v}\| e_\tau$	50 ms 时间误差（一个周期）	7.0 mm
$2r\sin(\theta/2)$	$\omega = 1.2$ rad/s 未被预测，$r = 3$ cm	7.2 mm
e_{dyn}	10° 斜坡上的球，无加速度模型	24 mm
ε	抓取传送带零件	[X] mm
网格间距	工作空间处的14 × 14 流	[X] mm

斜坡一项使用纯滚动实心球的加速度 $a = \frac{5}{7} g \sin\alpha \approx 1.2\,\text{m/s}^2$（$\alpha = 10°$），以及 $\Delta = 0.2$ s 时的 $\frac{1}{2} a \Delta^2$。

G.7 适用范围

这一分解针对的是接触前运动由外部决定的刚性目标的接近过程。它不涵盖可变形或铰接的目标，因为其在 $\mathcal{O}$ 上的运动场不由六个数决定。它也不涵盖接触后的运动，后者取决于动作本身，需要以动作为条件的预测，这正是让世界读取动作可能起作用的情形。目标角色随时间变化的场景（例如依次操作多个物体的任务）同样不在其范围内。感知质量只通过 e_{loc} 与 e_v 进入，我们单独测量它（表 S1）。这个界不是成功的概率，它指出哪些误差随哪些因素放大。

H 更多相关工作

本附录补充第 2 节中只简要涉及的工作。

动态操作与延迟。 经典系统通过预测跟踪 [4] 与视觉伺服 [32] 补偿延迟，并在估计的轨迹上规划，以抓取或拦截运动物体 [2, 6, 27]，后来又与抓取和可达性规划结合 [1, 52]。学习型视觉运动策略 [16, 98] 与视觉—语言—动作模型 [9, 11, 37, 55, 56, 106] 能够跨物体与指令泛化，但它们大多在模型计算期间场景保持静止的条件下训练和评测。在面向运动场景的学习方法中，DynamicManip 从单条静态示范合成动态示范 [41]，DynaWM 针对运动物体修正基础 VLA 的动作块 [14]。

世界模型与世界—动作模型。 世界模型已被用于基于视觉预见的规划 [21]、在学习的隐空间中进行强化学习 [24, 25]，以及在预训练视觉特征上规划 [3, 102]。在操作任务中，生成的帧或子目标图像已被转化为动作 [8, 17, 96]。对 WAM 的研究比较了视频流与动作流应如何交换信息 [75, 86]，以及上下文应有多长、压缩到什么程度 [31, 47]。其他预测目标还包括按运动加权的视频 [33]，以及光流或运动向量 [15, 42]。

3D 与运动表示。 以物体为中心的点云提升泛化能力 [105]，3D 与 4D VLA 把 3D 与时空输入引入大模型 [93, 99]。稠密像素运动也被用作中间表示加以预测 [54, 57, 58]。除 SE(3) 分解之外，3D 动态

场景记忆 [83] 与场景流估计 [45, 69] 也刻画场景如何运动。点跟踪器、位姿估计器与前馈重建模型 [34, 73, 76, 80, 92] 可以从视频中提取这类运动标签；我们的 DROID 预训练使用 PointWorld 提取的 3D 点轨迹 [30]（附录 B）。