# SE(3)-WAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿


**摘要**

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景。因此，策略必须推断场景如何运动、预判它将到达何处；然而在这些推断上多花的每一毫秒，都会让目标走得更远。现有方法没有很好地化解这一矛盾：世界—动作模型以统一的精细程度预测未来图像或隐变量，把容量和时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器则忽略了约束其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；场景其余部分只通过它留下的间隙起作用。我们提出 SE(3)-WAM，一个学习这种按角色区分精度的 4D 结构的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，并被训练去精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测周围场景。它的动作流读取由这些预测塑造的表示，以条件流匹配生成动作块，并在每一步之后重新规划；预测本身从不回流到动作，部署时被跳过，因此推理既不需要过去的帧，也不需要生成未来，速度足以支撑实时控制。在推理期间场景持续运动的仿真基准 Dynamic-14 上，SE(3)-WAM 的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在涵盖直线、圆周与加速目标运动的五个真机任务上，它的成功率为 [XX]%。


**图占位：图 1 预览——运动场景的按角色区分精度的 4D 视图（真机）**

**版式**：通栏，两部分。**(a) 左侧，约 62%**：直线运动抓取的一帧真机画面，取动作块发出的瞬间。按论文语义配色叠加：蓝色为因果跟踪器给出的目标过去 SE(3) 位姿（$-350 \ldots 0$ ms 的小三轴，随时间变淡）；橙色为动作块各执行时刻的目标 SE(3) 预测，取自离线运行的训练期预测头；浅橙色箭头为仅画在环境上的$14 \times 14$ 网格稀疏 3D 流；紫色为在 $\tau^{a}$ 与目标相遇的指令夹爪路径。灰色虚影标出采集时观测到的位姿，红色虚线箭头示意反应式策略会在何处闭合。图像下方的细时间轴：采集 $\tau_t \rightarrow$ 延迟 $\ell_t \rightarrow$ 执行 $\tau^{a}$。**(b) 右侧，约 38%**：上：“图像空间 WAM：以统一精细程度预测未来帧或隐变量”（胶片图标）；中：“SE(3)-WAM：目标用 SE(3)，环境用稀疏 3D 流，仅训练时使用”（三轴 + 稀疏箭头）；下（**必需**）：SE(3)-WAM 与最强基线的成功率随附加延迟（0–200 ms）的变化（数据：附录 E.2 的延迟扫描）。**规则**：真实照片不做修饰；叠加由该次试验记录的跟踪、预测与指令数据绘制；图注说明该次试验的结果。

图 1. **运动场景的按角色区分精度的 4D 视图。**从图像采集到第一条指令之间，传送带上的零件移动的距离超过了抓取所能容忍的误差。SE(3)-WAM 编码目标的度量运动（蓝色），并被训练去精确预测目标的 SE(3) 位姿、以稀疏 3D 流预测周围场景（橙色）；部署时跳过这一预测，因此它的指令在执行时与目标相遇（紫色）。图像空间的世界—动作模型则以统一精细程度预测外观。右：Dynamic-14 上成功率随附加延迟的变化。

## 1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[9, 16, 37, 57, 76, 85, 107]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。这带来两个相互耦合的困难。单张图像无法揭示目标如何运动；而等到动作执行时，目标已不在它被看到的位置：传送带上以 0.1 m/s 运动的零件在 150 ms 的延迟中移动 15 mm，超过了平行夹爪抓取通常能容忍的误差（图 1）。

近期工作为策略加入对过去运动的记忆和对未来的预测 [19, 50, 68, 95]。两者都消耗动态操作最缺乏的资源：时间。更丰富的历史和更稠密的预测增加计算，计算增加延迟，而延迟又放大了预测本应消除的误差。因此，现有设计在信息与速度之间权衡。基于视频的 WAM 位于一端 [50, 76, 85]：它们以统一的精细程度预测完整的未来帧或隐变量，为此付出延迟，把大部分容量花在外观上，而决定接触的量——动作执行时目标的度量位姿——仍然是隐式的。只预测动态区域或显著 token 的方法 [68, 95] 缩小了预测范围，但仍在图像空间中预测，该位姿同样是隐式的。以目标为中心的预测器位于另一端 [19, 28, 51]：它们速度快，却看不到可能阻挡或改变目标运动的周围环境。它们都没有提供这样一种对运动场景的认识：在接触所依赖之处精确，在其他地方粗略，并且在执行时使用的代价很低。

我们的关键观察是：动态策略需要精确知道的东西其实很少。接触取决于动作执行时刻目标的位姿，精度要到毫米；场景的其余部分只通过它留下的间隙起作用。预测也不必在测试时计算：在训练中作为监督的预测，会塑造策略所学到的表示，部署时即可去掉。基于这一观察，我们提出 SE(3)-WAM ，一个面向动态操作、按角色区分精度的世界—动作模型（图 2）。它的输入只保留运动所需的信息：由冻结编码器编码的当前图像，以及目标度量 SE(3) 位姿和机器人状态的短历史；这些历史直接表达运动，而不必编码一叠过去的帧。世界流把这些输入汇聚为少量摘要 token，并被训练在同一个度量 4D 空间中精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流预测场景的其余部分。动作流通过共享注意力在每一层读取摘要 token，以条件流匹配生成动作块，并在每执行一步后重新规划，因此它的动作随目标运动而调整。预测只作为监督：它们在训练中塑造摘要 token，从不回流到动作，部署时预测头被跳过。因此，SE(3)-WAM 以接近反应式策略的延迟，获得了度量预测带来的精度。

我们在 Dynamic-14 上评估 SE(3)-WAM 。这是一个包含 14 个任务的仿真基准，观测、场景运动与动作执行共用同一个物理时钟，策略计算期间场景持续运动。SE(3)-WAM 以 [XX.X]% 的成功率达到最优，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms；在涵盖直线、圆周与加速目标运动的五个真机任务上，它的成功率为 [XX]%，最强基线为 [XX]%。消融表明：SE(3) 位姿历史优于视觉历史；按角色区分的预测优于以目标为中心的预测和图像空间预测；只把预测作为训练信号，效果与把预测喂给动作相当，同时保持部署快速。

我们的贡献有三点：

- 我们指出，在动态操作中，推理延迟会直接转化为接触误差，并提出按角色区分精度的 4D 建模：用度量的 SE(3) 位姿历史和未来轨迹精确表示目标，用稀疏 3D 流粗略表示场景的其余部分。
- 我们提出 SE(3)-WAM ，一个世界—动作模型：其动作流读取由这些按角色区分的预测所塑造的表示，而预测本身从不回流、部署时被跳过，从而以接近反应式策略的延迟获得预测带来的精度。
- 我们构建了 Dynamic-14 ，在其中感知、场景运动与执行共用一个物理时钟。SE(3)-WAM 在该基准和五个真机任务上取得最优结果，消融实验证实了每个组件的贡献。

## 2 相关工作

**动态操作。** 作用于运动目标，需要补偿从感知到执行之间的时间；这一问题与含纯滞后的反馈控制 [65] 和预测跟踪 [4] 一样古老。经典的接物与抓取系统用卡尔曼类滤波器估计目标轨迹 [5]，在视觉特征上伺服 [32]，并规划拦截 [2, 6, 27]，后来又与抓取和可达性规划结合 [1, 53]。这些流水线精确，但需要为每个物体和任务专门设计。学习型视觉运动策略 [16, 99] 与视觉—语言—动作模型（VLA）[9, 11, 37, 56, 57, 107] 能够跨物体和指令泛化，但它们在准静态场景中训练和评测，模型计算时世界保持不动。近期工作把学习型策略带入运动场景。DOMINO 提出了动态基准以及 PUMA；PUMA 读取历史光流，并以未来物体特征作为监督 [19]。DynamicManip 从单条静态示范合成动态示范 [41]，DynamicWAM 以过去的光流和

运动学描述作为 WAM 的条件 [50]，DynaWM 针对运动物体重新生成基础 VLA 的动作块 [14]。另一些方法预测显著的视觉 token [68]、一张未来图像 [96]、带有距下一次夹爪事件时间的紧凑未来编码 [51]，或在线优化的 3D 高斯速度场 [91]，并在测试时把预测交给策略。执行方案则从另一侧减小或掩盖延迟。DynamicVLA 与 StreamingVLA 让推理与执行重叠 [61, 82]，实时分块与双向解码保持相邻动作块一致 [10, 47]，异步推理把预测与控制解耦 [63]，VLASH 把机器人状态前推到执行时刻 [69]，Chronos Policy 编码观测与执行时间戳 [73]。这些方案改变的是动作何时计算、何时执行，而 SE(3)-WAM 改变的是策略表示什么，因此二者正交。与我们最接近的是 PUMA，它同样只把未来预测用作训练信号。它从 2D 光流预测目标经掩码池化的图像特征，而 SE(3)-WAM 预测目标的度量 SE(3) 轨迹及其周围环境的稀疏 3D 流。

**世界模型与世界—动作模型。** 世界模型学习观测如何演化，已被用于基于视觉预见的规划 [21]、在学习到的隐空间中进行强化学习 [24, 25]，以及在预训练视觉特征上规划 [3, 103]。在操作任务中，预测的帧或子目标图像被转换为动作 [8, 17, 97]；视频预测还被用作预训练 [80]、逆动力学的预测目标 [71]，以及预测性特征的来源 [29]。世界—动作模型（WAM）在同一网络中联合生成未来视频与动作 [40, 76, 85, 104]。近期研究比较了两条流应如何交换信息 [76, 87]，以及上下文应多长、压缩到什么程度 [31, 48]。由于视频代价高且以外观为主，越来越多的工作改变预测的内容：动态区域、深度与语义特征 [95]，在 RGB 之外加入光流、几何与语义 [89]，按运动加权的视频 [33]，物体掩码 [86] 或物体槽 [49]，光流 [15] 或运动向量 [42]，紧凑的未来隐变量 [38, 39]，以及策略自身条件空间或 token 空间中的目标 [67, 98]。第二个问题是测试时是否需要预测。Fast-WAM 发现，跳过测试时想象后，视频建模的大部分收益仍然保留 [90]；其他方法在训练后去掉预测器 [19, 67, 98] 或辅助结构分支 [89]。SE(3)-WAM 沿用这种只在训练中使用预测的方式，但改变了预测目标。它不在统一分辨率下预测像素或隐变量，而是预测精度随实体角色而定的度量 4D 状态：目标的完整 SE(3) 轨迹，以及场景其余部分的稀疏 3D 流。其动作流读取由这些预测塑造、源自观测的摘要 token，而从不读取预测本身，因此部署时跳过预测头。

**结构化的 3D 与 4D 表示。** 度量的 3D 结构让操作策略更精确、样本效率更高。体素、多视角与点云策略直接作用于场景几何 [22, 35, 62, 92]，物体中心的点云提升泛化 [106]，3D 与 4D VLA 为大模型引入 3D 与时空输入 [94, 100]。运动则通过 2D 点轨迹 [7, 78, 83, 101]、稠密像素运动 [55, 58, 59] 与 3D 流 [23, 88, 102] 提供给策略，或作为输入，或作为先预测、再转换为动作的中间量。物体级表示包括关键点 [52]、物体 SE(3) 轨迹 [28, 66, 79]，以及分别编码机器人、任务物体与障碍物 [18]。刚体结构早已用于学习场景动力学，从点云的 SE(3) 分解 [12, 13] 与 3D 动态场景记忆 [84]，到场景流估计 [46, 70]；PointWorld 把以动作为条件的 3D 点流扩展到真实环境的机器人数据 [30]。点跟踪器、位姿估计器与前馈重建模型 [34, 74, 77, 81, 93] 使得从视频中提取这类标签的代价变得很低。这些表示通常对整个场景采用同一粒度：要么处处是稠密几何与流，要么每个物体都用位姿。SE(3)-WAM 按角色分配粒度。接触取决于毫米级精度的目标，用其 SE(3) 位姿历史与预测描述；场景其余部分只通过留出的间隙产生影响，用稀疏 3D 流描述。面向真机，我们用 PointWorld 从 DROID 中提取的 3D 点轨迹在 DROID 上预训练 [30]。

## 3 SE(3)-WAM

SE(3)-WAM （图 2）是一个包含世界流与动作流、两者共享注意力的 Transformer。世界流编码当前观测和近期运动，并被训练去预测按角色区分精度的 4D 场景。动作流以条件流匹配 [43] 生成动作块，只通过少量摘要 token 读取世界。我们先说明驱动这一设计的问题设定。

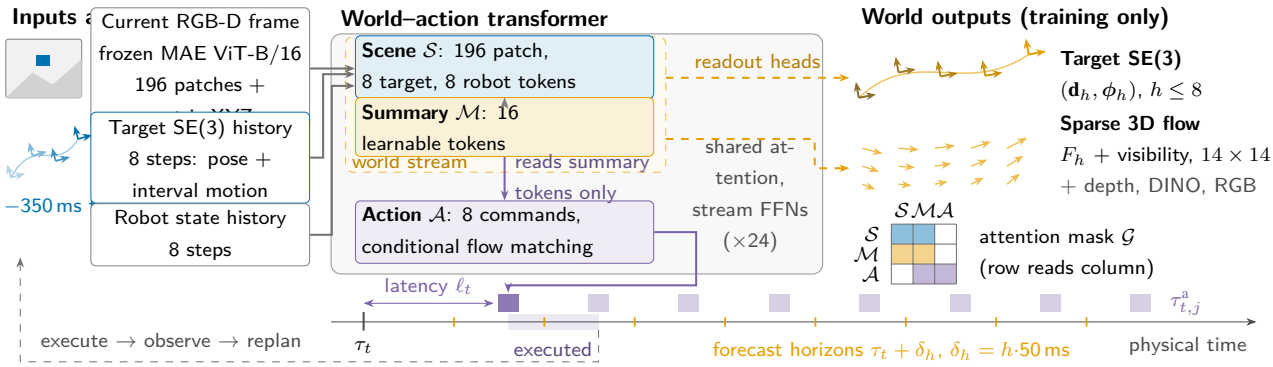



图 2. **SE(3)-WAM** 。世界流包含 212 个场景 token（冻结编码器给出的当前图像 patch，以及目标度量 SE(3) 位姿与机器人状态的短历史）和 16 个摘要 token。训练时，轻量读出头把世界流读出为物理时域 $\tau_t + \delta_h$ 上按角色区分精度的 4D 预测：目标的 SE(3) 轨迹、$14 \times 14$ 网格上带可见性的稀疏 3D 流，以及外观目标（虚线：仅训练）。动作流以流匹配生成 8 条指令组成的动作块。注意力掩码 $\mathcal{G}$ 只允许世界 token 读取彼此、动作 token 读取摘要 token 与彼此，因此预测永远不会进入动作。策略执行一条指令、重新观测，然后重新规划。

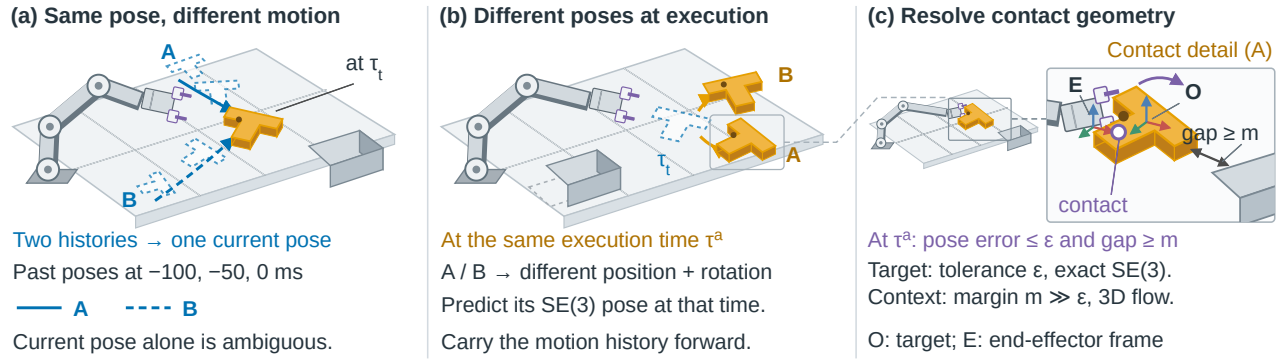



图 3. **作用于运动目标**（示意图）。(a) 两段历史在采集时刻 $\tau_t$ 到达相同位姿，但对应不同运动。(b) 在执行时刻 $\tau^a$，它们对应不同的目标位姿。(c) 接触要求末端执行器坐标系 $E$ 与目标 $O$ 在 $\varepsilon$ 内对齐，而环境只通过它留下的间隙起作用，$m \gg \varepsilon$。

## 3.1 作用于运动目标

**执行时刻。** 在第 $t$ 次查询时，策略接收在时刻 $\tau_t$ 采集的图像、深度图与机器人状态，以及更早状态的历史，并输出动作块 $A_t = (\mathbf{a}_{t,0}, \dots, \mathbf{a}_{t,H-1})$，其第 $j$ 条指令在

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + \ell_t + j\Delta_a \tag{1}$$

执行，其中 $\ell_t$ 为从采集到首次执行的延迟（预处理、推理与执行机构），$\Delta_a$ 为控制周期。指令必须适合 $\tau^{\mathrm{a}}_{t,j}$ 而非 $\tau_t$ 时刻的场景（图 3），而领先时长 $\Delta_{t,j} = \tau^{\mathrm{a}}_{t,j} - \tau_t$ 随推理的每一毫秒增长。

**目标与环境。** 令 $W_t(\mathbf{x}, \tau) \in \mathbb{R}^3$ 为位于 $\mathbf{x}$ 的场景点在 $\tau_t$ 与 $\tau$ 之间的位移，以机器人基座坐标系表示。目标 $\mathcal{O}$ 是其位姿误差进入接触或容纳容差 $\varepsilon$ 的刚体，例如要抓取的物体或要放入的容器。环境 $\mathcal{C}$ 包含只需避开的物体，例如传送带或遮挡物，其间隙为 $m$。在目标上，运动场由其位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 决定：

$$W_t(\mathbf{x}, \tau) = T(\tau)\, T(\tau_t)^{-1}\mathbf{x} - \mathbf{x}, \qquad \mathbf{x} \in \mathcal{O}. \tag{2}$$

**误差从何而来。** 设策略显式或隐式地依据目标在 $\tau^{\mathrm{a}}$ 时位姿的估计 $\hat{T}$ 行动。对于力臂为 $r$ 的接触点和旋转误差 $\theta$，接触误差至多为 $\|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\| + 2r\sin(\theta/2)$。把领先时长 $\Delta$ 内的运动写成匀速 $\mathbf{v}$ 加残

差 $\boldsymbol{\rho}$（加速、滚动、撞击），得到

$$\|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\| \le e_{\mathrm{loc}} + \Delta\, e_v + \|\mathbf{v}\|\, e_\tau + e_{\mathrm{dyn}}, \tag{3}$$

四项依次为当前位置误差、速度误差乘以领先时长、时刻误差乘以速度，以及残差运动误差（附录 G）。对环境而言，发生碰撞要求沿指令路径某处的预测误差至少为 $m$。由此得到两点结论。第一，重要的精度集中在目标上：需要毫米级地估计其位姿与运动，旋转误差还会经力臂 $r$ 放大；环境则可以粗略得多地预测。第二，延迟两次进入误差预算：一次通过放大每个速度误差的领先时长 $\Delta$，一次通过残差累积的运动；因此，消耗推理时间的信息，只有当它消除的误差多于额外延迟带来的误差时才划算。这两点决定了 SE(3)-WAM 的三个部分：它记住什么（第 3.2 节），它学会预测什么（第 3.3 节），以及它的动作如何在部署时不为预测付出代价地使用预测（第 3.4 节）。

### 3.2 输入：当前帧与运动历史

SE(3)-WAM 只看一张图像。冻结的 MAE ViT-B/16 [26] 把当前 RGB 帧编码为 196 个 patch token，深度图为每个 patch 给出其中心点在基座坐标系中的度量 3D 位置。运动来自最近 8 个控制步（20 Hz 下为 350 ms）上的两段短历史。目标历史由基座坐标系下的当前目标位姿和相邻采样之间的七段区间运动组成：平移、相对旋转、时间间隔，以及有限差分得到的速度与加速度，均为物理单位（附录 A.1）。它们构成 8 个目标状态 token。机器人历史构成 8 个末端执行器状态 token。它们与 patch token 一起构成 212 个场景 token。在真机上，因果跟踪器在每一帧估计目标位姿：SAM 2 从目标上的提示传播掩码 [60]，FoundationPose 借助物体模型或少量参考视图跟踪物体 [77]。每个估计连同其采集时刻只输出一次，之后的帧不会修改它（附录 A.2）。在仿真中，我们从仿真器读取目标位姿，使策略与跟踪误差分离，并单独评估位姿噪声与跟踪位姿的影响（附录 F.2）。模型不接收过去的图像，因此输入代价不随历史增长。

### 3.3 按角色区分精度的 4D 预测

世界流被训练在时域 $\tau_t + \delta_h$ 上预测 $W_t$，其中 $\delta_h = h{\cdot}50\,\mathrm{ms}$、$h = 1, \dots, 8$，覆盖整个动作块的执行时刻（400 ms）。我们通过式 (2) 参数化目标。对每个时域，

$$\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t), \quad \boldsymbol{\phi}_h = \mathrm{Log}\big(R(\tau_t{+}\delta_h)R(\tau_t)^{\top}\big)^{\vee}, \tag{4}$$

位姿头以平移平方误差加 $\lambda_R$ 倍的测地旋转平方误差回归 $(\mathbf{d}_h, \boldsymbol{\phi}_h)$（$\mathcal{L}_P$）。场景其余部分用稀疏 3D 流表示：对 $14 \times 14$ 网格上 196 个 patch 的中心点（在工作空间中相距约 [X] mm），流头在每个时域回归其在基座坐标系中的位移 $F_h \in \mathbb{R}^3$ 与可见性（$\mathcal{L}_F$）。网格刻意取得较粗，因为环境的误差只要小于间隙即可容忍，而目标的精度来自其位姿而非其上的点。作为额外的训练目标，外观头回归未来深度、冻结 DINOv3 教师 [64] 的特征与运动表面的 RGB，重建头恢复当前图像中的目标区域（$\mathcal{L}_{\mathrm{aux}}$）。所有头都是世界流最终隐藏状态上的轻量读出，所有标签都从当前状态累计，损失只使用有效标签。

### 3.4 动作与共享主干

世界流包含 212 个场景 token 和 16 个可学习的摘要 token。动作流包含 8 个 token，每条指令一个，嵌入带噪指令与流时间。一个动作块覆盖 8 个 $\Delta_a = 50\,\mathrm{ms}$ 的控制周期，每条指令是末端执行器的平移与旋转加夹爪指令。注意力掩码 $\mathcal{G}$ 只允许世界 token 读取世界 token，并允许动作 token 读取摘要 token 与彼此。因此，动作只通过摘要 token 读取世界；训练中预测损失塑造摘要 token 的内容，而预测本身

从不进入动作流。两条流在每一层共享注意力投影，并各有独立的前馈网络，因此它们在注意力中交换信息，同时保留各自的容量。对归一化的动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与 $u \sim \mathcal{U}[0,1]$，动作损失为

$$\mathcal{L}_A = \mathbb{E}\left\| v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t, \mathcal{G}) - (\mathbf{a}_1 - \mathbf{a}_0) \right\|^2, \tag{5}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为第 $t$ 次查询的场景 token。总损失为 $\mathcal{L} = \mathcal{L}_A + \lambda_F \mathcal{L}_F + \lambda_P \mathcal{L}_P + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}}$。第 4.4 节把这种耦合与其他方案比较，记号如下：R0 关闭预测损失；R2 加入世界查询，动作在每一层读取其隐藏状态；R3 让这些查询读取动作，R4 同时开启两个方向；R5 把解码出的预测编码为几何 token 供动作读取（附录 A.5）。

**部署。** 测试时跳过预测头。由于世界 token 从不读取动作，世界流每次查询只运行一次，动作流在缓存的 key 与 value 上积分 5 个 Euler 步。机器人执行第一条指令，策略重新观测并重新规划，因此每条被执行的指令都来自仅早 $\ell_t$ 的观测。在 RTX 5090 上，p95 出动作时间为 [XX] ms。

**实现。** Transformer 有 24 层，宽度 1024，16 个注意力头，前馈宽度 4096，主干参数 504.0M，可训练参数共 523.8M。MAE ViT-B/16 编码器（85.8M）和 DINOv3 教师（303M）保持冻结。在 Dynamic-14 上，我们用每个任务 800 条示范的全部窗口训练 20 轮（全局 batch 512 下 51,740 次更新），使用 AdamW 与余弦调度，$\lambda_F = \lambda_P = 1$、$\lambda_R = \lambda_{\text{aux}} = 0.1$；每个训练种子在 [N] 块 RTX PRO 6000 GPU 上约需 [X] 小时（附录 A.6）。

### 3.5 面向真机的预训练

真实机器人数据不提供物体位姿，因此真机基座学习 DROID [36] 所能支持的那部分预测。它采用相同架构，有 48 层（1.02B 可训练参数），输入与仿真模型相同，只是没有目标历史。其目标为动作、稀疏 3D 流和未来 DINOv3 特征。流标签来自 PointWorld 为 DROID 发布的 3D 点轨迹与优化后的相机标定 [30]，重采样为每个图像 patch 一条轨迹，并保留 DROID 的原生时间。我们在 42,087 个 episode 的 598,889 个窗口上、用 64 块 GPU 训练 21,060 次更新（附录 B）。每个真机策略从该基座初始化，加入目标状态 token 与位姿头，并用跟踪位姿在其任务上微调。仿真模型从通用初始化（冻结的 MAE 编码器加随机初始化的 Transformer）训练。

## 4 实验

我们在仿真和真机上比较 SE(3)-WAM 与反应式、动态及世界—动作策略（第 4.2 节与第 4.3 节），然后对它的历史、预测以及动作使用预测的方式做消融（第 4.4 节）。

### 4.1 设置

**Dynamic-14 。** 我们在 MuJoCo/robosuite [72, 105] 中构建了五个任务族共 14 个任务：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（附录 C，图 S3）。扫描变量包括速度（0.5–1.5×）、附加延迟（0–200 ms）和通道间隙（[取值] mm）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个，新种子）上报告所有 Dynamic-14 数值。本文各变体取三个训练种子的平均，每个基线训练一次。我们给出对留出场景自助法得到的配对 95% 区间。

表 1. **主要结果。**Dynamic-14 留出集成功率（%；1,400 个新场景，按任务等权，实时协议，本文各变体取三个训练种子的平均，基线训练一次），按任务族分列；另列加入 150 ms 延迟后的成功率、推理期间物理暂停时的成功率（暂停）、接触时刻误差 $e_t$（ms）、首次接触时的位置误差 $e_p$（mm），以及在一块 RTX 5090 上的 p95 出动作时间。输入：R 为 RGB 与机器人状态；D 为深度；P 为目标 SE(3) 历史。粗体为最佳；置信区间见附录 E。

| | | Dynamic-14 成功率，除注明外为实时协议 | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 方法 | 输入 | 全部 | 抓取 | 放置 | 穿越 | 捕获 | 撞击 | +150 ms | 暂停 | $e_t$ | $e_p$ | p95 (ms) |
| ACT [99] | R | — | — | — | — | — | — | — | — | — | — | — |
| Diffusion Policy [16] | R | — | — | — | — | — | — | — | — | — | — | — |
| $\pi_{0.5}$ [57] | R | — | — | — | — | — | — | — | — | — | — | — |
| $\pi_{0.5}$ + SE(3) | R+P | — | — | — | — | — | — | — | — | — | — | — |
| DynamicVLA [82] | R | — | — | — | — | — | — | — | — | — | — | — |
| PUMA [19] | R | — | — | — | — | — | — | — | — | — | — | — |
| DreamVLA [95] | R | — | — | — | — | — | — | — | — | — | — | — |
| OpenWAM-$\alpha$ [76] | R | — | — | — | — | — | — | — | — | — | — | — |
| DynamicWAM [50] | R | — | — | — | — | — | — | — | — | — | — | — |
| DynamicWAM + SE(3) | R+P | — | — | — | — | — | — | — | — | — | — | — |
| SE(3)-WAM，匀速外推输入 | RD+P | — | — | — | — | — | — | — | — | — | — | — |
| 卡尔曼拦截器 | D+P | — | — | — | — | — | — | — | — | — | — | — |
| SE(3)-WAM | RD+P | — | — | — | — | — | — | — | — | — | — | — |

**协议。** 观测、场景运动与执行共用一个控制周期为 50 ms 的物理时钟。所有方法在同一执行器下运行，方法计算期间物理世界按其在一块 RTX 5090 上测得的延迟继续推进。一条指令执行完毕且上一次推理结束后，策略再次被查询；新动作块到达之前，执行器继续执行上一个动作块。+150 ms 设置为每个方法额外加入 150 ms 延迟，暂停设置在推理期间停止物理仿真（附录 C.3）。我们报告按任务等权的成功率（SR）、接触时刻误差 $e_t$、首次接触时的位置误差 $e_p$ 以及 p95 出动作时间。

**基线。** 我们比较反应式策略（ACT [99]、Diffusion Policy [16] 与 $\pi_{0.5}$ [57]）、动态 VLA（DynamicVLA [82] 与 PUMA [19]）、图像或隐空间 WAM（DreamVLA [95] 与 OpenWAM-$\alpha$ [76]），以及一个动态 WAM（DynamicWAM [50]）。每个基线使用其官方代码、输入与训练配方，在相同示范上训练；若其配方使用腕部相机，则提供渲染的腕部图像（附录 D）。SE(3)-WAM 只使用主视角，但还使用深度和目标位姿。为了把这些输入与模型本身区分开，$\pi_{0.5}$ 与 DynamicWAM 还额外接收我们的 SE(3) 历史 token（+SE(3)）；另有两个基线只使用位姿历史：匀速输入是去掉预测损失、改为接收目标位姿匀速外推作为输入 token 的 SE(3)-WAM；卡尔曼拦截器则规划到匀加速卡尔曼滤波器 [5] 预测的目标位姿。

## 4.2 主要结果

SE(3)-WAM 在 Dynamic-14 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [最强基线名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。优势最大的是 [旋转目标以及快速的传送带和平移目标]，即领先时长内目标移动最远的任务。它的 p95 出动作时间为 [XX] ms，是图像空间 WAM 的 [X] 分之一；后者的延迟会叠加到它们需要弥补的领先时长上。加入 150 ms 延迟后，SE(3)-WAM 保持 [XX.X]%，而反应式策略降至 [XX.X]%，图像空间 WAM 降至 [XX.X]%。推理期间暂停物理仿真时，它与 [暂停设置下最强基线名称] 的差为 [±X.X] 个百分点，从而把速度的贡献与表示的贡献区分开。匀速输入变体与卡尔曼拦截器分别落后 SE(3)-WAM [X.X] 和 [X.X] 个百分点，主要差在非匀速运动上，因此学习的模型并不只是在外推位姿。DOMINO [19] 与静态 LIBERO 任务 [44]

表 2. **真机结果。**五个任务按目标运动类型分组的成功率（%；每个任务每个方法 [20] 次试验）及全部试验的成功率。每个方法都在相同示范上逐任务微调。二项分布 95% 区间见附录 D.3。

| | 直线 | | 圆周 | | 加速 | |
|---|---|---|---|---|---|---|
| 方法 | [T1] | [T2] | [T3] | [T4] | [T5] | 全部 |
| $\pi_{0.5}$ [57] | — | — | — | — | — | — |
| DynamicWAM [50] | — | — | — | — | — | — |
| SE(3)-WAM，无 DROID 基座 | — | — | — | — | — | — |
| SE(3)-WAM | — | — | — | — | — | — |

**图占位：图 4——真机试验**

**行：**SE(3)-WAM 在加速任务上的一次成功；最强基线在同一试验键上的表现；SE(3)-WAM 的一次失败。**列：**查询帧、首个执行时刻 $\tau^a$ 与接触时刻。**叠加：**蓝色为跟踪得到的过去位姿；紫色为指令的夹爪路径。真实照片不做修饰；叠加来自各次试验的日志数据。

图 4. **真机试验。**SE(3)-WAM 在指令执行时目标将到达的位置闭合，而基线在目标后方闭合。下：跟踪器在夹爪下丢失目标后的一次失败。

上的结果见附录 D.2。

### 4.3 真机实验

我们在配备平行夹爪与标定 RGB-D 相机的七自由度 Franka 机械臂上评估五个任务（图 S4）。目标在两个任务（[T1、T2]）中沿直线运动，在两个任务（[T3、T4]）中沿圆周运动，在一个任务（[T5]）中加速运动（表 2，附录 D.3）。每个方法在相同的 [N] 条遥操作示范上逐任务微调，并以共享的试验键在每个任务上运行 [20] 次试验。SE(3)-WAM 用 FoundationPose [77] 跟踪目标，在一块 RTX 5090 上运行，p95 出动作时间为 [XX] ms。它在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%，不使用 DROID 基座时为 [XX.X]%（表 2）。它的优势在 [加速运动] 上最大，因为外推最后观测到的速度在那里会失败；它剩余的失败主要是 [夹爪下跟踪丢失之后的迟闭合]（图 4）。

**预训练。** DROID 基座使真机 SR 比通用初始化高 [X.X] 个百分点（表 2）；在相同预算下，只用动作预训练的基座恢复了这一增益的 [XX]%，因此大部分收益来自 3D 流与 DINO 目标（附录 B）。

### 4.4 消融：动态策略需要什么？

每个变体只改变最终模型的一个组件，数据、训练预算和其他组件保持不变（表 3 与图 5）。完整比较见附录 F。

**记住什么。** 我们固定当前帧、当前目标位姿和机器人历史。加入八帧 RGB、同一窗口上带 DynamicWAM 运动统计量的光流 [50]，或视频 VAE 隐变量，使 SR 变化 [X.X] 到 [X.X] 个百分点，并使出动作时间最多增加到 [X] 倍；而 SE(3) 历史几乎不增加代价就带来 [X.X] 个百分点（表 3）。这一增益在领先时长超过任务族的临界领先时长 $\varepsilon/\|\mathbf{v}\|$ 后出现，随延迟增大，对静止目标消失（图 5a）。冻结读出表明视觉历史确实包含运动信息（附录 F.2），但在我们的数据规模下，策略没有把它转化为度量速度。在真

表 3. **消融实验**（Dynamic-14 留出场景，三个训练种子）。每组只改变 SE(3)-WAM （⋆）的一个组件。SR、$SR_{150}$：不加和加入 150 ms 延迟时的成功率（%）；$e_t$：接触时刻误差（ms）；$e_p$：首次接触时的位置误差（mm）；p95：出动作时间（ms）。

| 变体 | SR | $SR_{150}$ | $e_t$ | $e_p$ | p95 |
|---|---|---|---|---|---|
| SE(3)-WAM ⋆ | — | — | — | — | — |
| 历史（保留当前帧与当前位姿） | | | | | |
| 无 | — | — | — | — | — |
| RGB 窗口（8 帧） | — | — | — | — | — |
| 光流与运动统计 | — | — | — | — | — |
| 视频 VAE 隐变量 | — | — | — | — | — |
| SE(3)（含跟踪噪声） | — | — | — | — | — |
| 预测目标 | | | | | |
| 无（关闭预测损失，R0） | — | — | — | — | — |
| 仅目标 SE(3) | — | — | — | — | — |
| 仅环境流 | — | — | — | — | — |
| 统一粒度：目标也用点流 | — | — | — | — | — |
| 图像空间：未来 RGB/隐变量 | — | — | — | — | — |
| 去除外观辅助目标 | — | — | — | — | — |
| 测试时如何使用预测 | | | | | |
| 动作读取世界查询（R2） | — | — | — | — | — |
| 世界读取动作（R3） | — | — | — | — | — |
| 双向读取（R4） | — | — | — | — | — |
| 由解码预测生成动作（R5） | — | — | — | — | — |

**图占位：图 5——消融（四个子图）**

**(a) 历史。**横轴：附加延迟（0–200 ms）；纵轴：相对仅当前帧的 ΔSR。曲线：RGB 窗口、光流、视频 VAE 隐变量（灰色），SE(3) 历史（蓝色），含位姿噪声的 SE(3) 历史（蓝色点线）；静止目标为浅色线；刻度标出各任务族的临界领先时长 $\varepsilon/\|\mathbf{v}\|$。**(b) 目标预测。**按运动类型（匀速、简谐、滚动/滑动、撞击后）的柱状图：CV、CA 与学习的 SE(3) 预测（橙色）在 $\tau^a$ 的预测误差，对应策略的 SR 以圆点表示。**(c) 环境。**仅穿越任务。横轴：间隙（mm）；纵轴：SR；曲线：无环境流、$14^2$、$28^2$、$56^2$ 网格、未来隐变量；标记：各网格实测的路径误差。**(d) 耦合。**横轴：p95 出动作时间（ms）；纵轴：附加 0 与 150 ms 延迟时的 SR；点：R0、SE(3)-WAM 、R2、R4、R5。留出场景、三个种子，带状区域为 95% 配对自助法区间。

图 5. **消融。**(a) 领先时长超过临界值后 SE(3) 历史开始起作用，延迟越大作用越大，而视觉历史始终持平。(b) 在非匀速运动上，学习的 SE(3) 预测优于外推。(c) 在间隙降到其路径误差之前，粗粒度环境流已经足够。(d) 测试时读取或解码预测会增加延迟，但不提高成功率。

实跟踪器的位姿噪声下，SE(3) 历史保留了 [XX]% 的增益。把同样的历史提供给 $\pi_{0.5}$ 与 DynamicWAM，它们的 SR 分别提高 [X.X] 和 [X.X] 个百分点（表 1），因此这一收益并非我们的模型所特有。

**预测什么。** 关闭全部预测损失（R0）使 SR 下降 [X.X] 个百分点，且差距随领先时长增大。只预测目标的 SE(3) 轨迹损失 [X.X] 个百分点，主要在环境约束运动的穿越与放置任务上；只预测环境流损失 [X.X] 个百分点，主要在旋转目标上，因为力臂会放大旋转误差。把目标位姿换成其上各点的流、使目标与环境同样粒度，损失 [X.X] 个百分点。在执行时刻，学习的 SE(3) 预测在传送带运动上与匀速外推一样准确，而在滚动、滑动和撞击后的运动上准确 [X] 倍（图 5b）。对环境而言，路径误差为 [X] mm 的$14 \times 14$ 流在通道间隙降到 [X] mm 之前与 $28^2$、$56^2$ 网格持平（图 5c）。图像空间的未来，即用未来 RGB 或视频隐变量代替 4D 预测，SR 为 [XX.X]%，训练代价为 [X] 倍。不过，作为 4D 预测之外的辅助目标，深度、DINO 特征和运动区域 RGB 带来 [X.X] 个百分点；与 4D 预测头一样，它们在部署时被跳过。

图占位：图 6——执行时刻的预测

**行**：一次滚动捕获（预测误差为中位数）与一次失败的撞击后抓取。**列**：$\tau_t$ 的查询帧、$\tau^a$ 的帧，以及基座坐标系中的 3D 小图。**叠加**：蓝色为过去位姿，橙色为训练期预测头给出的预测三轴与粗粒度流箭头，灰色为同一时刻的真值，紫色为指令路径。完整示例见图 S5。

图 6. **执行时刻的预测**（Dynamic-14 留出回合，读自训练期预测头）。上：SE(3) 预测跟随滚动目标，而外推冲过了头。下：撞击之前，回归得到的预测对可能的结果取平均，抓取落空。

**如何使用预测。** 让动作读取世界查询的隐藏状态（R2）、让世界也读取动作（R3、R4），或由解码出的预测生成动作（R5），使 SR 变化 [±X.X] 到 [±X.X] 个百分点，处于种子波动范围之内，而出动作时间是 SE(3)-WAM 的 [X.X]–[X.X] 倍（图 5d）。在 150 ms 附加延迟下，差异仍在 [±X.X] 个百分点之内。因此，预测作为训练信号塑造动作所读取的内容而发挥作用，这与 Fast-WAM 在静态场景中的发现一致 [90]；在测试时生成预测只增加延迟，不增加成功率。在参数量相同时，用世界流与动作流各自独立的参数代替共享注意力，使 SR 变化 [±X.X] 个百分点（附录 F.1）。

## 5 结论

我们提出了 SE(3)-WAM ，一个用于操作运动物体的世界—动作模型：它把精度花在接触所依赖之处，把时间只花在值得的地方。它记住目标的度量 SE(3) 运动而非过去的帧，学会精确预测目标的 SE(3) 轨迹并以稀疏 3D 流预测场景其余部分，并让动作读取由这些预测塑造的表示，而不在测试时生成预测。在策略计算期间场景持续运动的 Dynamic-14 上，以及在五个真机任务上，它优于反应式、动态与世界—动作策略。消融把收益归因于度量运动历史以及作为训练信号使用的按角色区分的预测，而非更丰富的外观模型或在线读取预测。对于动态场景中的世界—动作模型，这些结果支持只预测决定接触的少数量，并让部署的策略与反应式策略一样快。

**局限性。** SE(3)-WAM 假设目标是刚体、在接触之前自行运动，因此可变形或带关节的目标以及接触后的动力学不在其范围内。它依赖目标的位姿估计，跟踪器的失败会传递给策略；在仿真中我们从仿真器读取位姿。回归得到的目标预测无法表示多模态的未来，例如撞击之前。我们的真机基座在没有目标位姿的 DROID 上学习，因此与位姿相关的部分只在微调中学习。最后，我们的任务只有单个目标，且环境运动较慢。

## LLM Usage Statement（大语言模型使用声明）

[投稿前补充：实际使用的工具、受影响的研究与稿件部分，以及使用程度。]

## 参考文献


[1] Iretiayo Akinola, Jingxi Xu, Shuran Song, and Peter K. Allen. Dynamic grasping with reachability and motion awareness. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 9422–9429, 2021.

[2] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[3] Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Mojtaba Komeili, et al. V-JEPA 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025.

[4] Ronald Azuma and Gary Bishop. Improving static and dynamic registration in an optical see-through HMD. In *Proceedings of SIGGRAPH*, pages 197–204, 1994.

[5] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation*. Wiley, 2001.

[6] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[7] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[8] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pre-trained image-editing diffusion models. In *International Conference on Learning Representations*, 2024.

[9] Kevin Black, Noah Brown, Danny Driess, et al. $\pi_0$: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[10] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, 2025.

[11] Anthony Brohan, Noah Brown, Justice Carbajal, et al. RT-1: Robotics transformer for real-world control at scale. In *Proceedings of Robotics: Science and Systems*, 2023.

[12] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, 2017.

[13] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[14] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[15] Yixiang Chen, Peiyan Li, Yuan Xu, Qisen Ma, Jiabing Yang, Kai Wang, Jianhua Yang, Dong An, He Guan, Gaoteng Liu, Jianlou Si, Jun Huang, Jing Liu, Nianfeng Liu, Yan Huang, and Liang Wang. FlowWAM: Optical flow as a unified action representation for world action models. *arXiv preprint arXiv:2607.13017*, 2026.

[16] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[17] Yilun Du et al. Learning universal policies via text-guided video generation. In *Advances in Neural Information Processing Systems*, 2023.

[18] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. *arXiv preprint arXiv:2503.11565*, 2025.

[19] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. *arXiv preprint arXiv:2603.15620*, 2026.

[20] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[21] Chelsea Finn and Sergey Levine. Deep visual foresight for planning robot motion. In *IEEE International Conference on Robotics and Automation*, 2017.

[22] Ankit Goyal, Jie Xu, Yijie Guo, Valts Blukis, Yu-Wei Chao, and Dieter Fox. RVT: Robotic view transformer for 3D object manipulation. In *Conference on Robot Learning*, pages 694–710, 2023.

[23] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *arXiv preprint arXiv:2505.10075*, 2025.

[24] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse control tasks through world models. *Nature*, 640(8059), 2025.

[25] Nicklas Hansen, Hao Su, and Xiaolong Wang. TD-MPC2: Scalable, robust world models for continuous control. In *International Conference on Learning Representations*, 2024.

[26] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[27] B. Hove and Jean-Jacques E. Slotine. Experiments in robotic catching. In *American Control Conference*, 1991.

[28] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[29] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *International Conference on Machine Learning*, 2025.

[30] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[31] Wei Huang, Bohan Zhang, Chenzhi Liu, Isabella Liu, Shuai Yang, Weian Mao, Luozhou Wang, Yicheng Xiao, Weifeng Lin, Qixin Hu, Bryan Chu, Sifei Liu, Linxi Fan, Xiaojuan Qi, Song Han, and Yukang Chen. Long-WAM: Scaling the context of world-action models. *arXiv preprint arXiv:2610.10528*, 2026.

[32] Seth Hutchinson, Gregory D. Hager, and Peter I. Corke. A tutorial on visual servo control. *IEEE Transactions on Robotics and Automation*, 12(5):651–670, 1996.

[33] Haoyuan Ji, Lingxiang Fan, Shang Su, Yinqiao Lu, Mengkai Shi, Jun Gao, and Shuo Feng. DC-WAM: Dynamic-centric visual supervision and reasoning for world-action models. *arXiv preprint arXiv:2607.25918*, 2026.

[34] Nikita Karaev, Ignacio Rocco, Benjamin Graham, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. CoTracker: It is better to track together. In *European Conference on Computer Vision*, 2024.

[35] Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3D diffuser actor: Policy diffusion with 3D scene representations. In *Conference on Robot Learning*, 2024.

[36] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset.

In *Proceedings of Robotics: Science and Systems*, 2024.

[37] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, 2024.

[38] Fenghao Lei, Zhixiong Huang, Long Yang, Jiabao Chen, Peilin Huang, Han Fu, Zhuo Li, and Xiaoxue Ren. DELE-w0.5: Inferring action from future latent state for robotic manipulation. *arXiv preprint arXiv:2608.22067*, 2026.

[39] Jiajun Li, Tiecheng Guo, Yifan Ye, Rongyu Zhang, Xiaowei Chi, Qianpu Sun, Ying Li, Yunfan Lou, Jinqiao Wang, Zhihe Lu, Meng Guo, and Shanghang Zhang. Efficient-WAM: A 1B-parameter world-action model with low-cost future imagination. *arXiv preprint arXiv:2606.10040*, 2026.

[40] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[41] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[42] Minghui Lin, Pengxiang Ding, Shu Wang, Zifeng Zhuang, Yang Liu, Xinyang Tong, Wenxuan Song, Shangke Lyu, Siteng Huang, and Donglin Wang. HiF-VLA: Hindsight, insight and foresight through motion representation for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[43] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[44] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: Benchmarking knowledge transfer for lifelong robot learning. In *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*, 2023.

[45] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[46] Xingyu Liu, Charles R. Qi, and Leonidas J. Guibas. FlowNet3D: Learning scene flow in 3D point clouds. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019.

[47] Yuejiang Liu, Jubayer Ibn Hamid, Annie Xie, Yoonho Lee, Maximilian Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, 2025.

[48] Yushan Liu, Jingjing Fan, Shoujie Li, Yifan Xie, Xiao-Ping Zhang, and Wenbo Ding. PACT-WAM: Predicting actions and visual foresight with compact temporal encoding for robot manipulation. *arXiv preprint arXiv:2602.15882*, 2026.

[49] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[50] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[51] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[52] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *International Symposium on Robotics Research*, 2019.

[53] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[54] Henrique Morimitsu, Xiaobin Zhu, Roberto M. Cesar, Xiangyang Ji, and Xu-Cheng Yin. DPFlow: Adaptive optical flow estimation with a dual-pyramid framework. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17810–17820, 2025.

[55] E-Ro Nguyen, Yichi Zhang, Kanchana Ranasinghe, Xiang Li, and Michael S. Ryoo. Pixel motion diffusion is what we need for robot control. *arXiv preprint arXiv:2509.22652*, 2025.

[56] Octo Model Team, Dibya Ghosh, Homer Walke, et al. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, 2024.

[57] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.

[58] Kanchana Ranasinghe, Xiang Li, E-Ro Nguyen, Cristina Mata, Jongwoo Park, and Michael S. Ryoo. Pixel motion as universal representation for robot control. *arXiv preprint arXiv:2505.07817*, 2025.

[59] Kanchana Ranasinghe, Honglu Zhou, Yu Fang, Luyu Yang, Le Xue, Ran Xu, Caiming Xiong, Silvio Savarese, Michael S. Ryoo, and Juan Carlos Niebles. Future optical flow prediction improves robot control & video generation. *arXiv preprint arXiv:2601.10781*, 2026.

[60] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, 2025.

[61] Yiran Shi, Dongqi Guo, Tianchen Zhao, Feng Gao, Liangzhi Shi, Chao Yu, ZhiJian Mo, Qihua Xiao, XiaoShuai Peng, Qingmin Liao, and Yu Wang. StreamingVLA: Streaming vision-language-action model with action flow matching and adaptive early observation. *arXiv preprint arXiv:2603.28565*, 2026.

[62] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, 2022.

[63] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[64] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[65] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[66] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. *arXiv preprint arXiv:2601.05237*, 2026.

[67] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. *arXiv preprint arXiv:2602.22010*, 2026.

[68] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. *arXiv preprint arXiv:2606.02486*, 2026.

[69] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[70] Zachary Teed and Jia Deng. RAFT-3D: Scene flow using rigid-motion embeddings. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.

[71] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Repre-*

*sentations*, 2025.

[72] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[73] Changhao Wang, Jaden Clark, and Shuran Song. Chronos policy: Learning robot policies on physical time. *arXiv preprint arXiv:2610.13929*, 2026.

[74] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[75] Ruicheng Wang, Sicheng Xu, Yue Dong, Yu Deng, Jianfeng Xiang, Zelong Lv, Guangzhong Sun, Xin Tong, and Jiaolong Yang. MoGe-2: Accurate monocular geometry with metric scale and sharp details. *arXiv preprint arXiv:2507.02546*, 2025.

[76] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[77] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[78] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[79] Gaoyuan Wu, Ziyu Shan, Haoyang Du, Yuyao Jiang, and Ziwei Wang. AffordTrajDP: Dynamic affordance-guided visuomotor policy learning for robotic manipulation. *arXiv preprint arXiv:2608.01603*, 2026.

[80] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, 2024.

[81] Yuxi Xiao, Qianqian Wang, Shangzhan Zhang, Nan Xue, Sida Peng, Yujun Shen, and Xiaowei Zhou. SpatialTracker: Tracking any 2D pixels in 3D space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[82] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. *arXiv preprint arXiv:2601.22153*, 2026.

[83] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, 2024.

[84] Zhenjia Xu, Zhanpeng He, Jiajun Wu, and Shuran Song. Learning 3D dynamic scene representations for robot manipulation. In *Conference on Robot Learning*, 2020.

[85] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[86] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[87] Heng Yu, David D. Yuan, Juze Zhang, Changan Chen, Yao Feng, Michelle Baldonado, Steve Cousins, Li Fei-Fei, Jiajun Wu, and Ehsan Adeli. OpenWAM: An open framework for composable world-action models. *arXiv preprint arXiv:2610.07922*, 2026.

[88] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2024.

[89] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[90] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

[91] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. *arXiv preprint arXiv:2607.01938*, 2026.

[92] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[93] Chuhan Zhang, Guillaume Le Moing, Skanda Koppula, Ignacio Rocco, Liliane Momeni, Junyu Xie, Shuyang Sun, Rahul Sukthankar, Joëlle K. Barral, Raia Hadsell, Zoubin Ghahramani, Andrew Zisserman, Junlin Zhang, and Mehdi S. M. Sajjadi. Efficiently reconstructing dynamic scenes one D4RT at a time. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[94] Jiahui Zhang, Yurui Chen, Yueming Xu, Ze Huang, Yanpeng Zhou, Yu-Jie Yuan, Xinyue Cai, Guowei Huang, Xingyue Quan, Hang Xu, and Li Zhang. 4D-VLA: Spatiotemporal vision-language-action pretraining with cross-scene calibration. In *Advances in Neural Information Processing Systems*, 2025.

[95] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[96] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[97] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Tsung-Yi Lin, Gordon Wetzstein, Ming-Yu Liu, and Donglai Xiang. CoT-VLA: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[98] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[99] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[100] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3D-VLA: A 3D vision-language-action generative world model. In *International Conference on Machine Learning*, 2024.

[101] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *International Conference on Learning Representations*, 2025.

[102] Hongyan Zhi, Peihao Chen, Siyuan Zhou, Yubo Dong, Quanxi Wu, Lei Han, and Mingkui Tan. 3DFlowAction: Learning cross-embodiment manipulation from 3D flow world model. *arXiv preprint arXiv:2506.06199*, 2025.

[103] Gaoyue Zhou, Hengkai Pan, Yann LeCun, and Lerrel Pinto. DINO-WM: World models on pre-trained visual features enable zero-shot planning. In *International Conference on Machine Learning*, 2025.

[104] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics:*

*Science and Systems*, 2025.

[105] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

[106] Yifeng Zhu, Zhenyu Jiang, Peter Stone, and Yuke Zhu. Learning generalizable manipulation policies with object-centric 3D representations. In *Conference on Robot Learning*, 2023.

[107] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, 2023.

# 补充材料

本补充材料给出 SE(3)-WAM 的实现细节（附录 A）、在真实机器人数据上的预训练（附录 B）、基准（附录 C）、基线、外部基准、真机与计时（附录 D）、补充结果（附录 E）、支撑第 4.4 节的完整消融研究（附录 F），以及促成这一设计的误差分析（附录 G）。彩色破折号与方括号内容表示等待最终实验填写的数值。

# A 实现

## A.1 场景 token 与摘要 token

**当前图像。** 冻结的 MAE ViT-B/16 [26] 把 $224\times224$ 的主视角 RGB 编码为 196 个 patch token。我们在开发场景上将它与冻结的 DINOv3 编码器 [64] 以及与策略一同训练的 CNN 比较后选定了它（附录 F.1）。每个 patch 获得视角嵌入、其平均有效度量深度的线性嵌入，以及其中心像素反投影到基座坐标系后位置的线性嵌入；后者由相机内参与外参计算。这些位置也进入 patch query 与 key 的 3D 旋转位置编码。同样的中心点就是稀疏 3D 流的源点（附录 A.3）。目标、机器人、摘要和动作 token 不使用旋转位置编码。过去的图像从不进入模型，我们在主干之前删去其槽位，因此场景共有 212 个 token。

**目标运动历史。** 每次查询时，目标历史覆盖最近 8 个控制步，即偏移 $-350,-300,\ldots,0$ ms。8 个目标状态 token 各是一个 25 维描述子 $(\mathbf{p},\log R,\Delta\mathbf{p},\log\Delta R,\Delta t,\mathbf{v},\boldsymbol{\omega},\mathbf{a},\boldsymbol{\alpha})$，各分量维数为 $(3,3,3,3,1,3,3,3,3)$。槽位 0–6 描述相邻偏移之间的七个区间，槽位 7 存放基座坐标系下当前的绝对位姿。速度为区间位移除以经过的时间，加速度为相邻速度之差。我们用训练统计量对每一维标准化，把无效维置零，并附加三个有效性标志（位姿、区间与加速度），然后送入带时间嵌入的 $28\to1024\to1024$ GELU MLP。当位姿来源报告目标丢失时，用一个可学习嵌入代替该位姿。在仿真中，位姿来自仿真器；在真机上，位姿来自附录 A.2 的因果跟踪器，我们在相同偏移处对其轨迹重采样：平移线性插值、旋转沿测地线插值，不外推，也不跨越超过两个相机周期的空缺插值。

**机器人状态。** 相同偏移处的 8 个末端执行器状态（位置、旋转向量与测得的夹爪开度）构成机器人 token。

**摘要 token。** 16 个可学习嵌入构成世界流的摘要 token。它们在每一层读取场景 token 与彼此，并且是动作 token 能读取的唯一世界 token。

## A.2 位姿跟踪器

在真机上，SAM 2.1 的 Hiera-small 版本从第一帧中的一个框因果地传播目标掩码 [60]，该框由 Grounding DINO 根据指令中的物体短语给出 [45]。FoundationPose 使用其发布的权重，在全分辨率 RGB-D 帧（[640 × 480]）中配准并跟踪物体 [77]，物体模型为 CAD 模型或每个物体采集一次的 [16] 张带掩码参考视图。跟踪器在独立线程中运行，每个估计带有采集时刻、可用时刻与有效标志。配准失败、掩码内深度缺失，或相邻帧之间跳变超过 [X] mm 时，该标志为假。每个估计只输出一次，之后的帧不会修改它。表 S1 报告跟踪器在带动作捕捉真值的记录回合与 Dynamic-14 回放上的精度；这些结果也用于标定附录 F.2 的位姿噪声模型。

表 S1. **因果跟踪器精度。**输出位姿相对真值的中位数与 p95 误差、报告丢失的帧比例，以及使用各位姿来源时 SE(3)-WAM 在 Dynamic-14 留出集上的成功率（⋆：仿真主实验的设置；真机使用 FoundationPose）。

| 跟踪器 | mm | ° | 丢失 | SR |
|---|---|---|---|---|
| FoundationPose，全分辨率 | — | — | — | — |
| FoundationPose，224 × 224 | — | — | — | — |
| 仿真位姿（真值）⋆ | 0/0 | 0/0 | 0 | — |
| 真机，CAD 先验 | — | — | — | – |
| 真机，参考视图 | — | — | — | – |

## A.3 预测头

所有预测头都是世界流最终隐藏状态上的轻量读出。它们与动作一同训练，部署时被跳过，且没有任何 token 读取其输出，因此它们只通过损失塑造世界流。

**目标。** 一个 MLP 从目标状态 token 与摘要 token 的池化最终状态读出轨迹 $\{(\mathbf{d}_h, \boldsymbol{\phi}_h)\}_{h=1}^{8}$。记有效时域集合为 $\mathcal{V}$，

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h \in \mathcal{V}} \Big[ \|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\mathrm{SO}(3)}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{S1}$$

其中 $\lambda_R = 0.1$，$\hat{R}_h = \mathrm{Exp}(\hat{\boldsymbol{\phi}}_h^{\wedge}) R(\tau_t)$。我们使用左相对旋转向量与累计平移，而不使用 twist 指数映射，因为后者会通过其雅可比矩阵把平移与旋转耦合起来。该预测是条件均值，因此会对多模态的未来取平均（例如撞击发生之前的结果）。

**稀疏 3D 流。** 流是 $N = 196$ 个 patch 中心点在 8 个时域上的累计 3D 位移 $F \in \mathbb{R}^{N \times 8 \times 3}$，以基座坐标系表示，并附带可见性 $o \in \{0,1\}^{N \times 8}$。每个 patch token 上的线性读出给出其点在每个时域的位移与可见性 logit。我们用在训练标签上拟合的一个固定尺度对位移归一化，并使用

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h) \in \mathcal{V}_F} o_{ih} \big\| \hat{F}_{ih} - F_{ih} \big\|^2 + \mathrm{BCE}(\hat{o}, o), \tag{S2}$$

其中 $\mathcal{V}_F$ 为有效标签，因此被遮挡的点只监督其可见性。这些点同样覆盖目标、机器人与环境；目标的精度来自其位姿头。

**外观目标。** 最终 patch token 上的 patch 解码器在每个时域预测三个目标：其 patch 的度量深度（在有效深度上取平方误差）、冻结 DINOv3 ViT-L/16 教师 [64] 在 $14 \times 14$ 网格上经通道层归一化后的特征（平方误差），以及运动表面的 RGB（即移动超过 1 mm 的表面，包括机器人），在该掩码内取平方误差。当前 patch token 上的线性解码器重建目标当前框内的 RGB，使 patch 特征与目标关联而不增加输入。这四个目标各以 0.1 的权重计入 $\mathcal{L}_{\text{aux}}$。

## A.4 动作流

每个动作块有 8 条七维指令，每条包含基座坐标系下的平移增量、左相对旋转向量与夹爪指令，控制周期为 50 ms。归一化使用训练集中有效且不重复的已下发指令的均值与总体标准差。流匹配在这些坐标中使用单位高斯，每个动作块一个 $u$，动作 token 通过自适应层归一化接收 $u$。每个训练窗口为其动作块抽取 8 个独立的噪声样本并对其损失取平均，这在不扩大 batch 的情况下降低了动作梯度的方差。部署时，我们积分 5 个 Euler 步，反归一化，解码旋转向量，并把平移与旋转在每个轴上分别截断到 0.10 m 与 0.5 rad。夹爪跟随其指令的符号。

## A.5 主干与耦合

**主干。** 24 层中的每一层都用共享投影对全部 token 做一次注意力，随后世界 token 与动作 token 分别通过各自的前馈网络（比例 4）。世界 token 使用层归一化，动作 token 使用自适应层归一化，主干可训练参数共 504.0M。附录 F.1 中的替代方案在参数量匹配的条件下，为两条流分别设置注意力投影、归一化与前馈网络。

**注意力掩码。** 掩码作用于三组 token：场景（$\mathcal{S}$）、摘要 token（$\mathcal{M}$）与动作（$\mathcal{A}$）。场景与摘要 token 读取 $\mathcal{S}$ 和 $\mathcal{M}$，动作 token 读取 $\mathcal{M}$ 和 $\mathcal{A}$。被阻断的连接在每一层、每个注意力头上、训练与部署时都取 logit $-\infty$。由于世界 token 既不读取动作，也不读取流时间，它们的状态在每次查询中只计算一次，并在各 Euler 步之间复用；除了预测损失在共享参数上的梯度之外，没有任何未来标签能到达动作。

**消融中的耦合方式。** 第 4.4 节的变体使用相同的模块、初始化与损失，只改变掩码或加入一个小模块。R0 关闭所有预测损失。R1 在世界流中加入一个物体查询和每个 patch 一个查询，它们读取 $\mathcal{S}$、$\mathcal{M}$ 与彼此，并代替池化状态承载预测读出，但它们与动作之间不开启任何连接。R2 让动作 token 在每一层读取这些查询。R3 让这些查询读取动作，R4 同时开启两个方向；在 R3 和 R4 中，世界状态在每个 Euler 步都要重算。R5 在每次查询中解码一次预测，把目标轨迹、流及其可见性概率（旋转采用连续的 6D 表示）经几何编码器（0.37M 参数）编码为几何 token，动作在 $\mathcal{M}$ 之外还读取这些 token。R5 在预测出的几何上训练，并让动作损失经由它反向传播，不使用教师强制。所有变体都不在两条流之间截断任何梯度。

## A.6 训练配方

表 S2 列出在 Dynamic-14 上训练的配方。示范中的每个控制步都是一个查询窗口，11,200 条示范共给出 1,324,374 个训练窗口；另有 350 个留出回合作为验证集。每个损失按整个累积全局 batch 上的有效标签数归一化。冻结网络在每一步都运行：图像编码器处理当前帧，DINOv3 教师对未来帧的特征按回合缓存一次。一次训练在 [N] 块 RTX PRO 6000 GPU 上约需 [X] 小时。DROID 基座使用附录 B.4 的配方。

表 S2. Dynamic-14 上的训练超参数。

| 项目 | 取值 |
|---|---|
| 主干 | 24 层，宽度 1024，16 个注意力头，前馈 4096，504.0M 参数 |
| Token | 212 个场景、16 个摘要、8 个动作 |
| 编码器 | 冻结的 MAE ViT-B/16，输入 $224 \times 224$ |
| 优化器 | AdamW，$\beta = (0.9, 0.999)$，$\epsilon = 10^{-8}$，权重衰减 $10^{-4}$ |
| 学习率 | $2 \times 10^{-4}$，从 0 开始 5,174 次预热更新，余弦衰减到 0 |
| Batch 与更新 | 全局 batch 512 个窗口，20 轮（51,740 次更新） |
| 损失权重 | $\lambda_P = \lambda_F = 1$，$\lambda_R = 0.1$，每个辅助目标 $\lambda_{\text{aux}} = 0.1$ |
| 精度 | 可训练权重 FP32，冻结编码器 BF16，梯度截断 0.1 |
| 动作噪声 | 每个窗口 8 个噪声样本 |
| 采样 | 动作 5 个 Euler 步 |
| 推理 | FP16，查询内缓存世界状态 |
| 硬件 | [N] 块 RTX PRO 6000 GPU，每次训练约 [X] 小时 |

### A.7 部署

每次查询编码最新观测，运行一次不带预测头的世界流，并在缓存的世界状态上积分动作流。动作块一旦可用，第一条指令即执行；策略重新观测，并在该指令执行完毕后开始下一次查询。新动作块到达之前，执行器继续执行上一个动作块中剩余的指令。附录 C.3 描述所有方法共用的执行器，附录 D.4 描述计时方法。

## B 在真实机器人数据上预训练

### B.1 数据、划分与时间

预训练语料为 DROID [36]，以 15 Hz 用两个外部相机和一个腕部相机录制，并配有 PointWorld 为其发布的 3D 点轨迹与优化后的相机标定 [30]。我们要求关节序列、末端执行器位姿、夹爪状态、指令和相机身份完全一致，以此把每个发布片段与其原始 DROID 回合对应起来，并排除采集时钟不单调或对应关系有歧义的片段。在 42,935 个已对齐回合中，42,087 个形成训练窗口。模型使用第一个外部相机、其深度以及 PointWorld 对它的标定。训练单元是带有对齐的未来标签与动作标签的因果观测窗口，每个控制步一个，共 598,889 个。我们在任何过滤之前按原始标识符把回合划分为训练集与验证集，因此两者没有共同回合。表 S3 报告保留量与标签有效率。

**时间。** 所有时间都是采集时间戳，我们不把帧重新标注为名义帧率。机器人历史因果地使用查询时刻及之前最近的 8 个状态，与部署时一致。流标签保留 PointWorld 自身的记录时刻，而不插值到仿真模型的 50 ms 时域。未来 DINOv3 目标使用相同记录时刻的帧。

**动作。** 机器人状态与笛卡尔指令经标定的法兰到 TCP 变换后，以机器人基座坐标系表示，参数化方式同附录 A.4。若标签取值有限且其参考状态可因果地获得，我们就接纳该标签。机器人的执行限幅不作为接纳规则，因为逐轴限幅会丢弃快速但有效的运动，使基座偏向慢速示范。在 4,791,112 个动作槽位中，我们屏蔽 DROID 采集程序未下发指令的 149,318 个，保留其余 96.88%，不按幅度或速度过滤。动作与流的有效性相互独立，因此无效动作不会移除其窗口的流标签。

### B.2 基座学习什么

DROID 不提供物体位姿，其指令虽然提到被操作物体，却没有标出它。因此基座没有目标状态 token，也没有位姿头。它的输入是当前 RGB-D 帧与机器人历史，目标是动作损失、patch 中心点的稀疏 3D 流（权重 1）和未来 DINOv3 特征（权重 0.1）。未来深度、运动区域 RGB 与目标重建关闭。由于 PointWorld 的轨迹只记录可见位置，流标签中没有不可见的负例，因此我们把可见性损失设为零，而不是让模型学到“每个点始终可见”。DROID 中的大多数物体只在机器人移动它们时才运动，因此基座主要学习度量几何、机器人自身动作引起的 3D 运动及其与动作的耦合；我们任务中的外源运动和目标位姿在微调时才进入。

### B.3 流标签

PointWorld 的轨迹已在基座坐标系中表示。$14 \times 14$ 网格中的每个 patch 在整个窗口内跟随一条固定轨迹。在初始投影落在该 patch 内、初始可见且具有有效正深度的发布轨迹中，我们优先选择图像运动最大的一条；若其 3D 位移与图像运动不一致，则换成另一条候选。否则取离 patch 中心最近的轨迹。

表 S3. **DROID 预训练数据。**各阶段的保留量与标签有效率。窗口指带有对齐标签的因果观测窗口，主相机的每个控制步一个；流标签按点与时域计数。

| | 训练 | 验证 | 全部 |
|---|---|---|---|
| 已对齐的 episode | – | – | 42,935 |
| 形成窗口的 episode | 37,874 | 4,213 | 42,087 |
| 窗口 | 538,740 | 60,149 | 598,889 |
| 有效动作（%） | — | — | 96.88 |
| 有效流标签（%） | — | — | 47.05 |
| DINO 目标的未来帧 | — | — | 3,425,218 |
| 含物体运动的窗口（%） | — | — | — |

**图占位：图 S1——由 PointWorld 轨迹得到的流标签（示意）**

**左：**主外部相机的一帧 DROID 画面，旁边并列 PointWorld 优化后的相机位姿与原始位姿，以及14 × 14 的 patch 网格。**中：**每个 patch 中的候选 PointWorld 轨迹（细灰线）与选中的轨迹（橙色）：在三维上保持一致的轨迹中图像运动最大的那条，否则回退到离 patch 中心最近的轨迹；没有有效轨迹的 patch 置灰。**右：**选中轨迹在 PointWorld 记录时刻、基座坐标系下的 3D 位移，机器人夹爪路径为紫色。使用一段真实 DROID 帧序列，仅做矢量叠加。

图 S1. DROID 基座的流标签。每个图像 patch 跟随一条 PointWorld 轨迹，选择规则使其在存在运动物体时覆盖它们；该轨迹在基座坐标系中的 3D 位移即为标签。无效标签屏蔽其损失。

这一规则能覆盖固定中心点会错过的运动物体：在 10 个回合的 30 个片段中，有 18 个片段存在可见的物体运动；该规则在其中 13 个片段中把一条动态轨迹的起点与两个未来点都落在物体内部，而中心规则只有 5 个。这衡量的是与图像一致的运动覆盖，而不是实测的 3D 精度，小物体上的 patch 仍可能漂到背景上。标签是该轨迹在每个记录时刻相对其初始位置的位移。没有有效轨迹的 patch 记为无效，我们不用邻居填补。在全部窗口中，47.05% 的点—时域槽位带有有效标签。

**标签质量。** 我们在相同场景上把 PointWorld 轨迹与由二维对应 [54] 加单目度量深度 [75] 提升得到的流进行比较。在图像中静止的表面上，选中的 PointWorld 轨迹在各时域上的移动为 [0.9] 与 [5.8] mm（中位数与第 95 百分位），而用单目深度提升的流为 [18] 与 [72] mm，其尺度随时间漂移；因此我们使用 PointWorld 轨迹，不混入提升得到的流。PointWorld 的掩码不足以可靠地把物体与背景分开，因此我们不使用它们。

## B.4 配方与规模

**仿真模型。** SE(3)-WAM 从通用视觉初始化出发，按表 S2 的配方在 Dynamic-14 上训练。我们在宽度 1024 下于 12、24、48 层中选择其深度，并用训练样本数相同的短训练选择配方，均在开发场景上决定（图 S2a）。

**DROID 基座。** 基座采用同一架构族，宽度 1024、48 层（1.02B 可训练参数），只使用真实数据。它从头训练 20 轮（21,060 次更新，其中 2,106 次预热），全局 batch 为 512，使用 64 块 GPU，优化器与精度同表 S2。验证损失最低的检查点即为基座（图 S2b）。表 S4 的对照基座按 12 层的试点规模训练，并与相同规模和预算的世界—动作基座比较。

表 S4. **初始化的受控比较。**每行从各自的初始化出发微调真机策略（五个任务上的 SR，%），并用 10/100% 的 Dynamic-14 示范后训练仿真模型（留出 SR，%，三个后训练种子）。最后两列为各基座在 DROID 验证 episode 上的误差：最后一个时域相对 PointWorld 轨迹的流端点误差（mm），以及第一条指令的动作误差（归一化）。对照基座按试点规模预训练，并与相同预算的世界—动作基座比较（附录 B.4）。

| | 真机 | Dynamic-14 SR，示范比例 | | DROID 验证 | |
|---|---|---|---|---|---|
| 初始化 | SR | 10% | 100% | 流（mm） | 动作 |
| 仅通用视觉初始化 | — | — | — | – | – |
| 仅动作基座，试点规模 | — | — | — | – | — |
| 动作 + 流基座，试点规模 | — | — | — | — | — |
| 动作 + 流 + DINO 基座，试点规模 | — | — | — | — | — |
| 动作 + 流 + DINO 基座，48 层（真机基座） | — | — | — | — | — |

**图占位：图 S2——配方与规模**

**(a) 仿真模型。**纵轴：开发集 SR；横轴：样本量相同条件下的 12、24、48 层；星号标出选定配置。**(b) DROID 基座。**横轴：训练样本数（对数）；纵轴：最后一个时域的验证流端点误差（左轴，mm）与动作损失（右轴）；细线为试点规模，粗线为 48 层的训练；标记为选定的检查点。

图 S2. 仿真模型 (a) 与 DROID 基座 (b) 的配方与规模。

### B.5 微调与对照

每个真机策略从基座初始化，并只在其任务的示范上微调。基座所缺少的目标状态 token、位姿头与外观头以新的初始化加入，策略从附录 A.2 的跟踪器获得位姿。仿真权重不用于初始化任何真机策略，基座也不接触仿真数据。每个策略自行建立优化器、学习率调度、仅用于训练的归一化与读出头。不使用基座的参照从通用视觉初始化出发，在相同示范上微调，并在开发试验上进行相同的搜索（[三]个学习率与两种训练长度）和相同的评测。仿真中的受控比较用下游配方和与通用初始化相同的数据比例对各基座做后训练。仅动作对照用同一模型、关闭全部预测损失进行预训练，其余对照依次加入流与 DINO 目标（表 S4）。

## C Dynamic-14

### C.1 任务、角色与误差项

我们在 MuJoCo 与 robosuite [72, 105] 上构建了 Dynamic-14，它包含五个任务族中的 14 个任务（图 S3）。表 S5 列出其成功条件，表 S7 列出其场景取值范围。我们将发布这些任务、通过筛选的场景、成功判定与示范。

**角色与临界领先时长。** 表 S6 把每个任务中的物体分配到第 3.1 节的两种角色。目标是其位姿误差进入接触或容纳容差 $\varepsilon$ 的物体，环境由只需以间隙 $m$ 避开的物体组成。因此移动料箱是目标，因为它的位姿决定能否放入。穿越任务中的导线同时扮演两种角色：它在入口处的位姿是目标，因为棒必须在那里对准到 30 mm 以内；它沿环路的几何是环境，因为任何接触都会失败。该表还给出每个任务的速度及

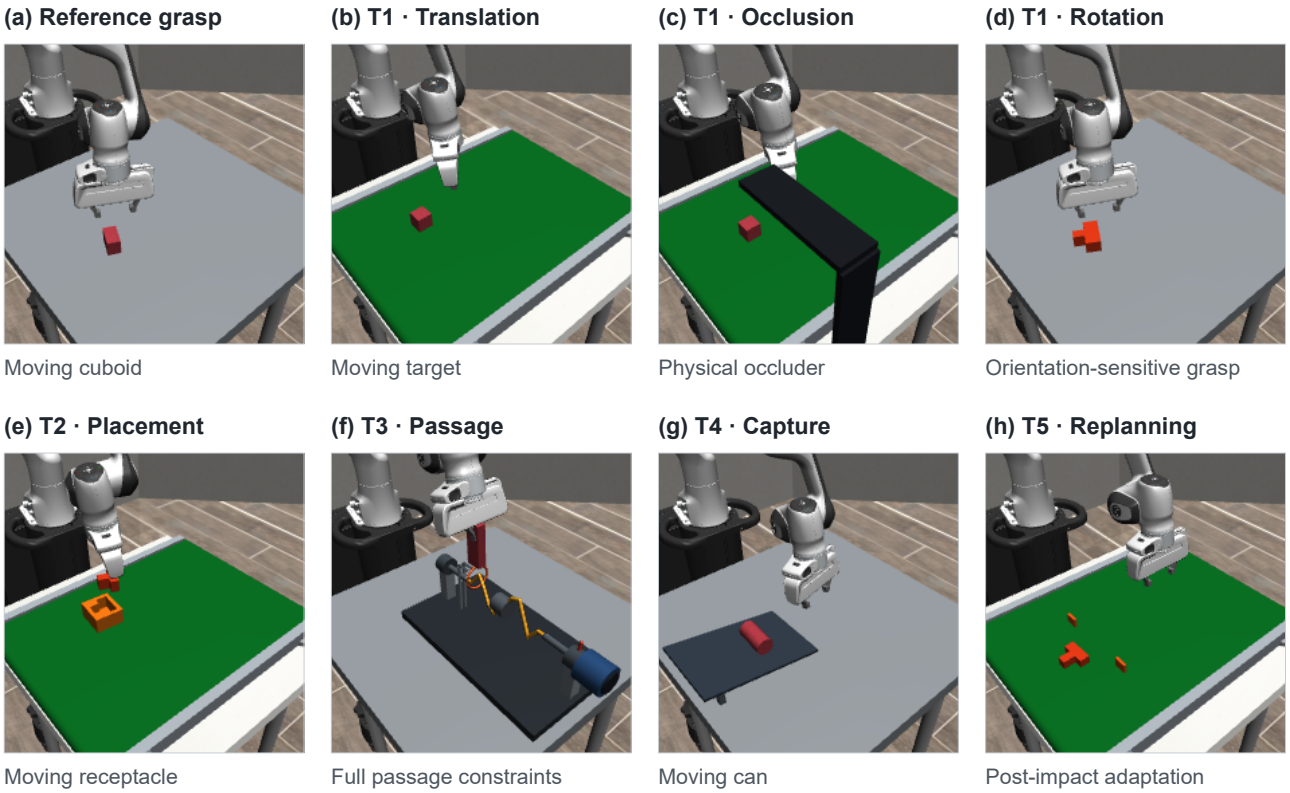



图 S3. Dynamic-14 的观测。八个示例涵盖参考抓取，抓取平移、被遮挡或旋转的目标，放入移动料箱，沿旋转导线穿越，捕获滚动物体，以及撞击后抓取。每个子图是一个开发集场景最后观测到的、未裁剪的 $224 \times 224$ 主视角 RGB。表 S5 列出全部 14 个任务。

其临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$（附录 G.5），最后一列列出每个任务涉及的误差项（式 3 与附录 G.2–G.3）。传送带与平移目标决定速度与领先时长；旋转目标、SE(3) 放置与导线使朝向进入接触；斜坡、低摩擦与撞击器产生外推无法预料的运动；遮挡物、导线、托盘与撞击器决定间隙，遮挡物还会去掉历史。

我们在每个 2 ms 的物理步、按表 S5 中要求的顺序检查成功，被中断的持续条件会重置其计数。终止事件分为五类，分别报告。*无效*事件是仿真器状态损坏。*边界*事件是离开工作空间或下游区域、掉落或目标时间窗过期。*安全*事件是不安全接触、过大的边缘冲量、触碰导线、释放冲量、机器人过早接触、无支撑的托盘接触或被撞击器卡住。*任务违规*是在目标外释放、路径偏离或倒退、过早释放、偏转而未捕获、倾倒、缺少或多出撞击，或出射运动改变不足。最后一类是*超时*。每个任务族在每个物理步按固定顺序检查其事件，并保留第一个终止事件。按任务等权的得分对每个任务赋予相同权重，包括某些方法从未成功的任务。

## C.2 场景与示范

我们对连续范围均匀采样，对离散选项等概率采样，然后进行物理可行性检查。评测回放存储下来的已通过场景。简谐平移遵循 $\mathbf{p}(t) = \mathbf{c} + (0, v_y, 0)t + (A_x \sin(2\pi f_x t + \phi), 0, 0)$，其中 $\phi \sim \mathcal{U}[-\pi, \pi]$。捕获任务的目标从静止开始，在 $[5, 15]^\circ$ 的斜坡上受重力与摩擦作用运动。只有当目标在开始时至少可见八帧、被完全遮挡 0.5–3.0 s、之后再次至少可见三帧时，我们才接受一个遮挡场景。

训练集包含 11,200 条示范，每个任务 800 条。它们由使用特权仿真器状态的专家生成，而学习型策略只接收第 3.2 节中的输入。我们以 20 Hz 记录示范，包含相机图像、深度、机器人状态、已发出的指令，以及目标位姿与场景几何的仿真真值，并据此计算未来标签、其有效掩码以及指令标签。策略从仿真器获得目标位姿，位姿噪声扫描会对其加入扰动（附录 C.3）。

表 S5. Dynamic-14 十四项任务的成功条件，阈值为我们任务实现中的取值。任务须依次通过各阶段，且不触发终止性失败。所有任务的控制频率为 20 Hz，物理仿真步长为 2 ms；下列时长均为物理时间。COM 表示质心。

| 任务 | 依次满足的成功条件 | 时限 |
|---|---|---|
| grasp; t1_belt, t1_xyz, t1_so3, t1_occ | 接近至 0.10 m 内；双侧指垫接触持续 0.05 s；碰撞几何体底部高于支撑面至少 0.05 m；接触与间隙保持 0.50 s。T1 分别加入传送带驱动、平移、旋转或实体遮挡物。SO3 无额外的成功角度阈值；OCC 中与遮挡物发生不安全接触即终止。 | 160 步<br>8 s |
| t2_trans | 接近至 0.10 m 内。物体的完整碰撞几何体位于容器内：平面间隙和底面间隙均 $\geq -0.002$ m，顶端不高于容器开口。释放要求张开指令 $< -0.5$ 且无指垫接触。相对线速度和角速度分别 $\leq 0.08$ m/s、0.8 rad/s，持续 0.10 s，随后稳定停留 0.50 s。 | 200<br>10 s |
| t2_se3 | 接近至 0.05 m 和 0.12 rad 内。完整纳入 T 形容器：平面间隙 $\geq 0.002$ m，底面间隙位于 $[-0.002, 0.002]$ m，倾角 $\leq 0.05$ rad，顶端低于开口。释放后，相对线速度和角速度分别 $\leq 0.02$ m/s、0.04 rad/s，持续 0.10 s，再停留 0.50 s。0.12 rad 阈值用于接近阶段。 | 200<br>10 s |
| t3_phase | 回合开始时杆已被抓住。相位对齐要求距离 $\leq 0.090$ m、环方向误差 $\leq 0.20$ rad。在进度 $\leq 0.15$ 时进入 0.030 m 范围；历史最大进度先达到 $\geq 0.60$，再达到 $\geq 0.85$，且距终点 $\leq 0.055$ m。 | 420<br>21 s |
| t3_full | 双侧接触持杆 0.05 s，然后完成上述相位阶段。在后续采样时刻，当前进度仍须 $\geq 0.85$，且离路径和终点均至少 0.045 m。最后张开夹爪（$< -0.5$）且无指垫接触。退出前释放判为失败。 | 640<br>32 s |
| t4_sphere | 接近至 0.10 m 内；首次合格接触须在离开斜坡后发生；成功前接触托盘即判为失败。双侧夹持的名义时长为 25 ms（12 个物理采样步，24 ms）。以首次达到双侧夹持条件时的高度为基准，将质心抬升 0.05 m，并保持接触和高度 0.50 s。 | 120<br>6 s |
| t4_sphere_tabletop; t4_slider | 接近至 0.10 m 内；接触须发生在离开斜坡后、仍受支撑、位于捕获区且平面速度 $\geq 0.08$ m/s 时。双侧夹持持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 $\geq 0.05$ m；随后保持接触和高度 0.50 s。 | 120<br>6 s |
| t4_can | 采用相同的受支撑捕获顺序。首次指垫接触前，若罐体轴线与竖直方向的点积绝对值 $> 0.45$，则按不稳定倾倒判为失败。配置不要求夹爪沿横向闭合。 | 120<br>6 s |
| t5_replan | 机器人接触前，所选侧恰有一个撞击组完成。在物理撞击结束时间戳后 30 ms，按分支方向取符号的横向速度 $\geq 0.035$ m/s，偏航角速度 $\geq 0.35$ rad/s。接近至 0.10 m 内；双侧夹持且抓取轴误差 $\leq 18°$，持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 $\geq 0.05$ m，并稳定夹持 0.50 s。撞击组时滞为 12 ms，最长接触时长为 0.10 s。 | 120<br>6 s |

## C.3 协议与扫描

**执行器。** 所有方法都在同一个 50 ms 控制时钟的异步执行器下运行。一条指令执行完毕且上一次推理结束后（取较晚者），方法再次被查询，因此速度足够快的方法会在每执行一条指令后重新规划。查询进行期间，执行器以每个控制周期一条的速度继续执行上一个动作块的剩余部分。新动作块替换这一剩余部分，并从下一个控制周期开始执行。若某个基线的原论文重规划频率更低，则在*原执行方式*协议下保留其自身的动作块长度。

**实时协议。** 除非另行说明，推理期间物理仿真按每次查询从该方法在一块 RTX 5090 上实测的延迟分布中采样的延迟推进（附录 D.4）。撞击后抓取任务本身还内置 50 ms 的指令延迟。表 S14 报告三种替代协议。在*暂停*协议下，仿真等待推理完成，许多仿真基准都是这样做的。在*等延迟*协议下，无论自身速度如何，每个方法都被计入相同的延迟，即 SE(3)-WAM 的 p95。在*原执行器*协议下，每个基线保留其论文中的执行方案。

表 S6. **Dynamic-14 各任务的角色、容差与临界领先时长。**目标是位姿误差进入接触或容纳容差 $\varepsilon$ 的物体；环境是只需以间隙 $m$ 避开的物体。速度取自表 S7 的采样范围（捕获任务取离开斜坡时的速度）；临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$ 按速度中位数给出。误差项：任务涉及的误差分解项。$v$：目标运动。$r\theta$：朝向影响接触。$e_{\text{dyn}}$：非匀速运动（谐波、重力、摩擦、撞击）。$m$：须避开某个环境物体。occ.：历史缺失。delay：任务内置的指令延迟。

| 任务 | 代号 | 目标 | 环境 | $\varepsilon$ (mm) | $\|\mathbf{v}\|$ (m/s) | $\Delta^\star$ (ms) | $m$ (mm) | 误差项 |
|---|---|---|---|---|---|---|---|---|
| 谐波抓取 | grasp | 物块 | 桌面 | [X] | 0.03–0.20 | [X] | – | $v$, $r\theta$, $e_{\text{dyn}}$ |
| 传送带抓取 | t1_belt | 零件 | 传送带 | [X] | 0.04–0.10 | [X] | – | $v$ |
| 平移抓取 | t1_xyz | 零件 | 桌面 | [X] | 0.04–0.15 | [X] | – | $v$, $e_{\text{dyn}}$ |
| 旋转抓取 | t1_so3 | 零件（$\omega \le 1.2$ rad/s） | 桌面 | [X] | 0.04–0.15 | [X] | – | $v$, $r\theta$, $e_{\text{dyn}}$ |
| 遮挡抓取 | t1_occ | 零件 | 遮挡罩 | [X] | 0.04–0.10 | [X] | [X] | $v$, $m$, occ. |
| 移动容器 | t2_trans | 容器 | 桌面 | [X] | 0.03–0.06 | [X] | – | $v$ |
| 旋转容器 | t2_se3 | T 形容器 | 桌面 | [X] | 0.03–0.06 | [X] | – | $v$, $r\theta$ |
| 导线穿越 | t3_phase | 导线环（入口） | 旋转导线 | 30 | [X] | [X] | 扫描 | $v$, $r\theta$, $m$ |
| 导线穿越（完整） | t3_full | 导线环（入口） | 旋转导线 | 30 | [X] | [X] | 扫描 | $v$, $r\theta$, $m$ |
| 小球捕获 | t4_sphere | 小球 | 托盘、斜坡 | [X] | [0.4–0.7] | [X] | [X] | $v$, $e_{\text{dyn}}$, $m$ |
| 小球捕获（桌面） | t4_sphere_tabletop | 小球 | 桌面、斜坡 | [X] | [0.4–0.7] | [X] | – | $v$, $e_{\text{dyn}}$ |
| 滑块捕获 | t4_slider | 滑块 | 桌面、斜坡 | [X] | [0.4–0.8] | [X] | – | $v$, $e_{\text{dyn}}$ |
| 罐体捕获 | t4_can | 罐体 | 桌面、斜坡 | [X] | [0.4–0.7] | [X] | – | $v$, $r\theta$, $e_{\text{dyn}}$ |
| 撞击后抓取 | t5_replan | 零件 | 撞击器 | [X] | 0.12–0.14 | [X] | [X] | $v$, $r\theta$, $e_{\text{dyn}}$, $m$, delay |

**延迟。** 在协议本身的延迟之外，推理后再插入 0、50、100、150 或 200 ms 的附加延迟，期间物理仿真继续推进。

**速度。** 场景中所有外部速度（传送带、料箱、导线以及简谐运动的速率）都乘以 $s \in \{0.5, 1, 1.5\}$。在某个系数下变得物理不可行的场景对所有方法都排除，我们报告剩余数量。

**间隙与网格分辨率。** 间隙扫描使用穿越任务，其导线是环境物体。棒的环与导线之间的自由间隙取 [X, X, X, X, X] mm，涵盖 $14^2$、$28^2$ 与 $56^2$ 流网格在工作空间中的间距（[X]、[X] 与 [X] mm），物体与运动保持不变。放置容差关乎目标精度（$\varepsilon$），不属于此扫描。

**位姿噪声。** 我们向目标位姿输入加入高斯噪声，其幅度按跟踪器的误差标定（表 S1），并按跟踪器的丢失率丢弃位姿（附录 F.2）。

**遮挡与静止。** 0.5、1、2 与 3 s 的遮挡以及一个无遮挡对照用于隔离历史空缺。静止目标变体冻结每个任务的外部运动，作为第 4.4 节的静态对照。

## C.4 数据划分与统计

所有设计决策都使用 1,400 个场景（每个任务 100 个）的开发集。我们在正文与本补充材料中报告的所有 Dynamic-14 数字都使用另外的 1,400 个留出场景；它们以相同的取值范围生成，使用不出现在任何训练、验证或开发回合中的新源种子。按种子递增顺序的前 100 个可行场景构成每个任务的集合。

最终模型、其消融以及表 3 中的变体使用训练种子 0、1 与 2。附录 F 中的筛选变体与各基线使用种子 0。在开发集场景上，同一配置的三个训练种子在 SR 上最多相差 [7.4] 个百分点。这一差异主要来自导线穿越任务，其成功率在不同种子之间从 [0] 到 [71]% 不等，因此我们不解读几个百分点的单种子差异。三个种子太少，无法重采样，因此我们先在每个场景上对种子取平均，再在每个任务内对留

表 S7. 场景的提议采样范围。除另有说明外，长度、线速度、角度和角速度的单位分别为 m、m/s、rad 和 rad/s。除注明的斜坡局部偏移外，位置均采用世界坐标。可行性检查前，连续区间内均匀采样，离散选项等概率采样。评测重放已存储的接受场景，其分布未必仍为均匀分布。谐波运动中心不等于初始位置。

| 任务 | 初态提议范围 | 运动或事件参数 |
|---|---|---|
| grasp | 谐波运动中心 $c_x \in [-.08, .08]$、$c_y \in [-.26, -.19]$、$z = .822$；偏航角 $[-1.1, 1.1]$。 | $v_y \in [.025, .125]$, $A_x \in [.015, .035]$, $f_x \in [.3, .7]$ Hz; $\omega_z \in [-1.2, 1.2]$. |
| t1_belt | 目标 $x \in [-.08, .08]$、$y \in [-.26, -.18]$、$z = .822$；姿态为单位旋转，初始 twist 为零。 | 传送带 $v_y \in [.04, .10]$。 |
| t1_occ | 目标提议范围同传送带任务；遮挡罩位于 $(.322, -.29, 1.20)$。 | 传送带速度范围相同；间隙参数为.20；实体遮挡。 |
| t1_xyz | 谐波运动中心 $c_x \in [-.025, .025]$、$c_y \in [-.24, -.20]$、$z = .818$；偏航角 $[-.35, .35]$。 | $v_y \in [.04, .09]$, $A_x \in [0, .03]$, $f_x \in [.25, .65]$ Hz; $\omega_z = 0$. |
| t1_so3 | 同 XYZ。 | 平移相同；$\omega_z \in [-1.2, -.4] \cup [.4, 1.2]$，正负等概率。 |
| t2_trans | 目标容器 $x \in [-.13, -.08]$、$y \in [-.18, -.12]$、$z = .825$；姿态固定。 | 目标容器 $v_y \in [.03, .06]$；无旋转。 |
| t2_se3 | 目标容器的 $x, y$ 范围相同，$z = .804$；偏航角 $[-.3, .3]$。 | 目标容器 $v_y \in [.03, .06]$；$\omega_z \in [-.25, -.08] \cup [.08, .25]$，正负等概率。 |
| t3_phase | 杆的位置 $x, y \in [-.03, .03]$、$z = .870$，偏航角 $[0, 2\pi]$；导线相位 $[-.25, .35]$。 | 导线中心 $(.10, -.02, .94)$；绕世界 X 轴旋转，$\omega_x = -\{2.5, 3, \ldots, 7.5\}°$/s（11 个等概率取值）。 |
| t3_full | 杆位于 $(-.05, -.02, 1.04)$，姿态为单位旋转；导线相位范围相同。 | 导线旋转相同；启用托架及释放要求。 |
| t4_sphere | 斜坡局部偏移：横向 $[-.015, .015]$，纵向 / 法向 $(-.145, .030)$；坡沿 $(.06, -.02, 1.10)$。 | 从静止开始由重力驱动；在 tick 0 释放闸门；坡度 $[5, 15]°$；目标 / 斜坡滑动摩擦系数 $[.7, .9]$；无支撑捕获。 |
| t4_sphere_tabletop | 横向 $[-.015, .015]$，纵向 / 法向 $(-.124, .034)$；坡沿 $(0, -.06, .808)$。 | 坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.7, .9]$，桌面摩擦系数.35。 |
| t4_slider | 横向 $[-.015, .015]$，纵向 / 法向 $(-.129, .024)$；受支撑斜坡。 | 坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.025, .045]$，桌面摩擦系数 $[.012, .018]$。 |
| t4_can | 横向 $[-.010, .010]$，相对斜坡轴线的偏航角 $[-4, 4]°$；纵向位置由闸门几何及罐体在该姿态下的包围范围确定。 | 坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.25, .45]$，桌面摩擦系数 $[.09, .15]$。 |
| t5_replan | $x \in [-.005, .005]$、$y = -.29$、$z = .812$；偏航角 $[-.08, .08]$；初始 twist 为零。 | 传送带 $v_y \in [.12, .14]$；在 $y = -.13$ 处等概率触发左 / 右撞击器；行程.098，脉冲.35 s，执行器缩放系数 $[1, 1.1]$，力上限 4 N；指令延迟 50 ms。 |

出场景做 bootstrap（各方法联合重采样），得到配对 95% 区间。区间落在 ±2 个百分点以内的差异视为持平。

## C.5 评测指标

按任务等权的成功率为

$$\mathrm{SR}(m) = \frac{1}{14} \sum_{k=1}^{14} \frac{1}{n_k} \sum_{i=1}^{n_k} y_{mki}, \tag{S3}$$

其中 $y_{mki}$ 是方法 $m$ 在任务 $k$ 的场景 $i$ 上的二值结果。一个场景的可行接触时间窗是满足任务第一个成功阶段的接触在运动学上可能发生的时刻集合，由目标真值轨迹与机器人可达工作空间计算。接触时刻误差是首次接触时刻到该时间窗的距离，在时间窗内为零。首次接触时的位置误差是该时刻末端到目标抓取坐标系的距离。两者都只在发生接触的回合上报告；没有接触的失败仍计入 SR 的分母，其接触误差记为缺失而不是零。碰撞统计安全事件。出动作时间是从观测到达到第一条指令可用的墙钟时间（附录 D.4），动作时龄是执行时刻减去采集时刻。

# D 基线、外部基准、真机与计时

## D.1 基线

**共同条件。** 表 S8 汇总各基线的适配。每个基线保留其官方架构、输入、动作块与初始化。ACT 与 Diffusion Policy 从头训练，$\pi_{0.5}$ 从 `pi05_base` 微调，其余方法从其发布的权重出发。它们都在相同的 11,200 条示范上训练，示范中的指令通过同一个笛卡尔控制器映射到各自的动作空间。Dynamic-14 除主视角外还渲染 $224 \times 224$ 的腕部相机，配方使用腕部视角的方法会获得该图像。SE(3)-WAM 与运动学基线只使用主视角。所有方法都在附录 C.3 的共享执行器与实时协议下运行，表 S14 另外给出它们原来的执行方式。

**训练。** 每个基线按官方配方训练到原论文的更新次数，只训练一次，种子为 0。我们只改动了数据读取与动作空间。对 DreamVLA，我们同时运行了其原始的 40 轮调度与 20 轮余弦调度，并报告在开发场景上更好的一个。相比之下，SE(3)-WAM 的配置由附录 F 的消融研究选出，这是基线所没有的搜索，而且其变体使用三个训练种子。

**输入。** PUMA [19] 接收在渲染帧上计算的历史光流。DreamVLA 接收七帧因果 RGB、末端执行器位置与朝向、手指位置和固定的任务文本，用十步 DDIM 和 1.5 的无分类器引导采样。OpenWAM-$\alpha$ 接收当前 RGB 视图、关节值、夹爪开度与任务文本，联合生成视频与动作，但不解码视频。DynamicWAM 接收其光流历史与运动学描述。

**加入 SE(3) 的基线。** $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.1 的八个目标状态 token，带有相同的有效标志与缺失状态嵌入。一个两层 MLP 把这些 token 映射到模型宽度。对 $\pi_{0.5}$，我们把它们附加在前缀中的图像 token 之后，动作专家会读取它们；对 DynamicWAM，它们并入其运动学描述。MLP 的输出层零初始化，因此训练从基础模型的行为出发，配方也沿用基础模型的配方。

**运动学基线。** *SE(3)-WAM*，匀速输入与 SE(3)-WAM 共享场景 token 和动作流，但没有预测损失；其动作流改为接收目标位姿在其动作块各执行时刻的匀速外推作为输入 token，并用相同数据和配方训练。附录 F.3 另有一个接收这些 token 且保留预测损失的变体。卡尔曼拦截器没有任何学习组件。匀加速卡尔曼滤波器 [5] 作用于目标位姿，过程噪声在开发场景上调节，并预测目标轨迹。拦截器选择在其实测延迟之后、手臂在速度限制下能到达的该轨迹上最早的点，沿专家的预抓取偏移接近，并在预测时刻闭合、释放或对准。它在每次查询时重新规划，并使用专家针对任务的抓取、放置与入口坐标系。

表 S8. **基线适配。**所有方法均在相同的 11,200 条示范上、以其原论文的输入训练，并在附录 C.3 的共享执行器下运行。更新数 × batch 沿用官方训练配方。Exec.：原论文的执行方式（重规划前每个动作块执行的指令数），仅用于表 S14 的原执行方式对照。参数量：可训练参数，不含冻结的编码器。Seeds：训练种子数。

| 方法 | 初始化 | 输入 | 更新数 × batch | 执行 | 参数量 | 种子 |
|---|---|---|---|---|---|---|
| ACT [99] | 从头训练 | 主视角 + 腕部 RGB、机器人状态 | 50,000 × 32 | 时间聚合 | [X] | 1 |
| Diffusion Policy [16] | 从头训练 | 主视角 + 腕部 RGB（原论文观测长度）、机器人状态 | 50,000 × 32 | 8 | [X] | 1 |
| $\pi_{0.5}$ [57] | `pi05_base` | 当前主视角 + 腕部 RGB、机器人状态、任务文本 | 30,000 × 256 | 10 | [X] | 1 |
| $\pi_{0.5}$ + SE(3) | `pi05_base` | 同 $\pi_{0.5}$ + SE(3) 运动 token | 30,000 × 256 | 10 | [X] | 1 |
| DynamicVLA [82] | 发布的 DOM 检查点 | 帧 $[-2, 0]$、机器人状态、任务文本 | 50,000 × 44 | 流式 | [X] | 1 |
| PUMA [19] | 官方检查点 | RGB、光流历史、机器人状态、任务文本 | [X]×[X] | [X] | [X] | 1 |
| DreamVLA [95] | 发布的组件 | 七个因果主视角 + 腕部 RGB 帧、机器人状态、任务文本 | 48,220 × 512 | 1 | [X] | 1 |
| OpenWAM-$\alpha$ [76] | 官方基础模型 | 当前主视角 + 腕部 RGB、关节、夹爪、任务文本 | 34,490 × 192 | 32 | [X] | 1 |
| DynamicWAM [50] | 官方初始化 | RGB、光流历史、运动学描述 | 40,000 × 128 | 16 | [X] | 1 |
| DynamicWAM + SE(3) | 官方初始化 | 同 DynamicWAM + SE(3) 运动 token | 40,000 × 128 | 16 | [X] | 1 |
| SE(3)-WAM，匀速外推输入 | 同 SE(3)-WAM | 同 SE(3)-WAM，另加匀速外推 token，无预测损失 | 同 SE(3)-WAM | – | [X] | 3 |
| 卡尔曼拦截器 | 无 | SE(3) 历史、专家抓取坐标系 | – | – | – | – |
| SE(3)-WAM | 冻结的 MAE 编码器 | 当前主视角 RGB-D、SE(3) 历史、机器人状态 | 51,740 × 512 | 1 | 523.8M | 3 |

## D.2 DOMINO 与 LIBERO

DOMINO [19] 包含两种交互类型（拦截与跟踪）、三个动力学等级（匀速、多项式轨迹、带突变的随机分段）的 35 个任务。我们在干净设置下、以 [0.1] 的速度系数，在全部三个等级上使用其中 [N] 个 Franka 单臂任务，使用官方示范与基准自带的评测器，每个任务和训练种子运行 100 个闭环回合。我们报告 SR 与 DOMINO 的操作得分（MS）；MS 用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度。在 LIBERO [44] 上，我们使用 Spatial、Object、Goal 与 Long 四个套件（各十个任务），每个任务评测 50 个回合，本文各变体三个训练种子、基线一个，并使用发布的示范与初始状态。LIBERO 用来检验按角色区分精度的预测不会损害静态任务的性能。在两个基准上，SE(3)-WAM 都从与 Dynamic-14 相同的通用初始化出发训练，并使用各自领域的归一化。与在 Dynamic-14 上一样，它从仿真器读取指令最先作用的物体的位姿；没有有效位姿的查询（LIBERO 上 [XX]%，DOMINO 上 [XX]%）使用附录 A.1 的缺失状态嵌入。该位姿是基线所没有的特权信息，因此表 S9 还报告了加入按跟踪误差标定的位姿噪声后的 SE(3)-WAM 。SE(3)-WAM 在 DOMINO 上达到 [XX.X]%，[DOMINO 上最强基线] 为 [XX.X]%；在 LIBERO 上它与 $\pi_{0.5}$ 相差不超过 [X.X] 个百分点。

## D.3 真机

**平台。** 机器人是带平行夹爪的七自由度 Franka 机械臂，通过带时间戳的笛卡尔接口以 20 Hz 控制（图 S4）。一台固定的 [RealSense D435] 以 [640 × 480] 与 [30] Hz 录制 RGB-D，每次采集前用棋盘格标定其外参。SE(3)-WAM 使用该第三人称视角；$\pi_{0.5}$ 按其配方还接收腕部第二个相机的图像。

**任务与成功判定。** 五个任务涵盖三种目标运动：直线运动（[T1、T2]）、圆周运动（[T3、T4]）和加速运动（[T5]）。[对每个任务说明驱动目标的装置、速度范围、物体与成功条件，例如两指稳定夹持物体并将其提起至少 0.5 s。] 触碰或推动目标、单指夹持，以及目标离开工作空间之后的动作，都算作失

表 S9. **外部基准**（本文各变体三个训练种子，基线一个）。DOMINO：单臂任务按交互类型与动力学等级（L1 匀速、L2 多项式轨迹、L3 含突变的随机分段）分列的 SR（%），以及操作得分 MS；LIBERO：各套件 SR（%）。

| | DOMINO | | | | | | LIBERO | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 方法 | 拦截 | 跟踪 | L1 | L2 | L3 | MS | 空间 | 物体 | 目标 | 长程 | 平均 |
| ACT | — | — | — | — | — | — | — | — | — | — | — |
| Diffusion Policy | — | — | — | — | — | — | — | — | — | — | — |
| $\pi_{0.5}$ | — | — | — | — | — | — | — | — | — | — | — |
| $\pi_{0.5}$ + SE(3) | — | — | — | — | — | — | — | — | — | — | — |
| DynamicVLA | — | — | — | — | — | — | — | — | — | — | — |
| PUMA | — | — | — | — | — | — | — | — | — | — | — |
| DreamVLA | — | — | — | — | — | — | — | — | — | — | — |
| OpenWAM-$\alpha$ | — | — | — | — | — | — | — | — | — | — | — |
| DynamicWAM | — | — | — | — | — | — | — | — | — | — | — |
| DynamicWAM + SE(3) | — | — | — | — | — | — | — | — | — | — | — |
| SE(3)-WAM，匀速外推输入 | — | — | — | — | — | — | — | — | — | — | — |
| SE(3)-WAM，含噪位姿 | — | — | — | — | — | — | — | — | — | — | — |
| SE(3)-WAM | — | — | — | — | — | — | — | — | — | — | — |

**图占位：图 S4——真机设置**

**左**：工作单元照片：带夹爪的 Franka 机械臂、固定的第三人称 RGB-D 相机、腕部相机，以及驱动目标运动的装置（[传送带、转台、斜坡]），并画出基座坐标系。**右**：每个任务在第一条指令时刻的一帧，标注目标的运动类型（直线、圆周、加速）以及按实测延迟计算的 $\|\mathbf{v}\|\Delta$。

图 S4. 真机设置：工作单元与五个任务。

败。我们在每组试验开始和结束时测量每个运动装置的速度，偏离名义值超过 5% 的试验重做，并记为设备故障。

**试验。** 每个方法在每个任务上运行 [20] 次试验。所有方法使用相同的预生成试验键，试验键确定物体实例、速度与起始位姿，起始位姿从标定的可达区域中采样。一个策略看不到的外部夹具设置并记录起始位姿。每个任务的试验以随机顺序运行，使装置的漂移不会与方法对齐。操作员手动重置场景。试验从第一个可用观测开始，没有额外的观察期，机器人随时可以运动。人员接触、安全停止和人工完成都算作失败。第一个可用观测之前的基础设施故障会重做并报告。测试试验使用未出现在任何示范中的物体实例，示范、开发试验与测试试验来自不同的采集批次。

**微调。** SE(3)-WAM 从 DROID 基座出发，在每个任务的 [N] 条遥操作示范上微调（附录 B.5）。不使用基座的参照从通用初始化出发，使用相同的示范与搜索；$\pi_{0.5}$ 与 DynamicWAM 从其发布的权重出发，在相同示范上微调。跟踪器使用 [每个物体的 CAD 模型或参考视图]（表 S1）。

**分析。** 我们以装置编码器计算的可行接触窗口为参照测量接触时刻误差，未接触的失败仍计入 SR 的分母。表 S10 报告每个任务的成功次数、合并成功率的 95% 二项区间，以及按试验键自助法得到的配

表 S10. **真机成功次数**，按任务分列（每个任务 [20] 次），并按目标运动类型分组。All：每个方法全部试验的成功率（%）及 95% 二项分布区间。Δ：相对 SE(3)-WAM 的配对差值（百分点）及按试验键自助法得到的区间。$e_t$：发生接触的试验中接触时刻误差的中位数（ms）。

| | 直线 | | 圆周 | | 加速 | | | |
|---|---|---|---|---|---|---|---|---|
| 方法 | [T1] | [T2] | [T3] | [T4] | [T5] | All | Δ | $e_t$ |
| $\pi_{0.5}$ | — | — | — | — | — | — | — | — |
| DynamicWAM | — | — | — | — | — | — | — | — |
| SE(3)-WAM，无 DROID 基座 | — | — | — | — | — | — | — | — |
| SE(3)-WAM | — | — | — | — | — | — | – | — |

表 S11. **单次查询的延迟分解**（SE(3)-WAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

| 阶段 | p50 | p95 |
|---|---|---|
| 位姿跟踪（每帧，真机） | — | — |
| 图像编码 | — | — |
| 世界流（每次查询一次） | — | — |
| 动作流（5 个 Euler 步） | — | — |
| 出动作时间（合计） | — | — |
| 预测头（仅训练，供参考） | — | — |
| 执行时的动作年龄（真机） | — | — |
| 超时比例（真机，%） | — | |

对差值。评测共用了 [X] 天。SE(3)-WAM 的失败大多是 [夹爪下跟踪丢失之后的迟闭合]。

### D.4 计时

我们在一块 RTX 5090（32 GB，即机器人部署所用的 GPU）上为所有方法计时。每个方法先预热三十次调用，再在三段各八帧的观测序列上测量 300 次调用；调用边界处做 CUDA 同步，按轮换的方法顺序进行三轮，每个方法使用其发布版本的精度。出动作时间包括图像编码与生成第一条指令，在真机上还包括跟踪最新一帧。对 SE(3)-WAM，我们另外记录预测头的耗时，尽管部署时跳过它们。表 1 给出 p95 值，表 S8 给出参数量。在真机上，日志记录采集、可用、预处理、推理开始与结束、进入队列、指令下发与执行等时刻。动作年龄为执行时刻减去采集时刻，我们报告其 p50、p95 与最大值，以及超时比例和峰值显存（表 S11）。Dynamic-14 的延迟扫描与实际部署不同：它在物理仿真继续推进的同时插入规定的延迟。

## E 补充结果

### E.1 逐任务结果与回合结局

表 S12 把表 1 中 Dynamic-14 的留出结果按任务拆分到每个方法，并给出 SE(3)-WAM 在每个任务上相对最强其他方法的配对区间。表 S13 报告回合如何结束。一个方法若以一种失败换另一种失败，例如以更少的碰撞换来更多的超时，只能在这里看出来。所有失败都留在成功率的分母中。

### E.2 协议与延迟

表 S14 在另外三种协议下评估每个方法。暂停物理仿真去除了计算的代价。等延迟协议向每个方法计入 SE(3)-WAM 的 p95 延迟，从而把方法的速度与其利用时间的方式区分开。原执行器协议检验我

表 S12. **Dynamic-14 各任务的留出成功率**（%），涵盖表 1 中的全部方法，本文各变体取三个训练种子的平均、基线训练一次，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。DrVLA：DreamVLA。OWAM：OpenWAM-$\alpha$。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。CV：匀速外推输入的 SE(3)-WAM 。KF：卡尔曼拦截器。$\sigma$：使用按跟踪误差标定的含噪位姿的 SE(3)-WAM 。Δ：该任务上 SE(3)-WAM 相对最强其他方法之差及其 95% 配对区间。任务代号见表 S6。

| 任务 | ACT | DP | $\pi_{0.5}$ | $\pi_{0.5}$+ | DVLA | PUMA | DrVLA | OWAM | DWAM | DWAM+ | CV | KF | $\sigma$ | 本文 | Δ [95% CI] |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 谐波抓取 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 传送带抓取 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 平移抓取 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 旋转抓取 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 遮挡抓取 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 移动容器 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 旋转容器 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 导线穿越 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 导线穿越（完整） | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 小球捕获 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 小球捕获（桌面） | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 滑块捕获 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 罐体捕获 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 撞击后抓取 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |
| 任务等权 | — | — | — | — | — | — | — | — | — | — | — | — | — | — | — |

们的共享执行器是否使某个方法处于不利地位。在暂停物理仿真时，SE(3)-WAM 与 [DreamVLA] 的差距为 [±X.X] 个百分点，在等延迟下为 [±X.X] 个百分点。原执行器使各基线的 SR 至多变化 [X.X] 个百分点。表 S15 给出扫描中每个附加延迟下的成功率，其中 SE(3)-WAM 与最强基线的两行即图 1（右）的数据。

### E.3 负面与无差异结果

**视觉历史。** 表 S17 中的八种视觉历史没有一种比只用当前帧高出两个百分点以上。其中 [N] 种的区间落在 ±2 个百分点以内，[N] 种无定论，包括带度量位置的 RGB-D 窗口。冻结读出能从这些历史中恢复过去的目标位置，误差为 [X]–[X] mm，而 SE(3) 历史为 [X] mm。因此信息是存在的，但在我们的数据规模下，策略没有把它转化为度量运动。更大的数据集或专门的运动目标可能会改变这一点。

**图像空间的未来。** 作为预测目标，表 S20 中没有任何图像空间的未来（场景轨迹、稠密位移、编解码器运动向量、视频隐变量、冻结视频模型、深度、DINO 或动态 RGB）比不带环境流的目标 SE(3) 轨迹高出 [X.X] 个百分点以上。它们的目标函数对像素或隐变量维度加权，而容差取决于度量误差。作为仅用于训练的目标加在按角色区分的预测旁边时，深度、DINO 特征与运动区域 RGB 带来 [X.X] 个百分点。因此，外观作为辅助目标是有帮助的，但不能替代度量预测。

**环境分辨率。** 在粗粒度流的路径误差之上，$28^2$ 与 $56^2$ 网格以及物体采样的流与 $14^2$ 网格相差在两个百分点以内，代价却高达其 [X] 倍；它们的优势只限于最窄的间隙。

**耦合方式。** 让动作读取世界查询（R2）、让世界读取动作（R3）、双向读取（R4）或让动作读取解码出的预测（R5），在任何延迟下都没有稳定地优于 SE(3)-WAM （表 S23），而且每一种都使出动作时间

表 S13. **结局类别**：Dynamic-14 留出场景（各类 episode 占比，%，种子平均，实时协议）。类别定义见附录 C.1；每行合计为 100。

| 方法 | 成功 | 安全 | 任务违规 | 边界 | 超时 | 无效 |
|---|---|---|---|---|---|---|
| ACT | — | — | — | — | — | — |
| Diffusion Policy | — | — | — | — | — | — |
| $\pi_{0.5}$ | — | — | — | — | — | — |
| $\pi_{0.5}$ + SE(3) | — | — | — | — | — | — |
| DynamicVLA | — | — | — | — | — | — |
| PUMA | — | — | — | — | — | — |
| DreamVLA | — | — | — | — | — | — |
| OpenWAM-$\alpha$ | — | — | — | — | — | — |
| DynamicWAM | — | — | — | — | — | — |
| DynamicWAM + SE(3) | — | — | — | — | — | — |
| SE(3)-WAM，匀速外推输入 | — | — | — | — | — | — |
| 卡尔曼拦截器 | — | — | — | — | — | — |
| SE(3)-WAM，含噪位姿 | — | — | — | — | — | — |
| SE(3)-WAM | — | — | — | — | — | — |

增加 [X.X] 到 [X.X] ms。在同一网络中关闭预测损失（R0）损失 [X.X] 个百分点，因此增益来自对摘要 token 所表示内容的监督，而不是来自读取预测。

**未解决的任务。** 放入旋转料箱的 SE(3) 放置任务（t2_se3）对所有方法都失败（表 S12）。[策略能到达料箱，但在它转开之前达不到其角度容差。]SE(3)-WAM 的任何变体都没有解决完整的导线穿越任务（t3_full），该任务在穿越之外还要求抓取与释放棒，而 [OpenWAM-$\alpha$] 在其中 [XX]% 的回合中成功。在以已抓住棒开始的穿越任务（t3_phase）上，SE(3)-WAM 的成功率在不同训练种子之间从 [0] 到 [71]% 不等。

**其他失败。** 图 S6a 中的曲线聚合在捕获任务上最弱（Spearman $\rho = [X.XX]$），因为这些任务的成功还取决于夹爪何时合拢；噪声交叉点位于无模型 $\sigma^\star$ 的 [X.X] 倍处。撞击后抓取从预测损失中获益最少（相对 CV 输入 [X.X] 个百分点），因为条件均值无法表示撞击的各种结果。按跟踪误差标定的位姿噪声损失 [X.X] 个百分点，主要在对称与细长的目标上。SE(3)-WAM 的其余失败大多是 [例如首次抓取失手后的超时]（表 S13）。

## E.4 执行时刻的预测

图 S5 把查询、预测、真值、发出的动作与首次接触按物理时间戳对齐。这些示例展示预测误差在何处出现——例如撞击的瞬间或滚动物体离开斜坡时——以及它们如何转化为接触时刻与位姿误差。

## E.5 补充视频

补充视频展示 SE(3)-WAM 与最强基线在全部五个真机任务上的试验（叠加跟踪位姿）、每个任务族的一组 Dynamic-14 回合（叠加训练期预测头的预测），以及第 4.3 节讨论的失败案例。

表 S14. **评测协议对照**：Dynamic-14 留出场景（SR，%）。暂停：推理期间物理暂停，各方法使用其原论文的执行方式。等延迟：共享执行器，所有方法均计入 SE(3)-WAM 的 p95 延迟。原执行方式：实时协议下使用各方法自身的执行方式。实时：表 1 的协议。丢弃：实时协议下因过时而被丢弃的指令比例（%）。

| 方法 | 暂停 | 等延迟 | 原执行执行器 | 实时 | 丢弃 (%) |
|---|---|---|---|---|---|
| ACT | — | — | — | — | — |
| Diffusion Policy | — | — | — | — | — |
| $\pi_{0.5}$ | — | — | — | — | — |
| $\pi_{0.5}$ + SE(3) | — | — | — | — | — |
| DynamicVLA | — | — | — | — | — |
| PUMA | — | — | — | — | — |
| DreamVLA | — | — | — | — | — |
| OpenWAM-$\alpha$ | — | — | — | — | — |
| DynamicWAM | — | — | — | — | — |
| DynamicWAM + SE(3) | — | — | — | — | — |
| SE(3)-WAM，匀速外推输入 | — | — | – | — | — |
| 卡尔曼拦截器 | — | — | – | — | — |
| SE(3)-WAM，含噪位姿 | — | — | – | — | — |
| SE(3)-WAM | — | — | – | — | — |

**图占位：图 S5——与实际发生对齐的预测**

**第 1–4 行**：每种运动类型（传送带、旋转目标、滚动捕获、撞击后）预测误差居中的留出回合；**第 5 行**：一次失败。**列**：$\tau_t$ 处的查询帧；首条指令执行时刻 $\tau^{\mathrm{a}}$ 处的帧；基座坐标系中的 3D 插图。**叠加**：蓝色过去的 SE(3) 位姿；橙色 $\tau_t + \delta_h$ 处预测的目标坐标轴与稀疏流箭头（读自训练期预测头）；灰色同一物理时刻的真值位姿；紫色发出的夹爪轨迹；首次接触处的标记。每行下方的条带画出学习的 SE(3)、匀速与匀加速预测的平移与旋转误差随时域的变化。用红色标注第 5 行的失败原因。

图 S5. 训练期预测头在留出回合上的预测，在物理时间上与真值和发出的动作对齐。第 1–4 行为每种运动类型预测误差居中的回合，第 5 行为一次失败。

表 S15. **成功率随附加延迟的变化：**Dynamic-14 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的 All 与 +150 ms 列。斜率：SR 对附加延迟的最小二乘斜率（每 100 ms 的百分点）。

| | 附加延迟（ms） | | | | | |
|---|---|---|---|---|---|---|
| 方法 | 0 | 50 | 100 | 150 | 200 | 斜率 |
| ACT | — | — | — | — | — | — |
| Diffusion Policy | — | — | — | — | — | — |
| $\pi_{0.5}$ | — | — | — | — | — | — |
| $\pi_{0.5}$ + SE(3) | — | — | — | — | — | — |
| DynamicVLA | — | — | — | — | — | — |
| PUMA | — | — | — | — | — | — |
| DreamVLA | — | — | — | — | — | — |
| OpenWAM-$\alpha$ | — | — | — | — | — | — |
| DynamicWAM | — | — | — | — | — | — |
| DynamicWAM + SE(3) | — | — | — | — | — | — |
| SE(3)-WAM，匀速外推输入 | — | — | — | — | — | — |
| 卡尔曼拦截器 | — | — | — | — | — | — |
| SE(3)-WAM，含噪位姿 | — | — | — | — | — | — |
| SE(3)-WAM | — | — | — | — | — | — |

# F 完整的消融研究

本附录列出我们在设计 SE(3)-WAM 时比较过的所有变体，包括表 3 中未列出的变体。每组比较只改变一个设计轴，其他轴保持在选定配置，所有变体使用相同的场景与推理种子。我们在缩小的规模上筛选变体：把 24 层的模型换成宽度 768 的 4 层模型，训练 4 轮（全局 batch 16 下 40,104 次更新），使用一个训练种子，所有选择决策都在开发集上做出。表 3 的各行使用最终模型与配方（附录 A.6）。各表报告留出场景上的结果。编码器与耦合方式的比较，以及同时出现在表 3 中的行，取三个训练种子的平均，其余行使用一个种子。整个研究共约 [XXXX] GPU 小时的训练与 [XXXXXX] 个评测回合。

**选择规则。** 候选方案必须在部署精度下保持 p95 出动作时间低于 200 ms、峰值显存低于一块 RTX 5090 的 80%。由于单个种子之间相差数个百分点（附录 C.4），只有当候选方案在开发集上用种子 0 提升超过 3 个百分点、并在种子 1 与 2 上保持提升时，我们才替换参考配置；否则保留更便宜或更简单的变体。

## F.1 共享组件

观测编码器与仅用于训练的外观目标为所有比较所共享，我们首先确定它们。我们在开发集场景上比较了与策略一同训练的 CNN、冻结的 DINOv3 ViT-S/16 与 ViT-L/16 [64] 以及 MAE ViT-B/16 [26] 编码器（表 S16）。冻结的 MAE 编码器三个种子的均值最高，为 [66.8]%，但其各种子在 [63.7] 到 [71.1]% 之间，与 DINOv3 编码器有重叠。我们因为这一均值以及它比 ViT-L/16 更便宜而选择了它。DINOv3 ViT-L/16 特征仍是未来外观目标之一，我们将其与世界表示一同选定（附录 F.3）。

## F.2 历史

**条件设置。** 每种条件都接收当前图像、当前目标位姿、八个机器人状态、选定的预测目标与选定的耦合方式。各条件只在保留过去 350 ms 中的哪些信息上不同。RGB 窗口保留七帧过去图像，每帧 196 个图像块，每 50 ms 采样一次，不做压缩。光流是在 $64 \times 64$ RGB 上、覆盖同一 350 ms 窗口的四个区间（100、100、100 与 50 ms）上计算的双向 Farnebäck 光流 [20]，带前向—后向有效性检查；“光流 + 运动统计” 附加 DynamicWAM [50] 每个区间的十二个物理统计量。编解码器运动向量来自真实的 MPEG-4 P 帧运动向量，编码方式与光流相同；视频隐变量是冻结 Wan2.2 VAE 的后验均值，由 56 个可学习查询读取。压缩窗口用八个共享查询读取过去的帧，或均匀分配，或按 PACT-WAM [48] 的分配给更新的帧更多查询。RGB-D 窗口为每个过去的图像块加入度量位置，检验缺失的是否是度量几何而非运动。在 SE(3) 变体中，仅位置的历史去掉朝向，含噪历史用下文位姿噪声扫描中按跟踪器标定的噪声扰动过去的位姿。最后一个对照从 RGB 窗口中去掉当前目标位姿，测量当前位姿本身的贡献。

**冻结读出。** 为区分历史编码包含的信息与策略使用的信息，我们在三个位置的冻结特征上拟合岭回归读出：历史编码器的输出、最终的目标状态 token，以及第一次函数求值时动作头的输入。标签为过去 50、200 与 350 ms 时的目标位置、最后一个区间的速度，以及 400 ms 时的未来位移，均在基座坐标系中表示。每个任务分别把 60、20 与 20 个不同的开发集回合分配给训练、验证与测试，每个回合取五个窗口。我们在验证误差上从 $\{0.1, 1, 10, 100\}$ 中选择惩罚系数，打乱标签的对照给出随机水平的界。条件读出先由当前图像、几何、机器人状态与当前位姿拟合基线，再用该位置的特征预测其残差，以检验历史在当前信息之外增加了什么。

表 S16. **观测编码器**（留出场景，三个训练种子），其余组件均为选定配置（⋆：采用）。参数量为编码器参数；p95 出动作时间在一块 RTX 5090 上测得。

| 编码器 | 参数 | 训练 | SR | $SR_{150}$ | p95 |
|---|---|---|---|---|---|
| CNN | — | 是 | — | — | — |
| DINOv3 ViT-S/16 | 22M | 冻结 | — | — | — |
| DINOv3 ViT-L/16 | 300M | 冻结 | — | — | — |
| MAE ViT-B/16⋆ | 86M | 冻结 | — | — | — |

表 S17. **历史：完整比较**（留出场景；一个训练种子，同时出现在表 3 中的行为三个种子）。所有条件均保留当前图像、当前目标位姿（最后一行除外）、机器人历史、选定的未来表示与选定的耦合方式。SR（%）按附加延迟分列；readout：冻结岭回归对 350 ms 前目标位置的读出误差（mm，越低越好）；$\delta a$：重复过去输入时首个动作平移的变化（mm）；tokens：新增历史 token 数；p95：出动作时间（ms）。

| | 不同附加延迟下的 SR（ms） | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 历史 | 0 | 50 | 100 | 150 | 200 | 读出 | $\delta a$ | Token | p95 |
| 仅当前帧 | — | — | — | — | — | — | 0 | 0 | — |
| RGB 窗口 | — | — | — | — | — | — | — | 1,372 | — |
| RGB-D 窗口 | — | — | — | — | — | — | — | 1,372 | — |
| 光流 | — | — | — | — | — | — | — | 60 | — |
| 光流 + 运动统计 | — | — | — | — | — | — | — | 60 | — |
| 编码器运动向量 | — | — | — | — | — | — | — | 56 | — |
| 视频 VAE 隐变量 | — | — | — | — | — | — | — | 56 | — |
| 压缩窗口（按时间分配） | — | — | — | — | — | — | — | 56 | — |
| 压缩窗口（均匀分配） | — | — | — | — | — | — | — | 56 | — |
| SE(3) 历史 ⋆ | — | — | — | — | — | — | — | 8 | — |
| SE(3) 历史（仅位置） | — | — | — | — | — | — | — | 8 | — |
| SE(3) 历史（跟踪噪声） | — | — | — | — | — | — | — | 8 | — |
| SE(3) 历史 + RGB 窗口 | — | — | — | — | — | — | — | 1,380 | — |
| RGB 窗口，无当前位姿 | — | — | — | — | — | — | — | 1,371 | — |

**扰动与干预。** 离线扰动在所有过去槽位中重复当前图像，或在保持当前帧、位姿与噪声不变时反转过去的图像，并测量首个发出动作的变化。在最终模型上（表 S18），*静止历史*在重新计算运动学之前用当前位姿替换每个过去位姿，从而去掉位移、速度与加速度。*时间反转*反转过去的位姿。*当前状态匹配的交换*代入最近的另一个开发集回合的历史，该回合任务、物体与相机相同，当前目标与末端位姿相差在 5 mm 与 5° 以内。*方向歧义子集*还要求最后一个区间的速度方向相反且至少为 0.01 m/s。

**位姿噪声。** 仿真位姿是精确的，因此我们直接检验对跟踪误差的敏感性。我们向每个过去的位姿估计独立加入高斯噪声，位置标准差 $\sigma_p \in \{0, 1, 2, 5, 10, 20, 40\}$ mm，旋转标准差 $\sigma_R = \sigma_p/(30\,\text{mm})$ rad，使两者在 3 cm 力臂处产生相同的位移，然后再计算运动学。当前位姿保持不变，因此该测试隔离了历史。我们按表 S6，以 $T = 350$ ms、$n = 8$ 与实际领先时长逐任务计算交叉噪声水平 $\sigma^\star$（附录 G.5），并与跟踪器实测误差（表 S1）一起标在图 S6b 中。“跟踪噪声”各行使用与该误差相当的噪声水平，并按跟踪器的丢失率丢弃位姿。

**遮挡与采样。** 0.5、1、2 与 3 s 的遮挡以及一个无遮挡对照检验历史空缺。采样测试保持 350 ms 跨度，选取 2、4 或 8 个偏移，并在实际偏移处使用时间嵌入。

表 S18. **冻结策略干预。**每行只在推理时改变一个输入。历史干预使用最终模型。隐藏状态干预使用耦合 R2，几何干预使用 R5（最终模型不读取预测）。SR 为留出场景成功率（%）。$\delta a$：首个动作平移的平均变化（mm）。

| 输入 | 干预 | SR | $\delta a$ |
|---|---|---|---|
| 历史 | 无 | — | 0 |
| | 静止（重复当前位姿） | — | — |
| | 时间反转 | — | — |
| | 当前状态匹配的交换 | — | — |
| | 方向歧义交换 | — | — |
| 世界状态（R2） | 无 | — | 0 |
| | 当前状态匹配的交换 | — | — |
| | 时域时刻偏移 ±50 ms | — | — |
| 解码几何（R5） | 无 | — | 0 |
| | 零运动 | — | — |
| | 当前状态匹配的打乱 | — | — |
| | 时间偏移 ±50 ms | — | — |
| | 真值（接触前） | — | — |

## F.3 预测目标

**表示。** 表 S19 定义各类未来目标。所有目标都从当前状态累计，覆盖 50 到 400 ms 的相同八个时域。表 S20 的每一行都保持选定配置的历史、耦合方式、动作损失、训练预算与世界分支容量，只替换预测目标，由读出头按附录 A.3 的方式从世界流回归。因此我们在同等容量下比较图像空间目标。冻结视频一行则读取预训练图生视频模型从当前帧预测的隐变量，这一未来不依赖我们的容量。Kabsch 一行预测物体轨迹并对其拟合 SE(3)，因此它得到与轨迹一行相同的信息外加一个刚性先验。最后一组保持选定的预测，只改变仅用于训练的外观目标（其读出头在部署时去掉），因此它衡量这些目标教给世界流的内容。

在开发集场景上，大多数表示的总体差距在几个百分点以内，差异集中在少数任务上。目标点轨迹加流的总体 SR 甚至略高于 SE(3) 轨迹（单种子 [+1.7] 个百分点）。我们保留了 SE(3) 轨迹，因为它直接给出位姿，并且对旋转目标最重要；表 S20 在留出场景上比较了两者。稠密 2D 位移是唯一明显有害的未来表示（相对无未来预测 [−3.6] 个百分点）。

**角色覆盖。** 在选定的表示上，各角色行保留所有源点与相同的计算，只改变哪些点（目标上的点或环境上的点）参与流损失。

**分辨率与间隙。** $28^2$ 与 $56^2$ 网格对同一图像更密地采样，物体采样的流把点放在环境掩码上而不是固定网格上。所有变体使用相同的标签、归一化与损失权重。路径误差 $e_F$ 是在执行路径经过时、距路径最近的 256 个留出环境点上的流端点误差。表 S21 报告所有变体在附录 C.3 间隙扫描上的结果，以及同等容量的视频隐变量未来。

**外推基线。** 匀速与匀加速预测只使用模型可见的 SE(3) 历史，即最后一个区间的速度与最后两个区间速度之差，作用于平移，并通过旋转向量作用于旋转。离线时，我们在执行时刻用真值为三种预测打分。为衡量它们的闭环价值，我们以相同的数据与预算训练两个变体（表 S22）：第一个把外推的目标轨迹作为额外输入 token，并保留选定模型的预测损失；第二个用这些输入 token 替代预测损失，即表 1 中的 CV 输入基线。

表 S19. “预测”研究中比较的未来目标族。张量形状不含 batch 和 query 轴。除保留解码器自身对应关系的 codec 向量外，位移均从当前状态累计。除冻结视频模型（其隐变量为该模型自身的预测）外，所有监督目标均来自记录的演示。未来深度、DINO 与动态 RGB 同时也是选定模型仅在训练中使用的辅助目标。

| 目标 | 形状 | 几何支持、单位与有效条件 |
|---|---|---|
| 目标位姿 | $8 \times 6$ | 累计平移 (m) 和左相对旋转向量 (rad)；位姿和 query 有效。 |
| 场景流，$k \times k$ 网格 | $k^2 \times 8 \times 3$ | 每边 $k \in \{14, 28, 56\}$ 个点的固定网格；基座坐标系中的米；源深度有效且未来位移有限。 |
| 场景流，按物体采样 | $196 \times 8 \times 3$ | 在环境掩码上以最远点采样代替固定网格选取的点。 |
| 物体点轨迹 | $32 \times 8 \times 3$ | 在当前目标掩码内作最远点采样；位移与可见性；填充点无效。Kabsch 变体对预测轨迹拟合 SE(3)。 |
| 物体 DINO | $8 \times 1024$ | 按掩码面积加权汇聚未来 patch 特征；沿通道作层归一化；掩码面积为正。 |
| 场景轨迹（二维） | $196 \times 8 \times 3$ | 网格源点；两个图像位移通道除以 224，另加一个可见性 logit。 |
| 稠密二维位移 | $8 \times 2 \times 224 \times 224$ | 固定源像素；位移除以 224；源像素有效且投影有限。 |
| 编码器运动向量 | $8 \times 2 \times 64 \times 64$ | 每对未来 / 当前帧编码为 P/I 帧；向量除以 64；使用有效向量区域。 |
| 视频 VAE 隐变量 | $48 \times 2 \times 14 \times 14$ | 冻结的 Wan2.2 VAE 后验均值及该 VAE 自身的归一化；两组分别截至 200 与 400 ms。 |
| 冻结视频模型 | $48 \times 2 \times 14 \times 14$ | 冻结的预训练图生视频模型由当前帧预测的隐变量；仅读取，不监督。 |
| 未来深度 | $8 \times 1 \times 224 \times 224$ | 米制深度；像素值为有限正数。 |
| 未来 DINO | $8 \times 196 \times 1024$ | 冻结的 DINOv3 ViT-L/16 教师 [64]，$14 \times 14$ 个 patch，沿通道作层归一化。 |
| 动态 RGB | $8 \times 3 \times 224 \times 224$ | 在世界坐标中移动超过 1 mm 的可见表面（含机器人）上取 RGB 并除以 255。 |

**预测误差。** 物理误差使用 256 个目标源点与 256 个环境源点组成的公共点池，确定性采样，并排除在训练查询之外。平移与旋转误差保持度量与测地单位，流误差是有效对应点上的端点误差。所有预测误差都在留出回合的执行时刻测量。

## F.4 预测的使用方式与主干

**主干。** 共享注意力的主干在所有 token 组之间共享注意力投影，并按流拆分前馈网络。分组主干的世界与动作参数组各有自己的注意力投影、自适应层归一化与前馈网络。我们通过分组主干的前馈比例（3 而非 4）匹配可训练参数量，在筛选规模下两者都约为 47.3M 参数，深度、宽度与注意力头数相同。相同的训练预算并不意味着相同的 FLOPs，因此我们报告实测代价。在开发集场景上，共享注意力主干达到 [66.8]%，分组主干为 [62.9]%（各三个种子），我们保留了前者。

**耦合方式。** 附录 A.5 定义 R0–R5 的注意力掩码。所有耦合方式共享模块、初始化、损失与训练预算。R0 保留读出头但关闭全部预测损失，因此它与 SE(3)-WAM 容量相同而没有预测监督。R1 加入承载读出的世界查询，但它们与动作之间不开启任何连接，因此它与 SE(3)-WAM 只差这些查询。我们以两种方式部署 SE(3)-WAM：只运行动作，或计算但不读取预测头，以隔离未使用预测的代价。R2 让动作读取世界查询的隐藏状态，R3 让世界查询读取带噪动作，R4 同时开启两个方向；R3 与 R4 在每个 Euler 步都重算世界。R5 解码预测，并用 0.37M 参数的几何编码器重新编码给动作，经由预测出的几何端到端训练，不使用教师强制。由于 R5 同时改变了动作读取的内容与其进入的位置，R2 与 R5 的比较是两个完整设计之间的比较，而不是单一因素的比较。

在开发集场景上，没有任何耦合方式稳定地优于 R1。让世界读取动作（R3）的三种子均值最高，比 R1 高 [+0.6] 个百分点，但差异全部来自导线穿越任务，而且两个方向的读取效应在不同种子之间符号不一致。由解码出的预测生成动作（R5）同样没有优于 R1。因此我们保留了只在训练中使用预测、

表 S20. **预测目标：完整的未来表示比较**（留出场景；一个训练种子，同时出现在表 3 中的行为三个种子）。历史与耦合方式固定为选定配置，各行世界分支容量相同，只改变其预测目标（定义见表 S19）。最后一组之前的各行保留选定的仅训练外观辅助目标；最后一组在选定表示上改变这些目标，其读出头在部署时去除。Pose：400 ms 处的平移（mm）与旋转（°）误差；$e_F$：沿执行路径的留出环境点上的流误差（mm）；$e_t$：接触时刻误差（ms）；cost：每次查询的世界分支耗时（ms）。

| 目标 | 环境 | SR | $SR_{150}$ | 位姿 (mm/°) | $e_F$ | $e_t$ | 碰撞 | 耗时 |
|---|---|---|---|---|---|---|---|---|
| 无 | 无 | — | — | – | – | — | — | 0 |
| SE(3) | 无 | — | — | — | – | — | — | — |
| 无 | 流，$14^2$ | — | — | – | — | — | — | — |
| SE(3) | 流，$14^{2\star}$ | — | — | — | — | — | — | — |
| SE(3) | 流，$28^2$ | — | — | — | — | — | — | — |
| SE(3) | 流，$56^2$ | — | — | — | — | — | — | — |
| SE(3) | 流，按物体采样 | — | — | — | — | — | — | — |
| 物体点轨迹 | 流，$14^2$ | — | — | – | — | — | — | — |
| 点轨迹 → SE(3) 拟合 | 流，$14^2$ | — | — | — | — | — | — | — |
| 物体 DINO | 流，$14^2$ | — | — | – | — | — | — | — |
| SE(3) | 场景轨迹（二维） | — | — | — | – | — | — | — |
| SE(3) | 稠密二维位移 | — | — | — | – | — | — | — |
| SE(3) | 编码器运动向量 | — | — | — | – | — | — | — |
| SE(3) | 视频 VAE 隐变量 | — | — | — | – | — | — | — |
| SE(3) | 冻结视频模型 | — | — | — | – | — | — | — |
| SE(3) | 未来深度 | — | — | — | – | — | — | — |
| SE(3) | 未来 DINO | — | — | — | – | — | — | — |
| SE(3) | 动态 RGB | — | — | — | – | — | — | — |
| *选定表示上的角色覆盖* | | | | | | | | |
| SE(3) | 流，仅目标点 | — | — | — | — | — | — | — |
| SE(3) | 流，仅环境点 | — | — | — | — | — | — | — |
| *选定表示（SE(3) + 流）上的仅训练外观目标* | | | | | | | | |
| 无 | | — | — | — | — | — | — | — |
| 未来深度 | | — | — | — | — | — | — | — |
| 未来 DINO 特征 | | — | — | — | — | — | — | — |
| 运动区域 RGB | | — | — | — | — | — | — | — |
| 三者全部 * | | — | — | — | — | — | — | — |
| 三者全部，去除当前目标 RGB 重建 | | — | — | — | — | — | — | — |

不设世界查询的方案，它的部署代价也最低。预测监督本身（R1 相对 R0）平均带来 [3.1] 个百分点，但其增益在不同种子之间从 [−1.3] 到 [+9.6] 个百分点不等。

**预测干预。** 干预保持场景 token、摘要 token 与动作噪声不变，只改变动作从世界读取的内容。在 R2 上，它们替换动作 token 在每一层读取的键和值。当前状态匹配的交换代入另一个开发集回合的世界状态，该回合当前目标位姿相差在 5 mm 与 5° 以内；时间偏移在每个时域偏移平移 50 ms 后重新计算它们。在 R5 上，它们在编码之前编辑解码出的几何：零运动使用零 3D 位移与单位目标位姿，可见性不变；当前状态匹配的打乱在同样的匹配下取另一个开发集回合的几何；时间偏移在 $\delta_h \pm 50$ ms 处重采样轨迹；真值使用首次接触前实测的外部运动。接触之后，未来标签取决于动作，因此真值分析在一个固定的候选动作序列下分叉仿真快照。动作不读取任何预测的 SE(3)-WAM 作为阴性对照。

表 S21. **环境分辨率与间隙**（穿越任务）：工作空间中的网格间距与路径误差 $e_F$（mm），以及各扫描间隙 $c_1 < \cdots < c_5$ 下的成功率（%）（附录 C.3）；目标始终以 SE(3) 预测。

| 环境 | 间距 | $e_F$ | $c_1$ | $c_2$ | $c_3$ | $c_4$ | $c_5$ |
|---|---|---|---|---|---|---|---|
| 无 | – | – | — | — | — | — | — |
| 流，$14^2$ | — | — | — | — | — | — | — |
| 流，$28^2$ | — | — | — | — | — | — | — |
| 流，$56^2$ | — | — | — | — | — | — | — |
| 流，按物体采样 | — | — | — | — | — | — | — |
| 视频 VAE 隐变量 | – | – | — | — | — | — | — |

表 S22. **预测损失与外推输入的比较**，按运动类型分列。上：在相同数据与训练预算下，以 SE(3) 历史的匀速（CV）或匀加速（CA）外推作为输入 token、有或没有预测损失的 SE(3)-WAM 变体的成功率（%）。无预测损失的 CV 行即表 1 中的匀速输入基线。下：两种外推与学习的位姿头在 400 ms 处的目标位置误差（mm）。

| | 匀速 | 谐波 | 滚动/滑动 | 撞击 |
|---|---|---|---|---|
| *无预测损失* | | | | |
| 无预测输入 | — | — | — | — |
| 匀速输入 | — | — | — | — |
| 匀加速输入 | — | — | — | — |
| *有预测损失* | | | | |
| SE(3)-WAM （无预测输入） | — | — | — | — |
| 匀速输入 | — | — | — | — |
| 匀加速输入 | — | — | — | — |
| *400 ms 处的位置误差（mm）* | | | | |
| 匀速外推 | — | — | — | — |
| 匀加速外推 | — | — | — | — |
| 学习的位姿头 | — | — | — | — |

表 S23. **如何使用预测：完整比较**（留出场景）。历史与预测目标固定为选定配置。附录 A.5 的各耦合方式在选定主干上逐一比较，另一主干只检验其中两种。$\mathrm{SR}_{\mathrm{static}}$：静止目标变体。NFE：每次查询的网络调用数（世界/动作）。显存：GPU 峰值显存（GiB）。p95 在一块 RTX 5090 上测得。

| 主干 | 耦合 | SR | $\mathrm{SR}_{150}$ | $\mathrm{SR}_{\mathrm{static}}$ | LIBERO | NFE | p95 (ms) | 显存 | $e_t$ |
|---|---|---|---|---|---|---|---|---|---|
| 共享注意力 ⋆ | SE(3)-WAM （读出头，无连接）⋆ | — | — | — | — | 1/5 | — | — | — |
| | SE(3)-WAM ，运行预测头 | — | — | — | — | 1/5 | — | — | — |
| | R0 （关闭预测损失） | — | — | — | — | 1/5 | — | — | — |
| | R1 （世界查询，无连接） | — | — | — | — | 1/5 | — | — | — |
| | R2 （世界 → 动作，隐藏状态） | — | — | — | — | 1/5 | — | — | — |
| | R3 （动作 → 世界） | — | — | — | — | 5/5 | — | — | — |
| | R4 （双向） | — | — | — | — | 5/5 | — | — | — |
| | R5 （解码几何） | — | — | — | — | 1/5 | — | — | — |
| 独立参数组 | SE(3)-WAM | — | — | — | — | 1/5 | — | — | — |
| | R2 （世界 → 动作，隐藏状态） | — | — | — | — | 1/5 | — | — | — |

# G 延迟下行动的误差分析

本附录推导第 3.1 节的误差分解，把它推广到旋转、环境与分块执行，推导简单的比例关系，给出 Dynamic-14 中各项的量级，并说明其不适用的情形。这一分解促成了 SE(3)-WAM 的设计，它不是成功率的模型。

## G.1 平移

设执行时刻目标的真实位置为 $\mathbf{p}(\tau^{\mathrm{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，策略的估计为 $\hat{\mathbf{p}}(\tau^{\mathrm{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。减去再加上 $\mathbf{v}\hat{\Delta}$ 得到恒等式

$$\begin{aligned}\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}}) = \big[\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\big] + (\hat{\mathbf{v}} - \mathbf{v})\hat{\Delta} \\ + \mathbf{v}(\hat{\Delta} - \Delta) + (\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}),\end{aligned} \tag{S4}$$

由三角不等式即得式 3。由于 $\mathbf{v}$ 是 $\tau_t$ 时的速度，$\boldsymbol{\rho}$ 恰好是匀速外推遗漏的那部分运动。在匀加速度 $\mathbf{a}$ 下，$\boldsymbol{\rho} = \frac{1}{2}\mathbf{a}\Delta^2$，从历史中估计的加速度可以消除 $e_{\mathrm{dyn}}$ 的一部分；撞击、滚动接触与摩擦变化留下的余项只有动力学模型才能减小。对于学习型预测器，其估计在 $\hat{\mathbf{v}}\hat{\Delta}$ 与 $\hat{\boldsymbol{\rho}}$ 之间的划分不可辨识，因为任何预测位置都可以写成这种形式。因此我们用这一分解说明每一项需要哪些信息。我们的实验不在学习型预测器内部分离各项，而是改变作用于已知项的领先时长、速度、位姿噪声与时间，并比较接收不同信息的变体（附录 G.5）。

## G.2 旋转与接触点

我们写 $R(\tau^{\mathrm{a}}) = \mathrm{Exp}(\boldsymbol{\omega}\Delta + \boldsymbol{\eta})R(\tau_t)$ 与 $\hat{R}(\tau^{\mathrm{a}}) = \mathrm{Exp}(\hat{\boldsymbol{\omega}}\hat{\Delta} + \hat{\boldsymbol{\eta}})\hat{R}(\tau_t)$。当 $R$ 与 $\hat{R}$ 绕同一固定轴旋转时，指数映射可以相加，于是

$$\theta = \big\| \mathrm{Log}(\hat{R}(\tau^{\mathrm{a}})R(\tau^{\mathrm{a}})^{\top})^{\vee} \big\| \le \theta_{\mathrm{loc}} + \hat{\Delta}\, e_{\omega} + \|\boldsymbol{\omega}\|\, e_{\tau} + e_{\eta}, \tag{S5}$$

其中 $\theta_{\mathrm{loc}}$ 是当前朝向误差，$e_{\omega}$ 与 $e_{\eta}$ 的定义与平移相同。对一般旋转，Baker–Campbell–Hausdorff 公式会带来角度的二阶项。物体坐标系中位于 $\mathbf{c}$、$\|\mathbf{c}\| = r$ 的接触点，其世界位置为 $\mathbf{p} + R\mathbf{c}$，因此误差为 $(\hat{\mathbf{p}} - \mathbf{p}) + (\hat{R}R^{\top} - I)R\mathbf{c}$。对转角为 $\theta$ 的旋转，$\hat{R}R^{\top} - I$ 的算子范数为 $2\sin(\theta/2)$，于是

$$e_{\mathrm{c}} \le \|\hat{\mathbf{p}} - \mathbf{p}\| + 2r\sin(\theta/2) \le \|\hat{\mathbf{p}} - \mathbf{p}\| + r\theta, \tag{S6}$$

这就是第 3.1 节中的接触误差界。因此朝向误差以力臂为比例进入接触几何，依赖朝向的抓取或放置需要 SE(3) 的目标状态。对于旋转对称的目标，绕对称轴的旋转不改变任何接触，我们从输入、标签与误差中排除它。

## G.3 环境与间隙

令 $\mathcal{P}$ 为执行路径经过的环境点与时刻的集合，并设路径使机器人与被携带物体上的每一点 $\mathbf{x}$ 与预测的环境位置 $\hat{\mathbf{y}}_t(\mathbf{z},\tau)$（$(\mathbf{z},\tau) \in \mathcal{P}$）至少相距 $m$。碰撞要求对某个 $(\mathbf{z},\tau) \in \mathcal{P}$ 有 $\mathbf{x} = \mathbf{y}_t(\mathbf{z},\tau)$，此时 $\|\hat{\mathbf{y}}_t(\mathbf{z},\tau) - \mathbf{y}_t(\mathbf{z},\tau)\| = \|\hat{\mathbf{y}}_t(\mathbf{z},\tau) - \mathbf{x}\| \ge m$，因此碰撞要求路径上某处的预测误差至少为 $m$。比 $m$ 更细的环境精度因而对成功率没有一阶影响。这个界只关乎误差的大小，与采样无关。在网格上采样的流会漏掉比其间距更细的结构，并在运动边界处出错；这两种效应都进入路径误差 $e_F$，我们在执行路径沿线的留出点上测量它（附录 F.3），而不是由网格间距推断。间隙本身也是一个设计变量：环境估计较粗时，策略可以保持更大的间隙，代价是可达性或时间。

图占位：图 S6——未补偿的运动与位姿噪声

**(a)** x：首个指令执行时刻的 $\|\mathbf{v}\|\Delta/\varepsilon$（对数）；y：SR。每个方法 × 任务族 × 速度 × 延迟一个点；反应式策略（灰）附拟合的 logistic 曲线与 Spearman $\rho$，标出阈值 1；补偿运动的基线与 SE(3)-WAM（橙）为平移后的曲线。**(b)** x：注入的位姿噪声 $\sigma$（mm，symlog）；y：SE(3) 历史的 SR；区间带：最佳视觉历史；竖线：$\sigma^\star$ 与跟踪器实测误差。

图 S6. **实测趋势。**(a) 反应式策略的成功率与相对容差的未补偿运动之间的关系；运动补偿使曲线右移。(b) 注入位姿噪声时 SE(3) 历史的价值。

## G.4 滚动重规划下的领先时长

动作块包含 $H$ 条指令，从动作块可用起按顺序每个控制周期执行一条；第 $t$ 次查询的第一条指令在延迟 $\ell_t$ 之后执行，后续指令只执行到下一个动作块替换它们为止。在每执行一条指令后重新规划时，相关的领先时长因此为 $\Delta_{t,j} = \ell_t + j\Delta_a$，其中 $j$ 只取下一个动作块到达之前被执行的少数几条。对于 SE(3)-WAM 的 p95 出动作时间加上扫描中最大的附加延迟（200 ms），这些领先时长都落在预测的 400 ms 之内，因此预测损失在任何指令可能执行的时刻都监督了表示。动作流不接收延迟，因此策略不会针对某个特定延迟调整指令；每条指令后都重新规划使被执行的领先时长保持较短，而延迟扫描衡量领先时长增大时成功率如何下降。

## G.5 比例关系

由这一分解可以得到三个关系。图 S6 给出与前两个关系相关的测量。

**临界领先时长。** 不补偿运动的策略（$\hat{\mathbf{v}} = 0$，$\hat{\boldsymbol{\rho}} = 0$）在 $e_{\text{loc}}$ 与 $\|\boldsymbol{\rho}\|$ 之外还要承受 $\|\mathbf{v}\|\Delta$。定位误差较小、运动平滑时，一旦 $\|\mathbf{v}\|\Delta > \varepsilon$，即超过临界领先时长 $\Delta^\star = \varepsilon/\|\mathbf{v}\|$，其接触就会失败，其成功率只通过 $\|\mathbf{v}\|\Delta/\varepsilon$ 依赖于任务、速度与延迟。表 S6 列出每个任务的 $\varepsilon$、$\|\mathbf{v}\|$ 与 $\Delta^\star$。图 S6a 给出每个方法的成功率与 $\|\mathbf{v}\|\Delta/\varepsilon$ 的关系，后者在每个回合的首个指令执行时刻计算，并在任务、速度与延迟上汇总；同时给出反应式策略的 Spearman 相关系数与拟合的 logistic 曲线。反应式策略 [落在同一条曲线上]（Spearman $\rho = [X.XX]$），其成功率在 [X.X] 处减半。这一分解只给出约为 1 的阈值，而不给出曲线的形状。捕获任务在曲线周围最分散，因为其成功还取决于夹爪何时合拢。

**位姿噪声。** 由跨度为 $T$ 的 $n$ 个等间隔位姿（每个轴上带独立噪声 $\sigma$）得到的最小二乘速度估计，其标准差为 $\sigma\sqrt{12(n-1)/(n(n+1))}/T \approx \sigma\sqrt{12/n}/T$ [5]。因此在噪声达到 $\sigma^\star = \varepsilon T\sqrt{n}/(\Delta\sqrt{12})$ 之前，位姿历史能使 $\hat{\Delta}e_v$ 保持在容差以下。取 $\varepsilon = 10$ mm、$T = 350$ ms、$n = 8$ 与 $\Delta = 200$ ms，得到 $\sigma^\star \approx 14$ mm。带运动先验的学习型估计器可以做得更好，因此 $\sigma^\star$ 是无模型线性估计对应的值。SE(3)-WAM 的 SE(3) 历史在注入 [X] mm 噪声时降到最佳视觉历史的水平（图 S6b），为 $\sigma^\star$ 的 [X.X] 倍、跟踪器误差的 [X] 倍。

**间隙。** 路径误差为 $e_F$ 的环境预测在 $m > e_F$ 时避开碰撞。因此，粗粒度流应当在高于其实测 $e_F$ 的间隙上与更细的流相当，在低于它时落后。

## G.6 Dynamic-14 中的量级

表 S24 在有代表性的 Dynamic-14 设置下（表 S7）计算各项的大小。每一项都与成功条件中毫米级的容差（表 S5）相当或更大。

表 S24. 领先时长为 200 ms 时式 3 各项的示意量级。数值由所述量推出，并非测量值。

| 项 | 设置 | 大小 |
|---|---|---|
| $\|\mathbf{v}\|\Delta$ | 传送带 0.10 m/s | 20 mm |
| $\hat{\Delta} e_v$ | 速度估计偏差 10% | 2.8 mm |
| $\|\mathbf{v}\| e_\tau$ | 50 ms 时间误差（一个周期） | 7.0 mm |
| $2r\sin(\theta/2)$ | $\omega = 1.2$ rad/s 未被预测，$r = 3$ cm | 7.2 mm |
| $e_{\text{dyn}}$ | $10^\circ$ 斜坡上的球，无加速度模型 | 24 mm |
| $\varepsilon$ | 抓取传送带零件 | [X] mm |
| 网格间距 | 工作空间处的$14 \times 14$ 流 | [X] mm |

斜坡一项使用纯滚动实心球的加速度 $a = \frac{5}{7} g \sin\alpha \approx 1.2\,\text{m/s}^2$（$\alpha = 10^\circ$），以及 $\Delta = 0.2\,\text{s}$ 时的 $\frac{1}{2} a \Delta^2$。

## G.7 适用范围

这一分解针对的是接触前运动由外部决定的刚性目标的接近过程。它不涵盖可变形或铰接的目标，因为其在 $\mathcal{O}$ 上的运动场不由六个数决定。它也不涵盖接触后的运动，后者取决于动作本身，需要以动作为条件的预测，这正是让世界读取动作可能起作用的情形。目标角色随时间变化的场景（例如依次操作多个物体的任务）同样不在其范围内。感知质量只通过 $e_{\text{loc}}$ 与 $e_v$ 进入，我们单独测量它（表 S1）。这个界不是成功的概率，它指出哪些误差随哪些因素放大。