SE(3)-WAM：通过动作生效时刻的预测学习动态操作

中文审读稿

摘要

操作运动物体需要指令与其生效时刻的场景相符，而这一时刻通常比图像采集晚几百毫秒。我们用物理时间中的误差预算分析该延迟：目标的接触误差随速度与领先时长的乘积增大，场景其余部分则只需预测到间隙所允许的精度。误差预算提示策略应记住什么（目标的度量运动）、预测什么及多高精度（目标的 SE(3) 轨迹和环境的粗粒度 3D 流），以及针对哪些时刻（指令生效时刻）。据此，我们构建世界—动作 Transformer SE(3)-WAM，联合学习以领先时长为条件的指令与上述 4D 预测。在实时评测的十四项动态任务 Dynamic-14 上，SE(3)-WAM 的留出 episode 成功率为 [XX.X]%，最强基线为 [XX.X]%。在指令生效时刻监督预测，无需在测试时生成预测也能获得预测的收益，因此部署时只运行动作流。在自动提升为 4D 标签的 DROID 上预训练的基座可迁移到真实传送带抓取；180 次试验中，SE(3)-WAM 成功率为 [XX]%，$\pi_{0.5}$ 为 [XX]%。

1 引言

从传送带上抓取零件、把物体放入移动的容器、接住从斜坡滚下的小球，都要求指令与其生效时刻的场景相符。从图像采集到夹爪闭合，策略需要推理，指令需要排队，机械臂也需要运动。传送带上以 0.10 m/s 运动的零件在 150 ms 延迟内会移动 15 mm，超过平行夹爪抓取它所能容忍的 [X] mm。从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[10, 31, 42, 49]，多数先进的视觉运动策略是在准静态场景中发展起来的，延迟在这些场景中影响很小 [1, 12, 46]。

近期工作以三种方式加入时间上下文：以堆叠帧、光流或压缩视频 token 作为历史输入 [23, 27, 29, 46, 59]；用世界模型预测未来视频、隐变量、物体状态或速度场 [12, 35, 49, 55]；以及在推理存在延迟时保持指令及时性的执行方案 [6, 36, 39]。动态策略需要哪些信息、需要多高精度、针对哪个时刻，仍不清楚。我们认为，答案可以从交互误差的来源中寻找。抓取或放置的误差由指令生效时刻目标的度量位姿决定，场景其余部分则仅通过其留下的间隙起作用。像素历史隐含了这种运动，而图像空间的预测将大部分容量用于外观。

我们用物理时间中的误差预算具体说明这一观点（第 3 节）。它把接触误差分为定位、运动、时间、未建模动力学与旋转几项；场景其余部分则只在预测误差超过间隙时产生影响。这一代数推导很初等，延迟补偿在控制与跟踪中也已有长期研究 [3, 4, 34]，但对学习型策略而言，误差预算提供了在场景中分配精度的方法，并给出可检验的预测，例如忽略运动的策略必然失败的领先时长界限。它也导出三项设计选择：记住目标的度量运动，预测目标的 SE(3) 轨迹及精度不超过间隙所需的环境 3D 流，并依据按生效时刻索引的预测与指令行动。

我们围绕这些选择构建 SE(3)-WAM （图 3）。Transformer 编码当前 RGB-D 帧、机器人状态，以及因果位姿跟踪器给出的目标 SE(3) 历史。世界流在物理时域上预测目标的 SE(3) 轨迹与粗粒度 3D 场景流，动作流则生成以领先时长为条件的指令；领先时长是从图像采集到指令生效的时间。世界流在训练时监督共享表示，部署时只运行动作流。对于真机，我们用现成的感知方法 [17, 18, 32] 把 DROID [20] 提升为度量 4D 标签，并据此预训练基座模型。

图占位：图 1 首图——在未来 4D 场景上行动（真机）

版式：通栏，左右两部分。**(a) 左侧约 62%**：传送带抓取在发出动作块瞬间的一帧真机图像。按论文语义配色叠加：蓝色为因果跟踪器给出的目标过去 SE(3) 位姿（$-350\ldots0$ ms 的小坐标轴，越旧越淡）；橙色为各指令生效时刻的目标 SE(3) 预测坐标轴，首个生效时刻 τ^{a} 处加粗；浅橙色箭头为仅在14×14 网格上的环境粗粒度 3D 流（预测叠加来自训练时的世界头，离线计算；部署时不运行它）；紫色为在 τ^{a} 与目标相遇的夹爪指令轨迹。灰色虚影标出采集时刻观测到的位姿，红色虚线箭头示意反应式策略会在何处合拢。图像下方一条细时间轴：采集 $\tau_t \to$ 延迟 $\ell_t \to$ 生效 τ^{a}。**(b) 右侧约 38%**：上：“图像空间 WAM：未来帧或隐变量”（胶片图标）；中：“SE(3)-WAM：目标用 SE(3)，环境用 3D 流，按生效时刻索引”（坐标轴 + 稀疏箭头）；下（**必需**）：SE(3)-WAM 与最强基线的成功率随附加延迟（0–200 ms）的变化（数据：附录 G.2 的延迟扫描）。**要求**：真实照片不修饰；叠加内容取自该次试验记录的跟踪、预测与指令数据；图注写明该次试验结果。

图 1. **预测动作生效时刻的场景。**从图像采集到第一条指令生效，传送带上的零件移动距离已超过抓取容差。SE(3)-WAM 编码目标的度量运动（蓝），并通过训练预测每条指令生效时刻的目标 SE(3) 位姿，以及周围场景的粗粒度 3D 流（橙，仅在训练期间预测），使指令在该处与目标相遇（紫）。图像空间的世界—动作模型则预测外观。右：Dynamic-14 上成功率随附加延迟的变化。

我们在 Dynamic-14 、DOMINO [12]、LIBERO [25] 和真实传送带上评测。Dynamic-14 包含我们构建的十四项仿真任务，能够分别改变误差预算中的各项；实时协议保证每种方法计算期间场景持续运动。SE(3)-WAM 在 Dynamic-14 留出场景上的成功率为 [XX.X]%，比最强基线高 [X.X] 个百分点；不过，推理时暂停物理仿真后，一个更大的模型领先。SE(3) 历史在超过临界领先时长后带来帮助，而 RGB、光流或视频隐变量历史的增益很小。只要在指令生效时刻监督预测，部署时去掉预测仍能保留大部分收益，与文献 [51] 在静态场景中的发现类似。误差预算的预测近似成立，偏差最大的是捕获任务 [，且有一项任务仍未被任何方法解决]。我们的贡献包括：

- 一个物理时间中的简单误差预算，用于指导设计，并由实验检验其预测；
- SE(3)-WAM ：联合学习以领先时长为条件的动作与按角色区分的 4D 预测，以及在带有提升后 4D 标签的 DROID 上预训练的真机基座；
- 采用实时协议的 Dynamic-14 ， SE(3)-WAM 在其上优于已有方法。我们将一并发布该基准、DROID 标签和代码。

2 相关工作

动态操作。 用预测补偿延迟是控制 [34] 与预测跟踪 [3] 中的经典方法。机器人接球和手眼系统通常用卡尔曼类滤波器 [4] 从视觉估计物体轨迹，并实施拦截 [2, 5, 15]。视觉伺服在图像特征上形成闭环 [19]，动态抓取则把运动预测与可达性结合起来 [1]。在学习型策略中，DOMINO 同时提出动态基准与 PUMA，后者读取历史光流并以未来物体特征监督 [12]。DynamicVLA 流式输出动作并丢弃过时指令 [46]，DynamicWAM 以光流和运动学描述作为 WAM 的条件 [29]，其他方法预测显著的未来 token [35] 或事件时刻 [56]。近期一些预印本通过运动感知世界模型、速度场或合成动态示范探索相关思路 [9, 22, 52]。在执行方面，实时分块在延迟下保持控制平滑 [6]，VLASH 把机器人状态前推到执行时刻 [36]，同期的 Chronos Policy 则以观测和执行时间戳为条件 [39]。这些方法处理机器人一侧的时间，或从像素中学习物体运动；我们关注的是策略在执行时刻必须知道哪些场景量。

世界—动作模型。 WAM 通过预测性特征 [16]、视觉子目标 [57] 或视频—动作联合生成 [21, 42, 49, 61]，耦合未来预测与动作生成。另一些方法在预测中加入深度、语义或动态区域，例如文献 [50, 55]，或压缩长历史 [27]。Fast-WAM 发现，在其静态任务上可以跳过测试时想象而不损失性能 [51]。这些模型在

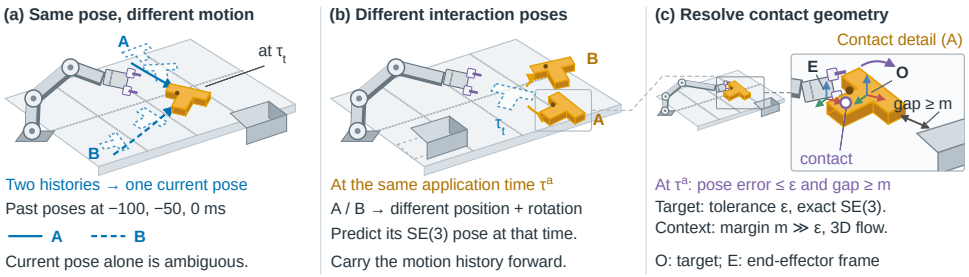


图 2. **在物理时间中行动的三个影响**（示意图）。(a) 两段历史在采集时刻 τ_t 到达相同位姿，但对应不同运动。(b) 在同一生效时刻 τ^{a}，它们对应的目标平移与旋转均不同。(c) 接触要求末端执行器坐标系 E 与目标 O 在容差 ε 内对齐，而环境仅通过其留下的间隙起作用，裕度为 $m \gg \varepsilon$。

图像或隐空间中预测，缺少误差预算所指向的度量化物体状态。SE(3)-WAM 在物理时域上预测这种状态，我们发现，只要在指令生效时刻监督预测，动态场景中也能在不进行测试时想象的情况下保留其收益。

结构化的三维与四维运动。 刚体结构长期用于学习动力学模型和场景流 [7, 8, 37, 48]，三维点跟踪则在空间中追踪像素 [45]。点轨迹与三维流已被用作策略接口 [44, 47, 60]，点云被用作策略输入 [53]，物体位姿则为世界模型与策略提供结构 [11, 28]。PointWorld 大规模预测以动作为条件的三维点流 [17]，前馈模型可重建场景几何 [40] 和动态点轨迹 [54]。我们仅对目标使用刚体结构，将场景其余部分保留为粗粒度 3D 流，两者均按指令生效时刻索引。

3 物理时间中的交互

物理时间。 我们考虑接收图像、机器人状态及其采集时间的策略。在第 t 次查询时，历史为 $\mathcal{H}_t = \{(o_i, s_i, \tau_i)\}_{\tau_i \le \tau_t}$，策略输出动作块 $A_t = (\mathbf{a}_{t,0}, \dots, \mathbf{a}_{t,H-1})$，其第 j 条指令的生效时刻为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + \ell_t + j\Delta_a, \tag{1}$$

其中 ℓ_t 是从采集到首条指令生效的延迟，包含预处理、推理、排队和执行；Δ_a 是控制周期。我们把 $\Delta_{t,j} = \tau^{\mathrm{a}}_{t,j} - \tau_t$ 称为指令 j 的领先时长。指令须适配 $\tau^{\mathrm{a}}_{t,j}$ 时刻的场景，而非 τ_t 时刻的场景。

目标与环境。 设 $W_t(\mathbf{x}, \tau) \in \mathbb{R}^3$ 表示在 τ_t 时位于 $\mathbf{x}$ 的场景点从 τ_t 到 τ 的位移，以机器人基座坐标系表示。我们按任务所需的精度划分场景（图 2）。目标 $\mathcal{O}$ 是其位姿误差直接影响接触或容纳容差 ε 的刚体，例如待抓物体或待放入的容器。环境 $\mathcal{C}$ 包括只需避开的物体，如传送带、线缆、遮挡物，其间隙为 m。目标上的运动场由位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 决定：

$$W_t(\mathbf{x}, \tau) = T(\tau)\, T(\tau_t)^{-1}\mathbf{x} - \mathbf{x}, \qquad \mathbf{x} \in \mathcal{O}. \tag{2}$$

交互误差预算。 考虑距目标原点力臂为 r 的接触点，以及显式或隐式依据目标在 τ^{a} 时刻的位姿估计 $\hat{T}$ 行动的策略。旋转误差为 θ 时，接触误差满足

$$e_{\mathrm{c}} \le \|\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}})\| + 2r\sin(\theta/2). \tag{3}$$

表 1. **误差预算给出的预测。**每行对应式 (4)–(5) 中的一项，第 5.3 节在 Dynamic-14 留出场景上扫描其中提到的因素来检验。$\ell^\star$ 与 $\sigma^\star$ 为临界领先时长与临界噪声，e_F 为环境流在路径上的误差。

原则	误差项	预测
整体	e_c/ε	无补偿时，成功率仅经由 $\|\mathbf{v}\|\Delta/\varepsilon$ 随任务、速度和延迟变化，并在该比值超过约 1 后下降。
记住	$\hat{\Delta}e_v$	SE(3) 历史在超过 $\ell^\star$（各任务 [X]–[X] ms）后起作用，且随延迟与速度增大。
	$e_v(\sigma)$	其增益在位姿噪声达到 $\sigma^\star$（[X]–[X] mm）前保持。
预测	e_{dyn}, $r\theta$	学习的 SE(3) 未来在非匀速运动上优于外推，在旋转目标上优于点轨迹。
	m	间隙不低于 e_F 时，粗粒度流已足够。
行动	$\|\mathbf{v}\|e_\tau$	在 0.10 m/s 时 50 ms 的时域偏移带来 5 mm 误差，静止目标不受影响。按控制步计的领先时长在延迟变化时失效。

把领先时长 $\Delta = \tau^{\text{a}} - \tau_t$ 内的真实运动写为 $\mathbf{p}(\tau^{\text{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，其中 $\boldsymbol{\rho}$ 表示匀速外推未涵盖的部分，如加速、滚动和碰撞；相应估计为 $\hat{\mathbf{p}}(\tau^{\text{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。加减 $\mathbf{v}\hat{\Delta}$ 得

$$\|\hat{\mathbf{p}} - \mathbf{p}\| \le \underbrace{e_{\text{loc}}}_{\text{当前}} + \underbrace{\hat{\Delta}\, e_v}_{\text{领先时长×运动}} + \underbrace{\|\mathbf{v}\|\, e_\tau}_{\text{速度×时间}} + \underbrace{e_{\text{dyn}}}_{\text{动力学}}, \tag{4}$$

其中 $e_{\text{loc}} = \|\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\|$，$e_v = \|\hat{\mathbf{v}} - \mathbf{v}\|$，$e_\tau = |\hat{\Delta} - \Delta|$，$e_{\text{dyn}} = \|\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}\|$。旋转也可类似分解（附录 A）。环境以不同方式起作用。若指令路径与预测的环境位置 $\hat{\mathbf{y}}_t(\mathbf{x}, \tau)$ 保持间隙 m，则发生碰撞意味着路径经过的集合 $\mathcal{P}$ 中至少某个点在某个时刻的预测误差达到 m：

$$\text{碰撞} \;\Rightarrow\; \max_{(\mathbf{x},\tau)\in\mathcal{P}} \left\|\hat{\mathbf{y}}_t(\mathbf{x},\tau) - \mathbf{y}_t(\mathbf{x},\tau)\right\| \ge m. \tag{5}$$

若 $e_c \le \varepsilon$ 且未发生碰撞，则试验成功。式 (3)–(5) 来自一个恒等式和三角不等式。我们将其用作误差预算，而非成功率模型。

预测。 给定各任务的容差和速度（附录 B.1）：(i) 忽略运动的策略产生 $\|\mathbf{v}\|\Delta$ 的误差，因此应在超过临界领先时长 $\ell^\star = \varepsilon/\|\mathbf{v}\|$ 后失败，其成功率应仅通过 $\|\mathbf{v}\|\Delta/\varepsilon$ 依赖任务、速度与延迟。(ii) 对时间跨度 T 内、噪声为 σ 的 n 个位姿进行最小二乘拟合，速度估计误差约为 $\sigma\sqrt{12/n}/T$ [4]，因此位姿历史在噪声达到 $\sigma^\star = \varepsilon T\sqrt{n}/(\Delta\sqrt{12})$ 之前仍应有用。(iii) 预测与生效时刻错位 δ 会增加 $\|\mathbf{v}\|\delta$ 的误差，该误差随速度增大，并在目标静止时消失。(iv) 路径误差为 e_F 的环境预测在 $m > e_F$ 时足够。

对设计的启示。 表 1 将各项误差对应到能够减小它的策略组成。*记住*。给定可靠的当前位姿，历史可减小 e_v，并通过加速度减小部分 e_{dyn}。由于 e_v 被领先时长放大，历史通过目标的度量运动状态起作用；像素、光流或视频 token 只有在策略能从中恢复该状态时才有帮助。*预测*。减小 e_{dyn} 需要目标运动模型，旋转误差则会被 r 放大。因此，目标未来应表示为完整的 SE(3) 轨迹，它根据式 (2) 决定目标所有点的运动。环境误差可容忍至 m，所以误差低于 m 的 3D 流已经足够，外观并不进入误差预算。*行动*。各项都在依赖延迟的 τ^{a} 时刻计算。因此，预测与指令应以物理时间索引，策略应知道每条指令的领先时长。动作应在线读取预测，还是通过训练将其编码进自身，误差预算并未给出答案；我们以实验回答这一问题（第 5.3 节）。

4 SE(3)-WAM

SE(3)-WAM （图 3）是一个包含三类 token 的 Transformer。条件 token 编码观测与目标运动历史（*记住*），世界查询在物理时域上预测运动场（*预测*），动作 token 生成以领先时长为条件的指令（*行动*）。

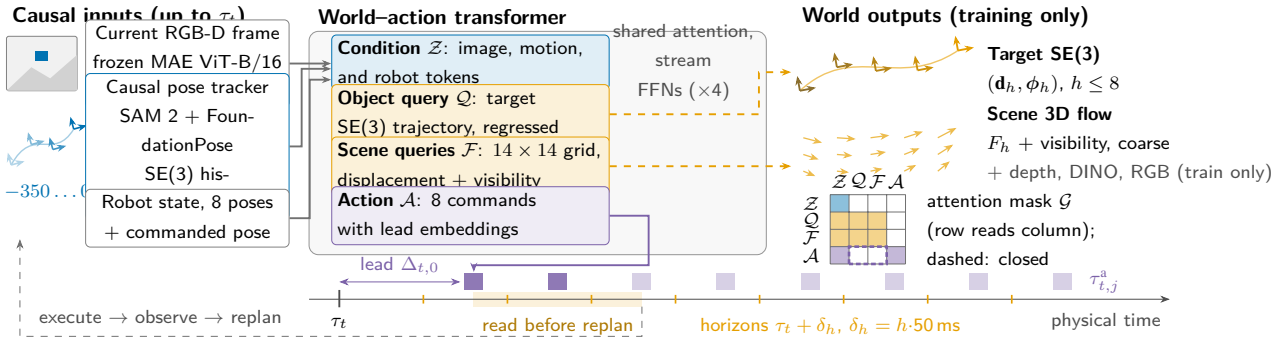


图 3. **SE(3)-WAM** 。条件 token $\mathcal{Z}$ 编码当前 RGB-D 帧、因果跟踪器给出的目标 SE(3) 历史与机器人状态（记住）。物体查询 $\mathcal{Q}$ 和场景查询 $\mathcal{F}$ 在物理时域 $\tau_t + \delta_h$ 回归目标 SE(3) 轨迹与带可见性的粗粒度 3D 场景流，外观头提供额外训练目标（预测）。动作 token $\mathcal{A}$ 生成在 $\tau^{\mathrm{a}}_{t,j}$ 生效、以领先时长为条件的指令，每 100 ms 重新规划（行动）。掩码 $\mathcal{G}$ 决定各组能关注哪些组。动作 token 不关注任何世界 token，因此部署时只运行动作流。

世界采用确定性预测，动作通过流匹配生成 [24]。

4.1 记住：目标的度量运动历史

我们用因果跟踪器在每帧全分辨率 RGB-D 图像中估计目标位姿。SAM 2 从目标提示传播掩码 [32]，FoundationPose 根据 CAD 模型或少量参考视图跟踪物体 [43]。若两者均不可用，则使用单目三维检测器逐帧估计度量三维框位姿 [18]。每个估计只输出一次，附带采集时间和有效性标记，后续帧不修订它。我们在 $-350, -300, \ldots, 0$ ms 对因果轨迹重采样，使其含义不依赖相机帧率，并用区间运动、有限差分速度与加速度及当前位姿构建 8 个运动 token，均以基座坐标系和物理单位表示（附录 C.1）。冻结的 MAE ViT-B/16 [14] 把当前 RGB 图像编码为 196 个图像块 token，深度图为每块提供用于旋转注意力的度量三维位置。机器人 token 包含 8 个末端执行器状态和首个生效时刻的指令位姿；模型不接收过去图像。训练使用与测试时相同的因果位姿估计，也包含跟踪失败。

4.2 预测：按角色区分的运动场

世界查询在 $\tau_t + \delta_h$ 时域预测 W_t，其中 $\delta_h = h{\cdot}50$ ms，$h = 1, \ldots, 8$。这些时域覆盖下次重规划前所有实际执行指令的领先时长（附录 A.4）。我们通过式 (2) 参数化目标。对每个时域，

$$\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t), \quad \phi_h = \mathrm{Log}\big(R(\tau_t{+}\delta_h)R(\tau_t)^\top\big)^\vee. \tag{6}$$

物体查询回归 $(\mathbf{d}_h, \phi_h)$，损失 $\mathcal{L}_P$ 为平移误差平方加上 λ_R 倍旋转测地误差平方。对旋转对称目标，排除绕对称轴不可观测的旋转。场景其余部分表示为 3D 场景流：固定14×14 图像网格上 $N = 196$ 个点在基座坐标系中的位移 $F_h \in \mathbb{R}^{N\times 3}$，这些点在工作空间内间距约为 [X] mm。每点对应一个带角色嵌入（目标、机器人或环境）的场景查询，回归其位移与可见性（$\mathcal{L}_F$）。按误差预算的允许范围，我们特意采用粗网格，并在第 5.3 节检验其何时足够。由于外观不进入误差预算，未来深度、DINOv3 特征 [33] 和运动表面的 RGB 仅作为场景查询的额外训练目标（$\mathcal{L}_{\mathrm{aux}}$）。所有标签均表示相对当前状态的累积变化，损失只使用有效标签。

4.3 行动：以领先时长为条件的动作

动作块包含 8 条指令，在式 (1) 给出的时刻生效。每条指令包括末端执行器在基座坐标系中的平移、左相对旋转，以及夹爪指令。增量相对控制器已知的上一生效时刻的指令位姿定义，而非采集时

刻的机械臂位姿 [36]。每个动作 token 嵌入其领先时长 $\Delta_{t,j} = \ell_t + j\Delta_a$。训练时采样 $\ell \sim \mathcal{U}[0, 250\,ms]$，从示范的 $\tau_t + \ell + j\Delta_a$ 时刻读取指令标签，使单个模型适用于该范围内的任意延迟。对归一化动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 和 $u \sim \mathcal{U}[0, 1]$，动作损失为

$$\mathcal{L}_A = \mathbb{E}\left\| v_\psi(\mathbf{a}_u, u \mid \mathcal{Z}_t, \hat{\mathcal{W}}_t, \mathcal{G}) - (\mathbf{a}_1 - \mathbf{a}_0) \right\|^2, \tag{7}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{Z}_t$ 为条件 token，$\hat{\mathcal{W}}_t$ 为耦合方式允许读取的世界信息。总损失为 $\mathcal{L} = \mathcal{L}_A + \lambda_F \mathcal{L}_F + \lambda_P \mathcal{L}_P + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}}$。

注意力掩码 $\mathcal{G}$ 作用于四组 token：条件 $\mathcal{Z}$、物体查询 $\mathcal{Q}$、场景查询 $\mathcal{F}$ 和动作 $\mathcal{A}$。条件 token 仅相互关注，世界查询关注条件及彼此，动作 token 关注条件、自身及其耦合方式允许读取的世界部分。第 5.3 节比较动作不读取世界、读取世界查询隐藏状态、读取解码几何，以及世界也读取动作的耦合方式。在 SE(3)-WAM 中，动作不读取任何世界 token。世界损失在训练时塑造共享参数，部署时只运行动作流。两条流共享注意力投影，使用独立的前馈网络。

执行与实现。 测试时，根据执行器的延迟预算设定领先时长，即近期推理时间的 p95 加执行延迟。Transformer 包含 4 层，宽度为 768，有 8 个注意力头，主干参数量为 47.3M，总可训练参数量为 62.2M。图像编码器与 DINOv3 教师均冻结。在 Dynamic-14 上，用 8 块 RTX PRO 6000 GPU 训练 4 个 epoch（全局 batch 为 16，约 40k 次更新），每个训练种子约需 7.7 小时。测试时，动作流以半精度执行 5 步 Euler 积分，在 RTX 5090 上从观测到动作的 p95 延迟为 [XX] ms（附录 C.6）。

4.4 在提升为 4D 的真实机器人数据上预训练

真实机器人数据既没有物体位姿，也没有场景流，因此我们在不使用物体模型的条件下，把 DROID [20] 提升为度量 4D 标签。场景流来自 PointWorld 为 DROID 发布的三维轨迹与优化后的相机标定 [17]。我们把指令中提到的物体作为目标，先用开放词汇检测器定位 [26]，再用 SAM 2 跟踪掩码，并由单目三维检测器估计度量位姿。输入来自与部署时相同的前向轨迹；式 (6) 的标签来自对整条 episode 平滑后的前向—后向轨迹。DROID 目标主要在机器人推动它们时运动（[X]% 的窗口在接触前存在目标运动），因此预训练主要学习度量几何、3D 流及其与领先时长条件动作的耦合。每项真机任务的策略均从该基座初始化。仿真模型从通用初始化训练，另设受控对照在 Dynamic-14 上对该基座后训练（附录 E）。

5 实验

5.1 设置

Dynamic-14 。 我们在 MuJoCo/robosuite [38, 62] 中构建十四项任务，分为五类：抓取运动目标（谐波、传送带、平移、旋转与遮挡运动）、向移动容器放置、沿旋转线缆移动套杆、捕获滚动或滑动物体，以及碰撞后抓取。各类任务考察误差预算中的特定项（附录 B.1、图 S1）。扫描改变速度（0.5–1.5×）、附加延迟（0–200 ms）、通行间隙（[取值] mm）和位姿噪声。使用仿真器状态的脚本专家为每项任务提供 800 条示范。我们在开发场景上选择配置，所有 Dynamic-14 数值均来自 1,400 个留出场景（每任务 100 个，采用新种子）。我们的方法变体平均三个训练种子，每个基线训练一次。报告种子均值，并通过对留出场景 bootstrap 给出配对 95% 区间。

协议。 所有方法在同一执行器下实时运行，物理仿真在方法计算期间按其在单块 RTX 5090 上实测的延迟推进。每隔 100 ms 或在上次推理结束时请求新的动作块；指令在各自生效时刻执行，过时指令

表 2. **主要结果**。Dynamic-14 留出集成功率（%；1,400 个新场景，按任务等权，实时协议，本文各变体取三个训练种子的平均，基线训练一次），按任务族分列；另列加入 150 ms 延迟后的成功率、推理期间物理暂停时的成功率（暂停）、DOMINO 单臂成功率、LIBERO 四个套件的平均成功率，以及在一块 RTX 5090 上的 p95 出动作时间。输入：R 为 RGB 与机器人状态；D 为深度；P 为本文跟踪器借助物体模型给出的目标 SE(3) 历史；P′ 为单目三维检测器给出的同一历史，无需物体模型。粗体为最佳；置信区间见附录 G。

		Dynamic-14，除注明外为实时协议										
方法	输入	全部	抓取	放置	穿越	捕获	撞击	+150 ms	暂停	DOMINO	LIBERO	p95 (ms)
ACT [58]	R	—	—	—	—	—	—	—	—	—	—	—
Diffusion Policy [10]	R	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ [31]	R	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	R+P	—	—	—	—	—	—	—	—	—	—	—
DynamicVLA [46]	R	—	—	—	—	—	—	—	—	—	—	—
PUMA [12]	R	—	—	—	—	—	—	—	—	—	—	—
DreamVLA [55]	R	—	—	—	—	—	—	—	—	—	—	—
OpenWAM-α [42]	R	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM [29]	R	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM + SE(3)	R+P	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	RD+P	—	—	—	—	—	—	—	—	—	—	—
卡尔曼拦截器	D+P	—	—	—	—	—	—	—	—	–	–	—
SE(3)-WAM，检测器位姿	RD+P′	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM	RD+P	—	—	—	—	—	—	—	—	—	—	—

被丢弃。+150 ms 设置为所有方法额外增加 150 ms 延迟，附录 G.2 将该协议与三种替代协议比较。我们报告任务均衡成功率（SR）、接触时间误差 e_t、首次接触时位置误差 e_p，以及从观测到动作的 p95 延迟。在 DOMINO [12] 上评测单臂拦截与跟踪，LIBERO [25] 则检验结构化世界表示是否损失静态任务性能。

基线。 我们比较反应式策略（ACT [58]、Diffusion Policy [10]、$\pi_{0.5}$ [31]）、动态 VLA（DynamicVLA [46]、PUMA [12]）、图像或隐空间 WAM（DreamVLA [55]、OpenWAM-α [42]），以及动态 WAM（DynamicWAM [29]）。各基线使用官方代码、输入与训练配方，在相同示范上训练一次；若原配方使用腕部相机，则提供对应渲染视图（附录 F）。SE(3)-WAM 只使用 agent 视角，但额外使用深度和跟踪得到的目标位姿。为区分这些输入与表示本身的影响，$\pi_{0.5}$ 和 DynamicWAM 也接收我们的 SE(3) 历史 token（+SE(3)），并报告使用无需物体模型的单目三维检测器位姿的 SE(3)-WAM 。两个基线仅使用跟踪器：*CV input* 是不含世界监督、以跟踪位姿的匀速外推作为输入 token 的 SE(3)-WAM ；卡尔曼拦截器则向匀加速卡尔曼滤波器预测的目标位姿规划 [4]。

5.2 主要结果

实时条件下，SE(3)-WAM 在 Dynamic-14 留出场景上达到 [XX.X]% SR（表 2），比最强基线 [最强基线名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [最强 +SE(3) 基线名称] 高 [X.X] 个百分点。然而，推理时暂停物理仿真后，[暂停协议下最强基线名称] 领先 [X.X] 个百分点。不计计算时间的代价时，其更大模型与更丰富预测能够发挥作用，但每次查询需要 [XXX] ms。SE(3)-WAM 的优势在 [旋转目标（$r\theta$）以及 $\|\mathbf{v}\|\Delta$ 主导的高速传送带和平移目标] 上最大 [，且没有方法解决向旋转容器进行 SE(3) 放置的任务]。附加 150 ms 延迟后，SE(3)-WAM 保持 [XX.X]%，反应式策略降至 [XX.X]%，图像空间 WAM 降至 [XX.X]%。以检测器位姿替代 CAD 模型损失 [X.X] 个百分点。CV-input 变体与卡

图占位：图 4——实测趋势与预测对照（六个面板）

(a) 未补偿运动。横轴：首条指令生效时的 $\|\mathbf{v}\|\Delta/\varepsilon$（对数）；纵轴：SR。每个点对应方法 × 任务族 × 速度 × 延迟；反应式策略用灰色，拟合 logistic 曲线并给出 Spearman ρ，标出预测阈值 1；运动补偿基线和 SE(3)-WAM （橙色）显示为偏移后的曲线。**(b) 记住 / 领先时长。**横轴：附加延迟（0–200 ms）；纵轴：相对当前帧的 ΔSR。曲线：RGB 窗口、光流、视频 VAE 隐变量（灰色），因果 SE(3)（蓝色），检测器 SE(3)（蓝色点线），真值 SE(3)（蓝色虚线）；静止目标用浅色线；标出各任务族的 $\ell^\star$。**(c) 记住 / 噪声。**横轴：注入的位姿噪声 σ（mm，含 $\sigma = 0$ 的 symlog 轴）；纵轴：SE(3) 历史的 SR；色带为最佳视觉历史；竖线标出预测 $\sigma^\star$ 与跟踪器实测误差。**(d) 预测 / 目标动力学。**按运动类型（匀速、谐波、滚动 / 滑动、碰撞后）分组画柱：CV、CA 与学习的 SE(3) 预测（橙色）在 τ^{a} 时的预测误差，对应策略的 SR 以点表示。**(e) 预测 / 环境。**仅通行任务。横轴：间隙（mm）；纵轴：SR；曲线：无环境流、14^2、28^2、56^2 网格、未来隐变量；标出各网格实测 e_F。**(f) 行动 / 耦合。**横轴：附加延迟；纵轴：相对仅训练时世界监督（R1）的 ΔSR；曲线：隐藏状态读取（R2）、双向（R4）、解码几何（R5）、关闭世界损失（R0，点线）；静止目标在右侧用点表示。留出场景、三个种子、95% 配对 bootstrap 色带；各面板中任务族配色一致。

图 4. **实测趋势与误差预算的预测对照。**(a) 反应式策略的成功率相对于未补偿运动与容差之比坍缩到同一曲线，运动补偿使曲线偏移。(b) SE(3) 历史在超过临界领先时长后产生收益，且收益随延迟增大；视觉历史基本不变。(c) 其价值保持到预测的噪声水平 $\sigma^\star$。(d) 学习的 SE(3) 预测在非匀速运动上优于外推。(e) 粗粒度环境流在间隙降到其误差前足够。(f) 仅训练时的世界监督在各延迟下均与在线使用预测相当。色带为 95% 配对 bootstrap 区间。

尔曼拦截器分别落后 SE(3)-WAM [X.X] 和 [X.X] 个百分点，差距主要来自非匀速运动；给 SE(3)-WAM 额外输入外推位姿使 SR 变化 [±X.X] 个百分点（附录 D.3）。在 DOMINO 上，SE(3)-WAM 为 [XX.X]%，[DOMINO 最强基线名称] 为 [XX.X]%。在静态 LIBERO 任务上，SE(3)-WAM 落后 $\pi_{0.5}$ [X.X] 个百分点（[XX.X]% 对 [XX.X]%）。

5.3 检验预测

我们用仅改变一个设计轴、保持数据、训练预算及其他轴不变的 SE(3)-WAM 变体，检验表 1 中的各项预测（表 3、图 4、附录 D）。

未补偿运动。 我们绘制所有方法的成功率与 $\|\mathbf{v}\|\Delta/\varepsilon$ 的关系，即目标在领先时长内的运动相对于容差的大小（图 4a）。跨任务、速度与延迟，反应式策略 [落在同一曲线上]（Spearman $\rho = [X.XX]$），成功率在 [X.X] 处减半。误差预算仅给出约为一的阈值，并不预测曲线形状。[捕获任务在曲线周围的离散最大]，因为其成功还取决于夹爪何时合拢。估计目标运动的方法使曲线右移，SE(3)-WAM 的右移最明显。

记住。 我们固定当前帧、当前目标位姿与机器人历史。加入八帧 RGB、同一窗口的光流及 DynamicWAM 运动统计 [29]，或视频 VAE 隐变量，使 SR 变化 [X.X] 个百分点（95% 区间 [[a, b]]）。因果 SE(3) 历史提升 [X.X] 个百分点，真值历史提升 [X.X] 个百分点（表 3）。收益在超过各任务族的临界领先时长后出现，随延迟增大，在静止目标上消失（图 4b）。冻结读出表明视觉历史包含运动信息（附录 D.2），但在我们的数据规模下，策略未将其转化为度量速度，即使为历史帧提供度量 XYZ 也如此（[±X.X] 个百分点）。注入位姿噪声后，SE(3) 历史在 [X] mm 处降至最佳视觉历史水平（图 4c），为不依赖学习模型的预测 $\sigma^\star$ 的 [X.X] 倍，这与带运动先验的学习型估计器预期更强相符；该噪声也为跟踪器误差的 [X] 倍。

预测。 用目标 SE(3) 轨迹代替点轨迹作为监督，总体 SR 变化 [±X.X] 个百分点，但在力臂放大旋转误差的旋转目标上提升 [X.X] 个百分点。对预测点轨迹拟合 SE(3) 可恢复其中 [X.X] 个百分点。在生效时刻，学习的 SE(3) 预测在传送带运动上与同一历史的匀速及匀加速外推精度相当，但在 e_{dyn} 主导的滚动、滑动与碰撞后运动上精度高出 [X] 倍（图 4d）。对于环境，路径误差为 $e_F = [X]$ mm 的14×14

表 3. **受控设计比较**（留出场景，三个训练种子）；选定配置（⋆）在开发集场景上确定。每组只改变一个设计轴，其余固定。SR、SR_{150}：不加和加入 150 ms 延迟时的成功率（%）；e_t：接触时刻误差（ms）；e_p：首次接触时的位置误差（mm）；p95：出动作时间（ms）。

变体	SR	SR_{150}	e_t	e_p	p95
记住（当前帧、当前位姿与机器人历史固定）					
仅当前帧	—	—	—	—	—
+ RGB 窗口（8 帧）	—	—	—	—	—
+ 光流与运动统计	—	—	—	—	—
+ 视频 VAE 隐变量	—	—	—	—	—
+ SE(3) 历史（因果估计）⋆	—	—	—	—	—
+ SE(3) 历史（真值）	—	—	—	—	—
预测（未来表示）					
无未来预测	—	—	—	—	—
目标点轨迹 + 环境流	—	—	—	—	—
目标点轨迹 → SE(3) 拟合 + 环境流	—	—	—	—	—
仅目标 SE(3)	—	—	—	—	—
SE(3) + 14 × 14 流⋆	—	—	—	—	—
SE(3) + 28 × 28 流	—	—	—	—	—
SE(3) + 未来 RGB/隐变量	—	—	—	—	—
行动（世界—动作耦合）					
世界仅作训练目标⋆	—	—	—	—	—
动作读取世界隐藏状态	—	—	—	—	—
双向读取隐藏状态	—	—	—	—	—
动作读取解码几何	—	—	—	—	—

流，在通行间隙降至 [X] mm 之前与 28^2 和 56^2 网格相当（图 4e），世界流的训练成本低 [X] 倍。去掉环境流损失 [X.X] 个百分点，主要来自通行任务。作为预测世界的表示，未来 RGB、VAE 隐变量、深度、DINO 特征或冻结视频模型的隐变量，相比 SE(3) 轨迹与流均无增益（容量匹配时为 [±X.X] 个百分点），训练成本却可高达 [X] 倍。然而，将深度、DINO 特征与运动区域 RGB 作为额外训练目标，可提升 [X.X] 个百分点。

行动。 物理时间索引如预测所示起作用。将时域平移 50 ms，在速度最快的三分之一场景上使 SR 降低 [X.X] 个百分点，在静止目标上降低 [X.X] 个百分点；从首条指令起按控制步计领先时长，在测试与训练延迟不同时损失 [X.X] 个百分点。仅训练时使用世界监督、部署时只运行动作，与读取世界的耦合方式性能相当（0 ms 和 150 ms 时分别相差 [±X.X]、[±X.X] 个百分点，图 4f），从观测到动作的时间却低 [X.X] 倍。关闭世界损失会损失 [X.X] 个百分点，差距随领先时长增加，并在目标静止时消失。因此，收益来自把领先时长条件动作与其生效时刻的场景预测联合训练。

5.4 消融与预训练

移除 SE(3) 历史、世界损失或领先时长嵌入，分别使 Dynamic-14 SR 降低 [X.X]、[X.X]、[X.X] 个百分点；附加 150 ms 延迟时分别降低 [X.X]、[X.X]、[X.X] 个百分点（表 4）。真机上，DROID 基座相对通用初始化提升 [X.X] 个百分点（表 5）。在 Dynamic-14 上，后训练该基座在使用全部示范时使 SR 变化 [X.X] 个百分点，使用 10% 示范时变化 [X.X] 个百分点；仅用动作预训练的基座可恢复低数据收益的 [XX]%（附录 E）。

表 4. **最终模型消融**：Dynamic-14 留出场景与 DOMINO 的成功率（%）。SR_{150} 表示加入 150 ms 延迟。

模型	SR	SR_{150}	DOMINO
SE(3)-WAM	—	—	—
去除			
SE(3) 历史（仅当前位姿）	—	—	—
世界损失（R0）	—	—	—
领先时长嵌入（不提供延迟）	—	—	—
外观辅助目标（仅训练）	—	—	—
替换为			
按控制步计的领先时长	—	—	—
动作读取世界隐藏状态	—	—	—
DROID 基座初始化	—	—	—

表 5. **真机传送带抓取**。按物体与传送带速度（慢、中、快：0.04、0.08、0.12 m/s）分列的成功率（%；各 60 次试验）及每个方法全部 180 次试验的成功率。每个方法以三个种子微调，每个种子执行一组 60 次试验。二项分布 95% 区间见附录 F.3。

	物体			带速			
方法	盒	罐	杯	慢	中	快	全部
$\pi_{0.5}$ [31]	—	—	—	—	—	—	—
SE(3)-WAM，无 DROID 基座	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—

5.5 真机实验

七自由度 Franka 机械臂配备平行夹爪，在标定 RGB-D 相机观测下，抓取由传送带运送经过的物体，提起并保持 0.5 s（图 S4）。三个物体对朝向的要求不同：边长不等的盒子、细长罐子和单柄杯。传送带速度为 0.04、0.08 或 0.12 m/s。各方法在相同的 [300] 条遥操作示范上以三个种子微调，并进行 180 次试验，每个物体和速度组合 20 次；试验按共同的试验键分为三块，每块使用一个种子。SE(3)-WAM 成功率为 [XX.X]%（95% 区间 [[a, b]]），$\pi_{0.5}$ 为 [XX.X]%，不使用 DROID 基座时为 [XX.X]%（表 5）。相对 $\pi_{0.5}$ 的优势从 0.04 m/s 时的 [X.X] 个百分点，增至 0.12 m/s 时的 [X.X] 个百分点，在 [杯子] 上最大。剩余失败主要为 [夹爪下方跟踪丢失后闭合过晚]。

6 结论

我们研究策略要对运动物体采取行动，需要知道哪些信息，以及这些信息应对应哪个时刻。物理时间中的误差预算指向目标的度量运动、目标 SE(3) 轨迹与环境粗粒度流，以及按生效时刻索引的指令。SE(3)-WAM 遵循这些选择，在实时条件下，在仿真和真实传送带上优于已有策略。暂停物理仿真的对照说明了收益的来源：时间停止时，大型视频模型表现很强；场景在它们计算期间持续运动后，这一优势便消失。对世界—动作模型，我们的结果支持在指令生效时刻监督未来，并保持部署策略快速运行，而非在测试时生成未来。

局限。 误差预算假设目标为刚体，且在接触前自主运动，因此不涵盖可变形或关节式目标以及接触后动力学。SE(3)-WAM 依赖位姿跟踪器，其失败会传播到策略。单目三维检测器给出的位姿无需物体模型，但精度有所损失；回归式目标预测也无法表示多模态未来，例如碰撞前的不同可能运动。把 DROID 提升为 4D 标签需要大量计算。此外，我们的任务只有一个目标，环境运动较慢，真机研究也仅覆盖单一平台上的一项任务。

LLM Usage Statement（大语言模型使用声明）

[投稿前补充：实际使用的工具、受影响的研究与稿件部分，以及使用程度。]

参考文献

[1] Iretiayo Akinola, Jingxi Xu, Shuran Song, and Peter K. Allen. Dynamic grasping with reachability and motion awareness. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 9422–9429, 2021.

[2] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[3] Ronald Azuma and Gary Bishop. Improving static and dynamic registration in an optical see-through HMD. In *Proceedings of SIGGRAPH*, pages 197–204, 1994.

[4] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation*. Wiley, 2001.

[5] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[6] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, 2025.

[7] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, 2017.

[8] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[9] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[10] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[11] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. *arXiv preprint arXiv:2503.11565*, 2025.

[12] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. *arXiv preprint arXiv:2603.15620*, 2026.

[13] Gunnar Farnebäck. Two-frame motion estimation based on polynomial expansion. In *Proceedings of the Scandinavian Conference on Image Analysis*, pages 363–370, 2003.

[14] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[15] B. Hove and Jean-Jacques E. Slotine. Experiments in robotic catching. In *American Control Conference*, 1991.

[16] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *International Conference on Machine Learning*, 2025.

[17] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[18] Weikai Huang, Jieyu Zhang, Sijun Li, Taoyang Jia, Jiafei Duan, et al. WildDet3D: Scaling promptable 3D detection in the wild. *arXiv preprint arXiv:2604.08626*, 2026.

[19] Seth Hutchinson, Gregory D. Hager, and Peter I. Corke. A tutorial on visual servo control. *IEEE Transactions on Robotics and Automation*, 12(5):651–670, 1996.

[20] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[21] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[22] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[23] Minghui Lin, Pengxiang Ding, Shu Wang, Zifeng Zhuang, Yang Liu, Xinyang Tong, Wenxuan Song, Shangke Lyu, Siteng Huang, and Donglin Wang. HiF-VLA: Hindsight, insight and foresight through motion representation for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[24] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[25] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: Benchmarking knowledge transfer for lifelong robot learning. In *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*, 2023.

[26] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[27] Yushan Liu, Jingjing Fan, Shoujie Li, Yifan Xie, Xiao-Ping Zhang, and Wenbo Ding. PACT-WAM: Predicting actions and visual foresight with compact temporal encoding for robot manipulation. *arXiv preprint arXiv:2602.15882*, 2026.

[28] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[29] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[30] Henrique Morimitsu, Xiaobin Zhu, Roberto M. Cesar, Xiangyang Ji, and Xu-Cheng Yin. DPFlow: Adaptive optical flow estimation with a dual-pyramid framework. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17810–17820, 2025.

[31] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.

[32] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, 2025.

[33] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[34] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[35] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. *arXiv preprint arXiv:2606.02486*, 2026.

[36] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[37] Zachary Teed and Jia Deng. RAFT-3D: Scene flow using rigid-motion embeddings. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.

[38] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[39] Changhao Wang, Jaden Clark, and Shuran Song. Chronos policy: Learning robot policies on physical time. *arXiv preprint arXiv:2610.13929*, 2026.

[40] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[41] Ruicheng Wang, Sicheng Xu, Yue Dong, Yu Deng, Jianfeng Xiang, Zelong Lv, Guangzhong Sun, Xin Tong, and Jiaolong Yang. MoGe-2: Accurate monocular geometry with metric scale and sharp details. *arXiv preprint arXiv:2507.02546*, 2025.

[42] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[43] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[44] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[45] Yuxi Xiao, Qianqian Wang, Shangzhan Zhang, Nan Xue, Sida Peng, Yujun Shen, and Xiaowei Zhou. SpatialTracker: Tracking any 2D pixels in 3D space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[46] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. *arXiv preprint arXiv:2601.22153*, 2026.

[47] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, 2024.

[48] Zhenjia Xu, Zhanpeng He, Jiajun Wu, and Shuran Song. Learning 3D dynamic scene representations for robot manipulation. In *Conference on Robot Learning*, 2020.

[49] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[50] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[51] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

[52] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. *arXiv preprint arXiv:2607.01938*, 2026.

[53] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[54] Chuhan Zhang, Guillaume Le Moing, Skanda Koppula, Ignacio Rocco, Liliane Momeni, Junyu Xie, Shuyang Sun, Rahul Sukthankar, Joëlle K. Barral, Raia Hadsell, Zoubin Ghahramani, Andrew Zisserman, Junlin Zhang, and Mehdi S. M. Sajjadi. Efficiently reconstructing dynamic scenes one D4RT at a time. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

[55] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[56] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[57] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Tsung-Yi Lin, Gordon Wetzstein, Ming-Yu Liu, and Donglai Xiang. CoT-VLA: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[58] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[59] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *International Conference on Learning Representations*, 2025.

[60] Hongyan Zhi, Peihao Chen, Siyuan Zhou, Yubo Dong, Quanxi Wu, Lei Han, and Mingkui Tan. 3DFlowAction: Learning cross-embodiment manipulation from 3D flow world model. *arXiv preprint arXiv:2506.06199*, 2025.

[61] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[62] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

补充材料

本补充材料给出误差预算的推导（附录 A）、基准（附录 B）、实现细节（附录 C）、设计研究（附录 D）、DROID 预训练（附录 E）、基线、外部基准、真机与计时（附录 F），以及补充结果（附录 G）。彩色破折号和方括号内容表示等待最终运行填写的数值。

A 交互误差预算

本附录推导第 3 节的误差预算，将其扩展到旋转和分块执行，给出具体预测及 Dynamic-14 中的量级，并说明其不适用的情形。

A.1 平移

设生效时刻的真实目标位置为 $\mathbf{p}(\tau^{\mathrm{a}}) = \mathbf{p}(\tau_t) + \mathbf{v}\Delta + \boldsymbol{\rho}$，策略估计为 $\hat{\mathbf{p}}(\tau^{\mathrm{a}}) = \hat{\mathbf{p}}(\tau_t) + \hat{\mathbf{v}}\hat{\Delta} + \hat{\boldsymbol{\rho}}$。加减 $\mathbf{v}\hat{\Delta}$ 得到恒等式

$$\begin{aligned}\hat{\mathbf{p}}(\tau^{\mathrm{a}}) - \mathbf{p}(\tau^{\mathrm{a}}) = \big[\hat{\mathbf{p}}(\tau_t) - \mathbf{p}(\tau_t)\big] + (\hat{\mathbf{v}} - \mathbf{v})\hat{\Delta} \\ + \mathbf{v}(\hat{\Delta} - \Delta) + (\hat{\boldsymbol{\rho}} - \boldsymbol{\rho}),\end{aligned} \tag{S1}$$

再由三角不等式得到式 4。由于 $\mathbf{v}$ 是 τ_t 时刻的速度，$\boldsymbol{\rho}$ 恰好是匀速外推未能涵盖的运动部分。恒定加速度 $\mathbf{a}$ 下，$\boldsymbol{\rho} = \frac{1}{2}\mathbf{a}\Delta^2$，由历史估计加速度可消除部分 e_{dyn}。碰撞、滚动接触及摩擦变化留下的剩余误差，需要动力学模型才能减小。对学习型预测器，将估计拆分为 $\hat{\mathbf{v}}\hat{\Delta}$ 与 $\hat{\boldsymbol{\rho}}$ 并不可辨识，因为任何预测位置均能写成这一形式。因此，我们用误差预算说明各项需要哪些信息。实验不分离学习型预测器内部的各项，而是改变领先时长、速度、位姿噪声和时序这些作用于已知项的因素，并比较接收不同信息的变体（附录 A.5）。

A.2 旋转与接触点

记 $R(\tau^{\mathrm{a}}) = \mathrm{Exp}(\boldsymbol{\omega}\Delta + \boldsymbol{\eta})R(\tau_t)$，$\hat{R}(\tau^{\mathrm{a}}) = \mathrm{Exp}(\hat{\boldsymbol{\omega}}\hat{\Delta} + \hat{\boldsymbol{\eta}})\hat{R}(\tau_t)$。当 R 与 $\hat{R}$ 绕同一固定轴旋转时，指数映射可以相加组合，因此

$$\theta = \big\| \mathrm{Log}(\hat{R}(\tau^{\mathrm{a}})R(\tau^{\mathrm{a}})^{\top})^{\vee} \big\| \le \theta_{\mathrm{loc}} + \hat{\Delta}\, e_{\omega} + \|\boldsymbol{\omega}\|\, e_{\tau} + e_{\eta}, \tag{S2}$$

其中 θ_{loc} 为当前朝向误差，e_{ω} 与 e_{η} 的定义类似于平移情形。对一般旋转，Baker–Campbell–Hausdorff 公式会引入角度的二阶项。物体坐标系中位于 $\mathbf{c}$、满足 $\|\mathbf{c}\| = r$ 的接触点，其世界位置为 $\mathbf{p} + R\mathbf{c}$，误差为 $(\hat{\mathbf{p}} - \mathbf{p}) + (\hat{R}R^{\top} - I)R\mathbf{c}$。旋转角为 θ 时，$\hat{R}R^{\top} - I$ 的算子范数为 $2\sin(\theta/2)$，故

$$e_{\mathrm{c}} \le \|\hat{\mathbf{p}} - \mathbf{p}\| + 2r\sin(\theta/2) \le \|\hat{\mathbf{p}} - \mathbf{p}\| + r\theta, \tag{S3}$$

即式 3。朝向误差因此按力臂放大后进入接触几何；依赖朝向的抓取或放置需要 SE(3) 目标状态。对旋转对称目标，绕对称轴旋转不改变任何接触，我们在输入、标签与误差中排除该分量。

A.3 环境与间隙

设 $\mathcal{P}$ 为执行路径经过的环境点与时刻集合。假设机器人及其携带物体的每个点 $\mathbf{x}$，均与 $(\mathbf{z}, \tau) \in \mathcal{P}$ 对应的预测环境位置 $\hat{\mathbf{y}}_t(\mathbf{z}, \tau)$ 保持至少 m 的距离。碰撞要求某个 $(\mathbf{z}, \tau) \in \mathcal{P}$ 满足 $\mathbf{x} = \mathbf{y}_t(\mathbf{z}, \tau)$，此时 $\|\hat{\mathbf{y}}_t(\mathbf{z}, \tau) - \mathbf{y}_t(\mathbf{z}, \tau)\| = \|\hat{\mathbf{y}}_t(\mathbf{z}, \tau) - \mathbf{x}\| \ge m$，即式 5。因此，环境精度细于 m 时，对成功没有一阶影响。

该界约束误差大小，并未约束采样。网格采样的流会遗漏比网格间距更细的结构，并在运动边界处产生误差。两者都进入路径误差 e_F；我们沿执行路径在留出点上测量它（附录 D.3），而不从网格间距推断。裕度本身也是设计变量：环境估计较粗时，策略可以留出更大裕度，但会付出可达性或时间代价。

A.4 分块执行下的领先时长

动作块包含 H 条指令，其中前 k 条在下一动作块替换其余指令前执行，相关领先时长为 $\Delta_{t,j} = \ell_t + j\Delta_a$，$j < k$。因此预测时域须覆盖 $[\ell_t, \ell_t + (k-1)\Delta_a]$；时域之间的状态通过插值得到，平移采用线性插值，旋转沿测地线插值。延迟最高为 250 ms、每隔 100 ms 重新规划时，领先时长保持在 350 ms 内，落在 400 ms 的预测范围内。由于时域和领先时长以物理时间索引，延迟变化只改变读取哪个时域，无需重新训练。“按控制步计领先时长”消融（表 4）则从首条指令开始以控制周期计数，与把观测和执行时刻视为相同的策略一致。它在训练延迟下训练，延迟变化时指向错误时刻。

A.5 预测

临界领先时长。 不补偿运动的策略（$\hat{\mathbf{v}} = 0$，$\hat{\boldsymbol{\rho}} = 0$）除 e_{loc} 与 $\|\boldsymbol{\rho}\|$ 外，还产生 $\|\mathbf{v}\|\Delta$ 的误差。定位误差较小且运动平滑时，一旦 $\|\mathbf{v}\|\Delta > \varepsilon$，即超过临界领先时长 $\ell^\star = \varepsilon/\|\mathbf{v}\|$，接触便会失败；成功率仅通过 $\|\mathbf{v}\|\Delta/\varepsilon$ 依赖任务、速度与延迟。表 S3 列出每项任务的 ε、$\|\mathbf{v}\|$ 与 $\ell^\star$。图 4a 将各方法成功率对 $\|\mathbf{v}\|\Delta/\varepsilon$ 作图：该量在每条 episode 首条指令生效时计算，汇总不同任务、速度与延迟，并对反应式策略给出 Spearman 相关系数和拟合的 logistic 曲线。

位姿噪声。 对时间跨度 T 内的 n 个等间隔位姿，若各轴具有独立噪声 σ，最小二乘速度估计的标准差为 $\sigma\sqrt{12(n-1)/(n(n+1))}/T \approx \sigma\sqrt{12/n}/T$ [4]。因此，位姿历史在噪声达到 $\sigma^\star = \varepsilon T\sqrt{n}/(\Delta\sqrt{12})$ 前可将 $\hat{\Delta}e_v$ 保持在容差内。取 $\varepsilon = 10\,\text{mm}$、$T = 350\,\text{ms}$、$n = 8$、$\Delta = 200\,\text{ms}$，得到 $\sigma^\star \approx 14\,\text{mm}$。带运动先验的学习型估计器可以更好，因此 $\sigma^\star$ 是不依赖学习模型的线性估计预测；图 4c 将其与实测交叉点比较。

时域偏移。 在 $\tau^{\text{a}} + \delta$ 而非 τ^{a} 读取预测，使 $e_\tau = |\delta|$，并给接触误差增加 $\|\mathbf{v}\|\,|\delta|$。固定偏移的代价因此随目标速度增大，在静止目标上消失。

间隙。 路径误差为 e_F 的环境预测在 $m > e_F$ 时可避免碰撞。因此，间隙高于实测 e_F 时，粗流应与更细的流相当，低于它时则落后。

A.6 Dynamic-14 中的量级

表 S1 在代表性 Dynamic-14 设置下计算各项（表 S4）。每一项都与成功条件中的毫米级容差相当或更大（表 S2）。

斜坡一项使用实心球无滑动滚动时的加速度：$\alpha = 10^\circ$ 时 $a = \frac{5}{7}g\sin\alpha \approx 1.2\,\text{m/s}^2$，并以 $\Delta = 0.2\,\text{s}$ 计算 $\frac{1}{2}a\Delta^2$。

A.7 适用范围

误差预算针对接近刚性目标的过程，目标在接触前作外源运动。它不涵盖可变形或关节式目标，其在 $\mathcal{O}$ 上的运动场无法用六个数确定；也不涵盖依赖动作本身的接触后运动，这类情形需要以动作为条

表 S1. 领先时长为 200 ms 时，误差预算各项的示例量级。这些数值由所列物理量计算得到，并非测量值。

项	设置	大小
$\|\mathbf{v}\|\Delta$	传送带速度 0.10 m/s	20 mm
$\hat{\Delta}e_v$	速度误估 10%	2.8 mm
$\|\mathbf{v}\|e_\tau$	时间误差 50 ms（一个周期）	7.0 mm
$2r\sin(\theta/2)$	未预测 $\omega = 1.2$ rad/s，$r = 3$ cm	7.2 mm
e_{dyn}	小球位于 10° 斜坡，无加速度模型	24 mm
ε	传送带零件的抓取容差	[X] mm
网格间距	工作空间处的14 × 14 流	[X] mm

件的预测，让世界读取动作可能在此时有用。目标角色随时间变化的场景，例如顺序多物体任务，也不在其范围内。感知质量仅通过 e_{loc} 和 e_v 进入，我们单独测量它（附录 E.4）。该界并非成功概率，而是识别各类误差如何随因素缩放；第 5.3 节检验这些缩放关系与上述数值。

B Dynamic-14

B.1 任务、角色与误差项

我们基于 MuJoCo 和 robosuite [38, 62] 构建 Dynamic-14 ，包含五个任务族中的十四项任务（图 S1）。表 S2 列出成功条件，表 S4 列出场景范围。我们将发布任务、通过可行性检查的场景、成功判定和示范。

角色与临界领先时长。 表 S3 将各任务中的物体划入第 3 节的两类角色。目标的位姿误差进入接触或容纳容差 ε；环境由只需保持间隙 m 以避开的物体组成。移动容器因此属于目标，其位姿决定是否容纳成功。通行任务的线缆同时承担两种角色：入口位姿是目标，因为套杆必须在 30 mm 内对齐；环内沿途几何是环境，因为任何接触都会导致失败。表中还给出各任务的速度、临界领先时长 $\ell^\star = \varepsilon/\|\mathbf{v}\|$（附录 A.5），末列列出各任务考察的误差项。传送带和平移目标决定速度与领先时长；旋转目标、SE(3) 放置和线缆使朝向影响接触；斜坡、低摩擦和撞击器产生外推无法涵盖的运动；遮挡物、线缆、托盘和撞击器决定间隙，遮挡物也会中断历史。

每个 2 ms 物理步都按表 S2 的顺序条件检查成功，连续条件一旦中断便重置计数。终止事件分为五类，分别报告。*无效*事件指仿真器状态损坏。*边界*事件包括越出工作空间或下游边界、掉落、目标时间窗口过期。*安全*事件包括不安全接触、过大的容器边缘冲量、线缆接触、释放冲量、机器人过早接触、无支撑的托盘接触或被撞击器卡住。*任务违规*包括在目标外释放、偏离路径或回退、提前释放、偏转而未捕获、倾倒、缺少或多出一次撞击，以及出射运动变化不足。最后一类为*超时*。各任务族在每个物理步按固定次序检查事件，并保留首个终止事件。任务均衡分数对每项任务等权，包括某些方法从未成功的任务。

B.2 场景与示范

连续范围均匀采样，离散选项等概率采样，随后检查物理可行性。评测回放保存的已接受场景。谐波平移满足 $\mathbf{p}(t) = \mathbf{c} + (0, v_y, 0)t + (A_x \sin(2\pi f_x t + \phi), 0, 0)$，$\phi \sim \mathcal{U}[-\pi, \pi]$。捕获目标从静止出发，在 $[5, 15]^\circ$ 斜坡上受重力与摩擦作用。遮挡场景仅在目标起初至少可见八帧、完全遮挡 0.5–3.0 s、随后重新可见至少三帧时接受。

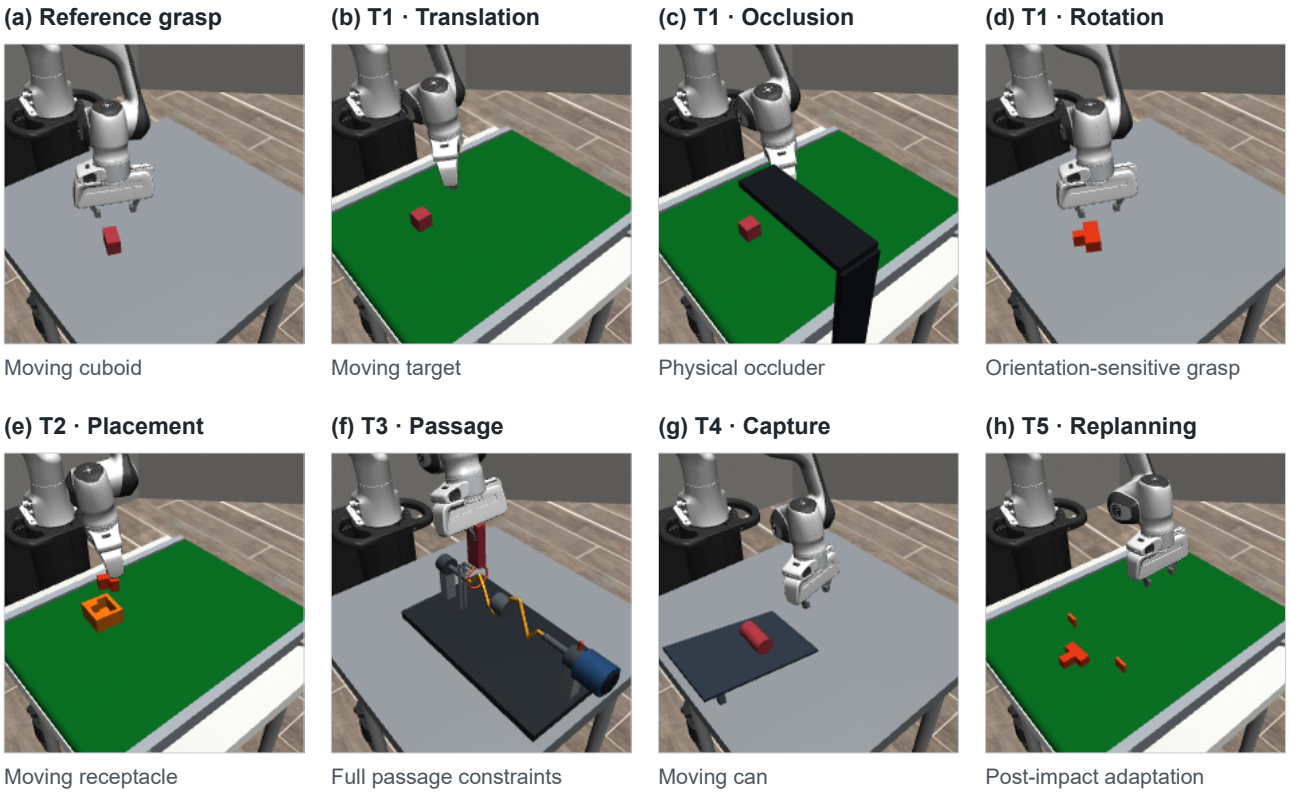


图 S1. Dynamic-14 的观测。八个示例覆盖参考抓取、平移 / 遮挡 / 旋转目标抓取、向移动容器放置、沿旋转线缆通行、滚动物体捕获和碰撞后抓取。每个面板为一个开发场景最后观测到的、未经裁剪的 224×224 agent 视角 RGB 图像。全部十四项任务见表 S2。

训练池包含 11,200 条示范，每项任务 800 条，由可读取特权仿真器状态的脚本专家生成；学习型策略仅接收第 4.1 节的输入。示范以 20 Hz 记录相机图像、深度、机器人状态、发出的指令，以及目标位姿和场景几何的仿真真值。据此计算未来标签、有效性掩码和延迟偏移后的指令标签。仿真中，跟踪器的物体模型是目标在仿真器中的网格，对应真机上的 CAD 模型。

B.3 协议与扫描

执行器。 所有方法使用同一异步执行器。每隔 100 ms 仿真时间请求一个动作块；若上一推理更晚结束，则在其结束后请求。每条指令在自身生效时刻执行。新动作块替换旧动作块未执行的部分；指令可用时若已过生效时刻，则丢弃并计数。不包含生效时刻概念的方法，其动作块按推理结束时发出处理，与其部署方式一致。

实时协议。 除非另有说明，推理期间物理仿真按每次查询抽取的延迟推进，该延迟来自方法在单块 RTX 5090 上的实测分布（附录 F.4）。碰撞后抓取任务额外内置 50 ms 指令延迟。表 S23 报告三种替代协议：*暂停物理*时，仿真等待推理完成，与许多仿真基准相同；*等延迟*时，所有方法均计入 SE(3)-WAM 的 p95 延迟，不考虑其自身速度；*原执行器*则保留各基线论文中的执行方式。

延迟。 在协议延迟之上，于推理后插入 0、50、100、150 或 200 ms 的额外延迟，期间物理持续推进。

速度。 场景中所有外源速度（传送带、容器、线缆及谐波运动速率）乘以 $s \in \{0.5, 1, 1.5\}$。在某个倍率下变得物理不可行的场景，对所有方法共同排除，并报告剩余数量。

表 S2. Dynamic-14 十四项任务的成功条件，阈值为我们任务实现中的取值。任务须依次通过各阶段，且不触发终止性失败。所有任务的控制频率为 20 Hz，物理仿真步长为 2 ms；下列时长均为物理时间。COM 表示质心。

任务	依次满足的成功条件	时限
grasp; t1_belt, t1_xyz, t1_so3, t1_occ	接近至 0.10 m 内；双侧指垫接触持续 0.05 s；碰撞几何体底部高于支撑面至少 0.05 m；接触与间隙保持 0.50 s。T1 分别加入传送带驱动、平移、旋转或实体遮挡物。SO3 无额外的成功角度阈值；OCC 中与遮挡物发生不安全接触即终止。	160 步 8 s
t2_trans	接近至 0.10 m 内。物体的完整碰撞几何体位于容器内：平面间隙和底面间隙均 ≥ -0.002 m，顶端不高于容器开口。释放要求张开指令 < -0.5 且无指垫接触。相对线速度和角速度分别 ≤ 0.08 m/s、0.8 rad/s，持续 0.10 s，随后稳定停留 0.50 s。	200 10 s
t2_se3	接近至 0.05 m 和 0.12 rad 内。完整纳入 T 形容器：平面间隙 ≥ 0.002 m，底面间隙位于 $[-0.002, 0.002]$ m，倾角 ≤ 0.05 rad，顶端低于开口。释放后，相对线速度和角速度分别 ≤ 0.02 m/s、0.04 rad/s，持续 0.10 s，再停留 0.50 s。0.12 rad 阈值用于接近阶段。	200 10 s
t3_phase	回合开始时杆已被抓住。相位对齐要求距离 ≤ 0.090 m、环方向误差 ≤ 0.20 rad。在进度 ≤ 0.15 时进入 0.030 m 范围；历史最大进度先达到 ≥ 0.60，再达到 ≥ 0.85，且距终点 ≤ 0.055 m。	420 21 s
t3_full	双侧接触持杆 0.05 s，然后完成上述相位阶段。在后续采样时刻，当前进度仍须 ≥ 0.85，且离路径和终点均至少 0.045 m。最后张开夹爪（< -0.5）且无指垫接触。退出前释放判为失败。	640 32 s
t4_sphere	接近至 0.10 m 内；首次合格接触须在离开斜坡后发生；成功前接触托盘即判为失败。双侧夹持的名义时长为 25 ms（12 个物理采样步，24 ms）。以首次达到双侧夹持条件时的高度为基准，将质心抬升 0.05 m，并保持接触和高度 0.50 s。	120 6 s
t4_sphere_tabletop; t4_slider	接近至 0.10 m 内；接触须发生在离开斜坡后、仍受支撑、位于捕获区且平面速度 ≥ 0.08 m/s 时。双侧夹持持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m；随后保持接触和高度 0.50 s。	120 6 s
t4_can	采用相同的受支撑捕获顺序。首次指垫接触前，若罐体轴线与竖直方向的点积绝对值 > 0.45，则按不稳定倾倒判为失败。配置不要求夹爪沿横向闭合。	120 6 s
t5_replan	机器人接触前，所选侧恰有一个撞击组完成。在物理撞击结束时间戳后 30 ms，按分支方向取符号的横向速度 ≥ 0.035 m/s，偏航角速度 ≥ 0.35 rad/s。接近至 0.10 m 内；双侧夹持且抓取轴误差 $\leq 18°$，持续 0.05 s；以首次达到该夹持条件时的高度为基准，质心抬升 ≥ 0.05 m，并稳定夹持 0.50 s。撞击组时滞为 12 ms，最长接触时长为 0.10 s。	120 6 s

间隙与网格分辨率。 间隙扫描使用线缆作为环境物体的通行任务。套杆环与线缆之间的自由间隙取 [X, X, X, X, X] mm，覆盖 14^2、28^2、56^2 流网格在工作空间中的间距（分别为 [X]、[X]、[X] mm）；物体和运动保持不变。放置容差涉及目标精度 ε，不属于此扫描。

位姿噪声。 我们在跟踪器的历史位姿估计上加入高斯噪声（附录 D.2）。

遮挡与静止。 用 0.5、1、2、3 s 遮挡及无遮挡对照隔离历史缺口。静止目标变体冻结各任务的外源运动，作为第 5.3 节的静态对照。

B.4 划分与统计

所有设计决策均使用 1,400 个开发场景（每任务 100 个）。正文和补充材料中报告的全部 Dynamic-14 数值，均使用独立的 1,400 个留出场景：采样范围相同，但源种子未出现在任何训练、验证或开发 episode 中。各任务按种子递增顺序取前 100 个可行场景。

表 S3. **Dynamic-14 各任务的角色、容差与临界领先时长。**目标是位姿误差进入接触或容纳容差 ε 的物体；环境是只需以间隙 m 避开的物体。速度取自表 S4 的采样范围（捕获任务取离开斜坡时的速度）；临界领先时长 $\ell^\star = \varepsilon/\|\mathbf{v}\|$ 按速度中位数给出。误差项：任务涉及的误差分解项。v：目标运动。$r\theta$：朝向影响接触。e_{dyn}：非匀速运动（谐波、重力、摩擦、撞击）。m：须避开某个环境物体。occ.：历史缺失。delay：任务内置的指令延迟。

任务	代号	目标	环境	ε (mm)	$\|\mathbf{v}\|$ (m/s)	$\ell^\star$ (ms)	m (mm)	误差项
谐波抓取	grasp	物块	桌面	[X]	0.03–0.20	[X]	–	v, $r\theta$, e_{dyn}
传送带抓取	t1_belt	零件	传送带	[X]	0.04–0.10	[X]	–	v
平移抓取	t1_xyz	零件	桌面	[X]	0.04–0.15	[X]	–	v, e_{dyn}
旋转抓取	t1_so3	零件（$\omega \le 1.2$ rad/s）	桌面	[X]	0.04–0.15	[X]	–	v, $r\theta$, e_{dyn}
遮挡抓取	t1_occ	零件	遮挡罩	[X]	0.04–0.10	[X]	[X]	v, m, occ.
移动容器	t2_trans	容器	桌面	[X]	0.03–0.06	[X]	–	v
旋转容器	t2_se3	T 形容器	桌面	[X]	0.03–0.06	[X]	–	v, $r\theta$
导线穿越	t3_phase	导线环（入口）	旋转导线	30	[X]	[X]	扫描	v, $r\theta$, m
导线穿越（完整）	t3_full	导线环（入口）	旋转导线	30	[X]	[X]	扫描	v, $r\theta$, m
小球捕获	t4_sphere	小球	托盘、斜坡	[X]	[0.4–0.7]	[X]	[X]	v, e_{dyn}, m
小球捕获（桌面）	t4_sphere_tabletop	小球	桌面、斜坡	[X]	[0.4–0.7]	[X]	–	v, e_{dyn}
滑块捕获	t4_slider	滑块	桌面、斜坡	[X]	[0.4–0.8]	[X]	–	v, e_{dyn}
罐体捕获	t4_can	罐体	桌面、斜坡	[X]	[0.4–0.7]	[X]	–	v, $r\theta$, e_{dyn}
撞击后抓取	t5_replan	零件	撞击器	[X]	0.12–0.14	[X]	[X]	v, $r\theta$, e_{dyn}, m, delay

最终模型、消融和表 3 的变体使用训练种子 0、1、2。附录 D 的筛选变体和基线使用种子 0。开发场景上，同一配置的三个训练种子 SR 最多相差 [7.4] 个百分点，大部分波动来自线缆通行，其跨种子成功率从 [0] 到 [71]%；因此不解释单种子几个百分点的差异。三个种子不足以进行重采样，我们先逐场景平均三个种子，再在每项任务内对留出场景做各方法联合的 bootstrap，得到配对 95% 区间。区间完全落在 ±2 个百分点内的差异视为持平。

B.5 指标

任务均衡成功率为

$$\mathrm{SR}(m) = \frac{1}{14}\sum_{k=1}^{14}\frac{1}{n_k}\sum_{i=1}^{n_k} y_{mki}, \tag{S4}$$

其中 y_{mki} 为方法 m 在任务 k 的场景 i 上的二元结果。场景的*可行接触窗口*是在运动学上可能发生满足任务首个成功阶段的接触的时刻集合，由真实目标轨迹与机器人可达工作空间计算。*接触时间误差*为首次接触时刻到该窗口的距离，窗口内为零。*首次接触位置误差*为该时刻末端执行器到目标抓取坐标系的距离。两者仅在发生接触的 episode 上报告。未接触的失败仍计入 SR 分母，其接触误差为缺失值，而非零。*碰撞*统计安全事件。*从观测到动作的时间*为观测到达至首条指令可用的墙钟时间（附录 F.4）；*动作年龄*为生效时刻减去采集时刻。

表 S4. 场景的提议采样范围。除另有说明外，长度、线速度、角度和角速度的单位分别为 m、m/s、rad 和 rad/s。除注明的斜坡局部偏移外，位置均采用世界坐标。可行性检查前，连续区间内均匀采样，离散选项等概率采样。评测重放已存储的接受场景，其分布未必仍为均匀分布。谐波运动中心不等于初始位置。

任务	初态提议范围	运动或事件参数
grasp	谐波运动中心 $c_x \in [-.08, .08]$、$c_y \in [-.26, -.19]$、$z = .822$；偏航角 $[-1.1, 1.1]$。	$v_y \in [.025, .125]$, $A_x \in [.015, .035]$, $f_x \in [.3, .7]$ Hz; $\omega_z \in [-1.2, 1.2]$.
t1_belt	目标 $x \in [-.08, .08]$、$y \in [-.26, -.18]$、$z = .822$；姿态为单位旋转，初始 twist 为零。	传送带 $v_y \in [.04, .10]$。
t1_occ	目标提议范围同传送带任务；遮挡罩位于 $(.322, -.29, 1.20)$。	传送带速度范围相同；间隙参数为.20；实体遮挡。
t1_xyz	谐波运动中心 $c_x \in [-.025, .025]$、$c_y \in [-.24, -.20]$、$z = .818$；偏航角 $[-.35, .35]$。	$v_y \in [.04, .09]$, $A_x \in [0, .03]$, $f_x \in [.25, .65]$ Hz; $\omega_z = 0$.
t1_so3	同 XYZ。	平移相同；$\omega_z \in [-1.2, -.4] \cup [.4, 1.2]$，正负等概率。
t2_trans	目标容器 $x \in [-.13, -.08]$、$y \in [-.18, -.12]$、$z = .825$；姿态固定。	目标容器 $v_y \in [.03, .06]$；无旋转。
t2_se3	目标容器的 x, y 范围相同，$z = .804$；偏航角 $[-.3, .3]$。	目标容器 $v_y \in [.03, .06]$；$\omega_z \in [-.25, -.08] \cup [.08, .25]$，正负等概率。
t3_phase	杆的位置 $x, y \in [-.03, .03]$、$z = .870$，偏航角 $[0, 2\pi]$；导线相位 $[-.25, .35]$。	导线中心 $(.10, -.02, .94)$；绕世界 X 轴旋转，$\omega_x = -\{2.5, 3, \ldots, 7.5\}°$/s（11 个等概率取值）。
t3_full	杆位于 $(-.05, -.02, 1.04)$，姿态为单位旋转；导线相位范围相同。	导线旋转相同；启用托架及释放要求。
t4_sphere	斜坡局部偏移：横向 $[-.015, .015]$，纵向 / 法向 $(-.145, .030)$；坡沿 $(.06, -.02, 1.10)$。	从静止开始由重力驱动；在 tick 0 释放闸门；坡度 $[5, 15]°$；目标 / 斜坡滑动摩擦系数 $[.7, .9]$；无支撑捕获。
t4_sphere_tabletop	横向 $[-.015, .015]$，纵向 / 法向 $(-.124, .034)$；坡沿 $(0, -.06, .808)$。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.7, .9]$，桌面摩擦系数.35。
t4_slider	横向 $[-.015, .015]$，纵向 / 法向 $(-.129, .024)$；受支撑斜坡。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.025, .045]$，桌面摩擦系数 $[.012, .018]$。
t4_can	横向 $[-.010, .010]$，相对斜坡轴线的偏航角 $[-4, 4]°$；纵向位置由闸门几何及罐体在该姿态下的包围范围确定。	坡度及释放方式相同；目标 / 斜坡摩擦系数 $[.25, .45]$，桌面摩擦系数 $[.09, .15]$。
t5_replan	$x \in [-.005, .005]$、$y = -.29$、$z = .812$；偏航角 $[-.08, .08]$；初始 twist 为零。	传送带 $v_y \in [.12, .14]$；在 $y = -.13$ 处等概率触发左 / 右撞击器；行程.098，脉冲.35 s，执行器缩放系数 $[1, 1.1]$，力上限 4 N；指令延迟 50 ms。

C 实现

C.1 条件 token

当前图像。 冻结的 MAE ViT-B/16 [14] 将 224×224 agent 视角 RGB 编码为 196 个图像块 token。我们在开发场景上比较冻结的 DINOv3 编码器 [33] 和与策略共同训练的 CNN 后选择它（附录 D.1）。每个图像块接收视角嵌入、有效度量深度均值的线性嵌入，以及反投影到基座坐标系的位置的线性嵌入。该位置根据固定源像素与相机内外参计算，也用于图像查询、键及共享相同源点的场景查询的三维旋

表 S5. **因果跟踪器精度。**输出位姿相对真值的中位数与 p95 误差、报告丢失的帧比例，以及使用各跟踪器时 SE(3)-WAM 在 Dynamic-14 留出集上的成功率（⋆：采用的设置）。

跟踪器	mm	°	丢失	SR
FoundationPose，全分辨率 ⋆	—	—	—	—
FoundationPose，224 × 224	—	—	—	—
单目三维检测器（无物体模型）	—	—	—	—
仿真位姿（真值）	0/0	0/0	0	—
真机，CAD 先验	—	—	—	–
真机，参考视图	—	—	—	–
真机，三维检测器	—	—	—	–

转位置嵌入。目标、机器人和动作 token 不使用旋转位置嵌入。仅训练时，条件 token 上的线性解码器重建当前目标框内的 RGB（在 $\mathcal{L}_{\text{aux}}$ 中权重为 0.1），从而在不增加输入的情况下把图像块特征与目标关联。

目标运动历史。 因果跟踪器（附录 C.2）在采集时刻输出位姿。每次查询时，在 $-350, -300, \ldots, 0$ ms 偏移处对已输出轨迹重采样，在估计之间对平移线性插值、对旋转沿测地线插值。不进行外推，也不跨越超过两个相机周期的缺口插值；两侧没有估计的偏移标记为无效。每个运动 token 为 25 维描述符 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta t, \mathbf{v}, \boldsymbol{\omega}, \mathbf{a}, \boldsymbol{\alpha})$，各部分维数为 $(3, 3, 3, 3, 1, 3, 3, 3, 3)$，共 8 个 token。槽位 0–6 描述相邻偏移间的七个区间，槽位 7 保存当前绝对位姿。速度由区间位移除以经过时间得到，加速度由相邻速度作差得到。各维按训练统计标准化，无效维置零，再附加三项有效性标记（位姿、区间、加速度），送入带时间嵌入的 $28 \to 768 \to 768$ GELU MLP。跟踪器报告目标丢失时，用可学习嵌入替代位姿。

机器人状态。 同一组偏移处的 8 个末端执行器状态（位置、旋转向量、实测夹爪开度）构成机器人 token。另一个 token 保存首个生效时刻 $\tau^{\text{a}}_{t,0}$ 的末端指令位姿，作为动作块增量的参考（附录 C.4）。

C.2 位姿跟踪器

SAM 2.1（Hiera-small）从首帧框因果传播目标掩码 [32]。仿真中，框来自目标的渲染掩码；真机上，框由 Grounding DINO 根据指令中的物体短语给出 [26]。FoundationPose 使用发布权重，在全分辨率 RGB-D 帧（[640 × 480]）中配准并跟踪物体 [43]。仿真中，物体模型为目标的仿真器网格；真机上为 CAD 模型或每个物体一次性采集的 [16] 个带掩码参考视图。跟踪器在独立线程中运行，每个估计附有采集时刻、可用时刻和有效性标记。配准失败、掩码范围内深度丢失，或帧间跳变超过 [X] mm 时，标记为无效。

单目三维检测器位姿（第 5.2 节）无需物体模型。对每个带掩码的帧，WildDet3D [18] 从 RGB 帧、紧致二维框及内参预测所提示目标的度量三维框。框轴存在由对称性导致的歧义，因此如 DROID 处理（附录 E.2），我们从 24 种轴排列与符号翻转中选择最接近前帧朝向的一种，把每个框映射到该 episode 内统一的物体坐标系。旋转对称目标的估计、标签与误差均投影去除绕对称轴的旋转。表 S5 报告两种跟踪器的精度与输入分辨率的影响。

C.3 世界流

世界由一个可学习物体查询（$\mathcal{Q}$）和每个网格点一个场景查询（$\mathcal{F}$）组成，宽度均为 768。它们由可学习嵌入和位置编码初始化，关注条件及彼此，并采用确定性回归，因此不输入未来标签或噪声。读出头嵌入每个时域的物理偏移 δ_h，从而可在其他偏移监督同一组查询，预训练即采用此方式（附录 E.1）。

目标。 MLP 从物体查询的最终状态读出轨迹 $\{(\mathbf{d}_h, \phi_h)\}_{h=1}^{8}$。对有效时域 $\mathcal{V}$，

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h \in \mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\mathrm{SO}(3)}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{S5}$$

其中 $\lambda_R = 0.1$，$\hat{R}_h = \mathrm{Exp}(\hat{\phi}_h^{\wedge}) R(\tau_t)$。对称目标的 $d_{\mathrm{SO}(3)}$ 忽略绕对称轴旋转。我们使用左相对旋转向量与累积平移，而非会通过雅可比耦合平移与旋转的 twist 指数映射。预测为条件均值，因此会平均多模态未来，例如碰撞发生前的多种可能结果。

场景流。 流表示 $N = 196$ 个源点在 8 个时域上的累积三维位移 $F \in \mathbb{R}^{N \times 8 \times 3}$，位于基座坐标系，并附有可见性 $o \in \{0,1\}^{N \times 8}$。每个场景查询包含源位置与角色嵌入。角色（目标、机器人或环境）来自跟踪器掩码以及机器人的渲染或运动学掩码。线性读出给出每点各时域的位移与可见性 logit。位移除以在训练标签上拟合的固定尺度，损失为

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h) \in \mathcal{V}_F} o_{ih} \big\| \hat{F}_{ih} - F_{ih} \big\|^2 + \mathrm{BCE}(\hat{o}, o), \tag{S6}$$

其中 $\mathcal{V}_F$ 包含有效标签，因此被遮挡点仅监督可见性。

外观目标。 场景查询最终状态上的图像块解码器，在各时域预测三类目标：该块的度量深度（有效深度上的平方误差）、冻结 DINOv3 ViT-L/16 教师 [33] 在 14×14 网格上的特征（逐通道层归一化后的平方误差），以及运动表面的 RGB（位移超过 1 mm 的表面，包含机器人，在该掩码内计算平方误差）。各目标在 $\mathcal{L}_{\mathrm{aux}}$ 中权重均为 0.1。部署时跳过这些头，没有 token 读取其输出，因此它们仅塑造场景查询状态。

C.4 动作流

每个动作块包含 8 条七维指令：基座坐标系平移增量、左相对旋转向量和夹爪指令。指令 j 相对 $\tau^{\mathrm{a}}_{t,j-1}$ 的指令位姿定义增量；当 $j = 0$ 时，参考位姿为仍在执行的上一动作块给 $\tau^{\mathrm{a}}_{t,0}$ 指定的位姿。因此动作块锚定于控制器精确已知的位姿，而非采集时刻机械臂的实测位姿。每个动作 token 加入其领先时长 $\Delta_{t,j} = \ell_t + j\Delta_a$ 的正弦嵌入。训练时每个窗口采样延迟 $\ell \sim \mathcal{U}[0, 250\,ms]$，指令 j 的标签为示范中 $\tau_t + \ell + j\Delta_a$ 时刻的指令增量，在控制步之间插值。归一化使用训练划分中有效、未重复的已发出指令的均值与总体标准差。流匹配在该坐标下使用单位高斯噪声，每块一个 u，动作 token 通过自适应层归一化接收 u。部署时逆归一化、解码旋转向量，并逐轴将平移和旋转截断到 0.10 m 和 0.5 rad。夹爪按指令符号动作。

C.5 耦合

注意力掩码作用于条件（$\mathcal{Z}$）、物体查询（$\mathcal{Q}$）、场景查询（$\mathcal{F}$）和动作（$\mathcal{A}$）四组 token。条件 token 仅关注 $\mathcal{Z}$；世界查询关注 $\mathcal{Z}$、$\mathcal{Q}$、$\mathcal{F}$；动作 token 关注 $\mathcal{Z}$、$\mathcal{A}$ 以及耦合增加的连接（附录 D.4）。阻断边

在训练和部署时的每层、每头 logit 均为 $-\infty$。因此，动作不关注的世界查询不能影响动作，未来标签也不能经条件流入动作。所有耦合共享模块、初始化与损失，仅掩码不同，R5 则另有几何编码器。两流之间不截断梯度。除非打开动作到世界的边，世界既不关注动作，也不关注流时间，因此 R1、R2、R5 的世界状态每次查询只计算一次，在 Euler 步间复用；R3、R4 则每步重算。选定的 R1 耦合没有打开从世界到动作的边。世界损失塑造共享参数，部署时只运行动作流，执行 5 步 Euler 积分。主干各组共享注意力投影，世界查询与动作 token 使用独立前馈网络（扩展比 4）。世界查询采用层归一化，动作 token 采用自适应层归一化，可训练主干参数为 47.3M。附录 D.4 的另一种参数化，其可训练参数量相差 0.013%。

C.6 训练配方

表 S6 列出 Dynamic-14 训练配方。每条示范提供查询间隔为 [8] 个控制步的窗口，约每条示范 [14] 个，每窗独立采样延迟。先导试验中，全局 batch 64 配合两倍学习率使训练快约 [2.5] 倍，但跨种子稳定性较低，因此保留 16。一次训练在 8 块 RTX PRO 6000 GPU 上约需 7.7 小时。DROID 基座与受控对照采用附录 E.5 的配方。

表 S6. Dynamic-14 上的训练超参数。

项目	取值
主干	4 层，宽度 768，8 个头，47.3M 参数
编码器	冻结 MAE ViT-B/16，224×224 输入
优化器	AdamW，$\beta = (0.9, 0.95)$，$\epsilon = 10^{-8}$，权重衰减 0.05
学习率	2×10^{-4}，1,000 次预热更新，余弦衰减到 0.1
batch 与更新	全局 batch 16，4 个 epoch（40,104 次更新，641,664 个窗口）
损失权重	$\lambda_P = \lambda_F = 1$，$\lambda_R = 0.1$，各目标 $\lambda_{\text{aux}} = 0.1$
延迟采样	每窗 $\ell \sim \mathcal{U}[0, 250\,ms]$
精度	BF16 配合 TF32，梯度裁剪阈值 1，无 dropout
采样	动作使用 5 步 Euler 积分
推理	FP16、编译、条件 token 缓存
硬件	8 块 RTX PRO 6000 GPU，每次约 7.7 小时

C.7 部署

每次查询编码最新观测，在查询内复用缓存的条件 token，并发出按各自生效时刻调度的动作块（式 1）。查询前，执行器将 ℓ_t 设为延迟预算，即最近 50 次实测推理时间的 p95 加平台执行延迟。若推理提前结束，指令等待至预定时刻；若推理超时，丢弃已过时指令，执行其余指令。附录 B.3 说明所有方法共享的执行器，附录 F.4 说明计时。

D 完整设计研究

本附录的各项比较只改变一个轴，其他轴保持选定配置，采用附录 C.6 的配方，各变体使用相同场景与推理种子。所有变体先用一个训练种子筛选，全部选择决策基于开发池，表中报告留出场景。编码器和耦合比较，以及同时出现在表 3 中的行，平均三个训练种子；其余行使用一个种子。整个研究共耗费约 [XXXX] GPU 小时训练和 [XXXXXX] 条评测 episode。

表 S7. **观测编码器**（留出场景，三个训练种子），其余组件均为选定配置（⋆：采用）。参数量为编码器参数；p95 出动作时间在一块 RTX 5090 上测得。

编码器	参数	训练	SR	SR_{150}	p95
CNN	—	是	—	—	—
DINOv3 ViT-S/16	22M	冻结	—	—	—
DINOv3 ViT-L/16	300M	冻结	—	—	—
MAE ViT-B/16⋆	86M	冻结	—	—	—

选择。 候选的部署性能须满足：从观测到动作的 p95 时间不超过 200 ms，峰值显存低于单块 RTX 5090 的 80%。由于单种子结果可相差数个百分点（附录 B.4），仅当候选在开发场景的种子 0 上提高超过 3 个百分点，且种子 1、2 均保持增益时，才替换参考配置；否则保留更便宜或更简单的变体。

D.1 共用组件

观测编码器和仅训练时使用的外观目标由三项研究共用，我们先确定它们。开发场景上比较与策略共同训练的 CNN、冻结 DINOv3 ViT-S/16 与 ViT-L/16 [33]，以及 MAE ViT-B/16 [14]（表 S7）。冻结 MAE 的三种子均值最高，为 [66.8]%，但种子范围为 [63.7]–[71.1]%，与 DINOv3 编码器重叠。我们依据其均值及低于 ViT-L/16 的成本选择它。DINOv3 ViT-L/16 特征仍作为未来外观目标之一，与世界表示一同选择（附录 D.3）。

D.2 记住

条件。 各条件都接收当前图像、因果跟踪器给出的当前目标位姿、八个机器人状态，以及选定的未来目标和耦合。差别仅在于保留过去 350 ms 的什么信息，从而固定 e_{loc} 并隔离历史对 e_v 的贡献。RGB 窗口保留每隔 50 ms 的七帧历史，每帧 196 个图像块，不压缩。光流为 64×64 RGB 上的双向 Farnebäck 流 [13]，覆盖 100、100、100、50 ms 四个区间，总计同一 350 ms 窗口，带前向—后向有效性；“光流 + 运动统计”另加 DynamicWAM 每区间十二项物理统计 [29]。编码器运动向量来自实际 MPEG-4 P 帧，并按光流方式编码；视频隐变量为冻结 Wan2.2 VAE 的后验均值，由 56 个可学习查询读取。压缩窗口用共享的八查询组读取历史帧，或均匀分配，或按 PACT-WAM [27] 为较新帧分配更多查询。RGB-D 窗口增加每个历史图像块的度量位置，检验缺少的是度量几何还是运动。SE(3) 变体中，仅位置历史去掉朝向；检测器历史以逐帧单目三维框替代物体模型（附录 C.2）；真值历史使用仿真器位姿。最后一个对照从 RGB 窗口中去掉当前目标位姿，测量当前位姿本身的贡献。

冻结读出。 为区分历史编码包含的信息与策略使用的信息，我们在三处冻结特征上拟合岭回归读出：历史编码器输出、最终物体查询、首次函数求值时动作头的输入。标签为过去 50、200、350 ms 的目标位置、最后区间的速度及 400 ms 未来位移，均在基座坐标系中。每项任务分别用 60、20、20 条不同开发 episode 训练、验证和测试，每条五个窗口。依据验证误差从 $\{0.1, 1, 10, 100\}$ 选择正则强度，以打乱标签的对照估计随机水平。条件读出先从当前图像、几何、机器人状态与当前位姿拟合基线，再从相应位置的特征预测其残差，以检验历史超出现有状态的增量信息。

扰动与干预。 离线扰动将所有历史槽位替换为当前图像，或倒序历史图像，同时固定当前帧、位姿和噪声，测量首条发出动作的变化。在最终模型上（表 S9），静止历史在重算运动学前将全部历史位姿替换为当前位姿，消除位移、速度和加速度。时间反转倒序历史位姿。当前状态匹配替换使用同任

表 S8. **记住：完整历史比较**（留出场景；一个训练种子，同时出现在表 3 中的行为三个种子）。所有条件均保留当前图像、当前目标位姿（最后一行除外）、机器人历史、选定的未来表示与选定的耦合方式。SR（%）按附加延迟分列；readout：冻结岭回归对 350 ms 前目标位置的读出误差（mm，越低越好）；Δa：重复过去输入时首个动作平移的变化（mm）；tokens：新增历史 token 数；p95：出动作时间（ms）。

	不同附加延迟下的 SR（ms）								
历史	0	50	100	150	200	读出	Δa	Token	p95
仅当前帧	—	—	—	—	—	—	0	0	—
RGB 窗口	—	—	—	—	—	—	—	1,372	—
RGB-D 窗口	—	—	—	—	—	—	—	1,372	—
光流	—	—	—	—	—	—	—	60	—
光流 + 运动统计	—	—	—	—	—	—	—	60	—
编码器运动向量	—	—	—	—	—	—	—	56	—
视频 VAE 隐变量	—	—	—	—	—	—	—	56	—
压缩窗口（按时间分配）	—	—	—	—	—	—	—	56	—
压缩窗口（均匀分配）	—	—	—	—	—	—	—	56	—
SE(3) 历史（因果估计）*	—	—	—	—	—	—	—	8	—
SE(3) 历史（仅位置）	—	—	—	—	—	—	—	8	—
SE(3) 历史（检测器三维框）	—	—	—	—	—	—	—	8	—
SE(3) 历史（真值）	—	—	—	—	—	—	—	8	—
SE(3) 历史 + RGB 窗口	—	—	—	—	—	—	—	1,380	—
RGB 窗口，无当前位姿	—	—	—	—	—	—	—	1,371	—

务、物体和相机的另一条最近开发 episode 的历史，要求当前目标和末端位姿在 5 mm、5° 内。方向歧义子集进一步要求末区间速度方向相反，且大小至少为 0.01 m/s。

位姿噪声。 计算运动学前，对各历史位姿独立加入位置标准差 $\sigma_p \in \{0, 1, 2, 5, 10, 20, 40\}$ mm、旋转标准差 $\sigma_R = \sigma_p/(30\,\text{mm})$ rad 的高斯噪声，使两者在 3 cm 力臂处产生同样位移。当前位姿保持不变，从而隔离历史作用。取 $T = 350$ ms、$n = 8$ 及实际领先时长，依据表 S3 逐任务计算预测交叉点 $\sigma^\star$（附录 A.5），并与跟踪器实测误差（表 S5）一起标在图 4c。

遮挡与采样。 用 0.5、1、2、3 s 遮挡及无遮挡对照检验历史缺口。采样试验保持 350 ms 跨度，选择 2、4 或 8 个偏移，时间嵌入使用实际偏移。

D.3 预测

表示。 表 S10 定义各类未来目标。所有目标均相对当前状态累积，覆盖从 50 到 400 ms 的相同八个时域。表 S11 各行保持选定配置的历史、耦合、动作损失、训练预算和世界流容量，仅替换由场景查询经附录 C.3 接口回归的世界目标，因此图像空间目标在容量匹配下比较。冻结视频一行则读取预训练图像到视频模型从当前帧预测的隐变量，其未来不依赖我们的模型容量。Kabsch 行先预测物体点轨迹，再拟合 SE(3)，所获信息与点轨迹行相同，但增加刚性先验。最后一组保留选定世界，仅改变部署时删除读出头的外观辅助目标，以测量它们教给场景查询的内容。

开发场景中，多数表示的总体差异只有数个百分点，差别集中于少数任务。目标点轨迹配合流的总体 SR 甚至略高于 SE(3) 轨迹（单种子 [+1.7] 个百分点）。我们保留直接给出位姿、且误差预算在旋

表 S9. **冻结策略干预。**每行只在推理时改变一个输入。历史干预使用最终模型。隐藏状态干预使用耦合 R2，几何干预使用 R5（最终模型不读取预测）。SR 为留出场景成功率（%）。Δa：首个动作平移的平均变化（mm）。

输入	干预	SR	Δa
历史	无	—	0
	静止（重复当前位姿）	—	—
	时间反转	—	—
	当前状态匹配的交换	—	—
	方向歧义交换	—	—
世界状态（R2）	无	—	0
	当前状态匹配的交换	—	—
	时域时刻偏移 ±50 ms	—	—
解码几何（R5）	无	—	0
	零运动	—	—
	当前状态匹配的打乱	—	—
	时间偏移 ±50 ms	—	—
	真值（接触前）	—	—

转目标上支持的 SE(3) 轨迹，表 S11 在留出场景上比较两者。稠密二维位移是唯一明显有害的未来目标（相对无未来为 [−3.6] 个百分点）。

角色覆盖。 在选定表示上，各角色行保留全部源点和相同计算量，仅改变哪些角色参与流损失。最后一行去掉角色嵌入，检验显式角色划分是否在依赖任务的读出之外提供帮助。

分辨率与间隙。 28^2、56^2 网格更密集地采样同一图像；按物体采样的流将点放在环境掩码上，而非固定网格。所有变体使用相同标签、归一化与损失权重。路径误差 e_F 是最接近执行路径的 256 个留出环境点，在路径经过它们时的流端点误差。表 S12 报告全部变体在附录 B.3 间隙扫描上的结果，并加入容量匹配的视频隐变量未来。

外推基线。 匀速和匀加速预测只使用模型可见的因果 SE(3) 历史，即末区间速度与最后两个区间的速度差，分别作用于平移和以旋转向量表示的旋转。离线时，将三类预测与生效时刻真值比较。为测量闭环价值，以相同数据和预算训练两个变体（表 S13）：第一个把外推目标轨迹作为额外输入 token，保留选定模型的世界监督；第二个以这些输入 token 替代世界监督，即表 2 的 CV-input 基线。

预测误差。 物理误差使用共同的 256 个目标源点和 256 个环境源点，以确定性方式采样并排除在训练查询之外。平移与旋转误差分别保留度量单位和测地单位，流误差为有效对应上的端点误差。所有预测误差均在留出 episode 的生效时刻测量。

D.4 行动

主干。 共享注意力主干在所有 token 组间共享注意力投影，按组分开前馈网络。独立参数组主干的世界与动作组各自包含注意力投影、自适应层归一化和前馈网络；条件与世界 token 共用世界组。通过将独立组前馈扩展比由 4 改为 3 匹配可训练参数量，两者均约 47.3M，层数、宽度和注意力头数相同。相同训练预算不意味着相同 FLOPs，因此报告实测成本。

表 S10. “预测”研究中比较的未来目标族。张量形状不含 batch 和 query 轴。除保留解码器自身对应关系的 codec 向量外，位移均从当前状态累计。除冻结视频模型（其隐变量为该模型自身的预测）外，所有监督目标均来自记录的演示。未来深度、DINO 与动态 RGB 同时也是选定模型仅在训练中使用的辅助目标。

目标	形状	几何支持、单位与有效条件
目标位姿	8×6	累计平移 (m) 和左相对旋转向量 (rad)；位姿和 query 有效。
场景流，$k \times k$ 网格	$k^2 \times 8 \times 3$	每边 $k \in \{14, 28, 56\}$ 个点的固定网格；基座坐标系中的米；源深度有效且未来位移有限。
场景流，按物体采样	$196 \times 8 \times 3$	在环境掩码上以最远点采样代替固定网格选取的点。
物体点轨迹	$32 \times 8 \times 3$	在当前目标掩码内作最远点采样；位移与可见性；填充点无效。Kabsch 变体对预测轨迹拟合 SE(3)。
物体 DINO	8×1024	按掩码面积加权汇聚未来 patch 特征；沿通道作层归一化；掩码面积为正。
场景轨迹（二维）	$196 \times 8 \times 3$	网格源点；两个图像位移通道除以 224，另加一个可见性 logit。
稠密二维位移	$8 \times 2 \times 224 \times 224$	固定源像素；位移除以 224；源像素有效且投影有限。
编码器运动向量	$8 \times 2 \times 64 \times 64$	每对未来 / 当前帧编码为 P/I 帧；向量除以 64；使用有效向量区域。
视频 VAE 隐变量	$48 \times 2 \times 14 \times 14$	冻结的 Wan2.2 VAE 后验均值及该 VAE 自身的归一化；两组分别截至 200 与 400 ms。
冻结视频模型	$48 \times 2 \times 14 \times 14$	冻结的预训练图生视频模型由当前帧预测的隐变量；仅读取，不监督。
未来深度	$8 \times 1 \times 224 \times 224$	米制深度；像素值为有限正数。
未来 DINO	$8 \times 196 \times 1024$	冻结的 DINOv3 ViT-L/16 教师 [33]，14×14 个 patch，沿通道作层归一化。
动态 RGB	$8 \times 3 \times 224 \times 224$	在世界坐标中移动超过 1 mm 的可见表面（含机器人）上取 RGB 并除以 255。

耦合。 各耦合的注意力掩码定义见附录 C.5，模块、初始化、损失和训练预算相同。R0 保留世界查询与读出头，但关闭全部世界损失，从而与 R1 容量匹配且无世界监督。R1 加入世界监督，关闭所有世界到动作的边。其同一检查点分别仅运行动作，或计算但不读取预测，以隔离无用预测的成本。R2 让动作读取世界查询隐藏状态，R3 让世界读取带噪动作，R4 打开双向连接。R3、R4 每个 Euler 步重算世界。R5 解码世界显式几何，再通过 0.37M 参数的几何编码器重新编码供动作使用，训练端到端穿过预测几何，不采用教师强制。由于 R5 同时改变动作读取的内容及其进入位置，R2 与 R5 比较的是完整设计，而非单因素。

开发场景中，没有耦合稳定优于 R1。世界读取动作的 R3 三种子均值最高，比 R1 高 [+0.6] 个百分点，但差异完全来自线缆通行，且两个读取方向的作用均跨种子变号。我们保留了同时也是最便宜的 R1。世界监督本身，即 R1 相对 R0，平均提高 [3.1] 个百分点，但各种子增益从 [−1.3] 到 [+9.6] 个百分点。

预测干预。 干预固定条件 token 和动作噪声，仅改变动作从世界读取的内容。对 R2，替换动作 token 在每层读取的键和值；当前状态匹配替换使用当前目标位姿在 5 mm 和 5° 内的另一条开发 episode 的世界状态，时间平移则将所有时域偏移 50 ms 后重算。对 R5，在几何编码前编辑解码几何：零运动采用零三维位移与单位目标位姿，保持可见性不变；匹配当前状态的打乱采用同样匹配条件下另一条开发 episode 的几何；时间平移在 $\delta_h \pm 50$ ms 重采样轨迹；真值干预使用首次接触前的实测外源运动。接触后未来标签依赖动作，因此真值分析从仿真器快照分叉，在固定候选动作序列下进行。恒等对照复制原始状态，动作完全不读取世界的耦合充当阴性对照。

表 S11. **预测：完整未来表示比较**（留出场景；一个训练种子，同时出现在表 3 中的行为三个种子）。历史与耦合方式固定为选定配置，各行世界分支容量相同，只改变其预测目标（定义见表 S10）。最后一组之前的各行保留选定的仅训练外观辅助目标；最后一组在选定表示上改变这些目标，其读出头在部署时去除。Pose：400 ms 处的平移（mm）与旋转（°）误差；e_F：沿执行路径的留出环境点上的流误差（mm）；e_t：接触时刻误差（ms）；cost：每次查询的世界分支耗时（ms）。

目标	环境	SR	SR_{150}	位姿 (mm/°)	e_F	e_t	碰撞	耗时
无	无	—	—	–	–	—	—	0
SE(3)	无	—	—	—	–	—	—	—
无	流，14^2	—	—	–	—	—	—	—
SE(3)	流，$14^{2\star}$	—	—	—	—	—	—	—
SE(3)	流，28^2	—	—	—	—	—	—	—
SE(3)	流，56^2	—	—	—	—	—	—	—
SE(3)	流，按物体采样	—	—	—	—	—	—	—
物体点轨迹	流，14^2	—	—	–	—	—	—	—
点轨迹 → SE(3) 拟合	流，14^2	—	—	—	—	—	—	—
物体 DINO	流，14^2	—	—	–	—	—	—	—
SE(3)	场景轨迹（二维）	—	—	—	–	—	—	—
SE(3)	稠密二维位移	—	—	—	–	—	—	—
SE(3)	编码器运动向量	—	—	—	–	—	—	—
SE(3)	视频 VAE 隐变量	—	—	—	–	—	—	—
SE(3)	冻结视频模型	—	—	—	–	—	—	—
SE(3)	未来深度	—	—	—	–	—	—	—
SE(3)	未来 DINO	—	—	—	–	—	—	—
SE(3)	动态 RGB	—	—	—	–	—	—	—
选定表示上的角色覆盖								
SE(3)	流，仅目标点	—	—	—	—	—	—	—
SE(3)	流，仅环境点	—	—	—	—	—	—	—
SE(3)	流，无角色嵌入	—	—	—	—	—	—	—
选定表示（SE(3) + 流）上的仅训练外观目标								
无		—	—	—	—	—	—	—
未来深度		—	—	—	—	—	—	—
未来 DINO 特征		—	—	—	—	—	—	—
运动区域 RGB		—	—	—	—	—	—	—
三者全部 ⋆		—	—	—	—	—	—	—
三者全部，去除当前目标 RGB 重建		—	—	—	—	—	—	—

表 S12. **环境分辨率与间隙**（穿越任务）：工作空间中的网格间距与路径误差 e_F（mm），以及各扫描间隙 $c_1 < \cdots < c_5$ 下的成功率（%）（附录 B.3）；目标始终以 SE(3) 预测。

环境	间距	e_F	c_1	c_2	c_3	c_4	c_5
无	–	–	—	—	—	—	—
流，14^2	—	—	—	—	—	—	—
流，28^2	—	—	—	—	—	—	—
流，56^2	—	—	—	—	—	—	—
流，按物体采样	—	—	—	—	—	—	—
视频 VAE 隐变量	–	–	—	—	—	—	—

表 S13. **世界监督与外推输入的比较**，按运动类型分列。上：在相同数据与训练预算下，以因果 SE(3) 历史的匀速（CV）或匀加速（CA）外推作为输入 token、有或没有世界监督的 SE(3)-WAM 变体的成功率（%）。无世界监督的 CV 行即表 2 中的匀速输入基线。下：两种外推与学习的世界头在 400 ms 处的目标位置误差（mm）。

	匀速	谐波	滚动/滑动	撞击
无世界监督				
无预测输入	—	—	—	—
匀速输入	—	—	—	—
匀加速输入	—	—	—	—
有世界监督				
SE(3)-WAM （无预测输入）	—	—	—	—
匀速输入	—	—	—	—
匀加速输入	—	—	—	—
400 ms 处的位置误差（mm）				
匀速外推	—	—	—	—
匀加速外推	—	—	—	—
学习的世界头	—	—	—	—

表 S14. **行动：完整耦合比较**（留出场景）。历史与未来表示固定为选定配置。附录 D.4 的各耦合方式在选定主干上逐一比较，另一主干只检验其中两种。$\mathrm{SR}_{\mathrm{static}}$：静止目标变体。NFE：每次查询的网络调用数（世界/动作）。显存：GPU 峰值显存（GiB）。p95 在一块 RTX 5090 上测得。

主干	耦合	SR	SR_{150}	$\mathrm{SR}_{\mathrm{static}}$	LIBERO	NFE	p95 (ms)	显存	e_t
共享注意力 ⋆	R0 （关闭世界损失）	—	—	—	—	0/5	—	—	—
	R1 （辅助，仅动作）⋆	—	—	—	—	0/5	—	—	—
	R1 （辅助，计算预测）	—	—	—	—	1/5	—	—	—
	R2 （世界 → 动作，隐藏状态）	—	—	—	—	1/5	—	—	—
	R3 （动作 → 世界）	—	—	—	—	5/5	—	—	—
	R4 （双向）	—	—	—	—	5/5	—	—	—
	R5 （解码几何）	—	—	—	—	1/5	—	—	—
独立参数组	R2 （世界 → 动作）	—	—	—	—	1/5	—	—	—
	R1 （辅助，仅动作）	—	—	—	—	0/5	—	—	—

E 真实机器人数据的 4D 提升与预训练

E.1 数据、划分与时间

预训练语料为 DROID [20]，以 15 Hz 记录两个外部相机和一个腕部相机，并结合 PointWorld 为其发布的三维点轨迹与优化相机标定 [17]。我们要求关节序列、末端位姿、夹爪状态、指令和相机身份完全一致，将发布片段关联到原始 DROID episode；排除采集时钟不单调或关联有歧义的片段。模型使用第一个外部相机。训练单位是一个因果观测窗口及其对齐的未来与动作标签。过滤前，按原始标识以固定随机种子将 episode 划分为训练、开发、留出集（90/5/5），避免同一 episode 的重叠片段跨划分。表 S15 报告各阶段产出，并分别统计 episode、窗口、动作和有效标签。

时间。 所有时间均为采集时间戳，不将帧改标为名义帧率。历史偏移位于 50 ms 网格，15 Hz 帧不能恰好落在其上，因此按照部署方式在偏移处重采样因果输入（附录 C.1），只在查询时刻前已输出的估计之间插值，不外推。目标标签同样对离线轨迹作位置线性插值和旋转测地线插值，不跨越长于两个源周期的缺口，因此落在主模型的时域上。流标签保留 PointWorld 自身的记录时刻，即未来 [0.13] 至 [1.13] s，不插值。世界读出头嵌入各时域的物理时间偏移 δ_h（附录 C.3），故场景查询在预训练时接受这些偏移的监督，之后在 50 ms 网格上监督。

动作。 机器人状态与笛卡尔指令经标定的法兰到 TCP 变换后，以机器人基座坐标系表示。指令标签遵循附录 C.4。每个标签为上一生效时刻的指令位姿到当前生效时刻指令位姿的增量；DROID 指令位姿按采样延迟插值至 $\tau_t + \ell + j\Delta_a$。数值有限且参考状态因果可用时，标签即可接收。机器人执行限幅不作为标签准入规则，因为每条指令逐轴 5 cm 的限制会丢弃最快四分之一运动中的 [XX]% 指令，使基座偏向慢速示范。仅屏蔽 DROID 采集器未发出指令的步（占窗口槽位 [3.1]%）。动作与流的有效性独立，无效动作不会移除该窗口的流标签。

E.2 目标及其位姿

DROID 不提供物体位姿，指令虽提到操作物体，却未标注其位置。我们将指令主谓结构中主要动词的直接宾语作为目标，由依存句法分析器提取，例如“把杯子放进水槽”中的“杯子”，每条 episode 保持同一个实例。Grounding DINO [26] 在该短语得分首次达到 0.35 的帧中给出框，SAM 2.1 [32] 跟踪其掩码。对每个非空掩码帧，将紧致二维框、RGB 帧和固定内参提供给 WildDet3D [18]。它通过自身几何估计从单图预测度量三维框，不使用外部深度；PointWorld 优化后的外参将框映射到基座坐标系。两个外部相机的框中心在基座坐标系内相距不超过 5 cm 时接受该框。排除指令未指定物体、指定多个物体或非刚体，以及没有可接受框的 episode。空掩码记为缺失观测，不用前一位姿填充。

物体坐标系。 三维框的坐标系仅在其对称性意义下确定，检测器可能逐帧排列或翻转坐标轴。因此，将每个新框映射到保持尺寸的等价坐标系中最接近前一有效估计的一种（轴排列与符号翻转），以固定每条 episode 的物体坐标系。此步骤后仍超过 45° 的相邻帧旋转跳变占 [X.X]% 帧，标为无效而非平滑。与仿真一样，对称目标绕对称轴的旋转从损失中排除（第 4.2 节）。

E.3 因果输入与离线标签

因果输入。 SAM 2.1（Hiera-small）因果传播掩码，WildDet3D 以全精度提升每个掩码帧，使估计不依赖 batch 组成。每次查询仅处理新可用帧并追加估计，不改写先前结果。空掩码、被拒绝框和旋转跳

表 S15. **提升为 4D 的 DROID**。各阶段的保留量。窗口指带有对齐标签的因果观测窗口。外源窗口指在机器人与目标首次接触前目标已在运动的窗口（附录 E.3）；最后两行比较全部窗口与有效窗口。

	训练	开发	留出
含 PointWorld 轨迹的 episode	—	—	—
与原始 DROID 对齐	—	—	—
指令只指定一个刚体且已检测	—	—	—
窗口	—	—	—
外源（%）	—	—	—
含因果位姿输入	—	—	—
有效动作（%）	—	—	—
有效 SE(3) 标签（时域，%）	—	—	—
有效 3D 流标签（点，%）	—	—	—
速度，全部 / 有效（cm/s）	—/—	—/—	—/—
遮挡，全部 / 有效（%）	—/—	—/—	—/—

图占位：图 S2——将真实机器人 episode 提升为度量 4D（示意图）

左侧（共同设置）：指令及下划线标出的物体短语（“把杯子 放进水槽”），两个外部视角首帧的 Grounding DINO 框，WildDet3D 框中心在基座系中一致；小插图比较 PointWorld 优化与原始相机位姿。**上排（因果输入路径，蓝色）**：帧从左向右到达，SAM 2 前向传播掩码，WildDet3D 将每个掩码帧提升为度量三维框；输出位姿用标有可用时刻的坐标轴表示，空掩码对应显式“缺失”token；没有时间上向后的箭头。**下排（离线标签路径，橙色）**：前后双向传播掩码，逐帧框映射到统一物体系，稳健平滑器融合两条位姿轨迹并保留抓取突变，在 50 ms 时域上形成累积 SE(3) 标签 $(\mathbf{d}_h, \phi_h)$；另一支在每网格块选择最近块中心的 PointWorld 轨迹，画出其记录时刻的三维位移，无效点灰显。竖虚线标出首次机器人—目标接触，其后的世界标签在屏蔽标签对照中删除。**右侧**：一个训练样本 = 上排因果输入 + 下排带掩码标签。采用真实 DROID 帧序列，仅绘制矢量叠加。

图 S2. 将 DROID 提升为度量 4D 监督。对指令中的目标检测框并跟踪。输入用仅前向跟踪复现部署条件，标签则利用整条 episode、双向跟踪和平滑，以及 PointWorld 三维轨迹。标签不回写输入，无效标签屏蔽对应损失。

变令输入无效；训练直接使用这些自然缺失状态，不添加合成 dropout。真机对没有 CAD 模型或参考视图的物体采用同一路径（附录 C.2）。

离线标签。 标签使用整条 episode 和相同目标短语。SAM 2 双向传播掩码，两个掩码 IoU 至少为 0.5 时接受该帧。两个方向的框送入同一个稳健平滑器：Huber 代价中位姿残差分别以 5 mm 和 3° 缩放，速度变化残差权重为 0.1。跨缺口，以及速度跳变超过 0.2 m/s 或 1 rad/s 时省略速度项，以保留突变。通过二十次流形 Gauss–Newton 迭代优化；双向框相差超过 20 mm 或 15° 的帧无效。目标标签为离线轨迹内部的 $\tilde{\mathbf{p}}_{t+h} - \tilde{\mathbf{p}}_t$ 和 $\mathrm{Log}(\tilde{R}_{t+h}\tilde{R}_t^\top)^\vee$。它们并非离线未来减去因果估计，因此不吸收当前位姿的修正。只有参考与未来位姿均有效，且身份和物体系一致，时域才有效。

场景流。 PointWorld 轨迹已位于基座坐标系。对每个网格点，选择初始投影在该图像块内最接近该点的发布轨迹，要求起初可见、具有图像内有效正深度，并与最近像素深度相差不超过 20 mm。没有此类轨迹的图像块无效，不用相邻点补齐。标签为各记录时刻相对初始位置的位移，可见性沿用 PointWorld。未来点被遮挡、出图或深度无效时，屏蔽位移损失，仅监督可见性。选定轨迹距块中心的中位距离为 [0.5] px，第 95 百分位为 [9] px。

接触与外源运动。 首次机器人—目标接触定义为目标框首次进入机器人运动学给出的夹指几何 1 cm 范围内的帧。若窗口的 400 ms 时域内，目标在该接触前移动超过 1 cm 或 5°，则该窗口为*外源运动*窗口，比例见表 S15。表 S16 的屏蔽标签对照删除首次接触后的全部世界标签，保留动作损失。它保留预训练低数据收益的 [XX]%，因此 [大部分收益并非来自预测机器人如何移动目标]。

表 S16. **初始化的受控比较。**每行从各自的初始化出发，用 10/25/50/100% 的 Dynamic-14 示范后训练仿真模型（留出 SR，%，三个后训练种子）；通用初始化即 SE(3)-WAM 所用的初始化。最后几列为各基座在留出 DROID episode 上最后一个时域的预测误差：目标平移（mm）与旋转（°，相对平滑标签），以及相对 PointWorld 轨迹的流端点误差（mm）。对照基座按试点规模预训练，并与相同预算的世界—动作基座比较（附录 E.5）。

	Dynamic-14 SR，示范比例				DROID 留出		
初始化	10%	25%	50%	100%	mm	°	流（mm）
仅通用视觉初始化（SE(3)-WAM ）	—	—	—	—	–	–	–
仅动作基座，相同 episode	—	—	—	—	–	–	–
世界—动作基座，单目深度提升的流	—	—	—	—	—	—	—
世界—动作基座，接触后屏蔽世界标签	—	—	—	—	—	—	—
世界—动作基座，试点规模	—	—	—	—	—	—	—
世界—动作基座（真机基座）	—	—	—	—	—	—	—

有效性偏差。 PointWorld 轨迹对静态表面的覆盖比快速运动表面更完整，可接受框偏向无遮挡、纹理清晰的目标。表 S15 比较全部窗口与有效窗口的目标速度和遮挡。表 S16 的标签来源对照，用二维对应 [30] 配合单目度量深度 [41] 提升的流替换轨迹，后者覆盖更多图像区域。

E.4 标签质量

我们检查四十段片段的标签，其中十四段用于开发、二十六段留出，每段五个锚点。片段覆盖七类情形：静止目标、平滑平移、旋转、接触或滑动、遮挡与恢复、外观弱纹理，以及对称或关节式部件。留出片段不用于调节估计器。随机 [200] 条 episode 的人工检查中，[XX]% 的接受框位于预期目标上。前缀截断和未来替换确认：已输出输入、有效性、身份和参考几何不随未来帧改变。独立人工关键点和多视角几何在约束充分处提供参考，其余位置的物理精度标为未经验证。留出片段中，因果路径的平移与旋转误差中位数为 [X] mm、[X]°，离线路径为 [X] mm、[X]°。身份失败占锚点 [X]%，已接受窗口中错误接受占 [X]%，标签覆盖 [XX]% 窗口。检查耗费 [X] 小时标注，全部 DROID 提升耗费 [X] GPU 小时。图像中静止表面上，选定 PointWorld 轨迹在预测时域内的位移中位数和第 95 百分位为 [0.9]、[5.8] mm；单目深度提升的流则为 [18]、[72] mm，其尺度随时间漂移。在两种来源均无参考真值的运动子集上，报告它们与前后向一致二维跟踪器的一致程度。

E.5 训练配方与规模

仿真模型。 SE(3)-WAM 从通用视觉初始化出发，按表 S6 在 Dynamic-14 训练。在训练样本数相同的条件下，扫描两种主干规模（参考规模，以及固定宽度增加深度使参数约翻倍）、两个全局 batch（B_0 和 $4B_0$）、每个 batch 两个学习率（B_0 使用 $\{0.5, 1\}\eta_0$，大 batch 使用 $\{1, 2\}\eta_0$），再围绕每种规模的最佳配置做 [四] 次局部调整；均按开发场景选择（图 S3a）。

DROID 基座。 基座使用相同架构和初始化，仅使用真实数据。我们在分层抽取的四分之一训练窗口上，将约为仿真主干两倍与四倍的两个先导规模各训练一遍。在单块 RTX 5090 部署预算内（从观测到动作的 p95 不超过 200 ms，任何调用不超过 250 ms），按留出预测和动作误差选规模。选定规模（[XX]M 主干参数）在全部训练窗口上预训练一次，共 [四] 遍，全局 batch 为 [256]，AdamW 优化器，2.5% 预热，余弦衰减至峰值学习率的 0.1。开发损失最低的检查点作为基座（图 S3b）。仅动作、标签来源和屏蔽标签对照采用较小先导规模和预算，与相同规模的世界—动作基座比较（表 S16）。

图占位：图 S3——训练配方与规模

(a) 仿真扫描。纵轴：开发 SR；横轴按两种主干规模分组，每组四根柱分别为相同样本训练量下的 $(B_0, 0.5\eta_0)$、(B_0, η_0)、$(4B_0, \eta_0)$、$(4B_0, 2\eta_0)$；局部调整用小菱形，选定配置加星。**(b) DROID 基座。**横轴：训练样本数（对数）；纵轴：最远时域目标平移误差（左轴，mm）与流端点误差（右轴，mm）；两个先导规模用细线，主训练用粗线，标出所选检查点；水平点线为同一历史的匀速外推。

图 S3. 仿真模型 (a) 与 DROID 基座 (b) 的训练配方和规模。

E.6 独立后训练与对照

真机策略从选定基座初始化，仅在传送带示范上微调。基座用检测器位姿预训练，传送带策略则接收基于物体模型的跟踪器位姿；微调使历史编码器适应该跟踪器，位姿来源变化的代价没有单独测量。任何真机策略均不从仿真权重初始化，基座也不接触仿真数据。各策略建立自己的优化器、调度、仅用训练数据计算的归一化及读出头；不兼容的动作或状态投影在各对照中用同种子重新初始化。无基座参考从通用视觉初始化出发，在相同示范上微调，使用相同的开发试验搜索（[三个] 学习率、两个训练长度）和评测。受控仿真比较在 Dynamic-14 上后训练基座，采用下游配方，与通用初始化使用相同数据比例。仅动作对照在相同窗口上预训练 R0，世界查询没有目标；标签来源对照只替换流标签；屏蔽标签对照删除首次接触后的世界标签（表 S16）。

F 基线、外部基准、真机与计时

F.1 基线

共同条件。 表 S17 汇总适配。各基线保留官方架构、输入、动作块和初始化。ACT 与 Diffusion Policy 从头训练，$\pi_{0.5}$ 从 `pi05_base` 微调，其他方法使用发布权重。所有方法在相同 11,200 条示范上训练，经同一个笛卡尔控制器将指令映射到各自动作空间。Dynamic-14 除 agent 视角外，还渲染 224×224 腕部相机；原配方使用腕部视角的方法获得该输入。SE(3)-WAM 与运动学基线仅用 agent 视角。所有方法采用附录 B.3 的共享执行器和实时协议，表 S23 另加原始执行器对照。

训练。 各基线遵循官方配方和已发表的更新次数，以种子 0 训练一次。我们只改数据读取和动作空间。DreamVLA 同时运行原始 40 epoch 调度与 20 epoch 余弦调度，报告开发场景上较优的一种。相比之下，SE(3)-WAM 的配置经过附录 D 的设计研究选择，而基线未获得同等搜索，其变体使用三个训练种子。

输入。 PUMA [12] 接收由渲染帧计算的历史光流。DreamVLA 接收七帧因果 RGB、末端位置与朝向、夹指位置及固定任务文本，以十步 DDIM 和 1.5 的无分类器引导采样。OpenWAM-α 接收当前 RGB 视角、关节值、夹爪开度和任务文本，联合生成视频与动作，但关闭视频解码。DynamicWAM 接收光流历史和运动学描述。

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从同一因果跟踪器接收附录 C.1 的八个运动 token，使用相同有效性标记与缺失状态嵌入。两层 MLP 将其映射到模型宽度。对 $\pi_{0.5}$，将其追加在前

表 S17. **基线适配**。所有方法均在相同的 11,200 条示范上、以其原论文的输入训练，并在附录 B.3 的共享执行器下运行。更新数 × batch 沿用官方训练配方。Exec.：原论文的执行方式（重规划前每个动作块执行的指令数），仅用于表 S23 的原执行方式对照。参数量：可训练参数，不含冻结的编码器。Seeds：训练种子数。

方法	初始化	输入	更新数 × batch	执行	参数量	种子
ACT [58]	从头训练	主视角 + 腕部 RGB、机器人状态	50,000 × 32	时间聚合	[X]	1
Diffusion Policy [10]	从头训练	主视角 + 腕部 RGB（原论文观测长度）、机器人状态	50,000 × 32	8	[X]	1
$\pi_{0.5}$ [31]	`pi05_base`	当前主视角 + 腕部 RGB、机器人状态、任务文本	30,000 × 256	10	[X]	1
$\pi_{0.5}$ + SE(3)	`pi05_base`	同 $\pi_{0.5}$ + SE(3) 运动 token	30,000 × 256	10	[X]	1
DynamicVLA [46]	发布的 DOM 检查点	帧 $[-2, 0]$、机器人状态、任务文本	50,000 × 44	流式	[X]	1
PUMA [12]	官方检查点	RGB、光流历史、机器人状态、任务文本	[X]×[X]	[X]	[X]	1
DreamVLA [55]	发布的组件	七个因果主视角 + 腕部 RGB 帧、机器人状态、任务文本	48,220 × 512	1	[X]	1
OpenWAM-α [42]	官方基础模型	当前主视角 + 腕部 RGB、关节、夹爪、任务文本	34,490 × 192	32	[X]	1
DynamicWAM [29]	官方初始化	RGB、光流历史、运动学描述	40,000 × 128	16	[X]	1
DynamicWAM + SE(3)	官方初始化	同 DynamicWAM + SE(3) 运动 token	40,000 × 128	16	[X]	1
SE(3)-WAM，匀速外推输入	同 SE(3)-WAM	同 SE(3)-WAM，另加匀速外推 token，无世界监督	同 SE(3)-WAM	–	[X]	3
卡尔曼拦截器	无	跟踪得到的 SE(3) 历史、专家抓取坐标系	–	–	–	–
SE(3)-WAM	冻结的 MAE 编码器	当前主视角 RGB-D、SE(3) 历史、机器人状态	40,104 × 16	–	62.2M	3

缀图像 token 之后，供动作专家关注；对 DynamicWAM，将其并入运动学描述。MLP 输出层零初始化，使训练起点保持基模型行为；训练配方也沿用基模型。

运动学基线。 *SE(3)-WAM*，*CV input* 共用 SE(3)-WAM 的跟踪器、条件 token 和动作流，但无世界监督。动作流改为接收在生效时刻对跟踪位姿作匀速外推的输入 token，在相同数据上按相同配方训练。附录 D.3 另加接收这些 token 且保留世界监督的变体。卡尔曼拦截器没有学习组件。匀加速卡尔曼滤波器 [4] 在跟踪位姿上运行，过程噪声在开发场景调节，并预测目标轨迹。拦截器选择延迟预算后、机械臂在速度限制内最早可达的轨迹点，沿专家的预抓取偏移接近，在预测时刻闭合、释放或对齐。它每次查询重规划，使用专家按任务定义的抓取、放置和入口坐标系。

F.2 DOMINO 与 LIBERO

DOMINO [12] 包含拦截和跟踪两种交互的 35 项任务，具有三级动力学：匀速、多项式轨迹、带突变的随机分段。我们在 clean 设置中使用 Franka 的 [N] 项单臂任务，速度系数 [0.1]，覆盖全部三级，采用官方示范和基准自身评测器，每任务、每训练种子运行 100 条闭环 episode。报告 SR 和 DOMINO 操作分数 MS；MS 按离开工作空间 / 视野及碰撞惩罚缩放路线完成度。表 2 的 DOMINO 列为任务均衡 SR。LIBERO [25] 使用 Spatial、Object、Goal、Long 四套任务，各十项，每任务评测 50 条 episode；我们的方法变体用三个训练种子，基线用一个，采用发布示范与初始状态。两基准上的 SE(3)-WAM 均从与 Dynamic-14 相同的通用初始化训练，使用各域独立归一化。跟踪器物体模型为指令首先作用物体的仿真器网格；无有效位姿的查询（LIBERO 为 [XX]%，DOMINO 为 [XX]%）使用附录 C.1 的缺失状态嵌入。网格是基线没有获得的特权信息，因此表 S18 也报告使用检测器位姿的 SE(3)-WAM，并分别报告各动力学级别与任务套件。

表 S18. **外部基准**（本文各变体三个训练种子，基线一个）。DOMINO：单臂任务按交互类型与动力学等级（L1 匀速、L2 多项式轨迹、L3 含突变的随机分段）分列的 SR（%），以及操作得分 MS；LIBERO：各套件 SR（%）。

	DOMINO						LIBERO				
方法	拦截	跟踪	L1	L2	L3	MS	空间	物体	目标	长程	平均
ACT	—	—	—	—	—	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—	—	—	—	—	—
PUMA	—	—	—	—	—	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，检测器位姿	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	—	—	—	—

图占位：图 S4——真机设置

左：实验单元照片，包含带夹爪的 Franka 机械臂、固定第三人称 RGB-D 相机、腕部相机和传送带，标出基座坐标系及传送带可抓取区域。**右**：三类物体（边长不等的盒子、细长罐子、单柄杯），训练与测试实例并列，标出等价抓取；下方为三种带速（0.04、0.08、0.12 m/s）下首条指令时刻各一帧，并按实测延迟标注 $\|\mathbf{v}\|\Delta$。

图 S4. 真机设置：传送带实验单元，以及三类物体的训练和测试实例。

F.3 真机

平台。 七自由度 Franka 机械臂配备平行夹爪，经带时间戳的笛卡尔接口以 20 Hz 控制（图 S4）。固定 [RealSense D435] 以 [640 × 480]、[30] Hz 记录 RGB-D，每次实验前用棋盘格标定外参。SE(3)-WAM 使用这一第三人称视角，$\pi_{0.5}$ 按其配方额外接收腕部第二相机图像。

任务与成功。 传送带将物体运送经过机械臂。若双指在可抓取区域内稳定夹持物体，将其提离传送带并保持至少 0.5 s，则试验成功。触碰或推动物体、单指夹持、物体离开工作空间后才抓取均算失败。

物体。 三类物体对朝向要求不同：边长不等的轻纸盒（其对称性允许少量等价抓取）、近似轴对称的细长空饮料罐，以及单柄轻塑料杯。记录各实例的质量、尺寸、材质、质心和等价抓取。测试实例不出现在示范中，示范、开发试验和测试试验分不同场次采集。

速度。 传送带以 0.04、0.08 或 0.12 m/s 运行。每个试验块起止时用编码器测量带速，因为电机升温会使带速在一个场次内下降最多 [3]%。速度偏离名义值超过 5% 的试验重做，并报告为设备失败。夹爪在罐子上闭合约需 [XX] ms，该时间计入附录 C.7 延迟预算的执行延迟。

表 S19. **真机成功次数**，按物体与传送带速度（S、M、F：0.04、0.08、0.12 m/s；每格 20 次）及按组（每组 60 次）分列。每组包含全部物体与速度，由一个微调种子执行。All：每个方法 180 次试验的成功率（%）及 95% 二项分布区间。Δ：相对 SE(3)-WAM 的配对差值（百分点）及按试验键自助法得到的区间。

	盒			罐			杯			组				
方法	S	M	F	S	M	F	S	M	F	1	2	3	All	Δ
$\pi_{0.5}$	—	—	—	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM，无 DROID 基座	—	—	—	—	—	—	—	—	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—	—	—	—	—	—	—	—	–

表 S20. **单次查询的延迟分解**（SE(3)-WAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧）	—	—
图像编码	—	—
条件 token（缓存）	—	—
动作生成（无世界）	—	—
出动作时间（合计）	—	—
可选预测（不被读取）	—	—
生效时的动作年龄（真机）	—	—
超时比例（真机，%）	—	

试验。 每方法运行 180 次，每个物体与速度组合 20 次。各方法使用相同的预生成试验键，固定物体实例、速度，以及从标定可抓取区域采样的起始位置与朝向。策略不可见的外部夹具设置并记录起始位姿。试验键分为三个均衡块，每块 60 次，各块使用独立随机次序，避免设备漂移与方法对应；每个微调种子负责一块。操作者手动复位。试验从首个可用观测开始，无免费观测期，机器人可随时运动。人工接触、安全停止和人工完成均计失败。首个可用观测前的基础设施故障重做并报告。

微调。 SE(3)-WAM 从 DROID 基座出发，在任务的 [300] 条遥操作示范上以三个种子微调（附录 E.6）。无基座参考采用通用初始化，示范、种子和搜索相同；$\pi_{0.5}$ 从 `pi05_base` 在相同示范上用三个种子微调。跟踪器使用 [盒子的 CAD 模型，以及罐子和杯子的参考视图]（表 S5）。

分析。 接触时间误差相对由传送带编码器计算的可行接触窗口测量，未接触失败仍计入 SR 分母。表 S19 按物体、速度和块报告成功次数，汇总成功率给出 95% 二项区间，并对试验键 bootstrap 得到配对差值。因物理和相机不同，真机结果与仿真传送带任务分开报告。评测耗时 [四] 天。SE(3)-WAM 的失败大多为 [罐子被夹爪遮挡时跟踪丢失，导致闭合过晚]；杯子上主要为 [从把手侧闭合的抓取]。

F.4 计时

所有方法在机器人部署 GPU，即单块 RTX 5090（32 GB）上计时。每方法先预热三十次，再在三个八帧观测序列上测量 300 次调用，调用边界 CUDA 同步，轮换方法顺序共做三轮，各自使用发布版本的精度。从观测到动作的时间包含最新帧跟踪、图像编码和首条指令生成；完整预测耗时单独记录。表 2 给出 p95，表 S17 给出参数量。真机轨迹记录采集、可用、预处理、推理起止、进入队列、发出和生效时刻。动作年龄为生效时刻减采集时刻，报告 p50、p95、最大值、错过截止时刻的比例及峰值显存（表 S20）。Dynamic-14 的延迟扫描与墙钟部署不同：它在物理持续推进时插入规定延迟。

表 S21. **Dynamic-14 各任务的留出成功率**（%），涵盖表 2 中的全部方法，本文各变体取三个训练种子的平均、基线训练一次，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。DrVLA：DreamVLA。OWAM：OpenWAM-α。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。CV：匀速外推输入的 SE(3)-WAM 。KF：卡尔曼拦截器。Det.：使用检测器位姿的 SE(3)-WAM 。Δ：该任务上 SE(3)-WAM 相对最强其他方法之差及其 95% 配对区间。任务代号见表 S3。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	DrVLA	OWAM	DWAM	DWAM+	CV	KF	Det.	本文	Δ [95% CI]
谐波抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
传送带抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
平移抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
遮挡抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
移动容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
旋转容器	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
导线穿越（完整）	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
小球捕获（桌面）	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
滑块捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
罐体捕获	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
撞击后抓取	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
任务等权	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—

G 补充结果

G.1 逐任务结果与结局

表 S21 将表 2 的 Dynamic-14 留出结果按各方法、各任务展开，给出 SE(3)-WAM 相对该任务最强其他方法的配对区间。表 S22 报告 episode 的终止方式；某方法若以一种失败换取另一种，例如更少碰撞但更多超时，只在此处才能看出。全部失败均保留在成功率分母。

G.2 协议与延迟

表 S23 在另外三种协议下评测所有方法。暂停物理去掉计算时间的代价；等延迟为各方法计入 SE(3)-WAM 的 p95 延迟，区分方法自身速度与利用时间的方式；原始执行器检验共享执行器是否使某方法处于劣势。排名依赖协议：暂停物理时，[DreamVLA] 领先 SE(3)-WAM [X.X] 个百分点，等延迟下差值为 [X.X] 个百分点。原始执行器对基线 SR 的改变最多为 [X.X] 个百分点。表 S24 给出扫描中各附加延迟的成功率，其中 SE(3)-WAM 与最强基线两行是图 1 右侧的数据。

G.3 阴性与无效结果

视觉历史。 表 S8 的八种视觉历史均未比当前帧提高超过两个百分点。其中 [N] 种的区间在 ±2 个百分点内，[N] 种结果不确定，包括带度量位置的 RGB-D 窗口。冻结读出从这些历史恢复过去目标位置的误差为 [X]–[X] mm，SE(3) 历史为 [X] mm。因此信息确实存在，但在我们的数据规模下，策略未将其转化为度量运动。更大数据集或专门运动目标可能改变这一结果。

图像空间未来。 表 S11 中作为世界目标的各类图像空间未来（场景轨迹、稠密位移、编码器运动向量、视频隐变量、冻结视频模型、深度、DINO 或动态 RGB），均未比不含环境的 SE(3) 未来高出超过

表 S22. **结局类别**：Dynamic-14 留出场景（各类 episode 占比，%，种子平均，实时协议）。类别定义见附录 B.1；每行合计为 100。

方法	成功	安全	任务违规	边界	超时	无效
ACT	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—
卡尔曼拦截器	—	—	—	—	—	—
SE(3)-WAM，检测器	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—

[X.X] 个百分点。其目标对像素或隐变量维度加权，而容差取决于度量误差。将深度、DINO 特征和运动区域 RGB 作为选定世界之外的训练辅助目标，可提高 [X.X] 个百分点。因此，外观有助于场景查询的辅助学习，但不能替代度量未来。

环境分辨率。 间隙高于粗流路径误差时，28^2、56^2 网格和按物体采样的流与 14^2 网格相差不超过两个百分点，成本最高为其 [X]×；其优势仅限于最窄间隙。

耦合。 世界读取动作（R3）或双向读取（R4），在任何延迟下均未稳定优于 R1（表 S14）。没有任何动作读取世界的耦合比仅训练时世界监督高出超过 [X.X] 个百分点。在同一网络中关闭世界损失（R0），相比 R1 损失 [X.X] 个百分点，因此收益来自监督，而非新增查询。R1 中没有世界到动作的边，部署时计算预测不改变动作，仅增加 [X.X] ms；实时协议下，这种部署比仅动作部署损失 [X.X] 个百分点。

未解决任务。 所有方法均无法完成向旋转容器的 SE(3) 放置（t2_se3，表 S21）。[策略到达容器，但在其转走前未能满足角度容差。] 所有 SE(3)-WAM 变体均未解决在线缆通行之外还需抓取和释放套杆的完整通行（t3_full），而 [OpenWAM-α] 在其中 [XX]% 的 episode 成功。对起始时已持杆的通行（t3_phase），SE(3)-WAM 的跨训练种子成功率从 [0] 到 [71]%。

其他失败。 图 4a 的曲线坍缩在捕获任务最弱（Spearman $\rho = [X.XX]$），因为成功也取决于夹爪闭合时刻；噪声交叉点高于不依赖学习模型的 $\sigma^\star$ [X.X] 倍。碰撞后抓取从世界监督获益最少（相对 CV input 提高 [X.X] 个百分点），因为条件均值无法表示碰撞的多种结果。检测器位姿损失 [X.X] 个百分点，主要发生在对称和细薄目标上。SE(3)-WAM 剩余失败主要为 [例如首次抓取错过后的超时]（表 S22）。

G.4 生效时刻的预测

图 S5 按物理时间戳对齐查询、预测、真值、发出动作和首次接触。示例展示预测误差在哪里产生，例如碰撞瞬间或滚动物体离开斜坡时，以及它们如何转化为接触时间和位姿误差。

表 S23. **评测协议对照**：Dynamic-14 留出场景（SR，%）。暂停：推理期间物理暂停，各方法使用其原论文的执行方式。等延迟：共享执行器，所有方法均计入 SE(3)-WAM 的 p95 延迟。原执行方式：实时协议下使用各方法自身的执行方式。实时：表 2 的协议。丢弃：实时协议下因过时而被丢弃的指令比例（%）。

方法	暂停	等延迟	原执行器	实时	丢弃 (%)
ACT	—	—	—	—	—
Diffusion Policy	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—
DynamicVLA	—	—	—	—	—
PUMA	—	—	—	—	—
DreamVLA	—	—	—	—	—
OpenWAM-α	—	—	—	—	—
DynamicWAM	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	–	—	—
卡尔曼拦截器	—	—	–	—	—
SE(3)-WAM，检测器位姿	—	—	–	—	—
SE(3)-WAM	—	—	–	—	—

图占位：图 S5——预测与实际发生的运动对齐

第 1–4 行：各运动类型（传送带、旋转目标、滚动捕获、碰撞后）中误差中位的留出 episode；**第 5 行**：一个失败案例。**列**：查询时刻 τ_t 的帧；首条指令生效时刻 τ^{a} 的帧；基座系三维插图。**叠加**：蓝色历史 SE(3) 位姿；橙色在 $\tau_t + \delta_h$ 的目标预测坐标轴与粗粒度环境流箭头；灰色相同物理时刻的真值位姿；紫色发出的夹爪路径；首次接触标记。每行下方绘制学习的 SE(3)、匀速、匀加速预测的平移与旋转误差随时域变化。红色标注第 5 行失败原因。

图 S5. 世界头在留出 episode 上的预测，与真值及发出动作在物理时间上对齐。第 1–4 行为各运动类型误差中位的 episode，第 5 行为失败案例。

G.5 补充视频

补充视频展示 SE(3)-WAM 与 $\pi_{0.5}$ 在三种带速下的传送带试验，并叠加预测；另含各任务族的一组 Dynamic-14 episode，以及第 5.5 节讨论的失败案例。

表 S24. **成功率随附加延迟的变化：**Dynamic-14 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 2 的 All 与 +150 ms 列。斜率：SR 对附加延迟的最小二乘斜率（每 100 ms 的百分点）。

	附加延迟（ms）					
方法	0	50	100	150	200	斜率
ACT	—	—	—	—	—	—
Diffusion Policy	—	—	—	—	—	—
$\pi_{0.5}$	—	—	—	—	—	—
$\pi_{0.5}$ + SE(3)	—	—	—	—	—	—
DynamicVLA	—	—	—	—	—	—
PUMA	—	—	—	—	—	—
DreamVLA	—	—	—	—	—	—
OpenWAM-α	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—
DynamicWAM + SE(3)	—	—	—	—	—	—
SE(3)-WAM，匀速外推输入	—	—	—	—	—	—
卡尔曼拦截器	—	—	—	—	—	—
SE(3)-WAM，检测器位姿	—	—	—	—	—	—
SE(3)-WAM	—	—	—	—	—	—