FoveaWAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

要操作运动中的物体，策略必须预测动作执行那一刻的场景，而用于预测的每一毫秒都会把那一刻推得更远。现有策略要么以统一的精细程度预测整个场景，因而行动迟缓；要么只关注目标、忽略其余一切，以换取速度。我们的核心洞察是，策略需要预测的内容可以按角色解耦：只有决定接触的目标位姿需要毫米级精度，而周围环境只通过它们留下的间隙和传给目标的运动起作用。我们提出 FoveaWAM，一个按角色分配精度的原生 4D 世界—动作模型：它把目标过去与未来的运动建模为度量的 SE(3) 轨迹，把周围环境建模为稀疏 3D 流，一切静态内容则交给当前帧。这种紧凑的表征使 FoveaWAM 在一块 RTX 5090 上 15.1 ms 即可输出动作，比视频世界—动作基线快约 10×，留给场景变化的时间很短。为了在每个策略自身的延迟下对其进行评测，我们提出动态操作基准 OnTimeBench：策略计算期间，场景持续运动。FoveaWAM 在 OnTimeBench 上的成功率达到 82.1%，比最强基线高 20.7 个百分点，并在 DOMINO 和真机任务上同样领先。

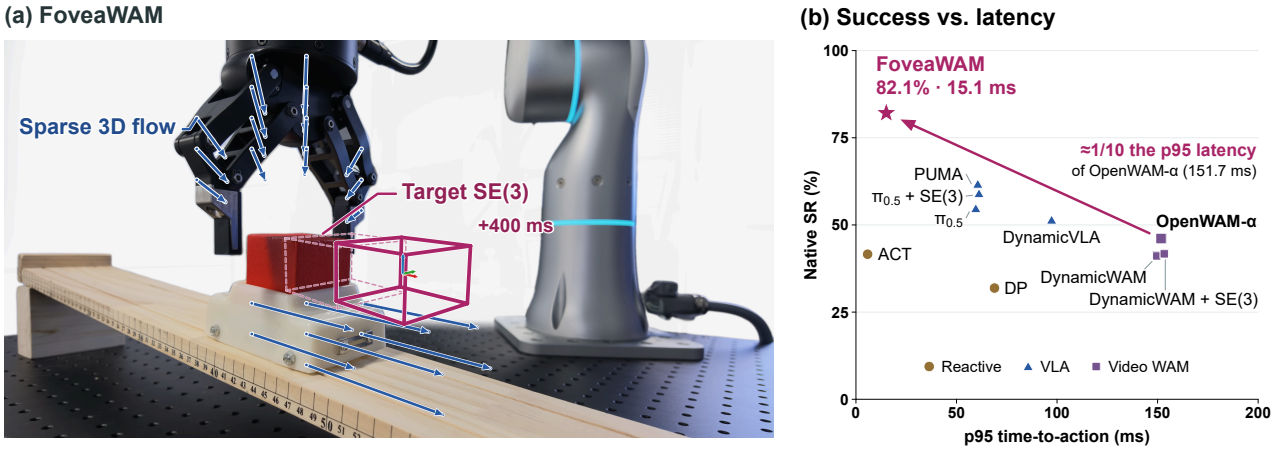


图 1. **FoveaWAM 按角色分配预测精度。**(a) 它为目标预测精确的 SE(3) 轨迹，为周围环境预测稀疏 3D 流。(b) OnTimeBench 上原生延迟下的成功率（SR）与 p95 出动作时间：FoveaWAM 的 SR 最高，延迟约为视频世界—动作模型的十分之一。

1 引言

机器人操作策略在“会等它”的场景中进展迅速 [5, 10, 56]：无论策略计算多久，它观测到的场景仍是它行动时的场景。运动的物体打破了这一前提。一个以约 0.9 m/s 的速度沿斜坡滚下的小球，在 200 ms 的推理期间会移动 18 cm，而接触只容许毫米级的误差。策略因此必须依据预测行动，即预测动作执行时场景将处于何处。但预测本身就是计算，它又拉长了自己必须覆盖的时间：策略预测得越多，动作就越晚，需要预测得也就越远。现有动态策略在这一矛盾的两端各取其一（图 2）。一类以统一的精细程度预测整个场景，形式为未来视频、隐变量或 3D 动力学 [31, 32, 49, 56, 61, 64]；它们看到一切，但动作来得晚。另一类只预测被操作的物体 [14, 17]；它们动作更早，却漏掉了会阻挡或改变其运动的周围环境。两者都把精度与覆盖范围绑在一起：凡是预测的部分都完整预测，于是对场景知道得越多，

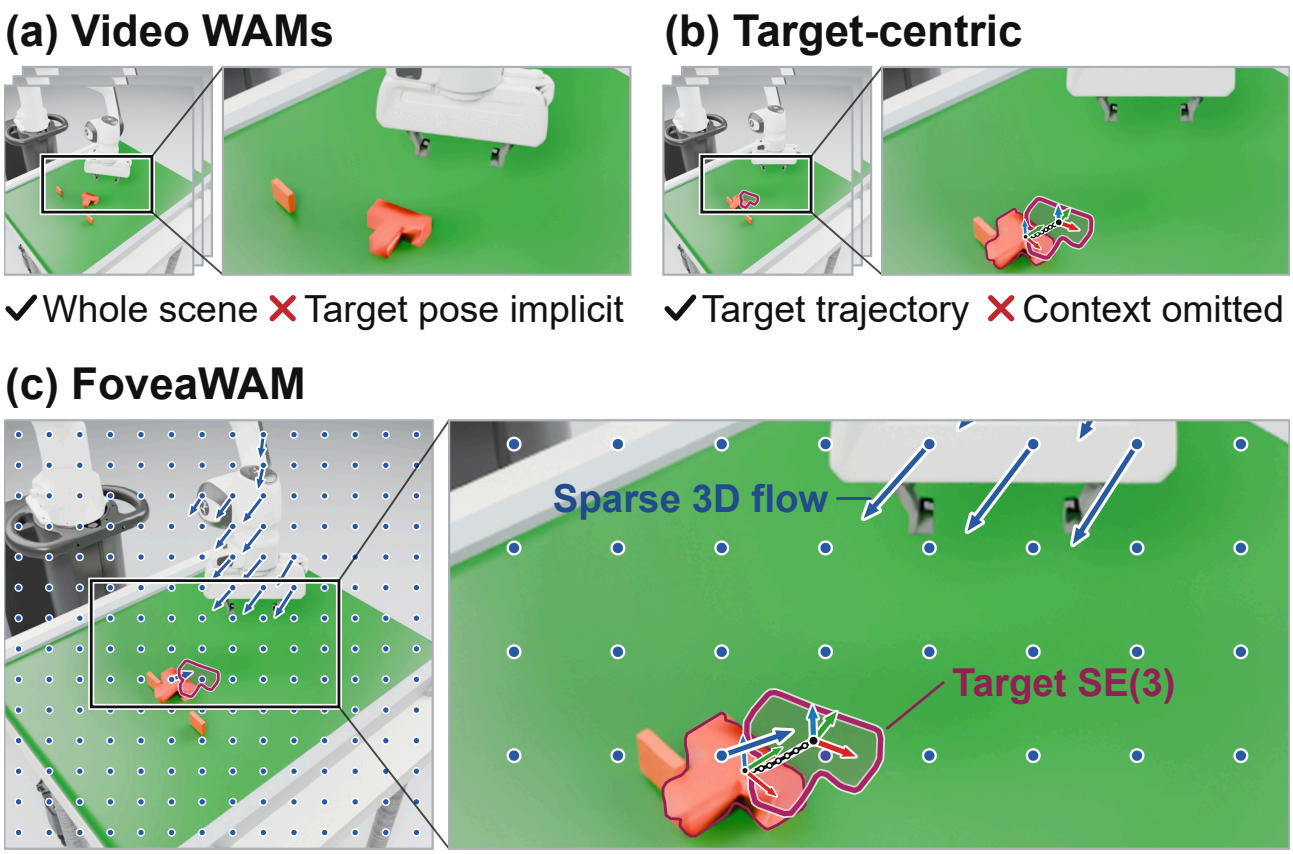


图 2. **预测精度分配在哪里。** (a) 视频世界—动作模型（WAM）预测整个场景，目标位姿隐含其中 [49, 56]。(b) 以目标为中心的预测器仅预测目标轨迹 [14, 17]。(c) FoveaWAM 根据单张当前帧和目标的位姿历史，预测精确的目标 SE(3) 轨迹和稀疏的 3D 场景流。(a) 和 (b) 的叠帧分别表示未来帧和观测历史。(b) 和 (c) 将未来运动叠加在当前帧上。

动作就越晚。我们转而要问：*为了及时完成接触，策略需要知道运动场景的哪些信息，又需要知道得多精确？*

我们的核心洞见是：这个问题的答案按角色解耦（图 1）。目标决定接触，因此它在动作执行时刻的位姿必须达到毫米级精度。周围环境只通过它们留下的间隙和传给目标的运动起作用，因此它们的运动只需粗略地知道。一切静止的部分已经在当前帧里，完全不需要预测。因此，必须精确知道的只是一个物体的轨迹，而不是整个场景；把精度花在这里的策略，可以在决定接触之处做到精确，同时来得及行动。生物视觉做的是同样的分配：中央凹只在注视之处分辨精细细节，周边视野虽然粗略却对运动保持敏锐，注视还会先于手到达即将发生接触的位置 [12, 19, 24, 36, 42]。

我们把这种分配构建为 **FoveaWAM**，一个原生 4D 世界—动作模型，其表示与三种角色相对应（图 2c）。目标由一条度量 SE(3) 轨迹描述：一段短的位姿历史代替过去的图像帧提供其过去的运动，模型学习预测这条轨迹的延续。周围环境由稀疏 3D 流描述，一切静止的部分只由当前帧描述。由于运动由一条轨迹和一组稀疏流表示，而不是由图像帧表示，FoveaWAM 在单张 RTX 5090 上 15.1 ms 内给出动作，约比视频世界—动作模型快 10 倍，使场景几乎来不及运动。

只有当延迟需要付出代价时，才能衡量一个策略是否来得及行动。为此我们提出 **OnTimeBench**，一个包含 14 个动态操作任务的基准，其中世界从不暂停：策略计算多久，场景就运动多久，每个方法都在其原生延迟下接受评测。在 OnTimeBench 上，FoveaWAM 的成功率为 82.1%，比最强基线高 20.7 个百分点；它在 DOMINO [14] 和真机任务上同样领先。消融实验验证了这种分配：去掉目标的位姿历史、其 SE(3) 预测或周围环境的稀疏流，成功率都会下降。在原生延迟下评测还改变了现有策略的排

名：世界暂停时最强的基线，在世界持续运动后下降 17.3 个百分点，并失去领先。

我们的贡献有三点：

- 我们指出动态操作的核心矛盾，即预测运动场景需要时间，而这段时间里场景又继续运动，并表明按角色分配精度可以化解它：目标在动作执行时刻的位姿需要毫米级精度，周围环境只需粗略的运动，静态场景无需预测。消融实验验证了这种分配的每一部分。
- 我们提出 **FoveaWAM**，一个原生 4D 世界—动作模型，用度量 SE(3) 目标轨迹和稀疏 3D 场景流实现这种分配。它在 15.1 ms 内给出动作，约比视频世界—动作模型快 10 倍，在 OnTimeBench 和 DOMINO 上分别领先最强基线 20.7 和 19.9 个百分点，在真机任务上同样取得提升。
- 我们提出 **OnTimeBench**，一个包含 14 个动态操作任务的基准，其中世界从不暂停，每个策略都在其原生延迟下接受评测，从而揭示了暂停式评测所掩盖的延迟代价。

2 相关工作

动态操作。 对运动物体的操作长期依靠人工设计的跟踪与拦截 [1–3, 34, 40]，如今转向从数据中学习 [9, 26, 54]。学习型策略从图像空间线索获取运动，例如 PUMA [14] 和 DynamicWAM [31] 中的光流，或在测试时依据对场景的预测来行动 [32, 44, 61, 64]。FoveaWAM 则读取目标的度量 SE(3) 位姿历史，并且只观测当前帧。执行方案 [6, 29, 38, 45, 54] 改变的是动作何时被施加，而不是策略表示什么，二者互为补充。DOMINO [14] 和 PhysMani-Bench [61] 提供了多样的动态任务，但默认在策略返回之前暂停仿真；OnTimeBench 在推理期间推进仿真，因此每个策略都在其自身的延迟下接受评测。

世界—动作模型中的预测。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [25, 49, 56, 68]，建立在以视频预测作为策略目标的工作之上 [46, 53]。由于生成视频代价高，近期工作转而预测更廉价的对象，如特征、流、物体 slot 或紧凑隐变量 [30, 43, 57, 59, 63, 67]，其中一些只在训练中使用预测 [14, 60, 65]。这些方法的预测都位于像素、特征或隐空间，目标的未来位姿仍是隐式的。FoveaWAM 保留“只在训练中预测”的用法，但预测的是精度按角色分配的度量 4D 状态，因此目标的未来位姿得到显式监督。

以物体为中心的几何运动表示。 度量 3D 输入提升了精度和样本效率 [37, 62]；运动则被表示为点轨迹 [4, 52, 55]、3D 流 [15, 18, 58, 61]、物体关键点或 SE(3) 轨迹 [17, 33, 41]，以及刚体分解 [7, 8]。它们要么对整个场景使用同一种表示，要么只建模目标 [14, 17]。DOCIR 区分了机器人、目标与障碍物，但只用作输入编码 [13]；中央凹化的机器人感知则围绕注视点分配图像分辨率 [11, 21, 23]。FoveaWAM 分配的是预测内容的精度：场景用粗略的稀疏流，目标用度量 SE(3) 轨迹。

3 FoveaWAM

我们提出 FoveaWAM，一个原生 4D 世界—动作模型，它在“当前时刻”的两侧都按角色分配精度（图 3）。它用同一种划分编码过去（第 3.2 节）并预测未来（第 3.3 节）：目标用度量 SE(3) 轨迹表示，周围环境用粗粒度 3D 几何表示，静态部分只用当前帧表示。动作流读取这一表示，生成按时刻索引的指令（第 3.4 节）。

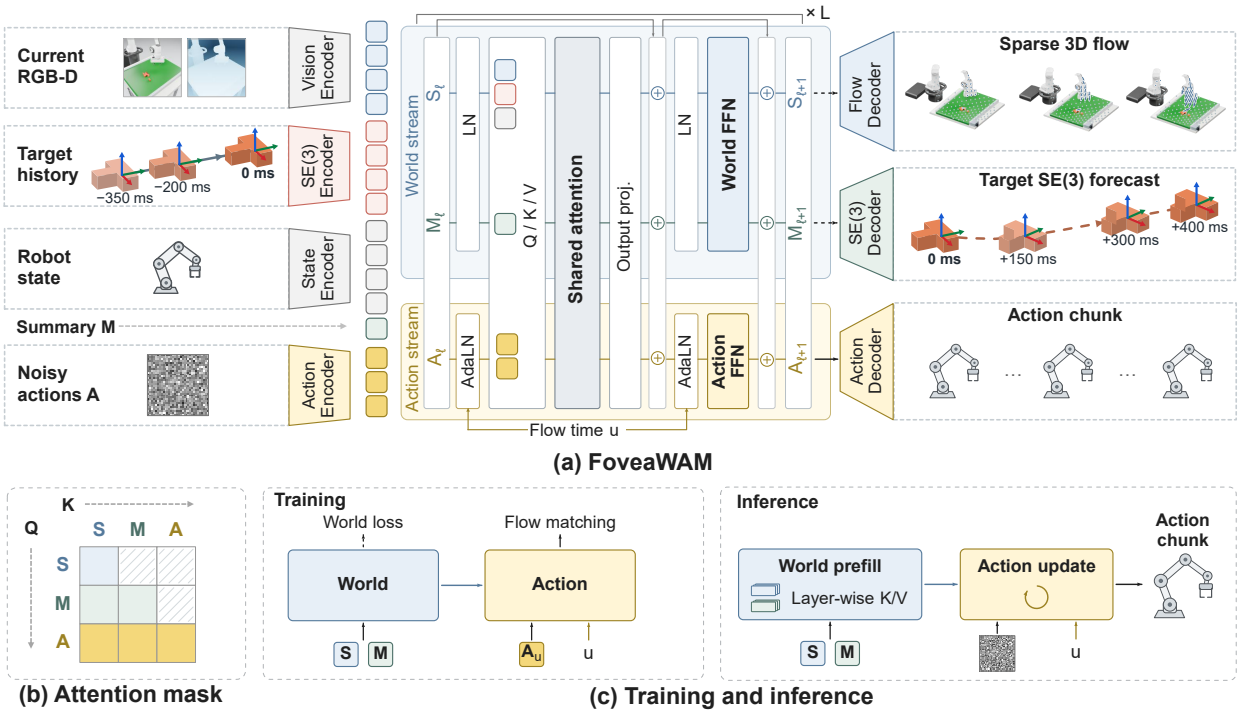


图 3. **FoveaWAM 总览。** (a) 架构。当前 RGB-D 帧与目标、机器人的历史组成场景 token S，另有摘要 token M 与带噪动作 token A。所有 token 共享掩码注意力，其后接各自独立的世界 FFN 与动作 FFN。稀疏 3D 流与目标 SE(3) 轨迹由 S 和 M 预测。(b) 注意力掩码。行为 query，列为 key。斜线格表示被屏蔽。(c) 训练与推理。世界流与动作流联合训练；推理时世界流只运行一次，并跳过预测头。

3.1 问题形式化

我们研究场景在策略计算期间持续运动的操作。在第 t 次查询时，从示范中学得的策略 π 读取在时刻 τ_t 采集的 RGB 图像 I_t 与深度图 D_t，以及目标位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 的历史 $\mathcal{T}_t$ 与机器人状态的历史 $\mathcal{R}_t$，所有几何量都在机器人基座坐标系中表示，并输出一个包含 H 条指令的动作块：

$$(\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1}) \sim \pi\big(\cdot \mid I_t, D_t, \mathcal{T}_t, \mathcal{R}_t\big), \tag{1}$$

其中第 j 条指令对应时刻 $\tau_t + j\Delta_a$，Δ_a 为控制周期。

每个任务把场景分为三种角色。目标是机器人须在接触或容纳容差内对齐其位姿的物体。环境是周围物体中起作用的部分：机器人须避开的障碍物，以及推动目标运动的驱动物。其余部分都是静态的。动作块要在推理完成后才可用，因此每条被执行的指令必须考虑目标与环境在其执行时刻、而不是 τ_t 时刻的状态。

3.2 按角色编码场景动态

策略需要了解的“过去”同样按角色解耦。静态场景没有值得编码的历史：当前帧已经给出它的布局。环境通过两种方式起作用：它留出的间隙属于当前几何，它传递给目标的运动则体现在目标已经发生的运动中。只有目标的运动需要精确获知，而这一运动是 SE(3) 中的一条刚体轨迹。因此 FoveaWAM 只观测单帧 RGB-D 来刻画场景，并用一段简短的度量位姿历史来刻画目标。从多帧图像 [10, 54] 或光流历史 [14, 31] 中获取运动的策略，需要在每个过去时刻对整幅图像做稠密提取，而目标的速度仍然隐含在外观中。FoveaWAM 则从几个低维 token 中直接得到以物理单位表示的速度。这种编码使模型足

够轻量，能在一个控制周期内出动作，同时保持目标运动的度量精度。

用当前帧刻画静态场景。 FoveaWAM 把每个 patch token 锚定在一个度量 3D 点上，使观测与预测、动作处于同一个基座坐标系中。冻结的 MAE ViT-B/16 [16] 把 RGB 图像编码为14×14 网格上的 196 个 patch token，深度图把 patch i 的中心反投影为基座坐标系中的点 $\mathbf{x}_i \in \mathbb{R}^3$。$\mathbf{x}_i$ 的线性嵌入加到 patch token 上，$\mathbf{x}_i$ 还驱动 patch 查询与键的 3D 旋转位置编码，使 patch 之间的注意力取决于它们的相对 3D 位置。单帧图像由此以度量几何的形式给出场景布局及其间隙。这些点 $\mathbf{x}_i$ 也是场景流的源点（第 3.3 节）。

用位姿历史刻画目标运动。 目标近期的运动以度量 SE(3) 状态的形式输入。目标历史以 20 Hz 的 8 次采样覆盖最近 350 ms；它的 8 个 token 包含当前目标位姿与相邻采样之间的七段运动，每段包含平移、相对旋转、时间间隔，以及以物理单位表示的有限差分速度与加速度。决定目标将到达何处的速度与加速度因此直接进入模型；传送带、斜坡等驱动物的作用，也通过它已经传递给目标的运动得到刻画。位姿在仿真中取自仿真器，在真机上由在线 RGB-D 跟踪器给出。

世界流。 patch token、目标 token，以及编码目标历史各采样时刻末端执行器状态的 8 个机器人 token，共同组成 212 个场景 token。它们与汇聚它们的 16 个可学习摘要 token 一起构成世界流。全部运动历史因此只占十六个低维 token，而每多输入一帧图像就要增加 196 个 token。

3.3 按角色预测 4D 未来

每条指令落地时的场景都晚于被观测的场景，因此表示必须预判指令执行时刻的场景，而所需的精度同样取决于角色。接触由目标的位姿决定，因此 FoveaWAM 预测目标完整的 SE(3) 轨迹。环境通过间隙和它传递的运动起作用，因此 FoveaWAM 只粗略地预测场景的运动，即 patch 网格上的稀疏 3D 流。两种预测都在基座坐标系中、以相对当前状态的变化表示于时刻 $\tau_t + \delta_h$，其中 $\delta_h = h \cdot 50\,\text{ms}$，$h = 1, \ldots, 8$；连同当前状态，这些时域覆盖动作块中所有指令的执行时刻。两者都是动作流本来就要读取的 token 上的线性读出：它们在训练时塑造表示，在推理时被跳过，因此预测不增加任何延迟。

稀疏 3D 场景流。 在 patch 网格的分辨率上，场景流覆盖 patch 所见的每个表面：机器人、目标，以及指令必须考虑其间隙与运动的环境。对 196 个点 $\mathbf{x}_i$ 中的每一个和每个时域 h，patch token i 最终状态上的线性头预测该点在基座坐标系中的位移 $\hat{F}_{ih} \in \mathbb{R}^3$ 与可见性 logit $\hat{o}_{ih}$，以如下损失训练：

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h)\in\mathcal{V}_F} \Big[\tfrac{1}{3} \big\| (\hat{F}_{ih} - F_{ih})/s \big\|^2 + \mathrm{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \tag{2}$$

其中 F_{ih} 为 $\mathbf{x}_i$ 处表面点的位移，o_{ih} 为其可见性，s 为在训练标签上拟合的固定尺度，$\mathcal{V}_F$ 为有效标签集合。

目标 SE(3) 轨迹。 场景流只在目标覆盖的少数几个 patch 上采样目标，过于稀疏，无法确定其旋转。因此由摘要 token 最终状态均值上的一个专用线性头直接预测目标的刚体运动：对每个时域 h，预测目标的位移 $\hat{\mathbf{d}}_h$ 与旋转增量 $\hat{\phi}_h$，以如下损失训练：

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h\in\mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\mathrm{SO(3)}}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{3}$$

其中 $\mathbf{d}_h = \mathbf{p}(\tau_t+\delta_h) - \mathbf{p}(\tau_t)$ 与 $R_h = R(\tau_t+\delta_h)$ 为真实的位移与朝向，$\hat{R}_h = \mathrm{Exp}(\hat{\boldsymbol{\phi}}_h^{\wedge})R(\tau_t)$，$d_{\mathrm{SO}(3)}$ 为测地距离，$\mathcal{V}$ 为具有有效标签的时域集合。旋转项是接触所必需的：旋转误差 θ 可使与目标原点相距 r 的接触点偏移至多 $2r\sin(\theta/2)$，在 $r = 10\,\mathrm{cm}$ 处 5° 的误差即接近 9 mm。

3.4 世界—动作联合学习与推理

动作流。 动作流以条件流匹配 [27] 生成动作块。它包含 $H = 8$ 个 token，每个嵌入一条加噪指令：末端执行器的平移增量、旋转增量与夹爪指令。每一层中，一个注意力以共享的投影覆盖两条流，其后接各自独立的前馈网络；世界 token 使用层归一化，动作 token 使用以流时间为条件的自适应层归一化。记场景、摘要与动作 token 为 S、M 与 A，注意力掩码允许 $S \to S$、$M \to \{S, M\}$ 与 $A \to \{S, M, A\}$，其中 $X \to \mathcal{Y}$ 表示 X 中的 token 读取 $\mathcal{Y}$ 中的 token。动作流因此在每一层都同时读取受场景流塑造的 patch 状态与受目标轨迹塑造的摘要状态，而世界流从不读取动作。

训练目标。 对以训练统计量归一化的动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与流时间 $u \sim \mathcal{U}[0, 1]$，动作流 v_ψ 回归流匹配速度：

$$\mathcal{L}_A = \mathbb{E}\,\mathrm{MSE}\big(v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t),\, \mathbf{a}_1 - \mathbf{a}_0\big), \tag{4}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为式 (1) 中的输入，MSE 在有效指令与动作维度上取平均。世界流与动作流以

$$\mathcal{L} = \mathcal{L}_A + \lambda_F\mathcal{L}_F + \lambda_P\mathcal{L}_P + \lambda_{\mathrm{aux}}\mathcal{L}_{\mathrm{aux}} \tag{5}$$

联合训练，其中 $\mathcal{L}_F$ 与 $\mathcal{L}_P$ 为式 (2) 与式 (3) 的流与位姿损失，$\mathcal{L}_{\mathrm{aux}}$ 为辅助外观损失之和。

推理。 部署时，FoveaWAM 跳过两个预测头 [25, 60, 63]。由于世界 token 既不读取动作，也不读取流时间，世界流每次查询只运行一次，动作流在场景与摘要 token 缓存的键和值上积分 5 个 Euler 步。在一块 RTX 5090 上，一次查询的 p95 耗时为 15.1 ms，在一个控制周期之内。指令按相对采集时刻的时间索引，因此策略不需要延迟输入：动作块到达时，从对应该时刻的指令开始执行（第 4.3 节）。更多实现细节见补充材料。

4 OnTimeBench 基准

4.1 概览

动态基准必须让每个策略为其计算所花的时间付出代价。如果仿真要等策略返回动作之后才推进，如 DOMINO [14] 与 PhysMani-Bench [61] 的默认评测器那样，慢的策略就被当作瞬时完成来评分：这样的评测衡量了策略预测了什么，却没有衡量预测能否及时到达，而后者正是真机上成败的关键。

为了评测策略能否及时作用于运动中的场景，我们提出 OnTimeBench ，一个包含 14 个动态操作任务的基准，其中世界从不暂停。观测、场景运动与动作执行共用一个物理时钟，因此每个策略计算多久，场景就继续运动多久。图 4(a) 展示了这一差别：在 200 ms 的推理期间，世界暂停时滚动的小球停在被观测到的位置；而在 OnTimeBench 中它已经滚出 18 cm，瞄准观测位置的动作会落空。OnTimeBench 包含五个任务族（图 4(b)）：*抓取*，抓取做简谐、传送带、平移、旋转或遮挡运动的目标；*放置*，把所持物体放入平移或旋转的容器；*穿越*，让棒沿旋转的导线穿过；*捕获*，捕获滚动或滑动的物体；以及*撞击*，在撞击后抓取零件。图 4(c) 展示了全部 14 个任务。这些任务共同改变决定成败的因素：目标的速度（0.03 至 1.14 m/s）、目标的旋转、障碍物留出的间隙，以及传送带、斜坡、撞击器等驱动物传递的运动。

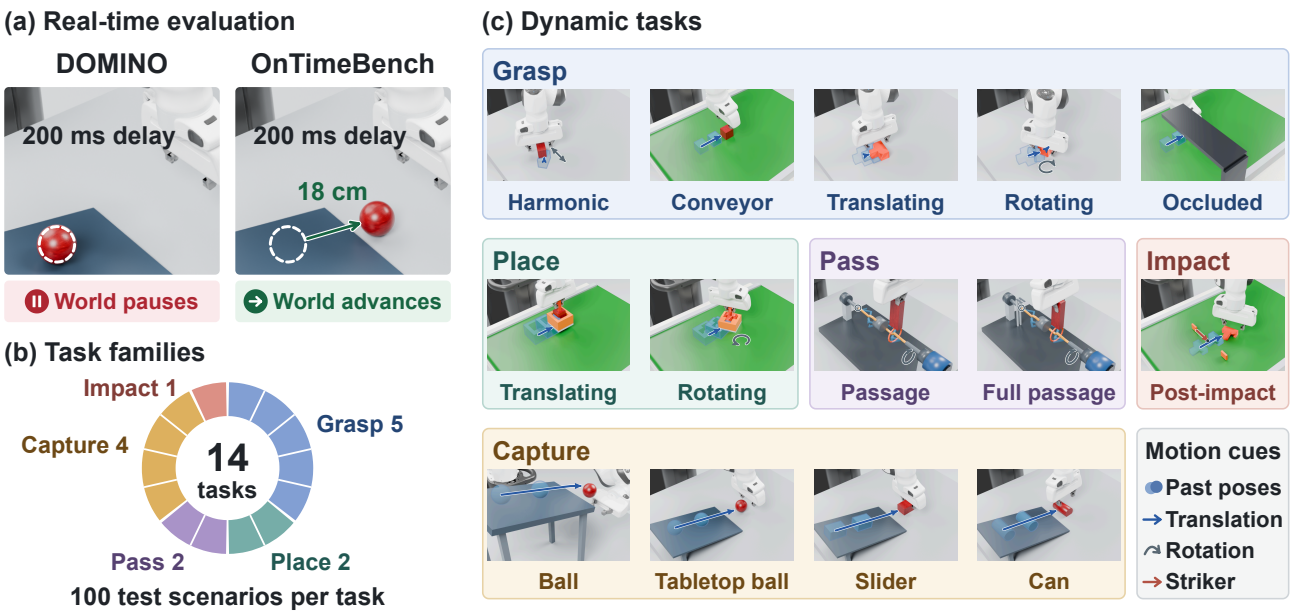


图 4. **OnTimeBench 总览。**OnTimeBench 在各方法的原生延迟下评测策略，包含五个任务族的 14 个动态任务和 1,400 个留出测试场景。(a) 在 200 ms 的推理期间，DOMINO [14] 的默认评测器暂停世界，OnTimeBench 则让世界持续运动。(b) 各任务族的任务数。(c) 14 个任务，叠加了运动线索。

4.2 构建

OnTimeBench 基于 MuJoCo 与 robosuite [47, 69] 构建，使用以 20 Hz 控制的 Franka Panda 机械臂。每个场景在任务各自的范围内采样目标的初始状态与运动参数。使用仿真特权状态的任务专家为每个任务提供 800 条示范，共 11,200 条。所有结果都在全部方法共用的 1,400 个留出测试场景（每个任务 100 个）上报告；配置在另外的开发场景上选择。

4.3 评测协议

原生延迟。 每次查询期间，物理按该方法自身的推理延迟推进；延迟从该方法在一块 RTX 5090 上以 batch 1 实测的延迟分布中抽取。所有方法共用同一个执行器：它在推理完成后的第一个控制周期边界接收动作块，并从对应该边界的指令开始执行。

设置与指标。 我们评测三种设置：*原生*，各方法承担自身的延迟；*+150 ms*，为每个方法附加 150 ms；以及*暂停*，在推理期间暂停世界。我们报告任务等权的成功率（SR）与 p95 出动作时间，即从采集观测到其第一条指令可用的时间。完整协议见补充材料。

5 实验

5.1 实现细节

基线。 我们比较反应式策略 ACT [66] 与 Diffusion Policy（DP）[10]、视觉—语言—动作模型（VLA）$\pi_{0.5}$ [5]、动态 VLA DynamicVLA [54] 与 PUMA [14]、WAM OpenWAM-α [49]，以及动态 WAM DynamicWAM [31]。每个基线保留官方架构与训练配方，并在相同示范上训练。为了单独考察目标运动输入的作用，$\pi_{0.5}$ 与 DynamicWAM 还以接收我们 SE(3) 历史 token 的形式运行（+SE(3)）。

表 1. **OnTimeBench 上的定量比较。**各方法在原生延迟、附加 150 ms 以及推理期间暂停世界三种设置下的 SR（%）。p95：在一块 RTX 5090 上的出动作时间。表中基线成功率来自单主视角评测。历史：携带过去运动信息的输入。off：关闭缓存与编译。每列的最佳与次佳已标出。

	历史			SR (%) ↑			
方法	RGB	光流	SE(3)	原生	+150 ms	暂停	p95 (ms) ↓
ACT [66]				41.6	24.6	40.6	**5.8**
DP [10]	✓			31.9	16.1	32.0	68.9
$\pi_{0.5}$ [5]				54.4	28.1	66.6	59.6
$\pi_{0.5}$+SE(3)			✓	58.7	28.0	76.0	61.2
DynamicVLA [54]	✓			51.1	23.5	54.9	97.3
PUMA [14]		✓		61.4	31.1	53.1	60.6
OpenWAM-α [49]				46.1	24.8	58.7	151.7
OpenWAM-α (off)				15.8	10.4	58.4	466.3
DynamicWAM [31]		✓		41.1	20.6	49.6	149.6
DynamicWAM+SE(3)		✓	✓	41.7	24.9	64.0	153.3
FoveaWAM			✓	**82.1**	**34.1**	**90.3**	15.1

模型与训练。 FoveaWAM 的 Transformer 共 12 层，宽度 1024，16 个注意力头，可训练参数 271.8M，建立在冻结的 MAE ViT-B/16 编码器之上。在 OnTimeBench 上，它从随机初始化开始，使用 AdamW 训练 10 轮（25,870 次更新）。推理采用编译后的 BF16 与 5 步 Euler。FoveaWAM 观测单帧主视角 RGB-D 与取自仿真器的目标 SE(3) 位姿历史。

5.2 动态操作结果

OnTimeBench 上的结果。 如表 1 所示，FoveaWAM 在原生延迟下的 SR 达到 82.1%，比最强基线 PUMA（61.4%）高 20.7 个百分点，并在全部三种设置下取得最高的 SR。它在 14 个任务中的 13 个上取得最高或并列最高的 SR（表 S4），在由运动容器或目标朝向决定成败的任务上优势最大：向平移容器和旋转容器放置分别高 30 和 55 个百分点，完整穿线高 28 个百分点。这一结果同时需要精确的目标运动和低延迟。获得相同的 SE(3) 历史后，$\pi_{0.5}$ 与 DynamicWAM 也只达到 58.7% 与 41.7%；唯一更快的方法 ACT 为 41.6%。

推理延迟的影响。 仅延迟一项就足以决定成败。OpenWAM-α 的两种部署运行同一个策略，暂停世界时结果一致（58.7% 与 58.4%）；但在原生延迟下，p95 为 151.7 ms 的部署为 46.1%，p95 为 466.3 ms 的部署为 15.8%。延迟还会削弱运动输入的价值：暂停世界时，SE(3) 历史使 $\pi_{0.5}$ 与 DynamicWAM 分别提高 9.4 和 14.4 个百分点，在原生延迟下只提高 4.3 和 0.6 个百分点。暂停评测因此高估了慢的策略，并排错了方法的次序：暂停世界时最强的基线 $\pi_{0.5}$+SE(3)（76.0%）在原生延迟下下降 17.3 个百分点，落到 PUMA 之后。FoveaWAM 在两种设置下均领先，并在每个附加延迟档位都是最好的方法（图 5）。附加 150 ms 后，所有方法都降到 35% 或以下，因为每个动作块剩余的指令必须覆盖更长的开环区间；FoveaWAM 仍然领先，但对 PUMA 的优势从 20.7 个百分点缩小到 3.0 个百分点。

DOMINO 上的结果。 为了在 OnTimeBench 之外评测 FoveaWAM，我们在 DOMINO [14] 的 24 个单臂 Franka 任务上，用其示范训练 FoveaWAM、$\pi_{0.5}$、DynamicWAM 与 PUMA，并用其原生评测器评测。

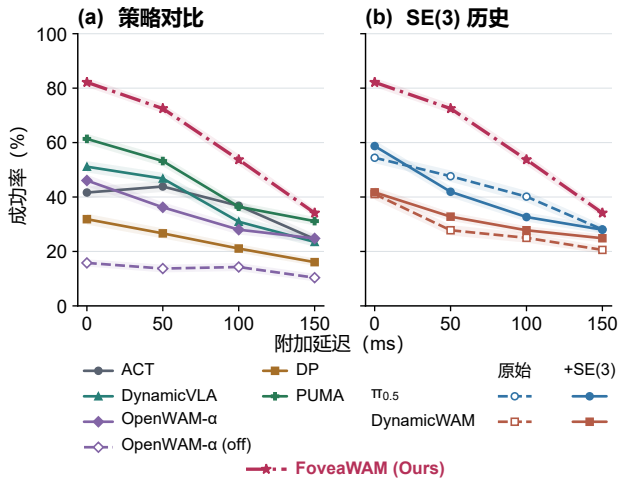


图 5. **附加延迟下的成功率。**在各方法原生延迟之上附加延迟时 OnTimeBench 上的 SR。(a) 全部方法；off 表示关闭缓存与编译。(b) 原始与 +SE(3) 版本。阴影：95% 区间。

表 2. **DOMINO [14] 上的定量比较。**其 24 个单臂任务（8 个拦截、16 个跟踪）上的 SR（%）。MS：操作得分。最佳与次佳已标出。

方法	拦截	跟踪	全部 ↑	MS ↑
$\pi_{0.5}$	23.8	8.1	13.3	27.8
DynamicWAM	16.8	31.9	26.9	41.4
PUMA	**36.3**	12.2	20.2	35.4
FoveaWAM	29.4	**55.5**	**46.8**	**62.0**

如表 2 所示，FoveaWAM 取得最高的总体 SR，为 46.8%，比最强基线 DynamicWAM（26.9%）高 19.9 个百分点，操作得分也最高。该评测器在推理期间暂停物理，因此这一领先反映的是角色化表示的质量，而不是它的速度。优势在 16 个跟踪任务上最大：FoveaWAM 为 55.5%，DynamicWAM 为 31.9%。

5.3 消融实验

我们在 OnTimeBench 上消融角色化设计的每个部分（表 3），报告原生延迟下的 SR，包括总体结果以及旋转敏感组（Rot.）和环境活跃组（Ctx.；表 S2）。除无目标历史外，所有变体只改变训练监督，因此延迟与 FoveaWAM 相同。

按角色预测的作用。 按角色的预测为目标提供了统一预测无法提供的精度。在相同密度下用统一场景流替代 SE(3) 轨迹，SR 总体下降 4.5 个百分点，在旋转敏感组上下降 8.6 个百分点。把统一场景流提高到 56×56 网格（点数为原来的 16 倍），可以恢复总体 SR（+0.8），但在旋转敏感组上仍低 3.4 个百分点，在环境活跃组上低 2.6 个百分点。改为移除稀疏场景流，SR 总体下降 4.2 个百分点，环境活跃组下降 3.9 个百分点，旋转敏感组下降 11.7 个百分点。可见两种预测相互补充：一条目标轨迹加 196 个流点，总体上与 3,136 个统一流点相当，在旋转和环境起作用的任务上更优。

目标运动历史的作用。 保留当前目标位姿而移除位姿历史后，SR 总体下降 19.6 个百分点，在旋转敏感组上下降 24.0 个百分点，是所有变体中最大的降幅。单个位姿无法表明目标如何运动；度量历史提供了指令必须预判的运动。

表 3. **OnTimeBench 上的消融结果。**FoveaWAM 的 SR（%）及各变体的变化（Δ，百分点；红色为下降，绿色为提升）。Rot./Ctx.：旋转敏感组与环境活跃组。

	SR，全部任务		任务组（原生）	
	原生	+150 ms	Rot.	Ctx.
FoveaWAM	**82.1**	**34.1**	**80.4**	**82.7**
精度分配				
统一粗粒度流	−4.5	−0.5	−8.6	−4.6
统一精细流	+0.8	−0.9	−3.4	−2.6
无场景流	−4.2	−1.4	−11.7	−3.9
目标运动历史				
无目标历史	−19.6	+0.2	−24.0	−2.3
未来监督				
无未来监督	−4.3	−3.4	−12.6	−2.1
无 $\mathcal{L}_{\text{aux}}$	−2.6	−1.9	−11.6	+0.1

未来监督的作用。 只监督目标的当前状态而不监督其未来，SR 总体下降 4.3 个百分点，在旋转敏感组上下降 12.6 个百分点，尽管预测头在部署时从不运行：预测通过它所塑造的表示起作用，而不是通过它的输出。移除辅助目标 $\mathcal{L}_{\text{aux}}$ 后，SR 总体下降 2.6 个百分点，在旋转敏感组上下降 11.6 个百分点。

5.4 真机评估

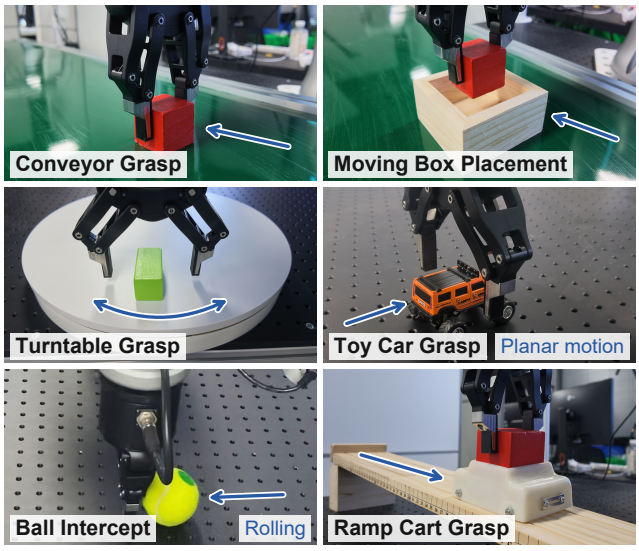


图 6. **真机任务。**箭头表示目标或移动盒在接触前的运动。

设置。 我们用一台配备 GN01 夹爪的 Flexiv Rizon 4s 机械臂在六个动态任务上评测（图 6 与表 S8）。所有方法都在同一套 600 条遥操作示范上训练，每个任务评测 20 次。FoveaWAM 从 DROID [22] 预训练基座出发，使用一台固定相机的 RGB-D 与在线估计的目标位姿。基线 $\pi_{0.5}$、ACT 和 DynamicWAM 使用固定相机和腕部相机的 RGB。

表 4. **真机结果。**每个任务 20 次试验的 SR（%）。p95：端到端出动作时间（ms）。每列最佳已标出。

方法	传送带抓取	移动盒放置	转盘抓取	玩具车抓取	网球拦截	斜坡抓取	All ↑	p95 (ms) ↓
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
ACT	—	—	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	37.5	—

结果。 如表 4 所示，FoveaWAM 在全部试验中的成功率为 37.5%，[最强基线] 为 [XX.X]%，优势最大的是 [任务]。包含跟踪在内，其 p95 延迟为 [XX] ms，[名称] 为 [XX] ms。[一个可由轨迹核实的接触实例：目标位姿、旋转或环境如何解释 FoveaWAM 的成功或基线的失败。]

6 结论

我们提出 FoveaWAM ，一个原生 4D 世界—动作模型，它面向动态操作的一个核心矛盾：预测运动中的场景需要时间，而这段时间又让场景运动得更远。FoveaWAM 按角色分配精度，用度量 SE(3) 轨迹表示目标，用稀疏 3D 流表示周围环境，用当前帧表示所有静态部分，因而在决定接触之处保持精确，并在 15.1 ms 内出动作。OnTimeBench 在各方法的原生延迟下评测每个策略；二者一起为构建和评测“及时行动”的策略提供了模型与基准。

LLM Usage Statement（大语言模型使用声明）

我们使用 OpenAI Codex 辅助文献调研、代码实现与调试、实验执行及论文语言润色。Codex 还用于辅助编写绘图代码，以及调整图表与论文排版。作者审阅了 AI 辅助生成或修改的内容，对照原始来源核查了参考文献，并通过测试与实验验证了实现。作者对最终稿件、实验结果和结论承担全部责任。

参考文献

[1] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[2] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. Wiley, 2001.

[3] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[4] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[5] Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *Proceedings of The 9th Conference on Robot Learning*, pages 17–40, 2025.

[6] Kevin Black, Manuel Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, pages 33383–33407, 2025.

[7] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, pages 173–180, 2017.

[8] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[9] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[10] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[11] Ian Chuang, Jinyu Zou, Andrew Lee, Dechen Gao, and Iman Soltani. Look, focus, act: Efficient and robust robot learning via human gaze and foveated vision transformers. In *IEEE International Conference on Robotics and Automation*, pages 18506–18513, 2026.

[12] Christine A. Curcio, Kenneth R. Sloan, Robert E. Kalina, and Anita E. Hendrickson. Human photoreceptor topography. *Journal of Comparative Neurology*, 292(4):497–523, 1990.

[13] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 15873–15879, 2025.

[14] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. In *European Conference on Computer Vision*, pages 314–333, 2026.

[15] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *IEEE Robotics and Automation Letters*, 11(3):2466–2473, 2026.

[16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[17] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[18] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20765–20779, 2026.

[19] Roland S. Johansson, Göran Westling, Anders Bäckström, and J. Randall Flanagan. Eye–hand coordination in object manipulation. *Journal of Neuroscience*, 21(17):6917–6932, 2001.

[20] Nikita Karaev, Iurii Makarov, Jianyuan Wang, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. CoTracker3: Simpler and better point tracking by pseudo-labelling real videos. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.

[21] Justin Kerr, Kush Hari, Ethan Weber, Chung Min Kim, Brent Yi, Tyler Bonnen, Ken Goldberg, and Angjoo Kanazawa. Eye, robot: Learning to look to act with a BC-RL perception-action loop. In *Proceedings of The 9th Conference on Robot Learning*, pages 3647–3664, 2025.

[22] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[23] Heecheol Kim, Yoshiyuki Ohmura, and Yasuo Kuniyoshi. Gaze-based dual resolution deep imitation learning for high-precision dexterous robot manipulation. *IEEE Robotics and Automation Letters*, 6(2):1630–1637, 2021.

[24] Michael F. Land and Peter McLeod. From eye movements to actions: How batsmen hit the ball. *Nature Neuroscience*, 3(12):1340–1345, 2000.

[25] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[26] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[27] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[28] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[29] Yuejiang Liu, Jubayer Hamid, Annie Xie, Yoonho Lee, Max Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, pages 4594–4627, 2025.

[30] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[31] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[32] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[33] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *Robotics Research: The 19th International Symposium ISRR*, pages 132–157. Springer, 2022.

[34] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[35] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, pages 28085–28128, 2025.

[36] Ruth Rosenholtz. Capabilities and limitations of peripheral vision. *Annual Review of Vision Science*, 2:437–457, 2016.

[37] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pages 785–799, 2023.

[38] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[39] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[40] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[41] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. In *European Conference on Computer Vision*, pages 437–453, 2026.

[42] Hans Strasburger, Ingo Rentschler, and Martin Jüttner. Peripheral vision and pattern recognition: A review. *Journal of Vision*, 11(5):13, 2011.

[43] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. In *Proceedings of the 43rd International Conference on Machine Learning*, pages 115917–115933, 2026.

[44] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. In *Conference on Robot Learning*, 2026. Accepted for publication.

[45] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[46] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, pages 92033–92052, 2025.

[47] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[48] Ruicheng Wang, Sicheng Xu, Yue Dong, Yu Deng, Jianfeng Xiang, Zelong Lv, Guangzhong Sun, Xin Tong, and Jiaolong Yang. MoGe-2: Accurate monocular geometry with metric scale and sharp details. In *Advances in Neural Information Processing Systems*, pages 35928–35959, 2025.

[49] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[50] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages

17868–17879, 2024.

[51] Bowen Wen, Matthew Trepte, Joseph Aribido, Jan Kautz, Orazio Gallo, and Stan Birchfield. FoundationStereo: Zero-shot stereo matching. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5249–5260, 2025.

[52] Chuan Wen, Xingyu Lin, John Ian Reyes So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[53] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, pages 10641–10662, 2024.

[54] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[55] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, pages 2475–2499, 2025.

[56] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[57] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[58] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2025.

[59] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[60] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[61] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. In *European Conference on Computer Vision*, pages 20–39, 2026.

[62] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[63] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[64] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[65] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[66] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[67] Ruijie Zheng, Jing Wang, Scott Reed, et al. FLARE: Robot learning with implicit world modeling. In *Proceedings of The 9th Conference on Robot Learning*, pages 3952–3971. PMLR, 2025.

[68] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world

models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[69] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

A 方法与训练细节

A.1 架构与训练

在 OnTimeBench 上，训练窗口包含 8 个连续的查询位置及各位置的因果历史（表 S1）。我们报告种子 0 训练的末次检查点。

表 S1. FoveaWAM 在 OnTimeBench 上的超参数与项目整体使用的训练集群。

参数	取值
模型	
输入图像	224 × 224 RGB-D，单视角
视觉编码器	MAE ViT-B/16，冻结
历史长度	8 步（350 ms）
预测时域	8 个（50 ms–400 ms）
摘要 token	16
层数	12
宽度	1024
注意力头	16
前馈宽度	4096
可训练参数	271.8M
动作	
动作维度	7
动作块长度	8
Euler 步数	5
每个查询的噪声采样数	8
训练	
优化器	Fused AdamW
Betas	(0.9, 0.999)
权重衰减	10^{-4}
学习率	2×10^{-4}
学习率调度	余弦，5,174 次预热更新
Batch 大小	512 个窗口
轮数	10（上限：20）
报告用检查点	第 25,870 次更新
梯度截断	0.1
$\lambda_F, \lambda_P, \lambda_R, \lambda_{\text{aux}}$	0.1
训练精度	BF16 计算、FP32 参数
训练集群	64 × RTX PRO 6000, 32 × H100

场景 token。 冻结的 MAE ViT-B/16 [16] 输出的每个 patch token 加上一个可学习的视角嵌入，以及其平均有效度量深度和其中心像素反投影后基座坐标系位置 $\mathbf{x}_i$ 的线性嵌入；中心像素没有有效深度的 patch 不加位置嵌入。只有 patch 的 query 与 key 使用由 $\mathbf{x}_i$ 驱动的 3D 旋转位置编码，同样的点也是稀疏 3D 流的源点。

状态 token。 8 个目标状态 token 在偏移 $-350, -300, \ldots, 0$ ms 处取样。每个都是 25 维描述子 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta t, \mathbf{v}, \boldsymbol{\omega}, \mathbf{a}, \boldsymbol{\alpha})$：槽位 0–6 描述相邻偏移之间的七个区间，速度与加速度由经过时间上的有限差分得到；槽位 7 存放基座坐标系下的当前位姿。每一维用训练统计量标准化，无效维置零，并附加三个有效性标志（位姿、区间与加速度）；没有任何有效特征的槽位在注意力中被掩码。机器人 token 包含相同偏移处的末端位置、旋转向量与夹爪开度，16 个可学习嵌入构成摘要 token。

预测头与损失。 除目标重建使用两层 MLP 外，每个预测头都是世界流最终状态上的一个线性层。位姿头读取摘要状态的均值（$\mathcal{L}_P$，式 3）。流头给出每个 patch 点在各时域的位移与可见性 logit（$\mathcal{L}_F$，式 2，尺度 $s = 0.715$ m，可见性权重为 1）；有效但不可见的点仍监督其位移。流标签由 patch 中心处渲染到

的表面点随其 MuJoCo 几何体的真值刚体运动得到；若未来点投影在图像内、落在同一几何体上，且深度差在 $\max(1\,\text{mm}, 0.001z)$ 以内，则视为可见。$\mathcal{L}_{\text{aux}}$ 由四项组成：未来度量深度（有效像素）、位移超过 1 mm 的表面的 RGB，以及经层归一化的 DINOv3 特征 [39] 上的平方误差，以及由摘要状态均值重建当前目标 RGB 区域的绝对误差。

动作流。 每个动作 token 嵌入一条七维指令：基座坐标系下的平移增量、左乘相对旋转向量与夹爪指令，均相对于施加时测得的末端位姿。查询 t 动作块的第 j 条指令标注为示范在 $\tau_t + j\Delta_a$ 下发的指令，因为 d_{task} 只在执行时起作用（式 (S1)）；指令在训练集上标准化。部署时，夹爪指令只有超出死区时才切换状态：小球捕获为 0.5，其余任务（含小球捕获（桌面））均为 0.1。

A.2 DROID 预训练与微调

真机基座在 DROID [22]（15 Hz）上训练，使用第一台外部相机及其深度，以及 PointWorld [18] 发布的 3D 点轨迹与标定。可用的 42,087 个回合给出 598,889 个锚定窗口，其中 60,149 个用于验证；与 OnTimeBench 相同，每个锚点扩展为 8 个查询位置，只有锚点带有流与 DINOv3 标签。每个 patch 跟随一条从其内部出发的 PointWorld 轨迹，优先选择运动最大且一致的一条，以覆盖小的运动物体；47% 的点—时域槽位带有标签。

DROID 没有物体位姿，因此基座省去目标状态 token 和位姿头。动作、稀疏 3D 流和未来 DINOv3 特征损失的权重依次为 1、0.1 和 0.1。流损失没有可见性项。预训练采用 AdamW，全局 batch 为 512，预算上限为 20 轮（21,060 次优化器更新）。主干采用 FP32，冻结的视觉编码器采用 BF16。

每个真机策略从 DROID 预训练基座出发，在该任务的示范上微调，并重新初始化目标状态 token 和新增预测头。每个任务的微调预算为 20,000 次优化器更新，全局 batch 为 32。AdamW 预热 500 步后采用余弦衰减，12 层和 24 层基座的峰值学习率分别为 3×10^{-5} 和 2×10^{-5}。

A.3 图示说明

图 1(a) 中的真机场景由 RGB 经 MoGe-2 [48] 重建，叠加的 SE(3) 未来位姿与稀疏 3D 流为示意。图 2 的叠加内容来自同一个 OnTimeBench 录制场景：位移不超过 2 mm 的流采样点画作圆点，目标坐标轴画在 0 与 400 ms。图 3 中的缩略图是同一段实录的 Blender 渲染，稀疏流为便于观察而放大；token 数量、层叠和动作图标均为示意。图 4(c) 渲染自专家轨迹，并叠加目标的历史位姿与运动标记。

B OnTimeBench 与评测协议

B.1 基准设计

任务在 MuJoCo 3.11.0 与 robosuite 1.5.2 [47, 69] 中运行，使用 Franka Panda 机械臂与平行夹爪，由 robosuite 的操作空间位姿控制器驱动，控制周期 50 ms，物理步长 2 ms。一台固定的第三人称相机，垂直视场角 40°，渲染 224×224 的 RGB-D 图像。动作是基座坐标系下末端的平移与旋转向量增量，加一条夹爪指令，按每个平移轴 0.10 m、每个旋转分量 0.5 rad 截断。表 S2 列出全部十四个任务。

B.2 场景、示范与数据划分

每个场景在各任务的范围内均匀采样目标的初始状态与运动参数。表 S2 汇总了目标运动。其他采样参数包括至多 35 mm、0.25–0.7 Hz 的谐波振幅、至多 1.2 rad/s 的偏航角速度，以及 5–15° 的斜坡坡度。遮挡场景中，目标被遮挡 0.5–3.0 s 后重新出现。只保留物理上可行的场景，评测时回放存储的场景。

专家是针对各任务的闭环状态机，使用仿真特权状态，并预判目标的运动，例如在捕获任务中预测截获点。只有专家成功、回放其动作能重现该回合、且路径与 jerk 通过质量检查的示范才被保留。训

表 S2. **OnTimeBench 的十四项任务。**目标是策略接收其位姿的物体（第 3.1 节）。放置任务的目标为容器。穿越任务的目标为导线入口，导线其余部分为环境。运动栏给出平移速度（m/s）或导线角速度（度/秒）。每项捕获任务使用 100 条留出场景的固定机器人参考轨迹，以首次记录离坡前后相邻两帧的位移除以 50 ms，估计速度并取范围。抓取要求双侧指垫接触、抬升至少 0.05 m 并连续保持 0.5 s。发生不安全接触、离开工作空间、掉落或达到时限时，回合失败。任务组（表 3）中的 R 表示目标在领先时长内旋转且朝向影响接触的任务。C 表示存在障碍间隙约束或传送带、斜坡、撞击器等驱动物的任务。

任务	代号	目标	运动范围	成功条件	时限（s）	任务组
谐波抓取	`grasp`	物块	0.03–0.20	抓取	8	R
传送带抓取	`t1_belt`	零件	0.04–0.10	抓取	8	C
平移抓取	`t1_xyz`	零件	0.04–0.15	抓取	8	–
旋转抓取	`t1_so3`	零件	0.04–0.15	抓取	8	R
遮挡抓取	`t1_occ`	零件	0.04–0.10	抓取，不接触遮挡罩	8	C
移动容器	`t2_trans`	容器	0.03–0.06	所持物体静止于容器内	10	–
旋转容器	`t2_se3`	T 形容器	0.03–0.06	所持 T 形件静止于容器内	10	R
导线穿越	`t3_phase`	导线入口	2.5–7.5°/s	30 mm 内对准，无接触穿过	21	R, C
完整导线穿越	`t3_full`	导线入口	2.5–7.5°/s	抓杆、穿过、离开、释放	32	R, C
小球捕获	`t4_sphere`	小球	0.67–1.14	触及托盘前抓取	6	C
桌面小球捕获	`t4_sphere_tabletop`	小球	0.59–1.03	滚动中抓取	6	C
滑块捕获	`t4_slider`	滑块	0.55–1.12	滑动中抓取	6	C
罐体捕获	`t4_can`	罐体	0.59–0.97	倾倒前抓取	6	R, C
撞击后抓取	`t5_replan`	零件	0.12–0.14	沿抓取轴抓取	6	R, C

练池包含 11,200 条示范（每个任务 800 条），以 20 Hz 记录 RGB-D、机器人状态、指令与仿真真值，另有 350 个回合构成验证集；策略只接收第 3 节的输入。

我们在 1,400 个开发场景（每个任务 100 个）上选择配置，并在 1,400 个留出场景上报告全部 OnTimeBench 结果；留出场景以相同的范围生成，所用种子不出现在任何训练、验证或开发回合中，所有方法共用这些场景。

B.3 实时评测与指标

执行器。 所有方法在 50 ms 控制时钟上共用一个执行器。第 t 次查询的第 j 条指令对应时刻 $\tau_t + j\Delta_a$，其执行时刻（第 3.1 节）为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\mathrm{task}}, \tag{S1}$$

其中撞击后抓取在下发每条指令 50 ms 后才施加，$d_{\mathrm{task}} = 50$ ms；其余任务 $d_{\mathrm{task}} = 0$。与 RTC [6] 相同，延迟按整数个控制周期计：总延迟为 L_t 的查询在其结束时或之后的第一个周期边界交出动作块，即采集后 $k_t = \lceil L_t/\Delta_a \rceil$ 个周期，执行从对应该边界的第 k_t 条指令继续。策略随即重新观测并开始下一次查询，其间上一个动作块继续执行，因此策略以其延迟允许的频率重新规划。动作块包含该方法原生的 H_m 条指令（表 S3），$k_t \geq H_m$ 时整体丢弃。在第一个动作块到达之前及动作块耗尽时，控制器保持当前的手臂目标与夹爪指令，不重复执行任何指令。执行器以异步方式运行，与 DynamicVLA 的流式执行相同；包括 FoveaWAM 在内，没有任何方法像 RTC 那样在动作块之间做补全。

协议。 在实时协议下，每次查询期间物理按该方法的延迟推进，延迟每次查询从其在一块 RTX 5090 上实测的分布中抽取，rollout 本身在 RTX PRO 6000 上运行。在暂停协议下，推理不占用物理时间，策略每 50 ms 重新规划；这去掉了推理等待，但也提高了反馈频率，因此它是参照而非性能上界。延迟扫描在实时协议下于推理之后附加 0 至 200 ms，步长 50 ms。

延迟测量。 我们在一块 RTX 5090 上独占运行，以 batch 1 为每个方法计时，基线采用发布版本的精度，FoveaWAM 采用 BF16 编译推理：三轮，每轮 30 次预热与 300 次测量调用，使用录制观测及所需的因果历史。一次计时查询从最新观测开始，到第一条指令可用时结束，包含所有需要最新帧的计算，例如预处理、图像编码、PUMA 与 DynamicWAM 的在线光流与运动描述子、采样与动作解码，在真机上还包括跟踪。PUMA 按其官方三相机输入计时，其他基线按双相机计时。FoveaWAM 运行 5 步 Euler

并关闭 TF32；编译和在录制观测上的热身在物理开始前完成，随后重置历史与推理种子。FoveaWAM 的预测头在部署时跳过，不计入出动作时间。出动作时间超过 50 ms 的查询称为超时；一条指令的动作年龄是其执行时刻减去采集时刻。附录 C.2 报告实测值。

指标。 SR 对 14 个任务等权平均。首次接触时的位置误差 e_p 是末端到专家在目标上的接触坐标系的距离；放置任务开始时物体已被抓住，因此使用所持物体与容器的接触及专家的放置位姿。e_p 在有接触的 13 个任务（不含 `t3_phase`）及发生接触的回合上平均；没有接触的失败仍计入 SR 的分母。配对 95% 区间在每个任务内、跨方法联合地对留出场景做自助法。

B.4 基线

表 S3. **基线训练。**训练量以优化器更新次数和全局 batch 大小表示。H 为每次查询返回的指令数。参数量只计入可训练参数。DOM 检查点指 DynamicVLA 发布的、在 DOM 上训练的检查点。

方法	初始化	更新数 ×batch	H	参数量
ACT [66]	从头训练	50,000 × 32	100	83.9M
DP [10]	从头训练	50,000 × 32	15	288.7M
$\pi_{0.5}$ [5]	`pi05_base`	30,000 × 256	10	3,353.4M
$\pi_{0.5}$+SE(3)	`pi05_base`	30,000 × 256	10	3,357.7M
DynamicVLA [54]	DOM 检查点	50,000 × 44	20	99.1M
PUMA [14]	官方	40,000 × 64	16	4,516.5M
OpenWAM-α [49]	官方	34,490 × 192	32	6,021.2M
DynamicWAM [31]	官方	40,000 × 128	16	988.8M
DynamicWAM+SE(3)	官方	40,000 × 128	16	989.4M
FoveaWAM	从头训练	25,870 × 512	8	271.8M

共同条件。 每个基线保留其官方架构、动作块长度、初始化与训练配方（表 S3），在相同的 11,200 条示范上训练（指令通过同一个笛卡尔控制器映射到其动作空间），配置在开发场景上选择。rollout 使用各基线训练时的主视角（腕部槽位被屏蔽）及表 1 所列历史；在两种方式都计时的七个配置中，屏蔽腕部视角使 p95 延迟至多改变 3.8 ms。DP 使用作者真机配方的 16 步 DDIM 采样器；OpenWAM-α 关闭视频解码运行，并分别在开启与关闭官方缓存和编译时计时。

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.1 的八个目标状态 token，带有相同的有效标志。一个输出层零初始化的两层 MLP 把它们映射到模型宽度；对 $\pi_{0.5}$，它们接在前缀中的图像 token 之后，由动作专家读取；对 DynamicWAM，它们并入其运动学描述。训练沿用基础模型的配方。

C 补充仿真结果

C.1 各任务结果

表 S4. **OnTimeBench 各任务的留出成功率**（%），涵盖表 1 的全部方法，采用 Native 实时协议：各方法实测推理延迟加**额外 +0 ms**，推理期间物理持续推进；每任务 100 个配对场景。FoveaWAM 使用编译 BF16 版 C（p95 为 15.1 ms）。DP：Diffusion Policy。DVLA：DynamicVLA。OWAM：官方缓存与编译的 OpenWAM-α；OW-off：关闭两者。DWAM：DynamicWAM。+：本文 SE(3) 历史 token。Δ 为 FoveaWAM 减去该任务最强其他方法；并列时按表中顺序选择。任务等权行与整体最强基线 PUMA 比较。括号为以所选对照与检查点为条件的逐项 95% 配对场景 bootstrap 区间（100,000 次重采样，不校正选择偏差）。末两行为首次接触位置误差 e_p（mm，13 个接触任务等权平均）与发生接触的回合数 n（附录 B.3）；–：无完整 13 任务均值。Δ 底色蓝色表示较高 SR、橙色表示较低，在 15 个百分点处饱和。粗体蓝底与浅蓝底标出显示值的最佳与次佳。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	OWAM	OW-off	DWAM	DWAM+	本文	Δ [95% CI]
谐波抓取	49.0	31.0	51.0	84.0	39.0	85.0	41.0	1.0	50.0	47.0	**99.0**	+14.0 [7.0, 22.0]
传送带抓取	45.0	45.0	96.0	62.0	89.0	89.0	62.0	0.0	59.0	60.0	**100.0**	+4.0 [1.0, 8.0]
平移抓取	14.0	33.0	59.0	42.0	61.0	51.0	53.0	0.0	53.0	18.0	**77.0**	+16.0 [4.0, 28.0]
旋转抓取	24.0	20.0	32.0	53.0	26.0	67.0	42.0	3.0	30.0	35.0	**71.0**	+4.0 [-8.0, 16.0]
遮挡抓取	30.0	28.0	37.0	60.0	80.0	84.0	34.0	0.0	44.0	38.0	**100.0**	+16.0 [9.0, 23.0]
移动容器	26.0	24.0	34.0	63.0	41.0	24.0	27.0	0.0	8.0	6.0	**93.0**	+30.0 [21.0, 40.0]
旋转容器	0.0	0.0	1.0	11.0	1.0	0.0	0.0	0.0	0.0	0.0	**66.0**	+55.0 [45.0, 65.0]
导线穿越	99.0	99.0	**100.0**	89.0	99.0	87.0	50.0	58.0	23.0	78.0	**100.0**	+0.0 [0.0, 0.0]
导线穿越（完整）	0.0	3.0	1.0	0.0	12.0	0.0	0.0	0.0	0.0	0.0	**40.0**	+28.0 [16.0, 40.0]
小球捕获	36.0	16.0	**46.0**	29.0	41.0	39.0	45.0	13.0	24.0	20.0	38.0	-8.0 [-18.0, 2.0]
小球捕获（桌面）	71.0	81.0	**100.0**	**100.0**	88.0	**100.0**	99.0	88.0	98.0	**100.0**	**100.0**	+0.0 [0.0, 0.0]
滑块捕获	56.0	30.0	58.0	62.0	28.0	76.0	71.0	31.0	47.0	63.0	**79.0**	+3.0 [-5.0, 12.0]
罐体捕获	91.0	31.0	98.0	99.0	72.0	**100.0**	**100.0**	5.0	96.0	**100.0**	**100.0**	+0.0 [0.0, 0.0]
撞击后抓取	42.0	5.0	49.0	68.0	39.0	57.0	21.0	22.0	43.0	19.0	**87.0**	+19.0 [7.0, 31.0]
任务等权	41.6	31.9	54.4	58.7	51.1	61.4	46.1	15.8	41.1	41.7	**82.1**	+20.8 [18.4, 23.1]
e_p (mm)	32.2	36.1	31.3	34.8	30.0	27.2	31.8	–	31.2	36.1	**22.0**	–
n	1110	946	1237	1191	1204	1272	1115	493	1193	1029	1285	–

表 S4 使用额外 +0 ms 延迟的 Native 实时协议。FoveaWAM 在移动容器放置与旋转容器放置上的成功率分别为 93% 和 66%，$\pi_{0.5}$+SE(3) 分别为 63% 和 11%。在完整导线穿越上，FoveaWAM 为 40%，DynamicVLA 为 12%。FoveaWAM 在相位导线穿越、桌面小球捕获和罐体捕获上与最强基线并列。其记录最多的失败类别为边缘冲量超限（1,400 场中的 160 场）和导线接触（55 场）。

C.2 时延

表 S5 列出十一配置在五个附加延迟条件下的全部结果；图 5 绘制 0 至 150 ms 的各点。在 +200 ms 时，FoveaWAM 的 8 条指令动作块与 $\pi_{0.5}$ 的 10 条指令动作块已无法覆盖到下一个动作块到达为止的间隔：分别只剩三条和四条指令可用于五个和六个控制周期，其间控制器保持上一个目标。因此该列衡量的是动作块长度，而不是对延迟的响应。

表 S5. **成功率随附加延迟的变化**：每点使用 1,400 个 OnTimeBench 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的原生与 +150 ms 列。粗体加蓝底与浅蓝底分别标记各列最佳与次佳。

	附加延迟（ms）				
方法	0	50	100	150	200
ACT	41.6	43.9	36.8	24.6	16.6
Diffusion Policy	31.9	26.6	21.1	16.1	14.4
$\pi_{0.5}$	54.4	47.6	40.1	28.1	13.6
$\pi_{0.5}$ + SE(3)	58.7	41.9	32.6	28.0	14.9
DynamicVLA	51.1	46.8	30.9	23.5	18.0
PUMA	61.4	53.2	36.4	31.1	**27.2**
OpenWAM-α	46.1	36.2	28.0	24.8	22.1
OpenWAM-α (off)	15.8	13.7	14.3	10.4	9.5
DynamicWAM	41.1	27.8	25.0	20.6	21.0
DynamicWAM + SE(3)	41.7	32.8	27.8	24.9	22.9
FoveaWAM	**82.1**	**72.5**	**53.7**	**34.1**	12.8

计时。 表 S6 分阶段报告第 20,696 步开发检查点的单次查询回放计时。

表 S6. **单次查询的延迟分解**（BF16 编译版 FoveaWAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。策略合计来自 900 次实测查询，不含位姿跟踪；品红色破折号表示待测。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
观测编码与 H2D 传输	4.83	5.28
世界流（每次查询一次）	3.93	4.22
动作流（5 个 Euler 步）	4.27	4.41
策略出动作时间（合计）	14.66	15.65
仅训练读出（供参考）	0.37	0.41
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

C.3 DOMINO 上的结果

我们使用 DOMINO [14] clean 一级设置的 24 个单臂 Franka 任务及其示范、场景与原生评测器。操作得分（MS）用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度。FoveaWAM 从仿真器读取指令所指目标的位姿真值，并屏蔽没有有效位姿的槽位（附录 A.1）。基于 RGB 的基线不接收这一位姿。

数据与适配。 数据划分包含 1,200 条训练与 240 条验证示范。各策略通过 DOMINO 原生控制器执行绝对关节位置目标，状态与动作投影适配其八维关节空间，归一化统计由训练数据计算。DynamicWAM 的官方采样器跳过过短的示范，因此使用 1,054 条训练与 210 条验证示范，有两个任务没有可用示范。测试集仍包含全部 24 个任务。DynamicWAM 以全局 batch 128 训练 40,000 次更新。$\pi_{0.5}$ 从官方基座出发，以全局 batch 256 训练 30,000 次更新，评测使用最终 EMA。PUMA 保留发布的权重与冻结的 teacher，以全局 batch 64 训练，按验证集动作 MSE 选定第 6,000 步权重。

FoveaWAM 的开发配置从零训练，全局 batch 为 512，在第 1,575 次更新后停止。验证损失最低的检查点是第 1,365 步，开发场景上的闭环比较选定每次查询执行 3 个动作。

C.4 消融对照

第 5.3 节的六个对照（表 3）共用数据、训练配方和执行器，均使用各自的末次检查点评测。去掉一项损失时同时去掉其预测头。无目标历史对照去掉槽位 0–6，保留存放当前位姿的槽位 7（附录 A.1）。统一精细流对照去掉 $\mathcal{L}_P$ 与位姿头，在每个 patch 内的 4×4 个点上监督场景流，组成 56×56 网格，标签来自同样的真值刚体运动。表 S7 给出各对照在三种设置（含暂停物理）下的结果。

表 S7. **三种设置下的消融对照。**FoveaWAM 在 OnTimeBench 留出场景上按任务等权的 SR（%），以及各对照的变化（Δ，百分点）。原生、+150 ms、Rot. 与 Ctx. 各列与表 3 相同；暂停列为暂停物理协议下的结果。红色表示下降，绿色表示提升，深浅按列缩放。Rot./Ctx.：旋转敏感组与环境活跃组（表 S2）。

	SR，全部任务			任务组（原生）	
	暂停	原生	+150 ms	Rot.	Ctx.
FoveaWAM	**90.3**	**82.1**	**34.1**	**80.4**	**82.7**
精度分配					
统一粗粒度流	+4.4	−4.5	−0.5	−8.6	−4.6
统一精细流	+1.3	+0.8	−0.9	−3.4	−2.6
无场景流	+3.1	−4.2	−1.4	−11.7	−3.9
目标运动历史					
无目标历史	−19.5	−19.6	+0.2	−24.0	−2.3
未来监督					
无未来监督	+0.2	−4.3	−3.4	−12.6	−2.1
无 $\mathcal{L}_{\text{aux}}$	−3.8	−2.6	−1.9	−11.6	+0.1

D 真机实验

D.1 平台与任务

机器人为一台配备 GN01 夹爪的 Flexiv Rizon 4s 机械臂。策略以 20 Hz 下发工具中心点的绝对笛卡尔位姿与夹爪目标。采集示范时，以 100 Hz 记录机器人控制数据。平台配有两台 RealSense D435，分别安装在固定支架和腕部，均以 640 × 480、60 Hz 采集 RGB。我们用 ChArUco 标定板求固定相机到机器人基座的变换。正式评测计划为 FoveaWAM 提供固定相机的 RGB-D 帧及该视角估计的目标位姿，为基线提供两台相机的 RGB。各任务装置轮流安装在这一平台上（图 6；表 S8）。

表 S8. **真机任务。**稳定夹住目标并将其抬离支撑面即为抓取成功。所有任务的试次时限均为 30 s。

任务	目标运动	成功判据
传送带抓取	方块随传送带移动	抓取
移动盒放置	无盖盒随传送带移动	方块留在盒内
转盘抓取	长方块随转盘运动	沿短边抓取
玩具车抓取	玩具车在桌面上移动	抓取
网球拦截	网球滚动，初速度大小和起始方向偏移随机化	夹爪使球停下或转向
斜坡小车抓取	斜坡小车载着方块移动	抓取

D.2 位姿跟踪与标签

离线标签。 我们对固定相机的录像离线标注。Grounding DINO [28] 与 SAM 2.1 [35] 生成目标掩码，FoundationPose [50] 利用 FoundationStereo [51] 深度和米制物体网格做正反向跟踪。我们核对两向跟踪的一致性，并用工具中心点的运动学补齐刚性夹持时受遮挡的帧。位姿标签保留 595 条示范，其中 97.1% 的帧有有效目标位姿。网球只标注平移。稀疏场景流将 CoTracker3 [20] 的点轨迹与双目深度结合，映射到机器人基座坐标系。我们对有效观测插值，取得 50–400 ms 各预测时域的监督。

在线位姿估计。 我们从固定相机的对齐 RGB-D 帧估计目标位姿，并用相机外参将其转换到机器人基座坐标系。策略以 20 Hz 采样位姿估计，构建目标状态历史。

D.3 训练与评测协议

共享数据集含 600 条遥操作示范，其中转盘抓取 101 条、网球拦截 99 条，其余任务各 100 条。ACT 为每个任务单独训练 50,000 步。DynamicWAM 在六个任务上联合微调 20,000 步。其部署配置采用 16

步异步动作块，旧队列还剩 4 步（200 ms）时查询新动作块，并融合重叠动作。FoveaWAM 的微调见附录 A.2。

试次按任务和方法分组，每组 20 次。操作员在每轮开始前重置场景，并在结束后记录结果。超时、人工干预和安全中止均计为失败。表 S6 给出真机计时。

D.4 结果与失败分析

表 S9. **真机成功率及其区间。**合并各方法的试次后计算成功率（%）和 95% Wilson 区间。逐任务成功率见表 4。

方法	All [95% CI]
$\pi_{0.5}$	—
DynamicWAM	—
ACT	—
FoveaWAM	—

图占位：真机失败

(a) 失败类别。每个方法用一根堆叠条显示各类失败次数。**(b) 代表性试次。**展示未经修饰的固定视角画面，标出决定结果的事件。

图 S1. **真机失败。**(a) 各方法按类别统计的失败次数。(b) 代表性试次的画面。[所示试次的任务、方法和结果。]

表 S9 给出合并成功率及其区间。图 S1 按可观察事件归类失败，包括抓取过晚或未对准、滑落或掉落、碰撞或安全中止、超时，以及目标跟踪丢失。[各方法的主要失败类型和判断时序误差的依据。]