FoveaWAM：面向动态操作的角色感知 4D 世界—动作建模

中文审读稿

摘要

操作运动物体时，动作必须适合它执行那一刻的场景，而不是图像采集时的场景；然而推断场景运动多花的每一毫秒，都会让目标走得更远。世界—动作模型以统一的精细程度预测未来图像或隐变量，把时间花在外观上，却让目标的度量位姿停留在隐式；以目标为中心的预测器速度快，却忽略了约束或推动其运动的周围环境。我们观察到，动态场景的不同部分所需的精度并不相同：目标的位姿决定接触，误差须在毫米以内；周围物体只通过它们留下的间隙和传给目标的运动起作用；其余背景则与任务无关。我们提出 FoveaWAM，一个建立在这种按角色区分精度的 4D 结构之上的世界—动作模型。它把目标的运动编码为度量的 SE(3) 位姿历史，因此只需一帧 RGB-D 作为输入。它学习精确预测目标未来的 SE(3) 轨迹、以稀疏 3D 流粗略预测整个场景，这些预测只在训练中使用。这些设计合在一起，使 FoveaWAM 在一块 RTX 5090 上 [XX] ms 即可输出动作，比视频世界—动作基线快 [N] 倍。我们还提出开源基准 ConMoto，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动。FoveaWAM 在 ConMoto 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点；在目标运动形式多样的六个真机任务上为 [XX]%。

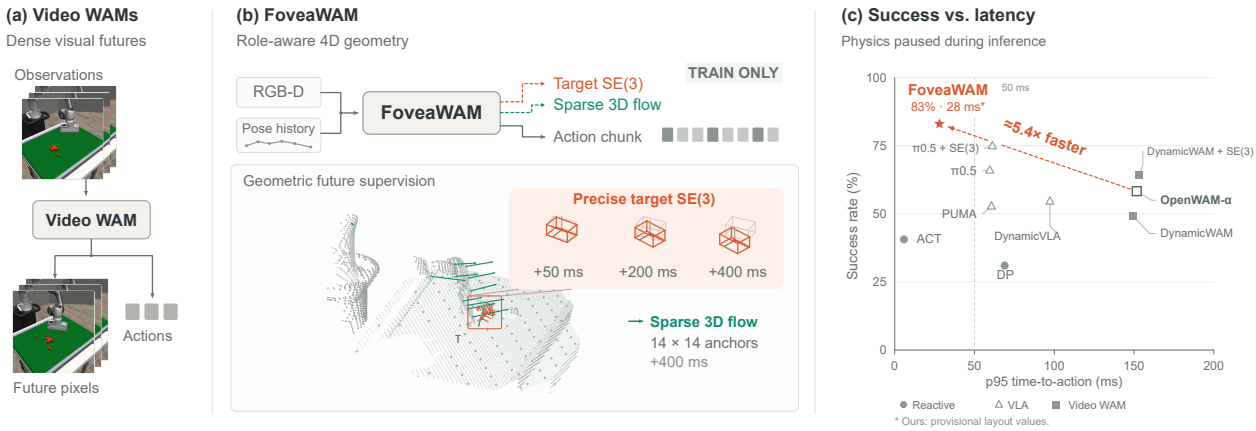


图 1. **FoveaWAM 按任务角色分配预测精度。**(a) 用参考录制展示稠密视频未来预测及动作输出的表示形式。(b) FoveaWAM 以一帧 RGB-D 和位姿历史为条件。目标 SE(3) 与稀疏 3D 流只用于训练监督，部署时输出动作块。裁切点云展示当前参考几何；未来位姿与流均为真实监督标签，并非模型预测。流在14 × 14 网格上采样；箭头表示放大 3× 的 400 ms 位移。位姿字形展示 +50、+200 和 +400 ms 时的目标。(c) 表 1 的 Paused 成功率（推理期间暂停物理）与原生 p95 出动作时间。虚线标记 50 ms。FoveaWAM 星形点（83%、28 ms）及相对 OpenWAM-α（151.7 ms）的 $\approx 5.4\times$ 加速均为排版占位，尚待实测。

1 引言

基于学习的机器人操作进展迅速，从扩散策略到视觉—语言—动作（VLA）模型与世界—动作模型（WAM）[5, 6, 12, 20, 42, 48, 62]；但这些进展大多假设，除非机器人去移动物体，物体都保持静止。在工厂、厨房与人机交接中，机器人感知、计算和执行的同时，物体一直在运动。在这样的场景中，动作必须适合它执行那一刻的场景，而不是观测采集那一刻的场景，因此策略必须知道场景如何运动。这

种认识本身需要推断，而推断需要时间，这段时间里场景仍在运动：策略为预判运动计算得越久，需要预判得就越远。

近期的动态策略加入了对过去运动的记忆（通常是光流等图像空间线索 [14, 27]）和对未来的预测 [27, 38, 55]。基于视频的 WAM 以统一的精细程度预测完整的未来帧或隐变量，把大量计算花在视觉细节上 [42, 48]。紧凑的未来编码 [28] 降低了这一开销，度量 3D 场景动力学 [53] 引入了几何，但两者仍对整个场景一视同仁。无论哪种情况，决定接触的量——动作执行时刻目标的度量位姿——仍然是隐式的。以目标为中心的预测器和预测物体层面未来的动态 VLA 位于另一端 [14, 17]：它们速度快，但只预判目标，把可能阻挡或改变其运动的周围环境排除在外。两类方法都没有按接触对场景各部分的要求来分配精度。由此引出一个核心问题：为了完成接触并保持较低的推理延迟，策略需要知道运动场景的哪些信息，又需要知道得多精确？

我们的关键观察是：动态策略需要精确知道的东西其实很少（图 1）。接触要求目标在动作执行时刻的位姿达到毫米级精度；周围物体只通过它们留下的间隙和传给目标的运动起作用，因此只需粗略地知道。基于这一观察，我们提出 FoveaWAM，一个学习按角色区分精度的度量 4D 表示的世界—动作模型，在接触需要之处保持精确（图 2）。为了在不编码过去图像帧的情况下获得运动信息，FoveaWAM 把单帧 RGB-D 与目标度量 SE(3) 位姿的一段短历史配对。世界流通过预测目标未来的 SE(3) 轨迹，以及以稀疏 3D 流表示的整个场景的运动，来学习这一表示。动作流读取世界流的场景 token 与摘要 token 来生成动作块，显式预测只在训练中进行 [52]。因此，FoveaWAM 把对目标运动的精确预判与较低的推理延迟结合起来，限制了从观测到动作之间场景的变化。

我们构建了开源基准 ConMoto，它包含 14 个仿真动态操作任务，场景在每个策略推理的全过程中持续运动，因此每个方法都要为自己的延迟付出代价。FoveaWAM 在 ConMoto 上的成功率为 [XX.X]%，比最强基线高 [XX.X] 个百分点，p95 延迟为 [XX] ms，比视频世界—动作基线低 [N] 倍。它在 24 个 DOMINO 任务 [14] 上同样领先，在六个真机任务上的试验成功率为 [XX]%，最强基线为 [XX]%。受控消融检验目标运动历史与未来监督的贡献，并比较按角色区分精度与统一精度的预测，以考察精度的分配。

我们的贡献有三点：

- 我们表明，动态策略只在动作执行时刻目标的位姿上需要毫米级精度，并把这一原理实例化为按角色区分精度的 4D 建模：为目标建立精确的度量 SE(3) 轨迹，为整个场景建立粗略的稀疏 3D 流。
- 我们提出 FoveaWAM，一个把目标的度量位姿历史与按角色区分精度的预测监督相结合、以低延迟生成动作的世界—动作模型。
- 我们提出开源动态操作基准 ConMoto，它为每个策略计入其自身的推理延迟；FoveaWAM 在 ConMoto、24 个 DOMINO 任务和六个真机任务上均优于强基线。

2 相关工作

动态操作。 补偿感知与执行之间的时间差是一个经典问题，从带纯滞后的控制 [35]，到用卡尔曼类滤波器跟踪目标并规划拦截的抓取系统 [1–3, 30]；这些系统精确，但针对每种物体和任务专门设计。近来，学习型策略开始进入运动场景 [46]。PUMA 读取历史光流，并以未来物体特征作为监督 [14]；DynamicWAM 以光流和运动学描述子为 WAM 提供条件，并以实时分块方式执行 [27]。两者都从图像空间线索中推断过去的运动，而 FoveaWAM 以目标的度量 SE(3) 位姿历史为输入，只观测当前一帧 RGB-D。另一些动态策略预测显著 token [38]、未来图像 [56]、紧凑的未来编码 [28] 或 3D 场景动力学 [53]，并在测试时以这些预测为条件生成动作。DynaWM 针对动态操作调整基础 VLA 的动作块 [10]，

DynamicManip 从单条静态示范合成动态示范 [22]。执行调度方案通过让推理与执行重叠 [33, 46]、保持相邻动作块一致 [7, 25]，或以执行时刻为条件 [39]，来减小或掩盖延迟。它们决定的是动作何时计算、何时执行，而不是策略表示什么。DOMINO [14] 与 PhysMani-Bench [53] 提供了多样的动态操作任务，但它们公开的默认评测流程只在策略返回预测之后才推进仿真。ConMoto 则在推理期间推进场景，并让每个方法承担其实测延迟。

WAM 中的预测监督。 世界—动作模型（WAM）在同一个网络中生成未来视频与动作 [21, 42, 48, 60]，其基础是把视频预测作为策略目标 [40, 45]。由于生成视频代价高，近期工作改变了预测的内容，例如动态区域、深度与语义特征 [55]，与 RGB 并列的光流和几何 [51]，物体掩码或物体槽 [26, 49]，以及紧凑隐变量 [37, 59]；它们也在追问测试时是否需要预测。Fast-WAM 在不做测试时想象的情况下保留了视频建模的大部分收益 [52]，PUMA 与 SG-WAM 则在训练后去掉预测器 [14, 57]。FoveaWAM 沿用这种只在训练中使用预测的方式，但主要预测的是度量 4D 状态，而不是像素、特征或隐变量，因此目标未来的位姿得到显式监督，而不是停留在隐式。

以物体为中心与基于几何的运动表示。 度量 3D 输入使策略更精确、样本效率更高 [32, 54]。运动已被表示为 2D 点轨迹 [4, 44, 47]、3D 流 [15, 18, 50, 53]，以及物体关键点或 SE(3) 轨迹 [17, 29, 36]；刚体分解也早已用于学习场景动力学 [8, 9]。这些工作用同一种表示描述场景：要么处处是稠密的流或轨迹，要么每个物体一个位姿。以目标为中心的预测器（包括预测物体层面未来的动态 VLA）只建模目标的未来 [14, 17]，把阻挡或推动目标的物体排除在外。DOCIR 把机器人、目标与障碍物分开，但只把这种区分用作输入编码 [13]。FoveaWAM 按角色分配精度：粗粒度的稀疏 3D 流描述整个场景，接触依赖毫米级精度的目标另由其 SE(3) 历史与预测描述。

3 FoveaWAM

我们把动态操作表述为：从一个表示生成按时刻索引的动作块（第 3.1 节），并在这些指令的执行时刻，用场景的稀疏 3D 流与目标的 SE(3) 轨迹监督该表示（图 2）。下文依次介绍度量输入（第 3.2 节）、这一监督（第 3.3 节），以及动作流如何读取该表示以生成动作块（第 3.4 节）。

3.1 问题形式化

我们研究场景在策略计算期间持续运动的操作。在第 t 次查询时，从示范中学得的策略 π 读取在时刻 τ_t 采集的 RGB 图像 I_t 与深度图 D_t，以及目标位姿 $T(\tau) = (R(\tau), \mathbf{p}(\tau)) \in \mathrm{SE}(3)$ 的历史 $\mathcal{T}_t$ 与机器人状态的历史 $\mathcal{R}_t$，所有几何量都在机器人基座坐标系中表示，并输出一个包含 H 条指令的动作块：

$$(\mathbf{a}_{t,0}, \ldots, \mathbf{a}_{t,H-1}) \sim \pi\big(\cdot \mid I_t, D_t, \mathcal{T}_t, \mathcal{R}_t\big), \tag{1}$$

其中第 j 条指令对应时刻 $\tau_t + j\Delta_a$，Δ_a 为控制周期。

每个任务指定一个目标，机器人须在接触或容纳容差内对齐其位姿。起作用的周围物体构成环境：机器人须避开的障碍物，以及推动目标运动的驱动物。动作块要在推理完成后才可用，因此每条被执行的指令必须考虑目标与环境在其执行时刻、而不是 τ_t 时刻的状态。

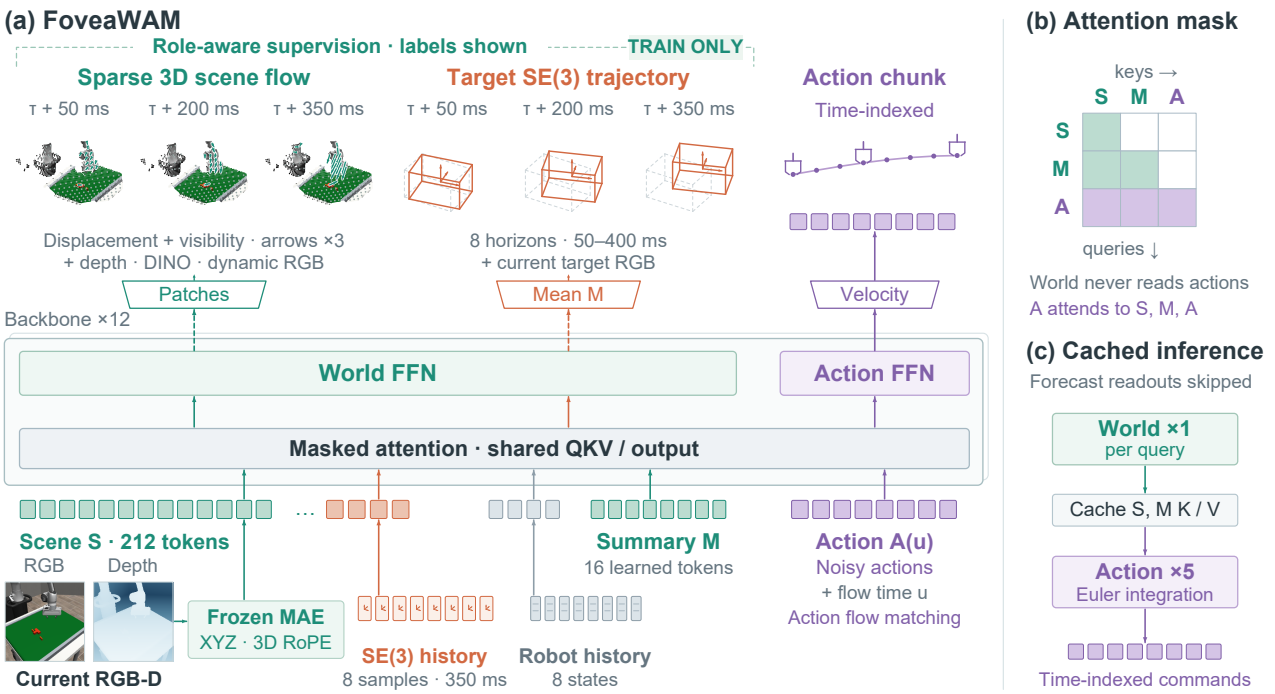


图 2. **FoveaWAM 架构。**(a) 自下而上阅读。当前 RGB-D 和目标、机器人状态历史组成场景 token S，16 个可学习摘要 token M 补全世界流。12 层主干共享注意力投影，世界流与动作流使用独立的 FFN。仅训练时使用的读出头（虚线）从 patch 状态预测稀疏场景位移和可见性，从摘要均值预测目标 SE(3) 轨迹；辅助监督目标列于几何面板下方。几何示例展示覆盖 50–400 ms 的 8 个时域中的 3 个实录标签：灰色 glyph 表示当前位姿，橙色 glyph 表示未来位姿（glyph 大小为示意）；当前点云上的位移箭头统一放大 3×。动作图标为示意。(b) 掩码的行表示 query，列表示 key：S 读取 S，M 读取 S, M，A 读取 S, M, A。动作读取世界隐状态。(c) 推理时跳过预测读出头，每次查询只计算并缓存一次世界流的键和值，在 5 个 Euler 动作步中复用。

3.2 度量场景与运动输入

FoveaWAM 精确编码目标的运动，并通过当前几何编码环境：当前 RGB-D 帧给出场景的度量布局，目标位姿的短历史给出单帧无法显示的运动，其中也反映了驱动物对目标的推动。

当前场景。 FoveaWAM 把每个 patch token 锚定在一个度量 3D 点上，使观测与预测、动作处于同一个基座坐标系中。冻结的 MAE ViT-B/16 [16] 把 RGB 图像编码为14×14 网格上的 196 个 patch token，深度图把 patch i 的中心反投影为基座坐标系中的点 $\mathbf{x}_i \in \mathbb{R}^3$。$\mathbf{x}_i$ 的线性嵌入加到 patch token 上，$\mathbf{x}_i$ 还驱动 patch 查询与键的 3D 旋转位置编码，使 patch 之间的注意力取决于它们的相对 3D 位置。这些点 $\mathbf{x}_i$ 也是场景流的源点（第 3.3 节）。

目标运动。 FoveaWAM 不使用过去的图像帧（从中恢复运动需要比较多帧图像），而是以度量 SE(3) 状态的形式接收目标近期的运动。目标历史以 20 Hz 的 8 次采样覆盖最近 350 ms；它的 8 个 token 包含当前目标位姿与相邻采样之间的七段运动，每段包含平移、相对旋转、时间间隔，以及以物理单位表示的有限差分速度与加速度。决定目标将到达何处的速度与加速度因此直接进入模型，代价只是几个低维 token；第 4.3 节去掉这段历史以衡量其作用。在仿真中，这些位姿来自仿真器；在真机上，由因果跟踪器从 RGB-D 流中估计。

世界流。 patch token、目标 token，以及编码目标历史各采样时刻末端执行器状态的 8 个机器人 token，共同组成 212 个场景 token。它们与汇聚它们的 16 个可学习摘要 token 一起构成世界流。

3.3 按角色区分精度的 4D 预测监督

FoveaWAM 用两种精度不同的几何预测监督其表示：以 patch 网格上的稀疏 3D 流表示整个场景的运动；由于目标的位姿决定接触，还预测目标完整的 SE(3) 轨迹。两者都在基座坐标系中、以相对当前状态的变化表示于时刻 $\tau_t + \delta_h$，其中 $\delta_h = h{\cdot}50\,\text{ms}$，$h = 1, \dots, 8$，即采集后 50 ms 到 400 ms；连同当前状态，这些时域覆盖动作块中所有指令的执行时刻。

场景流。 在 patch 网格的分辨率上，场景流覆盖 patch 所见的每个表面：机器人、目标，以及指令必须考虑其间隙与运动的环境。对 196 个点 $\mathbf{x}_i$ 中的每一个和每个时域 h，patch token i 最终状态上的线性头预测该点在基座坐标系中的位移 $\hat{F}_{ih} \in \mathbb{R}^3$ 与可见性 logit $\hat{o}_{ih}$，以如下损失训练：

$$\mathcal{L}_F = \frac{1}{|\mathcal{V}_F|} \sum_{(i,h)\in\mathcal{V}_F} \Big[\tfrac{1}{3} \big\| (\hat{F}_{ih} - F_{ih})/s \big\|^2 + \text{BCE}(\hat{o}_{ih}, o_{ih}) \Big], \tag{2}$$

其中 F_{ih} 为 $\mathbf{x}_i$ 处表面点的位移，o_{ih} 为其可见性，s 为在训练标签上拟合的固定尺度，$\mathcal{V}_F$ 为有效标签集合。

目标轨迹。 场景流只在目标覆盖的少数几个 patch 上采样目标，过于稀疏，无法确定其旋转，因此由摘要 token 最终状态均值上的一个专用线性头直接预测目标的刚体运动：对每个时域 h，预测目标的位移 $\hat{\mathbf{d}}_h$ 与旋转增量 $\hat{\boldsymbol{\phi}}_h$，以如下损失训练：

$$\mathcal{L}_P = \frac{1}{|\mathcal{V}|} \sum_{h\in\mathcal{V}} \Big[\|\hat{\mathbf{d}}_h - \mathbf{d}_h\|^2 + \lambda_R \, d_{\text{SO(3)}}\big(\hat{R}_h, R_h\big)^2 \Big], \tag{3}$$

其中 $\mathbf{d}_h = \mathbf{p}(\tau_t{+}\delta_h) - \mathbf{p}(\tau_t)$ 与 $R_h = R(\tau_t{+}\delta_h)$ 为真实的位移与朝向，$\hat{R}_h = \text{Exp}(\hat{\boldsymbol{\phi}}_h^{\wedge}) R(\tau_t)$，$d_{\text{SO(3)}}$ 为测地距离，$\mathcal{V}$ 为具有有效标签的时域集合。旋转项对接触很重要：旋转误差 θ 可使与目标原点相距 r 的接触点偏移至多 $2r\sin(\theta/2)$。例如，在 $r = 10\,\text{cm}$ 处，5° 的误差可使接触点偏移近 9 mm。

3.4 世界—动作联合学习与推理

动作流。 动作流以条件流匹配 [23] 生成动作块。它包含 $H = 8$ 个 token，每个嵌入一条加噪指令：末端执行器的平移增量、旋转增量与夹爪指令。每一层中，一个注意力以共享的投影覆盖两条流，其后接各自独立的前馈网络；世界 token 使用层归一化，动作 token 使用以流时间为条件的自适应层归一化。记场景、摘要与动作 token 为 S、M 与 A，注意力掩码允许 $S \to S$、$M \to \{S, M\}$ 与 $A \to \{S, M, A\}$，其中 $X \to \mathcal{Y}$ 表示 X 中的 token 读取 $\mathcal{Y}$ 中的 token。世界流从不读取动作。动作流在每一层都同时读取受场景流监督塑造的 patch 状态与受目标轨迹监督塑造的摘要状态。

训练目标。 对以训练统计量归一化的动作块 $\mathbf{a}_1$、噪声 $\mathbf{a}_0 \sim \mathcal{N}(0, I)$ 与流时间 $u \sim \mathcal{U}[0, 1]$，动作流 v_ψ 回归流匹配速度：

$$\mathcal{L}_A = \mathbb{E}\,\text{MSE}\big(v_\psi(\mathbf{a}_u, u \mid \mathcal{S}_t),\, \mathbf{a}_1 - \mathbf{a}_0\big), \tag{4}$$

其中 $\mathbf{a}_u = (1-u)\mathbf{a}_0 + u\mathbf{a}_1$，$\mathcal{S}_t$ 为式 (1) 中的输入，MSE 在有效指令与动作维度上取平均。世界流与动作流以

$$\mathcal{L} = \mathcal{L}_A + \lambda_F \mathcal{L}_F + \lambda_P \mathcal{L}_P + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}} \tag{5}$$

联合训练，其中 $\mathcal{L}_F$ 与 $\mathcal{L}_P$ 为式 (2) 与式 (3) 的流与位姿损失，$\mathcal{L}_{\text{aux}}$ 为辅助外观损失之和。

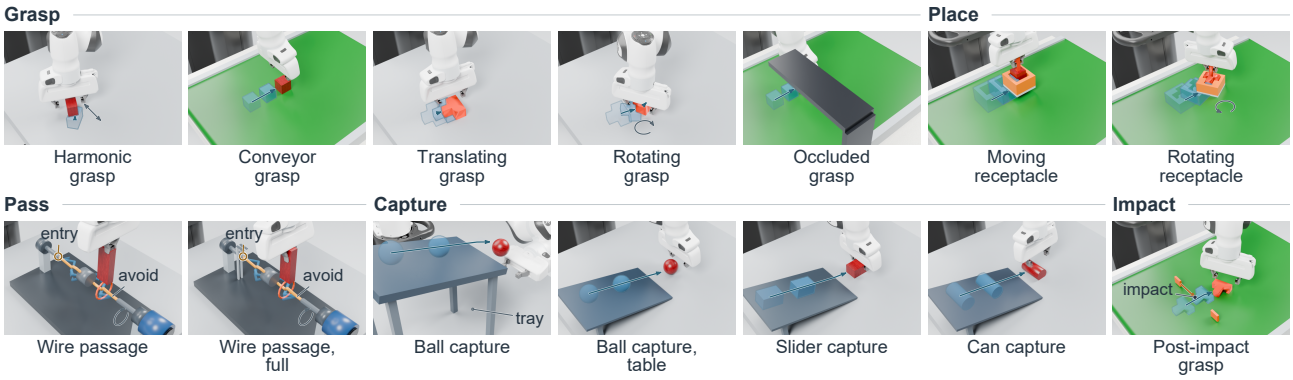


图 3. **ConMoto** 。采用统一主视角，从记录的仿真状态渲染五个任务族共 14 个任务。选取的历史位姿以半透明蓝色显示，时间越早越淡；深蓝轨迹表示记录的过去运动。深蓝箭头沿记录的平移轨迹，物体旁的灰色符号定性表示旋转或振荡；橙色箭头表示记录中的滑块接近过程，*impact* 标注指向实际接触位置。两个 Pass 子图均展示穿越阶段：导线在入口处是目标，沿途则是避碰障碍；Full 还要求获取、退出和释放。被遮挡的运动保持隐藏。这些原生专家示例用于展示任务动态，不代表 FoveaWAM 的执行结果，图中不显示未来预测。

推理。 部署时，FoveaWAM 跳过预测头，与近期的世界—动作模型相同 [21, 52, 55]。由于世界 token 既不读取动作，也不读取流时间，世界流每次查询只运行一次，动作流在场景与摘要 token 缓存的键和值上积分 5 个 Euler 步。指令按相对采集时刻的时间索引，因此策略不需要延迟输入：执行器在推理完成时或之后的第一个控制周期边界接收动作块，并从对应该边界的指令开始执行。在真机上，一次查询的延迟还包括在最新一帧中跟踪目标的时间。更多实现细节见补充材料。

4 实验

我们检验：当场景在推理期间持续运动时，按角色区分的精度与较低的延迟能否共同改善操作。我们先将 FoveaWAM 与已有策略比较，每个方法都承担自身的延迟（第 4.2 节）；再分析其设计中哪些部分带来了这些结果（第 4.3 节）；最后在使用跟踪目标位姿的真机上验证（第 4.4 节）。

4.1 实验设置

ConMoto 。 DOMINO [14] 与 PhysMani-Bench [53] 的评测器在策略返回预测之后才推进仿真；与之不同，ConMoto 让观测、场景运动与动作执行共用一个物理时钟，因此策略计算时场景继续运动。它包含五个任务族共 14 个任务，基于 MuJoCo/robosuite [41, 61] 构建：抓取运动目标（简谐、传送带、平移、旋转与遮挡运动）、放入移动的容器、让棒沿旋转的导线穿过、捕获滚动或滑动的物体，以及撞击后的抓取（图 3）。使用仿真特权状态的专家为每个任务提供 800 条示范。我们在开发场景上选择配置，并在 1,400 个留出场景（每个任务 100 个）上报告全部 ConMoto 结果。

评测。 每次查询期间，物理按该方法的推理延迟推进：延迟从该方法在其原生部署设置下、于一块 RTX 5090（我们机器人所用的 GPU）上以 batch 1 实测的延迟分布中抽取。所有方法共用同一个执行器，它从对应于动作块到达时那个控制周期边界的指令开始执行该动作块。除这一原生设置外，我们还为每个方法附加 150 ms 延迟，并以推理期间暂停物理作为不计计算代价的参照。我们报告任务等权的成功率（SR）与 p95 出动作时间，即从观测到其第一条指令可用的实测时间；配对 95% 区间由对留出场景的自助法得到。完整的评测协议见补充材料。

表 1. **ConMoto 上的结果。**1,400 个留出场景上按任务等权的 SR（%），分别为各方法的原生延迟、附加 150 ms，以及推理期间暂停物理。p95：各方法在一块 RTX 5090 上、按其原生部署设置测得的出动作时间。历史：当前帧之外携带过去运动信息的输入。OpenWAM-α 使用官方的缓存与编译，off 关闭两者。PUMA 的 p95 使用官方 D14 三相机计时预算，但其 E7 rollout 训练输入为单 agentview；其他基线使用双相机计时输入。每列的最佳与次佳已标出。[一句结论，例如 FoveaWAM 以远低于 WAM 的延迟取得最高的原生 SR。]

	历史			SR (%) ↑			
方法	腕部 RGB	光流	SE(3)	原生	+150 ms	暂停	p95 (ms) ↓
ACT [58]				41.6	24.3	40.6	**5.8**
DP [12]	✓			30.7	15.9	31.0	68.9
$\pi_{0.5}$ [5]				53.8	27.8	66.0	59.6
$\pi_{0.5}$+SE(3)			✓	52.8	28.2	**74.9**	61.2
DynamicVLA [46]	✓			50.9	23.4	54.6	97.3
PUMA [14]		✓		**59.6**	**31.1**	52.8	60.6
OpenWAM-α [42]				46.1	24.7	58.3	151.7
OpenWAM-α (off)				15.8	10.4	58.3	466.3
DynamicWAM [27]		✓		40.5	20.6	49.1	149.6
DynamicWAM+SE(3)		✓	✓	36.8	21.9	64.1	153.3
FoveaWAM			✓	—	—	—	—

基线。 我们比较反应式策略 ACT [58] 与 Diffusion Policy [12] 及 VLA $\pi_{0.5}$ [5]；动态 VLA DynamicVLA [46] 与 PUMA [14]；WAM OpenWAM-α [42]；以及动态 WAM DynamicWAM [27]（表 1）。每个基线使用官方架构和任务适配后的配方，在相同示范上训练。FoveaWAM 接收单帧主视角 RGB-D 与目标的 SE(3) 历史，不使用过去的帧。为了让基线获得相同的目标运动信息，$\pi_{0.5}$ 与 DynamicWAM 还以接收我们 SE(3) 历史 token 的形式运行（+SE(3)）。

实现。 FoveaWAM 的 Transformer 共 24 层，宽度 1024，16 个注意力头，可训练参数 523.8M，建立在冻结的 MAE ViT-B/16 编码器之上。在 ConMoto 上，它从随机初始化开始，使用 AdamW 训练至多 20 轮，我们保留验证损失最低的检查点。

4.2 动态操作结果

与基线的比较。 在原生延迟下，FoveaWAM 在 ConMoto 留出场景上的 SR 为 [XX.X]%（表 1），比最强基线 [名称] 高 [X.X] 个百分点，比接收相同 SE(3) 历史的最强基线 [名称] 高 [X.X] 个百分点。由于 +SE(3) 基线接收相同的目标运动输入，后一差距衡量的是 FoveaWAM 的表示在这一输入之外带来的增益。它的 p95 延迟为 [XX] ms，是视频 WAM（OpenWAM-α 与 DynamicWAM）的 [X] 分之一，与 [最快的反应式策略，待定] 相近。优势最大的是 [任务类型]。

推理延迟的影响。 [计入计算时间会改变排序：] 推理期间暂停物理时，FoveaWAM 领先 [名称] [X.X] 个百分点，原生延迟下领先 [X.X] 个百分点，而视频 WAM 从 [XX.X]% 降至 [XX.X]%（表 1）。附加 150 ms 延迟拉长了每个方法需要预判的时长。FoveaWAM 保持 [XX.X]% 的 SR，而不预判目标运动的反应式策略，其速度误差在更长的延迟中累积，平均降至 [XX.X]%；本就较慢的视频 WAM 降至 [XX.X]%。图 4 将这一比较扩展到 0 至 200 ms：[趋势，例如差距随每档附加延迟扩大]。

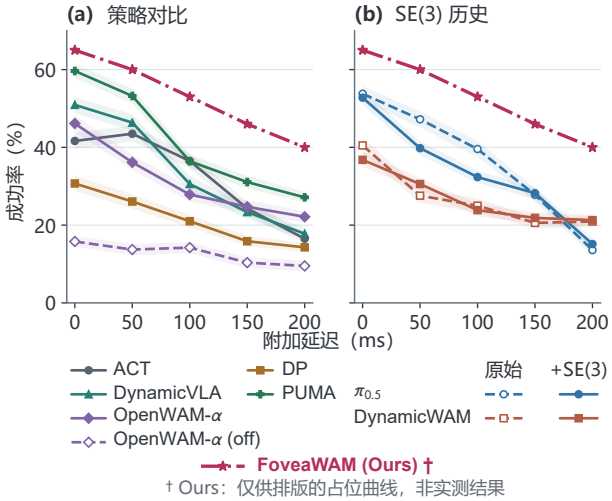


图 4. **附加延迟下的成功率。**1,400 个 ConMoto 留出场景上的任务平衡 SR。延迟加在各方法原生延迟之上。(a) 基线部署；off 关闭 OpenWAM-α 的缓存与编译。(b) 原始与加入 SE(3) 历史的版本。PUMA 的单 agentview E7 rollout 使用官方 D14 三相机计时预算。阴影：按任务分层的场景 bootstrap 95% 区间。

表 2. **DOMINO 结果：**24 个单臂 Franka clean-L1 任务，各方法使用相同的 1,200 个测试场景（每任务 50 场）。拦截/跟踪包含 8/16 个任务；全部列对 24 个任务等权。SR 与 MS 均为 0–100 尺度，保留失败场次。最佳与次佳已标出。

方法	拦截	跟踪	全部↑	MS↑
$\pi_{0.5}$	**33.8**	9.1	17.3	31.1
DynamicWAM	18.3	**34.9**	**29.3**	**42.8**
PUMA	29.5	12.8	18.3	33.4
FoveaWAM	—	—	—	—

DOMINO 上的结果。 为了在 ConMoto 之外检验这一设计，我们在 DOMINO [14] 的 24 个单臂 Franka 任务上，用其示范训练 FoveaWAM 、$\pi_{0.5}$、DynamicWAM 与 PUMA，并用其原生评测器评测；与在 ConMoto 上一样，FoveaWAM 读取仿真器中的目标位姿。在已完成的基线中，DynamicWAM 的总体 SR 最高，为 29.3%，PUMA 与 $\pi_{0.5}$ 分别为 18.3% 和 17.3%（表 2）；$\pi_{0.5}$ 在拦截任务上最高，为 33.8%。[补入 FoveaWAM 已验收的结果及比较。] 更多结果见补充材料。

4.3 角色化建模分析

六个对照各改变 FoveaWAM 的一个部分，保持其数据与配方不变（图 5）。除无目标历史的对照外，每个对照只改变训练损失，而这些损失对应的预测头在部署时被跳过，因此其推理与 FoveaWAM 相同。我们依次报告每个对照在原生延迟与附加 150 ms 延迟下的 SR 变化。

精度的分配。 去掉专用 SE(3) 监督后，目标只剩下整个场景共有的统一粗粒度场景流监督，SR 分别下降 [X.X] 与 [X.X] 个百分点。若改为在 [56×56] 网格上监督统一而精细的场景流，使典型目标上有 [约 X 个] 流点，SR 变化 [X.X] 与 [X.X] 个百分点，[说明遍布全场景的精度不能替代专门的目标轨迹]。去掉场景流监督后，目标保留其 SE(3) 轨迹，而场景其余部分（包括环境）失去运动监督，SR 分别下降 [X.X] 与 [X.X] 个百分点。这三个消融与完整模型一样保留全部辅助目标。如果精度按角色分配，SE(3) 监督应在预先声明的旋转敏感任务上作用最大，而流监督应在环境活跃任务上作用最大，这些任务的环境约束机器人或推动目标。[图 5 是否呈现这一模式，以及它对精度分配意味着什么。]

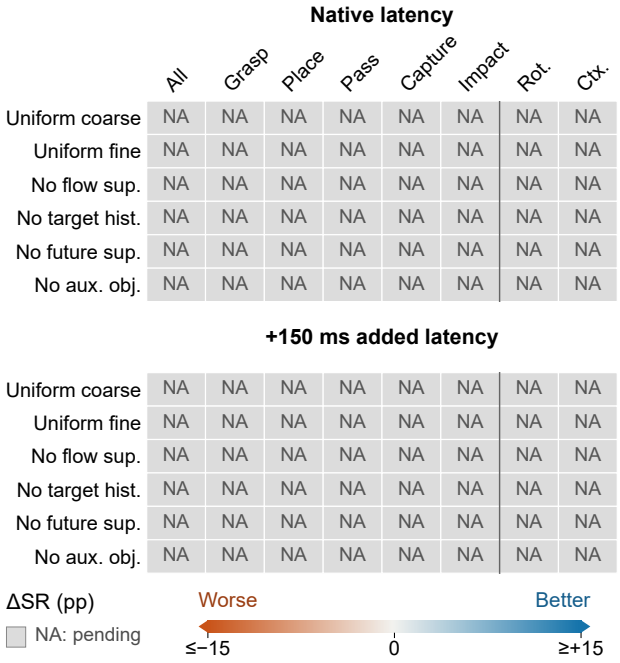


图 5. **按任务的消融效应（设计预览；数据待齐）。** ΔSR = SR(对照) − SR(完整模型)，单位为百分点；色阶在 ±15 处饱和。各行为第 4.3 节的六个对照：统一粗粒度流去掉专用 SE(3) 监督，使目标只接受整个场景共有的场景流监督；统一精细流同样去掉它，但在 [56×56] 网格上监督场景流。完整模型在原生延迟下的 SR 为 [XX.X]%，附加 150 ms 时为 [XX.X]%。Rot./Ctx. 分别表示预先声明、可重叠的旋转敏感组和环境活跃组（表 S2）。粗体：配对 95% 场景自助法区间不含零。NA：暂无数据。

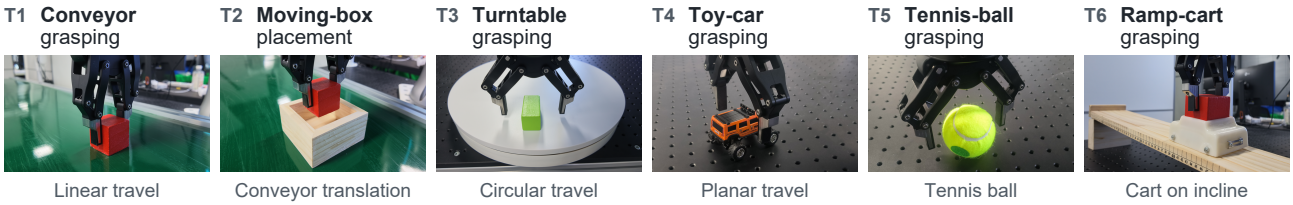


图 6. **真机任务场景。**六项任务的实拍照片：传送带抓取（T1）、向移动盒放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5）和斜坡小车载块抓取（T6）。

目标运动历史。 移除过去的目标位姿及其速度、加速度特征，同时保留当前图像、当前目标位姿与机器人历史，SR 分别下降 [X.X] 与 [X.X] 个百分点。[下降幅度随附加延迟增大，] 这与历史提供目标速度的作用一致：延迟越长，速度误差累积得越远。由于历史依赖位姿估计，我们还对位姿施加扰动；在每轴标准差为 5 mm 与 1° 的合成时序相关位姿噪声下，FoveaWAM 的 SR 为 [XX.X]%，比无噪声位姿低 [X.X] 个百分点。

未来监督与辅助目标。 移除全部未来监督，即 SE(3)、场景流与未来外观目标，同时保留当前目标的重建，推理不变，但 SR 分别下降 [X.X] 与 [X.X] 个百分点，在 [目标做非匀速运动的任务] 上最明显。若改为移除辅助目标 $\mathcal{L}_{\text{aux}}$（包括当前目标重建）并保留两种几何预测，SR 变化 [X.X] 个百分点，[这对辅助目标的作用意味着什么]。[用一句话概括哪些组件起作用、在哪里起作用。]

表 3. **真机结果。**第 4.4 节六个任务上的成功率（%），每个任务每个方法 20 次试验；All 合并全部试验。p95：在一块 RTX 5090 上实测的端到端出动作时间（ms），FoveaWAM 包含跟踪。每列最佳已标出，并列者同样标出。

方法	T1	T2	T3	T4	T5	T6	All ↑	p95 (ms) ↓
$\pi_{0.5}$	—	—	—	—	—	—	—	—
DynamicWAM	—	—	—	—	—	—	—	—
ACT	—	—	—	—	—	—	—	—
FoveaWAM	—	—	—	—	—	—	—	—

4.4 真机评估

设置。 我们在 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机上评估六个任务（图 6）：传送带抓取（T1）、向移动盒放置（T2）、转盘抓取（T3）、移动玩具车抓取（T4）、网球抓取（T5），以及斜坡小车载块抓取（T6）。基线为仿真中最强的基线 $\pi_{0.5}$、低延迟的模仿学习策略 ACT，以及动态 WAM DynamicWAM。所有方法都在每个任务相同的 100 条遥操作示范上训练或微调（FoveaWAM 从一个在 DROID [19] 上预训练的 48 层基座出发），并以共享试验键各运行 20 次试验。基线接收 RGB[，若配方使用腕部相机则一并提供]；FoveaWAM 接收第三人称 RGB-D 帧与 FoundationPose [43] 的目标位姿估计，后者在每个控制周期边界、查询之前更新。

结果。 FoveaWAM 在全部试验中的成功率为 [XX.X]%，[最强基线] 为 [XX.X]%，配对差为 [X.X] 个百分点（95% 区间 [[X.X, X.X]]；表 3）。包含跟踪在内，其 p95 延迟为 [XX] ms，[在一个控制周期之内]，而 [名称] 需要 [XX] ms。优势最大的是 [任务]。[表 1 的排序在真实感知下是否保持，以及跟踪带来的代价。][一个可由轨迹核实的接触实例：目标位姿、旋转或环境如何解释 FoveaWAM 的成功或基线的失败。]FoveaWAM 的主要失败模式是 [失败模式]。更多细节见补充材料。

5 结论

FoveaWAM 把精度花在接触所依赖之处：用度量 SE(3) 历史与预测表示目标，用稀疏 3D 流表示整个场景，并且预测只作为训练监督。当每个方法都承担自身的延迟时，这些设计让 FoveaWAM 既精确又迅速：它在 ConMoto 与六个真机任务上优于反应式策略、VLA 与世界—动作模型，包括为运动目标设计的模型，在 ConMoto 上的 p95 延迟为 [XX] ms；它在 DOMINO 上同样领先。[说明计入延迟后排序相对暂停评测有何变化。][一到两条最强的消融发现。] 我们将公开 ConMoto，使今后的动态策略在计入延迟的条件下评测。

局限性。 FoveaWAM 需要一个指定的刚体目标及可靠的位姿估计，其预测也忽略了机器人自身的接触如何改变目标的运动；学习以接触为条件的目标动力学是自然的扩展。目标轨迹预测头在每个时域只预测一个未来，因而无法表示多模态运动；不确定性感知的预测可以弥补这一点。我们的任务中没有独立于目标运动的环境；在这类场景中，环境同样需要运动历史，例如其场景流的历史。

LLM Usage Statement（大语言模型使用声明）

我们使用 OpenAI Codex 辅助文献调研、代码实现与调试、实验执行及论文语言润色。Codex 还用于辅助编写绘图代码，以及调整图表与论文排版。作者审阅了 AI 辅助生成或修改的内容，对照原始来源核查了参考文献，并通过测试与实验验证了实现。作者对最终稿件、实验结果和结论承担全部责任。

参考文献

[1] Peter K. Allen, Aleksandar Timcenko, Billibon Yoshimi, and Paul Michelman. Automated tracking and grasping of a moving object with a robotic hand-eye system. *IEEE Transactions on Robotics and Automation*, 9(2):152–165, 1993.

[2] Yaakov Bar-Shalom, X. Rong Li, and Thiagalingam Kirubarajan. *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. Wiley, 2001.

[3] Berthold Bäuml, Thomas Wimböck, and Gerd Hirzinger. Kinematically optimal catching a flying ball with a hand-arm-system. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2010.

[4] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision*, 2024.

[5] Kevin Black, Noah Brown, James Darpinian, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *Proceedings of The 9th Conference on Robot Learning*, pages 17–40, 2025.

[6] Kevin Black, Noah Brown, Danny Driess, et al. π_0: A vision-language-action flow model for general robot control. In *Proceedings of Robotics: Science and Systems*, 2025.

[7] Kevin Black, Manuel Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Advances in Neural Information Processing Systems*, pages 33383–33407, 2025.

[8] Arunkumar Byravan and Dieter Fox. SE3-Nets: Learning rigid body motion using deep neural networks. In *IEEE International Conference on Robotics and Automation*, pages 173–180, 2017.

[9] Arunkumar Byravan, Felix Leeb, Franziska Meier, and Dieter Fox. SE3-Pose-Nets: Structured deep dynamics models for visuomotor control. In *IEEE International Conference on Robotics and Automation*, 2018.

[10] Chongkei Chang and Zhidong Deng. DynaWM: A base-VLA-guided world foundation model for moving-object manipulation. *arXiv preprint arXiv:2607.02604*, 2026.

[11] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Joon-Young Lee, and Alexander Schwing. Putting the object back into video object segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[12] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin C. M. Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems*, 2023.

[13] David Emukpere, Romain Deffayet, Bingbing Wu, Romain Brégier, Michael Niemaz, Jean-Luc Meunier, Denys Proux, Jean-Michel Renders, and Seungsu Kim. Disentangled object-centric image representation for robotic manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 15873–15879, 2025.

[14] Heng Fang, Shangru Li, Shuhan Wang, Xuanyang Xi, Dingkang Liang, and Xiang Bai. Towards generalizable robotic manipulation in dynamic environments. In *European Conference on Computer Vision*, pages 314–333, 2026.

[15] Jun Guo, Xiaojian Ma, Yikai Wang, Min Yang, Huaping Liu, and Qing Li. FlowDreamer: A RGB-D world model with flow-based motion representations for robot manipulation. *IEEE Robotics and Automation Letters*, 11(3):2466–2473, 2026.

[16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.

[17] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. In *IEEE International Conference on Robotics and Automation*, 2025.

[18] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. PointWorld: Scaling 3D world models for in-the-wild robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20765–20779, 2026.

[19] Alexander Khazatsky, Karl Pertsch, Suraj Nair, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.

[20] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. OpenVLA: An open-source vision-language-action model. In *Conference on Robot Learning*, pages 2679–2713, 2025.

[21] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Proceedings of Robotics: Science and Systems*, 2025.

[22] Haoran Liao, Pengyue Wang, Shuoyu Chen, Kehan Cheng, Xuhang Chen, Yuhao Lin, Mu Lin, Zhizhao Liang, Xiaoyi Fan, Chengyi Xing, Dan Niu, Yi-Lin Wei, and Wei-Shi Zheng. DynamicManip: Enabling dynamic manipulation from a single static demonstration. *arXiv preprint arXiv:2608.01452*, 2026.

[23] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.

[24] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision*, 2024.

[25] Yuejiang Liu, Jubayer Hamid, Annie Xie, Yoonho Lee, Max Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *International Conference on Learning Representations*, pages 4594–4627, 2025.

[26] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, and Wenbo Ding. OA-WAM: Object-addressable world action model for robust robot manipulation. *arXiv preprint arXiv:2605.06481*, 2026.

[27] Yunfan Lou, Hewen Gao, Xiyu Zhu, Zhuoran Qiao, Xuan Han, Yifan Yang, Yifan Ye, Boxian Yao, and Zhibo Pang. DynamicWAM: Dual-path motion conditioning for world-action models in dynamic manipulation. *arXiv preprint arXiv:2608.00793*, 2026.

[28] Siyuan Ma, Yutian Zhang, Boshi Zhang, Qinglian Wu, Jiaqi Zhai, Dong Wei, and Xiaojin Huang. ForeTime-VLA: Causal future-token distillation from a world action model for conveyor-belt manipulation. *arXiv preprint arXiv:2608.20735*, 2026.

[29] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kPAM: Keypoint affordances for category-level robotic manipulation. In *Robotics Research: The 19th International Symposium ISRR*, pages 132–157. Springer, 2022.

[30] Naresh Marturi, Marek Kopicki, Alireza Rastegarpanah, et al. Dynamic grasp and trajectory planning for moving objects. *Autonomous Robots*, 43(5):1241–1256, 2019.

[31] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, pages 28085–28128, 2025.

[32] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pages 785–799, 2023.

[33] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[34] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

[35] Otto J. M. Smith. Closer control of loops with dead time. *Chemical Engineering Progress*, 53(5):217–219, 1957.

[36] Rustin Soraki, Homanga Bharadhwaj, Ali Farhadi, and Roozbeh Mottaghi. ObjectForesight: Predicting future 3D object trajectories from human videos. In *European Conference on Computer Vision*, pages 437–453, 2026.

[37] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. In *Proceedings of the 43rd International Conference on Machine Learning*, pages 115917–115933, 2026.

[38] Shahram Najam Syed, Arthur Jakobsson, Haoran Hao, and Jeffrey Ichnowski. Intercepting the future: Latent-space predictive world model for dynamic VLA manipulation. In *Conference on Robot Learning*, 2026. Accepted for publication.

[39] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. VLASH: Real-time VLAs via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.

[40] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *International Conference on Learning Representations*, pages 92033–92052, 2025.

[41] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A physics engine for model-based control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.

[42] Yuran Wang, Siqiao Huang, Mingleyang Li, Chenhao Zhang, Jiaqi Liang, Weiyang Jin, Yue Chen, Xuemin Chi, Donghao Zhou, Qize Yu, Yu-Kai Wang, Yuhan Rui, Shenzhe Yao, Zhen Yuan, Zhenhao Shen, Kefei Zhu, Zijie Zhu, Ning Gao, Xiaowei Chi, Guanqi He, Shanghang Zhang, Hao Dong, Lin Shao, and Hang Zhao. OpenWAM: An open, modular exploration towards systematic world-action model pretraining. *arXiv preprint arXiv:2609.07398*, 2026.

[43] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17868–17879, 2024.

[44] Chuan Wen, Xingyu Lin, John Ian Reyes So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *Proceedings of Robotics: Science and Systems*, 2024.

[45] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *International Conference on Learning Representations*, pages 10641–10662, 2024.

[46] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[47] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning*, pages 2475–2499, 2025.

[48] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.

[49] Hanyang Yu, Haitao Lin, Jingbo Zhang, Wenyao Zhang, Chenghao Gu, Heng Li, and Ping Tan. MaskWAM: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.

[50] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *Conference on Robot Learning*, pages 1541–1566, 2025.

[51] Shanglin Yuan, Weiheng Zhao, Xin Shi, Haoyi Jiang, Xianda Guo, Liu Liu, Wenyu Liu, Wei Sui, and Xinggang Wang. DreamWAM: Beyond RGB future prediction for world action models. *arXiv preprint arXiv:2608.04996*, 2026.

[52] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? In *Advances in Neural Information Processing Systems*, 2026. Accepted for publication.

[53] Peng Yun, Shouwang Huang, Hao Li, Jinxi Li, Jianan Wang, and Bo Yang. PhysMani: Physics-principled 3D world model for dynamic object manipulation. In *European Conference on Computer Vision*, pages 20–39, 2026.

[54] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations. In *Proceedings of Robotics: Science and Systems*, 2024.

[55] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, XinQiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A vision-language-action model dreamed with comprehensive world knowledge. In *Advances in Neural Information Processing Systems*, pages 24195–24228, 2025.

[56] Yifan Zhang, Ruiping Wang, and Xilin Chen. Dynamic behavior cloning with temporal feature prediction: Enhancing robotic arm manipulation in moving object tasks. *IEEE Robotics and Automation Letters*, 10(6):5209–5216, 2025.

[57] Ruiteng Zhao, Zhengshen Zhang, Yue Su, Wenshuo Wang, Jiahui Li, Zhiyuan Yang, Francis E. H. Tay, Marcelo H. Ang, and Haiyue Zhu. SG-WAM: Self-guided world modeling in geometry-aware policy space. *arXiv preprint arXiv:2608.01397*, 2026.

[58] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023.

[59] Ruijie Zheng, Jing Wang, Scott Reed, et al. FLARE: Robot learning with implicit world modeling. In *Proceedings of The 9th Conference on Robot Learning*, pages 3952–3971. PMLR, 2025.

[60] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Proceedings of Robotics: Science and Systems*, 2025.

[61] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Kevin Lin, Abhiram Maddukuri, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

[62] Brianna Zitkovich, Tianhe Yu, Sichun Xu, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183, 2023.

A 方法与训练细节

A.1 架构与训练

表 S1 列出 FoveaWAM 在 ConMoto 上的超参数。

表 S1. FoveaWAM 在 ConMoto 上的超参数。一个训练窗口包含 8 个连续的查询位置，每个位置有自己的因果历史。

参数	取值
模型	
输入图像	224×224 RGB-D，单视角
视觉编码器	MAE ViT-B/16，冻结
历史长度	8 步（350 ms）
预测时域	8 个（50 ms–400 ms）
摘要 token	16
层数	24
宽度	1024
注意力头	16
前馈宽度	4096
可训练参数	523.8M
动作	
动作维度	7
动作块长度	8
Euler 步数	5
每个查询的噪声采样数	8
训练	
优化器	AdamW
Betas	(0.9, 0.999)
权重衰减	10^{-4}
学习率	2×10^{-4}
学习率调度	余弦，5,174 次预热更新
Batch 大小	512 个窗口
轮数	至多 20
梯度截断	0.1
$\lambda_F, \lambda_P, \lambda_R, \lambda_{\text{aux}}$	0.1
精度	FP32，冻结编码器 BF16
硬件	[N] 块 RTX PRO 6000 GPU，[X] h

场景 token。 冻结的 MAE ViT-B/16 [16] 输出的每个 patch token 加上一个可学习的视角嵌入，以及其平均有效度量深度和其中心像素反投影后基座坐标系位置 $\mathbf{x}_i$ 的线性嵌入；中心像素没有有效深度的 patch 不加位置嵌入。只有 patch 的 query 与 key 使用由 $\mathbf{x}_i$ 驱动的 3D 旋转位置编码，同样的点也是稀疏 3D 流的源点。

状态 token。 8 个目标状态 token 在偏移 $-350, -300, \ldots, 0$ ms 处取样。每个都是 25 维描述子 $(\mathbf{p}, \log R, \Delta\mathbf{p}, \log \Delta R, \Delta t, \mathbf{v}, \boldsymbol{\omega}, \mathbf{a}, \boldsymbol{\alpha})$：槽位 0–6 描述相邻偏移之间的七个区间，速度与加速度由经过时间上的有限差分得到；槽位 7 存放基座坐标系下的当前位姿。每一维用训练统计量标准化，无效维置零，并附加三个有效性标志（位姿、区间与加速度）；没有任何有效特征的槽位在注意力中被掩码。机器人 token 包含相同偏移处的末端位置、旋转向量与夹爪开度，16 个可学习嵌入构成摘要 token。

预测头与损失。 除目标重建使用两层 MLP 外，每个预测头都是世界流最终状态上的一个线性层。位姿头读取摘要状态的均值（$\mathcal{L}_P$，式 3）。流头给出每个 patch 点在各时域的位移与可见性 logit（$\mathcal{L}_F$，式 2，尺度 $s = 0.715$ m，可见性权重为 1）；有效但不可见的点仍监督其位移。流标签由 patch 中心处渲染到的表面点随其 MuJoCo 几何体的真值刚体运动得到；若未来点投影在图像内、落在同一几何体上，且深度差在 $\max(1\,\text{mm}, 0.001z)$ 以内，则视为可见。$\mathcal{L}_{\text{aux}}$ 由四项组成：未来度量深度（有效像素）、位移

超过 1 mm 的表面的 RGB，以及经层归一化的 DINOv3 特征 [34] 上的平方误差，以及由摘要状态均值重建当前目标 RGB 区域的绝对误差。

动作流。 每个动作 token 嵌入一条七维指令：基座坐标系下的平移增量、左乘相对旋转向量与夹爪指令，均相对于施加时测得的末端位姿。查询 t 动作块的第 j 条指令标注为示范在 $\tau_t + j\Delta_a$ 下发的指令，因为 d_{task} 只在执行时起作用（式 (S1)）；指令在训练集上标准化。部署时，夹爪指令只有超出死区（小球捕获任务为 0.5，其余任务为 0.1）时才切换状态。

A.2 DROID 预训练与微调

真机基座在 DROID [19]（15 Hz）上训练，使用第一台外部相机及其深度，以及 PointWorld [18] 发布的 3D 点轨迹与标定。可用的 42,087 个回合给出 598,889 个锚定窗口，其中 60,149 个用于验证；与 ConMoto 相同，每个锚点扩展为 8 个查询位置，只有锚点带有流与 DINOv3 标签。每个 patch 跟随一条从其内部出发的 PointWorld 轨迹，优先选择运动最大且一致的一条，以覆盖小的运动物体；47% 的点—时域槽位带有标签。

DROID 没有物体位姿，因此基座没有目标状态 token 与位姿头；它训练动作损失、$\lambda_F = 1$ 且不含可见性项的稀疏 3D 流，以及权重 0.1 的未来 DINOv3 特征。基座共 48 层，宽度 1024（可训练参数 1.02B），以全局 batch 512 在 64 块 GPU 上训练 20 轮（21,060 次更新），优化器与精度同表 S1。每个真机策略从基座出发，在其任务的示范上微调 [更新次数、学习率与 batch 大小]，目标状态 token 与基座缺少的预测头重新初始化；真机策略不使用任何仿真数据或权重。

B ConMoto 与评测协议

B.1 基准设计

任务在 MuJoCo 3.11.0 与 robosuite 1.5.2 [41, 61] 中运行，使用 Franka Panda 机械臂与平行夹爪，由 robosuite 的操作空间位姿控制器驱动，控制周期 50 ms，物理步长 2 ms。一台固定的第三人称相机，垂直视场角 40°，渲染 224 × 224 的 RGB-D 图像。动作是基座坐标系下末端的平移与旋转向量增量，加一条夹爪指令，按每个平移轴 0.10 m、每个旋转分量 0.5 rad 截断。表 S2 列出全部十四个任务。

表 S2. **ConMoto 的十四项任务。**目标：策略接收其位姿的物体（第 3.1 节）；放置任务为容器，穿越任务为导线入口，导线其余部分为环境。速度：目标速度范围（捕获任务取离开斜坡时的速度）。抓取：双侧指垫接触、抬升至少 0.05 m 并连续保持 0.5 s。发生不安全接触、离开工作空间、掉落或达到时限（时限列）时回合失败。任务组（图 5）：R 为旋转敏感组（目标在领先时长内旋转且其朝向在接触时起作用），C 为环境活跃组（存在障碍间隙或驱动物：传送带、斜坡或撞击器）。

任务	代号	目标	速度（m/s）	成功条件	时限（s）	任务组
谐波抓取	`grasp`	物块	0.03–0.20	抓取	8	R
传送带抓取	`t1_belt`	零件	0.04–0.10	抓取	8	C
平移抓取	`t1_xyz`	零件	0.04–0.15	抓取	8	–
旋转抓取	`t1_so3`	零件	0.04–0.15	抓取	8	R
遮挡抓取	`t1_occ`	零件	0.04–0.10	抓取，不接触遮挡罩	8	C
移动容器	`t2_trans`	容器	0.03–0.06	所持物体静止于容器内	10	–
旋转容器	`t2_se3`	T 形容器	0.03–0.06	所持 T 形件静止于容器内	10	R
导线穿越	`t3_phase`	导线入口	[X]	30 mm 内对准，无接触穿过	21	R, C
完整导线穿越	`t3_full`	导线入口	[X]	抓杆、穿过、离开、释放	32	R, C
小球捕获	`t4_sphere`	小球	[0.4–0.7]	触及托盘前抓取	6	C
桌面小球捕获	`t4_sphere_tabletop`	小球	[0.4–0.7]	滚动中抓取	6	C
滑块捕获	`t4_slider`	滑块	[0.4–0.8]	滑动中抓取	6	C
罐体捕获	`t4_can`	罐体	[0.4–0.7]	倾倒前抓取	6	R, C
撞击后抓取	`t5_replan`	零件	0.12–0.14	沿抓取轴抓取	6	R, C

B.2 场景、示范与数据划分

每个场景在各任务的范围内均匀采样目标的初始状态与运动参数：除表 S2 的速度外，还包括至多 35 mm、0.25–0.7 Hz 的谐波振幅、至多 1.2 rad/s 的偏航角速度、2.5–7.5°/s 的导线转速，以及 5–15° 的斜坡坡度。遮挡场景中，目标被遮挡 0.5–3.0 s 后重新出现。只保留物理上可行的场景，评测时回放存储的场景。

专家是针对各任务的闭环状态机，使用仿真特权状态，并预判目标的运动，例如在捕获任务中预测截获点。只有专家成功、回放其动作能重现该回合、且路径与 jerk 通过质量检查的示范才被保留。训练池包含 11,200 条示范（每个任务 800 条），以 20 Hz 记录 RGB-D、机器人状态、指令与仿真真值，另有 350 个回合构成验证集；策略只接收第 3 节的输入。

我们在 1,400 个开发场景（每个任务 100 个）上选择配置，并在 1,400 个留出场景上报告全部 ConMoto 结果；留出场景以相同的范围生成，所用种子不出现在任何训练、验证或开发回合中，所有方法共用这些场景。

B.3 实时评测与指标

执行器。 所有方法在 50 ms 控制时钟上共用一个执行器。第 t 次查询的第 j 条指令对应时刻 $\tau_t + j\Delta_a$，其执行时刻（第 3.1 节）为

$$\tau^{\mathrm{a}}_{t,j} = \tau_t + j\Delta_a + d_{\mathrm{task}}, \tag{S1}$$

其中撞击后抓取在下发每条指令 50 ms 后才施加，$d_{\mathrm{task}} = 50$ ms；其余任务 $d_{\mathrm{task}} = 0$。与 RTC [7] 相同，延迟按整数个控制周期计：总延迟为 L_t 的查询在其结束时或之后的第一个周期边界交出动作块，即采集后 $k_t = \lceil L_t/\Delta_a \rceil$ 个周期，执行从对应该边界的第 k_t 条指令继续。策略随即重新观测并开始下一次查询，其间上一个动作块继续执行，因此策略以其延迟允许的频率重新规划。动作块包含该方法原生的 H_m 条指令（表 S3），$k_t \geq H_m$ 时整体丢弃。在第一个动作块到达之前及动作块耗尽时，控制器保持当前的手臂目标与夹爪指令，不重复执行任何指令。执行器以异步方式运行，与 DynamicVLA 的流式执行相同；包括 FoveaWAM 在内，没有任何方法像 RTC 那样在动作块之间做补全。

协议。 在实时协议下，每次查询期间物理按该方法的延迟推进，延迟每次查询从其在一块 RTX 5090 上实测的分布中抽取，rollout 本身在 RTX PRO 6000 上运行。在暂停协议下，推理不占用物理时间，策略每 50 ms 重新规划；这去掉了推理等待，但也提高了反馈频率，因此它是参照而非性能上界。延迟扫描在实时协议下于推理之后附加 0 至 200 ms，步长 50 ms。

延迟测量。 我们在一块 RTX 5090 上独占运行，以 batch 1 和各方法发布版本的精度（FoveaWAM 为 FP32）为每个方法计时：三轮，每轮 30 次预热与 300 次测量调用，使用录制观测及所需的因果历史。一次计时查询从最新观测开始，到第一条指令可用时结束，包含所有需要最新帧的计算，例如预处理、图像编码、PUMA 与 DynamicWAM 的在线光流与运动描述子、采样与动作解码，在真机上还包括跟踪。FoveaWAM 的预测头在部署时跳过，另行计时。出动作时间超过 50 ms 的查询称为超时；一条指令的动作年龄是其执行时刻减去采集时刻。附录 C.2 报告实测值。

指标。 SR 对 14 个任务等权平均。首次接触时的位置误差 e_p 是末端到专家在目标上的接触坐标系的距离；放置任务开始时物体已被抓住，因此使用所持物体与容器的接触及专家的放置位姿。e_p 在有接触的 13 个任务（不含 `t3_phase`）及发生接触的回合上平均；没有接触的失败仍计入 SR 的分母。配对 95% 区间在每个任务内、跨方法联合地对留出场景做自助法。

表 S3. **基线训练。**更新数 × batch：训练量。H：每个返回动作块中的指令数。参数量：可训练参数，不含冻结的编码器。DOM 检查点：DynamicVLA 发布的、在 DOM 上训练的检查点。

方法	初始化	更新数 ×batch	H	参数量
ACT [58]	从头训练	50,000 × 32	100	[X]
DP [12]	从头训练	50,000 × 32	15	[X]
$\pi_{0.5}$ [5]	`pi05_base`	30,000 × 256	10	[X]
$\pi_{0.5}$+SE(3)	`pi05_base`	30,000 × 256	10	[X]
DynamicVLA [46]	DOM 检查点	50,000 × 44	20	[X]
PUMA [14]	官方	[X]×[X]	[X]	[X]
OpenWAM-α [42]	官方	34,490 × 192	32	[X]
DynamicWAM [27]	官方	40,000 × 128	16	[X]
DynamicWAM+SE(3)	官方	40,000 × 128	16	[X]
FoveaWAM	从头训练	51,740 × 512	8	523.8M

B.4 基线

共同条件。 每个基线保留其官方架构、动作块长度、初始化与训练配方（表 S3），在相同的 11,200 条示范上训练（指令通过同一个笛卡尔控制器映射到其动作空间），配置在开发场景上选择。rollout 使用各基线训练时的主视角（腕部槽位被屏蔽）及表 1 所列历史；在两种方式都计时的七个配置中，屏蔽腕部视角使 p95 延迟至多改变 3.8 ms。DP 使用作者真机配方的 16 步 DDIM 采样器；OpenWAM-α 关闭视频解码运行，并分别在开启与关闭官方缓存和编译时计时。

加入 SE(3) 的基线。 $\pi_{0.5}$+SE(3) 与 DynamicWAM+SE(3) 从相同的位姿来源接收附录 A.1 的八个目标状态 token，带有相同的有效标志。一个输出层零初始化的两层 MLP 把它们映射到模型宽度；对 $\pi_{0.5}$，它们接在前缀中的图像 token 之后，由动作专家读取；对 DynamicWAM，它们并入其运动学描述。训练沿用基础模型的配方。

C 补充仿真结果

C.1 各任务结果

表 S4. **ConMoto 各任务的留出成功率**（%），涵盖表 1 中的全部方法，实时协议。DP：Diffusion Policy。DVLA：DynamicVLA。OWAM：使用官方缓存与编译的 OpenWAM-α；OW-off：关闭两者。DWAM：DynamicWAM。+：加入本文 SE(3) 历史 token。Δ：该任务上 FoveaWAM 相对最强其他方法之差及其 95% 配对区间。最后两行为首次接触时的位置误差 e_p（mm，在有接触的 13 个任务上平均）与发生接触的回合数 n（附录 B.3）；–：无 13 任务均值。Δ 的底色：蓝色表示 SR 更高，橙色表示更低，在 15 个百分点处饱和。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

任务	ACT	DP	$\pi_{0.5}$	$\pi_{0.5}$+	DVLA	PUMA	OWAM	OW-off	DWAM	DWAM+	本文	Δ [95% CI]
谐波抓取	49.0	31.0	51.0	**85.0**	39.0	—	41.0	1.0	50.0	51.0	—	—
传送带抓取	45.0	45.0	**96.0**	58.0	89.0	—	62.0	0.0	59.0	47.0	—	—
平移抓取	14.0	33.0	59.0	38.0	**61.0**	—	53.0	0.0	53.0	15.0	—	—
旋转抓取	24.0	20.0	32.0	**44.0**	26.0	—	42.0	3.0	30.0	37.0	—	—
遮挡抓取	30.0	28.0	37.0	51.0	**80.0**	—	34.0	0.0	44.0	36.0	—	—
移动容器	26.0	8.0	26.0	19.0	**39.0**	—	28.0	0.0	0.0	0.0	—	—
旋转容器	**0.0**	**0.0**	**0.0**	**0.0**	**0.0**	—	**0.0**	**0.0**	**0.0**	**0.0**	—	—
导线穿越	99.0	99.0	**100.0**	**100.0**	99.0	—	50.0	58.0	23.0	23.0	—	—
导线穿越（完整）	0.0	3.0	1.0	5.0	**12.0**	—	0.0	0.0	0.0	0.0	—	—
小球捕获	36.0	16.0	**46.0**	21.0	41.0	—	45.0	13.0	24.0	23.0	—	—
小球捕获（桌面）	71.0	81.0	**100.0**	**100.0**	88.0	—	99.0	88.0	98.0	**100.0**	—	—
滑块捕获	56.0	30.0	58.0	68.0	28.0	—	**71.0**	31.0	47.0	63.0	—	—
罐体捕获	91.0	31.0	98.0	99.0	72.0	—	**100.0**	5.0	96.0	**100.0**	—	—
撞击后抓取	42.0	5.0	49.0	**51.0**	39.0	—	21.0	22.0	43.0	20.0	—	—
任务等权	41.6	30.7	**53.8**	52.8	50.9	—	46.1	15.8	40.5	36.8	—	—
e_p (mm)	32.2	36.2	31.2	32.5	**30.0**	—	31.7	–	31.2	37.0	—	–
n	1110	941	1231	1187	1203	—	1115	439	1193	970	—	–

表 S4 按任务分解 ConMoto 结果。[所有方法都失败或基线优于 FoveaWAM 的任务，以及 FoveaWAM 的主要失败模式。]

C.2 时延

表 S5 列出全部配置在五个附加延迟点的结果，图 4 绘制其中一部分。

表 S5. **成功率随附加延迟的变化**：每点使用 1,400 个 ConMoto 留出场景（SR，%；实时协议）。0 与 150 ms 两列分别等于表 1 的原生与 +150 ms 列。粗体加蓝底与浅蓝底仅对已有结果排名，待测项不参与。

	附加延迟（ms）				
方法	0	50	100	150	200
ACT	41.6	43.5	36.5	24.3	16.5
Diffusion Policy	30.7	26.1	21.0	15.9	14.3
$\pi_{0.5}$	53.8	47.2	**39.6**	27.8	13.6
$\pi_{0.5}$ + SE(3)	52.8	39.8	32.4	28.2	15.1
DynamicVLA	50.9	46.4	30.6	23.4	17.8
PUMA	**59.6**	**53.2**	36.4	**31.1**	**27.1**
OpenWAM-α	46.1	36.1	27.9	24.7	22.1
OpenWAM-α (off)	15.8	13.7	14.2	10.4	9.5
DynamicWAM	40.5	27.6	25.0	20.6	20.9
DynamicWAM + SE(3)	36.8	30.6	23.9	21.9	21.3
FoveaWAM	—	—	—	—	—

计时。 表 S6 按阶段分解 FoveaWAM 的单次查询。

表 S6. **单次查询的延迟分解**（FoveaWAM，RTX 5090，ms；p50 / p95），batch 为 1，以及真机上的动作年龄。

阶段	p50	p95
位姿跟踪（每帧，真机）	—	—
图像编码	—	—
世界流（每次查询一次）	—	—
动作流（5 个 Euler 步）	—	—
出动作时间（合计）	—	—
预测头（仅训练，供参考）	—	—
执行时的动作年龄（真机）	—	—
超过 50 ms 的查询（真机，%）	—	

C.3 DOMINO 上的结果

我们使用 DOMINO [14] clean 一级设置的 24 个单臂 Franka 任务及其示范、场景与原生评测器。操作得分（MS）用离开工作空间或视野以及碰撞的惩罚来缩放路线完成度。FoveaWAM 读取指令所指目标在仿真器中的位姿，没有有效位姿的槽位被掩码（附录 A.1）；基于 RGB 的基线不接收这一位姿。

数据与适配。 所有方法共用 1,200 条训练与 240 条验证示范，通过 DOMINO 原生控制器执行绝对关节位置目标，并把状态与动作投影适配到其八维关节空间；归一化统计仅由训练数据计算。DynamicWAM 的官方采样器跳过长度不足以构成其窗口的示范，因此只有 1,054 条训练与 210 条验证示范参与其监督，有两个任务没有可用示范；测试集仍包含全部 24 个任务。DynamicWAM 以 global batch 128 训练 40,000 次更新。$\pi_{0.5}$ 从官方基座出发，以 global batch 256 训练 30,000 次更新，评测使用最终 EMA。PUMA 保留发布的权重与冻结的 teacher，以 global batch 64 训练，并按验证集动作 MSE 早停，选定第 6,000 步权重。[FoveaWAM：初始化、更新次数、batch 大小与检查点选择。]

C.4 消融对照

第 4.3 节的六个对照（图 5）各只改变表 S1 配置中的一个组件，数据、含检查点选择在内的配方以及执行器保持不变。去掉一项损失时同时去掉其预测头；无目标历史对照去掉目标状态槽位 0–6，保留存放当前位姿的槽位 7（附录 A.1）。统一精细流对照去掉 $\mathcal{L}_P$ 与位姿头，在每个 patch 内的 [4×4] 个点上（即 [56×56] 网格）监督场景流，标签来自同样的真值刚体运动。

C.5 对位姿噪声的鲁棒性

在权重冻结的条件下，我们评估三种对目标位姿的合成扰动：标称的时序相关噪声、两倍幅度的噪声，以及带连续缺失观测的标称噪声。标称过程由每回合固定的偏置与平稳相关分量组成，二者每轴的标准差均为 5 mm 与 1°，相关时间为 200 ms。缺失持续 200 ms，其间隔服从均值为 3.8 s 的几何分布，长期缺失比例为 5%。扰动作用于当前与过去的估计，在计算历史特征之前施加。

在相同留出场景与原生延迟下（图 S1），相对干净位姿，三种扰动下的 SR 分别变化 [X.X]、[X.X] 与 [X.X] 个百分点。

图占位：图 S1——位姿噪声

横轴：干净位姿、标称相关噪声、两倍幅度噪声、带缺失观测的标称噪声；纵轴：FoveaWAM 在各任务族上的 SR，冻结权重，实时协议；匹配场景上的配对区间。

图 S1. **对位姿噪声的鲁棒性。**在目标位姿的合成扰动下 FoveaWAM 的 SR，相对干净位姿。

D 真机实验

D.1 平台与任务

机器人为 Franka 机械臂（[型号]），配备 [夹爪型号] 与固定 RealSense D435 RGB-D 相机，通过 [带时间戳的笛卡尔接口] 以 [控制频率] 控制；一台固定的第三人称相机以 [分辨率与帧率] 录制 RGB-D，每次采集前用 [标定方法] 标定；配方使用腕部视角的基线另外获得 [腕部相机]。各任务装置轮流安装在这一平台上（图 6；表 S7）。

表 S7. **真机任务。**目标：被跟踪的物体。试验键：20 个测试键各自固定的内容。速度：由全部测试试验录制的 RGB-D 测得的目标速度（m/s，均值 ± 标准差）。抓取：物体被两指夹持并抬起 [X] cm。每个任务有 100 条训练示范与 20 条验证示范。

任务	目标	运动	试验键	速度	成功条件	时限（s）
T1	方块	传送带	[在带上的放置、带速]	—	抓取	[X]
T2	无盖盒	传送带	[盒子的放置、带速]	—	所持方块留在盒内	[X]
T3	边长不等的方块	转盘	[半径、初始角度与偏航、角速度]	—	沿短边抓取	[X]
T4	玩具小车	遥控，固定油门	[起始位姿、航向]	—	抓取	[X]
T5	网球	[运动机制]	[释放位置、运动设定]	—	抓取	[X]
T6	小车上的方块	倾斜轨道	[坡度、释放点]	—	抓取	[X]

D.2 位姿跟踪与标签

跟踪不使用标记，每个物体实例有一个米制网格；球体由球心与半径定义。首帧中，Grounding DINO [24] 定位任务所指的物体，SAM 2.1 [31] 分割它，FoundationPose [43] 注册其位姿；之后 Cutie [11] 传播掩码，FoundationPose 在每次更新时精修卡尔曼滤波的预测。掩码为空时估计无效，不沿用上一位姿，[丢失后的重新初始化]。跟踪器在每个控制周期边界用最新一帧更新，并保留该帧的采集时刻，目标状态 token 的有限差分基于这些时刻。

示范的目标状态输入由同一跟踪器在其录制的 RGB-D 上因果回放得到。位姿标签是未来周期边界上的跟踪位姿 [（在整个回合上离线精修）]，流标签来自 [录制 RGB-D 的 3D 点轨迹，做法同 DROID（附录 A.2）]。对于球体，目标状态 token 与位姿头只使用平移。在 FoveaWAM 的全部测试试验中，估计在 [X]% 的控制周期边界上无效，最长缺失 [X] s，重新初始化 [X] 次 [，主要集中在某任务]。

D.3 训练与评测协议

各基线的初始化、配方与动作块长度见表 S3，FoveaWAM 按附录 A.2 微调；DynamicWAM [是否使用实时分块执行]。示范、开发试验与测试试验来自不同的采集批次。

每个任务有 20 个预生成的试验键，固定物体实例、其初始位姿与装置设定。操作员参照参考图像重置场景后，四个方法对每个键以随机顺序连续运行，使装置的漂移不会与方法对齐。试验在成功、失败、安全中止或时限（约为该任务示范时长中位数的三倍）时结束。只有装置自身偏离试验键时（[实测速度超出设定的 ±X%，或装置故障]）才重做该键；其余情况都计为失败，包括 FoveaWAM 的跟踪

丢失。表 S6 同时给出真机上的动作年龄与超时比例。

D.4 结果与失败分析

表 S8. **真机成功率及其区间。**All：每个方法 120 次测试试验的成功率（%）及其 95% Wilson 区间。Δ：相对 FoveaWAM 的配对差值（百分点），区间在每个任务内按试验键自助法得到。逐任务成功率见表 3。

方法	All [95% CI]	Δ [95% CI]
$\pi_{0.5}$	—	—
DynamicWAM	—	—
ACT	—	—
FoveaWAM	—	–

图占位：图 S2——真机失败

(a) 按类别的失败（约 35% 宽）：每个方法（$\pi_{0.5}$、DynamicWAM、ACT、FoveaWAM ）一根横向堆叠条，长度为 120 次测试试验中的失败次数，分段固定依次为过晚、未对准、滑落/掉落、碰撞或安全中止、超时、跟踪丢失。**(b) 一个配对试验键**（约 65%）：两行各五帧未经修饰的第三人称画面，上行为 FoveaWAM （成功），下行为 [基线]（过晚），取第一条指令之后的相同时刻；标出夹爪闭合帧。

图 S2. **真机失败。**(a) 每个方法 120 次测试试验中按类别统计的失败。(b) [任务] 的一个试验键：FoveaWAM 抓住目标，而 [基线] 的夹爪在目标后方合拢（过晚）。所选试验键上，该基线以其最常见的失败类别失败；各帧取第一条指令之后的相同时刻。

表 S8 给出合并成功率及其区间，图 S2 给出失败情况。失败类别在测试试验前确定，都是可观察的事件：过晚（夹爪在目标后方合拢）、抓取未对准、接触后滑落或掉落、碰撞或安全中止、超时，以及跟踪丢失（仅 FoveaWAM ）。[各方法的主导失败类型及其对时延的说明；FoveaWAM 最常见的失败。]